

单位代码： 10293 密 级： _____

南京邮电大学
专 业 学 位 硕 士 论 文



论文题目： 基于 CNN 与 Transformer 混合架构的 GTZAN
音乐流派分类研究

学 号 1025040702

姓 名 顾宇轩

导 师 陈兴国

专业学位类别 _____

类 型 _____

专业（领域） *****

论文提交日期 _____

摘要

为解决音乐流派自动分类中的特征提取效率与模型泛化能力问题，本文基于 GTZAN 数据集开展深度学习模型对比研究。该数据集包含 10 类音乐流派，共计 1000 个 30 秒音频样本。首先通过 Librosa 工具提取 mel 频谱及一阶差分 mel 频谱作为核心特征；随后设计并实现了 5 种不同模型架构，包括基础 CNN、切片 CNN、LG-Attention Transformer、CNN-Transformer 混合模型及纯 Transformer，并采用 6:2:2 的数据集划分策略与固定随机种子（random_state=42）保证实验一致性。创新地提出”先划分数据集后音频切片”的预处理流程，避免数据泄露，并引入投票机制融合切片预测结果。实验结果表明，CNN-Transformer 混合模型取得最优性能，投票后准确率达 86.50%；切片 CNN 模型次之，准确率为 84.00%；而纯 Transformer 模型难以适应小数据集与局部特征提取需求，准确率仅 49.00%。混淆矩阵分析显示，分类错误主要集中于 country 与 rock 流派，这与 GTZAN 数据集存在的标签错误、跨类别重复等固有缺陷密切相关。本文的研究为小样本音频分类任务提供了有效的模型架构与数据预处理方案。

关键词：音乐分类,GTZAN 数据集,卷积神经网络,Transformer,mel 频谱,音频切片,注意力机制

Abstract

To address the issues of feature extraction efficiency and model generalization ability in automatic music genre classification, this paper conducts a comparative study of deep learning models based on the GTZAN dataset. The dataset consists of 10 music genres with a total of 1000 30-second audio samples. First, mel-spectrogram and first-order difference mel-spectrogram are extracted as core features using the Librosa tool. Subsequently, 5 different model architectures are designed and implemented, including Basic CNN, Segmented CNN, LG-Attention Transformer, CNN-Transformer Hybrid Model, and Pure Transformer. A 6:2:2 dataset splitting strategy and a fixed random seed (random_state=42) are adopted to ensure experimental consistency. Innovatively, a preprocessing workflow of "splitting the dataset first and then segmenting audio" is proposed to avoid data leakage, and a voting mechanism is introduced to fuse segment prediction results. Experimental results show that the CNN-Transformer Hybrid Model achieves the optimal performance with an accuracy of 86.50% after voting; the Segmented CNN Model ranks second with an accuracy of 84.00%; while the Pure Transformer Model only achieves an accuracy of 49.00% due to its difficulty in adapting to small datasets and local feature extraction requirements. Confusion matrix analysis indicates that classification errors are mainly concentrated between country and rock genres, which is closely related to the inherent flaws of the GTZAN dataset such as label errors and cross-category duplicates. This research provides an effective model architecture and data preprocessing scheme for small-sample audio classification tasks.

Key Words: Music Classification, GTZAN Dataset, Convolutional Neural Network (CNN), Transformer, Mel-Spectrogram, Audio Segmentation, Attention Mechanism

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
第一章 引言	1
1.1 研究背景与意义	1
1.1.1 章内标题 1.1.1	1
1.1.2 章内标题 1.1.2	1
1.2 研究现状	1
1.3 本文主要贡献	2
1.4 论文结构	2
第二章 相关技术背景	3
2.1 音频特征提取	3
2.2 卷积神经网络 (CNN)	3
2.3 Transformer 模型	4
2.4 混合架构设计思路	4
第三章 实验设计	5
3.1 实验环境	5
3.2 数据集介绍	5
3.3 数据预处理	5
3.3.1 特征提取	5
3.3.2 数据集划分	6
3.3.3 音频切片与投票机制	6
3.4 模型架构设计	6
3.4.1 基础 CNN 模型	6
3.4.2 切片 CNN 模型	6
3.4.3 LG-Attention Transformer 模型	7
3.4.4 CNN-Transformer 混合模型	7
3.4.5 纯 Transformer 模型	8
第四章 实验结果与分析	9
4.1 各模型性能对比	9
4.2 混淆矩阵分析	10
4.2.1 基础 CNN 模型混淆矩阵	10
4.2.2 切片 CNN 模型混淆矩阵	10
4.2.3 CNN-Transformer 混合模型混淆矩阵	10
4.2.4 纯 Transformer 模型混淆矩阵	11
4.3 性能影响因素分析	12
4.3.1 数据预处理策略的影响	12
4.3.2 模型架构的影响	12
4.3.3 数据集缺陷的影响	13

第五章 结论与展望	14
5.1 研究结论	14
5.2 未来展望	14
参考文献	16

插图索引

图 2.1	梅尔频谱图特征	3
图 3.1	CNN 模型结构	7
图 3.2	LG-Attention 层结构	7
图 3.3	CNN-Transformer 混合模型结构	8
图 4.1	基础 CNN 模型的混淆矩阵	10
图 4.2	切片识别的 CNN 模型混淆矩阵	11
图 4.3	CNN-Transformer 模型的混淆矩阵	11
图 4.4	纯 Transformer 模型的混淆矩阵	12

表格索引

表 4.1 各模型性能对比 9

第一章 引言

1.1 研究背景与意义

随着数字音乐产业的快速发展，全球音乐库规模呈指数级增长。据统计，主流音乐流媒体平台的曲库数量已突破数千万首，如何实现高效的音乐内容检索与管理成为行业核心需求。音乐流派分类作为音乐信息检索领域的基础任务，能够为个性化推荐、版权管理、音乐数据分析等应用提供技术支撑，具有重要的学术价值与实用意义。

传统音乐分类方法依赖人工设计特征（如 MFCC、谱质心、节奏强度等）与机器学习模型（SVM、随机森林等），但人工特征的表达能力有限，难以捕捉复杂音乐的深层语义信息。深度学习技术的兴起为音乐分类带来新的突破，卷积神经网络（CNN）凭借强大的局部特征提取能力在音频频域特征处理中表现突出，而 Transformer 模型通过自注意力机制实现了长序列依赖关系的建模，为捕捉音乐的全局结构特征提供了可能。

1.1.1 章内标题 1.1.1

《正文》*****

(1) 正文内一级序号（首行不缩进）《正文》*****

- (a) 正文内二级序号
- (b) 正文内二级序号

(2) 正文内一级序号（首行不缩进）《正文》*****

- (a) 正文内二级序号
- (b) 正文内二级序号

1.1.2 章内标题 1.1.2

《正文》*****

1.2 研究现状

现有深度学习音乐分类研究主要集中于特征工程与模型架构优化两大方向。在特征提取方面，mel 频谱因贴合人类听觉系统特性，成为音频分类的主流特征选择，部分研究通过融合

一阶 / 二阶差分频谱进一步提升特征区分度。在模型架构方面, CNN 模型通过卷积与池化操作有效提取音频的局部频谱模式, 是早期深度学习音乐分类的主流方案; Transformer 模型自 2017 年提出以来, 被广泛应用于自然语言处理与计算机视觉领域^[1], 近年逐步拓展至音频任务, 部分研究尝试将 CNN 与 Transformer 结合^[2], 利用 CNN 提取局部特征、Transformer 建模全局依赖, 取得了优于单一模型的性能。

1.3 本文主要贡献

本文针对现有研究的不足, 开展了系统的音乐流派分类研究, 主要贡献如下:

- (1) 提出”先划分数据集后音频切片”的预处理策略, 结合投票机制, 有效避免数据泄露的同时提升了模型对完整音频的分类性能;
- (2) 设计并实现了 5 种不同架构的深度学习模型, 涵盖单一 CNN、单一 Transformer、混合架构等类型, 通过充分对比实验验证了各模型的适应性;
- (3) 深入分析了 GTZAN 数据集的固有缺陷对分类性能的影响, 为同类研究提供了数据集选择与结果解读的参考;
- (4) 验证了 CNN 与 Transformer 混合架构在小样本音频分类任务中的优势, 其核心在于兼顾局部频谱特征提取与全局时序依赖建模。

1.4 论文结构

本文后续章节安排如下: 第 2 章介绍相关技术背景, 包括特征提取方法、CNN 与 Transformer 核心原理; 第 3 章详细描述实验设计, 包括数据集、实验环境、数据预处理流程与各模型结构; 第 4 章呈现实验结果并进行深入分析; 第 5 章总结研究结论并提出未来改进方向。

第二章 相关技术背景

2.1 音频特征提取

音频信号是典型的时序信号，直接输入深度学习模型难以有效捕捉关键特征。通常需要将其转换至频域或时频域进行处理，常用方法包括傅里叶变换、短时傅里叶变换（STFT）与 mel 频谱分析。

mel 频谱通过模拟人类听觉系统对不同频率声音的感知灵敏度，将线性频率刻度转换为非线性的 mel 刻度，能够更有效地突出音频的语义相关特征。其计算过程如下：首先对音频信号进行预加重与分帧加窗，通过 STFT 得到功率谱；随后将功率谱通过 mel 滤波器组，计算每个滤波器的对数能量，最终得到 mel 频谱矩阵。

一阶差分 mel 频谱通过计算相邻时间帧 mel 频谱的差值得到，能够捕捉频谱的动态变化特征，与静态 mel 频谱结合使用可丰富特征维度，提升模型的区别能力。本文通过 Librosa 工具实现上述特征的提取与可视化，提取的 mel 频谱特征如图2.1所示。




图 2.1 梅尔频谱图特征

2.2 卷积神经网络（CNN）

CNN 是一类专门用于处理网格结构数据的深度学习模型，其核心优势在于通过局部感受野、权重共享与池化操作，高效提取局部特征并降低模型复杂度。在音频分类任务中，mel 频

谱可视为二维网格数据（频率 $\times$ 时间），CNN 能够有效捕捉不同频率通道的局部关联与频谱纹理特征。

典型的 CNN 模型由卷积层、激活函数、池化层与全连接层组成：卷积层通过卷积核与输入特征图的局部区域进行卷积运算，生成包含局部特征的特征图；ReLU 激活函数用于引入非线性，增强模型表达能力；池化层（如最大池化）通过下采样操作减少特征维度，提升模型泛化能力；全连接层将池化后的特征映射至类别空间，实现分类预测。

2.3 Transformer 模型

Transformer 模型基于自注意力机制（Self-Attention）构建，由 Google 团队在 2017 年提出，最初用于自然语言处理任务。其核心优势在于能够并行计算，并通过自注意力机制捕捉序列数据的全局依赖关系^[3]。

Transformer 编码器的基本单元包含两层：多头自注意力层（Multi-Head Attention）与前馈网络（FFN）。多头自注意力层通过多个注意力头并行计算，捕捉不同尺度的依赖关系；前馈网络由两个线性变换与 ReLU 激活函数组成，对每个位置的特征进行独立处理。为适应时序数据，Transformer 需引入位置编码（Positional Encoding），将位置信息注入输入特征中。

LG-Attention 是对标准 Transformer 的改进，将前馈网络替换为 CNN 层，试图同时捕捉局部特征与全局依赖^[4]。但该结构存在内在任务冲突，可能导致两方面性能均受影响。并且该论文数据集划分不规范，且未验证小数据场景下的适应性。

2.4 混合架构设计思路

CNN 擅长提取局部特征，但难以捕捉长时序依赖；Transformer 擅长建模全局关系，但在小数据集场景下易过拟合且局部特征提取能力不足。基于此，混合架构的核心思路是将两者优势结合：通过 CNN 提取局部频谱特征，减少输入序列长度；将 CNN 输出转换为序列 token，通过 Transformer 捕捉全局时序依赖；最终通过全连接层实现分类预测。

第三章 实验设计

3.1 实验环境

本文实验基于以下软硬件环境搭建：操作系统：Windows 11；显卡：NVIDIA RTX 5060；编程语言：Python 3.12.11；深度学习框架：PyTorch 2.8

3.2 数据集介绍

本文采用 GTZAN 数据集作为实验基准数据集，该数据集是音乐分类领域应用最广泛的标准数据集之一。数据集包含 10 个音乐流派，分别为 blues、classical、country、disco、hiphop、jazz、metal、pop、reggae、rock，每类流派包含 100 个音频样本，共计 1000 个样本。每个音频样本的时长为 30 秒。本文中采样率设置为 22050Hz。

需要注意的是，GTZAN 数据集存在固有缺陷^[5]，具体包括：（1）10.6% 的样本存在标签错误；（2）7.2% 的样本源自同一录音，其中 5% 为跨类别重复；（3）部分流派存在严重的艺术家集中现象，如 Reggae 类 35 个样本为 Bob Marley 作品，Pop 类 24 个样本为 Britney Spears 作品。这些缺陷会对模型分类性能产生一定影响，在结果分析中需重点考虑。

3.3 数据预处理

3.3.1 特征提取

本文采用 mel 频谱与一阶差分 mel 频谱作为核心特征，具体提取流程为：

- （1）音频加载：使用 Librosa 加载音频文件，获取采样率与音频时间序列；
- （2）mel 特征频谱：计算 STFT (Short-Time Fourier Transform), 参数 $n_fft=1024$, $hop_length=512$ 。映射到 Mel 刻度 $n_mels=128$ 。使用 `librosa.power_to_db` 将功率谱转换为分贝 (dB) 单位，得到 Log Mel。
- （3）一阶差分 mel 频谱：计算 Log Mel 频谱的一阶导数，捕捉声音的动态变化趋势。提取的特征维度为 $[2, 128, 1292]$ ，其中 2 代表特征通道数（mel 频谱 + 一阶差分），128 代表 mel 滤波器数量，1292 代表时间帧数量（对应 30 秒完整音频）
- （4）归一化：在加载整个数据集后，进行全局最小-最大归一化 (Min-Max Normalization)，将所有特征值缩放到 $[0, 1]$ 区间。

3.3.2 数据集划分

为保证实验的公平性与可重复性，本文采用固定比例的数据集划分策略：将 1000 个音频样本按 6:2:2 的比例划分为训练集（600 个）、验证集（200 个）、测试集（200 个）。所有实验中随机种子均设置为 `random_state=42`，确保数据划分结果与模型训练过程的一致性。

3.3.3 音频切片与投票机制

针对 30 秒完整音频时间域维度过大导致的 CNN 特征提取困难问题，本文借鉴了林怡的音频切片策略^[4]，但是该论文采用的手动切片方法并不能代表一般情况，因此本文调整了切片的策略。我的切片逻辑是将每个 30 秒音频均匀切分为 6 个 5 秒的短切片，每个切片对应特征维度为 [2, 128, 216]。对测试集中的每个原始音频，模型先对其 6 个切片分别进行分类预测，得到 6 个预测类别。之后统计各类别的预测次数，将得票最多的类别作为该音频的最终分类结果。

为了避免数据泄露，本文采用“先划分数据集后切片”的流程，即先将原始音频划分为训练集、验证集、测试集，再对各集合内的音频分别进行切片。该流程可避免同一首音频的不同切片同时出现在训练集与测试集，确保模型泛化能力评估的准确性。

3.4 模型架构设计

本文设计并实现了 5 种不同架构的深度学习模型，所有模型均基于 PyTorch 框架构建，具体结构如下：

3.4.1 基础 CNN 模型

该模型为基于完整音频特征的 CNN 分类模型，核心用于验证基础深度学习架构在音乐分类任务中的性能上限。模型输入 [batch_size, 2, 128, 1292] 维度的特征输入，输出 10 类流派的概率分布。模型结构如图 3.1 所示。卷积操作有三个结构相似的块，每块包括卷积层、批归一化、非线性层 ReLU、池化层。之后经过全连接层（FC）和 softmax 输出，得到音乐的分类结果。

3.4.2 切片 CNN 模型

该模型基于音频切片特征训练，结构与基础 CNN 模型一致。由于输入的是 5s 的音频片段，因此输入维度调整为 [batch_size, 2, 128, 216]。训练过程仅针对单个切片进行分类，测试阶段通过投票机制融合 6 个切片的预测结果，得到原始音频的分类标签。




图 3.1 CNN 模型结构

3.4.3 LG-Attention Transformer 模型

该模型复现了 LG-Attention 结构^[4]，基于标准 Transformer 编码器改进，LG-Attention 层的具体结构如图3.2所示。




图 3.2 LG-Attention 层结构

输入时将 [2, 128, 216] 的切片特征拼接成 [256, 216] 的序列格式，使用位置编码注入时序信息。之后经过 2-8 层的 LG-Attention 层，每层将标准 TransformerEncoder 的 FFN 替换为 CNN 模块。输出时与上面的 cnn 模型类似，也是通过全局池化和全连接层，最后 Softmax 输出。

3.4.4 CNN-Transformer 混合模型

该模型结合 CNN 的局部特征提取能力与 Transformer 的全局依赖建模能力^[2]，结构设计如图3.3所示。

输入的特征形状仍然是 $[2, 128, 216]$ ，经过卷积和池化，变成 $[128, 27]$ 的形状，接下来是标准的 TransformerEncoder 层，和官方论文一致^[3]。位置编码使用标准正弦余弦位置编码

形式。Transformer 编码器包含多头自注意力层（8 个头）与 FFN（前馈网络）。输出时也是通过全局池化和全连接层，最后 Softmax 输出




图 3.3 CNN-Transformer 混合模型结构

3.4.5 纯 Transformer 模型

该模型为消融实验对照组，用于验证 Transformer 单独在音乐分类任务中的性能。cnn 单独的性能已经在 3.4.2 中验证，不再做消融实验。

该模型与 CNN-Transformer 混合模型类似，只是移除了 CNN 的相关模块。

输入时将 $[2, 128, 216]$ 的音频切片特征展平为 $[256, 216]$ ，相当于有 216 个位置，每个位置的输入是一个长度为 256 的向量。之后使用正弦位置编码，以及 3 层 Transformer 编码器，结构与混合模型一致。

第四章 实验结果与分析

4.1 各模型性能对比

本文所有模型均经过 50 个 epoch 的训练，最终测试性能如表4.1所示。性能指标包括单个切片的测试准确率（Segments Accuracy）与基于投票机制的轨道级测试准确率（Tracks Voting Accuracy），其中轨道级准确率更能反映模型对完整音频的分类能力。

表 4.1 各模型性能对比

模型名称	切片测试 准确率 (%)	轨道投票 准确率 (%)	核心优势	主要不足
基础 CNN 模型	—	74.50	结构简单, 训练稳定	时间域过大, 特征提取困难
切片 CNN 模型	80.25	84.00	局部特征捕捉能力强, 效率高	缺乏全局时序依赖建模
LG-Attention Trans- former	56.08	62.50	尝试融合局部与全局特征	结构冲突, 小数据适应性差
CNN-Transformer 混 合模型	80.08	86.50	兼顾局部特征与全局依赖	模型复杂度较高
纯 Transformer 模型	45.17	49.00	全局依赖建模能力强	局部特征提取弱, 易过拟合

从表4.1可以看出，切片策略显著提升了 CNN 模型的性能，轨道投票准确率从 74.50% 提升至 84.00%，即使是单个 5 秒的切片准确率也提升至 80.25%，验证了时间域过大导致特征提取困难的假设，这说明一个切片的时间已经足够体现音频特征。

CNN-Transformer 混合模型取得最优性能，轨道投票准确率达 86.50%，说明局部特征提取与全局依赖建模的结合能够有效提升分类性能。相比之下，纯 Transformer 模型性能最差，切片准确率仅 45.17%，轨道投票准确率 49.00%，表明在小数据集场景下，Transformer 缺乏有效的局部特征提取能力，难以捕捉音频的频谱纹理特征。

LG-Attention Transformer 模型性能未达预期，我在本任务尝试了 2 到 8 层的 LG-Attention 层，最优准确率仅 62.50%。虽然在相同注意力层数下，其性能比传统 Transformer 略好，但是远不如 CNN-Transformer 混合模型。这说明该结构存在的内在矛盾，CNN 子层与自注意力层的任务目标不一致。且该结构对数据量要求较高，在 GTZAN 这种小数据集未做数据增强时难以发挥作用。

4.2 混淆矩阵分析

混淆矩阵能够直观反映模型对各类别的分类效果，本文对 4 个核心模型（基础 CNN、切片 CNN、CNN-Transformer 混合模型、纯 Transformer）进行了混淆矩阵可视化，具体结果如下。

4.2.1 基础 CNN 模型混淆矩阵

基础 CNN 模型的混淆矩阵如图4.1所示。对部分类别的分类准确率较高，可达到 90%，这些音乐的频谱特征差异显著。对 country 与 rock 类别的混淆较为严重，这两类音乐的节奏型与乐器配置较为相似。对 reggae 类别的分类准确率中等，可能是受数据集艺术家集中现象影响，部分样本特征过于单一。




图 4.1 基础 CNN 模型的混淆矩阵

4.2.2 切片 CNN 模型混淆矩阵

切片 CNN 模型的混淆矩阵如图4.2所示。对比切片与基础 CNN 模型的混淆矩阵可以发现，country 与 rock 的识别准确率仍然不佳。有可能是这两类音频特征比较相似，切片后更加难以分辨属于哪一类。

尽管存在一定弊端，切片 CNN 仍有效提升了其他类别的识别准确率。投票机制通过多切片的结果融合，减少了单一切片的随机误差，提升了模型的稳定性。切片级混淆矩阵中，部分类别（如 hiphop、jazz）存在一定比例的随机错误，投票后这类错误显著减少。

4.2.3 CNN-Transformer 混合模型混淆矩阵

CNN-Transformer 混合模型的混淆矩阵如图4.3所示。轨道投票混淆矩阵中，classical、hiphop、metal、pop 类别的准确率均超过 90%，country 类别的识别准确率比纯 CNN 模型大幅上升。整




图 4.2 切片识别的 CNN 模型混淆矩阵

体混淆程度最低，各类别准确率分布更均衡，验证了混合架构的优越性。这说明 Transformer 捕捉的长距离依赖能够有效区分音乐的节奏结构差异。




图 4.3 CNN-Transformer 模型的混淆矩阵

4.2.4 纯 Transformer 模型混淆矩阵

纯 Transformer 模型的混淆矩阵如图4.4所示。纯 Transformer 模型的混淆矩阵显示，尽管整体准确率较低，但对 classical、metal、pop 类别的识别准确率仍超过 70%，这三类音乐的长距离结构特征最为显著。

不过，纯 Transformer 对其他类型的混淆极为严重，缺乏局部特征提取能力导致模型无法区分细微的频谱差异。投票机制对性能提升有限，整体的全局依赖建模难以弥补局部特征的缺失。




图 4.4 纯 Transformer 模型的混淆矩阵

4.3 性能影响因素分析

4.3.1 数据预处理策略的影响

先划分后切片的预处理策略是准确评估性能的基础。若采用先切片后划分的策略，同一音频的不同切片可能分布在训练集与测试集，导致模型提前学习到测试集特征，测试准确率会虚高（预估可达 90% 以上），但泛化能力极差。本文的策略有效避免了数据泄露，确保了实验结果的真实性。

投票机制通过多切片结果融合，降低了单一切片的随机误差与局部特征缺失的影响。从实验结果看，投票机制平均提升了 3-5 个百分点的准确率，且模型越复杂，投票机制的效果越显著。

4.3.2 模型架构的影响

CNN 的局部特征提取能力是音乐分类的基础，无论是切片 CNN 还是混合模型，CNN 模块均承担了核心的特征提取任务。纯 Transformer 模型的低性能证明，在音频分类任务中，局部频谱特征的重要性高于全局时序依赖。

Transformer 的长距离依赖建模在混合模型中起到了补充作用，能够捕捉不同时间片段的关联特征，尤其是对结构复杂的音乐提升了分类准确率。但 Transformer 的层数并非越多越好，实验中 3 层 Transformer 编码器已能达到最优性能，增加层数会导致模型过拟合。

LG-Attention 结构的失败表明，局部特征提取与全局依赖建模应采用分离式设计（如混合模型的 CNN+Transformer 串行结构），而将 FFN 替换为 CNN 的融合式设计是不合理的。将 CNN 结构全部设置在 Transformer 编码器前面能够有效避免任务冲突。

4.3.3 数据集缺陷的影响

GTZAN 数据集的固有缺陷是分类性能难以突破 90% 的重要原因。标签错误导致模型训练过程中学习到错误的特征关联，部分样本的分类错误无法通过模型优化解决。

跨类别重复样本使得模型难以区分相似录音的流派差异。艺术家集中现象导致部分类别的特征多样性不足，模型学到的特征具有局限性，泛化能力受限。

第五章 结论与展望

5.1 研究结论

本文基于 GTZAN 数据集开展了系统的音乐流派分类研究，通过设计不同架构的深度学习模型与规范的数据预处理流程，得出以下结论：

- (1) 数据预处理策略对分类性能至关重要，先划分数据集后音频切片的流程能够有效避免数据泄露，保证测试的公平性。投票机制能够融合多切片特征，提升完整音频的分类准确率。
- (2) CNN 在音频局部特征提取方面具有不可替代的优势，切片 CNN 模型通过降低时间域维度，显著提升了分类性能，轨道投票准确率达 84.00%
- (3) CNN-Transformer 混合架构是最优选择，通过 CNN 提取局部频谱特征、Transformer 建模全局时序依赖，实现了 86.50% 的轨道投票准确率，且收敛稳定、泛化能力强。
- (4) 纯 Transformer 模型与 LG-Attention Transformer 模型在小数据集场景下表现不佳。前者缺乏局部特征提取能力，后者虽然性能略强于纯 Transformer，但是存在结构设计冲突。
- (5) GTZAN 数据集的固有缺陷（标签错误、重复样本、艺术家集中）限制了分类性能的进一步提升，同类研究应关注更高质量的数据集。

5.2 未来展望

本文的研究仍存在一定的改进空间，未来可从以下方向展开：

- (1) 数据增强：引入音频数据增强技术（如噪声添加、音调偏移、时间拉伸等），扩大数据集规模，缓解小数据集过拟合问题，尤其可提升 Transformer 模型的性能。值得注意的是，数据增强也应该在划分数据集之后进行，只能对训练集进行增强，以保证测试的公平性。
- (2) 特征优化：融合更多类型的音频特征（如 MFCC、谱质心、节奏特征等），构建多模态特征输入，丰富特征表达能力。
- (3) 模型优化：优化混合模型的结构，如采用注意力机制增强 CNN 的特征选择能力、引入自适应切片策略，根据音乐节奏动态调整切片位置。

- (4) 迁移学习：利用预训练模型（如在大规模音频数据集上预训练的 Transformer 模型）进行迁移学习，提升小数据集场景下 Transformer 的模型性能。

参考文献

- [1] 李翔, 张涛, 张哲, 等. Transformer 在计算机视觉领域的研究综述[J]. 计算机工程与应用, 2023, 59(1): 14.
- [2] Chen J, Wu P, Zhang X, et al. Add-vit: Cnn-transformer hybrid architecture for small data paradigm processing [J]. Neural Processing Letters, 2024, 56(3): 1–17.
- [3] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. arXiv, 2017.
- [4] 林怡, 徐超兰, 龙桂铃. 使用自注意力机制及数据增强策略的乐曲风格识别方法[J]. 应用声学, 2025(3).
- [5] Sturm B L. An analysis of the gtzan music genre dataset[J]. ACM, 2012.