

单位代码： 10293 密 级： 秘密

南京邮电大学
专 业 学 位 硕 士 论 文



论文题目： 基于深度卷积神经网络的恒星-类星体分类

学 号	<u>1025040705</u>
姓 名	<u>江民央</u>
导 师	<u>邹志强</u>
专业学位论文类别	<u>学硕</u>
类 型	<u>专业学位论文</u>
专业（领域）	<u>电子信息</u>
论文提交日期	<u>2026 年 6 月</u>

摘要

恒星与类星体的高效区分是大规模光学巡天数据分析中的基础任务。针对传统方法在自动化程度与泛化能力方面的不足，本文基于斯隆数字巡天（Sloan Digital Sky Survey, SDSS）的 RGB 巡天图像，提出了一种基于卷积神经网络的恒星-类星体二分类方法。本文构建了高置信度标注数据集，并采用迁移学习策略训练 ResNet-18 模型。实验结果表明，该方法在独立测试集上取得了约 85% 的总体分类准确率，并在 ROC 曲线、AUC 指标以及精确率-召回率曲线等方面表现稳定。进一步地，本文通过 t-SNE 特征可视化和 Grad-CAM 激活热力图对模型进行可解释性分析，结果显示网络能够捕获具有物理意义的判别特征，从而区分点源形态明显的恒星与空间结构更复杂的类星体。上述结果表明，基于 RGB 巡天图像的深度学习方法能够为现代天文巡天中的恒星-类星体自动分类提供一种有效、可解释且可扩展的解决方案。

关键词：恒星-类星体分类，卷积神经网络，图像分类，ResNet-18，可解释性分析

Abstract

Efficient discrimination between stars and quasars is a fundamental task in the analysis of large-scale optical survey data. To address the limitations of traditional methods in automation and generalization, this work presents a convolutional neural network based approach for star–quasar binary classification using RGB survey images from the Sloan Digital Sky Survey (SDSS). A high-confidence labeled dataset is constructed, and a ResNet-18 model is trained with transfer learning. The proposed method achieves an overall classification accuracy of approximately 85% on an independent test set, with stable performance in terms of ROC, AUC, and precision–recall metrics. Further interpretability analyses using t-SNE feature visualization and Grad-CAM activation maps demonstrate that the network effectively captures physically meaningful characteristics, distinguishing point-like stellar sources from quasars with more complex spatial structures. These results indicate that deep learning methods based on RGB survey images provide an effective, interpretable, and scalable solution for automated star–quasar classification in modern astronomical surveys.

Key Words: Star–quasar classification, convolutional neural networks, image-based classification, ResNet-18, interpretability analysis

目 录

摘要	I
Abstract	II
插图索引	IV
第一章 绪论	1
1.1 研究背景与意义	1
1.2 研究内容	1
1.3 论文结构安排	2
第二章 数据与样本构建	3
2.1 巡天数据与样本来源	3
2.2 RGB 图像构建与预处理	3
2.3 样本划分策略	3
2.4 数据集特点与分类挑战	3
第三章 基于卷积神经网络的分类方法	4
3.1 问题定义	4
3.2 网络结构	4
3.3 迁移学习策略	4
3.4 模型训练与优化	4
3.5 模型可解释性分析	5
第四章 实验结果与分析	6
4.1 整体分类性能	6
4.2 特征空间可视化分析	7
4.3 Grad-CAM 激活响应分析	9
第五章 结论与展望	10
5.1 研究结论	10
5.2 未来展望	10
参考文献	12

插图索引

图 4.1	恒星—类星体分类任务的归一化混淆矩阵	6
图 4.2	恒星—类星体分类模型的 ROC 曲线	7
图 4.3	恒星—类星体分类模型的 PR 曲线	8
图 4.4	基于 ResNet-18 高层特征的 t-SNE 可视化结果	8
图 4.5	Grad-CAM 对典型样本的局部响应可视化	9

第一章 绪论

1.1 研究背景与意义

随着现代天文巡天工程的快速发展，斯隆数字巡天（Sloan Digital Sky Survey, SDSS）和大天区面积多目标光纤光谱望远镜（Large Sky Area Multi-Object Fiber Spectroscopic Telescope, LAMOST）等项目持续产生大规模观测数据，天体图像与光谱数据量呈指数级增长。在此背景下，依赖人工检查或简单统计判据的传统天体分类方法已经难以满足大规模数据分析的需求^[1,2]。恒星和类星体是天文学研究中的两类重要天体，二者的准确区分对于后续物理性质分析、宇宙学研究以及巡天目标选择具有重要意义。

经典的恒星-类星体分类方法通常依赖测光颜色空间中的经验切分规则，或依赖星像形态参数进行判别。然而，在暗弱源、低信噪比或复杂观测条件下，恒星与类星体在成像形态上的差异会显著减弱，传统方法的分类性能容易下降。此外，这类方法通常依赖人工设计特征，因而对测光误差、背景噪声和观测条件变化较为敏感，泛化能力有限。

近年来，计算机视觉技术快速发展，卷积神经网络（Convolutional Neural Network, CNN）已经成为图像分类任务中的主流方法。CNN 能够直接从原始像素级数据中自动学习具有判别能力的特征，显著降低对人工特征工程的依赖。在天文学领域，深度学习已经被成功应用于星系形态分类、光谱分类和红移估计等任务^[3,4]。对于恒星-类星体分类任务，已有研究尝试将 CNN 与传统机器学习方法结合，同时利用深度图像特征和传统光学特征以提升分类性能；也有研究表明，面向紧致天体的深度模型能够在 SDSS 数据上有效区分恒星、类星体与紧致星系，尤其在暗弱目标分类中具有较强潜力。

1.2 研究内容

本文以 RGB 巡天图像为输入，采用 ResNet-18 卷积神经网络作为分类器，对恒星和类星体进行二分类研究。与基于颜色切分或形态参数阈值的传统方法不同，本文方法直接从图像数据中自动提取判别特征，并通过端到端训练获得分类模型。具体研究内容包括：

- 构建用于恒星-类星体分类的高置信度标注数据集，并利用天体坐标批量获取对应的 RGB 巡天图像；
- 采用迁移学习策略训练 ResNet-18 模型，利用交叉熵损失函数和梯度优化方法完成二分类学习；
- 通过准确率、混淆矩阵、ROC 曲线、AUC 指标和 PR 曲线对模型性能进行定量评估；
- 使用 t-SNE 特征可视化和 Grad-CAM 激活热力图分析模型内部表示与决策依据，验证其分类依据是否具有合理的天体物理解释。

1.3 论文结构安排

本文后续章节安排如下：第二章介绍数据来源、RGB 图像构建、样本划分策略以及数据集特点；第三章介绍基于 ResNet-18 的恒星-类星体分类方法，包括网络结构、迁移学习策略、模型训练与可解释性分析方法；第四章给出实验结果与分析，重点讨论模型的整体分类性能、特征空间分布以及 Grad-CAM 可视化结果；第五章总结全文，并对后续可能的研究方向进行展望。

第二章 数据与样本构建

2.1 巡天数据与样本来源

本文所使用的数据来自大规模光学巡天项目。以 SDSS 为代表的现代巡天项目通过统一的观测策略和标准化的数据处理流程，为天体分类研究提供了高质量的成像数据和光谱数据^[5,6]。SDSS 对天空进行了 u 、 g 、 r 、 i 、 z 五个测光波段的系统观测，并为大量天体提供了光谱分类标签，因此是恒星-类星体监督学习研究中最常用的数据来源之一。

本文中恒星与类星体的类别标签来自已有的高置信度分类结果，例如光谱认证结果，并将其作为监督学习任务中的真实标签。为了尽量降低标签不确定性对模型训练和评估的影响，样本构建过程中仅选取分类可靠的天体目标参与模型训练和测试。

2.2 RGB 图像构建与预处理

为了充分发挥卷积神经网络在图像特征学习方面的优势，本文采用 RGB 格式巡天图像作为模型输入。具体而言，首先收集约 20000 条星表记录，其中包含天体的 objID、赤经 (Right Ascension, RA) 和赤纬 (Declination, Dec) 等关键信息。随后，依据星表中给出的天球坐标，通过 SDSS 图像裁剪服务批量下载对应的 RGB 图像。这种处理方式已经在基于深度学习的天文图像研究中被广泛采用，既能够保留目标的重要物理信息，又能够满足通用计算机视觉模型的输入要求^[3,4]。

所有图像均通过一致的数据处理流程生成，并统一裁剪为 64×64 像素大小，以保证输入尺度的一致性。在模型训练前，对图像执行标准化等预处理操作，使不同样本的像素分布更加稳定，从而提升训练稳定性并加快模型收敛。

2.3 样本划分策略

在数据集构建过程中，本文按照天体目标进行训练集、验证集和测试集划分，确保同一天体目标的图像不会同时出现在多个数据子集中。该策略对于天文图像分类任务尤为重要，因为它能够有效避免潜在的信息泄漏，从而保证模型评估结果的可靠性和泛化性。

其中，训练集用于模型参数学习，验证集用于模型超参数调节，测试集仅用于最终性能评估。不同子集中的类别比例保持基本一致，以降低类别不平衡对实验结果的影响。

2.4 数据集特点与分类挑战

需要指出的是，在巡天图像中，恒星和类星体通常都表现为紧致源，尤其在暗弱星等范围内，二者的形态差异会变得更加细微，这给分类任务带来了显著挑战。此外，观测噪声、背景污染、邻近天体干扰和成像伪影都可能进一步降低图像质量。因此，恒星-类星体分类任务不仅考验模型的判别能力，也对模型的鲁棒性和泛化性能提出了较高要求。

第三章 基于卷积神经网络的分类方法

3.1 问题定义

本文将恒星与类星体区分建模为监督学习框架下的二分类问题。给定一幅包含目标天体的 RGB 巡天图像，模型需要判断该天体属于恒星类别还是类星体类别，并输出对应的分类概率。由于输入数据为二维图像，而恒星与类星体在图像形态结构和颜色分布上的差异相对细微，因此卷积神经网络能够为自动特征提取与分类提供自然且有效的解决方案。

3.2 网络结构

本文采用 ResNet-18 卷积神经网络作为分类模型的主干网络。ResNet 通过引入残差连接，有效缓解了深层网络训练过程中的梯度消失和性能退化问题，使模型能够在保持较低复杂度的同时学习高层判别特征。由于 ResNet-18 的网络结构较为紧凑、参数量适中，因此能够在分类性能与计算效率之间取得较好平衡，适合用于中等规模的天文图像分类实验。

在具体实现中，网络以三通道 RGB 图像作为输入，并通过多层卷积与池化操作逐步提取空间特征。随后，模型通过全局平均池化层将空间特征聚合为全局特征表示，并利用全连接层输出恒星和类星体两个类别的分类结果。最终，softmax 函数将网络输出映射为两个类别上的概率分布。

3.3 迁移学习策略

考虑到天文数据标注成本较高且样本数量相对有限，本文采用迁移学习策略训练模型。具体而言，ResNet-18 网络首先使用在 ImageNet 数据集上预训练得到的权重进行初始化。虽然 ImageNet 图像与天文图像在内容上存在显著差异，但预训练模型在底层学习到的边缘、纹理和局部结构等特征仍具有一定可迁移性，能够为天文图像分析提供有益的初始化。

在训练过程中，模型基于预训练权重进行微调，使网络逐步适应巡天图像中恒星和类星体的形态特征。这一策略能够有效加速模型收敛，并在一定程度上提升模型的泛化能力。

3.4 模型训练与优化

本文采用交叉熵损失函数作为优化目标，用于衡量模型预测结果与真实类别标签之间的差异。给定输入图像 x 及其真实标签 y ，模型输出类别概率分布 $p(y | x)$ ，交叉熵损失可表示为：

$$L = - \sum_{c=1}^C y_c \log p_c, \quad (3.1)$$

其中， C 表示类别数，本文中 $C = 2$ ； y_c 为真实标签的 one-hot 表示， p_c 为模型对第 c 类

的预测概率。训练过程中，采用自适应梯度优化算法迭代更新网络参数。为增强训练稳定性并缓解过拟合，在训练阶段引入标准数据增强和正则化策略。

模型在训练集上完成参数学习，并利用验证集进行模型参数与超参数调整。测试集仅用于最终性能评估，以保证实验结果的客观性和可靠性。

3.5 模型可解释性分析

为了进一步理解训练后模型的决策过程，本文引入多种可视化技术进行可解释性分析。首先，对网络在最终全连接层之前提取的高层特征应用 t-SNE 降维方法，以观察恒星和类星体样本在学习特征空间中的分布情况。其次，采用 Grad-CAM 方法生成类别相关的显著性热力图，以揭示模型在做出分类决策时重点关注的图像区域。上述可解释性分析有助于验证模型是否学习到了与天体物理特征一致的判别信息，并为后续实验结果分析提供直观依据。

第四章 实验结果与分析

4.1 整体分类性能

为了系统评估所提出模型在恒星-类星体二分类任务中的性能，本文在独立测试集上进行了定量分析。实验采用多种常用分类评价指标，包括总体分类准确率、混淆矩阵、受试者工作特征曲线 (Receiver Operating Characteristic, ROC) 和精确率-召回率曲线 (Precision-Recall, PR)，从不同角度对模型性能进行综合评价。

从总体分类准确率来看，基于 ResNet-18 的模型在测试集上取得了 84.9% 的准确率，说明所提出方法能够较为有效地区分恒星和类星体。为了进一步分析模型在不同类别上的分类行为，本文绘制了对应的混淆矩阵。如图4.1所示，大多数恒星样本和类星体样本均被模型正确分类，仍然存在一部分误分类样本，这些错误主要集中在形态特征高度相似的目标中。




图 4.1 恒星-类星体分类任务的归一化混淆矩阵

考虑到恒星和类星体之间可能存在类别不均衡，仅使用总体准确率无法完全刻画模型性能。因此，本文进一步使用 ROC 曲线和 PR 曲线分析模型在不同决策阈值下的分类表现。图4.2显示，模型在较宽阈值范围内均保持了较强的判别能力，其性能显著优于随机分类器。

ROC 曲线下面积 AUC 反映了两类样本之间较高的可分性。




图 4.2 恒星-类星体分类模型的 ROC 曲线

与此同时，PR 曲线更加关注正类样本，即类星体样本的识别性能。如图4.3所示，模型在保持较高召回率的同时仍能够维持较高精确率，说明该方法在类星体候选体筛选任务中具有一定实际应用价值。在真实巡天应用中，样本完备性与纯净度之间通常需要取得平衡，因此 PR 曲线结果具有重要参考意义。

总体而言，基于 RGB 巡天图像的卷积神经网络模型在多种评价指标上均表现出稳定可靠的分类能力，为后续特征分析和可解释性研究提供了基础。

4.2 特征空间可视化分析

尽管深度卷积神经网络在天文图像分类任务中能够取得较好性能，但其“黑箱”特征可能限制结果的物理可解释性。因此，有必要进一步分析模型的中间特征表示和决策机制，验证模型是否学习到了有意义的天体物理信息，而非依赖偶然的统计相关性。本文从特征空间分布和局部响应分析两个角度研究 ResNet-18 模型的可解释性。

首先，本文采用 t 分布随机邻域嵌入 (t-distributed Stochastic Neighbor Embedding, t-SNE) 方法，对模型最终全连接层之前提取的高维特征进行二维可视化。实验结果如图4.4所示，恒星样本和类星体样本在二维特征空间中形成了相对清晰的聚类结构。大多数恒星样本集中在较紧凑的区域，而类星体样本的分布更加分散。

这种分布差异反映了两类天体在成像形态上的内在差异：恒星通常表现为光度高度集中的点源，而类星体虽然在低分辨率图像中也可能接近点源形态，但其观测图像可能受到宿主




图 4.3 恒星-类星体分类模型的 PR 曲线




图 4.4 基于 ResNet-18 高层特征的 t-SNE 可视化结果

星系结构、活动星系核以及观测条件差异的影响，从而呈现更加复杂的空间结构。特征空间中的有效分离表明，模型在训练过程中成功学习到了具有判别意义的高层语义特征。

4.3 Grad-CAM 激活响应分析

为了进一步考察模型在单幅图像层面的决策过程,本文采用梯度加权类激活映射(Gradient-weighted Class Activation Mapping, Grad-CAM) 技术对卷积层激活区域进行可视化。对于多数恒星样本,模型的高响应区域主要集中在目标中心像素附近,呈现出典型的点源响应模式。对于类星体样本,模型的激活区域往往覆盖更宽范围,在部分样本中高响应区域会从中心核区向周围扩展,如图4.5所示。




图 4.5 Grad-CAM 对典型样本的局部响应可视化

这些响应可能与类星体宿主星系结构、非对称光分布或周围背景扰动有关。该现象说明,模型在分类时并非仅依赖整体亮度,而是综合利用了空间光分布特征。

进一步地,本文对误分类样本的 Grad-CAM 可视化结果进行了分析。如图??所示,被错误分类为恒星的类星体通常具有高度紧致的核区结构,在成像数据中与恒星点源非常相似;相反,被错误分类为类星体的恒星往往受到背景噪声、邻近天体或成像伪影影响。这些现象与传统天文形态分类中已知的困难一致,也进一步验证了模型决策行为的物理合理性。

综合特征空间可视化和激活响应分析可以看出, ResNet-18 模型能够学习与恒星-类星体分类相关的形态特征,其分类决策具有一定可解释性。这为深度学习方法在大规模天文巡天数据中的可靠应用提供了支持。

第五章 结论与展望

5.1 研究结论

本文围绕恒星与类星体的二分类问题，提出了一种基于卷积神经网络的深度学习方法，并以 RGB 巡天图像作为模型输入。本文的主要结论如下。

首先，本文采用 ResNet-18 作为主干分类网络，并结合迁移学习和数据增强策略完成模型训练。实验结果表明，所提出模型在测试集上取得了约 85% 的总体分类准确率，并在 ROC 曲线、AUC 指标和 PR 曲线等评价指标上表现稳定。这说明基于 RGB 巡天图像的深度卷积神经网络能够有效区分恒星和类星体。

其次，通过 t-SNE 高维特征可视化和基于 Grad-CAM 的激活图分析，本文验证了模型在分类过程中关注的图像区域与已知天体物理特征具有较好一致性。恒星的点源特征和类星体更加扩展或复杂的结构特征均能够被模型捕获。此外，对误分类样本的分析表明，观测噪声、信噪比不足、邻近天体污染和成像伪影是造成分类错误的重要因素。上述结果表明，该模型不仅具有较好的分类性能，而且具有一定物理可解释性和科学可信度。

最后，本文方法在大规模巡天数据分析中具有较强应用潜力。随着 LSST、CSST 等下一代光学巡天项目的推进，天文成像数据量将持续增长，传统依赖颜色或人工形态参数的分类方法将更加难以满足自动化处理需求。基于深度卷积神经网络的自动分类框架能够有效提取判别特征，提高数据处理效率，并为暗弱或复杂目标识别提供可靠工具。

5.2 未来展望

尽管本文基于 ResNet-18 的深度学习方法在恒星-类星体分类任务中取得了较好效果，但仍存在进一步优化和扩展空间。后续研究可以从以下几个方面展开。

- 多波段与光谱信息融合。除 RGB 图像外，进一步引入完整多波段成像、光谱特征或时域变源信息，可以为模型提供更加丰富的物理上下文，从而提升其对暗弱目标或高红移类星体的识别能力。
- 半监督与自监督学习方法。随着巡天数据规模快速增长，人工标注成本较高。半监督或自监督学习方法能够利用大量无标签数据进行特征学习，从而扩展模型适用范围并提升泛化能力。
- 可解释性与物理约束结合。在模型训练过程中引入物理先验或约束，有助于提高模型科学可解释性，并减少由噪声或观测不确定性导致的误分类，从而为天体物理分析提供更加可靠的支持。

综上所述，基于 RGB 巡天图像的卷积神经网络方法能够为恒星-类星体自动分类提供有

效方案。未来若进一步融合多模态天文观测信息，并结合更强的自监督表征学习和物理可解释性约束，有望实现更高精度、更高可靠性的天体分类与物理分析。

参考文献

- [1] Chaini S, Bagul A, Deshpande A, et al. Photometric identification of compact galaxies, stars, and quasars using multiple neural networks[J]. Monthly Notices of the Royal Astronomical Society, 2023, 518(2): 3123–3136.
- [2] Baqui P O, Marra V, Casarini L, et al. The miniJPAS survey: star-galaxy classification using machine learning[J]. Astronomy & Astrophysics, 2021, 645: A87.
- [3] Kim E J, Brunner R J. Star-galaxy classification using deep convolutional neural networks[J]. Monthly Notices of the Royal Astronomical Society, 2016: stw2672.
- [4] Pasquet-Itam J, Pasquet J. Deep learning approach for classifying, detecting and predicting photometric redshifts of quasars in the Sloan Digital Sky Survey stripe 82[J]. Astronomy & Astrophysics, 2018, 611: A97.
- [5] York D G, Adelman J, Anderson Jr J E, et al. The Sloan Digital Sky Survey: Technical summary[J]. The Astronomical Journal, 2000, 120(3): 1579.
- [6] Abolfathi B, Aguado D S, Aguilar G, et al. The fourteenth data release of the Sloan Digital Sky Survey[J]. The Astrophysical Journal Supplement Series, 2017.