

单位代码：10293

密级：公开

南京邮电大学

专业学位硕士研究生学位论文

基于 CLIP 语义奖励与目标条件补偿的 长程具身任务强化学习方法研究

学号	1025040710
姓名	李昊橙
导师	张伯雷
专业学位类别	电子信息
类型	学位论文
专业（领域）	人工智能
论文提交日期	2026 年 5 月

Nanjing University of Posts and Telecommunications

Research on Long-Horizon Embodied Reinforcement Learning with CLIP Semantic Reward and Goal-Conditioned Compensation

Thesis Submitted to Nanjing University of Posts and Telecommunications
in Partial Fulfillment of the Requirements for the Professional Master's
Degree

By

Li Haocheng

Supervisor: Zhang Bolei

May 2026

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：_____ 研究生签名：_____ 日期：_____

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：_____ 导师签名：_____ 日期：_____

摘要

长程具身任务要求智能体在三维交互环境中按照阶段顺序完成一系列对象操作。此类任务通常包含延迟反馈、相似子目标、重复无效探索以及训练不稳定等问题。针对上述问题，本文围绕 AI2-THOR 厨房场景中的苹果、微波炉和冰箱任务，研究一种结合 CLIP 语义奖励、目标条件补偿、same-frame penalty 与大语言模型辅助诊断的强化学习框架。

本文方法以 PPO 为底层策略优化算法，将 CLIP 用于图像与文本子目标之间的语义奖励塑形，而不直接作为策略网络的视觉输入。针对相邻阶段在视觉语义上容易混淆的问题，本文引入目标条件补偿矩阵，根据当前子目标对 CLIP 分数进行阶段化修正；针对重复视角和无效动作问题，进一步使用 same-frame penalty 抑制画面停滞。大语言模型被定位为任务分解、补偿表修正和训练日志诊断模块，而不是直接控制底层动作。

实验结果表明，完整配置在五个随机种子训练中取得较高成功率，目标条件补偿和 same-frame penalty 对长程任务的稳定推进具有明显贡献。消融实验进一步说明，单纯依赖原始 CLIP 分数容易受到阶段语义混淆影响，而缺少画面停滞惩罚时智能体更容易陷入重复探索。本文的研究表明，将视觉-语言语义信号作为奖励侧辅助信息，并与阶段条件约束和训练诊断机制结合，有助于提高长程具身任务中的学习稳定性与任务完成率。

关键词：具身智能；强化学习；CLIP；目标条件补偿；大语言模型

Abstract

Long-horizon embodied tasks require an agent to complete a sequence of object interactions in a three-dimensional environment. Such tasks often suffer from delayed feedback, visually similar subgoals, repeated ineffective exploration, and unstable reinforcement learning. To address these issues, this thesis studies a reinforcement learning framework for an AI2-THOR kitchen task involving an apple, a microwave, and a refrigerator. The framework combines CLIP-based semantic reward, goal-conditioned compensation, same-frame penalty, and large-language-model-assisted diagnosis.

The proposed framework uses PPO as the low-level policy optimization algorithm. CLIP is employed on the reward side to measure image-text semantic alignment, while the policy network receives low-dimensional state features and the current goal indicator. A goal-conditioned compensation matrix is introduced to correct CLIP scores according to the current subgoal, and same-frame penalty is used to discourage visually stagnant actions. The large language model is used for task decomposition, compensation-table refinement, and training-log diagnosis rather than direct low-level control.

Experimental results show that the complete configuration achieves a relatively high success rate over five random seeds. Goal-conditioned compensation and same-frame penalty make clear contributions to stable long-horizon task execution. Ablation results further indicate that raw CLIP scores may be affected by semantic ambiguity across adjacent stages, while the absence of visual-stagnation penalty tends to increase repeated ineffective exploration. These results suggest that reward-side visual-language semantic feedback, when combined with stage-aware constraints and training diagnosis, can improve learning stability and task completion in long-horizon embodied reinforcement learning.

Key Words: Embodied AI; reinforcement learning; CLIP; goal-conditioned compensation; large language model

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景	1
1.2 研究目的与意义	1
1.3 主要内容	2
1.4 论文结构安排	2
第二章 相关工作	3
2.1 具身智能与长程任务	3
2.2 视觉-语言模型辅助奖励	3
2.3 强化学习与奖励塑形	3
2.4 大语言模型辅助任务分解	4
第三章 方法设计	5
3.1 总体框架	5
3.2 任务定义与状态表示	5
3.3 PPO 策略优化	6
3.4 CLIP 语义奖励与目标条件补偿	7
3.5 Same-frame Penalty	8
3.6 LLM 辅助诊断流程	8
第四章 实验设计与结果展示	10
4.1 实验环境	10
4.2 主实验结果	10
4.3 LLM 外环消融	12
4.4 独立评测与跨场景测试	12
4.5 失败阶段与敏感性分析	14
第五章 讨论与展望	16
5.1 方法层面的讨论	16
5.2 LLM 角色边界	16
5.3 方法适用性分析	16
5.4 局限性与未来工作	17
第六章 总结	18
参考文献	19
附录 A 程序清单	20
附录 B 攻读专业学位硕士期间撰写的论文	21
附录 C 攻读专业学位硕士期间申请的专利	22
附录 D 攻读专业学位硕士期间参加的科研项目	23

插图索引

图 1.1	论文整体结构流程图	2
图 3.1	本文方法总体框架。LLM 不直接执行动作，而是参与任务分解、补偿表修正和训练诊断。 ..	5
图 3.2	LLM 辅助诊断流程。	8
图 3.3	训练流程伪代码。	9
图 4.1	AI2-THOR 厨房任务场景与阶段子目标示意。	10
图 4.2	主消融实验结果。完整配置在总体成功率上表现最好。	11
图 4.3	LLM prompt 与补偿表修正消融。	12
图 4.4	冻结 checkpoint 独立 eval 结果。	13
图 4.5	FloorPlan3 跨场景压力测试结果。	14
图 4.6	相对 full 的 bootstrap 95% 置信区间。	14
图 4.7	失败阶段分布热力图。	15
图 4.8	same-frame penalty 敏感性分析。	15

表格索引

表 3.1 策略状态与监督信号 6

表 3.2 目标条件补偿矩阵示例 7

表 4.1 核心实验设置 10

表 4.2 8 子目标 hard 任务主要结果 11

表 4.3 LLM prompt 与补偿表修正消融结果 12

表 4.4 关键配置冻结 checkpoint 独立 eval 结果 13

表 5.1 LLM 模块在本文中的角色边界 16

专用术语注释表

符号或缩写	含义
AI2-THOR	一种可交互三维家庭场景仿真平台，用于视觉智能体和具身任务研究。
CLIP	Contrastive Language–Image Pre-training，图像–文本对比预训练模型。
PPO	Proximal Policy Optimization，本文采用的强化学习策略优化算法。
LLM	Large Language Model，大语言模型，在本文中用于任务分解和训练诊断。
$\mathbf{b}_t$	第 t 步的有序子目标完成向量。
k_t	当前第一个尚未完成的子目标索引。
M	目标条件补偿矩阵，用于根据当前子目标修正 CLIP 分数。
α	CLIP 语义奖励权重。
β	same-frame penalty 的惩罚权重。
GC-CLIP-PPO	本文提出的目标条件 CLIP 奖励强化学习方法缩写。

第一章 绪论

1.1 研究背景

具身智能研究关注智能体如何在物理或仿真环境中通过感知、理解和行动完成目标任务。与静态图像识别不同，具身任务的关键不只是识别画面中有什么对象，还要在连续交互中决定下一步应该做什么。典型家庭任务例如“拿起苹果、打开微波炉、放入苹果、关闭微波炉，再移动到冰箱完成放置”，看似由若干简单动作组成，但实际执行时涉及对象状态、空间位置和阶段顺序。

强化学习为此类序列决策问题提供了自然建模方式。智能体通过与环境交互获得奖励，并逐渐学习从状态到动作的策略。然而长程具身任务通常存在奖励稀疏、阶段反馈延迟、探索空间较大和训练不稳定等问题。如果只在完整任务成功时给予奖励，智能体在训练早期很难频繁采样到成功轨迹；即便提供阶段奖励，多个子目标之间也可能具有相似视觉语义，导致策略学习受到噪声影响。

近年来，视觉-语言预训练模型为具身强化学习提供了新的语义监督信号。CLIP 能够把图像和文本映射到统一表示空间，使当前视觉观测与文本子目标之间的匹配程度成为一种可用的辅助反馈。与此同时，大语言模型在任务分解、文本生成和日志分析方面具有较强能力，可以帮助研究者把自然语言任务整理为阶段子目标，并根据训练现象提出调参建议。

1.2 研究目的与意义

本文的研究目的在于缓解长程具身任务中阶段奖励稀疏、语义目标混淆和重复无效探索等问题。围绕家庭厨房场景中的多阶段对象操作任务，本文尝试将视觉-语言模型提供的语义匹配能力引入强化学习奖励设计，并通过目标条件补偿矩阵把语义奖励约束到当前任务阶段，从而提高奖励信号与任务进度的一致性。

本文研究的意义主要体现在两个方面。一方面，CLIP 等视觉-语言模型能够为具身智能提供更灵活的语义反馈，有助于降低完全依赖人工奖励设计的成本；另一方面，长程任务对阶段顺序和状态闭环具有较高要求，单纯使用语义匹配分数并不足以保证策略稳定学习。因此，研究语义奖励、阶段补偿和训练诊断之间的协同关系，对于提升复杂交互任务中的强化学习效率具有一定参考价值。

1.3 主要内容

本文围绕基于 CLIP 语义奖励与目标条件补偿的长程具身任务强化学习方法展开，主要内容如下：

- (1) 建立长程厨房任务的问题定义，明确子目标序列、状态特征、动作空间和奖励组成。
- (2) 设计目标条件补偿矩阵，用显式表格展示不同阶段之间的语义修正关系。
- (3) 引入 same-frame penalty，用于抑制画面几乎不变化的重复探索行为。
- (4) 将大语言模型定位为任务分解和训练诊断模块，体现人工智能系统中的模块协同关系。
- (5) 通过多组实验和消融分析比较不同奖励项对训练稳定性与任务成功率的影响。

1.4 论文结构安排

本文共分为六章。第一章介绍研究背景、研究目的与主要内容；第二章综述具身智能、视觉-语言模型和大语言模型辅助训练相关工作；第三章给出方法设计；第四章展示实验设置与结果；第五章讨论方法特点、适用性与局限性；第六章总结全文。




图 1.1 论文整体结构流程图

第二章 相关工作

2.1 具身智能与长程任务

AI2-THOR^[1] 和 Habitat^[2] 等仿真平台使研究者能够在可重复环境中研究具身智能问题。这类平台提供三维场景、可交互对象、视觉观测和动作接口, 适合开展视觉导航、语言指令执行和对象交互任务。早期目标驱动导航方法通常关注单一目标定位, 例如从当前图像和目标图像学习动作策略^[3]; 随后, 研究逐渐扩展到自然语言指令跟随和多阶段对象操作, 例如 VLN^[4] 与 ALFRED^[5]。

长程任务的难点在于阶段之间存在强顺序依赖。智能体不仅要判断当前应该接近哪个对象, 还要识别对象是否已经打开、是否持有物体以及下一步是否应该切换到新的容器状态。因此, 本文选择一个受控厨房任务作为实验对象, 使子目标、动作空间和奖励信号之间的关系能够被清楚刻画。

2.2 视觉-语言模型辅助奖励

CLIP 通过大规模图像-文本对比学习获得统一语义表示空间^[6]。在具身任务中, CLIP 可以用来计算当前画面与文本子目标之间的匹配程度, 从而作为额外奖励信号。与完全手工设计奖励相比, CLIP 奖励可以利用自然语言描述表达更丰富的语义目标; 但它也可能把同一对象的多个状态混淆, 例如“打开微波炉”和“把苹果放入微波炉”在视觉上共享大量背景和对象信息。

本文采用奖励侧使用方式: CLIP 不直接替代策略网络, 也不承担动作决策, 而是负责提供图像-文本匹配分数。为了避免原始 CLIP 分数与当前阶段错位, 本文进一步加入目标条件补偿, 使 CLIP 奖励根据当前子目标进行修正。

2.3 强化学习与奖励塑形

PPO 是一种常用的策略梯度方法, 因其实现相对简单、训练稳定性较好而被广泛用于连续控制和离散动作任务^[7]。奖励塑形可以改善强化学习中的样本效率, 但不恰当的附加奖励可能改变原始任务目标。Ng 等关于 potential-based reward shaping 的研究指出, 若希望理论上保持最优策略不变, 奖励塑形需要满足特定形式约束^[8]。

本文的定位偏向工程验证与机制分析, 并不声称给出严格的理论最优性保证。相反, 本文通过多组消融实验观察不同奖励项是否带来可解释的改进, 包括关闭 CLIP、关闭目标条件补偿、关闭 same-frame penalty, 以及调整 CLIP 权重等。

2.4 大语言模型辅助任务分解

大语言模型在少样本推理和文本结构化方面表现突出^[9]，已经被用于机器人任务规划和具身控制相关研究。**Huang** 等将语言模型作为零样本规划器，从自然语言中抽取可执行动作知识^[10]；**SayCan** 将语言模型评分与机器人技能可执行性结合，用于选择动作^[11]；**ProgPrompt** 则使用程序化提示生成带环境状态约束的任务计划^[12]。**ReAct**^[13] 和 **Reflexion**^[14] 进一步展示了语言模型在反馈循环中的推理与反思能力。

本文借鉴上述思想，但更强调角色边界：**LLM** 负责把任务文本整理为子目标、分析 **CLIP** 离线评分、阅读训练日志并提出补偿表或参数建议；底层动作控制仍由 **PPO** 策略通过环境交互学习完成。

第三章 方法设计

3.1 总体框架

本文将方法命名为 GC-CLIP-PPO。框架由四个部分组成：PPO 策略学习模块、CLIP 语义奖励模块、目标条件补偿模块和 LLM 辅助诊断模块。整体流程如图 3.1 所示。PPO 负责根据低维状态和当前目标选择宏动作；CLIP 根据当前图像和子目标文本计算语义分数；补偿矩阵根据当前阶段修正 CLIP 分数；LLM 在训练前后辅助生成子目标文本、分析混淆关系和诊断训练日志。




图 3.1 本文方法总体框架。LLM 不直接执行动作，而是参与任务分解、补偿表修正和训练诊断。

3.2 任务定义与状态表示

给定有序子目标集合

$$G = \{g_1, g_2, \dots, g_N\}, \quad (3.1)$$

智能体需要按顺序完成所有子目标。本文展示任务中 $N = 8$ ，完整宏动作序列包含取苹果、移动至微波炉、打开微波炉、放入苹果、关闭微波炉、开启并关闭微波炉、再次取出苹果、移动至冰箱、打开冰箱、放入苹果和关闭冰箱等操作。

环境维护一个有序完成向量

$$\mathbf{b}_t = [b_t^1, b_t^2, \dots, b_t^N], \quad (3.2)$$

其中 $b_t^i = 1$ 表示第 i 个子目标已经完成。当前目标索引定义为

$$k_t = \min\{i \mid b_t^i = 0\}. \quad (3.3)$$

若所有子目标均完成，则任务成功。

策略输入由 9 维低维状态和 8 维当前目标 one-hot 拼接得到。需要说明的是，这里的低维状态来自 AI2-THOR metadata，属于特权状态输入，不代表端到端视觉控制。表 3.1 给出了主要状态信息。

表 3.1 策略状态与监督信号

项目	维度	说明
低维状态	9	包括是否持有苹果、是否靠近微波炉、微波炉是否打开、冰箱是否打开等信息。
当前目标 one-hot	8	表示当前第一个尚未完成的阶段子目标。
完成 flags	8	用于奖励计算和目标索引更新，不直接作为 actor 的完整输入。
动作 mask	12	根据当前上下文屏蔽明显不可执行的宏动作。

3.3 PPO 策略优化

本文使用 PPO 作为底层策略优化算法。给定状态 s_t 和当前目标 k_t ，策略网络输出离散动作分布：

$$a_t \sim \pi_\theta(a_t \mid s_t, k_t). \quad (3.4)$$

PPO 的裁剪目标可以写为

$$L^{\text{PPO}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (3.5)$$

其中 $r_t(\theta)$ 是新旧策略概率比， $\hat{A}_t$ 是优势估计， ϵ 是裁剪系数。

3.4 CLIP 语义奖励与目标条件补偿

给定当前图像 I_t 和子目标文本 T_i ，CLIP 计算图像-文本相似度：

$$c_t^i = \text{sim}(f_I(I_t), f_T(T_i)). \quad (3.6)$$

为了使 CLIP 分数更符合当前阶段，本文引入目标条件补偿矩阵 M ：

$$\tilde{c}_t^i = c_t^i + \lambda_c M_{k_t, i}, \quad (3.7)$$

其中 λ_c 表示补偿强度。补偿矩阵如表 3.2 所示。表格的意义不在于数值本身绝对正确，而在于展示论文中如何使用矩阵、表格和数学符号表达算法设计。

表 3.2 目标条件补偿矩阵示例

当前目标	g_0	g_1	g_2	g_3	g_4	g_5	g_6	g_7
g_0	0.002	0.000	0.000	0.000	0.000	0.000	0.000	0.000
g_1	-0.006	0.008	0.000	0.000	0.000	0.000	0.000	0.000
g_2	-0.006	-0.006	0.012	-0.002	-0.002	0.000	0.000	0.000
g_3	-0.004	-0.004	-0.003	0.004	-0.006	0.000	0.000	0.000
g_4	-0.004	-0.004	-0.002	-0.008	0.004	0.000	0.000	0.000
g_5	-0.006	-0.006	-0.004	-0.004	-0.004	0.022	-0.002	-0.002
g_6	0.000	0.000	0.000	0.000	0.000	-0.006	0.024	-0.002
g_7	0.000	0.000	0.000	0.000	0.000	-0.008	-0.008	0.028

总奖励定义为

$$r_t = r_t^{\text{stage}} + r_t^{\text{final}} + r_t^{\text{clip}} + r_t^{\text{penalty}}, \quad (3.8)$$

其中 CLIP 语义奖励为

$$r_t^{\text{clip}} = \alpha \cdot \text{clip} \left(\tilde{c}_t^{k_t} - \max_{j \neq k_t} \tilde{c}_t^j, -0.12, 0.12 \right). \quad (3.9)$$

3.5 Same-frame Penalty

重复视角和无效动作会导致长程任务训练停滞。为此，本文计算连续帧归一化差异：

$$\Delta_t = \frac{1}{HWC} \|I_t - I_{t-1}\|_1. \quad (3.10)$$

当 Δ_t 小于阈值且当前动作没有推进子目标时，施加惩罚：

$$r_t^{\text{same}} = -\beta. \quad (3.11)$$

该机制的直观作用是鼓励智能体避免在几乎相同画面中反复执行无收益动作。

3.6 LLM 辅助诊断流程

LLM 辅助流程如图 3.2 所示。其作用分为三个层次：第一，根据任务描述生成子目标文本；第二，结合 CLIP 离线评分识别容易混淆的阶段；第三，阅读早期训练日志并提出补偿表或超参数调整建议。




图 3.2 LLM 辅助诊断流程。

输入：子目标文本、补偿矩阵、CLIP 模型、PPO 参数。

步骤 1：LLM 将自然语言任务整理为阶段子目标。

步骤 2：环境返回低维状态和当前图像，PPO 选择宏动作。

步骤 3：CLIP 对当前图像和所有子目标文本打分。

步骤 4：根据当前目标从补偿矩阵中读取修正项，得到补偿后分数。

步骤 5：计算阶段奖励、最终奖励、CLIP 奖励和 same-frame penalty。

步骤 6：PPO 根据采样轨迹更新策略，LLM 周期性阅读日志并辅助诊断。

图 3.3 训练流程伪代码。

第四章 实验设计与结果展示

4.1 实验环境

实验基于 AI2-THOR 厨房场景构造。训练场景为 FloorPlan1，跨场景压力测试使用 FloorPlan3。任务包含 8 个有序子目标和 12 个宏动作。策略输入为 17 维向量，其中 9 维来自低维环境状态，8 维为当前目标 one-hot。表 4.1 汇总了主要实验设置。

表 4.1 核心实验设置

类别	设置
环境与任务	AI2-THOR 厨房场景；8 个有序子目标；12 个宏动作。
策略与优化	PPO；两层 MLP actor-critic；每个随机种子训练 400 episodes。
语义奖励	CLIP 图像-文本匹配分数；主实验 CLIP 权重为 1.0。
补偿与惩罚	启用目标条件补偿矩阵和 same-frame penalty。
评估方式	训练成功率、最后 50 轮成功率、独立 eval、跨场景压力测试。




图 4.1 AI2-THOR 厨房任务场景与阶段子目标示意。

4.2 主实验结果

表 4.2 和图 4.2 展示了不同配置在 8 子目标任务上的表现。完整配置 full 取得最高总体成功率，说明 CLIP 语义奖励、目标条件补偿和 same-frame penalty 的组合能够提高训练稳定

性。

表 4.2 8 子目标 hard 任务主要结果

配置	总体成功率	最后 50 轮成功率	相对 full	AUC 成功率	成功步数	平均 flags
full	71.55	96.40	0.00	36.10	35.68	6.99/8
clip_w3	65.40	99.20	-6.15	33.52	35.22	6.95/8
clip_w0	63.60	98.40	-7.95	32.78	36.67	6.87/8
stage_final	59.55	97.20	-12.00	28.88	37.97	6.79/8
comp_shuffle	44.65	96.80	-26.90	17.58	39.82	5.89/8
no_comp	29.65	60.40	-41.90	11.76	43.59	5.20/8
no_same_frame	26.10	39.60	-45.45	14.46	51.91	4.74/8




图 4.2 主消融实验结果。完整配置在总体成功率上表现最好。

从结果可以看出，关闭目标条件补偿后，成功率明显下降；关闭 same-frame penalty 后，训练稳定性进一步恶化。这说明仅仅加入 CLIP 分数并不足够，必须把视觉-语言语义信号与当前任务阶段绑定起来。

4.3 LLM 外环消融

为了展示 LLM 在文本生成和补偿表修正中的作用，本文整理了三组外环消融，如表 4.3 所示。结果显示，仅替换 **prompt** 的提升有限，而引入结构化局部补偿表后，成功率明显提高。

表 4.3 LLM prompt 与补偿表修正消融结果

配置	变量设置	总体成功率	AUC 成功率	成功步数
no_llm_manual	人工简化 prompt + 人工补偿表	47.10	22.41	43.95
llm_prompt_manual_M	当前 prompt + 人工补偿表	51.05	24.29	42.68
llm_prompt_llm_M	当前 prompt + 结构化局部补偿表	65.30	34.81	36.48
full	当前 prompt + 完整补偿与诊断配置	71.55	36.10	35.68




图 4.3 LLM prompt 与补偿表修正消融。

4.4 独立评测与跨场景测试

训练结束后冻结关键配置的 **final checkpoint**，并运行独立 **eval**。表 4.4 显示，完整配置在 150 个 **eval episodes** 上取得 100% 成功率。图 4.4 给出了更直观的展示。

表 4.4 关键配置冻结 checkpoint 独立 eval 结果

配置	Episodes	成功率	平均步数	平均 flags
full	150	100.00	25.35	8.00/8
clip_w0	150	99.33	28.77	7.97/8
stage_final	150	97.33	32.43	7.94/8
no_comp	150	66.67	40.89	6.59/8
no_same_frame	150	32.67	57.29	4.01/8

Independent Evaluation of Frozen Checkpoints




图 4.4 冻结 checkpoint 独立 eval 结果。

跨场景压力测试将 full 的多个 checkpoint 迁移到 FloorPlan3，在相同宏动作接口和 goal-aware recovery 设置下取得稳定结果。该实验用于展示受控设置下的迁移现象，不等价于开放场景泛化结论。

Cross-scene Transfer of Full Checkpoints to FloorPlan3




图 4.5 FloorPlan3 跨场景压力测试结果。

4.5 失败阶段与敏感性分析

图 4.6 展示了相对完整配置的 bootstrap 置信区间，图 4.7 展示了失败阶段分布。可以看出，失败并不是均匀发生，而是集中在后半段容器状态切换等关键阶段。




图 4.6 相对 full 的 bootstrap 95% 置信区间。




图 4.7 失败阶段分布热力图。




图 4.8 same-frame penalty 敏感性分析。

第五章 讨论与展望

5.1 方法层面的讨论

本文方法的核心思想是把不同模型放在相对合适的位置。PPO 负责通过环境交互学习底层动作策略；CLIP 负责提供图像-文本语义反馈；目标条件补偿矩阵负责把语义反馈绑定到当前任务阶段；LLM 负责整理任务文本和诊断训练现象。这种模块化结构使每个组件都可以被单独替换或消融，便于分析。

从实验展示结果看，目标条件补偿和 same-frame penalty 的贡献最明显。前者缓解 CLIP 原始分数与当前阶段不一致的问题，后者降低重复画面和无效动作带来的训练停滞。CLIP 权重过大时性能并未继续提升，说明视觉-语言语义奖励更适合作为辅助信号，而不是完全主导强化学习目标。

5.2 LLM 角色边界

本文并不把 LLM 包装为可以直接替代强化学习策略的控制器。LLM-only 开环规划基线 在实验中能够生成合法动作名称，但由于缺少环境反馈，容易遗漏关键中间动作。例如在微波炉加热后需要重新取出苹果，否则后续冰箱放置阶段无法完成。这说明在需要状态闭环的具身任务中，语言模型更适合作为高层辅助模块，而不是独立执行器。

表 5.1 LLM 模块在本文中的角色边界

角色	适合承担	不适合直接承担
任务文本处理	生成子目标描述、整理 prompt	保证动作序列一定可执行
训练诊断	分析日志、提出补偿表建议	替代 PPO 进行交互学习
实验分析	归纳训练现象、辅助定位异常	替代真实环境验证过程

5.3 方法适用性分析

本文方法适用于目标能够被拆分为若干阶段、且阶段状态可由视觉观测和低维状态共同刻画的具身交互任务。在这类任务中，CLIP 语义奖励可以为中间过程提供比稀疏成功奖励更密集的反馈，目标条件补偿矩阵则用于降低相邻阶段语义相似带来的误导。same-frame penalty 对重复视角和停滞行为具有直接约束作用，适合用于动作空间较小但容易循环探索的交互环境。

与此同时，本文方法并不适合完全无阶段结构或目标难以用文本描述的任务。当子目标无法被清晰表达时，CLIP 分数的解释性会下降；当环境状态变化主要体现在触觉、力反馈或隐藏变量中时，仅依赖视觉语义奖励也可能无法提供充分监督。因此，本文更适合被看作一种面向可描述、多阶段、视觉可观测任务的奖励辅助框架。

5.4 局限性与未来工作

本文仍存在以下局限性：

- 实验场景相对受控，尚未覆盖更多房间类型、对象组合和开放式自然语言指令。
- 目标条件补偿矩阵主要依赖人工经验和离线分析，自动学习补偿关系仍有进一步研究空间。
- CLIP 奖励对视觉遮挡、光照变化和对象状态细节较为敏感，在复杂场景中可能出现误判。
- LLM 在本文中主要承担任务分解和诊断角色，其建议仍需研究者筛选，尚未形成完全自动闭环。

后续研究可以从三个方向展开：其一，扩展实验任务和场景规模，检验方法在更复杂交互环境中的泛化能力；其二，引入数据驱动方式学习补偿矩阵，减少人工设定带来的主观性；其三，将 LLM 诊断结果与强化学习训练过程更紧密地结合，探索可控、可验证的自动奖励修正机制。

第六章 总结

本文围绕长程具身任务中的阶段监督、语义奖励、补偿矩阵、same-frame penalty 和 LLM 诊断展开研究，提出一种基于 CLIP 语义奖励与目标条件补偿的强化学习方法。该方法以 PPO 作为底层策略优化算法，将 CLIP 用于奖励侧图像-文本语义匹配，并通过阶段化补偿矩阵修正相邻子目标之间的语义混淆。

研究结果表明，CLIP 更适合作为奖励侧语义反馈来源，而不是直接控制策略的视觉编码器；目标条件补偿能够缓解相邻阶段的语义混淆；same-frame penalty 有助于减少重复视角带来的训练停滞；LLM 则适合承担任务分解和训练诊断等高层辅助功能。多组消融实验说明，上述模块协同使用时能够提高长程具身任务的训练稳定性与任务成功率。

未来工作将进一步扩展实验场景与任务类型，验证该方法在开放式对象交互和更复杂自然语言指令下的泛化能力。同时，可以探索自动学习目标条件补偿矩阵的方法，并将 LLM 的日志诊断结果转化为可验证的训练调整策略，从而减少人工经验对奖励设计的依赖。

参考文献

- [1] Kolve E, Mottaghi R, Han W, et al. Ai2-thor: An interactive 3d environment for visual ai[J]. arXiv preprint arXiv:1712.05474, 2017.
- [2] Savva M, Kadian A, Maksymets O, et al. Habitat: A platform for embodied ai research[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. [S.l.: s.n.], 2019: 9339–9347.
- [3] Zhu Y, Mottaghi R, Kolve E, et al. Target-driven visual navigation in indoor scenes using deep reinforcement learning[C]. IEEE International Conference on Robotics and Automation. [S.l.: s.n.], 2017: 3357–3364.
- [4] Anderson P, Wu Q, Teney D, et al. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2018: 3674–3683.
- [5] Shridhar M, Thomason J, Gordon D, et al. Alfred: A benchmark for interpreting grounded instructions for everyday tasks[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2020: 10740–10749.
- [6] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision [C]. International Conference on Machine Learning. [S.l.: s.n.], 2021: 8748–8763.
- [7] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.
- [8] Ng A Y, Harada D, Russell S. Policy invariance under reward transformations: Theory and application to reward shaping[C]. International Conference on Machine Learning. [S.l.: s.n.], 1999: 278–287.
- [9] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[C]. Advances in Neural Information Processing Systems: volume 33. [S.l.: s.n.], 2020: 1877–1901.
- [10] Huang W, Abbeel P, Pathak D, et al. Language models as zero-shot planners: Extracting actionable knowledge for embodied agents[C]. International Conference on Machine Learning. [S.l.: s.n.], 2022: 9118–9147.
- [11] Ahn M, Brohan A, Brown N, et al. Do as i can, not as i say: Grounding language in robotic affordances[C]. Conference on Robot Learning. [S.l.: s.n.], 2022: 287–318.
- [12] Singh I, Blukis V, Mousavian A, et al. Progprompt: Generating situated robot task plans using large language models[C]. IEEE International Conference on Robotics and Automation. [S.l.: s.n.], 2023: 11523–11530.
- [13] Yao S, Zhao J, Yu D, et al. React: Synergizing reasoning and acting in language models[C]. International Conference on Learning Representations. [S.l.: s.n.], 2023.
- [14] Shinn N, Cassano F, Gopinath A, et al. Reflexion: Language agents with verbal reinforcement learning[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2023.

附录 A 程序清单

代码 1 奖励计算伪代码示例

```
1 def compute_reward(stage_reward, final_reward, clip_scores ,  
2                     goal_index, compensation_matrix, same_frame):  
3     corrected = clip_scores + compensation_matrix[goal_index]  
4     margin = corrected [goal_index] - max_other(corrected, goal_index)  
5     clip_reward = clip (margin, -0.12, 0.12)  
6     penalty = -0.05 if same_frame else 0.0  
7     return stage_reward + final_reward + clip_reward + penalty
```

附录 B 攻读专业学位硕士期间撰写的论文

- (1) 李昊橙. 基于 CLIP 语义奖励与目标条件补偿的长程具身任务强化学习方法研究, 2026。

附录 C 攻读专业学位硕士期间申请的专利

- (1) 暂无已授权专利。

附录 D 攻读专业学位硕士期间参加的科研项目

- [1] 长程具身任务强化学习与视觉-语言奖励塑形研究项目，2026。