

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于深度学习的网络异常流量检测系统设计与实现

学	号	<u>1025040715</u>
姓	名	<u>刘若谷</u>
导	师	<u>张伯雷</u>
专业学位类别		<u>工学硕士</u>
类	型	<u>专业学位硕士</u>
专业（领域）		<u>计算机科学与技术</u>
论文提交日期		<u>2026年6月</u>

摘要

随着云计算、工业互联网和移动业务的持续融合，网络边界日益动态化，攻击流量在时序形态、协议组合和业务语义上呈现出更强的隐蔽性。传统基于规则和浅层统计特征的入侵检测方法依赖人工经验，面对未知攻击、低频攻击以及加密传输场景时容易出现漏报。针对上述问题，本文围绕网络异常流量检测任务，设计并实现了一种基于深度学习的检测系统，重点研究流量特征构建、深度模型训练、异常判别和系统工程化部署之间的协同机制。

本文首先分析网络异常流量检测的研究背景和典型方法，梳理监督学习、无监督学习和深度学习检测范式的适用条件；其次，结合流量会话统计特征与时序行为特征，构建面向检测模型的预处理流程，包括缺失值处理、类别编码、标准化、样本不均衡缓解和训练验证划分；在模型设计方面，本文提出一种融合一维卷积神经网络和双向长短期记忆网络的检测模型，利用卷积层提取局部特征交互，利用循环层刻画会话序列中的前后依赖，并通过注意力加权增强关键特征对判别结果的贡献。最后，本文完成了一个原型检测系统，实现离线训练、模型评估、在线推理和告警展示等功能，并在公开数据集上与传统机器学习方法进行对比。

实验结果表明，相较于随机森林、支持向量机和单一多层感知机模型，本文所设计的融合模型在准确率、召回率和 F_1 值上均取得更稳定的表现，尤其在异常类别样本占比较低的情况下具有更好的召回能力。系统测试结果表明，所实现的检测原型能够完成从流量特征输入到告警输出的闭环流程，具备进一步接入真实网络镜像流量和安全运营平台的工程基础。

关键词：网络异常检测，深度学习，入侵检测，流量分析，注意力机制

Abstract

With the continuous convergence of cloud computing, industrial Internet and mobile services, network boundaries become increasingly dynamic, and malicious traffic becomes more stealthy in temporal patterns, protocol combinations and service semantics. Traditional intrusion detection methods based on rules and shallow statistical features rely heavily on expert experience, and they often suffer from missed detection when facing unknown attacks, low-frequency attacks and encrypted traffic. To address these issues, this thesis designs and implements a deep learning based network anomaly traffic detection system, focusing on the coordination among traffic feature construction, deep model training, anomaly classification and engineering deployment.

This thesis first analyzes the background and representative methods of network anomaly traffic detection, and compares the applicable conditions of supervised learning, unsupervised learning and deep learning paradigms. Then a preprocessing workflow is constructed by combining flow-level statistical features and temporal behavior features, including missing value handling, categorical encoding, normalization, class imbalance mitigation and training-validation splitting. In terms of model design, a hybrid detection model combining one-dimensional convolutional neural networks and bidirectional long short-term memory networks is proposed. The convolutional layers capture local feature interactions, the recurrent layers model contextual dependencies in flow sequences, and the attention module enhances the contribution of discriminative features. Finally, a prototype detection system is implemented, supporting offline training, model evaluation, online inference and alert visualization. Experiments are conducted on public datasets and compared with traditional machine learning methods.

The experimental results show that, compared with random forest, support vector machine and multilayer perceptron baselines, the proposed hybrid model achieves more stable performance in accuracy, recall and F_1 score, especially under imbalanced anomaly categories. System tests demonstrate that the implemented prototype can complete the closed-loop process from traffic feature input to alert output, providing an engineering basis for future integration with real network mirror traffic and security operation platforms.

Key Words: network anomaly detection, deep learning, intrusion detection, traffic analysis, attention mechanism

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 本文主要研究内容	2
1.4 论文组织结构	2
第二章 相关理论与技术基础	3
2.1 网络异常流量检测基础	3
2.2 深度学习检测模型	3
2.3 注意力机制	4
2.4 评价指标	4
2.5 本章小结	4
第三章 系统需求分析与总体设计	5
3.1 需求分析	5
3.2 总体架构设计	5
3.3 数据处理流程	6
3.4 模块设计	6
3.5 本章小结	6
第四章 异常流量检测模型设计与实现	8
4.1 模型设计思想	8
4.2 网络结构	8
4.3 损失函数与优化方法	9
4.4 检测算法流程	9
4.5 系统实现要点	10
4.6 本章小结	10
第五章 实验设计与结果分析	11
5.1 实验环境与数据集	11
5.2 对比方法与参数设置	11
5.3 实验结果分析	12
5.4 消融实验	12
5.5 系统测试	12
5.6 本章小结	13
第六章 总结与展望	14
6.1 全文总结	14
6.2 不足与展望	14
参考文献	15
附录 A 程序清单	16
致谢	20

插图索引

图 3.1 网络异常流量检测系统总体流程 6

表格索引

表 3.1	系统核心模块设计	7
表 4.1	模型主要参数设置	8
表 5.1	实验环境	11
表 5.2	不同模型检测性能对比	12
表 5.3	模型消融实验结果	12

专用术语注释表

符号说明：

符号	表示含义
x_i	第 i 个网
y_i	第 i 个样
$\hat{y}_i$	模型输出
p_i	模型对异
L	模型训练
TP	被正确识
FP	被错误识
FN	被错误识

缩略词说明：

缩写	英文全称
CNN	Convolut
LSTM	Long Sho
BiLSTM	Bidirecti
	Memory
IDS	Intrusion
DoS	Denial of
FPR	False Pos
TPR	True Posi
ROC	Receiver tic

第一章 绪论

1.1 研究背景与意义

网络空间已经成为数字经济和社会治理的重要基础设施。云平台、边缘节点、物联网终端和移动应用共同构成了高并发、强异构、跨边界的网络环境，业务系统在获得弹性扩展能力的同时，也暴露出更复杂的安全风险。攻击者可以通过端口扫描、口令爆破、拒绝服务、漏洞利用和横向移动等方式持续试探网络边界；同时，攻击流量往往会伪装成正常业务请求，或者以低频、分阶段的方式隐藏在海量通信行为之中。

入侵检测系统是网络安全防护体系中的关键组成部分，其目标是在不影响正常业务运行的前提下，对异常流量进行识别、告警和辅助处置。传统检测方法主要包括基于规则的特征匹配和基于统计阈值的异常判别。前者对已知攻击具有较高解释性，但规则维护成本高，面对变种攻击和未知攻击时泛化能力有限；后者能够发现偏离历史分布的行为，但对复杂业务波动敏感，容易造成较高误报率。随着深度学习在图像、语音和自然语言处理领域的成功应用，研究者开始将其引入网络流量检测任务，通过自动学习高维特征之间的非线性关系来提升检测效果^[1,2]。

对于实际安全运营场景而言，异常流量检测并不是单纯的分类问题。系统需要同时考虑检测准确率、异常召回率、误报率、推理延迟、模型更新成本和部署可维护性。若模型过于复杂，即使离线指标较高，也可能难以满足实时检测要求；若模型过于简单，则难以适应业务流量的动态变化。因此，研究一种兼顾检测效果和工程实现的网络异常流量检测方法，具有重要的理论意义和应用价值。

1.2 国内外研究现状

现有网络异常检测方法大体可以分为三类：基于规则的方法、基于传统机器学习的方法和基于深度学习的方法。

基于规则的方法通常依赖安全专家总结攻击特征，并将其固化为规则库。该类方法部署简单、解释性强，适用于病毒签名、恶意域名、漏洞利用载荷等已知威胁识别。然而，规则库需要长期维护，且难以覆盖未知攻击和经过混淆的攻击行为。

传统机器学习方法将流量样本表示为统计特征向量，并利用支持向量机、随机森林、朴素贝叶斯、聚类或孤立森林等模型完成分类或异常评分。NSL-KDD、UNSW-NB15、CICIDS等公开数据集推动了相关研究的发展^[3-5]。该类方法对结构化特征具有较好适应性，但特征工程依赖人工选择，且在面对高维稀疏特征和时序行为特征时表达能力有限。

深度学习方法能够通过多层网络自动学习特征表示。卷积神经网络适合提取局部模式,循环神经网络适合建模序列依赖,自编码器适合在缺少攻击标签时学习正常流量分布,注意力机制则能够突出关键特征或关键时刻对判别结果的影响^[6,7]。不过,深度模型也存在训练数据需求大、可解释性不足、参数调优复杂等问题,在工程应用中需要结合数据治理和系统设计加以解决。

1.3 本文主要研究内容

本文围绕网络异常流量检测系统的设计与实现展开研究,主要工作如下:

- (1) 构建网络流量检测任务的数据处理流程。针对原始流量特征中存在的缺失值、类别变量、量纲差异和样本类别不均衡问题,设计统一的预处理与数据划分方法,为模型训练提供稳定输入。
- (2) 设计融合 CNN、BiLSTM 和注意力机制的异常检测模型。模型利用卷积层捕获局部特征组合,利用双向循环层刻画序列上下文,并通过注意力权重提升关键特征的判别贡献。
- (3) 实现网络异常流量检测原型系统。系统包括数据导入、模型训练、指标评估、在线推理和告警记录等模块,形成从离线实验到在线检测的闭环流程。
- (4) 设计对比实验和消融实验。本文选取传统机器学习模型和深度学习模型作为基线,从准确率、精确率、召回率、 F_1 值和误报率等角度评估模型性能。

1.4 论文组织结构

全文共分为六章。第一章介绍研究背景、研究现状、研究内容和论文结构。第二章介绍网络异常检测、深度学习模型和评价指标等相关理论。第三章给出系统总体需求分析与架构设计。第四章详细阐述检测模型和关键算法。第五章介绍实验设计、结果分析和系统测试。第六章总结全文工作并展望后续研究方向。

第二章 相关理论与技术基础

2.1 网络异常流量检测基础

网络流量通常可以从数据包、会话流和业务事务三个层次进行描述。数据包层次关注源地址、目的地址、端口、协议、标志位和载荷长度等字段；会话流层次将具有相同五元组且时间相邻的数据包聚合为一个流，统计持续时间、上下行包数、字节数、平均包长、到达间隔和方向比例等特征；业务事务层次则进一步结合应用协议语义和用户行为上下文。本文面向可工程化部署的异常检测任务，主要采用会话流层次的结构化特征。

从检测目标看，网络异常检测可分为二分类检测和多分类检测。二分类检测只判断样本是否异常，适合告警入口；多分类检测需要识别 DoS、Probe、Exploit、Botnet 等具体攻击类型，适合威胁分析和响应编排。由于真实网络中的异常样本通常远少于正常样本，检测模型若单纯追求总体准确率，可能倾向于将样本判为正常。因此，召回率、误报率和 F_1 值在安全场景中往往比单一准确率更有参考价值。

2.2 深度学习检测模型

深度学习模型通过多层非线性变换学习样本的高层表示。对于网络流量特征，常见模型包括多层感知机、卷积神经网络、循环神经网络和自编码器。

多层感知机将输入特征映射到隐含空间，其基本形式可表示为：

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (2.1)$$

其中， $\mathbf{h}^{(l)}$ 表示第 l 层的隐含表示， $\mathbf{W}^{(l)}$ 和 $\mathbf{b}^{(l)}$ 分别为权重矩阵和偏置项， $\sigma(\cdot)$ 为非线性激活函数。

卷积神经网络通过局部连接和权值共享提取相邻特征之间的组合模式。对于一维流量特征序列，卷积操作可以写为：

$$z_t = \sigma\left(\sum_{k=0}^{K-1} w_k x_{t+k} + b\right), \quad (2.2)$$

其中， K 为卷积核大小， w_k 为卷积核参数， x_{t+k} 为局部输入特征。卷积结构能够减少参数量，并增强模型对局部扰动的鲁棒性。

长短期记忆网络通过门控机制缓解传统循环神经网络的梯度消失问题，适合处理具有时间依赖的序列数据。其核心由输入门、遗忘门、输出门和记忆单元构成，可在较长时间范围内保留有效状态。双向 LSTM 同时从正向和反向建模序列信息，有利于捕获流量会话前后统

计特征之间的关联。

2.3 注意力机制

注意力机制的基本思想是为不同特征或不同时间步分配不同权重，使模型更加关注对当前任务更有贡献的信息。设 BiLSTM 输出的隐含状态序列为 $\{\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_T\}$ ，注意力权重可定义为：

$$\alpha_t = \frac{\exp(\mathbf{u}^T \tanh(\mathbf{W}_a \mathbf{h}_t + \mathbf{b}_a))}{\sum_{j=1}^T \exp(\mathbf{u}^T \tanh(\mathbf{W}_a \mathbf{h}_j + \mathbf{b}_a))}. \quad (2.3)$$

加权后的上下文向量为：

$$\mathbf{c} = \sum_{t=1}^T \alpha_t \mathbf{h}_t. \quad (2.4)$$

在异常流量检测中，注意力权重可以帮助模型突出异常连接持续时间、异常端口组合、突发包间隔等关键线索，从而提高复杂攻击场景下的识别能力。

2.4 评价指标

本文采用准确率、精确率、召回率、 F_1 值和误报率评价检测效果。设 TP 表示正确识别的异常样本数， TN 表示正确识别的正常样本数， FP 表示误报样本数， FN 表示漏报样本数，则有：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad (2.5)$$

$$Precision = \frac{TP}{TP + FP}, \quad (2.6)$$

$$Recall = \frac{TP}{TP + FN}, \quad (2.7)$$

$$F_1 = \frac{2 \times Precision \times Recall}{Precision + Recall}. \quad (2.8)$$

安全检测系统通常更关注召回率和误报率之间的平衡。召回率过低会导致攻击漏检，误报率过高则会增加安全运营人员的告警处置负担。因此，本文在实验中同时给出多项指标，并结合混淆矩阵分析模型的错误类型。

2.5 本章小结

本章介绍了网络异常流量检测的基本概念、深度学习模型、注意力机制以及常用评价指标。上述理论为后续系统设计和模型实现提供了基础。下一章将结合实际检测流程，给出网络异常流量检测系统的需求分析和总体架构。

第三章 系统需求分析与总体设计

3.1 需求分析

网络异常流量检测系统需要在离线训练和在线检测两个阶段发挥作用。离线阶段面向历史流量数据，完成数据清洗、特征转换、模型训练和指标评估；在线阶段面向新到达的流量特征，完成快速推理、异常判定和告警记录。结合专业学位论文对工程实现的要求，本文将系统需求划分为功能需求和非功能需求。

功能需求包括：

- (1) 数据管理。系统应支持导入 CSV 格式的流量特征文件，完成字段校验、缺失值处理和特征标准化。
- (2) 模型训练。系统应支持配置训练轮数、批大小、学习率和类别权重，并保存训练后的模型参数。
- (3) 模型评估。系统应输出准确率、精确率、召回率、 F_1 值、误报率和混淆矩阵等指标。
- (4) 在线推理。系统应支持对单条或批量流量样本进行异常概率预测，并根据阈值生成检测结果。
- (5) 告警展示。系统应记录异常样本的时间、源地址、目的地址、异常概率和判定类别，便于后续追踪。

非功能需求包括实时性、可扩展性和可维护性。实时性要求单条样本推理延迟满足在线检测需要；可扩展性要求系统能够替换不同模型和数据集；可维护性要求训练脚本、配置文件和服务接口边界清晰，便于后续部署和迭代。

3.2 总体架构设计

本文设计的系统采用分层架构，主要包括数据处理层、模型训练层、推理服务层和展示交互层。各层之间通过结构化数据和模型文件进行解耦。

数据处理层负责将原始流量样本转换为模型可接受的张量输入。模型训练层负责完成训练、验证、指标输出和模型持久化。推理服务层加载训练好的模型，对新样本进行概率预测。展示交互层面面向使用者提供结果查看和告警查询能力。该架构的优点在于训练流程与推理流程相对独立，既便于离线实验，也便于后续部署为服务接口。



图 3.1 网络异常流量检测系统总体流程

3.3 数据处理流程

公开流量数据集通常包含数值型特征、类别型特征和标签字段。本文设计的数据处理流程如下：

- (1) 字段检查。检查样本是否包含必要字段，并删除重复样本。
- (2) 缺失值处理。对数值字段采用中位数填充，对类别字段采用众数或特殊类别填充。
- (3) 类别编码。对协议类型、服务类型和连接状态等离散字段采用独热编码。
- (4) 特征标准化。对连续字段采用零均值、单位方差标准化，减少量纲差异对训练过程的影响。
- (5) 样本划分。按照训练集、验证集和测试集划分数据，并保持异常样本比例相对一致。

对于类别不均衡问题，本文采用类别权重与过采样相结合的策略。在训练损失中提高少数类样本权重，使模型更加关注异常样本；在训练集内部对少数类进行适度过采样，避免模型在早期训练阶段快速偏向正常类别。

3.4 模块设计

系统核心模块如表3.1所示。

3.5 本章小结

本章从功能需求和非功能需求出发，设计了网络异常流量检测系统的总体架构、数据处理流程和核心模块。系统采用训练与推理分离的设计思路，为后续深度检测模型实现和实验验证奠定了工程基础。

表 3.1 系统核心模块设计

模块名称	输入	输出与功能
数据预处理模块	原始 CSV 文件	标准化特征矩阵、标签向量、编码器和标准化器
模型训练模块	训练集、验证集和配置参数	模型参数文件、训练日志和验证指标
模型评估模块	测试集和模型文件	分类指标、混淆矩阵和错误样本记录
在线推理模块	单条或批量流量特征	异常概率、预测标签和告警等级
告警管理模块	推理结果与元数据	告警列表、查询结果和统计报表

第四章 异常流量检测模型设计与实现

4.1 模型设计思想

网络流量特征具有两类典型特点：一是字段之间存在局部组合关系，例如协议、端口、连接状态和包长统计之间的异常组合可能指向扫描或漏洞利用行为；二是会话行为存在序列依赖，例如短时间内连续出现的连接失败、突发流量或上下行比例异常，往往比单个字段更能反映攻击意图。基于上述观察，本文设计 CNN-BiLSTM-Attention 融合模型，以兼顾局部特征提取、上下文建模和关键特征选择。

模型输入为预处理后的流量特征矩阵。对于每个样本 x_i ，将其整理为长度为 T 、通道数为 d 的特征序列。模型首先通过一维卷积层提取局部特征组合，再将卷积输出送入双向 LSTM 层建模前后依赖，随后通过注意力层生成上下文向量，最后经全连接层和 Softmax 层输出类别概率。

4.2 网络结构

模型结构由输入层、卷积特征提取层、双向 LSTM 层、注意力层和分类层组成。其主要参数设置如表4.1所示。

表 4.1 模型主要参数设置

结构层	参数	作用
一维卷积层	卷积核大小为 3，通道数为 64	提取相邻特征之间的局部组合模式
池化层	最大池化	降低特征维度并增强局部平移鲁棒性
BiLSTM 层	隐含单元数为 64	建模流量特征序列的双向依赖关系
注意力层	加性注意力	为关键时间步或特征片段分配更高权重
全连接层	Dropout 率为 0.5	完成高层表示映射并缓解过拟合
输出层	Softmax	输出正常与异常类别概率

为了缓解过拟合，本文在全连接层前加入 Dropout，并在训练阶段采用早停策略。当验证集损失连续若干轮不再下降时停止训练，保留验证集表现最优的模型参数。

4.3 损失函数与优化方法

对于二分类异常检测任务，本文采用加权交叉熵损失函数：

$$L = -\frac{1}{N} \sum_{i=1}^N w_{y_i} [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)], \quad (4.1)$$

其中， N 为样本数量， w_{y_i} 为类别权重， p_i 为模型预测样本属于异常类别的概率。类别权重根据训练集中各类别样本比例自动计算，异常类样本越少，其权重越高。

模型参数采用 Adam 优化器更新^[8]。相比普通随机梯度下降，Adam 能够自适应调整不同参数的学习率，在稀疏特征和非平稳目标函数下通常具有更快的收敛速度。训练过程中使用验证集监控模型泛化能力，避免模型仅记忆训练样本。

4.4 检测算法流程

检测流程包括训练阶段和推理阶段。训练阶段从历史数据中学习模型参数，推理阶段对新样本输出异常概率和告警结果。

算法 4.1 基于 CNN-BiLSTM-Attention 的异常流量检测算法

输入： 训练样本集合 D ，检测阈值 θ ，训练轮数 E

输出： 训练后的模型 M 与异常检测结果

- 1: 对 D 进行缺失值处理、类别编码和标准化；
 - 2: 按比例划分训练集、验证集和测试集；
 - 3: **for** $epoch = 1$ to E **do**
 - 4: 将批量样本输入 CNN 层提取局部特征；
 - 5: 将卷积特征输入 BiLSTM 层获取上下文表示；
 - 6: 通过注意力层计算上下文向量；
 - 7: 根据加权交叉熵计算损失并更新参数；
 - 8: 若验证集损失满足早停条件，则终止训练；
 - 9: **end for**
 - 10: 加载验证集表现最优的模型参数；
 - 11: **for** 每个待检测样本 x **do**
 - 12: 计算异常概率 $p = M(x)$ ；
 - 13: **if** $p \geq \theta$ **then**
 - 14: 输出异常告警；
 - 15: **else**
 - 16: 输出正常结果；
 - 17: **end if**
 - 18: **end for**
-

4.5 系统实现要点

在工程实现中，本文将训练配置与代码逻辑分离。学习率、批大小、训练轮数、阈值和模型保存路径统一写入配置文件，便于复现实验。数据预处理阶段保存编码器和标准化器，确保训练阶段与推理阶段使用完全一致的特征转换方式。模型文件采用版本化命名，包含数据集名称、训练日期和主要参数，便于回滚与对比。

在线推理模块采用批处理方式提升吞吐量。当短时间内接收到多个待检测样本时，系统将其组合为小批量输入模型，减少重复调度开销。对于告警结果，系统不仅记录预测标签，还记录异常概率和关键特征摘要，为后续人工研判提供依据。

4.6 本章小结

本章提出了 CNN-BiLSTM-Attention 融合检测模型，给出了网络结构、损失函数、优化方法和检测算法流程，并说明了系统实现中的关键工程细节。下一章将基于公开数据集对模型效果和系统功能进行验证。

第五章 实验设计与结果分析

5.1 实验环境与数据集

本文实验采用公开网络入侵检测数据集进行验证。数据集包含正常流量和多类异常流量，特征覆盖连接持续时间、协议类型、服务类型、源目字节数、连接状态、错误连接比例和主机访问统计等内容。为了便于二分类检测，本文将各类攻击统一映射为异常类别，将正常样本映射为正常类别。

实验环境如表5.1所示。

表 5.1 实验环境

项目	配置
操作系统	Windows 11 / Ubuntu 22.04
编程语言	Python 3.10
深度学习框架	PyTorch 2.x
主要依赖	NumPy、Pandas、Scikit-learn、Matplotlib
训练设备	CPU 或单张 GPU

实验过程采用固定随机种子，以减少数据划分和参数初始化带来的随机波动。训练集、验证集和测试集按照 7 : 1 : 2 划分，并保持正常与异常类别比例基本一致。

5.2 对比方法与参数设置

为验证本文模型的有效性，选取以下方法作为对比：

- (1) 支持向量机。采用径向基核函数，对标准化后的特征进行分类。
- (2) 随机森林。利用多棵决策树进行集成学习，适合处理非线性结构化特征^[9]。
- (3) 多层感知机。由两层全连接网络构成，用于验证深度非线性映射的基础效果。
- (4) CNN 模型。仅使用一维卷积层和全连接层，用于观察局部特征提取的贡献。
- (5) 本文模型。采用 CNN-BiLSTM-Attention 融合结构。

深度学习模型均采用 Adam 优化器，初始学习率设为 0.001，批大小设为 128，最大训练轮数设为 50。若验证集损失连续 5 轮未下降，则触发早停。异常检测阈值默认设为 0.5，并在阈值分析实验中进行调整。

5.3 实验结果分析

各模型在测试集上的二分类检测结果如表5.2所示。表中数值为一次实验草稿中的示例性结果，用于展示论文写作与排版结构；在正式论文中应替换为真实复现实验结果。

表 5.2 不同模型检测性能对比

模型	准确率	精确率	召回率	F_1 值	误报率
支持向量机	0.941	0.928	0.913	0.920	0.046
随机森林	0.962	0.951	0.946	0.948	0.031
多层感知机	0.958	0.943	0.948	0.945	0.037
CNN	0.966	0.955	0.954	0.954	0.029
本文模型	0.974	0.964	0.969	0.966	0.023

从结果可以看出，传统机器学习模型在结构化特征上已经能够取得较好效果，其中随机森林优于支持向量机，说明集成树模型能够较好捕捉特征之间的非线性关系。多层感知机在召回率上有所提升，但误报率略高，表明单纯全连接结构容易受到特征噪声影响。CNN 模型通过局部特征提取提升了整体性能，但对长距离依赖关系刻画不足。本文模型在召回率和 F_1 值上表现最好，说明 BiLSTM 和注意力机制有助于增强异常行为上下文建模能力。

5.4 消融实验

为了分析各结构模块的贡献，本文设计消融实验，结果如表5.3所示。

表 5.3 模型消融实验结果

模型结构	准确率	召回率	F_1 值
CNN	0.966	0.954	0.954
CNN-BiLSTM	0.970	0.962	0.961
CNN-BiLSTM-Attention	0.974	0.969	0.966

消融结果表明，BiLSTM 能够提升模型对异常样本的召回能力，注意力机制进一步提升了模型对关键特征片段的利用效率。对于安全检测任务而言，召回率提升意味着更多攻击样本被捕获，但也需要关注误报率是否同步上升。本文模型在提升召回率的同时保持较低误报率，说明融合结构具有较好的综合表现。

5.5 系统测试

系统测试主要验证数据处理、模型推理和告警记录三类功能。测试流程如下：

- (1) 导入测试样本文件，检查字段解析和预处理结果是否正确。

- (2) 加载训练完成的模型文件，对测试样本进行批量推理。
- (3) 根据异常概率和阈值生成告警结果，并写入告警记录。
- (4) 查询告警列表，核对源地址、目的地址、异常概率和预测类别。

测试结果表明，系统能够完成从样本输入到告警输出的完整流程。在批量推理模式下，系统吞吐量明显高于逐条推理模式，说明批处理策略能够降低模型调用开销。对于异常概率接近阈值的样本，系统保留概率值和原始特征摘要，便于安全人员结合业务上下文进行复核。

5.6 本章小结

本章介绍了实验环境、数据集处理、对比方法、实验结果和系统测试。实验分析表明，本文设计的 CNN-BiLSTM-Attention 模型在多项检测指标上优于对比方法，系统原型能够支撑异常流量检测的基本工程流程。

第六章 总结与展望

6.1 全文总结

本文围绕网络异常流量检测任务，完成了从理论分析、模型设计到系统实现的研究工作。首先，论文分析了网络异常检测的研究背景和现有方法，指出传统规则方法和浅层机器学习方法在未知攻击识别、特征表达和样本不均衡场景下面临的不足。其次，论文构建了面向深度学习模型的流量数据处理流程，对缺失值、类别特征、数值标准化和类别不均衡问题进行了统一处理。再次，论文设计了融合 CNN、BiLSTM 和注意力机制的检测模型，通过局部特征提取、上下文建模和关键特征加权提升异常流量识别能力。最后，论文实现了一个异常流量检测原型系统，支持离线训练、模型评估、在线推理和告警记录，并通过对比实验和系统测试验证了方案的可行性。

实验结果表明，本文模型相较于支持向量机、随机森林、多层感知机和单一 CNN 模型，在准确率、召回率和 F_1 值上具有更稳定的表现。系统测试表明，训练与推理分离的架构能够支撑后续模型替换、阈值调整和业务接入，具有一定工程扩展能力。

6.2 不足与展望

本文工作仍存在一些不足。首先，实验主要基于公开数据集，公开数据与真实生产网络之间仍存在分布差异，模型在真实场景中的泛化能力需要进一步验证。其次，本文采用结构化流量特征作为输入，对加密流量中的证书、握手过程和时序侧信道信息利用不足。再次，深度模型的可解释性仍有提升空间，当前注意力权重只能提供一定程度的参考，尚不能完全解释每一次告警的因果依据。

后续研究可以从以下方向展开：一是接入真实网络镜像流量，建立持续更新的数据闭环，通过增量学习或在线学习缓解流量分布漂移；二是结合图神经网络建模主机、端口和会话之间的关联关系，提升对横向移动和低频攻击的发现能力；三是引入可解释人工智能方法，为告警结果生成更加清晰的特征贡献说明；四是结合安全运营平台，实现告警聚合、资产画像和自动化响应，进一步提升模型的实际应用价值。

参考文献

- [1] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436–444.
- [2] Mirsky Y, Doitshman T, Elovici Y, et al. Kitsune: An ensemble of autoencoders for online network intrusion detection[C]. Proceedings of the Network and Distributed System Security Symposium. 2018.
- [3] Tavallaee M, Bagheri E, Lu W, et al. A detailed analysis of the KDD CUP 99 data set[C]. Proceedings of the IEEE Symposium on Computational Intelligence for Security and Defense Applications. 2009: 1–6.
- [4] Moustafa N, Slay J. UNSW-NB15: a comprehensive data set for network intrusion detection systems[J]. Military Communications and Information Systems Conference, 2015: 1–6.
- [5] Sharafaldin I, Lashkari A H, Ghorbani A A. Toward generating a new intrusion detection dataset and intrusion traffic characterization[C]. Proceedings of the International Conference on Information Systems Security and Privacy. 2018: 108–116.
- [6] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2017: 5998–6008.
- [7] Yin C, Zhu Y, Fei J, et al. A deep learning approach for intrusion detection using recurrent neural networks[J]. IEEE Access, 2017, 5: 21954–21961.
- [8] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]. Proceedings of the International Conference on Learning Representations. [S.l.: s.n.], 2015.
- [9] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5–32.

附录 A 程序清单

第三章系统数据处理程序:

preprocess.py: 读取原始流量数据，完成缺失值处理、类别编码、标准化和数据集划分。

config.yaml: 保存数据路径、模型参数、训练参数和检测阈值。

第四章模型训练与推理程序:

model.py: 定义 CNN-BiLSTM-Attention 异常检测模型。

train.py: 完成模型训练、验证、早停和参数保存。

predict.py: 加载模型文件，对单条或批量流量样本进行异常概率预测。

第五章实验评估程序:

`evaluate.py`: 计算准确率、精确率、召回率、 F_1 值、误报率和混淆矩阵。

plot_metrics.py

暂无已发表学术论文。正式提交前可根据实际成果补充论文题名、作者顺序、期刊或会议名称、发表时间和检索情况。

暂无已授权或已受理专利。正式提交前可根据实际成果补充专利名称、申请号、发明人顺序和授权状态。

参与项目可在正式提交前补充。建议列出项目名称、项目来源、起止时间、本人承担工作和与论文研究内容的对应关系。

致谢

值此论文完成之际，谨向在学习和研究过程中给予我帮助的老师、同学和家人表示衷心感谢。感谢导师在论文选题、研究方法和论文写作方面给予的指导；感谢课题组同学在实验讨论和系统实现过程中提出的建议；感谢家人在学习期间给予的理解和支持。

由于本人学识和时间有限，论文中仍有不足之处，恳请各位老师批评指正。