



南京邮电大学
Nanjing University of Posts and Telecommunications

A Renegotiable contract-theoretic incentive mechanism for Federated learning

Xavier Tan¹, Xiaoli Tang¹, Han Yu¹

¹College of Computing and Data Science, Nanyang Technological University, Singapore

arXiv:2510.15344

汇报人：卢锦帆

汇报日期：2025.12.12





目录

CONTENTS

- 1 Introduction
- 2 System Model And Problem Formulation
- 3 Theoretical Proof
- 4 Experiment
- 5 Conclusion

联邦学习（FL）因数据隐私问题日益凸显而备受关注。隐私限制使得数据消费者Data Consumers（DC）难以准确评估数据所有者Data Owners（DO）的能力与投入。因此，要让开放协作的联邦学习市场蓬勃发展，有效的激励机制至关重要，因为它们能激励数据所有者（DO）参与联邦学习任务。合同理论是开发联邦学习激励机制的有效工具。现有方法通常假设一旦DC与DO签订合同，该合同将保持不变直至联邦学习任务完成。然而，不可预见的情况可能导致DO无法履行现有合同，从而造成DC预算的低效利用。为解决这一局限，我们提出联邦学习的可重新协商合同理论激励机制（RC-TIM）。与以往方法不同，该机制通过支持合同重新协商，灵活应对DO行为变化和预算约束，提供动态且富有弹性的激励方案。在RC-TIM下，FL系统能更好地适应可能影响DO服务质量的运行环境中的不可预测变化。在三个基准数据集上的大量实验表明，RC-TIM显著优于四种最先进的相关方法，平均效用增加高达45.76%。

1.Introduction

背景动机

近年来，联邦学习（FL）作为一项关键技术，已引发学界广泛关注。为促进联邦学习场景下数据消费者（DC）与数据所有者（DO）的开放协作，向DO提供合理激励机制至关重要。对于那些主营业务并非机器学习模型训练的机构（如医院、金融机构），这种激励机制尤为重要，因为参与联邦学习往往需要将宝贵资源从核心业务中抽调。此外，由于隐私保护要求，DC无法直接评估DO的实际能力或投入程度，这种信息不对称可能导致激励机制效果欠佳。为此，合同理论（CT）已被广泛应用于多种FL激励机制的设计中。合同理论研究的核心思路在于探究实体在面临利益冲突和信息不对称时如何达成最优协议。在基于合同的联邦学习框架中，DC会制定包含预期贡献标准与对应奖励机制的合同清单，使DO可根据自身类型从这些合同中选择加入联邦学习。合同的自我披露特性即使在信息不对称的情况下，也能有效引导各方达成最优条款。



1.Introduction

挑战

现有基于合同的联邦学习（FL）面临实际限制。

首先，当前方法要求DC和DO在合同执行期间保持完全承诺，这在现实中往往难以实现。

DO可能因网络问题、电池续航不足或故意采取半诚实行为而中途退出，导致合同履行不完整。其次，制定最优合同需要DC准确评估完成训练任务所需的资源（如预算、时间、数据、算力、通信带宽）。在现实竞争环境中，项目常出现超支或延期，迫使双方重新协商或延长合同。此外，FL任务涉及多轮训练，这引发了对DO持续投入的担忧。预期贡献与实际贡献的差距可能导致奖励不确定性，进而引发参与度不足和预算高估问题。因此，为整个联邦学习任务周期绑定单一合同既不可行也不高效。



1.Introduction

主要贡献

现有基于合同的联邦学习方法无法支持动态合同重新协商。为弥补这一重要差距，我们为联邦学习（FL）提出了可重新协商的合同理论激励机制（RC-TIM）。该机制采用两阶段可重新协商的合同框架设计，通过实时监测DO的行为和资源使用情况，有效防范类型误报或虚假陈述。在第一阶段，系统会生成初始合同。该合同基于前期估算制定。随着对DO的观测数据逐步积累，系统会通过贝叶斯更新机制，根据DO类型的概率进行合同修订。这种动态调整机制能有效解决补偿调整初期可能出现的偏差。RC-TIM既保留了对DO类型分布的自主权，又降低了对精确分布假设的过度依赖，从而优化合同设计。在三个基准数据集上的大规模实验表明，RC-TIM相较现有四种前沿方法表现显著提升，其平均效用收益最高可提升32%。



2. System Model And Problem Formulation

2.1. 基于合同的FL系统模型

我们考虑这样一种场景： $\mathcal{N} = \{1, \dots, n, \dots, N\}$ 的DOs可参与DC委托的联邦学习（FL）任务。该任务的目标是在 $\mathcal{T}$ 个全局通信轮次内或模型达到预设的泛化精度目标（以先发生者为准）训练出一个全局模型 $\omega(\mathcal{T})$ 。图1展示了该过程的概览。在每一通信轮次 $t \in [0, \mathcal{T}]$ 中，模型通过以下五个阶段进行训练。

第一阶段：任务初始化与合同设计。在此阶段，DC启动一项任务，通过最小化损失函数来训练全局模型 $\omega(t)$ ，其性能由 $\xi(\omega(t))$ 表征。DC会根据数据样本大小对可用DO划分为K类，形成集合 $\Theta = \{\theta_1, \dots, \theta_K\}$ ，并按样本量升序排列： $\theta_1 < \dots < \theta_k < \dots < \theta_K, \forall k \in \{1, \dots, K\}$ 。 θ_k 越大，表明该类DO拥有的可用数据越多，这有助于加速联邦学习训练任务的执行。DC为 θ_k 类别提供合同 $\Upsilon = (R_k, e_k)$ 。其中 $e_k = x_k \cdot d_k$ 表示k类型DO执行者需要付出的努力，该数值由本地周期数 x_k 与样本数据量 d_k 相乘得出。 R_k 代表合同完成后的奖励。随着信息交互的深入，初始分类会随着信息积累而动态调整。当存在信息不对称时，DC无法直接获知DO类型，需根据现有观测数据推断其属于k类型的概率 ρ_k ，其中 $\sum_k^K \rho_k = 1$ 。



2. System Model And Problem Formulation

第二阶段：DO进行合同选择和验收。在收到DC发来的合同清单 Υ 后，每个DO选择并验收能使其效用最大化的一份合同。

第三阶段：模型初始化。合同一经接受，DC便将当前全局模型 $\omega(t)$ 发送给参与的DOs。

第四阶段：本地模型训练与更新。在 $n \in \mathcal{N}$ 中的每个DO会使用自身数据集和计算资源，在指定的本地训练轮数 x_n 内训练本地模型 $\omega_n(t)$ ，以实现模型精度最大化，随后将模型更新提交至DC。

第五阶段：模型聚合与 RC-TIM。在接收DO的模型更新后，DC会采用联邦学习算法（如 FedAvg）进行模型聚合，以更新全局模型 $\omega(t)$ 。经过多轮联邦学习训练后，DC能更精准地判断DO与特定类型之间的关联概率，并据此修订双方利益更契合的最优合同——即修订版合同 Υ^* 。若双方对新合同达成共识，修订后的合同 Υ^* 将取代原有合同；否则，原合同将继续有效。

第六阶段：奖励和模型分发。当DO完成合同后，DC将提供约定的奖励。新更新的模型也将在该阶段分发。



2. System Model And Problem Formulation




Fig. 1: Illustration of the workflow of RC-TIM.

第一阶段：任务初始化与合同设计。
第二阶段：DO进行合同选择和验收。
第三阶段：模型初始化。
第四阶段：本地模型训练与更新。
第五阶段：模型聚合与 RC-TIM。
第六阶段：奖励和模型分发。

2. System Model And Problem Formulation

2.2. 数据所有者的能源成本

在第 t 轮训练中，DO n 与DC之间的通信成本由以下公式给出：

$$E_n^{comm}(t) = T_n^{comm} p_n^{trans} = \frac{s_n(t) \cdot p_n^{trans}}{z_n}, \quad (1)$$

其中， p_n^{trans} 表示第 n 个DO的传输功率， $s_n(t)$ 为局部模型 $\omega_n(t)$ 的规模，我们假设由于所有参与相同FL任务的参与者都在训练相同的全局模型，因此模型规模在所有参与者中保持恒定。给定传输带宽 β 时，DO的传输速率 z_n 定义为：

$$z_n = \beta \ln \left(1 + \frac{\kappa_n p_n^{trans}}{\mathcal{H}_0} \right), \quad (2)$$

其中 K_n 是DO n 与DC之间链路的信道增益，而 $\mathcal{H}_0$ 表示背景噪声。因此，等式(1)可重写为：

$$E_n^{comm}(t) = \frac{s_n(t) \cdot p_n^{trans}}{\beta \ln \left(1 + \frac{\kappa_n p_n^{trans}}{\mathcal{H}_0} \right)}. \quad (3)$$



2. System Model And Problem Formulation

不同类型的DO可分配的资源量各不相同，这直接影响其执行的本地训练轮次数量。

每个全局训练轮次的**计算能耗**（记作 $E_n^{comp}(x_n)$ ）由以下公式给出：

$$E_n^{comp}(x_n) = P_n^{cmp} \cdot T_n^{cmp}(x_n)$$

$P_n^{cmp} = \zeta_n \nu_n^2 F_n$ 表示第n个DO的计算能力。

ζ_n 是n设备计算芯片组的有效负载电容，

ν_n 为n设备处理器所需的供电电压。

F_n 则代表n设备CPU的运行频率。

$T_n^{cmp}(x_n) = \frac{\mu_n d_n x_n}{F_n}$ 表示本地训练所需的计算时间。

x_n 表示设备n在全局通信轮次中执行的本地训练轮次数量。

d_n 表示设备n为训练联邦学习模型提供的数据量。

μ_n 表示训练每单位数据所需的总CPU周期数

$$E_n^{comp} = \zeta_n \nu_n^2 \mu_n e_n$$



2. System Model And Problem Formulation

随后，DOn在单个全局通信轮次 t 中参与训练联邦学习服务器 f 模型的总成本是计算成本与通信成本的总和，其表达式为：

$$C_n^{total}(x_n, t) = \gamma_n \cdot (E_n^{cmp}(x_n) + E_n^{comm}(t)), \quad (4)$$

其中， γ_n 是成本换算系数，将DOn的能源消耗转换为货币或资源成本。



2. System Model And Problem Formulation

2.3 效用函数

DC提供的合同中，k型DO的效用量化了DO从参与中获得的收益或价值。考虑到所获得的奖励和所发生的成本，其表达式为：

$$U_k(e_k) = \theta_k R_k - C_k^{total}(e_k), \quad (5)$$

其中 e_k 表示如前所述的k型DO所付出的努力。假设行为理性，DO们往往会根据自身利益选择合同，通过挑选能最大化自身效用的合同，在追求最高回报的同时尽量降低相关成本。换句话说，DO们更倾向于留在与之建立了良好关系（即被认定为高类型）的DC。因此，DO会从可选合同中选择最优方案，力求在回报与付出之间取得最佳平衡。效用最大化行为可表示为：

$$\max_{(R_k, e_k)} U_k(e_k) = \rho_k b_k \left(\theta_k R_k - C_k^{total}(e_k) \right), \quad (6)$$

其中 ρ_k 表示DO属于k类的概率。二进制变量 b_k 用于标识第k类DO是否被选中参与联邦学习任务：若被选中则 $b_k=1$ ，否则 $b_k=0$ 。需要特别说明的是，我们假设每个DO每次只能参与一项任务。



2. System Model And Problem Formulation

DC基于所有合同提供的总效用可表示为:

$$U = \sum_k^K \rho_k \left(Q[\xi(\omega_k)] + \ln \left[T_{max} - \frac{\mu_k e_k}{F_k} - T_k^{comm} \right] - \theta_k R_k \right), \quad (7)$$

其中Q是基于模型性能的收入转换函数。



2. System Model And Problem Formulation

2.4 RC-TIM算法

为了使DO偏好于DC提供的合同 k 而优于其他可用选项，合同必须满足以下基本要求。

定义1.激励相容性（Incentive Compatibility）确保DOs被激励去如实披露其私人信息，并选择能最大化其预期效用的合同，

$$\begin{aligned}\theta_k R_k - C_k^{total}(e_k) &\geq \theta_j R_j - C_k^{total}(e_j), \\ \forall k, j &\in \{1, \dots, K\}, k \neq j.\end{aligned}\quad (8)$$

定义2.个体理性（Individual Rationality）确保DOs不会因参与而处于不利境地，即每个DO只有在预期效用为非负值时才会做出贡献。

$$U_k(e_k) = \theta_k R_k - C_k^{total}(e_k) \geq 0. \quad (9)$$

定义3.预算可行性（Budget feasibility）要求每轮全局通信的总支付不得超过DC预先定义的最大预算 B^{max} 即

$$\sum_k^K \theta_k R_k \leq B^{max}$$

为了最大化效用，DC必须在向DOs支付的总金额与全局模型的性能之间取得平衡。然而，最大化等式（7）中定义的目标并不符合凸优化的要求，这使得直接推导最优解变得困难。为解决这一问题，我们首先放松激励相容性和个体理性约束，然后通过迭代验证解决方案是否符合局部向下激励相容性（LDIC）和局部向上激励相容性（LUIC）约束。结合单调性约束，上下两种激励相容性都能得以保持。因此，可以将IC约束视为简化后的IC问题。这些条件确保了没有任何代理（即DO）会出于自身认知而虚报其类型（无论是少报还是多报）。从而促进诚实参与和高效结果。



3.Theoretical Proof

引理1：如果 θ_1 的IR约束得到满足，其他更高类型的全部IR约束均可被简化。

Lemma 1: If θ_1 's IR constraint is satisfied, all IR constraint for other higher types can be reduced.

Proof 1: It is given that,

$$\theta_k R_k - C_k^{total}(e_k) \geq \theta_k R_1 - C_1^{total}(e_1), \quad (10)$$

$$\theta_k R_1 - C_1^{total}(e_1) \geq \theta_1 R_1 - C_1^{total}(e_1), \quad (11)$$

we can reduce the IR constraints to the following,

$$\theta_1 R_1 - C_1^{total}(e_1) = 0. \quad (12)$$

这意味着，在设计最优合同时，DC（数据消费者）为了最大化自身效用，会将最低类型DO的报酬压到刚好使其愿意参与的水平（ $U_1=0$ ），而不用担心高类型DO会因为效用为负而不参与。

引理2：单调性：如果 $\theta_k \geq \theta_j$ ，那么必然有 $e_k \geq e_j$ ，从而必然有 $R_k \geq R_j$ ，其中 k 的类型高于 j ， $\forall k, j \in \{1, \dots, K\}$ 。

Lemma 2: Monotonicity: If $\theta_k \geq \theta_j$, then it must be true that $e_k \geq e_j$ such that inevitably $R_k \geq R_j$, where k is a higher type than j , $\forall k, j \in \{1, \dots, K\}$.

Proof 2: According to definition of IC and Eq. (8), we know for sure that

$$\theta_k R_k - C_k^{total}(e_k) \geq \theta_k R_j - C_j^{total}(e_j), \quad (13)$$

$$\theta_j R_j - C_j^{total}(e_j) \geq \theta_j R_k - C_k^{total}(e_k), \quad (14)$$

Combining the above two equation will yield us: $(\frac{1}{\theta_j} - \frac{1}{\theta_k})(e_k - e_j) \geq 0$, and $(R_k - R_j) \geq C_k^{total}(e_k) - C_j^{total}(e_j)$ which can be further simplified into:

$$(R_k - R_j) \geq \mu_k \zeta_k \nu_k^2 (e_k - e_j). \quad (15)$$

In other words, $(R_k \geq R_j)$ is true if and only if $e_k \geq e_j$, thus monotonicity must be held.

引理2的证明通过同时利用“高类型不会装低”和“低类型不会装高”这两个IC约束，逻辑上强制要求合同清单必须是单调的：分配给高类型DO的努力和报酬都不能低于低类型的。



3.Theoretical Proof

Lemma 3: In conjunction with lemma 2, the IC constraints can therefore be further reduced as a pair of LDIC and LUIC constraints, $\theta_k R_k - (\mu_k \zeta_k \nu_k^2 e_k) \geq \theta_k R_{k-1} - (\mu_{k-1} \zeta_{k-1} \nu_{k-1}^2 e_{k-1})$, $k \in \{2, \dots, K\}$, $k \in \{2, \dots, K\}$ and $\theta_k R_k^f - (\mu_k \zeta_k \nu_k^2 e_k) \geq \theta_k R_{k+1}^f - (\mu_{k+1} \zeta_{k+1} \nu_{k+1}^2 e_{k+1})$, $k \in \{1, \dots, K-1\}$ respectively.

However, because of the monotonicity as aforementioned, the following can be deduced, $\theta_{k+1}(R_k - R_{k-1}) \geq \theta_k(R_k - R_{k-1}) \geq \mu_k \zeta_k \nu_k^2 (e_k - e_{k-1})$. Thereafter, we can combine and simplify the pair of LDIC and LUIC to be:

$$\theta_k R_k - (\mu_k \zeta_k \nu_k^2 e_k) \geq \theta_k R_{k-1} - (\mu_{k-1} \zeta_{k-1} \nu_{k-1}^2 e_{k-1}). \quad (16)$$

Proof 3: From Eq. (12), it is in the interest of the DC to reduce R_1 as much as possible, such that they could maximise their utility yield (i.e., hiring DOs at cost price $\theta_1 R_1 - C_1^{total}(e_1) = 0$). This applies to LDIC as well, the DC would want to reduce reward value until $\theta_k R_k - C_1^{total} = \theta_k R_{k-1} - C_1^{total}(e_{k-1})$. This can be reformatted as $\theta_k R_k - \theta_k R_{k-1} = (\mu_n \zeta_n \nu_k^2 e_k - e_{k-1})$ combining with Eq. (15) we can derive our reduced IC constraint Eq. (16).

k型DO选择k型合同的效用不小于k型DO选择k-1型合同的效用 (LDIC)

k型DO选择k型合同的效用不小于k+1型DO选择k+1型合同的效用 (LUIC)

根据式12, DC为使得其效用最大化, 要尽可能减少R1, 即以成本价雇佣DO。

将其推广至LDIC中, k型DO选择k型合同的效用等于k型DO选择k-1型合同的效用



3.Theoretical Proof

假设所有DO在所有通信轮次中都经历相似的通信条件，即对于任何 t ，我们有 $E_1^{comm} = E_2^{comm} = \dots = E_k^{comm}$ 对于所有 $k \in K$ ，并且 γ_k 保持不变，那么在等式(7)中定义的效用函数可以重写为：

$$\max_{(R_k, e_k)} U(e_k, R_k), \quad (17)$$

subjected to:

$$\theta_1 R_1 - C_1^{total}(e_1) = 0, \quad (18)$$

$$\theta_k R_k - (\mu_k \zeta_k \nu_k^2 e_k) \geq 0, \quad (19)$$

$$\theta_k R_{k-1} - (\mu_{k-1} \zeta_{k-1} \nu_{k-1}^2 e_{k-1}), k \in \{2, \dots, K\},$$

$$\sum_{k=1}^K \theta_k R_k \leq B^{max}, \forall k \in K. \quad (20)$$

等式（18）-等式（20）分别代表了IC和IR要求的简化版本以及预算约束。



3.Theoretical Proof

整合约束条件， 我们可以推导出 R_k 如下：

$$R_k = \sum_{k=2}^K \frac{1}{\theta_k} \mu_k \zeta_k \nu_k^2 (e_k - e_{k-1}) + \frac{1}{\theta_1} \left(C_1^{total}(e_1) \right). \quad (21)$$

在等式（21）中，最优奖励 R_k 现在取决于DO的努力 e_k 。这使我们能够使用单个变量有效求解等式（17）。换句话说，我们可以根据每个DO可提供的可行努力水平集迭代确定最优合同奖励 $R_k(e_k)$ ，并确保该解满足单调性约束；即，付出较少努力的低类型DO获得的奖励低于付出更多努力的高类型代理。

$$\text{由 } \theta_1 R_1 - C_1^{total}(e_1) = 0, \quad R_1 = \frac{1}{\theta_1} \left(C_1^{total}(e_1) \right)$$

$$\text{由 } \theta_2 R_2 - \mu_2 \zeta_2 \nu_2^2 e_2 = \theta_2 R_1 - \mu_1 \zeta_1 \nu_1^2 e_1, \quad R_2 = R_1 + \frac{1}{\theta_2} (\mu_2 \zeta_2 \nu_2^2 e_2 - \mu_1 \zeta_1 \nu_1^2 e_1)$$

$$\text{由 } \theta_3 R_3 - \mu_3 \zeta_3 \nu_3^2 e_3 = \theta_3 R_2 - \mu_2 \zeta_2 \nu_2^2 e_2, \quad R_3 = R_2 + \frac{1}{\theta_3} (\mu_3 \zeta_3 \nu_3^2 e_3 - \mu_2 \zeta_2 \nu_2^2 e_2)$$



3.Theoretical Proof

将 R_k 代入总期望奖励函数 $\sum_k^K \rho_k \theta_k R_k$ 后，我们可以推导出类型k的DO在概率分布 ρ_k 下所需的总奖励：

$$\sum_k^K \rho_k \theta_k R_k = \sum_k^K X_k + \frac{C_1^{comm}}{\theta_1} \sum_k^K \theta_k \rho_k. \quad (22)$$

For $k < K$, we have:

$$X_k = \mu_k \zeta_k \nu_k^2 e_k + \mu_k \zeta_k \nu_k^2 e_k \left(\frac{1}{\theta_k} - \frac{1}{\theta_{k+1}} \right) \sum_{i=k+1}^K \theta_i \rho_i, \quad (23)$$

$$\text{if } k = K, X_k = \mu_K \zeta_K \nu_K^2 e_K$$

X_k 作为代数替换变量，用于保持方程的清晰简洁。通过闭式解法，我们可以将目标函数转化为单变量问题。进一步推导得出 $\frac{\delta^2 U}{\delta e_k^2} \leq 0$ ，表明该函数存在极大值点。运用凸优化技术，可推导出最优努力值 $\hat{e}_k$ 及其对应奖励 $\hat{R}_k^f$ 。



3.Theoretical Proof

最初，我们假设DO类型是均匀分布的。然后可以确定每个DO的本地训练周期数，即 $x_k = \frac{e_k}{d_k}$ 经过t轮次的沟通后，DC将获得关于参与DO行为的新观测数据，记为 ψ 。这些更新后的观测数据可用于优化对DO类型的先验认知。通过贝叶斯定理，决策中心可以更新其类型分布： $\Pr(\theta = k|\psi) \propto \Pr(\psi) \Pr(\psi|\theta = k)$ ，将新信息融入决策流程。此时更新后的类型概率分布将变为：

$$\Pr(\theta = k|\psi) = \frac{\Pr(\psi|\theta = k) \Pr(\theta = k)}{\Pr(\psi)}, \quad (24)$$

$\Pr(\theta = k)$: 先验概率 (初始为 $1/K$)。

$\Pr(\psi | \theta = k)$: 似然函数，表示如果 DO 真实类型为 k ，观察到 ψ 的概率。

$\Pr(\psi)$: 边际似然，用于归一化。

$\Pr(\theta = k | \psi)$: 后验概率，即更新后认为该 DO 属于类型 k 的概率。

其中， $\Pr(\psi)$ 可使用全概率定律计算： $\Pr(\psi) = \sum_{k=1}^K \Pr(\psi|\theta = k) \Pr(\theta = k)$ 。随后，DC可以向参与
的DOs提出新起草的合同 Υ^* 。为确保预算可行性，DC会检查模型是否按预期收敛，并确认重新签订合同
时有足够的预算剩余。具体而言，DC验证条件 $\sum_t^{T/a} \sum_k^K \theta_k R_k \leq \frac{B_f^{max}}{a}$ 和 $\omega(t) \leq \omega(t-1)$ 在 $t = \frac{T}{a}$ 轮
成立，其中a代表对总训练轮数的预定义划分。



3.Theoretical Proof

Algorithm 1 RC-TIM

Initialize: $\omega_f(0)$; T_{max} ; training parameters.
Formulate the menu of contracts for DOs types based on prior probability distribution, $\Upsilon = (R_k(e_k)|\mathcal{P}_k)$;
Each DO n choose preferred contract and participate in FL task;
DC publishes $\omega(0)$ to all participating DOs;
while $t < T$ **do**
 When budget expenditure is available, perform FL training with FedAvg
 if $k = K$ **then**
 $\hat{R}_k = \mu_k \zeta_k \nu_k^2 e_k$;
 else
 $\hat{R}_k = \mu_k \zeta_k \nu_k^2 e_k + \mu_k \zeta_k \nu_k^2 e_k (\frac{1}{\theta_k} - \frac{1}{\theta_{k+1}})$;
 end if
 if $t = \frac{T}{a}$ & $\sum_t^{T/a} \sum_k^K R_k \leq \frac{B_f^{max}}{a}$ & $\omega(t) \leq \omega(t-1)$
 then
 update ψ and probability distribution;
 $\Pr(\theta = k|\psi) = \frac{\Pr(\psi|\theta=k) \Pr(\theta=k)}{\Pr(\psi)}$;
 Reformulate contract, $\Upsilon^* = [R^k(e_k)|(\mathcal{P}_k|\psi)]$;
 if n accepts new contract **then**
 Υ^* takes effect, and DC pays the new $\hat{R}^k$ to DO n of type k .
 else
 Υ is still effective.
 end if
 end if
 end while

新合同将根据等式（23）进行设计，确保其更符合实际观察到的行为和能力，从而提升协议的公平性和有效性。RC-TIM的伪代码展示为算法1。



4.Expeiment

在本节中，我们基于三个基准数据集评估了RC-TIM与 另外四种最先进的方法。

A.实验设置

在CIFAR-10数据集[16]上训练的模型包含1,006,206个参数，采用两层卷积神经网络（CNN）模块后接三层全连接（FC）层的架构，其中第三层前设有丢弃层。

而用于EMNIST[17]balanced数据集的模型参数数量为907,491，其架构与CIFAR-10类似，但仅保留单输入通道且未配置丢弃层。

MNIST模型[18]有21,840个参数，由两个简单的CNN和最大池化块组成，后面跟着两个较小的全连接层。最初，45个DO被分为10种不同类型，即 $\{1, \dots, 10\}$ ，每种类型的概率均为0.1。对于收益转换函数，我们设定 $Q(\xi(\omega_k)) = 2 \cdot \xi(\omega_k)$ 。

我们在IID和非IID场景下测试了我们的方法以及其他四种先进方法。对于RC-TIM方法，我们假设DO最初具有均匀的类型先验分布。在50轮通信中的25轮后，如果DC观察到某些DO的类型偏离预期，它可以在满足某些条件的情况下更新这些DO的类型并提出新的合同。其他超参数设置记录在表I中。

TABLE I: Experiment parameters.

Parameters	Value	Parameters	Value	Parameters	Value
Budget	400	T_{max}	1500ms	Batch Size	128
Total Rounds	50	Total DOs	45	Learning rate	0.01
DO starting price	0.2	γ_f	0.003	E_n^{cmp}	0.01
Momentum	0.9	Number of types	10	E_n^{comm}	0.1



4.Expeiment

B.比较基线

我们将本方法与四种其他前沿方法进行了比较，这些方法在联邦学习（FL）的激励机制客户选择场景中已展现出优异性能。

- 1) GTG-SV: Shapley value (SV) 是一种用于评估每个参与者贡献水平的方法，奖励根据每个参与者的相关SV按比例分配。为了降低SV的计算复杂度，GTG-SV提供了一种引导估计方法。
- 2) OORT: 该方法可以逐步有效地选择参与者，平衡探索和利用的困境，以确定高性能的贡献者。
- 3) RRAFL: 在逆向拍卖框架下设计的声誉感知激励机制，旨在在遵守给定的预算约束的情况下，选择k个信誉最好的参与者。
- 4) 合同: 这种方法完全基于最优方案合同，奖励对应于等式(21)和等式(23)。



4.Expeiment

C. 结果和分析

实验结果详见表II，其中最优结果以粗体标出。数据显示，RC-TIM在非独立同分布（nonIID）场景中表现尤为突出，整体优于其他前沿方法。

具体而言，在MNIST非IID数据集上，RC-TIM的总效用分别比基础合同方法、GTGSV、OORT和RRAFL高出4.52%、29.93%、33.84%和38.02%。

而在更具挑战性的CIFAR10非IID数据集上，RC-TIM的总效用则以11.58%、51.08%、81.27%和39.11%的增幅，再次展现出压倒性优势。

TABLE II: Simulation Results.

Method	Dataset	IID	Non-IID
		Utility ($\times 10^2$)	
RC-TIM	MNIST	77.20	73.37
	EMNIST-balanced	79.20	59.29
	CIFAR10	44.48	43.18
Contract	MNIST	76.76	70.20
	EMNIST-balanced	77.16	58.66
	CIFAR10	34.67	38.70
GTG-SV	MNIST	68.37	56.47
	EMNIST-balanced	76.98	58.31
	CIFAR10	36.97	28.58
OORT	MNIST	67.66	54.82
	EMNIST-balanced	73.44	53.65
	CIFAR10	35.05	23.82
RRAFL	MNIST	62.06	53.16
	EMNIST-balanced	68.22	56.16
	CIFAR10	29.07	31.04



5. Conclusion

本文提出了一种基于合同理论的激励机制RC-TIM，旨在使奖励机制与DO的能力和偏好相匹配。然而，合同理论依赖于对DO类型的假设，这些假设可能因误报、DO行为随时间变化或对DO类型概率分布的错误假设等问题而存在偏差。通过利用联邦学习（FL）在多轮通信中持续进行的特点，我们充分利用了各轮次中披露的新信息，能够更新DO所属特定类型的概率，从而重新构建新的合同清单。大量实验结果表明，相较于现有最先进方法，RC-TIM在非IID场景中尤其展现出更优的效用表现。

展望

后续研究中，将通过探索更高效的合同更新方法，并开发更具动态性的评估机制，来优化RC-TIM系统，从而为DC部门针对每个独立DO启动合同审查提供最佳决策依据。





南京邮电大学先进网络与经济实验室

谢谢!



计算机学院 软件学院
网络空间安全学院
School of Computer Science

