

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于多任务联邦学习与激励机制的车联网资源分配策略

学	号	<u>1025040716</u>
姓	名	<u>卢锦帆</u>
导	师	<u>刘婷婷</u>
专业学位类别		<u>工学</u>
类	型	<u>全日制</u>
专业（领域）		<u>计算机科学与技术</u>
论文提交日期		<u>2026.5.22</u>

摘要

随着车联网 (IoV) 应用的持续涌现, 众多资源密集型应用对计算资源的需求呈现爆发式增长态势, 这对车辆本身有限的计算资源构成了严峻挑战。本文设计了一种基于两层博弈机制的车联网联邦学习架构, 利用智能路边终端实现联邦优化; 同时提出了一种名为“激励驱动型联邦学习与云边缘游戏 (FL- CEGID)” 的算法, 用于车联网中的动态任务卸载。该算法通过分层分布式方法优化车辆与计算资源分配及缓存更新, 采用独立的车辆智能策略和边缘智能策略分别进行卸载决策与缓存管理。实验结果表明, 相较于其他方案, FL- CEGID 在传输容量、传输延迟以及车联网关键任务与场景下的性能表现均显著提升。

关键词: 车联网, 联邦学习, 激励机制, 云边缘游戏, 资源分配

Abstract

With the continuous emergence of Internet of Vehicles (IoV) applications, the demand for computational resources of many resource-intensive applications in IoV has shown an explosive growth trend, which poses a serious challenge to the limited computational resources of the vehicles themselves. This paper designs a federated learning structure with a two-layer game for vehicular networks, using intelligent roadside terminals for federated optimization. Meanwhile, this paper proposes a Federated Learning and Cloud-Edge Gaming with Incentive-Driven (FL-CEGID) algorithm for dynamic task offloading in IoV. Our proposed algorithm optimizes vehicle and computing resource allocation as well as cache updates through a hierarchical distributed approach, which has separate vehicle and edge intelligence strategies for offloading decisions and caching strategies. The experimental results show that our proposed FL-CEGID has significant improvements in transmission capacity, transmission delay, and advantages in different key tasks and times in IoV compared to other schemes.

Key Words: Internet of Vehicles, federated learning, incentive mechanisms, cloud-edge game, resource allocation

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 研究难点	3
1.4 主要研究内容与创新点	3
第二章 相关背景知识介绍	4
2.1 联邦学习	4
2.2 车联网	4
2.3 本章小结	5
第三章 多条智能路边终端间用于 IOV 的联邦学习层级架构	6
3.1 分层结构	6
3.2 卸载收益模型	8
3.3 回收效益的建模	9
3.4 本章小结	10
第四章 基于云边缘博弈的联合激励驱动学习算法	11
4.1 客户端和服务端更新	11
4.2 激励目标函数与激励驱动机制	12
4.3 破解云与边缘的博弈	13
4.4 本章小结	14
第五章 实验与分析	15
5.1 实验设置	15
5.1.1 具体配置	15
5.1.2 基线方法	15
5.2 实验指标	16
5.3 吞吐量与收益分析	16
5.4 满意度分析	17
5.5 本章小结	18
第六章 总结与展望	19
6.1 本文工作总结	19
6.2 进一步研究方向	19
参考文献	20

插图索引

图 3.1 车联网 (IoV) 中多个智能路边终端间的联邦学习层级结构	6
图 5.1 不同条件下的吞吐量	16
图 5.2 不同条件下的收益值	17
图 5.3 不同条件下的满意度	18

表格索引

表 5.1 多源数据传输实验设置 18

第一章 绪论

1.1 研究背景与意义

随着车联网 (IoV) 应用的持续涌现, 众多资源密集型应用对计算资源的需求呈现爆发式增长态势, 这对车辆本身有限的计算资源构成了严峻挑战^[1]。联邦学习是一种采用“客户端-服务器”模式的分布式机器学习方法, 能够在不共享数据所有者原始数据的情况下实现大规模数据的协作学习^[2]。与云计算和移动边缘计算 (MEC) 相比, 联邦学习无需在客户端与服务器之间共享原始数据, 从而为客户端数据隐私提供了保障。相较于原始数据的传输, 联邦学习有效降低了物联网 (IoV) 的通信开销^{[1][2]}。IoV 是联邦学习的重要应用场景。新兴的 IoV 系统涉及大量车辆传感器数据, 以及在复杂车辆环境中各类智能驾驶与智能交通应用^[3]。与此同时, 某些新兴服务 (例如互联式智能驾驶与智能交通系统) 需要前所未有的高可靠性、高精度和快速响应能力。不同用户对时间、位置及内容方面的资源需求存在显著差异。仅考虑单个车辆智能处理能力或依赖将车辆数据传输至云端由集中式云服务器处理的 IoV 系统, 将无法满足新兴服务的需求^{[4][5]}。

联邦学习通过实现无需共享原始数据的协作式模型训练, 能够显著提升自动驾驶和智能交通管理能力。在自动驾驶领域, 车辆会处理摄像头图像、雷达信号等传感器数据以完成导航和决策。借助联邦学习技术, 各车辆可协同优化目标检测与路径规划模型; 边缘服务器则负责协调本地模型参数的聚合, 构建全局模型以支持实时决策。这一机制有效提升了自动驾驶的安全性并保护了数据隐私。

1.2 国内外研究现状

本节将综述与联邦学习及物联网车辆 (IoV) 相关的研究工作, 重点关注以下关键领域: 联邦学习的应用与挑战、协作学习的构建方式及 IoV 的基础设施、深度强化学习在 IoV 中的应用。

联邦学习使车辆能够从分布式数据中学习, 同时保护用户隐私, 但面临数据和节点资源异构性等挑战。联邦学习对多次聚合轮次的依赖也会消耗通信和计算资源, 增加车辆用户的成本。车辆资源的差异可能导致模型更新延迟, 影响服务效率。因此, 提升本地数据质量与优化参与者选择策略对于增强车联网中的联邦学习至关重要^[6]。为实现更智能的车联网系统, 亟需不同车辆与 RSU 之间开展协作学习, 以充分利用更智能车辆的数据、资源和能力, 同时满足部署联邦学习的车联网用户隐私保护需求——通常情况下, 移动车辆作为联邦学习的客户端, 而联邦学习聚合服务器部署在 RSU 或基站上^[7]。在一些研究中, 采用了两级联邦学习

结构：除了区域服务单元（RSU）与其覆盖范围内的若干车辆之间进行的低层级学习之外，还建立了高层级联邦学习机制，涉及云计算及若干 RSU，旨在聚合更广泛的数据信息并获得更有效的机器学习模型。在联网车辆和联邦学习领域，研究已解决了资源分配、任务卸载及数据隐私等问题。初期工作重点在于构建联邦学习基础设施与算法^[8]：该策略通过优化客户端选择与模型聚合来改进联邦学习算法，从而提升模型精度与收敛速度^[9]。随后，研究人员探索了边缘计算与深度学习的结合，以优化任务卸载与资源分配^{[10], [11]}。

已有多项研究致力于通过移动边缘计算和深度强化学习来提升车载网络的性能。Zhang 等人^[12] 采用深度强化学习开发了一种智能流量控制方案，用于解决联合优化问题并高效分配网络资源。He 等人^[13] 提出了一种改进的深度强化学习算法，旨在提升用户体验质量（QoE）满意度，并找到能节省能耗的最佳卸载模式。Qi 等人^[14] 提出了一种车载网络中的服务卸载决策框架，旨在解决卸载决策的资源调度问题；该框架考虑了长期规划，并采用深度强化学习来获取多任务卸载决策的最优解。为解决车辆实时响应问题，Lee 等人^[15] 提出了一种启发式算法来寻找有效解决方案，并将其与强化学习相结合，利用收集到的车辆移动及停车状态数据来制定更高效的资源分配决策。为应对复杂多变的车辆环境，Zhang 等人^[16] 将数字孪生与人工智能技术融入车载边缘计算网络，通过多智能深度强化学习实现计算任务卸载与边缘资源分配。部分学者已针对车载网络中的通信稳定性与资源分配展开研究。Lin 等人^[17] 提出了一种适用于车载网络的内容感知型稳定多媒体通信算法，该算法可根据特定范围内车辆的数据相关性进行动态调整，以最大化数据共享并实现稳定的多媒体通信网络结构。为解决资源分配问题，Sun 等人^[18] 提出了一种基于联邦学习的最优资源分配方法：将最佳 CPU 周期分配给高优先级任务，优化延迟与能耗的乘积，平衡延迟与能效性能，并利用联邦学习技术估算边缘服务器的执行时间。Nguyen 等人^[19] 对数据冗余与协作任务计算进行了建模，采用子模块优化技术设计出能有效减少数据传输量的算法，进而提出协作任务计算方案以优化成本并保证延迟。Naeem 等人^[20] 提出了一种调度算法，该算法利用软件定义网络实现动作价值分布的智能调度。该算法采用生成对抗网络，并引入奖励剪枝技术以确保这些网络的训练过程稳定进行。

关于联邦学习在车载网络中的应用，Samarakoon 等人^[21] 针对城市道路环境中车辆功率控制与资源分配的传输问题，提出了一种基于联邦学习的分布式解决方案：车辆在小范围内本地训练自身模型参数，随后通过路边单元在大时间尺度上进行全局模型平均。Ye 等人^[22] 针对车载应用中的边缘计算图像训练问题，每辆车都在本地训练深度神经网络（DNN）；为解决各车辆间的数据孤岛问题，采用了联邦学习机制实现模型共享。Zhang 等人^[23] 结合区块链与联邦学习技术，以兼顾物联网车辆（IoV）边缘计算的安全性及隐私保护，并通过有向无环图来表示授权区块链。Chen 等人^[24] 解决了无人机辅助边缘缓存替换策略的问题；在用户端，基于回声状态网络（Echo State Network），根据用户的移动上下文信息预测其移动模式及请求分布。He 等人^[25] 解决了在边缘智能中部署联邦学习算法时涉及的安全与隐私问题。He 等人^[26]

基于半分布式强化学习解决了这一问题，而半分布式强化学习本身存在较高的通信成本和数据泄露风险。针对最小化任务卸载延迟的问题，Chen 等人^[27]通常会让所有用户和边缘节点参与全局聚合，并将延迟最小化问题抽象为双边多对一匹配问题。针对用户偏好的时变特性，Zheng 等人^[28]采用基于长短期记忆（LSTM）网络的替代策略，在用户端预测用户偏好，并通过将全局聚合结果与当前模型的损失函数相加权，计算出边侧的聚合度。本文通过为每个 RSU 服务器分配唯一的云模型来增强联邦学习，从而提升个性化效果。

1.3 研究难点

本文深入剖析了联邦学习的训练流程，优化并改进了客户端选择机制、服务器端全局模型聚合及客户端本地模型训练方法，并为边缘智能设计了一套自适应联邦学习框架与算法。通过这些研究，本文实现了联邦学习算法在边缘智能场景中的优化升级，为边缘智能系统的部署提供了创新解决方案。

传统优化算法由于存在模型固化问题及计算复杂度过高，远无法满足车辆互联网（IoV）中资源分配与计算任务卸载的需求。本文采用联邦学习方法，有效应对车载网络中资源不确定性、资源动态变化以及多任务处理高并发性带来的挑战——这些挑战包括环境感知能力不足、环境不稳定性 and 系统复杂度高等问题。

1.4 主要研究内容与创新点

本研究的主要贡献概述如下：

（1）本文设计了一种适用于车载网络的联邦学习架构，该架构采用双层博弈机制，并利用智能路边终端实现联邦优化。

（2）本文提出了一种基于激励驱动的联邦学习与云边缘游戏（FL-CEGID）算法，该算法将联邦学习与云边缘游戏相结合，利用状态代理、动作代理、奖励代理和边缘代理来优化车辆卸载、资源分配及缓存策略。

（3）本文构建了一种多任务联邦学习与分析激励机制，该机制通过奖励率激励数据所有者，优化计算资源分配，并辅助任务卸载决策。

第二章 相关背景知识介绍

本章主要对文章的相关背景知识进行介绍，共分为两个部分：

2.1 联邦学习

联邦学习是一种分布式机器学习范式，其核心思想是“数据不动，模型动”。在传统的集中式机器学习中，所有数据需要汇集到中央服务器进行模型训练，这往往会引发数据隐私泄露、通信开销大以及数据孤岛等问题。联邦学习通过让数据持有方在本地进行模型训练，仅将模型参数（如梯度或权重）上传至服务器进行聚合，从而在不共享原始数据的前提下实现全局模型的协同学习。

联邦学习的基本架构通常采用“客户端-服务器”模式。每个客户端利用本地数据训练模型，服务器收集各客户端的模型更新后进行聚合（如联邦平均算法），再将聚合后的全局模型分发回客户端，如此迭代直至模型收敛。这一过程天然保护了数据隐私，因为原始数据从未离开本地设备。此外，联邦学习还能显著降低通信带宽需求，因为传输的仅是模型参数而非大规模原始数据。

然而，联邦学习也面临诸多挑战。首先是数据异构性问题：不同客户端的数据分布往往不一致（即非独立同分布），这会降低全局模型的收敛速度和精度。其次是系统异构性：客户端在计算能力、存储资源、网络状况等方面存在差异，可能导致“掉队者”问题。此外，联邦学习对通信轮次的依赖使得其在无线网络环境下的稳定性成为关键瓶颈。近年来，研究者们提出了多种改进方案，包括客户端选择策略、自适应聚合权重、个性化联邦学习等，以提升联邦学习在实际应用中的性能与鲁棒性。

2.2 车联网

车联网（Internet of Vehicles, IoV）是物联网技术在交通运输领域的重要应用，旨在通过车辆与周围环境的全方位通信，构建“人-车-路-云”一体化的智能交通系统。在车联网中，每辆汽车不仅是交通工具，更是一个集成了传感、计算、通信能力的智能移动节点。车辆可以通过车载单元与路边单元（RSU）、其他车辆、行人设备以及云端服务器进行实时数据交换，从而获取交通状况、道路危险、信号灯状态等信息，实现辅助驾驶、路径优化、碰撞预警等功能。

车联网的典型应用场景包括自动驾驶、智能交通管理、实时导航、车队协同控制等。这些应用对通信延迟、数据传输可靠性和计算资源提出了极高要求。例如，自动驾驶车辆需要在毫秒级时间内完成对周围环境的感知、决策与控制，任何延迟都可能引发严重后果。与此

同时，车联网中车辆数量庞大、移动速度快、连接时间短，使得网络拓扑结构高度动态，传统的集中式云端处理模式难以满足实时性需求。

为解决上述问题，移动边缘计算（MEC）被引入车联网，将计算和存储资源下沉至网络边缘（如路边单元或基站），使车辆能够就近卸载任务，降低响应延迟。然而，车联网中的数据隐私问题同样不容忽视——车辆轨迹、驾驶行为等敏感信息一旦泄露，将威胁用户安全。因此，如何在保护隐私的前提下高效利用分布式车辆数据进行智能模型的训练，成为车联网研究的热点。联邦学习因其“数据本地化、模型共享化”的特性，恰好契合了这一需求，为车联网中的协同学习与资源优化提供了新的技术路径。

2.3 本章小结

本章内容共分为两个部分。旨在为后续研究打下坚实的理论基础。通过本章内容的介绍，为文章的方法提供了充分的理论支撑与技术依据。

第三章 多条智能路边终端间用于 IOV 的联邦学习层级架构

在 IoV 联邦学习架构中,云服务器与 RSU 服务器之间的同步学习过程会受到车辆移动性的影响,导致不同 RSU 覆盖区域的学习效果存在差异。这使得各 RSU 服务器的学习水平不一,从而在云服务器数据聚合后,模型在个性化能力和性能方面得到提升。

3.1 分层结构

在多个 RSU (资源服务单元) 之间的联邦学习层级架构中,较低层级是指各 RSU (车辆单元) 内多个车辆客户端与其 RSU 服务器之间的联邦学习结构,而较高层级则是多个 RSU 服务器与云服务器之间的联邦学习结构。高层级学习采用同步联邦学习模式:即每隔固定时间间隔,所有 RSU 服务器和云服务器都会依次执行“上传-聚合-下载-个性化”流程的联邦学习轮次。由于低层级学习中车辆的移动特性,不同 RSU 内部的联邦学习情况各不相同,导致同一时间不同 RSU 服务器上的模型学习水平存在差异;因此,在高层级学习中,由不同 RSU 服务器上传至云服务器的模型学习水平也会有所不同。整体架构如图 3.1 所示。




图 3.1 车联网 (IoV) 中多个智能路边终端间的联邦学习层级结构

图 3.1 展示了联邦学习的流程,从本地计算开始,逐步扩展至边缘云和智能网联汽车的整合,以提升智能车辆管理及交通安全水平。整个流程始于多个数据持有者(从数据持有者 1 到数据持有者 n),每个持有者负责存储、管理和本地处理其数据。完成本地计算后,这些数据持有者会将更新后的模型发送至中央服务器;该服务器会对这些更新进行汇总、处理,并利用汇总后的知识初始化系统,从而向各数据持有者提供反馈。与此同时,边缘云与物联网车辆 (IoV) 之间的交互关系通过一系列连续步骤展开:首先通过车辆和路边设备配备的无线

天线实现大规模通信，以收集和控制信息。这种结构化方法确保了本地数据处理、集中式或边缘云层面的数据聚合，以及通过联邦学习实现的模型更新。

在多个 RSU 与云端之间的联邦学习高层架构中，每个 RSU 上部署一台联邦学习服务器，多个 RSU 上的服务器集合表示为 $\mathcal{R} = \{r_1, r_2, \dots, r_n\}, n > 0$ 。在第 p 轮中，RSU 服务器上的模型 r_n 记为 $w_{r_n}^p$ ，模型携带的注意力信息记为 $\xi_{r_n}^p$ ，模型准确度记为 $acc_{r_n}^p$ ，模型损失记为 $loss_{r_n}^p$ 。注意力信息用于聚焦任务的关键信息，而精确度和损失则用于表征模型的学习水平。

在第 p 轮中，每个 RSU 服务器 r_n 将其模型 $w_{r_n}^p$ 上传至云服务器 r_{cloud} ，因此云服务器 r_{cloud} 将接收模型集合 $\{w_{r_1}^p, w_{r_2}^p, \dots, w_{r_n}^p\}, n > 0$ 。对应的注意力信息集合为 $\{\xi_{r_1}^p, \xi_{r_2}^p, \dots, \xi_{r_n}^p\}$ ，模型准确率集合为 $\{acc_{r_1}^p, acc_{r_2}^p, \dots, acc_{r_n}^p\}$ ，模型损失集合为 $\{loss_{r_1}^p, loss_{r_2}^p, \dots, loss_{r_n}^p\}$ 。

与传统的联邦学习算法不同（后者仅在全球服务器上计算单一全局模型），该方法采用历史化的云端个性化模型。 $\bar{w}_{r_n}^p$ 将存储在每个 RSU 服务器 r_n 对应的云服务器 r_{cloud} 中，因此模型集合 $\{\bar{w}_{r_1}^p, \bar{w}_{r_2}^p, \dots, \bar{w}_{r_n}^p\}$ 将存储在云服务器 r_{cloud} 中。由 RSU 服务器 r_n 上传的模型注意力信息 $w_{r_n}^p$ 可表示为该模型与对应历史云个性化模型 $\bar{w}_{r_n}^p$ 之间的欧几里得距离：

$$\xi_{r_n}^p = \frac{\|w_{r_n}^p - \bar{w}_{r_n}^p\|}{\|\bar{w}_{r_n}^p\|} \quad (3.1)$$

在第 p 轮中，针对每个模型 $w_{r_n}^p$ ，会在云服务器 r_{cloud} 上执行一次个性化全局聚合。该聚合公式包含了所有接收模型的注意力信息、准确率和损失值，其表达式可表示为：

$$\bar{w}_{r_n}^{p+1} = \left(1 - \sum_{i=n} \bar{\eta}_{r_i}^p\right) \cdot \bar{w}_{r_n}^p + \sum_{i=n} (\bar{\eta}_{r_i}^p \cdot \eta \cdot w_{r_i}^p) \quad (3.2)$$

RSU 服务器 r_i 中模型用于个性化全局聚合的权重表示如下：

$$\bar{\eta}_{r_i}^p = \theta_1 \cdot \frac{\xi_{r_i}^p}{\sum_j \xi_{r_j}^p} + \theta_2 \cdot \frac{acc_{r_i}^p}{\sum_j acc_{r_j}^p} + \theta_3 \cdot \frac{(loss_{r_i}^p)^{-1}}{\sum_j (loss_{r_j}^p)^{-1}} \quad (3.3)$$

其中 θ_1 、 θ_2 、 θ_3 均为固定值，且 $\theta_1 + \theta_2 + \theta_3 = 1$ 。

在第 p 轮中，云服务器 r_{cloud} 上的模型集合从 $\{\bar{w}_{r_1}^p, \bar{w}_{r_2}^p, \dots, \bar{w}_{r_n}^p\}$ 变为 $\{\bar{w}_{r_1}^{p+1}, \bar{w}_{r_2}^{p+1}, \dots, \bar{w}_{r_n}^{p+1}\}$ 。在云服务器 r_{cloud} 执行上述针对每个历史云个性化模型 $\bar{w}_{r_n}^p$ 的个性化全局聚合后，云服务器 r_{cloud} 将每个新模型发送至相应的 RSU 服务器，即模型 $\bar{w}_{r_n}^{p+1}$ 会被发送到 RSU 服务器 r_n 。

当 RSU 服务器 r_n 收到新模型 $\bar{w}_{r_n}^{p+1}$ 时，该方法会对原始 RSU 模型 $w_{r_n}^p$ 进行个性化本地聚合。聚合公式如下：

$$\hat{w}_{r_n}^{p+1} = (1 - \eta_{r_n}^p) \cdot w_{r_n}^p + \eta_{r_n}^p \cdot \bar{w}_{r_n}^{p+1} \quad (3.4)$$

其中 $\eta_{r_n}^p$ 是个性化局部聚合的权重，该权重由 RSU 服务器 r_n 根据当前时刻的模型状态（包括

注意力信息 $\bar{\xi}_{r_n}^{p+1}$ 、模型精度 $a\bar{c}c_{r_n}^{p+1}$ 及模型损失 $\bar{loss}_{r_n}^{p+1}$) 自适应地计算得出。注意力信息可通过云个性化模型 $\bar{w}_{r_n}^{p+1}$ 以及原始 RSU 局部模型 $w_{r_n}^p$ 之间的欧几里得距离来表示:

$$\bar{\xi}_{r_n}^{p+1} = \frac{\|\bar{w}_{r_n}^{p+1} - w_{r_n}^p\|}{\|w_{r_n}^p\|} \quad (3.5)$$

经过个性化局部聚合后获得的模型 $\hat{w}_{r_n}^{p+1}$ 的注意力信息记为 $\hat{\xi}_{r_n}^{p+1}$, 模型准确度记为 $a\hat{c}c_{r_n}^{p+1}$, 模型损失记为 $\hat{loss}_{r_n}^{p+1}$ 。此时的注意力信息可通过个性化局部聚合后的模型 $\hat{w}_{r_n}^{p+1}$ 与原始 RSU 局部模型 $w_{r_n}^p$ 之间的欧氏距离来表示:

$$\hat{\xi}_{r_n}^{p+1} = \frac{\|\hat{w}_{r_n}^{p+1} - w_{r_n}^p\|}{\|w_{r_n}^p\|} \quad (3.6)$$

3.2 卸载收益模型

该任务流程旨在通过综合考量任务卸载带来的效用与所产生的成本, 来确定最优卸载价格; 因此, 任务收益函数可表示为:

$$R = U - C \quad (3.7)$$

其中 U 和 C 分别表示效用函数和成本函数。

对于一个等待处理的应用任务流 $a \in \mathcal{A}$, 必须提供合适的定价 p_a^o 以激励车队 $\mathcal{V}$ 提供计算资源。给定定价策略 p_a^o , 每辆成员车辆 v 会确定其愿意向数据流 a 提供的数据处理单元数量 n_v^a 。

任务流 $a \in \mathcal{A}$ 从任务卸载中获得的效用可表示为:

$$U_a^o = \sum_{v \in \mathcal{V}} [q_v \log_2(1 + n_v^a)] \quad (3.8)$$

其中 q 表示计算资源单位的效用系数, 该系数用于量化每单位计算资源贡献到任务流的用途。 v 表示车辆提供的计算资源量, 反映了车辆在参与任务卸载时实际提供的计算能力。

根据车队 $\mathcal{V}$ 提供的计算资源量, 任务流 a 的计算成本可表示为:

$$C_a^o = \sum_{v \in \mathcal{V}} p_a^o n_v^a \quad (3.9)$$

其中 p 表示每单位计算资源的成本系数, 用于衡量每单位计算资源的消耗成本。 a 表示计算资源的使用量, 即任务执行过程中实际消耗的计算资源总量。 o 表示与任务相关的调整系数, 该系数考虑了任务类型和优先级等因素对成本的影响。

将效用函数与成本函数相结合，卸载阶段任务流 a 的效益函数可表示为：

$$\max R_a^o = U_a^o - C_a^o \quad (3.10)$$

从资源提供方的角度来看，该服务具有实用性。由卸载过程派生的效用函数 U_v^o 可表示为：

$$U_v^o = \sum_{a \in \mathcal{A}} U_v^a = \sum_{a \in \mathcal{A}} (\delta_v p_a^o N_v n_v^a - n_v^a n_v^a) \quad (3.11)$$

其中 δ_v 和 N_v 分别表示车辆的效用水平和计算资源的最大允许供应量。同时，单位计算成本和 V2V 数据传输成本分别定义为 β_v 和 ω_v 。执行任务所产生的成本函数如下所示：

$$C_v^o = \sum_{a \in \mathcal{A}} C_v^a = \sum_{a \in \mathcal{A}} \left(\beta_v \frac{n_v^a}{q_v} + \omega_v n_v^a \sigma \right) d_u \quad (3.12)$$

因此，车队成员 v 参与卸载计算所获得的收入由 $\max R_v^o = U_v^o - C_v^o$ 给出：

$$\text{s.t. } \sum_{a \in \mathcal{A}} n_v^a \leq N_v, \forall v \in \mathcal{V} n_v^a \geq 0. \quad (3.13)$$

3.3 回收效益的建模

鉴于车辆流动性持续较高，必须对即将退出车队的车辆所持有的待处理任务进行回收与重新分配，以确保这些任务能够准确、彻底地完成。为降低数据传输成本，来自离队车辆的任务将根据当前网络内潜在服务提供商的可用资源进行重新分配。

计算回收任务 $b \in \mathcal{B}$ 的回收成本，其单位计算成本为 p_b^t ；而 b 的回收成本由以下公式给出：

$$C_b^t = \sum_{v \in \mathcal{V}} (\omega_v d_u n_v^b + p_b^t n_v^b) \quad (3.14)$$

其中 n_v^b 表示 v 为处理回收任务 b 所提供的数据处理单元数量。

收益函数如下所示：

$$R_b^t = \sum_{v \in \mathcal{V}} [q_v \log_2(1 + n_v^b)] - C_b^t \quad (3.15)$$

与公式 (3.11) 和 (3.12) 类似，效用函数 U_v^t 及车辆 v 的成本函数 C_v^t 可表示为：

$$U_v^t = \sum_{b \in \mathcal{B}} U_v^b = \sum_{b \in \mathcal{B}} (\delta_v p_b^t N_v n_v^b - n_v^b n_v^b) C_v^t = \sum_{b \in \mathcal{B}} C_v^b = \sum_{b \in \mathcal{B}} \left(\beta_v \frac{n_v^b}{q_v} + \omega_v n_v^b \sigma \right) d_u \quad (3.16)$$

v 在回收过程中对卸载处理的益处如下：

$$\max R_v^t = \sum_{b \in \mathcal{B}} (\delta_v p_b^t N_v n_v^b - n_v^b n_v^b) - \sum_{b \in \mathcal{B}} \left(\beta_v \frac{n_v^b}{q_v} + \omega_v n_v^b \sigma \right) d_u \text{ s.t. } \sum_{b \in \mathcal{B}} n_v^b \leq N_v, \forall v \in \mathcal{V} n_v^b \geq 0 \quad (3.17)$$

3.4 本章小结

为云端的每台 RSU 服务器维护历史性的云个性化模型，能够克服传统方法（如参数解耦和模型插值）中存在的个性化局限性，有效保留 RSU 特定数据的本地特征。得益于云计算强大的计算与存储能力，该方法不会显著延长数据聚合时间，从而使得维护和更新各 RSU 模型既可行又实用。此策略通过充分利用云聚合技术，在不产生重大弊端的前提下，提升了具有本地特征数据的模型信息整合与个性化水平。

第四章 基于云边缘博弈的联合激励驱动学习算法

4.1 客户端和服务端更新

在第一阶段, 客户端利用从服务器接收的全局表示部分 G 与本地维护的个性化头信息 H_i 相结合, 获得本地模型 (G, H_i) 。让 (G, H_i) 在本地进行 τ_{sync} 轮次的训练, 以同步更新全局表示 G 和个性化头信息 H_i 。首先计算并获取本地数据 D_i 上的梯度, 其表达式为:

$$g_i^t = \frac{1}{B} \sum_{j=1}^B \nabla \hat{f}_i(G_i^k, H_i^k; \xi_j^k)_i \quad (4.1)$$

其中 $\xi_1^k, \dots, \xi_B^k \in D_i$; B 为局部更新的批量大小。需注意, 该方法采用较小批量 B 来获取梯度的无偏估计 $\nabla f_i(G_i, H_i, D_i)$, 原因是计算整个批次的梯度成本较高。较小的 B 也能提升模型的泛化能力。此外, 为简化算法流程, 在公式中使用 g_i^k 来代替等式 (4.1) 来表示梯度的计算过程。获得梯度 g_i^k 后, 全局表示 G 与个性化头 H_i 需同时更新。具体而言, 对于 $t = 1, \dots, \tau_{sync}$, 更新过程的第一阶段可表示为:

$$(G_i^{k,t+1}, H_i^{k,t+1}) = (G_i^{k,t}, H_i^{k,t}) - \eta \cdot g_i^k \quad (4.2)$$

其中 η 表示客户端本地模型的学习率。

接下来, 第二阶段与第一阶段的区别在于: 全局表示 G 将被冻结, 仅个性化头部 H_i 会进行微调。对于 $t = \tau_{sync} + 1$ 至 $t = \tau_{sync} + \tau_{head}$, 微调过程可表示为:

$$(G_i^k, H_i^{k,t+1}) = (G_i^k, H_i^{k,t}) - \eta \cdot g_i^k \quad (4.3)$$

将 τ_{head} 设置为大于 τ_{sync} 的值。具体而言, FL-CEGID 方法首先同步更新全局表示 G_i 和个性化头信息 H_i 的参数, 随后通过多轮迭代对个性化头信息 H_i 进行微调。这样, 较小的 τ_{sync} 可确保全局表示部分 G_i 在聚合后不会与本地数据分布产生过大偏差从而导致模型无法收敛; 而较大的 τ_{head} 则能保证本地模型头具备足够的个性化能力以提升模型的本地性能。

在第一阶段, 服务器首先使用比率 r , 选择 $r \cdot N$ 个客户端参与本轮联邦学习过程。随后, 服务器将初始化后或经过最后一轮聚合后的共享全局表示 G^k 发送给选定的客户端。服务器等待每个客户端使用 FL-CEGID 方法本地更新全局表示 G_i^k 和个性化表示 H_i^k 。

在第二阶段, 服务器接收每个客户端返回的更新后的全局表示 G_i^{k+1} , 并将这些全局表示 $G_i^{k+1} (i \in N_k)$ 聚合, 生成新一轮全局表示参数 G^{k+1} :

$$G^{k+1} = \frac{1}{N_k} \sum_{i=1}^{N_k} G_i^{k+1} \quad (4.4)$$

更重要的是，每个客户端将同时上传其更新后的个性化表征 H_i^{k+1} 。中央服务器创建并维护个性化模型表头字典 $\{H_0, \dots, H_N\}$ ，并将接收到的更新后的个性化表头 H_i^{k+1} 存储在该表头字典中。在每轮训练结束时，该表头字典将根据客户端编号索引，按照公式 (4.5) 的方式，用新的个性化表头替换现有的个性化表头 $H_{i,\tau}$ ：

$$\{H_0, \dots, H_N\} \leftarrow H_i^{k,\tau} \quad (4.5)$$

其中 $i \in \{1, \dots, N_k\}$ 。

最后，当联邦学习过程结束时，FL-CEGID 会向每个客户端提供一个本地模型，该模型由全局共享表示 G 和个性化表示 H_i 组成。每个本地模型都能在本地数据分布中实现良好性能。与此同时，FL-CEGID 在服务器端维护一个头部字典。通过聚合该头部字典中的个性化头部信息，FL-CEGID 能够生成具备泛化能力的全局头 H_{global} ，其生成过程可表述为：

$$H_{global} \leftarrow \frac{1}{N} \sum_{i=1}^N H_i \quad (4.6)$$

将全局头 H_{global} 与通用全局表示 G 进行拼接后，FL-CEGID 最终提供了一种具备泛化能力且能在全局测试中表现优异的全局方法。

4.2 激励目标函数与激励驱动机制

本文采用效用函数来量化参与者之间的交互关系。在云中心层，边缘云会发布总奖励 r^t ，以最大化效用函数并实现优化目标：

$$r^* = \arg \max_{r^t} U_c(d^t, r^t) \quad (4.7)$$

在边缘服务器层，客户端根据服务器提供的总最优奖励 r^* ，确定训练策略 $\{d_1^t, \dots, d_N^t\}$ ，该策略进而为下一阶段的数据感知提供最优奖励 p ，其优化目标为：

$$\{d_i^{t*}\}, p^* = \arg \max_{d^t, p} U_{e-n}(x, p) + \arg \max_{d_i^t} U_i(r^t, d_i^t) \quad (4.8)$$

用户 k 自行决定其数据交易量，优化目标可表示为：

$$x^* = \arg \max_{x_k} U_k(x_k, p) \quad (4.9)$$

联邦学习中每位参与者的激励机制，是通过上述优化博弈过程中的效用函数实现的。

在云边缘博弈的联邦学习训练过程中，为将激励机制直接与训练过程挂钩，模型分发过程与奖励相关联。具体而言，设定了奖励阈值 θ : $\rho_i = \frac{r_i}{\theta} \geq 0$ 。当 $\rho \geq 1$ 时，服务器会向客户端 i 分发完整的训练模型；当 $\rho < 1$ 时，梯度权重将按比例排序并分发给客户端。尽管这种设置不会对本地模型的性能产生比例性影响，但它能有效区分各组件的贡献度。

4.3 破解云与边缘的博弈

首先确定云-边缘博弈过程中跟随者博弈的存在性与唯一性。对于客户端 i ，其可用性可通过令 $\frac{\partial U_i(r_i^t, d_i^t)}{\partial d_i^t} = 0$ 来验证：

$$\frac{\partial U_i}{\partial d_i^t} = \frac{\tau r^t \left(\sum_{j \neq i} d_j^t - (N-1)d_i^{t-1} \right)}{\left(\sum_{i=1}^N d_i^t - N d_i^{t-1} \right)^2} - \lambda_i = 0 \quad (4.10)$$

求解等式 (4.10) 得到：

$$(d_i^t)^* = \frac{\tau r^t \left(\sum_{j \neq i} d_j^t - (N-1)d_i^{t-1} \right)}{\lambda_i} + N d_i^{t-1} - \sum_{j \neq i} d_j^t \quad (4.11)$$

$$\sum_{i=1}^N d_i^* = \frac{(N-1)\tau r^t}{\sum_{i=1}^N \lambda_i} + N d_i^{t-1} \quad (4.12)$$

将等式 (4.12) 代入等式 (4.11) 可得：

$$(d_i^t)^* = d^{t-1} + \frac{(N-1)\tau r^t}{\sum_{i=1}^N \lambda_i} - \frac{\lambda_i}{\tau r^t} \left(\frac{(N-1)\tau r^t}{\sum_{i=1}^N \lambda_i} \right)^2 \quad (4.13)$$

在云边缘博弈的第一阶段，可通过代入等式 (4.13) 并令 $\frac{\partial U_C(r^t, d^t)}{\partial r^t} = 0$ 后整理得到等式 (4.12)：

$$\frac{\partial U_C(r^t, d^t)}{\partial r^t} = \frac{\delta \tau (N-1)}{\sum_{i=1}^N \lambda_i (1 + N d^{t-1}) + (N-1)\tau r^t} - K \quad (4.14)$$

奖励 r^t 的最佳解决方案可通过等式 (4.14) 获得：

$$(r^t)^* = \frac{\delta}{K} - \frac{\sum_{i=1}^N \lambda_i (1 + N d^{t-1})}{(N-1)\tau} \quad (4.15)$$

采用激励驱动算法的联邦学习与云边缘博弈的伪代码如下所示。

Algorithm 1 基于激励驱动的联邦学习与云边缘博弈算法**Require:** 每次迭代中参与训练的客户端数量 m , 本地迭代轮数 E , 奖励阈值 θ **Ensure:** 全局模型 ω_G

```

1: 服务器端:
2: 初始化全局变量  $\omega_G$  和奖励  $r^0$ 
3: for  $t = 1$  到  $T$  do
4:   从客户端集合  $N$  中选择  $m$  个可用客户端, 构成子集  $S^t$ 
5:   确定本轮客户端的训练策略  $(d^t)^*$ 
6:   for 每个客户端  $i \in S^t$  do
7:     根据  $\rho_i$  确定发送给客户端  $i$  的模型大小
8:      $\omega_i^{t+1} \leftarrow$  本地训练( $i, \omega_G^t, E, B$ )
9:   end for
10:   $\omega_G^{t+1} = \frac{\sum_{i=1}^N |D_i| \omega_i^t}{\sum_{i=1}^N |D_i|}$ 
11:  通过计算确定下一轮奖励  $r^{t+1}$ 
12: end for

13: 客户端:
14: function 本地训练 ( $\omega_i, d_i^t$ )
15:   输入大小为  $d_i^t$  的数据集  $D_i$ 
16:   将数据集  $D_i$  按批量大小  $B$  划分
17:   for  $t = 1$  到  $E$  do
18:      $\omega_i \leftarrow \omega_i - \eta \nabla f_i(\omega, B)$ 
19:   end for
20:   return  $\omega_i$ 
21: end function

```

4.4 本章小结

云服务器为每个 RSU 创建独特的个性化模型, 并基于准确率和损失等性能指标进行全局聚合, 从而优化模型更新效果并降低联邦学习中聚合结果的波动性。RSU 使用相同的评估指标计算本地个性化权重以进行本地更新。

第五章 实验与分析

5.1 实验设置

5.1.1 具体配置

本文将一个边长为 15 公里的正方形区域设为模拟区域, 车辆可在该长度区域内正常行驶并实现有效通信。参数 100 和 150 分别表示实验结果记录间隔为 100 次和 150 次。RSU 与车辆之间的通信距离为 2.2 公里。在此通信范围内, 车辆在向其他车辆传输信息时应具备充足的反应时间以做出合理判断和决策。为满足高速公路行驶车辆的速度要求, 将车辆的最大速度和最小速度分别设定为 50 m/s 和 20 m/s 是合理的。为在传输一定量有效信息的同时提高数据成功率, 每个数据单元的包大小设定为 1.0 千字节。鉴于车辆通信的时间限制, 需在最短可能的时间槽内完成数据传输, 因此将时间槽设置为 1.0 毫秒以满足短时通信需求。本实验数据集来源于 <http://www.cvlibs.net/datasets/kitti/>。

为使车辆能够高效、安全地执行任务, FL-CEGID 采用了多维激励机制、关键任务识别机制以及数据干扰机制。在多维激励机制中, 比特率、源节点与目的节点之间的匹配度、效用函数、成本函数和社会福利函数均被纳入考量。该机制被认为能激励更多车辆参与任务。车辆完成任务后, 能够快速识别关键任务, 从而提高任务完成效率。为确保任务关键信息的安全传输, 系统采用了数据干扰机制来保护这些信息向边缘服务器的传递过程。

5.1.2 基线方法

本文采用以下方法与 FL-CEGID 进行性能比较。

多智能体强化学习 (MARL)^[29]: 该算法是一种先进的分布式多智能体算法, 所有智能体仅通过获取相同的奖励和本地观察到的环境信息, 在本地独立训练其模型。

非正交多址移动边缘计算 (NOMA-MEC)^[30]: 通过优化目标函数和约束条件, 精确实现计算负载卸载以及延迟与能耗的资源分配。

动态阈值任务卸载决策 (DTTOD)^[31]: 基于动态阈值, 车辆用户将任务卸载所耗时间与预设的动态阈值进行比较, 以决定是否向 MEC 服务器发送任务卸载请求。

博弈论中的资源分配 (RAGT)^[32]: 在 IoV 中, 采用博弈论的纳什均衡来解决数据服务之间的资源分配问题。操作员 (DSA) 与雾节点 (FN) 协同工作, 实现资源的最佳分配。

基于负载均衡的资源分配 (RALB)^[33]: 在 IoV 中, 通过均衡各节点的负载, 可避免单个节点过载, 从而提升系统的整体性能与稳定性。

5.2 实验指标

在车辆互联网 (IoV) 的背景下, 鉴于车辆具有高度机动性且连接周期较短, 本文设计了以下实验指标用于定量分析算法性能, 并基于这三项指标进行了实验分析。

吞吐量 (TP): 车辆能够从设备接收并转发且不丢失数据帧的最大数据速率。

收益 (RE): 源节点在中继节点完成数据转发后获得的收益。

满意度 (SA): 指中继节点完成数据转发后, 目标节点获取信息的满意度。该指标由高效的评分函数计算得出, 最终反映节点自身的评分水平。

收益值 re 由完成任务所需的时间成本及任务完成质量共同决定。当 $tm \geq tm_0$ (tm_0 为时间阈值) 时, 收益值计算公式为 $re = -co \cdot tm$, 其中 co 为正系数, tm 表示完成任务所耗时间, 这表明收益值随时间缩短而增加。当 $0 < tm < tm_0$ 时, $re = co \cdot qa$, 其中 qa 代表任务完成质量——在预定时间范围内任务完成质量越高, 收益值越大, 该质量由发布方确定。

5.3 吞吐量与收益分析

不同关键任务的吞吐量如图 5.1(a) 所示, 不同时间点的吞吐量如图 5.1(b) 所示。如图 5.1(a) 所示, FL-CEGID 具有最高的吞吐量: 随着关键任务数量的增加, 吞吐量也随之提升, 这导致数据传输量增加; 所传输的信息量与关键任务数量及吞吐量均呈正相关。从图 5.1(b) 可以明显看出, 沿时间轴观察的吞吐量趋势显示 FL-CEGID 仍保持最高水平。由于 FL-CEGID 与其他方法采用不同的拍卖机制来增加任务参与和完成数量, 因此任务相关的传输量随之增加。这使得车辆的数据传输速率得以提升, 因此所有算法的吞吐量均随时间推移而持续增长。此外, FL-CEGID 为车载网络设计了多维激励机制和关键任务识别方法, 从而显著提高车辆的数据传输速率, 最终实现最高吞吐量。




图 5.1 不同条件下的吞吐量

随着关键任务数量的增加, 收益也会相应提升, 从而推动数据通信量和资源消耗的增长。

这些指标最终会导致收益的增加。图 5.2(a) 展示了最高的收益值，图 5.2(b) 则展示了收益随时间变化的趋势。通过上述实验结果可以观察到，FL-CEGID 的收益高于其他算法，表现更




图 5.2 不同条件下的收益值

优。FL-CEGID 始终保持着最高的收益值。随着增益的提升，所消耗的资源也随之增加。随着时间的推移，随着车辆间传输的数据量增加，收益也会相应提升。

5.4 满意度分析

如图 5.3(a) 所示，FL-CEGID 在满意度评估结果上表现优异：观察发现，随着关键任务数量的增加，满意度会相应下降。关键任务数量增加会导致数据通信量增大，从而消耗更多资源。所有算法的满意度持续下降，这是由于信息传输量增加、关键任务数量增多所致。

FL-CEGID 方案获得了最高的满意度，这得益于多维度激励机制和关键任务识别机制逐渐在高效覆盖通信范围方面发挥了关键作用，类似结果可在图 7 中观察到。从图 5.3(b) 可以明显看出，FL-CEGID 方案的满意度最高：满意度在前 410 秒呈下降趋势，但在 410 秒后开始上升。这是因为车辆在初始阶段未因完成任务而获得收益，而是在后续阶段完成任务后才获得收益。收益值基于三个关键因素计算：任务质量、完成任务所需时间以及在发布方容许范围内的时间。收益金额会随着在规定时间内完成任务的质量提高而增加。由于初始阶段任务数量较少，车辆实现了较高的满意度。然而，随着传输数据量的增加，满意度水平会随时间推移发生变化，高速移动还会带来未知情况和系统不稳定性。

在多源数据传输实验中，四个不同的数据源在不同位置 and 不同时间点发起数据传输请求。数据源车辆与非数据源车辆分别采用 FL-CEGID 实时协作传输技术及其他多种数据传输方法。该实验统计了每个数据源所需的传输延迟。以完成数据传输及传输过程中的系统资源利用率。实验结果如表 5.1 所示。

从表 5.1 可以明显看出，FL-CEGID 能够实现比其他几种方法更短的传输延迟。这是因




图 5.3 不同条件下的满意度

表 5.1 多源数据传输实验设置

数据源	数据大小 (MB)	初始位置 (m)	请求时间 (s)	行驶方向 (东/西)
1	45	281.26	15	东
2	35	1622.54	12	西
3	25	1137.92	18	西
4	15	1964.48	10	东

为 FL- CEGID 的传输策略始终选择能实现更高传输数据速率的源节点，而其他方法则需要在缺乏控制的情况下搜索潜在的中继节点和传输路径。

5.5 本章小结

联邦学习架构通过仅将模型参数而非原始数据上传至服务器进行聚合处理，从根本上保障了数据隐私，显著降低了数据泄露风险。在物联网汽车（IoV）场景中，车辆可在本地利用传感器数据训练模型，从而避免原始数据外泄。此外，在参数上传过程中，同态加密技术使服务器无需解密即可对加密后的参数进行聚合处理，有效维护数据机密性。同时，数字签名技术可验证参数来源的可信度，防止数据篡改，确保数据完整性和真实性。

第六章 总结与展望

6.1 本文工作总结

传统优化算法由于存在模型固化问题及计算复杂度过高，远无法满足车辆互联网（IoV）中资源分配与计算任务卸载的需求。本文采用联邦学习方法，有效应对车载网络中资源不确定性、资源动态变化以及多任务处理高并发性带来的挑战——这些挑战包括环境感知能力不足、环境不稳定性和系统复杂度高等问题。实验结果不仅验证了理论分析的准确性，还表明 FL-CEGID 能显著提升数据传输性能、降低系统通信资源占用率，并分别提高用户满意度和系统可靠性。该方法不仅具备出色的收敛性能与实用性，在不同应用场景下还能带来更优的任务卸载效果。

6.2 进一步研究方向

未来的研究方向将聚焦于优化算法性能并改进模型聚合策略。具体包括探索更先进的模型聚合算法（例如基于动态权重调整或模型压缩技术的算法），以进一步提升联邦学习模型的精度与训练效率，并减轻车辆数据分布差异及高移动性对模型收敛的影响。

参考文献

- [1] Zhao L, Valero M, Pouriyech S, et al. Toward decentralized communication-efficient federated analytics framework for connected vehicles[J]. IEEE Transactions on Vehicular Technology, 2024, 73(7): 10856–10861.
- [2] He Y, Huang K, Zhang G, et al. BIFT: A blockchain-based federated learning system for connected and autonomous vehicles[J]. IEEE Internet of Things Journal, 2022, 9(14): 12311–12322.
- [3] Shen Y, Yu C, Zhang K, et al. Resource-constrained communication-efficient federated learning for connected vehicles[C]. Proceedings of the International Wireless Communications and Mobile Computing Conference (IWCMC). [S.l.: s.n.], 2021: 1636–1641.
- [4] Cui C, Du H, Jia Z, et al. Impact of data poisoning attacks on federated learning for connected and autonomous vehicles using hybrid particle swarm optimization[J]. IEEE Access, 2023, 11: 136361–136369.
- [5] Rajan D, Eswaran P, Srivastava G, et al. Blockchain-based multi-layer federated extreme learning network for connected vehicles[J]. Expert Systems, 2023, 40(6): 1–19.
- [6] Zhang J, Li A, Yang Q, et al. Semi-synchronous federated learning protocol based on dynamic aggregation for internet of vehicles[J]. IEEE Transactions on Vehicular Technology, 2022, 71(5): 4677–4691.
- [7] Fu Y, Li C, Yu F R, et al. Incentive mechanism for federated learning in autonomous driving with supervision game[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(12): 14800–14812.
- [8] Krupa A J D, Dhanalakshmi S, Lai K W, et al. An iomt-based deep learning framework for automatic fetal QRS detection: A solution for remote prenatal care[J]. Journal of King Saud University - Computer and Information Sciences, 2022, 34(9): 7200–7211.
- [9] Yang T, Yang F. An efficient dual-layer path planning method for uavs in vast airspace[J]. Chinese Journal of Information Fusion, 2024, 1(2): 109–125.
- [10] Ren B, Liu J, Zhang S, et al. Online configuration recognition and control of modular reconfigurable flight arrays[J]. IEEE Transactions on Intelligent Systems, 2024, 1(2): 91–101.
- [11] Ali S H, Ullah I, Ali S A, et al. Cyber-physical system for smart city networks based on on-board diagnostic II[J]. IEEE Transactions on Intelligent Systems, 2024, 1(2): 49–57.
- [12] Ning Z, et al. Joint computing and caching in vehicular networks under 5g vision: A deep reinforcement learning-based traffic control system[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(8): 5201–5212.
- [13] He X, Lu H, Du M, et al. QoE-based task offloading with deep reinforcement learning in edge computing-enabled internet of vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(4): 2252–2261.
- [14] Qi Q, et al. Knowledge-driven service offloading decision for vehicular edge computing: A deep reinforcement learning approach[J]. IEEE Transactions on Vehicular Technology, 2019, 68(5): 4192–4203.

- [15] Lee S S, Lee S. Resource allocation for vehicle fog computing using reinforcement learning with heuristic information[J]. IEEE Internet of Things Journal, 2020, 7(10): 10450–10464.
- [16] Zhang K, Cao J, Zhang Y. Adaptive digital twin and multi-agent deep reinforcement learning for vehicular edge computing and networking[J]. IEEE Transactions on Industrial Informatics, 2022, 18(2): 1405–1413.
- [17] Lin K, Xia F, Fortino G. A data-driven clustering approach for multimedia communication in internet of vehicles[J]. Future Generation Computing Systems, 2019, 94: 610–619.
- [18] Sun F, Zhang Z, Zeadally S, et al. Internet of vehicles based on edge computing: Toward a federated learning-enabled scheduling scheme[J]. IEEE Transactions on Vehicular Technology, 2022, 71(9): 10088–10103.
- [19] Nguyen T D T, Nguyen V, Pham V N, et al. Modeling data redundancy and cost-aware task assignment in MEC-supported internet of vehicles applications[J]. IEEE Internet of Things Journal, 2021, 8(3): 1687–1701.
- [20] Naeem F, Seifollahi S, Zhou Z, et al. A generative adversarial network-based deep distributional reinforcement learning for transmission scheduling in internet of vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(7): 4550–4559.
- [21] Samarakoon S, Bennis M, Saad W, et al. Distributed federated learning for ultra-reliable low-latency vehicular communications[J]. IEEE Transactions on Communications, 2019, 68(2): 1146–1159.
- [22] Ye D, Yu R, Pan M, et al. Federated learning in vehicular edge computing: A selective model aggregation approach[J]. IEEE Access, 2020, 8: 23920–23935.
- [23] Lu Y, Huang X, Zhang K, et al. Blockchain-based asynchronous federated learning for secure data sharing in internet of vehicles[J]. IEEE Transactions on Vehicular Technology, 2020, 69(4): 4298–4311.
- [24] Chen M, Mozaffari M, Saad W, et al. Caching in the sky: Proactive deployment of cache-enabled unmanned aerial vehicles for optimized quality of experience[J]. IEEE Journal on Selected Areas in Communications, 2017, 35(5): 1046–1061.
- [25] He J, Guo S, Qiao D, et al. HeteFL: Network-aware federated learning optimization for heterogeneous MEC-enabled iot[J]. IEEE Internet of Things Journal, 2022, 9(15): 14073–14086.
- [26] He Y, Yang M, He Z, et al. Digital twin-based federated learning framework for resource allocation in heterogeneous cellular networks[J]. IEEE Transactions on Vehicular Technology, 2023, 72(1): 1149–1158.
- [27] Chen D, et al. Low-latency scheme for multi-task federated learning in MEC networks based on matching theory[J]. IEEE Internet of Things Journal, 2021, 8(14): 11415–11426.
- [28] Zheng C, Liu S, Huang Y, et al. Unsupervised recurrent federated learning for edge popularity prediction in privacy-preserving mobile edge computing networks[J]. IEEE Internet of Things Journal, 2022, 9(23): 24328–24345.
- [29] Jiang K, Liu W, Wang Y, et al. Credit assignment in heterogeneous multi-agent reinforcement learning for fully cooperative tasks[J]. Applied Intelligence, 2023, 53(23): 29205–29222.
- [30] Cheng Y, Li K H, Liu Y, et al. Downlink and uplink intelligent reflecting surface-assisted networks: NOMA vs. OMA[J]. IEEE Transactions on Wireless Communications, 2021, 20(6): 3988–4000.
- [31] Guo H, Liu J. Cooperative computation offloading for multi-access edge computing over fiber-wireless net-

- works[J]. IEEE Transactions on Vehicular Technology, 2018, 67(5): 4514–4526.
- [32] Carlucci D, Renna P, Materi S, et al. An intelligent decision-making model for resource allocation in cloud manufacturing based on minority game[J]. Management Decision, 2020, 58(11): 2305–2325.
- [33] Xu X L, Fang Z J, Qi L Y, et al. A deep reinforcement learning-based distributed service offloading method in internet of vehicles edge computing environment[J]. Chinese Journal of Computers, 2021, 44(12): 2382–2405.