

模式识别与机器学习研究组

Evidential Deep Learning to Quantify Classification Uncertainty

汇报人：1025040722邵家骅

2025年10月23日

汇报提纲

- ▶ 论文研究主题（任务）及其研究意义
- ▶ 该研究主题（任务）已有方法的不足或当前面临的挑战
- ▶ 本文解决思路
- ▶ 所提出的模型/方案
- ▶ 实验设置与结果分析
- ▶ 总结与结论
- ▶ 启发与思考

论文研究主题（任务）及其研究意义

研究主题

深度学习模型的不确定性量化与分布外(OOD)样本检测

核心问题

- 深度模型对OOD样本过度自信，无法表达"不知道"
- 需要区分偶然不确定性（数据噪声）与认知不确定性（模型能力限制）

研究意义

- 提升模型在未知场景下的可靠性
- 使模型能够识别训练分布之外的输入并拒绝预测

该研究主题（任务）当前面临的挑战

对于如何量化不确定性，已经存在了一些方法：

- 贝叶斯神经网络(Bayesian Neural Networks, BNN)的思路：

不再把网络参数 θ 看作固定值,而是看作概率分布 $p(\theta|D)$ 。

预测时不是用单一的 θ ，而是对所有可能的 θ 进行积分： $p(y|x) = \int p(y|x, \theta) p(\theta|D) d\theta$

这样输出的就不是一个确定的概率，而是**概率的分布**。

然而，后验分布 $p(\theta|D)$ 计算代价过高，近似方法在深度网络中并不适用，且需要重新设计网络结构，损失函数，训练流程，难以直接应用到现有的预训练模型上。

- 集成方法(Ensemble)的思路：

训练多个独立的网络，通过预测的方差来估计不确定性。

训练和存储 N 个模型,推理时需要 N 次前向传播，计算开销极大。

这些方法都是**间接地**量化不确定性——通过参数的不确定性或多次采样的分歧度来推断预测的不确定性。

能否让模型直接输出不确定性？

本文解决思路

从贝叶斯推断的角度出发：将分类概率视为随机对象 $\rightarrow$ 选择二阶分布族 $\rightarrow$

利用共轭性构造训练目标 $\rightarrow$ 让神经网络输出分布参数

第一步：潜变量建模视角

标签 $y \in \{e_1, \dots, e_K\}$ 来自 $y \sim \text{Cat}(P)$ ，目标是学得这个 p 以及其不确定性。

第二步：选择一个先验

取 $p \sim \text{Dir}(\alpha)$, $\alpha = [\alpha_1, \dots, \alpha_K]$, $\alpha_i > 0$ 狄利克雷总强度 $S = \sum_{i=1}^K \alpha_i$

第三步：后验更新与预测

对于单样本 $y = e_j$ 时，由共轭性：

$$p(p|y) = \text{Dir}(\alpha + e_j), \quad E[p_k|\alpha] = \frac{\alpha_k}{S}$$

这里把 $E[p_k|\alpha]$ 作为点估计， $u = \frac{K}{S}$ 作为不确定性。

第四步：网络参数化

令网络给出非负证据： $e_k = \varphi(z_k) \geq 0$ ，并设 $\alpha_k = e_k + 1$, $S = \sum_{k=1}^K e_k + 1$

*为什么要选Dirichlet分布？

(1) Dirichlet是分类分布的共轭先验,这意味着后验仍然是Dirichlet形式,所有计算都有解析解。

(2) Dirichlet的支撑恰好是概率单纯形,与我们要建模的对象(类别概率)的定义域完全吻合。

但是这并非唯一选择。可以使用Logistic-Normal分布(先对正态分布采样再做softmax)或其他二阶分布,这样做会失去解析性,需要变分推断或蒙特卡洛方法。

本文解决思路

第五步：损失函数

我们需要 $\max \log p(y|x, \alpha) = \max \log \int p(y|p)p(p|\alpha)dp$

对于one-hot标签 y_k (第k个位置为1,其余为0), 分类似然为: $p(y_k|p) = p_k$

$$p(y_k|\alpha) = \int p_k \cdot \text{Dir}(p|\alpha)dp = E_{p \sim \text{Dir}(\alpha)}[p_k] = \frac{\alpha_k}{S}$$

故点估计的似然为: $\log p(y_k|\alpha) = \log \alpha_k - \log S$

然而, 由于类别概率 p 是随机的, 实际上需要求的是期望的似然:

引入变分推断, 有 $\log p(y_k|\alpha) \geq E_{q(p)}[\log p(y_k|p)] - KL[q(p)||p(p|\alpha)]$

$$\begin{aligned} \text{代入等号条件 } q(p) = \text{Dir}(p|\alpha): \log p(y_k|\alpha) &= E_{p \sim \text{Dir}(\alpha)}[\log p(y_k|p)] = E_{p \sim \text{Dir}(\alpha)}[\log p_k] \\ &= y_k(\psi(\alpha_k) - \psi(S)) \end{aligned}$$

其中 $\psi(\cdot)$ 是Digamma函数(Gamma函数的对数导数)

$$\text{故 } \mathcal{L}_{data}(\theta) = \max \log p(y|x, \alpha) = \max \sum_{k=1}^K y_k(\psi(\alpha_k) - \psi(S)) = \min \sum_{k=1}^K y_k(\psi(S) - \psi(\alpha_k))$$

本文解决思路

第六步：正则化（压缩错类证据）

$$\mathcal{L}(\theta) = \mathcal{L}_{data}(\theta) + KL[Dir(p_i|\tilde{a}_i)||Dir(p_i|\langle 1, \dots, 1 \rangle)]$$

其中 $\lambda(t)$ 使用模拟退火优化：早期小、后期大，避免把 α 过早压回 1。

第七步：推断与OOD

点预测： $\hat{y} = \operatorname{argmax}_k \frac{\alpha_k}{S}$

不确定性： $u = \frac{K}{S}$ 或预测熵 $H(E(p))$

OOD 拒识：阈值化 u 或 S （大 u / 小 S 判OOD）

所提出的模型/方案--Overview


给出分类任务的不确定性量化问题的形式化定义:

给定训练集 $D = \{(x_i, y_i)\}_{i=1}^N$, 其中 $x_i \in \mathbb{R}^d$ 是 d 维输入样本, $y_i \in \{1, 2, \dots, K\}$ 是对应的类别标签。

目标是学习一个映射函数使得对于任意输入 x :

- 1) $f(x)$ 能准确预测 x 的类别分布
- 2) $f(x)$ 能同时输出对该预测的不确定性度量 $u(x)$
- 3) 当 x 不属于训练分布时, $u(x)$ 显著高于 x 属于训练分布时的值

整体模型结构如下:



所提出的模型/方案--关键（创新）模块

（1）证据生成

用 $b = \{b_1, \dots, b_k\}$ 表示K个类别的可信度， u 表示预测结果的不确定性。基于证据理论，我们认为：

$$u + \sum_{i=1}^K b_i = 1$$

那么就可以根据 b 来求出 u ， b 可以通过证据生成来得到：

$$b_i = \frac{e_i}{S}, \text{ 令 } S = \sum_{i=1}^K (e_i + 1), \text{ 于是 } u = \frac{K}{S}$$

其中 e_i 被称为evidence，即为把神经网络生成的特征通过非负激活函数转化为对每个类别的证据。

（2）Dirichlet参数化

显然， b 和 u 是在建模“概率的概率”，因此联想到同样是建模“概率的概率”的Dirichlet分布：

$$f(x; \alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^K p_i^{\alpha_i - 1}$$

由Dirichlet的均值形式 $\tilde{\alpha}_i = E(p_i) = \frac{\alpha_i}{\sum_{i=1}^K \alpha_i}$ ，可以发现当 $\alpha_i = e_i + 1$ 时， $b_i + ua_i = \frac{e_i}{S} + \frac{K}{S} \cdot \frac{1}{K} = E(p_i)$

两者完全一致。因此认为在条件 $\alpha_i = e_i + 1$ 下，能使得 b 和 u 满足Dirichlet分布。

此处计算 $b_i + ua_i$ ，
 $a_i = \frac{1}{K}$
是因为这是主观逻辑
(Subjective Logic ,
SL) 定义的投影算
子，意在把意见投到
概率单纯形上

所提出的模型/方案--关键（创新）模块

（3）预测与不确定性分解

由于已经把**b**和**u**凑成了Dirichlet分布，可以直接沿用分布的期望作为类别概率估计： $\hat{p}_k = \frac{\alpha_k}{S} = E(p)$

不确定性**u**从**S**中计算得出： $u = \frac{K}{S}$

这样单次前向传播即可同时获得预测和不确定性。

所提出的模型/方案--损失函数

该损失函数需要达成的目标：

- (1) 准确预测ID样本：对于训练集中的样本，模型应该积累充足的证据支持正确类别，使得 $\hat{p}(y = y_{true}|x)$ 尽可能接近1。
- (2) 抑制错误证据：模型不应该为错误类别积累证据。如果样本真实类别是“猫”，那么支持“狗”的证据应保持较低。
- (3) 不确定性感知：这是EDL与传统方法的关键区别。模型应该学会：难样本应该输出较少的证据量。在训练初期或面对难以区分的样本时，允许模型输出较低的总证据量S，表达不确定性。

因此，EDL将损失分为两个部分，平方误差损失用于分类预测，KL散度正则项用于证据抑制。

$$\mathcal{L}(\theta) = \sum_{i=1}^N \mathcal{L}_{MSE\ i}(\theta) + \lambda_t \sum_{i=1}^N KL[Dir(p_i|\tilde{a}_i)||Dir(p_i|\langle 1, \dots, 1 \rangle)]$$

其中权重系数 λ_t 随训练epoch t 线性增长： $\lambda_t = \min\left(1, \frac{t}{T}\right)$

T 是预设的退火周期，通常设为总训练轮数的10-20%

给KL的系数 λ 做退火是为避免早期训练被KL主导把 α 压回1（无证据），是为了先学判别再逐步强化校准与正则；该做法与网络结构无关，可推广到含任意正则项的模型。

所提出的模型/方案--损失函数

下面详细展开两部分损失

第一部分：平方误差损失

从贝叶斯决策理论出发,给定样本(x, y),我们希望最小化期望平方误差: $\mathcal{L}_{MSE} = E_{p \sim Dir(\alpha)}[\|y - p\|^2]$

其中y是one-hot编码的真实标签, p是类别概率向量。展开期望: $\mathcal{L}_{MSE} = \int Dir(p|\alpha) \sum_{k=1}^K (y_k - p_k)^2 dp$

由Dirichlet分布的均值与方差, 展开 $(y_k - p_k)^2$ 对每一项求期望: $E[(y_k - p_k)^2] = y_k^2 - 2y_k \frac{\alpha_k}{S} + \frac{\alpha_k(S-\alpha_k)}{S^2(S+1)} + \frac{\alpha_k^2}{S^2}$

代入化简有: $\mathcal{L}_{MSE} = \sum_{k=1}^K \left[\left(y_k - \frac{\alpha_k}{S} \right)^2 + \frac{\alpha_k(S-\alpha_k)}{S^2(S+1)} \right]$, 其中 $\frac{\alpha_k}{S} = \hat{p}_k$

第一项是预测误差值, 第二项是不确定性惩罚, 本质上是Dirichlet方差项。

所提出的模型/方案--损失函数

第二部分：KL散度正则项

该项目的目的在于惩罚模型为**非目标类别**积累证据，即希望目标类别的 evidence 不变，其他的 evidence 尽可能往“完全不可信”这个分布上去靠拢：

$$\mathcal{L}_{\text{KL}} = \text{KL}[\text{Dir}(p|\tilde{\alpha})||\text{Dir}(p|1)]$$

其中：

$$\tilde{\alpha} = \begin{cases} 1 & \text{if } y = 1 \\ \alpha & \text{if } y = 0 \end{cases} \quad \text{Dir}(p|1) \text{ 是参数全为1的均匀Dirichlet先验,表示完全不确定状态(没有任何证据)}$$

两个Dirichlet分布之间的KL散度有闭式解：

$$\text{KL} [\text{Dir}(p|\tilde{\alpha})|| \text{Dir}(p|1)] = \log \frac{\Gamma(\tilde{S})}{\prod_{k=1}^K \Gamma(\tilde{\alpha}_k)} + \sum_{k=1}^K (\tilde{\alpha}_k - 1) [\psi(\tilde{\alpha}_k) - \psi(\tilde{S})] - \log \Gamma(K)$$

从此式可以直观看出 $\tilde{\alpha}$ 对于KL的影响：

- 如果所有错误类别的 $\tilde{\alpha}_k$ 都接近1(无证据),则 $\mathcal{L}_{\text{KL}} \approx 0$
- 如果某个错误类别的 $\tilde{\alpha}_k$ 很大,则 $\mathcal{L}_{\text{KL}}$ 增大,产生惩罚
- 效果是压制非目标类别的证据,使模型学会只为真实类别收集证据

当 λ 过大或样本很难时，最优解倾向于把所有 $\tilde{\alpha}_k$ 压到1，造成欠拟合；且少样本类更新稀疏，学习变慢。

实验设置与结果分析--Experimental Datasets

MNIST

手写数字分类数据集，10 类（0–9），共 70,000 张灰度图（训练 60k、测试 10k）。单张大小 28×28 ，1 通道（grayscale）。

CIFAR10

自然物体图像分类数据集，10 类，共 60,000 张彩色图（训练 50k、测试 10k）。单张大小 32×32 ，3 通道（RGB）。

notMNIST

字母 A–J 的字符图像（字体多样），常用于 OOD/迁移评测；提供 small $\approx$ 20k 与 large $\approx$ 530k 两个版本。单张大小 28×28 ，1 通道（grayscale）。

实验设置与结果分析--Evaluation Metrics

Accuracy:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\arg \max \hat{p}_i = y_i]$$

Uncertainty threshold:

$$u(x) = \frac{K}{S} = \frac{K}{\sum_{k=1}^K \alpha_k}$$

K 为类别总数， $S = \sum_{i=1}^K (e_i + 1)$ 为Dirichlet分布的强度参数(总证据量)

Entropy:

$$H(\hat{p}) = - \sum_{k=1}^K \hat{p}_k \log \hat{p}_k, \quad \hat{p}_k = \frac{\alpha_k}{S}$$

熵度量的是预测分布的数据不确定性

实验设置与结果分析--Experimental setting

Lenet

在MNIST上训练:

模型: 原始 LeNet (in=1)

conv1: $1 \rightarrow 20, k5$; conv2: $20 \rightarrow 50, k5$; 无池化;

fc1: $20000 \rightarrow 500$; fc2: $500 \rightarrow 10$

输入与预处理: 28×28 灰度; $\text{Normalize}((0.1307,),(0.3081,))$

批次与训练: batch=128, epochs=50

优化器: Adam (lr=1e-4, weight_decay=1e-3)

学习率: StepLR(step_size=7, gamma=0.1)

损失: EDL-MSE

证据映射: $e = \text{relu}(\text{logits})$

*这里选择不同的证据头激活函数是因为在CIFAR10这种相对复杂的数据集下原始的RELU在实验中表现出了更差的收敛性与准确率。一个可能的原因是CIFAR-10 初期大量类别的 $z < 0$ 被截断

在CIFAR10上训练:

模型: LeNetCIFAR (in=3) , 在 conv2 后加 AdaptiveAvgPool2d(20,20), 保持

fc1= $20000 \rightarrow 500$

输入与预处理: 32×32 RGB;

$\text{Normalize}((0.4914,0.4822,0.4465),(0.2470,0.2435,0.2616))$

批次与训练: batch=128, epochs=50

优化器: Adam (lr=3e-4, weight_decay=5e-4)

学习率: StepLR(step_size=30, gamma=0.1)

损失: EDL-MSE

证据映射: $e = \text{softplus}(\text{logits} / T_e), T_e \in [0.5,0.8]$

实验设置与结果分析--Experimental setting

ResNet-18

在MNIST上训练:

模型: `resnet18(num_classes=10)`, 修改
`conv1 = Conv2d(1,64,k3,s1,p1,bias=False);`
`maxpool = Identity()`

批次与训练: `batch=128, epochs=50`

优化器: `Adam(lr=3e-4, weight_decay=5e-3)`

学习率: `StepLR(step_size=30, gamma=0.1)`

损失: EDL-MSE


证据映射: $e = \text{softplus}(\text{logits} / T_e), T_e \in [0.5, 0.8]$

在CIFAR10上训练:

模型: `resnet18(num_classes=10)`, CIFAR 化
`conv1 = Conv2d(3,64,k3,s1,p1,bias=False);`
`maxpool = Identity()`

其余与MNIST一致

*为什么要额外跑一个ResNet的实验:
对比On Calibration中的深度神经网络会
over confidence的问题, 尤其是考虑到
那篇文章说Lenet校准性良好



实验设置与结果分析--Competing Methods

(1) **L2**: 确定性网络 + 权重衰减。训练最小化 $\mathcal{L}_{CE}(\theta) + \lambda \|\theta\|_2^2$

预测用 softmax 概率；把 $\max_k \text{softmax}_k$ 当置信度。无显式不确定性建模。

(2) **Dropout**: 把 dropout 当近似后验 $q(\theta)$ 。测试时采样 T 次掩码: $\hat{p}(y|x) = \frac{1}{T} \sum_{t=1}^T \text{softmax}(f(x))$

用熵衡量 epistemic 不确定性。

(3) **Deep Ensemble**: 独立训练 M 个确定性模型并平均: $\hat{p} = \frac{1}{M} \sum_{m=1}^M \text{softmax}(f(x))$

成本高但校准与鲁棒性好；不确定性来自成员间分歧。

(4) **FFGU**: 贝叶斯神经网络, 假设权重后验完全因子化 $q(\theta) = \prod_i N(\mu_i, \sigma_i^2)$
通过 ELBO 训练；预测用对 $q(\theta)$ 的 MC 采样均值与方差。


(5) **FFLU**: 与 FFGU 类似, 但 $q(\theta) = \prod_i \text{Laplace}(\mu_i, b_i)$

(6) **MNFG**: 用乘性正则化流构造权重后验 $w = s(\epsilon; \varphi) \odot \mu, \epsilon \sim N(0, I)$
训练最小化 ELBO；预测同样 MC。


Method	MNIST	CIFAR 5
<i>L2</i>	99.4	76
<i>Dropout</i>	99.5	84
<i>Deep Ensemble</i>	99.3	79
<i>FFGU</i>	99.1	78
<i>FFLU</i>	99.1	77
<i>MNFG</i>	99.3	84
<i>EDL</i>	99.3	83

Table 1: Test accuracies (%) for MNIST and CIFAR5 datasets.

实验设置与结果分析--Experimental results




Train on MNIST
Test on notMNIST




Train on CIFAR-5(first 5)
Test on last five
categories of CIFAR10

显然EDL在这两个OOD测试下都表现出了某种
阈值特性——在超过特定的熵之后表现出样本
的大量聚集（几乎直线上升）





MNIST上的对抗扰动




- EDL**: 熵曲线最高, 说明在对抗样本上“更不自信”(能觉察异常); 但准确率往往最低。
- L2 基线**: 熵几乎不升, 表示**过度自信**, 即使已被攻击而误判。
- CIFAR10** 比 **MNIST** 更难, 较小 ϵ 就能显著致错, 熵增长也更慢(模型更容易被“骗到某类”)。

CIFAR10上的对抗扰动




实验设置与结果分析--Experimental results



Train on CIFAR10
Test on CIFAR10

置信度为 $\max \hat{p}_k$


Train on CIFAR10
Test on MNIST




表现出了明显的lack confidence

为什么会这样?

KL过强导致真类的证据不够多, 直接
弱化退火系数 $\lambda=0.1$ 后:
ECE有所下降




ResNet18 的
OOD 可分性明显
优于 LeNet, 但
是仍然容易过度
自信



实验设置与结果分析--Experimental results

Cifar10下训练与测试
左图为EDL，右图为原始模型



可以发现，EDL的ECE明显高于原始模型的ECE，校准更差

总结与结论

EDL 用“证据→Dirichlet”将类别判断（相对大小）与把握程度（绝对强度）解耦，在保持精度的同时，大幅改善OOD、对抗场景下的风险可控性，是轻量而实用的不确定性学习方案。

然而，经过实验发现，EDL在更为复杂的ResNet18上表现并非很好，尤其是在KL的退火系数下降之后才能获得相对好的效果，但是降低退火系数本身是违背EDL的想法的，即应当使非正类样本的分布完全趋于均匀分布。因此如何处理KL是一个大问题。

另外，将EDL与校准结合，可以调整ID内的分布，同时在不改变U的情况下保持OOD的不确定性检测能力。