

模式识别与机器学习研究组

UPL-SFDA: Uncertainty-aware Pseudo Label Guided Source-Free
Domain Adaptation for Medical Image Segmentation

汇报提纲

- ▶ 论文研究主题（任务）及其研究意义
- ▶ 该研究主题（任务）已有方法的不足或当前面临的挑战
- ▶ 本文解决思路
- ▶ 所提出的模型/方案
- ▶ 实验设置与结果分析
- ▶ 总结与结论
- ▶ 启发与思考

论文研究主题（任务）及其研究意义

研究主题：无源域自适应医学影像分割（场景突破）

问题定义： 源域数据集 $D^S = \{(X_n^S, Y_n^S)\}_{n=1}^{N_S}$ ，目标域无标签集 $D^T = \{(X_n^T)\}_{n=1}^{N_T}$ ，
2D数据集 $X_n \in \mathbb{R}^{H \times W \times C}$, $Y_n^S \in \{0,1\}^{H \times W \times K}$, 3D数据集 $X_n \in \mathbb{R}^{D \times H \times W \times C}$, $Y_n^S \in \{0,1\}^{D \times H \times W \times K}$
其中 C 是通道数， K 是类别数， D 是深度。

研究意义：

1. 临床实用性

解决不同医院、设备、成像协议间的域差异

保护患者隐私（无需源域数据）

降低标注成本（无需目标域标注）

2. 技术优势

适用于任意预训练模型

无需源域特殊预训练策略

提供一种可靠的伪标签生成机制

该研究主题（任务）已有方法的不足

监督式微调:

不足: 需要大量目标域的标注数据，然而在实际医学场景中，目标域的标注通常难以获得或非常稀缺

无监督域适应 (Unsupervised Domain Adaptation, UDA): 使用无标注的目标域数据进行分割

- 图像对齐: 将目标域图像转换为源域风格的图像
- 特征对齐: 使用对抗训练使源域和目标域的特征分布相似
- 输出对齐: 使用伪标签技术

不足: 需要同时访问源域和目标域数据，而在实际部署中往往无法同时获取源域和目标域数据

无源域适应 (Source-Free Domain Adaptation, SFDA):

仅使用目标域的无标注数据和源域预训练模型进行域自适应

不足:

1. 预训练模型适用性受限

现有的无源域适应方法往往对源域预训练过程有特定要求，如需要预先设计辅助任务或特殊网络结构。

2. 伪标签质量难以保证

现有无源域适应自训练方法由于源域与目标领域分布的变化，很难获得准确的伪标签

3. 熵最小化约束不足

熵最小化作为监督并不能提供足够的约束，这使得模型倾向于给出高置信度但错误的预测。

本文解决思路

1. 通用预训练模型适应策略

设计一种通用的域适应框架，无需对源域预训练过程有特殊要求，能够直接应用于任何标准预训练的分割模型。这使得方法具有更广泛的适用性，可以灵活应用于各种医学图像分割场景。


2. 不确定性感知的伪标签生成

提出一种基于模型不确定性估计的伪标签生成机制，能够自动评估目标域预测的可靠性，筛选高质量的伪标签用于模型自训练。


3. 目标域增长策略

设计了目标域增长（Target Domain Growing, TDG）策略，通过逐步扩大可靠伪标签的覆盖范围，实现模型在目标域的渐进式适应，避免了一次性使用所有可能不可靠的伪标签带来的负面影响。

所提出的模型/方案--Overview




所提出的模型/方案--关键（创新）模块



TDG模块：在目标领域中，将预训练的预测头（解码器）复制 K 次，每个分支分别加入随机空间变换和Dropout扰动，获得多样化的预测结果；最终将 K 个预测概率图取平均，实现稳健的集成预测。

$$p^k = T_k^{-1} \circ h^k(g(T_k \circ x))$$

$$\bar{p} = \frac{1}{K} \sum_{k=1}^K p^k$$



TFS模块：在目标领域中，TFS模块采用两次前向传播策略：第一次前向传播生成伪标签及其可靠性图；第二次前向传播使用这些伪标签作为监督信号，通过可靠性图加权损失函数，仅对高置信度区域进行有效学习，同时对低置信度区域应用熵最小化约束，实现更稳健的自训练过程。

所提出的模型/方案--损失函数

总损失函数:

$$L = L_{TFS} + \lambda L_{ment}$$

两次前向传播监督损失+熵最小化损失

$$\left\{ \begin{array}{l} L_{TFS} = \frac{1}{K} \sum_{k=1}^K L_{w-dice}(p'_k, \tilde{y}, M) \\ \mathcal{L}_{w-dice} = 1 - \frac{1}{C} \sum_{c=1}^C \frac{\sum_n 2M_n \mathbf{p}'^k_{c,n} \tilde{y}_{c,n}}{\sum_n M_n (\mathbf{p}'^k_{c,n} + \tilde{y}_{c,n}) + \eta} \\ L_{ment} = -\frac{1}{HW} \sum_{n=1}^{HW} \sum_{c=1}^C \bar{p}'_{c,n} \log(\bar{p}'_{c,n}) \end{array} \right. \quad \text{加权DICE损失}$$

实验设置与结果分析--Experimental Datasets

该论文实验基于三个医学图像分割数据集:

1. 多中心心脏图像分割数据集 (M&MS)


来源: 公开数据集, 包含345个心脏MRI容积

领域划分: 4个领域(A-D), 基于不同厂商

分辨率: 平面内0.85-1.45mm, 切片厚度9.2-10mm

实验设置: 领域A作为源域, B/C/D作为目标域

分割目标: 左心室(LV)、右心室(RV)、心肌(MYO)



2. 胎儿脑部分割数据集 (FB)

来源: 内部数据集, 包含两种MRI序列

领域划分: HASTE序列作为源域, 作为目标域

分辨率: HASTE平面内0.64-0.70mm, 切片厚度6.5-7.15mm; TrueFISP平面内0.67-1.12mm, 切片厚度6.5mm

3. 胎儿组织标注数据集 (FeTA)


来源: 公开的FeTA2022挑战数据集, 80个样本

领域划分: 基于不同超分辨率重建方法

分辨率: 原始T2加权序列平面内0.5×0.5mm, 切片厚度3-5mm

分割目标: 7种脑组织(ECF、GM、WM、Ven、Cer、DGM、BS)

所有数据集均按70%/10%/20%比例划分为训练/验证/测试集, 目标域训练集中的标签在实验中被舍弃。




实验设置与结果分析--Evaluation Metrics

1.DICE系数


$$3D\ DICE = \frac{2 * |V_X \cap V_Y|}{|V_X| + |V_Y|}$$

2.ASSD: 平均对称表面距离



$$ASSD = \frac{\frac{\sum_{x \in X} \min_{y \in Y} d(x, y)}{len(X)} + \frac{\sum_{y \in Y} \min_{x \in X} d(y, x)}{len(Y)}}{2}$$

实验设置与结果分析--Experimental setting



源域预训练

- Dice损失 + Adam优化器
- 初始学习率: 0.01, 每4个epoch衰减至90%
- 训练400个epoch, 选择验证集最佳模型

目标域自适应

- 复制K个解码器分支
- Adam优化器, 固定学习率 10^{-4}
- 更新所有参数, 训练20个epoch, 选择验证集最佳模型

实验设置与结果分析-- Experimental results

实验一：多域医学图像分割性能对比

DICE:

Method	Target domain B			Target domain C			Target domain D		
	LV	MYO	RV	LV	MYO	RV	LV	MYO	RV
Source only	87.54±10.40	75.50±10.97	81.50±16.97	86.47±7.61	77.46±7.71	80.55±11.44	88.04±6.71	75.88±8.57	77.76±17.88
Source only-Esb	88.62±8.19	77.22±9.99	82.82±19.22	86.60±7.94	78.54±9.53	84.26±9.14	88.22±7.56	77.53±8.06	79.35±17.56
Fine-tune valid	90.34±6.30	81.68±6.53	85.30±12.13	89.54±6.06	82.82±4.67	86.20±8.20	88.38±8.46	81.08±4.10	83.47±11.69
Fine-tune train	90.90±5.36	83.76±5.48	87.63±6.11	89.59±5.69	83.98±4.85	87.46±5.38	90.68±5.40	83.89±4.29	85.93±5.57
Target only	91.13±6.37	84.37±6.56	87.27±8.86	89.40±7.57	82.67±5.66	82.99±7.85	88.69±8.35	81.60±5.35	83.41±11.25
PTBN [32]	89.62±7.11	79.99±6.40**	82.31±15.73	86.06±8.96	79.62±7.07	83.76±7.34	88.19±6.51	79.03±4.92	81.01±11.30
TENT [12]	89.03±8.46	79.96±6.44**	83.72±11.42	84.97±10.98	78.68±6.76	84.65±7.18	84.28±10.62	79.08±4.07	82.34±9.70
TTT [9]	89.41±7.06	79.50±6.99**	82.72±13.27	85.89±9.12	79.57±7.10	83.62±6.56	88.13±6.93	79.91±4.60	82.31±9.63
URMA [21]	90.38±5.64	82.09±5.39***	84.30±7.27	88.44±6.29*	81.73±6.21*	86.52±4.90*	88.94±5.92	80.69±4.74	83.01±7.61
Ours w/o Esb	90.70±5.38*	81.82±5.81***	85.73±9.22	89.74±3.98**	83.10±5.61**	86.69±5.50*	89.09±6.00	80.89±3.91	83.87±9.37
Ours	91.02±5.50 *	82.77±5.25***	87.33±7.87*	89.64±4.03*	84.00±5.04***	88.73±4.51***	89.13±6.04	81.84±4.27*	85.30±9.53

ASSD:

Method	Target domain B			Target domain C			Target domain D		
	LV	MYO	RV	LV	MYO	RV	LV	MYO	RV
Source only	0.55±0.46	0.64±0.45	0.88±1.10	0.58±0.37	0.57±0.21	1.18±1.38	0.54±0.34	0.59±0.30	1.59±2.55
Source only-Esb	0.49±0.43	0.61±0.48	0.77±1.54	0.54±0.30	0.54±0.22	0.64±0.56	0.53±0.38	0.57±0.32	0.85±0.91
Fine-tune valid	0.43±0.36	0.55±0.46	0.49±0.44	0.46±0.30	0.49±0.18	0.68±0.68	0.53±0.43	0.50±0.23	0.69±0.60
Fine-tune train	0.43±0.44	0.50±0.45	0.43±0.29	0.41±0.20	0.40±0.12	0.53±0.38	0.36±0.16	0.39±0.11	0.48±0.22
Target only	0.52±0.77	0.55±0.61	0.54±0.95	0.40±0.24	0.44±0.16	1.31±0.99	0.57±0.55	0.51±0.24	0.88±0.69
PTBN [32]	0.51±0.43	0.60±0.46	0.79±1.33	0.65±0.44	0.53±0.16	1.03±0.92	0.63±0.53	0.55±0.26	1.21±1.41
TENT [12]	0.61±0.69	0.62±0.54	0.67±0.99	0.71±0.65	0.59±0.24	0.87±0.73	0.88±0.72	0.59±0.25	0.55±0.31
TTT [9]	0.48±0.38	0.59±0.47	0.82±1.23	0.71±0.55	0.55±0.19	1.16±0.89	0.64±0.53	0.53±0.21	1.01±1.20
URMA [21]	0.41±0.25*	0.51±0.35	0.50±0.23*	0.45±0.23*	0.46±0.13**	0.53±0.32*	0.47±0.22	0.50±0.16	0.52±0.22
Ours w/o Esb	0.46±0.52	0.58±0.57	0.54±0.37*	0.42±0.24**	0.46±0.18*	0.62±0.43	0.56±0.39	0.51±0.21	0.59±0.46
Ours	0.45±0.54	0.54±0.57	0.40±0.38*	0.40±0.16**	0.43±0.16**	0.39±0.26**	0.48±0.30	0.47±0.19	0.46±0.29

UPL-SFDA 显著优于仅源域 (Source only) 和其他 SFDA 方法。
相比仅源域的平均 Dice 提升: +5.53 (B) , +5.97 (C) , +4.87 (D) 点。
在某些情况下, 性能可与完全监督的Target only/Fine-tune valid相媲美甚至更优。


实验设置与结果分析-- Experimental results

实验一：多域医学图像分割性能对比-可视化版

M&MS 数据集的领域 B、C 和 D。


FB 数据集

FeTA 数据集



实验设置与结果分析-- Experimental results

实验二：超参数敏感性分析




三个关键超参数：预测头数量 K 、置信度阈值 τ 及损失权重 λ 。

实验表明， $K=4$ 时目标域扩展效果最佳。 τ 值影响伪标签质量，M&MS数据集上 $\tau=0.95$ 、FB数据集上 $\tau=0.90$ 时表现更优。最终，损失权重 λ 在不同数据集上均以1.0为最佳选择。

实验设置与结果分析-- Experimental results

实验二：超参数敏感性分析



图中展示了不同置信度阈值 τ 对可靠伪标签区域的影响。随着 τ 值增加，各类别的可靠区域明显缩小，这有效防止了模型在训练过程中受到低质量伪标签的干扰。

实验设置与结果分析-- Ablation experiments

实验三：消融实验

Components					Dice (%)				ASSD (pixel)			
M	TDG	$\mathcal{T}$	TFS	L_{ment}	M&MS B	M&MS C	M&MS D	FB	M&MS B	M&MS C	M&MS D	FB
					84.10±9.67	84.20±6.16	83.37±6.90	83.44±7.38	0.60±0.84	0.64±0.36	0.60±0.38	1.39±0.76
✓					84.49±10.35	85.09±5.79	84.10±6.97	85.88±5.49	0.58±0.80	0.49±0.21	0.56±0.36	1.56±1.01
✓	✓				84.52±10.31	85.22±5.57	84.12±6.89	86.77±4.17	0.56±0.63	0.50±0.22	0.55±0.34	0.95±0.24
✓	✓	✓			86.39±7.90	86.16±6.17	84.98±7.08	86.92±5.41	0.44±0.43	0.46±0.25	0.48±0.26	0.91±0.36
✓	✓	✓	✓		86.52±6.63	86.79±4.44	85.20±7.02	88.11±5.06	0.46±0.44	0.42±0.17	0.48±0.26	0.86±0.34
✓	✓	✓	✓	✓	87.04±6.20	87.46±4.52	85.43±6.61	89.10±3.09	0.46±0.38	0.40±0.24	0.47±0.33	1.08±0.49
✓	✓		✓	✓	85.16±6.91	85.43±6.54	84.42±6.89	87.57±3.20	0.49±0.32	0.56±0.37	0.54±0.36	1.02±0.27
	✓	✓		✓	85.82±7.95	86.94±5.13	84.09±7.87	84.48±6.88	0.46±0.42	0.41±0.20	0.55±0.39	1.52±0.92
Source only					81.51±12.78	81.47±8.92	80.56±11.05	84.09±6.34	0.69±0.67	0.71±0.65	0.90±1.06	1.33±0.49
Target only					87.59±7.26	85.02±7.02	84.56±8.31	88.85±4.12	0.53±0.77	0.71±0.46	0.65±0.49	0.91±0.30

目标域扩展与空间变换(TDG+T)、可靠性加权伪标签(M)、熵最小化(L_{ment})、双向前传监督(TFS)确实有提升效果的作用

总结与结论

贡献:

本文提出了一种基于多头预测与一致性评估的不确定性感知伪标签框架，通过目标域扩展、可靠性加权和双向监督机制，实现无源域适应的医学图像分割。

限制:

- 伪标签质量仍受限于初始源域模型的性能，对于源域模型完全失效的区域难以恢复。
- 多头预测结构和双向前传机制增加了模型训练的计算复杂度和内存需求。
- 该论文针对协变量偏移问题设计，而未能有效解决OOD问题。
- 该方法中的不确定性估计过于简化，仅依赖多次前向传播取平均和固定阈值筛选，而非我们常用的不确定性感知方法

启发与思考

优点:

- 1.创新提出了目标域增长和双向前传监督策略，有效解决了源自由域适应中伪标签质量和模型退化问题。
- 2.该方法不依赖特定预训练策略或网络结构，可应用于任意预训练的分割模型

缺点:

- 1.不确定性估计机制过于简化，并非我们常用的不确定性感知方法
- 2.主要针对协变量偏移问题设计，对于OOD问题处理能力有限。
- 3.多头预测结构和双向前传策略增加了计算复杂度和内存需求。

启发:

- 1.不确定性驱动的自训练提供了一种有效的无监督学习新思路，可以引入证据学习使其变成可信的源域free域自适应
- 2.可以将SAM集成到伪标签生成流程中，利用其强大的零样本分割能力辅助生成高质量伪标签。
- 3.可以在测试域引入有意设计的OOD数据