

机器学习公平性 当AI学会“偏见”

汇报人：石涛

今天我们要聊什么

机器学习公平性：当AI学会"偏见"

四大核心议题，从现实案例到解决方案，全面理解AI公平性

01 现实中的AI偏见

从人脸识别认错肤色到招聘系统筛掉女性简历，通过三个触目惊心的真实案例揭示AI偏见如何悄悄影响医疗、招聘、司法等关键领域的生活决策



真实案例

02 什么是ML公平性

解释机器学习公平性的核心概念——为什么"一视同仁"对AI来说如此困难，以及直接歧视与间接歧视、群体公平与个体公平的不同维度



核心概念

03 偏见从哪来

深入分析偏见的两大来源：训练数据本身带有的历史偏见与社会刻板印象，以及模型学习过程中因设计缺陷放大的系统性歧视



数据与模型

04 如何解决

介绍三大类去偏见策略：在训练前修正数据、在训练中约束模型、在训练后调整结果，构建技术与社会规范并重的可信AI



解决方案

现实中的AI偏见

机器学习系统在关键领域显现的系统性偏见及其社会影响

医疗诊断、招聘筛选、刑事判决等场景中的算法歧视正在对特定群体造成实质性伤害，加剧社会不平等。



医疗诊断案例

斯坦福皮肤癌检测系统使用13万张图片训练，但深肤色样本不足5%，导致对深肤色人群识别准确率显著偏低，可能延误治疗时机并加剧医疗不平等。

<5%

深肤色训练样本占比



招聘筛选案例

自动化简历筛选系统被发现存在性别偏见，合格的女性候选人仅因性别属性被系统错误过滤，实质复制了职场中的历史性歧视模式。

Gender

系统性过滤属性



刑事判决案例

犯罪风险评估算法对不同肤色人群给出差异化预测结果，导致少数族裔面临更严格的司法审查，加剧了刑事司法系统中的结构性不平等。

Bias

风险评估差异化

什么是机器学习公平性？

算法决策应避免基于敏感属性产生歧视性待遇

机器学习公平性要求同时防范直接歧视与间接歧视，并在群体层面与个体层面实现多维度公平。



直接歧视

决策规则明确使用敏感属性（如性别、种族）导致不利待遇，例如系统仅因应聘者女性就筛除其简历，这种歧视形式最为直观且违法。



间接歧视

决策表面基于非敏感属性（如邮政编码），但这些属性与敏感属性高度相关，变相实现对特定群体的不利对待，这种隐蔽歧视更难被发现。



群体公平

要求不同敏感属性群体的整体统计指标相等（如贷款批准率、阳性预测率），确保宏观层面的机会均等，常用指标包括人口统计均等和机会均等。



个体公平

强调相似个体应获得相似预测结果，通过度量样本间距离确保微观层面的待遇一致性，避免"同命不同运"，需定义合适的距离度量函数。

偏见来源（一）：数据带来的偏见

训练数据是机器学习偏见的首要来源

历史数据中的社会刻板印象、采样偏差、测量缺陷及属性相关性在数据层面固化并传导至模型决策。



潜在偏见

历史数据反映的社会刻板印象，如就业数据中存在的性别或种族歧视，模型会学习并延续这些过时且违法的偏见模式，将历史不公带入未来决策。



不平衡偏见

数据采集便利性导致某些群体过度代表，ImageNet中45%数据来自美国（仅占全球人口4%），而中印占36%人口却仅贡献3%数据，导致模型对非西方文化场景识别能力显著不足。



测量偏见

数据收集方式不合理导致系统性偏差，如波士顿Street Bump App主要被年轻人和富裕群体使用，导致老年人及低收入社区的路况数据缺失，造成公共资源配置不公。




相关偏见

即使删除敏感属性，模型仍可通过代理属性（如姓名、身高体重预测性别）推断并歧视，形成“红线效应”或间接歧视，使表面中立的算法仍产生歧视性结果。

偏见来源（二）：模型设计的缺陷

模型架构与训练过程引入的系统性偏差

特征选择不当、因果混淆与拟合问题都会导致算法对不同群体产生差异化预测，形成模型层面的公平性隐患。



属性偏见

特征选择阶段引入的偏见，如选用与敏感属性高度相关的代理特征（邮政编码预测种族），或在特征工程中不当加权某些属性，加剧数据中的相关偏见。



因果偏见

模型混淆相关性与因果关系，仅学习统计关联而非真正因果机制，如自动驾驶系统盲目模仿人类驾驶行为而未理解因果逻辑，在未知场景下产生不公平决策。



拟合偏见

过拟合导致模型对训练集中的优势群体过度优化，欠拟合使模型未能捕捉关键特征，如人脸识别系统对儿童准确率远低于成人，因儿童面部非简单缩小版。

如何衡量公平？三大评估指标

公平性度量是构建可信AI的技术基础


通过人口统计均等、机会均等和个体公平等不同维度的指标，量化评估模型是否存在系统性歧视。



人口统计均等

不同群体的正例预测率相等（如男女贷款批准率相同），实现结果层面的绝对平等，但可能忽视群体间基础率差异。


✓ 适用于追求结果配额场景



机会均等

真正具备资格的不同群体成员被正确识别为正例的概率相等，关注资格与机会的匹配，避免对合格个体的错误拒绝。

✓ 适用于信贷审批场景



个体公平

基于距离度量，要求输入空间中相似的个体在输出空间中获得相似的预测结果，避免微观层面的任意歧视。

✓ 适用于个性化推荐场景

如何解决？三大类去偏见策略

Pre-processing · In-processing · Post-processing

去偏见策略根据干预时机分为三大类，分别在数据准备、模型训练和预测输出阶段消除歧视，需在计算成本与模型准确性间权衡。



预处理策略

在模型训练前修正数据，包括重新加权样本使各群体平衡、修改标签纠正历史歧视、调整代理特征等。无需访问模型内部，灵活且易于实现，是工程实践中最常用的基础手段。



处理中策略

在训练过程中引入公平性约束，如加入公平性正则化项或学习公平的数据表征。使模型在追求准确性的同时满足公平性指标，效果最优但计算复杂度高，适合对公平性要求严格的场景。



后处理策略

在模型输出后调整决策阈值或预测结果，如为不同群体设置不同分类阈值以确保机会均等。操作简单且适用于黑盒模型，但可能以牺牲整体准确性为代价，适合快速部署和合规审计。

感谢观看

汇报人：石涛