

MoTAS: MoE-Guided Feature Selection from TTS-Augmented Speech for Enhanced Multimodal Alzheimer's Early Screening

MoTAS: 基于MoE和TTS增强语音的特征选择, 用于增强多模态阿尔茨海默病早期筛查

期刊	ACM MM
发表时间	2025
单位	上海交大

汇报人: 王纯洁

汇报时间: 2026.5.23

01 背景：阿尔兹海默症（AD, Alzheimer's disease）



阿尔茨海默病（俗称老年痴呆症）是一种进行性神经退行性疾病，主要影响认知功能、记忆和语言能力。作为痴呆症最常见的病因，其患病率正在急剧上升，据估计全球有5500万人受到影响。由于人口老龄化，预计到2050年，这一数字将达到1.39亿。



目前困境

- AD尚无治愈方法
- 对医疗保健系统构成了重大挑战
- 护理成本不断攀升、经济压力增大



早期诊断筛查在减缓疾病进展和改善患者预后方面有至关重要的作用

02 背景：传统AD筛查方式




01

磁共振成像(MRI)



02

正电子发射断层扫描(PET)



03

脑脊液(CSF)生物标志物分析

共同问题

- 成本高
- 资源消耗大：不利于社区级、家庭级连续筛查
- 流程负担重：患者和照护者的参与成本高
- 窗口偏后：很多方法更适合确诊或评估，而不是前置筛查

因此，论文把语音视为一种
“低成本、非侵入、可重复采集”的筛查信号。

03 背景：语音AD早筛




为什么选择语音：

◆ AD 患者的早期异常会同时投射到声学、语言和认知表达

- 声学：停顿、犹豫、流畅度下降，发音错误、语速变化
- 语言：词汇贫乏、语义组织变弱句子表达更不稳定
- 认知：描述任务中的规划、记忆和注意控制受影响

◆ 语音分析可以同时捕捉声学模式与语言模式



04 语言AD早筛：现有问题

01 临床语音样本有限


AD数据集小，模型容易过拟合。
跨人群差异大，模型泛化能力差。

02 多模态特征维度杂

特征冗余与噪声并存，人工或固定策略难以兼顾个体差异与模态重要性。

03 临床实时应用受限

推理延迟、资源消耗大，难以在真实临床环境中部署。



数据少 → TTS 扩充

利用 TTS 合成多样化语音，
扩充训练数据，缓解样本稀缺。

特征多 → MoE 选择


MoE 动态选择关键特征，
抑制冗余噪声，提升判别力。

多模态融合 → 提升筛查效果

融合声学、文本、深层语音表征，提升 AD
早期筛查准确性与稳定性。



05 MoTAS方法：整体框架

MoTAS: 提出了一种基于MoE和TTS增强语音，面向阿尔茨海默病语音早筛的多模态检测框架



整体框架包含四个关键步骤：

1. 基于 ASR-TTS 的语音数据增强
2. 多模态声学与文本特征提取
3. MoE 引导的自适应特征选择
4. 多模态特征融合




本文先利用 ASR 将原始语音转写成文本，再利用 TTS 合成增强语音以扩充小样本临床语音数据；随后从语音和文本中提取多模态特征，并通过 MoE 动态选择最有判别力的特征，最终完成 AD/CN 二分类。

06 MoTAS方法：ASR-TTS 语音数据增强

ASR：自动语音识别（Automatic Speech Recognition）

TTS：文本转语音(Text-to-Speech)

解决问题：扩充训练数据，缓解样本稀缺。



具体过程：

1、原始语音



2、Whisper ASR




3、得到文本



4、FishSpeech TTS

5、合成语音
(新样本)



07 MoTAS方法：ASR-TTS 语音数据增强

FishSpeech：一种最先进的TTS模型，专为高保真度的说话人保留合成而设计，确保生成的语音保留原始说话人的韵律、节奏和发音。


$$\hat{s}_i^{\text{AD}} = f_{\text{TTS}}(t_j^{\text{AD}}, s_i^{\text{AD}}), \quad \hat{s}_i^{\text{CN}} = f_{\text{TTS}}(t_j^{\text{CN}}, s_i^{\text{CN}}) \quad (2)$$

$$S_{\text{aug}} = S_{\text{orig}} \cup \{\hat{s}_i^{\text{AD}}, \hat{s}_i^{\text{CN}}\} \quad (3)$$

$$T_{\text{aug}} = f_{\text{ASR}}(S_{\text{aug}}), \quad \text{where } f_{\text{ASR}} = \text{Whisper} \quad (4)$$

s_i 提供说话人身份特征，而 t_j 提供语言内容。

TTS模型合成的语音结合了 s_i 的声音特征和 t_j 的文本记录。



设计优势：

1、保留说话人特征

固定说话人 s_i ，使用其音色与发音特征；保持 speaker identity，降低分布偏移风险。

2、增加文本多样性

从同语义/同主题文本池中替换文本 t_j ，丰富语言表达。

3、音频与文本同步扩充

先用 TTS 合成新语音 S_{aug} ，再用 ASR 识别，得到新文本 T ，避免只扩音频不扩文本，保证多模态一致性。

08 数据规模与预处理

数据规模

- 数据集：ADReSSo，任务为 Cookie Theft 图描述。
- 训练集 166 人，测试集 71 人。
- 增强后训练集扩大，显著提升数据规模，


Table 1: Dataset Splits Before and After 3× Augmentation

	Train	Train_aug	Test
AD	87	253	35
CN	79	228	36
Total	166	481	71

增强后 AD 和 CN 都按原始类别比例扩展，避免简单扩容导致类别分布被破坏。

① Data Collection

Figure Description



Alzheimer's
Disease(AD)

Cognitively
Normal (CN)

09 多模态特征提取

四类特征及其编码器


$f_{W2V2}(s_i)$ 表示使用Wav2Vec2提取的深度语音特征，捕捉反映语音韵律、发音动态的细微声学模式；

$f_{MFCC}(s_i)$ 表示基于MFCC的时间动态，由BiLSTM建模，反映频谱包络和短期时间结构；

$f_{Spec}(s_i)$ 表示使用ResNet18提取的基于频谱图的特征，捕捉局部时频能量分布和韵律线索；

$f_{Text}(t_i)$ 对应于从BERT获得的语义和句法嵌入，编码语音的高级语义和句法模式。

$$X = \{x_w, x_m, x_s, x_t\} = \{f_{W2V2}(s_i), f_{MFCC}(s_i), f_{Spec}(s_i), f_{Text}(t_i)\} \quad (6)$$




10 MoE的重要性

使用MoE的原因

- 01 不是所有特征都同等重要
不同样本依赖的线索不同。
- 02 AD 线索来源多样
可能来自停顿、发音、韵律、语义混乱等不同维度。
- 03 固定融合容易冗余
全部平均使用会引入噪声、降低效率。

MOE 的作用:动态选择更有用的专家和特征



核心思想：让模型按样本自适应关注最有价值的信息

11 MoE特征选择机制

MoE机制： 动态选择信息量最大的多模态特征，从而优化分类性能。

特征子集： 不包含Wav2Vec2组件。（此特征由预训练模型提取，并且已经包含丰富的表征能力。由于它主要集中于表示声学特征，因此没有必要进行进一步的选择。）



$$X_{\text{MoE}} = \{x_m, x_s, x_t\} = \{f_{\text{MFCC}}(s_i), f_{\text{Spec}}(s_i), f_{\text{Text}}(t_i)\} \quad (7)$$

$$w = G(x) = \text{softmax}(W_g x + b_g) \quad (9)$$

$$x_{\text{MoE}}^{\text{mfcc}} = \sum_{i=1}^k w_i^{\text{mfcc}} y_i^{\text{mfcc}}, \quad (10)$$

$$x_{\text{MoE}}^{\text{spec}} = \sum_{i=1}^k w_i^{\text{spec}} y_i^{\text{spec}}, \quad (11)$$

$$x_{\text{MoE}}^{\text{text}} = \sum_{i=1}^k w_i^{\text{text}} y_i^{\text{text}} \quad (12)$$



12 特征融合与分类

在MoE引导的特征选择之后，通过整合Wav2Vec2提取的深度语音嵌入来进一步增强多模态融合。


$$x_{\text{final}} = \text{concat}(x_{\text{MoE}}^{\text{mfcc}}, x_{\text{MoE}}^{\text{spec}}, x_{\text{MoE}}^{\text{text}}, x_w) \quad (13)$$

MoE 指导的特征提供高级声学 and 语言信息，而 Wav2Vec2 捕获语音和低级语音特征。这种双层融合策略确保最终的特征表示有效地整合了高级语义和细粒度的声学细节。

$$f_{\text{MLP}}(x) = \text{FC}_3 (\text{ReLU} (\text{Dropout} (\text{FC}_2 (\text{ReLU} (\text{FC}_1 (x)))))) \quad (14)$$

多层感知器（MLP）分类器由三个全连接层组成，具有 ReLU 激活和 dropout 正则化，专门用于处理融合特征之间的复杂交互并防止过拟合。

$$y = f_{\text{MLP}}(x_{\text{final}}) \quad (15)$$



13 实验设置

数据集：ADReSSo，任务为 Cookie Theft 图描述。

对比方法：

1. 不使用 ASR 转写的方法：

- ADReSSo Baseline (eGeMAPS + SVM) :
使用手工声学特征，并通过 SVM 进行 AD/CN 分类，传统声学特征方法的代表。
- Wav2Vec2 + TB:
使用 Wav2Vec2 提取深层语音表征，再进行分类，代表基于自监督语音模型的声学方法。

2. 使用 ASR 转写的方法：

- ADReSSo Baseline (Late Fusion) :
将声学特征和 ASR 文本特征进行后期融合，是基础多模态融合方法。
- WavBERT Mb (W2V2 ASR + BERT) :
使用 Wav2Vec2 ASR 生成转写文本，再用 BERT 提取文本语义特征，用于 AD 分类。

指标：

- Accuracy：整体分类准确率。
- Precision-AD：AD 精确率。
被模型预测为 AD 的样本中，真实为 AD 的比例。该指标反映模型预测 AD 时的可靠性。
- Recall-AD：AD 召回率。
真实 AD 样本中被正确识别为 AD 的比例。该指标在早筛任务中很重要，因为召回率越高，漏诊风险越低。
- F1 Score-AD：AD 类 F1 值。
综合衡量 AD 类的 precision 和 recall，适合评价模型对 AD 患者的整体识别能力。

14 结果分析

Table 2: Comparison of Our Method With Existing Approaches on the ADReSSo Test Set. Metrics Include Accuracy, Precision, Recall, and F1-Score, Following Definitions From the Baseline Study [29]. Our Method’s Results Are Averaged Over Five Runs.

Method	Accuracy (%)	Precision (%)		Recall (%)		F1 Score (%)	
		AD	CN	AD	CN	AD	CN
Without ASR Transcripts							
ADReSSo Baseline (eGeMAPS+SVM)[29]	64.79	-	-	-	-	-	-
Wav2Vec2+TB [33]	74.65	77.42	72.50	68.57	80.56	72.73	76.32
Whisper-TL medium[24]	77.46	77.14	77.78	77.14	77.78	77.14	77.78
With ASR Transcripts							
ADReSSo Baseline (Late Fusion)[29]	78.87	77.78	80.00	80.00	77.78	78.87	78.87
WavBERT M _b (W2V2 ASR + BERT)[46]	73.24	75.00	71.79	68.57	77.78	71.64	74.67
C-Attention-Unified[41]	78.03	74.15	84.12	87.22	68.57	80.09	75.42
WavBERT M _p (W2V2 ASR + BERT + Pauses)[46]	83.10	87.10	80.00	77.14	88.89	81.82	84.21
TDNN-ASR-M5[33]	84.51	81.58	87.88	88.57	80.56	84.93	84.06
Whisper-TL-FTP Medium[24]	84.51	83.33	85.71	85.71	83.33	84.50	84.50
MoTAS (Ours)	85.71	80.49	93.10	94.29	77.14	86.84	84.38

MoTAS框架实现了最高的整体分类准确率（85.71%），优于来自单模态和多模态类别的所有基线。AD召回率（94.29%）很高，说明漏诊风险越低，在临床早筛中尤为重要。

15 消融实验




Figure 3: Test Accuracy on the ADReSSo Dataset [29] With Different TTS Augmentation Factors

对于TTS增强：图3展示了不同增强水平对测试准确率的影响。

随着增强因子从无增加到2倍，准确率稳步提高，达到峰值85.71%。然而，进一步增强到2.5倍和3倍导致准确率分别下降到82.86%和80.29%。

这种性能下降可能归因于真实样本比例的减少，这导致模型过度拟合合成分布，并损害其泛化能力。

因此，有效的数据增强不仅应侧重于增加数量，还应确保合成数据的质量。适度的增强可以提高样本多样性并缓解过拟合，而过度的增强可能会对性能产生负面影响。基于这些发现，本文选择2× TTS增强作为最佳配置，从而在数据集丰富性和训练稳定性之间取得平衡。

16 消融实验

Table 3: Ablation Study on TTS Augmentation and MoE. We Evaluated Dataset Expansion at 1.5 $\times$, 2 $\times$, 2.5 $\times$, and 3 $\times$, Followed by MoE Ablation on Both the Original and Best-Performing Augmented Datasets. Results Are Averaged Over Five Runs on the ADReSSo Test Set[29].

ID	TTS (times)	MoE	Accuracy (%)	Precision (%)		Recall (%)		F1 Score (%)	
				AD	CN	AD	CN	AD	CN
1	X	X	78.28	81.46	76.06	73.71	82.86	77.20	79.20
2	X	✓	79.71	82.58	77.98	76.00	83.43	78.81	80.40
3	✓(2)	X	81.72	78.30	86.75	88.00	75.43	82.74	80.48
4	✓(2)	✓	85.71	80.49	93.10	94.29	77.14	86.84	84.38
5	✓(1.5)	✓	81.72	80.76	82.99	83.43	80.00	82.02	81.38
6	✓(2.5)	✓	82.86	79.29	87.73	89.14	76.57	83.87	81.68
7	✓(3)	✓	80.29	80.65	82.40	81.72	78.86	80.43	79.75

结果表明，MoE机制在各种设置下均能持续提升性能。在没有TTS增强的情况下，引入MoE将测试准确率从78.28%提高到79.71%（ID1 vs. ID2），表明其在数据有限条件下的有效性。

当应用于2倍增强数据集时，MoE进一步将准确率从81.72%提高到85.71%。通过动态加权多模态特征的重要性，MoE机制有效地减少了冗余，并增强了模型捕获与AD相关的声学 and 语言特征的能力。

17 总结

优点:

- 提出了 TTS 数据增强 + MoE 特征选择的 MoTAS 框架，缓解了 AD 语音早筛中数据少、特征冗余、容易过拟合的问题。
- 通过 ASR-TTS 生成增强语音，并融合 Wav2Vec2、MFCC、Spectrogram、BERT 等多模态特征，提高了 AD/CN 分类性能。
- MoE 能够动态选择更有效的声学 and 文本特征，相比简单特征拼接更灵活。

不足:

- MoTAS 主要面向 AD，AD 语音异常与认知和语言表达密切相关，因此 ASR 文本和 BERT 语义特征较为适用。
- 帕金森语音更多属于运动性语音障碍，核心线索在发声、构音、节律、停顿、语速和韵律中，不能直接把 MoTAS 的文本语义路径作为 PD 早筛核心。
- 因此，MoTAS 的低资源增强和自适应特征选择思想可以借鉴，但用于 PD 时应将重点转向节律、构音和发声特征建模。