



南京邮电大学
Nanjing University of Posts and Telecommunications

Beyond Model-Centric Prediction—Agentic Time Series Forecasting



汇报人：王硕




日期：2025/11

引言



以模型为中心的静态单通道预测问题，将历史观测值映射到未来值。



不断调整参数，使误差（Loss）越来越小，就可以得到效果比较好的k和b

下次我输入一个x,直接代入到这个函数表达式就能计算出y

研究现状

好处

这类方法在提高预测精度和减少人工经验依赖方面取得了显著进展。

不足和优化之处

- 1) **静态的本质**: 目标和输入一旦设定就一条路走到黑, 缺乏应对动态环境的调整机制。
- 2) **封闭的运作**: 预测被死死限制在模型内部, 无法自主调用外部工具 (如查阅新闻、调取数据库) 来补充知识。
- 3) **缺乏反思**: 没有自我评估、检查假设或纠错的机制。
- 4) **经验的隐式吸收**: 模型过去犯过的错, 只能通过重新训练参数来隐式吸收, 无法把经验变成清晰的规则供未来直接复用。

为了打破这些局限, ATSF 提出将预测重构为一个由五个认知组件构成的智能体工作流。这个系统不再是一个死板的计算器, 而更像是一个人类专家。

Agentic Time Series Forecasting



ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及**感知**、**规划**、**行动**、**反思**和**记忆**的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

Agentic Time Series Forecasting

ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及感知、规划、行动、反思和记忆的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

感知是指预测系统在做出任何预测决策之前，从嘈杂、异构且通常是非结构化的输入中提取与任务相关的信息的能力。至关重要是，ATSF中的感知不仅仅是一个固定的预处理步骤，而是一个必要的、自适应的认知过程，它决定了在不同环境和任务下哪些信息被认为是相关的。

Agentic Time Series Forecasting

ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及感知、规划、行动、反思和记忆的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

在感知到环境后，**规划**负责制定预测目标，将复杂的预测任务分解为可管理的子任务，并确定指导后续行动的高层策略。规划并不是在预测之前做出的一次性决策，而是一个持续的过程，可以根据新的观察结果、中间结果或外部反馈进行修改。

Agentic Time Series Forecasting

ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及感知、规划、行动、反思和记忆的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

行动是指通过与工具的自主交互来执行在规划阶段制定的决策。在 ATSF 中，行动主要负责准备、丰富和构建有效预测所需的上下文证据。API的调用

Agentic Time Series Forecasting

ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及感知、规划、行动、反思和记忆的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

反思通过允许智能体预测系统评估、解释和修改其自身的预测，从而实现预测的迭代纠错。反思在 ATSF 中不仅是一个终端评估步骤，更是作为一个内部的自我评估机制，根据期望、假设和上下文证据来检查预测结果

Agentic Time Series Forecasting

ATSF: 不再将预测视为直接的模型输出，而是将其视为涉及感知、规划、行动、反思和记忆的一系列决策的结果。




Figure 1. Illustration of the core components and workflow of agentic time series forecasting.

记忆使 ATSF 能够实现跨实例的经验转移和随时间的持续演进。与仅仅依靠参数更新来吸收过去信息的传统方法不同，ATSF 强调显式的记忆机制，以存储超越单个预测实例的可重用经验。

代码层面的落地

Implementation Paradigms of ATSF: 三条主流的落地道路

基于工作流的设计 (Agentic Workflow Design):

以经典的RAG流水线为例，RAG 链（接收问题 → 检索数据库 → 拼接提示词 → 生成答案）。这种方法最像企业的标准作业程序（SOP）。人类工程师提前在代码里画好一张固定的流程图（比如规定死：先感知，再规划，接着行动）

```
chain = (  
    {  
        "input": RunnablePassthrough(),  
        "context": RunnableLambda(format_for_retriever) | retriever | format_document  
    } | RunnableLambda(format_for_prompt_template) | self.prompt_template | print_prompt | self.chat_model | StrOutputParser()  
)
```

优点：极其稳定、透明且容易排错。预测失败了，人类一眼就能看出是规划阶段出了问题还是工具没调对。

缺点：略显死板。如果遇到了人类在画流程图时没有考虑到的突发奇葩情况，系统可能就卡壳了。

Implementation Paradigms of ATSF：三条主流的落地道路

智能体强化学习 (Agentic Reinforcement Learning)

```
class ReactAgent: 3用法
    def __init__(self):
        self.agent = create_agent(
            model=chat_model,
            tools=[rag_summarize, get_weather, get_user_location, get_user_id,
                  get_current_month, fetch_external_data, fill_context_for_report],
            system_prompt=load_prompt("main"),  // 获取提示词:main rag_summarize report
            middleware=[monitor_tool, log_before_model, report_prompt_switch]
        )
    def execute_stream(self, query:str): 2个用法(1个动态)
        input_dict = {
            "messages":[
                {"role":"user", "content":query}]
        }
```

这是一种“放养式”的训练。我们不写死任何流程，而是给智能体设定一个目标（比如“把误差降到最低”），然后让它在海量数据里自己去“试错”。它会自己摸索出什么时候该调用天气工具、什么时候该停下来反思。优点：高度自治，甚至能进化出连人类专家都想不到的绝佳预测策略。

缺点：训练过程极其痛苦且不稳定，而且由于它自己瞎摸索，最终的决策过程往往会重新变成人类难以理解的“黑盒”。

Implementation Paradigms of ATSF: 三条主流的落地道路

混合智能体工作流 (Hybrid Agentic Workflow / AgenticFlow)

它通过局部和结构化的自适应，将基于工作流的设计与智能体强化学习结合起来 宏观上，大框架是写死的（保证不乱套）；但在微观的特定节点（比如面对多个预测模型，具体该选哪一个），则放权交给强化学习去动态决定。这既保住了人类的安全感（可解释性），又赋予了机器灵活性。

ATSF+焊接参数预测

1. 感知 (Perception) 在焊接中的体现：智能体不仅仅接收结构化的表格数据（板厚=5mm，材料=Q345），它还能从嘈杂、非结构化的输入中提取信息。例如，读取当前的工厂环境温度、焊丝的批次报告，或者识别出用户输入的特殊要求（“要求极高的疲劳强度”），并判断哪些因素对当前任务最关键。

2. 规划 (Planning)

在焊接中的体现：面对复杂的焊接要求，智能体不会直接硬算。它会拆解任务：

步骤一：先确定基础的电流电压范围。

步骤二：计算对应的热输入。

步骤三：评估冷却速度对金相组织的影响。

如果发现某一步无法满足要求，它可以随时修改计划。

ATSF+焊接参数预测

3.行动 (Action)

在焊接中的体现：智能体可以自主调用外部工具来执行计划。它可能会：
调用传统的机器学习预测模型初步给出一个参数。

自动查询“焊接材料数据库”获取热导率数据。

甚至调用一个轻量级的热力学仿真软件来跑一下模拟。

4. 反思 (Reflection)

在焊接中的体现：这是最关键的一环。当智能体生成一组预测参数（如 220A, 26V, 30cm/min）后，它会自我审查：“这个参数组合算出来的热输入是不是太大了？对于这块薄板，根据过往经验，这极易引起变形或烧穿。”

发现偏差后，系统不会把这个错误参数输出给用户，而是打回重做，触发新一轮的预测。

5. 记忆 (Memory)

在焊接中的体现：积累显式的“试错经验”。如果前天用某组预测参数进行实焊，结果发生了“未熔合”缺陷，这个反馈可以作为文字或规则记录在智能体的“记忆库”中：“当坡口角度小于 45 度时，预测的电流值应比常规模型高 10%，以防未熔合。”

下次遇到类似情况，系统可以直接提取这条经验，而不需要费时费力地去重新训练底层大模型。