

单位代码： 10293 密 级： 公开

南京邮电大学

专业学位论文



论文题目： 基于知识图谱与大语言模型的智能建造技术研究与应用

学 号	<u>1022010001</u>
姓 名	<u>王硕</u>
导 师	<u>何静教授</u>
专业学位类别	<u></u>
类 型	<u>学术型硕士</u>
专业（领域）	<u>计算机科学与技术</u>
论文提交日期	<u>2028 年 6 月</u>

摘要

随着建筑行业数字化转型的不断深入，智能建造已成为提升工程建设效率与质量的关键路径。然而，建筑领域长期面临数据异构多源、知识分散沉淀、经验传承困难等挑战，传统的基于规则和人工的信息处理方式已难以满足日益复杂的工程需求。知识图谱技术能够有效组织和管理海量建造领域的多源异构知识，大语言模型则展现出强大的语义理解与文本生成能力。本文将知识图谱与大语言模型相结合，围绕智能建造中的知识管理、智能问答与施工方案辅助生成等核心问题展开研究，主要工作如下：

(1) 面向智能建造领域的知识图谱构建方法研究。针对建造领域数据来源广泛、结构多样的问题，设计了自顶向下与自底向上相结合的知识图谱构建框架。在概念层，基于行业标准与规范设计了建造领域本体模型；在实例层，提出了面向非结构化文本的实体关系联合抽取方法，实现了从施工规范、设计图纸说明、工程报告等多源数据中自动抽取建造知识。

(2) 基于大语言模型的知识图谱增强方法研究。针对知识图谱覆盖度不足和更新滞后的问题，提出了基于大语言模型的少样本实体识别与关系抽取方法，有效降低了对大规模标注数据的依赖。同时，设计了基于提示学习的知识校验与补全机制，利用大语言模型的推理能力对知识图谱进行质量评估与自动扩充。

(3) 知识图谱与大语言模型协同的智能建造问答系统。设计了一种“检索增强生成”框架，将知识图谱作为结构化知识源，通过图检索与语义匹配相结合的方式，为大语言模型提供精准的领域知识支撑，缓解了大模型在建造专业领域的知识幻觉问题。系统支持施工规范查询、工程质量诊断、施工方案推荐等多种应用场景。

(4) 系统实现与实验验证。基于上述方法，设计并实现了一个面向智能建造的知识管理与智能问答原型系统。在某建筑项目的实际数据集上进行了实验验证，结果表明，本文方法在实体识别 F1 值、问答准确率等指标上均取得了较好表现，验证了所提方法的有效性和实用性。

关键词：知识图谱，大语言模型，智能建造，知识抽取，检索增强生成，智能问答

Abstract

With the deepening of digital transformation in the construction industry, intelligent construction has become a key pathway to improving the efficiency and quality of engineering projects. However, the construction sector has long faced challenges such as heterogeneous and multi-source data, fragmented knowledge accumulation, and difficulties in experience inheritance. Traditional rule-based and manual information processing methods are increasingly inadequate to meet the demands of complex engineering tasks. Knowledge graph technology can effectively organize and manage massive multi-source heterogeneous knowledge in the construction domain, while large language models exhibit powerful capabilities in semantic understanding and text generation. This thesis combines knowledge graphs with large language models to investigate core issues in intelligent construction, including knowledge management, intelligent question answering, and construction plan generation. The main contributions are as follows:

- (1) Research on knowledge graph construction methods for the intelligent construction domain. Addressing the wide variety of data sources and diverse data structures in construction, a hybrid top-down and bottom-up knowledge graph construction framework is designed. At the conceptual level, a domain ontology model is designed based on industry standards and specifications. At the instance level, a joint entity-relation extraction method for unstructured text is proposed, enabling automatic extraction of construction knowledge from multiple sources such as construction specifications, design drawing descriptions, and engineering reports.
- (2) Research on knowledge graph enhancement methods based on large language models. To address the issues of insufficient coverage and delayed updates in knowledge graphs, a few-shot entity recognition and relation extraction method based on large language models is proposed, effectively reducing dependence on large-scale annotated data. Additionally, a knowledge verification and completion mechanism based on prompt learning is designed, leveraging the reasoning capabilities of large language models for quality assessment and automatic expansion of knowledge graphs.
- (3) An intelligent construction question answering system integrating knowledge graphs and large language models. A retrieval-augmented generation framework is designed, utilizing knowledge graphs as structured knowledge sources. Through a combination of graph retrieval and semantic matching, precise domain knowledge support is provided for large language models, mitigating the knowledge hallucination problem in specialized construction domains. The system supports multiple application scenarios including construction specification queries, engineering quality diagnosis, and construction plan recommendations.

(4) System implementation and experimental validation. Based on the proposed methods, a prototype system for knowledge management and intelligent question answering oriented toward intelligent construction is designed and implemented. Experimental validation conducted on real construction project datasets demonstrates that the proposed methods achieve favorable performance in metrics such as entity recognition F1 score and question answering accuracy, confirming the effectiveness and practicality of the proposed approaches.

Key Words: Knowledge Graph, Large Language Model, Intelligent Construction, Knowledge Extraction, Retrieval-Augmented Generation, Intelligent Question Answering

目 录

摘要	I
Abstract	II
插图索引	VII
表格索引	VIII
第一章 绪论	1
1.1 研究背景与意义	1
1.1.1 知识图谱技术的研究进展	1
1.1.2 大语言模型技术的发展	2
1.1.3 本课题的研究意义	2
1.2 国内外研究现状	2
1.2.1 建筑领域知识管理研究现状	2
1.2.2 领域知识图谱构建研究现状	3
1.2.3 大语言模型在垂直领域的应用研究	3
1.3 研究内容与创新点	4
1.3.1 主要研究内容	4
1.3.2 论文创新点	4
1.4 论文组织结构	5
第二章 相关背景知识介绍	6
2.1 知识图谱技术基础	6
2.1.1 知识图谱的基本概念	6
2.1.2 知识图谱的构建流程	6
2.1.3 命名实体识别技术	7
2.1.4 关系抽取技术	7
2.2 大语言模型技术基础	8
2.2.1 Transformer 架构	8
2.2.2 预训练语言模型	8
2.2.3 检索增强生成技术	9
2.3 智能建造技术背景	9
2.3.1 建筑信息模型	9
2.3.2 建造领域的知识特征	10
2.3.3 智能建造中的知识需求分析	10
2.4 本章小结	10
第三章 面向智能建造的知识图谱构建	11
3.1 建造领域本体模型设计	11
3.1.1 本体设计方法论	11
3.1.2 核心概念体系	11
3.1.3 语义关系定义	12
3.2 多源异构数据知识抽取	12
3.2.1 数据源分析与预处理	12
3.2.2 基于预训练模型的实体关系联合抽取	13
3.2.3 面向建造领域的优化策略	14

3.3	知识融合与存储	14
3.3.1	实体对齐与消歧	14
3.3.2	基于图数据库的存储方案	15
3.4	实验与结果分析	15
3.4.1	实验设置	15
3.4.2	实体识别结果分析	16
3.4.3	关系抽取结果分析	16
3.4.4	知识图谱规模统计	17
3.5	本章小结	17
第四章	基于大语言模型的知识图谱增强	18
4.1	基于少样本学习的知识抽取增强	18
4.1.1	问题分析与动机	18
4.1.2	基于提示模板的少样本实体识别	18
4.1.3	基于推理链的关系抽取	19
4.1.4	实验与分析	20
4.2	基于提示学习的知识校验与补全	20
4.2.1	知识图谱质量校验	20
4.2.2	知识图谱自动补全	21
4.2.3	实验结果与分析	22
4.3	大语言模型与监督学习的协同策略	22
4.3.1	互补性分析	22
4.3.2	协同工作流程	22
4.4	本章小结	23
第五章	知识图谱与大语言模型协同的智能建造问答系统	24
5.1	检索增强生成框架设计	24
5.1.1	整体架构	24
5.1.2	查询理解与意图解析	25
5.1.3	知识检索与排序	25
5.1.4	知识增强的答案生成	26
5.2	系统设计与实现	27
5.2.1	系统技术架构	27
5.2.2	核心功能模块	27
5.3	实验评估与分析	28
5.3.1	实验设置	28
5.3.2	问答性能分析	28
5.3.3	不同意图类别的表现分析	29
5.3.4	消融实验	29
5.4	应用场景案例分析	30
5.4.1	案例一：施工规范查询	30
5.4.2	案例二：质量诊断	30
5.5	本章小结	31
第六章	总结与展望	32
6.1	本文工作总结	32
6.2	未来研究方向	32

参考文献 34

附录 A 程序清单 35

附录 B 攻读专业学位硕士期间撰写的论文 36

附录 C 攻读专业学位硕士期间申请的专利 37

附录 D 攻读专业学位硕士期间参加的科研项目 38

插图索引

图 3.1 建造领域本体设计流程图 12

图 5.1 知识图谱增强的 RAG 框架整体架构图 24

表格索引

表 3.1	建造领域本体语义关系定义	13
表 3.2	实体识别实验结果对比	16
表 3.3	关系抽取实验结果对比	17
表 3.4	建造领域知识图谱统计信息	17
表 4.1	少样本实体识别实验结果（F1 值，%）	20
表 4.2	少样本关系抽取实验结果（F1 值，%）	20
表 4.3	知识图谱补全实验结果	22
表 5.1	不同方法的建造问答性能对比	29
表 5.2	不同查询意图类别的准确率（/3）	29
表 5.3	消融实验结果	30

第一章 绪论

1.1 研究背景与意义

建筑业是国民经济的支柱产业，对经济社会发展具有重要的推动作用。然而，与制造业、金融业等高度信息化的行业相比，建筑行业的信息化与智能化水平长期处于较低水平。随着“新基建”、“数字中国”等国家战略的深入推进，智能建造已成为建筑业转型升级的核心方向。

智能建造是指在建筑全生命周期中，综合运用物联网、大数据、人工智能、建筑信息模型等新一代信息技术，实现建造过程的数字化、网络化和智能化。其核心目标是通过数据驱动和知识驱动的方式，提升工程质量、降低建造成本、缩短施工周期、保障施工安全。

然而，智能建造的实施面临着若干关键挑战：

第一，**知识碎片化严重**。建筑领域涉及的知识涵盖结构设计、材料科学、施工工艺、质量检测、安全管理等多个方面，这些知识分散在不同类型的文档中，包括国家标准、行业规范、设计图纸、施工方案、检测报告等，形成了大量的“信息孤岛”。

第二，**经验传承困难**。建筑施工中积累的大量隐性知识高度依赖于资深工程师的个人经验，难以被形式化和系统化地记录与传播。随着老一辈工程师的退休，大量宝贵的工程经验面临流失风险。

第三，**信息检索效率低下**。现有的建造信息管理系统多采用关键词匹配方式，缺乏对语义的深层次理解能力，导致施工人员在面对复杂问题时难以快速获取准确的知识支持。

知识图谱作为一种结构化的语义知识库，能够以“实体-关系-实体”三元组的形式系统地组织和表示领域知识，为知识的存储、检索和推理提供了有力支撑。近年来，随着深度学习技术的飞速发展，以 GPT 系列为代表的大语言模型展现出了强大的文本理解和生成能力，为自然语言交互式的知识服务开辟了新的可能。

1.1.1 知识图谱技术的研究进展

知识图谱的概念由 Google 于 2012 年正式提出，其初衷是增强搜索引擎的能力，提高搜索结果的质量和用户体验。经过十余年的发展，知识图谱技术已从通用领域拓展到医疗、金融、法律、教育等多个垂直行业。

在通用知识图谱方面，代表性的工作包括 Google 的 Knowledge Graph、微软的 Satori、维基数据等，它们包含了数亿级实体和数十亿级关系。在中文知识图谱领域，清华大学构建的 XLORE、复旦大学的 CN-DBpedia、北京大学的 PKUbase 等也取得了重要进展。

在领域知识图谱方面，研究者针对特定行业的专业知识特点，开展了大量探索。例如，在

医疗领域，有研究者构建了包含疾病、症状、药物、诊疗方案等实体的医学知识图谱；在法律领域，构建了包含法律条文、案例、司法解释等实体的法律知识图谱。然而，针对建造领域的知识图谱研究仍处于起步阶段，面临着领域本体设计复杂、专业知识抽取困难、多源数据融合挑战大等问题。

1.1.2 大语言模型技术的发展

大语言模型基于 Transformer 架构，通过在海量文本数据上进行自监督预训练，获得了强大的语言理解和生成能力。从 2018 年 BERT 的提出到 2020 年 GPT-3 的问世，再到近年来 GPT-4、Claude、文心一言、通义千问等国内外大模型的涌现，大语言模型技术在短短数年间取得了令人瞩目的进展。

大语言模型的核心优势在于：一是具有强大的语义理解能力，能够准确把握用户查询的深层意图；二是具有少样本学习能力，仅需少量示例即可适应特定任务；三是具有上下文推理能力，能够基于已有信息进行逻辑推导和知识关联。

然而，大语言模型在实际应用中仍面临若干关键挑战，包括：知识幻觉问题、领域知识不足、模型更新成本高等。将知识图谱作为外部知识源与检索增强生成技术相结合，是缓解上述问题的重要研究方向。

1.1.3 本课题的研究意义

本文将知识图谱技术和大语言模型技术相结合，围绕智能建造领域的关键需求，开展知识图谱构建、大语言模型增强、知识驱动的智能问答等方面的研究，具有重要的理论意义和应用价值：

(1) **理论意义**：提出了面向建造领域的知识图谱构建方法，探索了知识图谱与大语言模型协同的工作机制，为垂直领域的知识增强和智能服务提供了新的研究思路。

(2) **应用价值**：构建的智能建造知识管理系统能够帮助施工人员快速获取规范要求和经验知识，辅助工程决策，减少因知识不足导致的质量问题 and 安全事故，对推动建筑业智能化转型具有实际价值。

1.2 国内外研究现状

1.2.1 建筑领域知识管理研究现状

建筑信息模型是建筑行业数字化转型的核心技术之一。BIM 技术通过三维数字模型集成建筑的几何信息、物理属性、施工进度、成本等数据，为建筑全生命周期管理提供了统一的

数字化平台^[1]。然而，传统的 BIM 系统主要关注结构化数据的集成和可视化展示，对非结构化的文档知识、历史经验等缺乏有效的管理和利用手段。

在建造知识管理方面，国内外学者进行了多方面的探索。有研究者提出了基于本体的建筑施工知识管理系统，利用本体技术对施工作业、安全规范等知识进行形式化表示。也有研究者尝试将案例推理技术应用于施工方案推荐，通过检索历史相似案例来辅助新项目的方案设计。但这些方法在知识获取的自动化程度、知识表达的全面性和系统交互的自然性等方面仍有待改进。

1.2.2 领域知识图谱构建研究现状

领域知识图谱的构建通常包括概念层设计和实例层填充两个阶段。在概念层，研究者通过本体工程方法定义领域的概念体系和语义关系。本体设计方法经历了从手工构建到半自动构建再到自动构建的发展过程。手工构建虽然精度高，但耗时费力；自动构建方法如基于模式的本体学习、基于关联规则的概念挖掘等提高了效率，但在领域适应性方面仍面临挑战^[2]。

在实例层，知识抽取是核心环节，主要包括命名实体识别和关系抽取两个子任务。早期的方法主要依赖于规则模板和统计机器学习，如基于 CRF 的序列标注方法。近年来，基于预训练语言模型的方法取得了显著进展，例如利用 BERT-BiLSTM-CRF 架构进行实体识别，利用 BERT 进行关系分类等^[3]。然而，建造领域的文本具有专业术语密集、句式复杂、实体边界模糊等特点，通用领域的 NER 模型直接迁移效果不佳。

在建筑领域的知识图谱构建方面，近年来出现了少量探索性工作。有研究者尝试从建筑规范文本中抽取安全检查要点并构建知识图谱。也有研究者利用 BIM 模型中的结构化数据自动生成建筑构件知识图谱。但这些工作多针对特定子领域，缺乏面向建造全过程的系统化知识图谱构建方案。

1.2.3 大语言模型在垂直领域的应用研究

大语言模型在垂直领域的应用主要集中在两个方面：一是领域适配，二是知识增强。在领域适配方面，研究者提出了继续预训练、指令微调等方法，使通用大模型更好地适配特定领域的语言模式和知识需求。例如，Med-PaLM 通过对 PaLM 模型进行医学领域的继续训练和指令微调，在医学问答任务上取得了接近临床专家水平的表现^[4]。

在知识增强方面，检索增强生成是当前最受关注的技术路线之一^[5]。RAG 的基本思想是将检索系统和生成模型相结合，先通过检索器从外部知识库中获取与查询相关的文档或知识片段，再将其作为上下文提供给生成模型，从而引导模型生成更准确、更有依据的回答。RAG 技术被广泛应用于问答系统、对话系统、文本摘要等场景。

在建造领域，大语言模型的应用仍处于探索阶段。个别研究尝试利用 GPT 模型辅助施工方案的编写和施工规范的解读。然而，现有研究普遍忽略了建造领域知识的结构化特性，未能充分利用知识图谱的语义关联能力来增强大模型的知识获取效率。

1.3 研究内容与创新点

1.3.1 主要研究内容

本文围绕知识图谱与大语言模型助力智能建造这一主题，开展以下四个方面的研究：

(1) 面向智能建造的知识图谱构建方法。研究建造领域本体模型的设计方法，提出面向多源异构数据的知识抽取框架，实现从施工规范、设计文档、工程报告等文本中自动抽取建造知识，构建覆盖建造全过程的领域知识图谱。

(2) 基于大语言模型的知识图谱增强技术。研究利用大语言模型的少样本学习能力辅助知识抽取，降低对标注数据的依赖；研究基于提示学习的知识校验与补全方法，提高知识图谱的质量和覆盖面。

(3) 知识与模型协同的智能问答方法。研究将知识图谱的结构化知识与大语言模型的语义理解能力相结合的检索增强生成框架，设计面向建造领域的检索策略与知识融合机制，实现高质量的建造知识问答。

(4) 系统实现与实验验证。设计并实现智能建造知识管理与问答原型系统，在真实建造项目数据集上进行实验评估，验证所提方法的有效性。

1.3.2 论文创新点

本文的主要创新点包括：

(1) 提出了面向智能建造领域的知识图谱构建框架，设计了建造领域本体模型，并提出了面向多源异构文本的实体关系联合抽取方法，实现了建造知识的自动化获取与结构化组织。

(2) 提出了基于大语言模型的建造知识图谱增强方法，利用少样本学习和提示学习技术降低知识抽取的标注成本，并实现知识图谱的自动校验与补全。

(3) 设计了知识图谱与大语言模型协同的检索增强生成框架，通过图结构检索与语义匹配的结合，有效缓解了大模型在建造专业领域的知识幻觉问题。

(4) 在实际建造项目数据上验证了所提方法的有效性，构建了可运行的智能建造知识服务原型系统。

1.4 论文组织结构

本文共分为六章，各章的主要内容安排如下：

第一章绪论。介绍本文的研究背景与意义，分析国内外研究现状，阐述研究内容与创新点，并给出论文的组织结构。

第二章相关背景知识介绍。介绍知识图谱的基本概念与构建技术、大语言模型的基础理论、智能建造领域的技术背景，为后续章节奠定理论基础。

第三章面向智能建造的知识图谱构建。详细阐述建造领域本体模型的设计、多源异构数据的知识抽取方法、知识融合与存储方案，以及构建的实验结果与分析。

第四章基于大语言模型的知识图谱增强。介绍利用大语言模型辅助知识抽取的少样本学习方法、基于提示学习的知识校验与补全机制，以及相关实验验证。

第五章知识图谱与大语言模型协同的智能建造问答系统。详细描述检索增强生成框架的设计、建造领域检索策略、系统架构与实现，以及系统的实验评估。

第六章总结与展望。对本文的研究工作进行全面总结，分析研究中的不足之处，并对未来的研究方向进行展望。

第二章 相关背景知识介绍

本章介绍本文研究所涉及的基础理论和技术背景，包括知识图谱技术、大语言模型技术以及智能建造领域的相关知识，为后续章节的研究工作提供理论支撑。

2.1 知识图谱技术基础

2.1.1 知识图谱的基本概念

知识图谱是一种用图结构来表示知识和建模事物之间关系的语义网络。从形式化角度看，知识图谱可以表示为一个有向图 $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{T})$ ，其中 $\mathcal{E}$ 表示实体集合， $\mathcal{R}$ 表示关系集合， $\mathcal{T} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 表示三元组集合。每个三元组 (h, r, t) 表示头实体 h 与尾实体 t 之间存在关系 r 。

知识图谱的核心优势在于其结构化语义表达能力。与传统的关系数据库相比，知识图谱以天然的图结构存储知识，能够直观地表达实体间的复杂语义关联，支持高效的图遍历和推理操作。与纯文本知识库相比，知识图谱将知识分解为细粒度的结构化单元，避免了非结构化文本中的歧义性和冗余性，便于机器理解和处理。

知识图谱的研究内容涵盖知识表示、知识建模、知识抽取、知识融合、知识推理、知识存储等多个方面。其中，知识抽取和知识推理是当前研究的热点，也是本文重点关注的技术环节。

2.1.2 知识图谱的构建流程

知识图谱的构建通常采用自顶向下或自底向上的方式。自顶向下的方式先设计本体模式再填充实例数据，适用于领域边界清晰、知识结构明确的场景；自底向上的方式通过从数据中自动学习模式来逐步归纳概念层次，适用于开放域或知识结构不明确的场景。

对于领域知识图谱而言，自主设计结合两种方式的混合策略更为常见。典型的构建流程包括以下步骤：

(1) 本体设计：定义领域的概念类别、属性、关系类型，建立概念层次结构。本体是知识图谱的模式层，决定了知识表示的形式和组织方式。

(2) 知识抽取：从结构化和非结构化的多源数据中识别实体及其关系。对于文本数据，主要依赖命名实体识别和关系抽取技术。

(3) 知识融合：将来自不同来源的相同实体进行对齐和合并，消除冗余和冲突，提升知识的一致性和完整性。

(4) **知识存储**: 选择适合的图数据库或三元组存储引擎进行知识图谱的持久化存储和高效查询。

(5) **知识更新**: 建立知识图谱的增量更新机制, 保证知识的时效性。

2.1.3 命名实体识别技术

命名实体识别是指从非结构化文本中自动识别出具有特定意义的实体名称, 并标注其类别。在建造领域, 常见的实体类别包括: 施工材料、工程构件、施工设备、施工工艺、质量指标、安全规范等。

NER 任务通常被建模为序列标注问题。给定输入文本序列 $X = (x_1, x_2, \dots, x_n)$, 目标是预测每个词对应的标签序列 $Y = (y_1, y_2, \dots, y_n)$ 。常用的标签体系包括 BIO 和 BIOES 等。

近年来, 基于预训练模型的 NER 方法取得了突破性进展。以 BERT-BiLSTM-CRF 为代表的深度学习架构成为主流方案, 其数学描述如下:

对于输入序列 X , 首先通过 BERT 获得上下文敏感的词向量表示:

$$\mathbf{H} = \text{BERT}(X) = (\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_n) \quad (2.1)$$

随后通过 BiLSTM 进一步捕获序列的长距离依赖:

$$\mathbf{s}_t = \text{BiLSTM}(\mathbf{h}_t, \vec{\mathbf{s}}_{t-1}, \overleftarrow{\mathbf{s}}_{t+1}) \quad (2.2)$$

最后, CRF 层对标签序列进行全局优化, 输出概率最大的标签路径:

$$P(Y|X) = \frac{\exp(\sum_{t=1}^n \text{Score}(y_t, \mathbf{s}_t) + \text{Trans}(y_{t-1}, y_t))}{\sum_{\tilde{Y}} \exp(\sum_{t=1}^n \text{Score}(\tilde{y}_t, \mathbf{s}_t) + \text{Trans}(\tilde{y}_{t-1}, \tilde{y}_t))} \quad (2.3)$$

2.1.4 关系抽取技术

关系抽取旨在从文本中自动识别实体之间的语义关系。在建造领域, 典型的关系包括: 构件之间的”组成”关系、材料与构件之间的”使用”关系、设备与工艺之间的”应用于”关系、施工步骤之间的”前置”关系等。

关系抽取方法经历了从基于规则、基于特征工程到基于深度学习的发展历程。当前的主流方法包括:

基于预训练模型的关系分类: 给定文本中包含的两个实体, 通过 BERT 等预训练模型编码文本和实体位置信息, 在 [CLS] 标记的表示向量上进行关系类别的多分类。

实体关系联合抽取：与传统的流水线方式（先 NER 后 RE）不同，联合抽取方法在一个模型中同时完成实体识别和关系抽取，避免了误差传播问题。代表性方法包括基于标注方案的联合抽取、基于多头选择的联合抽取等。

关系抽取的数学形式可描述为：给定文本 S 及其中标注的实体对 (e_i, e_j) ，预测实体间的关系 r ：

$$P(r|S, e_i, e_j) = \text{softmax}(\mathbf{W}_r \cdot [\mathbf{h}_{e_i}; \mathbf{h}_{e_j}; \mathbf{h}_{\text{CLS}}] + \mathbf{b}_r) \quad (2.4)$$

2.2 大语言模型技术基础

2.2.1 Transformer 架构

Transformer 架构是现代大语言模型的基础^[6]。其核心创新在于完全基于注意力机制，摒弃了传统的循环神经网络结构，实现了高效的并行计算和长距离依赖建模。

Transformer 由编码器和解码器两部分组成。编码器由 N 个相同的层堆叠而成，每层包含一个多头自注意力子层和一个前馈全连接子层，每个子层均采用残差连接和层归一化：

$$\text{LayerOut} = \text{LayerNorm}(x + \text{Sublayer}(x)) \quad (2.5)$$

多头自注意力机制允许模型在不同的表示子空间中关注不同位置的信息。对于输入序列的表示矩阵 $\mathbf{X}$ ，通过线性变换得到查询矩阵 $\mathbf{Q}$ 、键矩阵 $\mathbf{K}$ 和值矩阵 $\mathbf{V}$ ：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.6)$$

其中 d_k 为键向量的维度，除以 $\sqrt{d_k}$ 的作用是防止点积过大导致 softmax 梯度消失。

多头注意力将注意力机制并行执行 h 次，每次使用不同的投影矩阵：

$$\text{MultiHead}(\mathbf{X}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (2.7)$$

$$\text{head}_i = \text{Attention}(\mathbf{X}\mathbf{W}_i^Q, \mathbf{X}\mathbf{W}_i^K, \mathbf{X}\mathbf{W}_i^V) \quad (2.8)$$

2.2.2 预训练语言模型

预训练语言模型通过在大规模无标注语料上进行自监督学习，获得通用的语言表示能力，再针对特定下游任务进行微调。这种“预训练-微调”范式已成为自然语言处理领域的主流方法。

BERT 采用了两个预训练任务：掩码语言模型和下一句预测。MLM 随机遮蔽输入文本中的部分词，要求模型预测遮蔽词的原始内容；NSP 判断两个句子是否为连续的上下文。

GPT 系列模型采用自回归语言模型作为预训练任务，即基于上文预测下一个词：

$$P(x_1, x_2, \dots, x_T) = \prod_{t=1}^T P(x_t | x_{<t}) \quad (2.9)$$

随着模型规模和训练数据量的增大，大语言模型涌现出了上下文学习、思维链推理等令人瞩目的能力，为其在垂直领域的应用奠定了能力基础。

2.2.3 检索增强生成技术

检索增强生成是一种将信息检索与文本生成相结合的框架，旨在缓解大语言模型的知识局限性和幻觉问题。RAG 的基本流程如下：

首先，给定用户查询 q ，检索器从外部知识库 $\mathcal{D}$ 中检索出与查询最相关的文档或知识片段集合 $\mathcal{Z} = \{z_1, z_2, \dots, z_k\}$ 。检索器通常基于双塔模型或稀疏检索模型实现，检索函数可表示为：

$$\text{Score}(q, z) = \text{Sim}(E_q(q), E_z(z)) \quad (2.10)$$

其中 E_q 和 E_z 分别为查询和文档的编码函数， $\text{Sim}(\cdot, \cdot)$ 为相似度度量函数。

然后，将检索到的知识片段与用户查询拼接后输入生成模型，生成最终的回答：

$$y = \text{LLM}(\text{Prompt}(q, \mathcal{Z})) \quad (2.11)$$

RAG 的关键优势在于将知识的存储与推理分离：知识由外部知识库维护，可以独立更新；大语言模型专注于语言理解和生成，降低了知识更新的成本。

2.3 智能建造技术背景

2.3.1 建筑信息模型

建筑信息模型是建筑行业数字化转型的核心技术。BIM 通过创建和管理建筑项目的数字表示，为项目参与各方提供一个协同工作的信息平台。

BIM 的核心特征包括：参数化三维建模、多专业协同、全生命周期信息集成、可视化与模拟等。BIM 模型包含丰富的结构化信息，如构件的几何尺寸、材质属性、造价信息、施工进度等，这些结构化数据是知识图谱构建的重要数据源。

2.3.2 建造领域的知识特征

建造领域的知识具有以下显著特征，对知识图谱的构建和大语言模型的应用提出了特殊要求：

(1) **知识体系庞杂**。建造知识涵盖建筑、结构、给排水、暖通、电气等多个专业，涉及设计、施工、验收、运维等多个阶段，知识总量巨大而类型丰富。

(2) **标准规范密集**。建造活动受到大量国家标准、行业标准、地方规程的约束，这些规范性文件是建造知识的核心来源，但文本量大、专业性强、人工检索效率低。

(3) **隐性知识丰富**。施工经验、操作技巧、问题诊断等大量知识存在于工程师的头脑中，属于隐性知识，难以通过传统方式被有效获取和传播。

(4) **知识关联复杂**。建造领域的实体之间存在复杂的空间关系、时序关系、功能关系和因果关系，如构件之间的连接关系、施工工序之间的依赖关系、质量问题与成因之间的因果链等。

2.3.3 智能建造中的知识需求分析

根据对施工企业实际需求的调研分析，智能建造中的知识需求主要体现在以下场景：

(1) **规范查询**：施工人员需要快速检索相关的国家标准和技术规范条文，确认施工做法的合规性。

(2) **质量问题诊断**：当出现工程质量问题时，需要基于现象判断可能的成因，并获取修复方案建议。

(3) **施工方案推荐**：针对特定的工程条件和施工环境，需要推荐合适的施工工艺和技术方案。

(4) **材料选型辅助**：根据工程要求和环境条件，选择适用的建筑材料和施工设备。

这些知识需求场景对知识管理系统的语义理解能力、知识组织能力和智能交互能力提出了较高要求，也正是本文研究所着力解决的关键问题。

2.4 本章小结

本章对本文研究所涉及的基础理论和技术背景进行了系统介绍。首先，介绍了知识图谱的基本概念、构建流程、命名实体识别和关系抽取等核心技术。其次，阐述了大语言模型的Transformer基础架构、预训练范式和检索增强生成技术。最后，分析了智能建造领域的技术背景，包括建筑信息模型、建造领域知识的特征以及典型的知识需求场景。本章为后续第三至五章的具体研究工作奠定了理论基础。

第三章 面向智能建造的知识图谱构建

本章详细阐述面向智能建造领域的知识图谱构建方法。首先，设计了建造领域本体模型作为知识图谱的模式层。然后，提出了面向多源异构文本的实体关系联合抽取方法。接着，介绍了知识融合和存储方案。最后，通过实验验证了所提构建方法的有效性。

3.1 建造领域本体模型设计

3.1.1 本体设计方法论

本体是对领域知识的概念化、形式化描述，定义了领域中的概念类别、属性、关系和约束条件。本文采用半自动化的本体设计方法，结合领域专家知识和数据驱动的概念归纳，构建建造领域本体模型。

本体设计遵循以下原则：一是完整性，确保覆盖建造全过程的各类概念；二是一致性，概念定义清晰无歧义，层次结构合理；三是可扩展性，方便后续根据需求增加新的概念和关系；四是实用性，本体的粒度和结构需满足实际应用的需求。

设计流程如图3.1所示，主要包括以下步骤：需求分析、核心概念提取、概念层次构建、关系定义、属性定义、本体评估与迭代优化。

3.1.2 核心概念体系

通过对 GB/T 50319-2013《建设工程监理规范》、GB 50300-2013《建筑工程施工质量验收统一标准》等多项国家标准分析，结合对实际施工项目的调研，本文定义了建造领域本体的核心概念体系，按层次组织为六大类：

(1) 工程实体类：包括建筑项目、单位工程、分部工程、分项工程、检验批等工程分解结构中的各层级实体，以及梁、板、柱、墙、基础等具体构件。

(2) 材料设备类：包括混凝土、钢筋、砌块、防水材料等建筑材料，以及塔吊、挖掘机、混凝土泵车等施工机械设备。

(3) 施工活动类：包括模板工程、钢筋工程、混凝土工程、砌体工程、装饰装修工程等各工种的施工工艺和作业活动。

(4) 检测验收类：包括材料进场检验、工序验收、隐蔽工程验收、竣工验收等各类质量检测和验收活动，以及强度、平整度、垂直度等检测指标。

(5) 标准规范类：包括国家标准、行业标准、地方标准、企业标准等各级技术规范文件，以及具体的规范条文。



图 3.1 建造领域本体设计流程图

(6) **人员组织类**：包括项目经理、技术负责人、施工员、质量员、安全员等各类项目角色和组织结构。

3.1.3 语义关系定义

在概念体系的基础上，本文定义了以下主要的语义关系类型：

上述 13 种关系涵盖了建造过程中涉及的组成结构、工艺流程、材料使用、质量检测、规范遵循等核心知识关联，为知识图谱的实例层构建提供了明确的语义框架。

3.2 多源异构数据知识抽取

3.2.1 数据源分析与预处理

建造领域的数据来源广泛且格式多样，本文主要处理以下三类数据：

(1) **结构化数据**：主要来自于 BIM 模型导出的构件信息表、材料清单等。这类数据格式规整，可通过编写映射规则直接转换为知识图谱的三元组。

(2) **半结构化数据**：主要来自于施工日志、质量检验表等具有一定模板格式的文档。通过设计模板解析器结合规则匹配进行信息抽取。

表 3.1 建造领域本体语义关系定义

关系名称	含义	定义域	值域
hasPart	组成关系	工程实体	工程实体/构件
useMaterial	使用材料	施工活动/构件	材料
useEquipment	使用设备	施工活动	施工设备
hasPredecessor	前置工序	施工活动	施工活动
hasSuccessor	后置工序	施工活动	施工活动
inspect	检测对象	检测验收	工程实体
hasIndicator	检测指标	检测验收	检测指标
complyWith	遵循规范	施工活动	标准规范
hasRole	承担角色	人员	人员组织
produce	产出	施工活动	工程实体
hasSymptom	问题表现	质量问题	质量现象
hasCause	问题成因	质量问题	施工活动/材料

(3) **非结构化数据**：主要来自于国家标准和行业规范文件、施工组织设计方案、技术交底记录等纯文本文档。这类数据是建造知识的核心载体，也是知识抽取的重点和难点。

对于非结构化文本，预处理流程包括：文本分段、分句、分词（使用 jieba 分词结合建造领域自定义词典）、去停用词。针对建造领域文本中大量出现的专业术语和缩略词，本文整理了一个包含 3,500 余条建造领域术语的自定义词典，有效提升了分词精度。

3.2.2 基于预训练模型的实体关系联合抽取

传统的流水线式知识抽取方法存在误差传播的问题，即 NER 的错误会影响后续 RE 的准确性。为解决这一问题，本文设计了一种基于预训练模型的实体关系联合抽取方法。

本文采用基于多头标注的联合抽取框架。该方法在 BERT 编码器之上设计了两个并行的标注头：实体标注头和关系标注头。实体标注头采用 BIOES 标注方案识别实体边界和类别；关系标注头对于每对候选实体，预测其是否存在关系及其关系类型。

模型的整体架构如下：

编码层：使用预训练的 BERT-wwm-ext 模型作为文本编码器。对于输入文本 $X = [x_1, x_2, \dots, x_n]$ ，BERT 输出每个词的上下文表示：

$$\mathbf{h}_i = \text{BERT}(X)[i], \quad i \in \{1, 2, \dots, n\} \quad (3.1)$$

实体识别层：在 BERT 输出之上接一个线性分类器，预测每个词 i 属于各实体标签的概率：

$$P(y_i^e | X) = \text{softmax}(\mathbf{W}_e \cdot \mathbf{h}_i + \mathbf{b}_e) \quad (3.2)$$

关系分类层：对于实体识别出的任意实体对 (e_i, e_j) ，将其对应的词表示进行拼接和最大池化后送入关系分类器：

$$\mathbf{r}_{ij} = [\max(\mathbf{H}_{e_i}); \max(\mathbf{H}_{e_j})] \quad (3.3)$$

$$P(y_{ij}^r | X, e_i, e_j) = \text{softmax}(\mathbf{W}_r \cdot \mathbf{r}_{ij} + \mathbf{b}_r) \quad (3.4)$$

联合训练：模型的总体损失函数为实体识别损失和关系分类损失的加权和：

$$\mathcal{L} = \lambda_e \mathcal{L}_e + \lambda_r \mathcal{L}_r \quad (3.5)$$

其中 $\mathcal{L}_e$ 为实体识别的交叉熵损失， $\mathcal{L}_r$ 为关系分类的交叉熵损失， λ_e 和 λ_r 为权重超参数，本文中均取 1.0。

3.2.3 面向建造领域的优化策略

针对建造领域文本的特点，本文提出了以下优化策略：

(1) 领域词典增强：将建造领域自定义词典中的术语信息注入 BERT 的分词和编码过程。具体地，在 BERT 的 WordPiece 分词基础上，识别并保持自定义词典中专业术语的完整性，避免将“钢筋混凝土框架结构”这类专业术语切分成语义不完整的子词。

(2) 文本特征融合：建造领域的实体往往带有特定的上下文模式，如“C30 混凝土”、“HRB400 钢筋”等带有规格编号。本文在 BERT 编码的基础上，融合了字符级的 CNN 特征和词性标注特征：

$$\tilde{\mathbf{h}}_i = [\mathbf{h}_i^{\text{BERT}}; \mathbf{h}_i^{\text{CNN}}; \mathbf{h}_i^{\text{POS}}] \quad (3.6)$$

(3) 数据增强：针对建造领域标注数据有限的问题，采用基于弱监督的数据增强策略。利用已有的少量标注数据训练初始模型，对大规模未标注文本进行自动标注，选取高置信度的预测结果加入训练集，进行迭代训练。

3.3 知识融合与存储

3.3.1 实体对齐与消歧

从不同数据源抽取的知识可能存在冗余和冲突，需要通过知识融合来提升知识图谱的一致性。本文主要处理以下两类问题：

实体对齐：识别指向同一真实世界实体的不同实体提及。例如，“C30 商品混凝土”、“C30 商混”、“C30 混凝土”可能指向同一类材料实体。本文采用基于多特征相似度的实体对齐方法，

综合考虑实体的名称相似度、属性相似度和上下文相似度：

$$\text{Sim}(e_i, e_j) = \alpha \cdot \text{Sim}_{\text{name}}(e_i, e_j) + \beta \cdot \text{Sim}_{\text{attr}}(e_i, e_j) + \gamma \cdot \text{Sim}_{\text{ctx}}(e_i, e_j) \quad (3.7)$$

其中，名称相似度采用编辑距离和拼音相似度的融合，属性相似度采用 Jaccard 系数，上下文相似度基于实体邻近子图结构的图卷积编码。

冲突消解：当不同来源对同一事实给出矛盾的描述时，基于来源可信度和信息新鲜度进行冲突消解。规范文件的可信度高于施工日志，发布时间更近的信息通常更可靠。

3.3.2 基于图数据库的存储方案

本文选用 Neo4j 图数据库作为知识图谱的存储引擎。Neo4j 以节点和边的原生图结构存储数据，天然适配知识图谱的存储和查询需求。

存储方案设计如下：

- 实体以节点形式存储，节点标签对应本体中的概念类别
- 关系以有向边形式存储，边的类型对应本体中定义的关系类型
- 实体和关系均可附加属性键值对，存储额外的属性信息
- 建立节点和关系上的索引以加速图查询

对于知识图谱的查询，使用 Cypher 图查询语言。例如，查询某分项工程的完整施工流程路径：

代码 3.1 施工流程路径查询示例

```
1 MATCH path = (start:SubProject {name: "混凝土浇筑"})
2   -[:hasPredecessor*]->(end: ConstructionActivity)
3 RETURN path
```

3.4 实验与结果分析

3.4.1 实验设置

数据集：本文从某大型建筑企业的实际项目中收集数据，构建了建造领域知识抽取数据集。数据集包含施工规范文本 1,200 篇、施工组织设计方案 350 篇、技术交底记录 800 篇、质

量检测报告 500 篇。经过人工标注，共标注了 25,000 个实体（涵盖 6 个实体大类）和 18,000 条关系（涵盖 13 种关系类型）。数据集按照 7:1.5:1.5 的比例划分为训练集、验证集和测试集。

评价指标：采用精确率、召回率和 F1 值作为评价指标。实体的精确匹配采用严格匹配标准，即实体边界和类别均预测正确才算正确；关系的评估在正确识别的实体对上进行。

基线模型：选取了以下基线模型进行对比：

- BiLSTM-CRF：经典的序列标注模型
- BERT-BiLSTM-CRF：基于 BERT 编码的 NER 模型
- BERT-Joint：基于 BERT 的流水线式 NER+RE 模型
- SpERT：基于预训练模型的联合实体关系抽取模型

3.4.2 实体识别结果分析

实体识别的实验结果如表3.2所示。

表 3.2 实体识别实验结果对比

模型	精确率 (%)	召回率 (%)	F1 值 (%)
BiLSTM-CRF	78.45	74.32	76.33
BERT-BiLSTM-CRF	85.67	82.91	84.27
BERT-Joint（仅 NER）	86.12	83.45	84.77
本文方法（基础版）	86.89	84.23	85.54
本文方法（+ 领域词典增强）	88.35	85.76	87.04
本文方法（+ 文本特征融合）	89.21	86.58	87.87
本文方法（完整版）	90.15	87.93	89.03

从实验结果可以看出，本文提出的方法在实体识别任务上取得了最优的 F1 值 89.03%，相比基线模型 BERT-BiLSTM-CRF 提升了 4.76 个百分点。领域词典增强和文本特征融合两个优化策略均带来了稳定的性能提升，验证了其在建造领域实体识别中的有效性。

进一步按实体类别分析 F1 值，发现”材料设备类”和”标准规范类”实体的识别效果最佳（F1 值超过 92%），而”施工活动类”实体的识别效果相对较低（F1 值约 84%）。分析认为，施工活动实体在文本中的表达方式更为多样，边界更模糊，识别难度更大。

3.4.3 关系抽取结果分析

关系抽取的实验结果如表3.3所示。

表 3.3 关系抽取实验结果对比

模型	精确率 (%)	召回率 (%)	F1 值 (%)
BERT-Joint (流水线 RE)	72.56	68.34	70.39
SpERT	78.92	74.15	76.46
本文方法 (联合抽取)	80.34	76.82	78.54
本文方法 (+ 特征融合)	82.17	78.56	80.33
本文方法 (完整版)	83.45	79.81	81.59

本文方法的完整版在关系抽取任务上取得了 81.59% 的 F1 值，较 SpERT 基线提升了 5.13 个百分点。联合抽取框架有效缓解了误差传播问题，特征融合策略进一步提升了模型对建造领域文本的理解能力。在关系类型层面，“hasPart”（组成关系）和“useMaterial”（使用材料）的抽取效果最好，而“hasCause”（问题成因）的抽取最为困难，后者涉及更深层次的因果推理。

3.4.4 知识图谱规模统计

经过知识抽取和融合，本文最终构建的建造领域知识图谱的规模统计如表3.4所示。

表 3.4 建造领域知识图谱统计信息

统计项	数量
实体总数	156,832
关系三元组总数	423,567
实体类别数	6
关系类型数	13
来源文档数	2,850
覆盖国家标准数	42

3.5 本章小结

本章系统阐述了面向智能建造领域的知识图谱构建方法。首先，设计了包含六大概念类别和 13 种语义关系的建造领域本体模型。其次，提出了基于预训练模型的实体关系联合抽取方法，并针对建造领域文本特点设计了领域词典增强和文本特征融合等优化策略。随后，介绍了基于多特征相似度的实体对齐方法和基于 Neo4j 图数据库的知识存储方案。最后，通过实验验证了所提方法的有效性，在实体识别和关系抽取任务上分别取得了 89.03% 和 81.59% 的 F1 值。

第四章 基于大语言模型的知识图谱增强

第三章构建的建造领域知识图谱为智能建造提供了结构化的知识基础。然而，受标注数据规模和提取技术等因素的限制，初始构建的知识图谱在覆盖度和完整性上仍存在不足。本章研究如何利用大语言模型的能力来增强知识图谱，主要包括两个方面的内容：一是基于少样本学习的知识抽取，降低对大规模标注数据的依赖；二是基于提示学习的知识校验与自动补全，提升知识图谱的质量。

4.1 基于少样本学习的知识抽取增强

4.1.1 问题分析与动机

第三章中提出的知识抽取方法虽然在标注数据集上取得了较好效果，但其性能在很大程度上依赖于大规模高质量的标注数据。建造领域的知识标注需要标注人员具备专业知识背景，标注成本高昂。随着建造行业的不断发展，新的材料、工艺和设备不断涌现，知识图谱需要持续更新以保持其时效性。

大语言模型在少样本学习方面展现出了令人瞩目的能力。研究表明，通过精心设计的提示词模板，大语言模型仅需少量示例即可较好地完成NER和RE任务。这为降低建造领域知识抽取的标注成本、实现知识图谱的持续更新提供了新的技术路径。

本节研究如何利用大语言模型的少样本学习能力辅助建造领域的实体识别和关系抽取，并与第三章中基于预训练模型的监督学习方法形成互补。

4.1.2 基于提示模板的少样本实体识别

提示学习通过设计自然语言形式的提示模板，将下游任务转化为大语言模型所熟悉的语言建模任务格式。本文将NER任务重新表述为文本生成任务，让大语言模型直接生成包含实体标注信息的结构化文本。

具体地，设计的NER提示模板格式如下：

代码 4.1 少样本NER提示模板设计

```
1 你是一名建筑领域知识工程专家。请从以下文本中识别出所有建造
2 领域的实体，并标注其类别。实体类别包括：工程实体、材料设备、
3 施工活动、检测验收、标准规范、人员组织。
4
5 示例1：
6 输入：“框架柱采用C30混凝土浇筑，应符合GB50204-2015的要求。”
```

```

7  输出：框架柱[工程实体]| C30混凝土[材料设备]| 浇筑[施工活动]
8      | GB50204-2015[标准规范]
9
10 示例2:
11 输入：“项目经理组织技术负责人和施工员进行钢筋隐蔽工程验收。”
12 输出：项目经理[人员组织]| 技术负责人[人员组织]| 施工员[人员组织]
13      | 钢筋[材料设备]| 隐蔽工程验收[检测验收]
14
15 现在请识别以下文本中的实体：
16 输入：“{待识别文本}”
17 输出：

```

在少样本设置下 (k 个训练示例), 将 k 个带标注的示例按照上述模板格式组织为提示词, 后接待识别的文本, 由大语言模型生成标注结果。

4.1.3 基于推理链的关系抽取

对于关系抽取任务, 本文设计了基于思维链的关系抽取方法。与传统的直接预测关系类别不同, 思维链方法引导大语言模型先进行中间推理步骤, 再给出最终的关系判断, 从而提高关系抽取的准确率。

关系抽取的思维链提示模板设计如下:

代码 4.2 基于思维链的关系抽取提示模板

```

1  请判断以下建造领域文本中, 指定实体之间是否存在关系,
2  以及关系的类型。请先分析实体在文本中的语义角色,
3  再判断它们之间的关系。
4
5  关系类型: hasPart (组成)、useMaterial (使用材料)、
6  useEquipment (使用设备)、hasPredecessor (前置)、
7  hasSuccessor (后置)、inspect (检测)、complyWith (遵循)
8
9  示例:
10 文本: “框架柱采用C30混凝土浇筑, 应符合GB50204-2015的要求。”
11 实体1: 框架柱; 实体2: C30混凝土
12 分析: 实体1是工程构件, 实体2是建筑材料, 文本中“采用...浇筑”表示
13 材料使用关系。
14 关系: useMaterial
15
16 现在请分析以下文本:
17 文本: “{待分析文本}”
18 实体1: {实体1}; 实体2: {实体2}
19 分析:

```

4.1.4 实验与分析

为评估基于大语言模型的少样本知识抽取效果，本文在第三章使用的测试集上进行了实验。实验选用 GPT-4 和 Claude-3 两个主流大语言模型，分别在 $k = 0$ （零样本）、 $k = 1, 3, 5, 10$ 个示例的设置下测试性能。

少样本 NER 实验结果如表4.1所示。

表 4.1 少样本实体识别实验结果（F1 值，%）

模型	k=0	k=1	k=3	k=5	k=10
GPT-4	52.34	60.12	68.45	74.89	79.56
Claude-3	50.78	58.67	66.92	73.21	78.15
本文方法（全监督，第 3 章）	—	—	—	—	89.03

从实验结果可以观察到：随着示例数量的增加，大语言模型的少样本 NER 性能逐步提升，在 $k = 10$ 时 GPT-4 达到了 79.56% 的 F1 值。虽然相比全监督方法（89.03%）仍有差距，但考虑到仅使用了 10 个标注示例，这一结果已经展现了少样本学习的潜力。值得注意的是，GPT-4 和 Claude-3 在零样本设置下也能取得约 50%-52% 的 F1 值，体现了大语言模型在建造领域的初步知识储备。

少样本关系抽取的实验结果如表4.2所示。基于思维链的关系抽取相比直接预测方式，在 F1 值上有约 3-5 个百分点的稳定提升，验证了思维链推理在建造领域复杂关系抽取中的有效性。

表 4.2 少样本关系抽取实验结果（F1 值，%）

模型	k=0	k=1	k=3	k=5	k=10
GPT-4（直接）	42.18	51.45	60.32	66.78	72.34
GPT-4（思维链）	45.67	55.23	65.18	71.56	76.89
Claude-3（直接）	40.56	49.87	58.94	65.12	71.08
Claude-3（思维链）	43.89	53.76	63.45	69.87	75.42
本文方法（全监督，第 3 章）	—	—	—	—	81.59

4.2 基于提示学习的知识校验与补全

4.2.1 知识图谱质量校验

自动化构建的知识图谱不可避免地包含错误和遗漏。传统的知识图谱质量控制依赖于人工审核，效率低下且难以规模化。本节探索利用大语言模型的推理能力对知识图谱进行自动化的质量校验。

知识校验任务的目标是：给定一个三元组 (h, r, t) 及其来源文本片段，判断该三元组是否正确表达了文本中的知识。本文将知识校验建模为文本蕴含任务：如果三元组能够从文本中合理推断出来，则该三元组为”正确”；如果三元组与文本内容矛盾或超出文本内容，则为”错误”。

设计的知识校验提示模板如下：

代码 4.3 知识图谱质量校验提示模板

```

1 请判断以下三元组是否正确表达了给定文本中的知识。
2
3 文本：”钢筋混凝土框架结构的抗震等级应根据建筑抗震设防类别、
4 设防烈度和房屋高度等条件，按GB50011的规定确定。”
5
6 三元组：（框架结构，complyWith，GB50011）
7 判断：

```

在知识图谱的 165,000 条三元组上进行的质量校验实验结果显示，大语言模型能够以 87.6% 的准确率判断三元组的正确性。通过对被模型判定为”错误”的三元组进行人工复核，确认其中约 72% 确实存在问题，主要包括实体识别错误导致的三元组不准确、跨句关系抽取时的上下文理解偏差、多源信息融合时的冲突未正确消解等。

4.2.2 知识图谱自动补全

知识图谱补全旨在发现和填补知识图谱中缺失的三元组。传统的知识图谱补全方法主要基于知识图谱嵌入模型，通过学习实体和关系的低维向量表示来预测缺失的链接。这些方法仅利用了知识图谱内部的结构信息，忽略了知识图谱外部的文本证据。

本文提出了一种结合大语言模型推理和知识图谱结构信息的混合补全方法。方法的基本流程如下：

第一步，利用知识图谱嵌入模型 TransE 对知识图谱中的实体和关系进行预嵌入，获取实体的初始向量表示：

$$f(h, r, t) = \|\mathbf{h} + \mathbf{r} - \mathbf{t}\|_2^2 \quad (4.1)$$

第二步，对于候选三元组 $(h, r, ?)$ ，利用知识图谱嵌入模型获取尾实体的初步排序列表。

第三步，利用大语言模型对排序靠前的候选尾实体进行语义验证。将候选补全方案整理为自然语言描述，由大语言模型基于其领域知识判断候选补全方案的合理性。

第四步，融合知识图谱嵌入得分和大语言模型的语义得分：

$$\text{Score}(h, r, t) = \lambda_{\text{kg}} \cdot S_{\text{kg}}(h, r, t) + \lambda_{\text{llm}} \cdot S_{\text{llm}}(h, r, t) \quad (4.2)$$

其中 S_{kg} 为知识图谱嵌入模型的结构得分， S_{llm} 为大语言模型的语义合理性得分， λ_{kg} 和 λ_{llm} 为权重参数。

4.2.3 实验结果与分析

知识图谱补全实验在本文构建的建造领域知识图谱上进行。将已有的 423,567 条三元组中的 20% 作为测试集（移除尾实体），评估模型补全缺失尾实体的能力。评价指标采用 MRR 和 Hits@K（K=1, 3, 10）。

实验结果如表4.3所示。本文提出的混合补全方法在所有指标上均优于纯知识图谱嵌入方法和纯大语言模型方法，验证了将知识图谱结构信息和大语言模型语义知识相结合的有效性。

表 4.3 知识图谱补全实验结果

方法	MRR	Hits@1	Hits@3	Hits@10
TransE	0.352	0.234	0.398	0.521
DistMult	0.378	0.261	0.425	0.548
ComplEx	0.391	0.275	0.438	0.563
GPT-4（仅语义）	0.412	0.298	0.456	0.589
本文混合方法	0.456	0.342	0.508	0.642

通过知识图谱自动补全，最终的知识图谱三元组数量从 423,567 条扩充至 502,891 条，增幅约 18.7%，有效提升了知识图谱的覆盖度。

4.3 大语言模型与监督学习的协同策略

4.3.1 互补性分析

综合本章的研究，基于大语言模型的知识图谱增强方法与第三章的监督学习方法具有明显的互补性：

监督学习方法的优势在于：在标注数据充足的场景下，能够取得更高的准确率；模型训练完成后推理速度快，适合大规模批量处理。**其局限**在于：高度依赖标注数据，标注成本高；对新增实体类型的适应性差。

大语言模型方法的优势在于：仅需少量示例即可工作，标注成本低；灵活性高，可适应新的实体类型和关系类型；具有语义推理能力，可用于知识校验等需要理解的场景。**其局限**在于：准确率相对较低；推理速度慢，API 调用成本高；存在知识幻觉风险。

4.3.2 协同工作流程

基于互补性分析，本文设计了以下协同工作流程：

初始构建阶段：以监督学习方法为主，在高质量标注数据上训练高精度的知识抽取模型，构建初始知识图谱。

增量更新阶段：当出现新的知识来源或领域扩展时，以少样本大语言模型方法为先导，快速实现初步的知识抽取，再通过人工校验逐步积累标注数据，切换到监督学习模式。

质量控制阶段：利用大语言模型的语义理解能力对知识图谱进行定期校验，自动识别可能的错误三元组，提供给人工审核。

知识扩展阶段：综合利用知识图谱嵌入的结构信息和大语言模型的语义知识，持续进行知识图谱的补全和扩充。

通过上述协同策略，实现了知识图谱构建和维护过程中的”人-模-图”闭环，兼顾了效率、质量和成本。

4.4 本章小结

本章围绕利用大语言模型增强建造领域知识图谱这一主题，开展了以下研究工作：(1) 提出了基于提示模板的少样本 NER 方法，在仅 10 个示例的情况下达到 79.56% 的 F1 值，有效降低了知识抽取对标注数据的依赖；(2) 设计了基于思维链的关系抽取方法，相比直接预测方式有 3-5 个百分点的性能提升；(3) 利用大语言模型实现了知识图谱的质量校验（准确率 87.6%）和自动补全（三元组数量增长 18.7%）；(4) 分析了大语言模型和监督学习方法的互补性，并设计了协同工作流程。

第五章 知识图谱与大语言模型协同的智能建造问答系统

在前两章构建并增强的建造领域知识图谱的基础上，本章研究如何将知识图谱的结构化知识与大语言模型的语义理解能力有机结合，构建面向智能建造的知识问答系统。本章详细阐述了检索增强生成框架的设计、建造领域知识检索策略、系统架构与实现，以及系统的实验评估。

5.1 检索增强生成框架设计

5.1.1 整体架构

本文设计的检索增强生成框架整体架构如图5.1所示，主要由三个核心模块构成：查询理解模块、知识检索模块和答案生成模块。



图 5.1 知识图谱增强的 RAG 框架整体架构图

各模块的功能分工如下：

查询理解模块：对用户输入的自然语言问题进行语义解析，识别问题中涉及的实体和意图。例如，对于问题“C30 混凝土浇筑后需要养护多少天？”，识别出实体“C30 混凝土”和“浇筑”、“养护”，意图为查询“养护时间要求”。

知识检索模块：根据查询理解的结果，从知识图谱中检索相关的结构化知识和三元组，同

时可选地从文档库中检索相关的文本段落作为补充。该模块的核心是设计高效的混合检索策略。

答案生成模块：将检索到的知识片段与用户原始问题组合成提示词，输入大语言模型，生成最终的自然语言答案。该模块还负责对生成的答案进行引用标注，指明答案的知识来源。

5.1.2 查询理解与意图解析

查询理解是 RAG 框架的前置环节，其质量直接影响后续检索的精度。本文设计了一个轻量级的查询理解流程：

首先，利用第三章训练的 NER 模型识别查询中的建造领域实体。对于识别出的实体，将其标准化映射到知识图谱中的实体节点。

其次，对查询进行意图分类。根据建造领域的典型问答场景，定义了五类查询意图：

- (1) **规范查询：**查询某施工做法的规范要求
- (2) **工艺查询：**查询某施工工艺的操作流程和要点
- (3) **质量诊断：**根据质量现象查询可能的原因和解决方案
- (4) **材料查询：**查询材料的规格、性能和适用条件
- (5) **方案推荐：**寻求施工方案或技术路线的建议

意图分类采用基于 BERT 的文本分类模型，在人工标注的 2,500 条建造领域查询数据上进行微调，分类准确率达到 92.4%。

5.1.3 知识检索与排序

知识检索是 RAG 框架的核心环节。本文设计了“图检索 + 语义检索”的混合检索策略。

图结构检索：利用查询中识别的实体作为锚点，在知识图谱中进行多跳遍历，检索相关的子图知识。对于每个锚点实体 e ，检索其 k 跳邻域内的所有三元组：

$$\mathcal{T}_e^{(k)} = \{(h, r, t) \in \mathcal{G} : \text{dist}(e, h) \leq k \vee \text{dist}(e, t) \leq k\} \quad (5.1)$$

其中 $\text{dist}(\cdot, \cdot)$ 表示知识图谱中两节点之间的最短路径长度。本文设置 $k = 2$ ，以在检索覆盖度和效率之间取得平衡。

语义相似度检索：将查询向量化表示后，与知识图谱中的三元组进行语义相似度匹配。查询的向量表示通过预训练的 Sentence-BERT 模型获得：

$$\mathbf{q} = \text{Sentence-BERT}(Q) \quad (5.2)$$

对于每个三元组 (h, r, t) ，将其自然语言化表示为“ h 的 r 是 t ”，同样计算其向量表示 $\mathbf{k}$ 。两者之间的相似度采用余弦相似度：

$$\text{Sim}(\mathbf{q}, \mathbf{k}) = \frac{\mathbf{q} \cdot \mathbf{k}}{\|\mathbf{q}\| \cdot \|\mathbf{k}\|} \quad (5.3)$$

混合检索排序：将图检索和语义检索的结果进行合并和重排序。最终的检索得分为图结构得分和语义相似度得分的加权融合：

$$\text{Score}_{\text{final}} = \alpha \cdot \text{Score}_{\text{graph}} + (1 - \alpha) \cdot \text{Score}_{\text{semantic}} \quad (5.4)$$

其中 α 为权重参数，通过验证集调优确定最优值为 0.65。

5.1.4 知识增强的答案生成

答案生成模块将检索到的知识片段组织为结构化提示词，输入大语言模型生成答案。提示词模板的设计遵循以下原则：明确系统角色、提供足够上下文、要求引用来源、设置安全边界。

代码 5.1 知识增强答案生成提示词模板

```

1  你是一名智能建造知识助手，你的回答基于以下从建造知识图谱中
2  检索到的专业知识。如果知识库中没有足够的信息，请诚实说明。
3
4  【检索到的相关知识】
5  {检索到的结构化知识三元组和文本段落}
6
7  【用户问题】
8  {用户的原始问题}
9
10 请基于上述知识回答用户的问题。要求：
11  1. 回答准确、专业，使用建造行业的规范术语
12  2. 如果涉及规范条文，请注明规范编号
13  3. 如果知识库中的信息不足以完全回答问题，请明确指出
14  4. 对于质量诊断类问题，请列出可能的原因并建议排查方法
15

```

16 | 回答:

5.2 系统设计与实现

5.2.1 系统技术架构

智能建造知识问答系统采用前后端分离的 B/S 架构进行设计。后端采用 Python 语言开发，基于 Flask 框架构建 RESTful API 服务；前端基于 Vue.js 框架构建 Web 交互界面。

系统的技术架构分为四层：

- (1) **数据存储层**：使用 Neo4j 图数据库存储建造知识图谱，使用 Elasticsearch 存储文档索引，使用 Redis 缓存高频查询结果。
- (2) **业务逻辑层**：封装知识图谱查询、RAG 检索、答案生成等核心算法模块。
- (3) **API 接口层**：提供 RESTful 风格的 HTTP 接口，包括问答接口、知识图谱浏览接口、知识检索接口等。
- (4) **展示交互层**：Web 前端页面，支持自然语言问答、知识图谱可视化浏览、历史记录管理等功能。

5.2.2 核心功能模块

系统实现了以下核心功能模块：

- (1) **自然语言问答模块**：用户以自然语言形式输入建造领域相关问题，系统通过 RAG 框架生成有据可查的专业回答。回答中标注了所引用的规范编号和知识来源，支持用户追溯验证。
- (2) **知识图谱可视化模块**：以交互式图谱的方式展示建造知识的关联结构。用户可以通过点击节点展开邻域，浏览实体间的语义关系，实现知识的”探索式”学习。
- (3) **施工规范检索模块**：支持按规范编号、关键词、适用范围等条件检索相关规范条文，并以高亮方式展示匹配的条文内容。
- (4) **质量诊断模块**：针对常见的工程质量问题，基于知识图谱的因果关联进行推理，列出可能的成因和推荐的处置方案。
- (5) **知识反馈模块**：用户可以对系统回答的质量进行评分和反馈，反馈信息纳入知识图谱的质量管理体系，支持知识的持续优化。

系统界面的主要交互流程为：用户在搜索框中输入查询 → 系统进行查询理解 → 在图谱和文档库中检索 → 大语言模型生成答案 → 展示答案及引用来源 → 用户可对答案进行反馈。

5.3 实验评估与分析

5.3.1 实验设置

测试数据集：为评估系统的问答性能，构建了建造领域问答评测数据集。从实际施工场景中收集和编制了 300 条问答对，涵盖五个意图类别（规范查询、工艺查询、质量诊断、材料查询、方案推荐），每类 60 条。每条数据包含一个问题、标准参考答案和相关知识图谱三元组。

对比方法：选取以下方法进行对比实验：

- **LLM-Only：**直接使用大语言模型（GPT-4）回答问题，不提供任何外部知识
- **Doc-RAG：**基于文档检索的 RAG 方法，从文档库中检索相关段落
- **KG-RAG（仅图检索）：**本文的 RAG 框架，但仅使用图结构检索
- **KG-RAG（完整版）：**本文的 RAG 框架完整版，使用混合检索策略

评价指标：

- **答案准确率（3 分制人工评分）：**完全正确 3 分，部分正确 2 分，不正确 1 分
- **答案完整率：**答案覆盖标准答案要点的比例
- **幻觉率：**答案中出现虚构事实或错误引用的比例
- **引用准确率：**引用的知识来源确实支持所生成答案的比例

5.3.2 问答性能分析

各方法在建造领域问答评测数据集上的表现如表5.1所示。

从实验结果可以得出以下分析：

(1) 本文提出的 KG-RAG 完整版在各项指标上均取得了最优结果。相比 LLM-Only 方法，答案准确率从 2.12 提升至 2.76（提升 30.2%），幻觉率从 24.3% 下降至 5.2%（降低 78.6%），充分验证了知识图谱增强对于缓解大模型知识幻觉的有效性。

表 5.1 不同方法的建造问答性能对比

方法	准确率 (/3)	完整率 (%)	幻觉率 (%)	引用准确率 (%)
LLM-Only	2.12	68.5	24.3	—
Doc-RAG	2.45	78.2	12.6	78.4
KG-RAG (仅图检索)	2.58	82.4	8.3	86.7
KG-RAG (完整版)	2.76	88.7	5.2	92.1

(2) KG-RAG 相比 Doc-RAG 在各项指标上均有提升，特别是在引用准确率方面（92.1% vs. 78.4%）。这是因为知识图谱的结构化知识提供了更为精确的溯源能力——每个三元组都有明确的来源和语义关系，而文档块中可能包含冗余或不相关的信息。

(3) 混合检索（图检索 + 语义检索）相比仅使用图检索，在答案完整率上有 6.3 个百分点的提升。分析发现，语义检索能够补充一些图结构检索覆盖不到的知识，特别是当用户查询不直接涉及特定实体而是需要跨领域综合知识时。

5.3.3 不同意图类别的表现分析

表5.2展示了 KG-RAG 完整版在不同查询意图类别上的准确率表现。

表 5.2 不同查询意图类别的准确率 (/3)

意图类别	准确率
规范查询	2.89
工艺查询	2.81
材料查询	2.78
质量诊断	2.65
方案推荐	2.67

规范查询的准确率最高（2.89/3），因为规范条文的知识结构化程度高，知识图谱中的覆盖度好，且检索结果对应关系明确。质量诊断和方案推荐的准确率相对较低，这两类问题通常需要综合多方面知识并进行推理判断，对系统的知识广度和推理深度提出了更高要求。

5.3.4 消融实验

为分析 KG-RAG 框架各组件的作用，进行了消融实验，结果如表5.3所示。

消融实验结果表明：图检索是影响系统性能最大的单个组件，移除后准确率下降 0.24，幻觉率上升 4.2 个百分点，再次验证了结构化知识图谱在领域问答中的重要价值。多跳图遍历和查询意图分类也对系统性能有正向贡献。

表 5.3 消融实验结果

消融项	准确率 (/3)	幻觉率 (%)
KG-RAG 完整版	2.76	5.2
- 查询意图分类	2.68	6.1
- 图检索	2.52	9.4
- 语义检索	2.71	5.8
- 知识图谱增强	2.45	12.6
- 多跳图遍历	2.64	7.3

5.4 应用场景案例分析

为直观展示系统的应用效果，本节给出两个典型的建造问答场景实例。

5.4.1 案例一：施工规范查询

用户问题：”大体积混凝土浇筑的温度控制有什么要求？”

系统回答：”根据 GB 50496-2018《大体积混凝土施工标准》的规定，大体积混凝土浇筑的温度控制应满足以下要求：

- (1) 混凝土入模温度不宜高于 30℃，浇筑体在入模温度基础上的温升值不宜大于 50℃。
- (2) 混凝土浇筑体的里表温差（不含混凝土收缩的当量温度）不宜大于 25℃。
- (3) 混凝土浇筑体的降温速率不宜大于 2.0℃/d。
- (4) 大体积混凝土施工前应进行温控计算，必要时宜进行温控试验。

此外，当预计混凝土浇筑体的里表温差或降温速率可能超过上述限值时，应采取相应的温控措施，主要包括：选用水化热低的水泥、掺加缓凝型减水剂、预冷骨料、通水冷却等。”

知识来源：该回答引用了 GB 50496-2018 的 §3.0.4、§5.1.1、§5.5.1 等相关条文，均可在知识图谱中溯源。

5.4.2 案例二：质量诊断

用户问题：”混凝土构件出现表面蜂窝麻面现象，可能是什么原因造成的？如何处理？”

系统回答：”混凝土构件表面出现蜂窝麻面现象，可能的原因和相应的处理建议如下：

可能原因：(1) 模板接缝不严密，导致漏浆；(2) 混凝土配合比不当，特别是砂率偏低或粗骨料粒径过大；(3) 振捣不充分或过振；(4) 混凝土坍落度过小，流动性不足；(5) 钢筋配筋过密，混凝土难以填充。

处理建议：(1) 对于轻微蜂窝麻面，表面面积不超过构件面积的 0.5% 且深度不超过保护层厚度时，可采用水泥砂浆修补抹面；(2) 对于较严重的蜂窝，应凿除松散部分，用高压水

冲洗干净，然后用比原强度等级高一级的细石混凝土进行修补；(3) 从根本上改善施工工艺：确保模板接缝严密、优化配合比设计、严格控制振捣质量。

请在实际处理前，由项目技术负责人确认缺陷等级和处理方案。”

5.5 本章小结

本章系统阐述了知识图谱与大语言模型协同的智能建造问答系统。首先，设计了检索增强生成框架的整体架构，包含查询理解、知识检索和答案生成三个核心模块。其次，提出了“图检索 + 语义检索”的混合检索策略，充分利用了知识图谱的结构化优势。然后，介绍了系统的技术架构和核心功能实现。最后，通过全面的实验评估验证了系统的有效性：KG-RAG 完整版在准确率（2.76/3）、完整率（88.7%）和幻觉率（5.2%）等指标上均显著优于对比方法。

第六章 总结与展望

6.1 本文工作总结

智能建造是建筑业数字化转型的核心方向，知识图谱与大语言模型作为人工智能领域的代表性技术，为解决建造领域的知识管理和智能服务问题提供了新的技术路径。本文围绕“知识图谱和大语言模型助力智能建造”这一主题，系统地开展了知识图谱构建、大语言模型增强、知识与模型协同的智能问答等方面的研究工作。本文的主要工作总结如下：

(1) **面向智能建造的知识图谱构建**。针对建造领域数据来源广泛、知识分散的特点，设计了自顶向下与自底向上相结合的知识图谱构建框架。在模式层，定义了包含六大概念类别和 13 种语义关系的建造领域本体模型，系统刻画了建造知识的语义结构。在实例层，提出了基于预训练模型的实体关系联合抽取方法，并结合领域词典增强和文本特征融合等优化策略，在建造领域实体识别和关系抽取任务上分别取得了 89.03% 和 81.59% 的 F1 值。最终构建了包含 156,832 个实体、423,567 条三元组、覆盖 42 项国家标准的建造领域知识图谱。

(2) **基于大语言模型的知识图谱增强**。研究了利用大语言模型增强知识图谱的多种途径。提出了基于提示模板的少样本命名实体识别方法和基于思维链的关系抽取方法，在仅 10 个标注示例的情况下分别达到了 79.56% 和 76.89% 的 F1 值，有效降低了知识抽取对大规模标注数据的依赖。利用大语言模型实现了知识图谱的质量校验（准确率 87.6%）和自动补全（三元组数量增长 18.7%）。设计了监督学习与大语言模型方法的协同工作流程，实现了建造知识图谱的高效构建和持续优化。

(3) **知识图谱与大语言模型协同的智能问答**。设计了检索增强生成框架，通过“图检索 + 语义检索”的混合检索策略，将知识图谱的结构化知识精准地提供给大语言模型，显著缓解了知识幻觉问题。实验结果表明，本文的 KG-RAG 方法在准确率、完整率和幻觉率方面均显著优于纯大语言模型方法和文档级 RAG 方法，幻觉率从 24.3% 降低至 5.2%。设计并实现了智能建造知识问答原型系统，支持施工规范查询、质量诊断、方案推荐等多种应用场景。

(4) **系统实现与验证**。基于上述方法，设计并开发了面向智能建造的知识管理与问答系统原型。系统采用 B/S 架构，支持自然语言问答、知识图谱可视化浏览、规范检索等功能。在实际建造项目数据集上进行了全面的实验评估，验证了所提方法的有效性和实用性。

6.2 未来研究方向

本文的研究工作虽然取得了一定的成果，但仍存在一些不足，未来的研究工作可以从以下几个方面开展：

(1) **多模态建造知识图谱的构建**。本文构建的知识图谱主要基于文本数据源。然而，建造领域大量使用图纸、照片、视频等视觉信息载体，如施工图纸、现场照片、监控视频等。将计算机视觉技术与知识图谱技术结合，构建融合文本和视觉信息的多模态建造知识图谱，将极大地丰富知识的表达维度和应用场景。例如，可以通过图像识别自动从施工照片中识别出使用的材料、设备和施工工艺，自动与知识图谱关联。

(2) **时序知识图谱与建造过程建模**。建造活动具有强烈的时序特性，施工工序之间存在严格的时间依赖关系，材料和结构的状态随时间发生变化。本文的知识图谱主要关注静态的语义关系，对时间维度的建模不足。引入时序知识图谱技术，构建能够反映建造过程中实体状态变化和事件演化规律的四维知识图谱，是一个值得深入探索的方向。

(3) **知识图谱驱动的自主决策与规划**。本文现有的系统主要面向知识查询和辅助诊断等知识服务场景。进一步的研究可以将知识图谱与强化学习、运筹优化等技术结合，实现知识图谱驱动的施工方案自动规划、资源优化调度等自主决策功能，从“知识辅助人”向“知识驱动系统”迈进。

(4) **大语言模型的安全性与可控性保障**。大语言模型虽然在知识问答中展现了强大的能力，但其生成内容的不可控性仍然是实际应用中需要重点关注的问题。在建造领域，错误的知识可能导致严重的工程质量问题甚至安全事故。未来需要研究更严格的生成控制机制，如基于规则的生成约束、可验证的知识引证等，确保系统输出的安全性和可靠性。

(5) **跨项目知识迁移与泛化**。不同建筑项目之间既有共性知识（如通用规范要求），也有项目特有的差异性知识（如特定地质条件下的施工方案）。研究如何从多个项目的知识图谱中提取共性规律，实现知识的跨项目迁移和泛化，提高知识图谱在不同类型、不同规模项目中的复用性，是推动技术规模化应用的关键。

(6) **与数字孪生的深度融合**。将建造知识图谱与数字孪生技术相结合，构建知识驱动的建筑数字孪生体，实现虚实映射场景下的智能诊断、预测和决策支持。知识图谱可以为数字孪生提供语义化的知识底座，而数字孪生可以为知识图谱提供实时的数据反馈和更新机制，二者的深度融合将为智能建造开辟更广阔的发展空间。

参考文献

- [1] 李健东, 郭梯云, 邬国扬. 移动通信[M]. 第四版. 西安: 西安电子科技大学出版社, 2007.
- [2] Sanguinetti L, Björnson E, Hoydis J. Toward Massive MIMO 2.0: Understanding Spatial Correlation, Interference Suppression, and Pilot Contamination[J]. IEEE Transactions on Communications, 2020, 68(1): 232–257.
- [3] Larsson E G, Edfors O, Tufvesson F, et al. Massive MIMO for next generation wireless systems[J]. IEEE Communications Magazine, 2014, 52(2): 186–195.
- [4] Hoydis J, ten Brink S, Debbah M. Massive MIMO in the UL/DL of Cellular Networks: How Many Antennas Do We Need?[J]. IEEE Journal on Selected Areas in Communications, 2013, 31(2): 160–171.
- [5] Marzetta T L. Noncooperative Cellular wireless with Unlimited Numbers of Base Station Antennas[J]. IEEE Transactions on Wireless Communications, 2010, 9(11): 3590–3600.
- [6] Venkatesan S, Lozano A, Valenzuela R. Network MIMO: Overcoming Intercell Interference in Indoor Wireless Systems[C]. Proceedings of the Asilomar Conference on Signals, Systems and Computers (ACSSC). 2007: 83–87.

附录 A 程序清单

第三章知识图谱构建系统程序 (KGConstruction 文件夹)

main_entity_extraction.py: 建造领域实体识别主程序

main_relation_extraction.py: 实体关系联合抽取主程序

data_preprocessor.py: 建造文本数据预处理模块

domain_dict_builder.py: 建造领域自定义词典构建工具

knowledge_fusion.py: 多源知识对齐与融合模块

neo4j_storage.py: Neo4j 图数据库存储接口模块

第四章大语言模型增强系统程序 (LLMEnhance 文件夹)

fewshot_ner.py: 基于提示模板的少样本 NER 程序

cot_relation_extraction.py: 基于思维链的关系抽取程序

kg_quality_check.py: 知识图谱质量校验程序

kg_completion.py: 知识图谱混合补全程序

prompt_templates.py: 提示词模板管理模块

llm_api_client.py: 大语言模型 API 调用接口模块

第五章智能建造问答系统程序 (ConstructQA 文件夹)

app.py: Flask Web 服务主程序

query_understanding.py: 查询理解与意图分类模块

graph_retriever.py: 知识图谱图结构检索模块

semantic_retriever.py: 语义相似度检索模块

answer_generator.py: 基于 RAG 的答案生成模块

knowledge_visualizer.py: 知识图谱前端可视化组件

frontend/: Vue.js 前端界面工程目录

附录 B 攻读专业学位硕士期间撰写的论文

- [1] 王硕, 张三, 李四, et al. 面向智能建造的领域知识图谱构建方法研究 [J]. 计算机学报, 2025, 48(3): 567-582. (EI: 0000000000000001)
- [2] 王硕, 张三. 基于检索增强生成的建造领域智能问答系统 [J]. 软件学报, 2025, 36(8): 2345-2360. (EI: 0000000000000002)
- [3] Zhang San, **Shuo Wang**, Li Si. Knowledge Graph Enhanced Large Language Model for Construction Quality Diagnosis[C]. Proceedings of the International Conference on Artificial Intelligence in Construction, 2025: 123-130. (EI: 0000000000000003)
- [4] 王硕, 李四. 基于大语言模型的少样本建造实体识别研究 [J]. 南京邮电大学学报 (自然科学版), 2025, 45(2): 89-96.
- [5] 王硕, 张三, 王五. 知识图谱与大语言模型协同的智能建造知识服务系统 [J]. 计算机应用, 2024, 44(12): 3789-3796.

附录 C 攻读专业学位硕士期间申请的专利

- [1] 王硕, 张三. 一种面向智能建造的知识图谱构建方法及系统, 202510000001.5, 2025.1.10, 2025.6.20;
- [2] 王硕, 李四, 张三. 一种知识图谱与大语言模型协同的建造问答方法及装置, 202510000002.3, 2025.2.15, 2025.8.10;
- [3] 张三, 王硕. 一种基于多模态数据融合的建筑工程质量评估系统, 202510000003.1, 2025.3.20;

附录 D 攻读专业学位硕士期间参加的科研项目

- [1] 国家自然科学基金面上项目，面向智能建造的领域知识图谱构建与推理关键技术研究 (620700000001)；
- [2] 江苏省重点研发计划项目，知识驱动的大语言模型智能建造应用研究 (BE20250001)；
- [3] 校企合作项目，建筑集团智能建造知识管理平台研发 (2024WY0001)。