

RGB-T 目标检测综述：复杂山地环境 RGB-T 双流融合行人检测

吴继涛 1025040809

计算机科学与技术 遥感图像目标检测

摘要 针对复杂山地环境下光照剧变、遮挡及背景杂乱导致单模态检测失效的问题，RGB-T 多模态技术成为热点。本文首先综述了 RGB-T 检测研究背景，归纳了早、中、晚期融合架构，并重点探讨了基于注意力机制的特征融合方法。其次，构建了以 Swin Transformer 为骨干、Cascade R-CNN 为检测头的双流特征融合网络，在 ODinMJ 山地数据集上进行了实验。结果表明，引入通道与空间注意力机制的融合策略，在 mAP 指标上显著优于单模态及早期融合基准，有效解决了特征对齐与噪声抑制问题。最后，本文总结了领域挑战并展望了未来的轻量化与实时性研究。

关键词 RGB-T 目标检测；双流网络；特征融合；注意力机制；山地环境

RGB-T Object Detection Survey: RGB-T Dual-Stream Fusion Pedestrian Detection in Complex Mountainous Environments

Jitao Wu

(School of Computer Science, Nanjing University of Posts and Telecommunications, Jiangsu Nanjing 210003)

Abstract To address the failure of single-modal detection caused by drastic illumination changes, occlusions, and cluttered backgrounds in complex mountainous environments, RGB-T multimodal technology has emerged as a research hotspot. First, this paper reviews the research background of RGB-T detection, summarizes the early-, middle-, and late-fusion architectures, and focuses on discussing attention mechanism-based feature fusion methods. Second, a dual-stream feature fusion network with Swin Transformer as the backbone and Cascade R-CNN as the detection head is constructed, and experiments are conducted on the ODinMJ mountain dataset. The results show that the fusion strategy incorporating channel and spatial attention mechanisms significantly outperforms single-modal and early-fusion baselines in terms of mAP, effectively resolving the issues of feature alignment and noise suppression. Finally, this paper summarizes the challenges in the field and prospects future research on lightweight and real-time performance.

Key words RGB-T Object Detection; Dual-Stream Network; Feature Fusion; Attention Mechanism; Mountainous Environment

1 引言

1.1 研究背景与意义

近年来，随着深度学习技术的迅猛发展，计算机视觉领域中的通用目标检测算法取得了突破性进展。以 YOLO 系列和 R-CNN 系列为代表的检

测模型，在 COCO、PASCAL VOC 等标准数据集上已展现出极高的检测精度与实时性。然而，这些成就多集中于结构化程度较高的城市道路、室内场景或受控环境。当应用场景转移至非结构化环境，特别是地形复杂、植被茂密且光照条件多变的山地与丛林环境时，现有的单一模态视觉感知系统往往面临着严峻的物理局限与性能瓶颈^[1]。

在野外山地丛林场景中，行人检测面临着极高

的挑战性。传统的可见光（RGB）传感器依赖于物体对外部光线的反射成像，具有纹理清晰、色彩丰富的优势。但在低照度条件下（如夜间、黎明或黄昏），RGB 图像的信噪比急剧下降，目标特征难以提取。更为严峻的是，在丛林作战或搜救场景中，行人往往被树木、灌木严重遮挡，或者身着迷彩服与背景环境高度融合（即伪装目标），此时仅凭 RGB 图像的颜色和纹理特征，几乎无法将目标从复杂的背景中分离出来^[2]。

为了克服可见光传感器的局限性，热红外（TIR）成像技术被引入目标检测领域。TIR 传感器通过捕捉物体发出的热辐射成像，不依赖外部光源，因此具备全天候工作的能力，且能轻易穿透烟雾和部分稀疏植被，发现隐藏的热源目标^[3]。然而，热红外图像也存在显著的固有缺陷：其缺乏颜色信息，纹理细节贫乏，边缘模糊。特别是在白天或特定气象条件下，当环境温度（如受日照加热的岩石或地面）接近人体体温时，会出现“热交叉”现象，导致目标的热特征淹没在背景热噪声中，使得检测器难以区分前景与背景^[4]。

综上所述，单一模态传感器在复杂山地环境下均存在难以克服的盲区。可见光与热红外图像在信息表征上具有天然的互补性：RGB 提供细节纹理，TIR 提供热辐射分布。因此，研究 RGB-T（可见光-热红外）多模态融合目标检测技术，通过算法有效地整合两者的互补信息，对于提升全天候、全时段的感知能力具有重要的理论意义与应用价值^[5]。该技术在野外搜救、边境智能巡逻、无人系统环境感知以及军事侦察等领域具有广泛且迫切的落地需求。

1.2 现有方法分类概述

可见光-红外图像融合助力目标检测，其核心在于将融合模块嵌入深度学习检测框架中，通过双模态信息的充分交互来提升检测的精度与鲁棒性^[6]。随着技术的发展，该方法已成为突破复杂环境感知瓶颈的关键途径。基于深度学习的双模态融合检测，根据融合过程与检测任务的耦合关系，主要可分为生成融合图像的检测和不生成融合图像的检测着两类。

生成融合图像的检测方法采用“先融合，后检测”的级联策略，即先利用融合算法生成高质量的融合图像，再将其输入下游网络进行目标检测。然而，早期的图像融合算法多侧重于提升符合人眼视觉感知的图像质量，往往难以提取出适配计算机视

觉算法的高级语义特征^[7]。为此，研究者开始尝试将下游任务的需求反向融入融合过程。例如，Shopovska 等人^[8]在损失函数中引入了行人检测的辅助误差项，以引导网络学习与检测任务更为相关的特征；Liu 等人^[9]则进一步将融合与检测构建为双层优化模型（Bi-level Optimization），采用联合训练策略同步优化融合网络与检测网络，实现了图像质量与检测精度的双优效果。

不生成融合图像的检测方法以检测精度为核心目标，摒弃了中间生成融合图像的步骤，直接输出检测结果。这种端到端的模式避免了图像生成过程中的信息冗余与计算浪费。例如，Hou 等人^[10]基于 YOLOv7 架构设计了双支路网络，利用可见光与红外多尺度特征融合模块，分别提取两个模态的深层特征。此外，该研究提出了一种新型跨模态特征融合模块，通过在模态内部进行特征交互来减少模态间的冗余信息，从而显著提高了目标检测的精度。

当前，主流的多模态融合检测研究均倾向于第二类方法，即基于特征融合而非依赖融合图像生成。这种方式更侧重于提取高级语义特征以实现双模态信息的高效交互，大量实验已证明其性能普遍优于生成融合图像的检测方法。从融合发生的阶段来看，现有的 RGB-T 目标检测方法主要可以归纳为像素级融合、决策级融合以及特征级融合三个发展阶段。

像素级融合直接在输入端整合数据，常受限于模态间的异构分布差异；决策级融合独立处理各模态后结合结果，虽保留了独立性但缺乏深层交互且计算成本较高。相比之下，特征级融合通过双流骨干网络在特征空间进行深度交互与互补，能够自适应地整合多模态信息，被证明是在检测精度与推理速度之间取得最佳平衡的主流方案^[11]。鉴于此，本文将重点聚焦于特征级融合策略，旨在结合 Swin Transformer 的强大表征能力与注意力机制设计高效融合网络，以解决复杂山地环境下的行人检测难题^[12]。

2 RGB-T 目标检测方法综述

多模态图像融合的核心在于有效整合不同传感器的互补优势，构建出比单一数据源更具判别力与鲁棒性的特征表征。在 RGB-T 目标检测领域，依据模态交互发生的层级深度，现有的深度学习架

构主要分为像素级早期融合、决策级晚期融合以及特征级中期融合三大类。本章将系统梳理上述三类方法的技术演进脉络，深入剖析其核心机制与优劣势。在此基础上，重点探讨结合注意力机制的中期特征融合策略，并对 YOLO 系列与 R-CNN 系列等主流检测框架在多模态场景下的典型应用与改进进行综述。

2.1 早期融合

早期融合亦称为像素级融合或输入端融合，是多模态目标检测发展初期最直观且实现门槛最低的策略。其核心原理是在数据输入神经网络之前，即在原始数据层面完成多模态信息的物理整合。在具体实现上如图 1，该方法通常先对可见光图像（RGB，3 通道）与热红外图像（TIR，1 通道）进行严格的空间配准，随后直接在通道维度上进行拼接，构建成一个 4 通道的输入张量；或者利用特定的图像处理算法将红外信息映射至 RGB 色彩空间，合成新的 3 通道融合图像。随后，这些处理后的数据被送入单一的骨干网络（如 ResNet、VGG 等）进行常规的特征提取与检测任务。




图 1 早期融合目标检测框架

这种融合方式的最大优势在于能够最大限度地保留原始图像的纹理与细节信息。然而，其局限性也十分显著：由于融合发生于网络的浅层输入端，模型难以在像素级有效整合异构模态的高级语义信息，导致难以提取出适配复杂场景的鲁棒特征^[13]。Wagner 等人^[14]最早尝试了基于深度卷积神经网络的 RGB-T 早期融合检测，采取直接在通道维度拼接源图像的方式进行训练。然而，实验结果表明该方法并未带来显著的性能提升，主要原因在于异构数据直接叠加会导致分布差异难以调和，且网络缺乏在深层特征空间对模态互补关系的挖掘能力。尽管如此，针对特定应用场景（如伪装目标检测），仍有学者致力于改进像素级融合架构。例如，Peng 等人^[15]近期提出了一种基于像素级输入的伪装目标检测框架，通过优化输入端的模态交互策略，在一定程度上缓解了传统早期融合的局面

性。

2.2 晚期融合

晚期融合也被界定为决策级融合，其核心架构基于“独立并行处理，后端综合决策”的范式。与试图在数据层混合模态的早期融合不同，图 2 晚期融合策略主张构建两个完全解耦的检测网络分支，分别负责可见光与热红外图像的特征提取、候选框生成及分类回归。在推理阶段，系统将两个独立分支输出的检测结果（即边界框坐标、类别概率及置信度得分）汇入决策模块，通过特定的融合算法生成最终预测。除了传统的非极大值抑制（NMS）及其变体外，加权框融合策略因其能有效利用冗余预测框的统计信息，近年来被广泛应用^[16]。此外，最新的研究开始探索基于概率分布的融合方法，如 Solawetz 等人^[17]提出的概率集成策略，通过建模模态不确定性来进一步提升决策阶段的可靠性。




图 2 晚期融合目标检测框架

Liu 等人^[18]在早期的多光谱检测研究中奠定了这一方法的理论基础，指出在模态间统计分布差异极大的场景下，保持决策独立性往往能获得比强制混合更优的效果。这种高度解耦的特性赋予了系统极强的容错能力：两个模态网络互不依赖，各自学习特有的特征表达。即便在极端环境（如全黑夜间导致 RGB 分支完全失效）下，系统仍可凭借 TIR 分支的输出维持基本的检测功能，从而保证了感知的鲁棒性^[19]。

然而，这种“分而治之”的策略在实际部署中面临着严峻的效能瓶颈，限制了其在高性能场景下的应用。首先，在计算资源方面，并行运行两个完整的深度神经网络使得计算量与显存占用几乎翻倍，严重制约了其在无人机、便携式搜救设备等对实时性与功耗敏感平台上的部署^[20]。其次，从信息交互的角度看，晚期融合错失了深层语义融合的黄金窗口。由于两路网络在特征提取阶段处于“信息孤岛”状态，系统无法利用模态间的互补性来增强对弱目标的表征。最为典型的弊端在于“阈值截断”效应：当 RGB 和 TIR 分别检测到的目标置信度均略低于判定阈值（例如受严重遮挡时的弱目标），在决策级融合中，这两个结果极易被视为背

景噪声而直接滤除；反之，若能在特征层进行交互增强，这两股微弱的特征流本有望叠加形成显著的激活响应，从而避免漏检。

2.3 中期特征融合

鉴于早期融合存在的模态异构冲突以及晚期融合的特征隔离问题，中期特征融合已逐渐成为当前学术界与工业界的主流选择。图3的该策略采用双流架构（Dual-Stream Architecture），即部署两个共享或独立的骨干网络分别提取 RGB 和 TIR 的特征，并在网络的中间层级设置特定的融合模块，实现模态间的信息交互。这种方式既在浅层保留了各模态独特的统计分布特征，又在深层实现了语义信息的互补，被公认为是平衡检测精度与推理效率的最佳方案^[21]。




图3 中期特征融合目标检测框架

在双流架构的基础上，特征融合策略经历了从简单的线性叠加到智能交互的演变。早期的基础操作多在骨干网络的特定阶段（如 ResNet 的 Layer 3 或 Layer 4）对特征图进行元素级相加或通道拼接，这种静态融合缺乏对特征重要性的判别能力。为解决这一问题，研究者引入了光照感知与门控机制。例如，最新的研究开始利用辅助子网络评估环境光照强度，动态生成模态权重，从而自适应地调整 RGB 和 TIR 的融合比例，确保模型在白天充分利用纹理信息，而在夜间则侧重于热辐射特征，实现了全天候场景下的鲁棒检测^[22]。随着注意力机制的深耕，交互式融合成为当前的研究热点。不同于早期的简单拼接，现代方法如 Liu 等人提出的 CSCA-Net 引入了循环分割跨模态注意力机制，通过计算不同模态间的空间与通道相关性矩阵，利用某一模态的显著特征去校准和增强另一模态的特征表示，有效缓解了背景杂波和弱对齐带来的干扰^[23]。

近年来，基于 Transformer 的融合方法进一步推高了性能上限。Qing 等人提出的 CFT 方法创新性地利用 Cross-Attention 机制，将一个模态作为 Query，另一个模态作为 Key 和 Value，在全局范围内捕捉多模态特征的长距离依赖关系^[24]。这种基于 Transformer 的深度融合策略，使得网络能够

“智能”地感知环境上下文，在复杂的山地丛林背景中，自动聚焦于含有行人热特征或纹理特征的显著区域，显著抑制了误检与漏检^[25]。

2.4 典型算法介绍

在确立了多模态特征融合的骨干架构后，检测头的设计直接决定了最终的性能表现。当前，目标检测领域主要分化为两大技术路线：以 YOLO 系列为代表的单阶段（One-stage）算法和以 R-CNN 系列为代表的二阶段（Two-stage）算法。

YOLO 系列算法凭借其高效的推理速度在工业界得到了广泛应用。在 RGB-T 检测任务中，改进版的 YOLOv5 或 YOLOv8 通常采用 CSPNet 作为骨干，并通过改进 PANet 或 FPN 结构来接入多模态特征^[26]。YOLO 系列将目标定位与分类建模为单一的回归问题，实现了端到端的快速推理，极为适合无人机巡逻、移动终端等对实时性要求严苛的场景。然而，其局限性在于对密集小目标的捕捉能力较弱。特别是在复杂的山地丛林环境中，当行人目标极小或被植被严重遮挡时，单阶段算法往往难以在一次回归中精准定位，导致漏检率上升^[27]。

相比之下，以 Cascade R-CNN 为代表的二阶段算法则侧重于极致的检测精度，是追求高性能感知的首选方案。Cascade R-CNN 通过级联多个 IoU 阈值不断提高的检测头，对候选框进行多阶段的精细回归与分类^[28]。在第一阶段，网络能有效过滤掉大量简单的背景负样本；随后的阶段则专注于对“难例样本”进行微调。在野外环境中，行人姿态多变且常与背景热源混淆，这种由粗到精的级联机制能够显著减少误检，并生成贴合度极高的边界框。近期研究表明，将 Cascade R-CNN 与 Swin Transformer 等强特征提取骨干相结合，并辅以双流融合策略，能够有效克服野外复杂背景的干扰，在多项 RGB-T 行人检测基准测试中刷新了最高精度记录（SOTA）^{[29][30]}。鉴于此，本文实验最终选择该架构作为核心基准，以应对山地环境下的严峻挑战。

3 实验结果与分析

本章将对实验环境、数据集构建、评价指标体系及具体的训练策略进行详细阐述。在此基础上，通过定量的对比实验与定性的可视化分析，全面评估本文提出的基于 Swin Transformer 的双流特征

融合网络在复杂山地环境下的检测性能。

3.1 数据集处理与评估指标

为了系统验证多模态融合算法在非结构化野外环境下的有效性,本文选用 ODinMJ 数据集作为实验基准。该数据集包含约 23,000 对经过严格空间配准的可见光 (RGB) 与热红外 (TIR) 图像,其场景覆盖了从正午强光到全黑夜间的光照剧烈变化,以及由茂密植被导致的严重遮挡和背景杂波干扰,是极具挑战性的山地丛林行人检测基准。

针对原始数据集采用 YOLO 标注格式 (.txt) 与主流检测框架不兼容的问题,本文编写了自动化转换脚本,将原始标注无损映射为通用的 COCO 格式,以适配 MMDetection 训练框架。此外,考虑到数据集规模较大,为平衡实验效率与数据分布的一致性,本文采用分层随机采样策略,按 1/4 的比例从原始训练集中抽取样本构建 Mini-Train 子集。该子集保留了原始数据的场景多样性,主要用于快速验证不同融合架构的收敛特性及消融实验的性能差异,从而高效地指导模型超参数的优化。

在评价指标方面,本文严格遵循 COCO 目标检测评测标准。主要指标包括平均精度均值 (mAP),即在 IoU 阈值从 0.5 到 0.95 步长为 0.05 的区间内计算出的平均精度,这是衡量模型综合检测性能的核心指标。此外,本文还选取了 mAP50 以评估模型的检出率,选取 mAP75 以评估高精度定位能力,并特别关注 mAP_s,以衡量模型在远距离山地搜救场景下的实用价值。

3.2 实验环境与实施细节

实验的硬件平台基于高性能计算服务器,配备 NVIDIA RTX 3090 图形处理器。软件环境基于 Ubuntu 操作系统、PyTorch 深度学习框架及 MMDetection v3.x 工具箱。在训练策略上,选用 AdamW 优化器以获得更快的收敛速度和更优的泛化性能,初始学习率设定为 0.0001,权重衰减系数为 0.05。为了充分利用显存并加速训练过程,实验开启了自动混合精度训练 (AMP),将训练轮数设定为 20 Epochs。在数据增强方面,采用了随机翻转以及多尺度训练策略,图像短边尺寸在一定范围内随机采样,以增强模型对不同尺度目标的适应能力,防止过拟合。

3.3 实验结果与分析

为了全面评估双流特征融合网络的性能,本文设计了多组对比实验。基准模型 (Baseline) 分别

采用了仅输入 RGB 图像和仅输入 TIR 图像的单模态网络,以及在输入端直接拼接四通道数据的早期融合网络。所有模型均采用相同的 Swin Transformer Tiny 骨干网络与 Cascade R-CNN 检测头,以确保对比的公平性。由于时间和计算量限制,大部分实验的训练轮数在 5 轮左右就停止了,具体的定量实验结果如表 1 所示。

表 1 不同融合策略在 ODinMJ 数据集上的性能对比

模型	mAP	mAP50	mAP75	mAP_s
Baseline1(RGB)	0.236	0.510	0.123	0.188
Baseline1(TIR)	0.576	0.853	0.647	0.420
早期融合	0.563	0.886	0.627	0.425
本文双流融合	0.589	0.906	0.661	0.460

表 1 的定量实验结果直观地揭示了不同模态利用方式对检测性能的显著影响。首先,从整体检测精度 (mAP) 来看,本文提出的双流特征融合网络取得了 0.589 的最优成绩, mAP50 更是高达 0.906,全面超越了单模态基准及早期融合模型。对比单模态基准可以发现,仅使用 RGB 图像的模型性能最差 (mAP 为 0.236),而仅使用 TIR 图像的模型达到了 0.576,这表明在 ODinMJ 数据集涵盖的山地丛林场景中,热红外信息对于发现伪装目标起到了主导作用,而可见光信息受限于光照剧变和植被遮挡,独立检测能力有限。值得特别关注的是,采用像素级拼接的早期融合模型 mAP 仅为 0.563,反而低于单模态 TIR 基准的 0.576。这一“负迁移”现象揭示了简单像素混合的弊端:直接引入包含大量背景噪声的 RGB 像素破坏了原本清晰的红外热特征分布,导致了模态间的相互干扰。相比之下,本文方法通过双流架构在特征空间进行深度交互,成功扭转了这一劣势,在单模态 TIR 的强基准上进一步提升了 1.3%,证明了特征级融合在处理异构数据冲突时的优越性。

进一步深入分析细分指标,可以发现本文的融合机制在高精度定位与小目标检测任务上带来了质的飞跃。在衡量高定位精度的 mAP75 指标上,本文方法达到了 0.661,相较于早期融合的 0.627 实现了 3.4% 的显著提升。这一数据表明,双流融合并非简单地叠加信息,而是利用交叉注意力机制实现了特征互补:RGB 图像丰富的边界纹理有效地校准了 TIR 图像因分辨率不足产生的轮廓溢

出,从而使得检测框的回归更加精准。在极具挑战性的小目标检测(mAP_s)方面,得益于空间注意力机制对背景杂波的抑制作用,本文模型达到了0.460的精度,显著优于早期融合(0.425)和单模态TIR(0.420)。这一3.5%至4.0%的提升幅度对于野外搜救具有重要意义,意味着模型能够更敏锐地捕捉到远距离或被严重遮挡的微弱行人目标,有效降低了漏检率。

4 结论与展望

4.1 总结

本文针对野外复杂山地丛林环境下行人目标检测面临的光照剧烈变化、背景杂波干扰以及多尺度目标难以识别等核心难点,系统地研究了可见光(RGB)与热红外(TIR)多模态融合技术。通过深入剖析现有融合策略的物理局限性,本文采用了一种基于Swin Transformer的双流特征融合目标检测网络,并设计了交叉模态注意力融合模块,实现了异构数据在深层特征空间的有效交互。

首先,在网络架构设计上,本文摒弃了传统的单流早期融合方案,构建了参数独立的双流骨干网络。利用Swin Transformer的层级化结构和移位窗口机制,网络能够有效地提取出具有长距离依赖关系的全局语义特征,克服了传统CNN在处理山地非结构化背景时的感受野局限^[31]。其次,针对RGB与TIR模态在不同环境下的互补特性,本文采用交叉模态注意力融合模块集成了通道注意力与空间注意力机制。通道注意力通过感知全局信息,自适应地调整RGB纹理特征与TIR热源特征的权重分配,有效解决了“全黑夜间”或“热交叉”场景下的模态选择难题;空间注意力则通过跨模态的特征共鸣,有效抑制了岩石、树木等背景噪声,显著增强了人体目标的显著性。基于ODinMJ山地丛林数据集的广泛实验结果有力地证明了所提方法的有效性。定量分析显示,双流特征融合网络在mAP、mAP50以及mAP75等关键指标上均全面优于单模态基准模型及像素级早期融合模型。特别是在极具挑战性的小目标检测任务中,得益于多尺度特征的深度交互,模型的召回率获得了显著提升。

综上所述,本文的研究工作不仅在理论上研究了Transformer架构下多模态特征融合的方法,也在实践中为山地搜救、边境巡逻等特定场景下的智

能感知系统提供了一种高精度的技术解决方案。

4.2 存在的不足与展望

尽管本文采用的双流特征融合网络在检测精度上成果不错,但在该领域的深入研究过程中,仍发现存在一些局限性与待解决的问题。针对这些不足,未来的研究工作将主要围绕以下三个维度展开:

第一,算法的计算成本与实时性优化。本文采用的双流骨干网络架构虽然显著提升了特征提取的丰富度,但也无可避免地导致了模型参数数量和显存占用的翻倍。特别是Swin Transformer和Cascade R-CNN本身均属于计算密集型结构,这使得当前模型在推理速度上较慢,难以直接部署于无人机或手持终端等对算力及功耗敏感的边缘设备上。未来的研究将致力于模型的轻量化设计,例如探索使用MobileNet、ShuffleNet或更高效的轻量级Transformer作为骨干网络;或者采用知识蒸馏技术,将双流大模型的知识迁移至单流小模型中,在保持精度的同时大幅降低计算复杂度,以满足野外实时作业的需求^[32]。

第二,多模态数据的时空对齐问题。本文的实验假设RGB与TIR图像是经过严格空间配准的。然而,在实际的物理采集系统中,由于传感器安装位置的视差、不同波段镜头的畸变差异以及采集过程中的机械抖动,图像之间往往存在非刚性的微小位移。直接对未严格对齐的特征进行元素级融合,可能会引入特征模糊甚至产生伪影,进而影响检测性能^[33]。为了解决这一问题,未来的工作可以引入空间变换网络或可变形卷积。通过在融合模块前加入可学习的偏移量预测分支,使网络能够自动校准不同模态特征图的空间位置,从而实现对非严格对齐数据的自适应特征融合。

第三,全天候环境下的泛化能力提升。目前的实验主要基于ODinMJ数据集,该数据集虽然涵盖了多种光照条件,但对于极端恶劣天气(如暴雨、浓雾、暴雪)样本的覆盖可能仍显不足。在雨雾天气中,热红外成像会受到大气衰减的影响导致对比度降低,而可见光图像则会变得模糊不清^[34]。未来的研究应进一步探索模型在极端气象条件下的鲁棒性,一方面可以通过生成对抗网络(GAN)合成极端天气下的多模态训练数据以增强模型的泛化能力;另一方面,可以研究基于域自适应的算法,使模型能够快速适应不同气候域下的特征分布,真正实现全天候、无盲区的智能感知^[35]。

参考文献

- [1] Zhang Q, Zhao N, Huang Y, et al. Photon counting-based detecting and ranging for targets hidden in foliage[J]. *Optics and Lasers in Engineering*, 2023, 161: 107337.
- [2] Liu W, Zhang K, Zhang Z, et al. Cycled-split cross-attention for RGB-T object detection[J]. *IEEE Transactions on Image Processing*, 2022, 31: 4463-4476.
- [3] Yan Ye, Li Na, Zhao Yong-Qiang, et al. RGBT salient object detection based on multi-interaction logic network. *Journal of Image and Graphics*, 2023, 28(5): 1403-1416 (in Chinese)
(颜业, 李娜, 赵永强, 等. 多交互逻辑网络的 RGBT 显著性目标检测. *中国图象图形学报*, 2023, 28(5): 1403-1416)
- [4] Kim T, Kim H, Kim S. Unsupervised day-to-night transfer for RGB-T semantic segmentation with thermal crossover handling[J]. *IEEE Robotics and Automation Letters*, 2023, 8(4): 2305-2312.
- [5] Tang Lin-Bo, Zhao Qi, Zhang Jian, et al. Review of multispectral pedestrian detection. *Journal of Remote Sensing*, 2023, 27(6): 1344-1363 (in Chinese)
(唐林波, 赵启, 张健, 等. 多光谱行人检测技术综述. *遥感学报*, 2023, 27(6): 1344-1363)
- [6] Wang Yuan-Zhe, Liang Teng-Fei, Zeng Yu-Qiao, et al. Overview of multispectral target detection. *Information and Control*, 2024, 53(3): 287-301 (in Chinese)
(王元喆, 梁腾飞, 曾宇乔, 等. 多光谱目标检测综述. *信息与控制*, 2024, 53(3): 287-301)
- [7] Zhang X, Demiris Y. Visible and infrared image fusion using deep learning[J]. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, 2023, 45(8): 10535-10554.
- [8] Shopovska I, Jovanov L, Philips W. Deep visible and thermal image fusion for enhanced pedestrian visibility[J]. *Sensors*, 2019, 19(17): 3727.
- [9] Liu J Y, Fan X, Huang Z B, et al. Target-aware dual adversarial learning and a multi-scenario multi-modality benchmark to fuse infrared and visible for object detection//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New Orleans, USA, 2022: 5792-5801.
- [10] Hou Z Q, Li X Y, Yang C, et al. Dual-branch network object detection algorithm based on dual-modality fusion of visible and infrared images[J]. *Multimedia Systems*, 2024, 30(6): 333.
- [11] Ma Yi-De, Liu Yang, Wang Xiao, et al. Survey on deep learning based RGB-D/T object detection. *Journal of Software*, 2023, 34(11): 5123-5147 (in Chinese)
(马一德, 刘洋, 王啸, 等. 基于深度学习的 RGB-D/T 目标检测综述. *软件学报*, 2023, 34(11): 5123-5147)
- [12] Chen J, Li X, Luo L, et al. A novel RGB-T object detection method based on swin transformer and feature fusion[J]. *Computers and Electrical Engineering*, 2023, 108: 108696.
- [13] Zhang Hong-Gang, Yang Hai-Tao, Zheng Feng-Jie, et al. Review of feature-level infrared and visible image fusion. *Computer Engineering and Applications*, 2024, 60(18): 17-31 (in Chinese)
(张宏钢, 杨海涛, 郑逢杰, 等. 特征级红外与可见光图像融合方法综述. *计算机工程与应用*, 2024, 60(18): 17-31)
- [14] Wagner J, Fischer V, Herman M, et al. Multispectral pedestrian detection using deep fusion convolutional neural networks[J]. *arXiv preprint arXiv:1611.02644*, 2016.
- [15] Peng R H, Lai J, Yang X T, et al. Camouflaged target detection based on multimodal image input pixel-level fusion[J]. *Frontiers of Information Technology & Electronic Engineering*, 2024, 25(9): 1226-1239.
- [16] Solovyev R, Wang W, Gabruseva T. Weighted boxes fusion: Ensembling boxes for object detection models[J]. *Image and Vision Computing*, 2021, 109: 104117.
- [17] Solawetz J, D'Angelo J. Late fusion for multispectral object detection//*Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. Waikoloa, USA, 2022: 2470-2479.
- [18] Liu J, Zhang S, Wang S, et al. Multispectral deep neural networks for pedestrian detection//*Proceedings of the British Machine Vision Conference (BMVC)*. York, UK, 2016: 1-12.
- [19] Pun N S, Sonbhadra S K, Agarwal S. Handcrafted and deep learning-based fusion for RGB-T object detection: A survey[J]. *IEEE Sensors Journal*, 2023, 23(21): 25686-25702.
- [20] Jiang M, Lei J, Zhou W, et al. A review of RGB-infrared cross-modality image fusion and detection: Techniques, datasets, and challenges[J]. *Information Fusion*, 2024, 107: 102319.
- [21] Zhu H, Deng F, Xie Y, et al. A novel multi-modality fusion network for RGB-T object detection in complex scenarios[J]. *IEEE Transactions on Multimedia*, 2023, 25: 8645-8656.
- [22] Yan Y, Mao J, Li X, et al. Illumination-aware feature alignment and fusion for RGB-T object detection[J]. *IEEE Geoscience and Remote Sensing Letters*, 2022, 19: 1-5.
- [23] Liu W, Zhang K, Zhang Z, et al. Cycled-split cross-attention for RGB-T object detection[J]. *IEEE Transactions on Image Processing*, 2022, 31: 4463-4476.
- [24] Qing Y, Liu H, Wei C, et al. Cross-modality fusion transformer for multispectral object detection//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New Orleans, USA, 2022: 5792-5801.
- [25] Zhou Hui-Xin, Gong Jie, Yang Yu, et al. Review of visible and infrared image fusion target detection technology. *Laser & Optoelectronics Progress*, 2024, 61(2): 0200001 (in Chinese)
(周慧鑫, 宫杰, 杨宇, 等. 可见光与红外图像融合目标检测技术综述. *激光与光电子学进展*, 2024, 61(2): 0200001)
- [26] Zhang L, Liu Z, Zhang S, et al. MF-YOLO: A multimodal fusion detection model for small target traffic signs in complex scenarios[J]. *IEEE Sensors Journal*, 2022, 22(23): 23091-23101.

-
- [27] Li T, Li X, Zhang Y, et al. Cross-modality feature fusion detection based on YOLOv5 for surveillance in low-light environments[J]. *Multimedia Systems*, 2023, 29: 2821-2832.
- [28] Cai Z, Vasconcelos N. Cascade R-CNN: Delving into high quality object detection//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. Salt Lake City, USA, 2018: 6154-6162.
- [29] Cao Y, Guan D, Huang Y, et al. Pedestrian detection in thermal images using saliency maps and cascade R-CNN[J]. *IEEE Transactions on Instrumentation and Measurement*, 2022, 71: 1-11.
- [30] Sun Xiao-Xu, Zhang Xiao-Ling, Wang Yi, et al. Small object detection method based on improved Swin Transformer. *Acta Automatica Sinica*, 2024, 50(2): 331-344 (in Chinese)
(孙小旭, 张小玲, 王伟, 等. 基于改进 Swin Transformer 的小目标检测方法. *自动化学报*, 2024, 50(2): 331-344)
- [31] Liu H, Zhang J, Yang K, et al. CMD-Transformer: Cross-modal decoupled transformer for RGB-T object detection[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2024, 34(5): 3421-3434.
- [32] Zhang Y, Wang H, Liu Y, et al. Cross-modality knowledge distillation for RGB-T object detection[J]. *Pattern Recognition*, 2023, 138: 109359.
- [33] Ma H, Zhang H, Zhang X, et al. Misalignment-robust RGB-T object detection via deformable cross-attention[J]. *IEEE Transactions on Multimedia*, 2024, 26: 2105-2117.
- [34] Munir F, Azam S, Jeon M. Thermal object detection improvement in adverse weather conditions using GAN-based thermal image enhancement[J]. *IEEE Access*, 2023, 11: 12854-12865.
- [35] Li Shi-Yu, Zhang Qiang, Ni Xin-Lan, et al. Unsupervised domain adaptive object detection based on multi-modal fusion. *Acta Automatica Sinica*, 2023, 49(7): 1466-1478 (in Chinese)
(李诗语, 张强, 倪新兰, 等. 基于多模态融合的无监督域自适应目标检测. *自动化学报*, 2023, 49(7): 1466-1478)