

TF-HTPA: 基于时频融合与层次化时间分区注意力的分布式光纤传感模式识别框架

文献阅读汇报与学术启发

汇报人: 夏宇阳

日期: 2026.4.14

来源文献: TF-HTPA: Distributed Optical Fiber Sensing Pattern Recognition Framework Based on Time-Frequency Fusion and Hierarchical Temporal Partition Attention (IEEE Sensors Journal)

作者信息



关注

管理个人资料

魏忠

id

隶属关系

光纤感测与通信关键实验室
中国电子科技大学（UESTC）
成都，中国

出版主题

光学放大器， 光纤， 声学场， 任意波形发生器， 数组处理， 注意力机制， 背景噪音， 波束成形， 方块对角， 宽带， 特征信号， 突变的特征

显示更多

传记

中伟于2004年获得中国桂林电子工业大学信息与计算科学学士学位，2007年获得武汉工业大学计算机应用技术硕士学位。他目前在中国成都电子科技大学攻读电子信息博士学位。2007年7月至2024年9月，他在中国电子科技集团公司（CETC）桂林第34研究所工作，担任系统软件部主任及集团公司专家等职务。自2025年7月起，他成为桂林航天大学（桂林）副教授兼全职教员。多年来，他的研究专注于航空航天和航空领域的通信与计算机应用。他的工作主要集中在通信网络的关键技术、通信设备、光缆线路监控（光纤传感）、通信网络管理与控制以及计算在通信中的应用。他主持并参与了众多项目，包括通信网络系统的示范、各种通信网络系统和通信设备的管理与控制软件开发。这些项目涉及人工智能、通信网络架构、光缆监控、多协议集成、态势感知以及智能管理控制等关键技术。作为技术负责人，他主要从事火箭、卫星、自主飞行器等数字孪生场景的仿真与验证，以及各种运行与维护控制软件的设计与开发。同时，他领导技术团队，负责目标识别和跟踪算法相关的研究和产品开发。
（基于2026年3月6日发布的文件） [少显示](#)

2026年1月25日收稿；2026年2月14日录用。2026年3月6日发表；研究得到国家自然科学基金（项目编号62466012）资助。

查贤伟

联系

济南安迅科技有限公司
济南
中国山东省

出版主题

注意力机制 背景噪音 特征信号 突变特征分析 复杂环境 关键挑战 挖掘， 环境噪声 事件检测 特征融合， 傅里叶变换 频域特征

陈彦

联系

计算机科学与工程学院
桂林航空航天大学
中国广西桂林

出版主题

异常数据 激活阈值 活动人士， 自适应系统 注意力机制 背景噪音 特征信号 突变特征分析 克隆选择， 克隆选择算法 复杂环境 关键挑战

[显示更多](#)

曾庆浩

联系

济南安迅科技有限公司
济南
中国山东省

出版主题

注意力机制 背景噪音 特征信号 突变特征分析 冷端， 复杂环境 关键挑战 当前匹配情况 挖掘， 电气性能， 整个设备， 环境噪声

复杂环境下的安防监控：DFOS的巨大潜力与现实技术瓶颈

技术潜力

✔ 分布式光纤传感 (DFOS)

将普通光纤转化为高灵敏度、长距离、连续的传感器阵列。

✔ 核心优势

抗电磁干扰、无源操作、部署成本低，在周界安防、结构健康监测等领域潜力巨大。

现实挑战

⚠ 瓶颈 1：单一域特征提取不足

传统深度学习（如仅时域的CNN或仅频域的频谱图）无法同时保留“频域周期性信息”与“瞬态突变特征”，导致环境鲁棒性差

⚠ 瓶颈 2：瞬态突变特征捕捉困难

如“攀爬”或“敲击”等真实入侵事件呈现毫秒级剧烈振幅突变。全局注意力机制极易将这些关键局部特征平滑和稀释，导致高误报率。


顶层破局：时频多域融合与层次化注意力机制的协同

策略一：多域融合 (Time-Frequency Fusion)

引入傅里叶变换，构建“**时域+幅值+相位**”三通道架构，彻底解决单一域信息丢失问题

策略二：层次化时间分区 (HTPA Module)

摒弃全局注意力，专注捕捉时间维度的瞬态依赖关系，专门针对毫秒级突变信号设计。



关键创新： HTPA模块通过层次划分和注意机制捕获时间依赖性

事件：背景|挖掘|敲打|浇水|摇晃|行走




Fig. 1. TF-HTPA framework for multievent detection in Φ -OTDR systems. (a) Φ -OTDR system architecture. (b) TF-HTPA model structure.



TF - HTPA 框架的两大核心-分别解决的问题:

两大核心创新:三通道时频特征融合and分层时间分区注意力HTPA。

- 时频融合解决传统方法单域特征提取不充分、无法同时保留时域突变与频域周期性的问题;
- HTPA 解决时域幅值突变特征捕获弱、全局注意力稀释关键瞬态信息的问题。

物理感知层：基于 Φ -OTDR 的信号采集与时空矩阵构建

由激光光源、掺铒光纤放大器（EDFA）、滤波器、声光调制器（AOM）以及与传感光纤相连的环形器组成。



环形器将瑞利背散射光导向光电探测器（PD）。接收信号经数据采集卡（DAQ）数字化，并在PC上处理。



系统架构

相位敏感光时域反射计 (Φ -OTDR) 捕捉沿光纤的瑞利背向散射光。



空间滑窗策略

系统在空间维度上采用**滑动窗口**，连续处理12个通道，兼顾光纤全覆盖与模型分辨率。



数据形态转化

原始振动事件转化为 **10000×12** 的**时间-空间矩阵** (Time-space matrix, T)，成为后续深度学习模型的标准输入。


算法核心 I：三通道时频多域特征提取与高效融合

三通道并行处理

- **T (时域)**：保留原始信号的瞬态结构。
- **M (幅值空间)**：经DFT变换，提取频率谐波特征。
- **P (相位空间)**：提取相位角信息。


跨阶段局部融合 (C2F-CSP)

- 利用级联瓶颈层 (Cascaded Bottleneck) 进行多尺度特征融合。
- **优势**：在维持模型轻量化的同时，显著提升多尺度特征的代表能力。



功能融合模块结构：C2F设计的级联瓶颈。

Feature fusion module




输入特征首先经过一个卷积批量归一化-SiLU（CBS）模块-初始的特征变换。此模块先通过 1×1 卷积扩展通道维度，随后进行批量归一化和Sigmoid线性单元（SiLU）激活。

随后，变换后的特征会沿着通道维度被均分为两部分。一部分作为残差路径保留，另一部分则经过一系列级联的瓶颈块处理。每个瓶颈块包含两个卷积层（先 1×1 ，后 3×3 ），并可能设置快捷连接以优化梯度流动和特征传播。

该模块的一个关键特征是其分层特征聚合方法。每个瓶颈块的输出都会被保留，随后与所有先前的特征拼接。这使得网络能够在多个转换阶段保留信息，并融合不同抽象层级的特征。

最后，拼接后的特征会经过一个终端CBS模块，该模块将所有多尺度特征融合为最终的输出表征。

物理意义透视：不同入侵事件的时频空间指纹差异




瞬态突变事件 (如挖掘/敲击)

表现为低频阵发与宽带周期性能量，具备强烈的局部高能量区域。→需要极高时间分辨率与突变捕捉能力。


持续性事件 (如浇水/晃动)

表现为持续的谐波结构与分散的空间分布。→需要精确频域特征鉴别。



结论：仅依靠单一域（仅看波形或仅看频谱）必然造成核心信息遗漏，时频联合是实现高鲁棒性的唯一路径。

Time-Frequency Spectrograms of Six Event Types



Spatiotemporal Heatmaps of Six Event Types





图5展示了利用短时傅里叶变换（*STFT*）计算得到的时频谱图：背景噪声表现为均匀的能量分布；挖掘事件呈现间歇性低频脉冲；敲击事件展现覆盖宽频范围的周期性能量带；浇水事件表现为连续的频谱分布；抖动事件呈现持续的谐波结构；行走事件则表现为准周期性的频谱脉冲。这些时频特征表明，不同事件具有独特的时频演变规律。

图6展示了时空热图，呈现了光纤传感系统中12个空间通道的信号分布情况：突发性事件（挖掘、敲击）表现为局部高能区域，而持续性事件（浇水、晃动、行走）则呈现出更分散的空间分布模式。

算法核心 II：HTPA 层次化时间分区注意力机制拆解



四个核心组件：
幅度显著性检测器
时间划分处理器
段级选择性注意力
通道注意力增强器

分层时间分区注意力机制HTPA的架构

1

幅值显著性检测 (Amplitude-Saliency)

使用 3×3 卷积敏锐捕捉信号的时间变化率，相当于边缘检测，强化突变特征。

2

时间分区 (Temporal-Partition)

核心创新：将特征沿时间轴切割为多个子段 ($n_seg=7$)，彻底避免全局注意力稀释局部突变。

3

段级选择性注意力 (Segment-level Attention)

在局部子段内独立计算权重，自适应放大段内突变信号的表征

4

通道注意力增强 (Channel Attention)

结合全局通道依赖关系重组特征，实现局部与全局的统一。

数据规模: 15,419 个高质量样本

分类任务: 6大类复杂事件

输入维度: 10000×12 时空矩阵


硬件环境: NVIDIA RTX 4060, PyTorch 2.0.1

6大分类事件

- 背景噪音 (Background)
- 挖掘 (Digging)
- 敲击 (Knocking)
- 浇水 (Watering)
- 晃动 (Shaking)
- 行走 (Walking)

核心评价指标

- 准确率 (Accuracy)
- 精确率 (Precision)
- 误报率 (NAR)
- F1-Score



这六项赛事如下：

1) 背景噪音

在白天和夜间均采集了未受人为干扰事件影响的信号。（我们的实验室位于主干道旁一栋办公楼的8楼）。

2) 挖掘

一人用小铲子在沙箱中埋在 15 厘米深、长约 10 米的传感光纤附近挖掘。

3) 敲击（模拟应力损伤）

一人拿起锤子，敲击防震板上约 10 米长的传感光纤。

4) 浇水（模拟下雨）

一人手持浇水壶，高度为 30 厘米，均匀地浇灌长度约为 10 米的传感光纤。

5) 摇晃（模拟入侵）

传感光纤用塑料扎带固定在栅栏上，一个人站在栅栏旁，以恒定的速度摇晃栅栏的不同部分。

6) 步行

一个人来回走动或跑步，覆盖约 20 米范围的传感光纤。

图 2. 六种典型事件的现场场景。(a) 背景噪声, (b) 挖掘, (c) 敲击, (d) 浇水, (e) 摇晃, 以及 (f) 行走。

Model	Event type	Precision	NAR	F1-score
SVM Average accuracy=0.831 Precision=0.841 NAR=0.175 F1-score=0.826	Background	0.762	0.014	0.860
	Digging	0.830	0.408	0.691
	Knocking	0.885	0.221	0.829
	Watering	0.925	0.202	0.857
	Shaking	0.866	0.075	0.895
	Walking	0.779	0.131	0.822
CNNError! Reference source not found. Average accuracy=0.916 Precision=0.916 NAR=0.088 F1-score=0.912	Background	0.950	0.025	0.962
	Digging	0.883	0.056	0.912
	Knocking	0.911	0.053	0.928
	Watering	0.894	0.135	0.879
	Shaking	0.908	0.038	0.934
	Walking	0.948	0.220	0.856
1DCNNs-BiLSTMError! Reference source not found. Average accuracy=0.937 Precision=0.937 NAR=0.064 F1-score=0.936	Background	0.957	0.020	0.968
	Digging	0.958	0.096	0.930
	Knocking	0.902	0.071	0.915
	Watering	0.934	0.064	0.935
	Shaking	0.955	0.027	0.964
	Walking	0.914	0.108	0.903
TFF-CNNError! Reference source not found. Average accuracy=0.949 Precision=0.950 NAR=0.053 F1-score=0.948	Background	0.975	0.003	0.986
	Digging	0.950	0.052	0.949
	Knocking	0.987	0.107	0.938
	Watering	0.933	0.080	0.926
	Shaking	0.918	0.011	0.952
	Walking	0.935	0.065	0.935
VisionTransformer0 Average accuracy=0.937 Precision=0.937 NAR=0.065 F1-score=0.936	Background	0.957	0.020	0.968
	Digging	0.958	0.096	0.930
	Knocking	0.902	0.071	0.915
	Watering	0.934	0.064	0.935
	Shaking	0.955	0.027	0.964
	Walking	0.914	0.108	0.903
TF-HTPA(Ours) Average accuracy=0.972 Precision=0.971 NAR=0.030 F1-score=0.970	Background	0.992	0.003	0.994
	Digging	0.953	0.040	0.956
	Knocking	0.951	0.003	0.973
	Watering	0.982	0.035	0.973
	Shaking	0.993	0.016	0.988
	Walking	0.956	0.080	0.938

为进一步验证提出的TF-HTPA模型的有效性，采用了四种代表性方法进行全面的比较实验：**SVM**、**CNN**、**1DCNNs-BiLSTM**、**TFF-CNN** 和**VisionTransformer**。

如表V所示，传统**SVM**方法的平均准确率为**0.831**，而基于深度学习的方法则逐步提升：**CNN**（**0.916**）、**1DCNNs-BiLSTM**（**0.937**）和**TFF-CNN**（**0.949**）。这些结果展示了将先进深度学习架构和时频融合技术应用于**DFOS**事件识别的有效性。

消融实验与混淆矩阵：模块贡献的量化验证


Step 4
完全体 TF-HTPA: 97.2% (各类别全面最优)

Step 3
+ 层次化注意力 (CNN-HTPA) : 94.6%
(大幅提升非背景事件的区分度)


Step 2
+ 时频融合 (CNN-TF) : 92.1%
(降低了背景噪声的混淆)

Step 1
基础 CNN: 91.6% (基准)


核心洞察：TF-HTPA 在极其相似的瞬态事件（如'敲击'与'挖掘'）上展现出惊人的区分能力，混淆数量降至个位数。




(a) CNN



(b) CNN-TF




(c) CNN-HTPA




(d) TF-HTPA

特征分布可视化：揭开高维特征分离的‘黑盒’



基础 CNN 特征空间

- 簇间重叠严重。尤其是“浇水(绿)”与“行走(黑)”、“挖掘(蓝)”与“敲击(黄)”边界模糊，表明模型未掌握核心判别特征。



TF-HTPA 特征空间

- 得益于时频融合，背景噪音(红)形成极度紧凑的独立簇。
- 得益于HTPA的时间分区，各类动态事件形成清晰边界，六大类事件在三维空间实现完美剥离。

SOTA 对比：确立 DFOS 模式识别的行业新标杆

SVM	Acc 0.831
1DCNNs-BiLSTM	Acc 0.937
VisionTransformer	Acc 0.937
TFF-CNN	Acc 0.949（次优）
TF-HTPA（本文）	Acc 0.972 极低 NAR（0.003-0.080）

底层代差优势分析

相比 TFF-CNN 的静态全局编码，HTPA 的"动态局部权重"机制有效抵抗了局部瞬态特征被海量静态数据稀释的数学困境，使其在突发安全事件检测中具备决定性优势。

全文总结：理论创新与工程价值的闭环

1



架构范式重构 (Framework Innovation)

成功将三通道时频信号特征与深度学习端到端结合，构建了无需人工繁琐特征工程的高效处理管线。

2



核心痛点攻克 (Breakthrough)

创新的 HTPA 机制彻底解决了 DFOS 信号中毫秒级瞬态突变特征极易被掩盖、稀释的世界级难题。

3



极高工程落地价值 (Engineering Value)

97.2% 的超高分类精度与极低误报率，为复杂环境、强噪声干扰下的真实安防监控系统提供了高度可靠的解决方案。

So What? 对后续学术研究的核心启发

Insight 1: 物理先验与黑盒模型的对齐

深度学习不应仅是盲目的数学映射。引入 FFT 提取幅相信息证明了：将物理先验知识（信号的频域周期性）强行注入网络结构，能极大提升模型的可解释性与泛化上限。

Insight 2: "分治策略"在长序列中的通用潜力

面对长时序高频采样，全局 Attention 并非万能。HTPA 的"先时间分区，再局部加权"思想，为解决长序列信号特征稀释提供了通用范式，可直接迁移至其他声学或振动监测任务。

Insight 3: 复杂系统微观事件的针对性捕获

显著性检测与多尺度融合（C2F模块）提示我：在未来的检测任务中，应专门设计针对“瞬变/微弱目标”的捕捉算子，而非一味堆砌庞大的通用 Backbone。