

单位代码： 10293 密 级：           

南京邮电大学  
专 业 学 位 硕 士 论 文



论文题目： PCA 与 K-means++ 人脸聚类分析

|        |   |                   |
|--------|---|-------------------|
| 学      | 号 | <u>1025040819</u> |
| 姓      | 名 | <u>张刘路</u>        |
| 导      | 师 | <u>指导教师</u>       |
| 专业学位类别 |   | <u>计算机科学与技术</u>   |
| 类      | 型 | <u>大数据分析</u>      |
| 专业（领域） |   | <u>计算机技术</u>      |
| 论文提交日期 |   | <u>2026 年 5 月</u> |

# 摘要

随着人工智能和计算机视觉技术的快速发展，高维图像数据的高效处理成为制约人脸识别、图像检索和无监督模式分析的重要瓶颈。ORL 人脸数据集包含 40 个对象的 400 幅灰度人脸图像，每幅图像分辨率为  $112 \times 92$ ，展平后单个样本维度达到 10,304。该数据集包含姿态、表情和光照变化，既是人脸识别研究中的经典基准，也为高维数据聚类带来了维度冗余、类内分散和类间混淆等挑战。

本文围绕“PCA 降维 + K-means++ 聚类”的技术路线，对 ORL 人脸数据集开展无监督聚类分析。首先，对原始灰度图像进行向量化、二值化、滤波和归一化等预处理，构建标准化的  $400 \times 10304$  特征矩阵。随后，利用主成分分析（PCA）将原始高维像素特征压缩至 100 维，在降低计算复杂度的同时尽量保留人脸身份判别信息。最后，采用 K-means++ 算法对降维后的特征进行 40 类聚类，并从调整兰德指数、轮廓系数、SSE、混淆矩阵和聚类样本可视化等角度进行综合评价。

实验结果表明，100 维 PCA 特征仅占原始维度的 0.97%，实现约 103:1 的压缩比，同时保留 89.42% 的累计方差信息，重构均方误差仅为 0.004857。基于该低维特征的 K-means++ 聚类取得 0.6366 的 ARI 和 0.2073 的轮廓系数，说明无监督聚类结果与真实身份类别之间具有显著正相关。可视化结果进一步表明，PCA 能够提取具有物理意义的特征脸，K-means++ 能够在部分簇中形成较好的身份一致性。本文验证了 PCA 与 K-means++ 结合用于 ORL 人脸数据无监督聚类的有效性，并为后续人脸聚类和算法优化提供了可靠基线。

**关键词：**主成分分析，K-means++，ORL 人脸数据集，人脸识别，降维，聚类分析

# Abstract

With the rapid development of artificial intelligence and computer vision, efficient processing of high-dimensional facial images has become a key issue in face recognition and unsupervised pattern analysis. This thesis studies an unsupervised clustering framework for the ORL Face Dataset based on PCA dimensionality reduction and K-means++ clustering.

The original  $112 \times 92$  grayscale face images are flattened into 10,304-dimensional vectors and preprocessed by binarization, filtering, and normalization. PCA is then used to reduce the features to 100 dimensions, preserving 89.42% cumulative variance with a compression ratio of about 103:1 and a reconstruction MSE of 0.004857. K-means++ is applied to cluster the reduced features into 40 groups. The clustering result obtains an ARI of 0.6366 and a silhouette coefficient of 0.2073. Quantitative metrics and visualizations demonstrate the effectiveness of the PCA and K-means++ pipeline for unsupervised face clustering on the ORL dataset.

**Key Words:** PCA, K-means++, ORL Face Dataset, face recognition, dimensionality reduction, clustering

# 目 录

|                            |     |
|----------------------------|-----|
| 摘要 .....                   | I   |
| Abstract .....             | II  |
| 插图索引 .....                 | V   |
| 表格索引 .....                 | VI  |
| 专用术语注释表 .....              | VII |
| <b>第一章 绪论</b> .....        | 1   |
| 1.1 研究背景 .....             | 1   |
| 1.2 研究意义 .....             | 1   |
| 1.3 研究内容 .....             | 1   |
| 1.4 论文结构 .....             | 2   |
| <b>第二章 相关工作</b> .....      | 3   |
| 2.1 主成分分析 .....            | 3   |
| 2.2 K-means 聚类算法 .....     | 3   |
| 2.3 K-means++ 改进 .....     | 4   |
| 2.4 本章小结 .....             | 4   |
| <b>第三章 问题定义与数据集</b> .....  | 5   |
| 3.1 ORL 人脸数据集介绍 .....      | 5   |
| 3.2 核心目标 .....             | 6   |
| 3.3 问题定义 .....             | 6   |
| 3.4 本章小结 .....             | 6   |
| <b>第四章 方法设计</b> .....      | 8   |
| 4.1 数据预处理 .....            | 8   |
| 4.2 PCA 降维算法 .....         | 8   |
| 4.2.1 数据中心化 .....          | 8   |
| 4.2.2 主成分提取与维度选择 .....     | 8   |
| 4.2.3 数据投影与特征保留 .....      | 9   |
| 4.3 K-means++ 聚类算法 .....   | 9   |
| 4.4 评价指标 .....             | 9   |
| 4.5 本章小结 .....             | 10  |
| <b>第五章 实验结果与分析</b> .....   | 11  |
| 5.1 PCA 降维效果分析 .....       | 11  |
| 5.1.1 定量指标分析 .....         | 11  |
| 5.1.2 可视化结果验证 .....        | 11  |
| 5.1.3 降维效果小结 .....         | 13  |
| 5.2 K-means++ 聚类效果分析 ..... | 13  |
| 5.2.1 聚类定量指标 .....         | 14  |
| 5.2.2 可视化结果验证 .....        | 14  |
| 5.3 本章小结 .....             | 14  |

|                  |    |
|------------------|----|
| 第六章 总结与展望 .....  | 17 |
| 6.1 全文总结 .....   | 17 |
| 6.2 不足之处 .....   | 17 |
| 6.3 未来工作 .....   | 17 |
| 6.4 课程学习体会 ..... | 17 |
| 6.5 本章小结 .....   | 18 |
| 参考文献 .....       | 19 |
| 程序清单 .....       | 20 |
| 发表文章目录 .....     | 21 |
| 发表专利目录 .....     | 22 |
| 参与项目目录 .....     | 23 |

插图索引

|       |                         |    |
|-------|-------------------------|----|
| 图 2.1 | PCA 技术流程概览 .....        | 3  |
| 图 3.1 | ORL 数据集部分样本展示 .....     | 5  |
| 图 5.1 | 累计方差贡献率曲线 .....         | 12 |
| 图 5.2 | 前 5 个主成分对应的特征脸可视化 ..... | 12 |
| 图 5.3 | 降维前后图像重构对比 .....        | 13 |
| 图 5.4 | 聚类混淆矩阵热力图 .....         | 15 |
| 图 5.5 | 前 8 个聚类簇样本展示 .....      | 16 |

表格索引

表 3.1 ORL 人脸数据集基本信息 ..... 5

表 4.1 K-means++ 主要参数设置 ..... 9

表 5.1 PCA 降维定量指标 ..... 11

表 5.2 K-means++ 聚类定量指标 ..... 14

## 专用术语注释表

### 符号说明:

| 符号          | 表示含义                |
|-------------|---------------------|
| $X$         | ORL 人脸样本矩阵          |
| $n$         | 样本数量, 本文中为 400      |
| $d$         | 原始特征维度, 本文中为 10,304 |
| $k$         | 聚类簇数, 本文中为 40       |
| $C_i$       | 第 $i$ 个聚类簇          |
| $\mu_i$     | 第 $i$ 个簇的聚类中心       |
| $\lambda_i$ | 第 $i$ 个主成分对应特征值     |

### 缩略词说明:

| 缩写  | 英文全称                         | 中文译名      |
|-----|------------------------------|-----------|
| PCA | Principal Component Analysis | 主成分分析     |
| ORL | Olivetti Research Laboratory | 奥利维蒂研究实验室 |
| ARI | Adjusted Rand Index          | 调整兰德指数    |
| SSE | Sum of Squared Errors        | 误差平方和     |
| MSE | Mean Squared Error           | 均方误差      |



# 第一章 绪论

## 1.1 研究背景

随着人工智能和计算机视觉技术的快速迭代与深度融合，高维图像数据的高效处理逐渐成为相关应用落地中的核心瓶颈。高维数据不仅会过度消耗存储和计算资源，增加数据处理成本与时间开销，还会由于“维度灾难”导致传统数据分析算法中的距离度量失真，从而使聚类准确率下降，削弱算法的实际应用价值。

ORL 人脸数据集是模式识别领域中具有代表性的高维图像数据集。该数据集由 40 个对象的 400 幅人脸图像组成，每幅图像为分辨率  $112 \times 92$  的灰度图，单个样本展平后的特征维度达到 10,304。数据集覆盖同一对象在不同姿态、表情和光照条件下的变化，例如左右约  $\pm 20^\circ$  偏转、睁眼与闭眼、微笑与严肃等，因此常被用于验证和优化人脸识别与聚类算法。

## 1.2 研究意义

在高维人脸数据的处理系统中，降维技术和聚类算法构成两类核心技术。降维技术能够压缩特征维度、去除冗余信息并降低计算复杂度；聚类算法则能够在没有人工标签的情况下对样本进行自动分组。将二者有机结合并应用于 ORL 人脸数据集，可以发挥技术互补优势，缓解高维人脸聚类中的维度冗余、类内分散和类间混淆问题。

本文采用 PCA 进行线性降维，以提取能够反映人脸结构的主成分特征；再使用 K-means++ 进行无监督聚类，以提高传统 K-means 对初始中心敏感问题下的稳定性。该方法既能降低原始高维像素特征带来的计算负担，也能通过可视化结果直观展示聚类效果，为无监督人脸识别提供可复现实验基线。

## 1.3 研究内容

本文的主要研究内容如下：

- (1) 对 ORL 人脸数据集进行介绍，分析其图像维度、样本结构和聚类难点；
- (2) 研究 PCA 降维算法在人脸特征提取中的作用，确定适合后续聚类的低维表示；
- (3) 采用 K-means++ 优化初始中心选择，完成 40 类无监督人脸聚类；
- (4) 使用 ARI、轮廓系数、SSE、重构 MSE 等指标对实验效果进行评价；
- (5) 通过累计方差曲线、特征脸、重构图像、混淆矩阵和聚类样本展示结果。

## 1.4 论文结构

全文共分为六章。第 1 章介绍研究背景、意义和主要内容。第 2 章综述 PCA 与 K-means 相关研究。第 3 章定义研究问题并介绍 ORL 数据集。第 4 章说明数据预处理、PCA 降维和 K-means++ 聚类方法。第 5 章展示实验结果与定量评价。第 6 章总结全文并讨论不足与未来工作。

## 第二章 相关工作

### 2.1 主成分分析

主成分分析（Principal Component Analysis, PCA）是一种经典线性降维算法，在现代人脸识别任务中仍被广泛应用<sup>[1]</sup>。其核心思想是通过线性变换将高维数据映射到低维子空间，使低维数据方差最大化，从而尽可能保留关键判别特征，同时消除冗余信息和噪声。

PCA 的优势主要体现在三个方面。第一，原理简单直观，基于线性代数中的特征值分解理论，不需要复杂模型假设，便于理解和实现。第二，计算效率较高，其时间开销主要来自协方差矩阵计算和特征值分解，与 t-SNE 等非线性降维方法相比，更适合较大规模高维人脸数据。第三，数据压缩效果明显，能够在显著降低维度的同时保留核心特征，从而缓解维度灾难对聚类任务的影响。

在人脸识别领域，PCA 具有代表性。ORL 数据集的 10,304 维像素特征包含大量冗余信息，例如不同光照下像素灰度值的相关性、背景区域和非关键区域像素等。通过 PCA 映射到低维子空间后，可以形成与主成分对应的“特征脸”（Eigenfaces）。该框架在二维 PCA 和稀疏鲁棒 PCA 等研究中被持续验证和改进<sup>[2,4]</sup>。Chan 等研究表明，在 PCA 降维后结合欧氏距离度量能够在 ORL 数据集上取得较高识别效果<sup>[3]</sup>。




图 2.1 PCA 技术流程概览

### 2.2 K-means 聚类算法

K-means 聚类算法由 MacQueen 于 1967 年提出，是聚类分析中最经典、应用最广泛的无监督学习算法之一<sup>[5]</sup>。其核心目标是在没有标签信息的情况下，根据特征相似性将数据自动划分为预设的  $k$  个簇，使簇内样本尽可能相似、簇间样本尽可能分离。

K-means 的优点包括计算效率较高、流程简单、可扩展性强和结果具备一定解释性。在迭

代过程中，算法主要执行距离计算和均值更新，因此适合较大规模人脸数据的快速聚类。与此同时，K-means 也可以灵活结合降维方法和特征工程，从而适应高维人脸数据分析任务<sup>[6]</sup>。

在人脸识别任务中，K-means 可在没有人工标注的情况下自动分组 ORL 样本，为无监督身份聚类提供支持<sup>[7]</sup>。然而，传统 K-means 也存在对初始中心敏感、易受异常样本影响、不擅长处理非球形簇等局限<sup>[8]</sup>。对于 ORL 数据集，同一对象不同姿态造成的类内分散，以及不同对象相似脸型造成的类间混淆，都会进一步放大这些问题。

## 2.3 K-means++ 改进

为缓解传统 K-means 对初始中心敏感的问题，本文采用 K-means++ 算法。该算法优先选择距离已选中心较远的样本作为新的初始中心，使初始中心在特征空间中更加分散，从而提高聚类稳定性和准确性。相关研究表明，改进的 K-means++ 初始化策略在高维人脸特征聚类中能够取得更稳定的表现<sup>[9]</sup>。

在 ORL 人脸数据集中，K-means++ 能够更好覆盖不同身份的人脸样本，减少随机初始化导致的局部最优风险。结合 PCA 降维后的低维特征，K-means++ 既保留了中心类聚类算法的效率优势，又增强了算法对复杂人脸特征分布的适应能力。

## 2.4 本章小结

本章介绍了 PCA 在人脸特征提取中的作用、K-means 聚类算法的基本特点，以及 K-means++ 在初始中心选择方面的改进。上述研究为后续构建“PCA 降维 +K-means++ 聚类”的 ORL 人脸聚类系统奠定了基础。

### 第三章 问题定义与数据集

#### 3.1 ORL 人脸数据集介绍

本文采用的 ORL（Olivetti Research Laboratory）人脸数据集是人脸识别和无监督学习领域的经典基准数据集。该数据集由英国 Olivetti Research Laboratory 于 1994 年发布，包含 40 个对象的 400 幅灰度人脸图像，每个对象有 10 幅图像。图像采集条件包含约  $\pm 20^\circ$  姿态偏转、睁眼与闭眼、微笑与严肃等表情变化，以及轻微光照变化。所有图像均为黑色背景并进行了居中对齐，不包含明显遮挡。

表 3.1 ORL 人脸数据集基本信息

| 项目      | 说明或数值          |
|---------|----------------|
| 样本总数    | 400            |
| 对象数量    | 40             |
| 每个对象图像数 | 10             |
| 图像类型    | 灰度图像           |
| 图像分辨率   | 112 × 92       |
| 单样本原始维度 | 10,304         |
| 灰度范围    | 0–255          |
| 类别分布    | 每类 10 个样本，分布均衡 |

每幅图像可通过矩阵展平转换为 10,304 维特征向量。数据集类别分布均衡，不存在明显类别偏置；图像经过基本规范化处理，噪声干扰较低，为聚类分析提供了较可靠的基础。与此同时，同一对象因姿态和表情变化产生的特征离散，以及不同对象间相似脸型导致的特征混淆，也为无监督聚类任务带来挑战。




图 3.1 ORL 数据集部分样本展示

## 3.2 核心目标

本文的核心目标是构建一个基于 PCA 降维和 K-means++ 聚类的 ORL 人脸数据聚类分析与可视化系统。具体而言，研究目标包括以下四个方面。

首先，实现高效降维。对于 ORL 数据集的 10,304 维原始特征，PCA 用于去除背景像素和光照噪声等冗余信息，缓解维度灾难，同时尽可能保留人脸轮廓、五官比例和身份差异等核心特征。最佳降维维度由特征值累计贡献率确定，以平衡降维幅度和信息保留。

其次，实现准确聚类。本文采用 K-means++ 对降维后的数据进行聚类，在不使用人工身份标签的情况下，将样本划分为 40 个簇，对应数据集中 40 个真实对象。理想情况下，同一对象不同姿态和表情下的样本应被划入同一簇，不同对象样本应尽量分离。

再次，建立综合评价体系。本文从聚类准确性、计算效率和资源消耗三个角度验证 PCA 与 K-means++ 结合的优势。聚类准确性主要使用调整兰德指数、Purity、轮廓系数等指标；计算效率与资源消耗则通过维度压缩比例、特征保留率和算法复杂度间接体现。

最后，实现直观可视化。本文设计多种可视化方式，包括降维后数据分布、特征脸展示、图像重构对比、聚类混淆矩阵和聚类样本展示，以直观呈现实验结果并支持算法优化。

## 3.3 问题定义

基于上述数据集特点和研究目标，本文研究问题可定义为：针对 400 个样本、10,304 维特征的 ORL 高维人脸数据集，解决高维数据聚类中的维度灾难、计算复杂度高、同一对象特征分散以及不同对象特征混淆等问题；通过 PCA 降维与 K-means++ 聚类的结合，实现高效、准确且可视化的无监督人脸聚类。

具体需要解决三个关键子问题：

- (1) **降维优化**：如何根据特征值累计贡献率确定 PCA 的最优降维维度，使降维后数据能够尽量消除冗余信息、降低计算复杂度，同时保留足够的身份判别特征。
- (2) **聚类精度提升**：如何通过 K-means++ 优化初始聚类中心，缓解传统 K-means 对初始值敏感的问题，并提高聚类结果与真实身份类别的一致性。
- (3) **结果呈现**：如何设计适合人脸数据的可视化方案，清晰展示降维过程、低维特征分布以及聚类结果与真实身份之间的对应关系。

## 3.4 本章小结

本章介绍了 ORL 人脸数据集的样本结构、图像特征和聚类难点，并明确了本文的研究目标和问题定义。后续章节将在此基础上设计完整的数据预处理、PCA 降维和 K-means++ 聚类

方案。

## 第四章 方法设计

### 4.1 数据预处理

数据预处理是保证后续算法性能的基础，其目标是统一数据格式、优化特征质量，并为 PCA 降维和 K-means++ 聚类提供可靠输入。结合 ORL 人脸数据集特点，本文采用完整数据集进行实验，即 40 个对象、每个对象 10 幅  $112 \times 92$  像素二维灰度图像，共 400 个样本。

首先，将每幅图像矩阵展平成 10,304 维特征向量，构建标准化的  $400 \times 10304$  样本矩阵。随后，对像素进行二值化处理：像素值大于 127 的设为 255 作为前景，小于或等于 127 的设为 0 作为背景，以增强人脸轮廓。接着，采用中值滤波去除局部噪声。最后，使用 Min-Max 归一化方法将所有特征值映射到  $[0, 1]$  区间，消除灰度幅值差异对距离计算的影响。考虑到数据集规模较小，本文直接使用全部样本进行后续实验，避免采样带来的信息损失。

### 4.2 PCA 降维算法

PCA 作为经典线性降维技术，目标是在保留人脸核心身份特征的同时去除冗余信息、降低数据维度并减轻高维计算负担。对于 ORL 数据集的 10,304 维特征，本文采用如下步骤实现 PCA。

#### 4.2.1 数据中心化

数据中心化由 sklearn 库中的 PCA 模块自动完成。具体而言，计算全体样本在每个像素特征上的均值，并将所有样本对应特征减去该均值，使处理后的数据在每个维度上均值为 0。该步骤能够保证协方差矩阵准确反映像素特征之间的线性相关关系。

#### 4.2.2 主成分提取与维度选择

本文使用 sklearn PCA 模块提取主成分，并依据累计方差贡献率确定降维维度。实验测试了 50 维、70 维和 100 维等候选维度，最终选择 100 维作为目标维度。该维度的累计方差贡献率为 89.42%，能够在保留接近 90% 核心人脸信息的同时，将维度从 10,304 压缩至 100，显著降低后续聚类计算复杂度。



### 4.2.3 数据投影与特征保留

原始 10,304 维数据被投影到由 100 个主成分构成的低维空间中，生成  $400 \times 100$  的低维特征矩阵，用于后续聚类实验。投影后的特征既包含人脸轮廓、五官布局等核心信息，也有效过滤了背景冗余和部分噪声。前 5 个主成分还可以可视化为特征脸，用于解释 PCA 所捕获的人脸结构信息。

## 4.3 K-means++ 聚类算法

本文采用 K-means++ 算法对 ORL 人脸样本进行聚类。作为传统 K-means 的改进版本，K-means++ 的核心优势在于优化初始中心选择，以提高聚类稳定性和准确性。该策略更适合 ORL 人脸数据中“同一对象特征分散、不同对象特征混淆”的分布特点。

表 4.1 K-means++ 主要参数设置

| 参数                 | 设置                   |
|--------------------|----------------------|
| 聚类簇数 $k$           | 40，对应 ORL 数据集 40 个对象 |
| 初始化方法              | K-means++            |
| 初始化尝试次数 $n_{init}$ | 30                   |
| 最大迭代次数             | 500                  |
| 终止阈值               | 聚类中心变化小于 $1e-6$      |
| 距离度量               | 欧氏距离                 |
| 输入特征               | PCA 降维后的 100 维特征     |

K-means++ 初始中心选择过程如下：首先从 400 个样本中随机选择 1 个样本作为第一个聚类中心；然后计算其他样本到已选中心集合的欧氏距离，并按距离平方成比例的概率选择下一个中心；重复该步骤直到确定 40 个初始中心。该策略能够使初始中心在特征空间中分布更均匀，覆盖不同身份的人脸样本。

聚类迭代过程包括样本分配和中心更新两个步骤。首先，计算每个样本到 40 个聚类中心的欧氏距离，并将样本分配给最近中心；随后，使用簇内样本的均值更新对应聚类中心。上述过程不断重复，直到满足终止条件。聚类完成后，将每个簇标签映射为该簇中出现频率最高的真实标签，以便进一步评价聚类结果与真实身份之间的一致性。

## 4.4 评价指标

本文从降维效果和聚类效果两个层面进行评价。降维效果主要考察降维维度占比、压缩比、累计方差贡献率和重构 MSE。聚类效果主要考察调整兰德指数、轮廓系数和 SSE。其中，ARI 用于衡量聚类结果与真实标签的一致性；轮廓系数用于衡量簇内紧凑性和簇间分离

性；SSE 用于衡量样本到聚类中心的总体平方误差。

## 4.5 本章小结

本章给出了完整方法设计，包括图像预处理、PCA 降维、K-means++ 聚类 and 评价指标。该流程将原始高维人脸图像转换为可聚类、可评价和可解释的低维特征表示。

## 第五章 实验结果与分析

### 5.1 PCA 降维效果分析

为缓解 ORL 人脸数据原始特征中的维度冗余，并提高后续聚类任务的计算效率，本文采用 PCA 进行线性降维。原始  $112 \times 92$  灰度图像展平后形成 10,304 维高维像素特征，其中包含大量背景冗余和噪声。直接使用这些特征进行聚类会显著增加计算复杂度，并可能影响模型性能。因此，本文选择 100 维作为 PCA 降维目标，并从定量指标和可视化结果两个方面系统评价其效果。

#### 5.1.1 定量指标分析

PCA 降维核心指标如表5.1所示。降维后特征维度仅占原始维度的 0.97%，实现约 103:1 的压缩比，显著降低后续数据处理计算负担。在信息保留方面，100 维特征的累计方差贡献率达到 89.42%，接近 90% 的实用信息保留阈值，说明少量主成分即可捕获原始数据中的大部分核心信息。重构 MSE 为 0.004857，表明将 100 维特征反投影回图像空间后，与原始人脸图像之间的像素级差异很小。

表 5.1 PCA 降维定量指标

| 指标      | 数值       |
|---------|----------|
| 原始维度    | 10,304   |
| 降维后维度   | 100      |
| 降维后维度占比 | 0.97%    |
| 压缩比     | 约 103:1  |
| 累计方差贡献率 | 89.42%   |
| 特征保留率   | 89.42%   |
| 重构 MSE  | 0.004857 |

#### 5.1.2 可视化结果验证

累计方差贡献率曲线如图5.1所示。曲线呈现“前期快速上升、后期逐渐平缓”的典型趋势：前 20 个主成分的累计贡献率超过 70%，前 100 个主成分达到 89.42%，并逐渐接近实验中设置的 90% 参考阈值。该结果说明人脸图像核心信息高度集中在前若干个主成分中，后续主成分主要包含少量细节冗余和噪声。选择 100 维能够在维度压缩和信息保留之间取得较好平衡。




图 5.1 累计方差贡献率曲线

前 5 个主成分对应的特征脸如图5.2所示。第一张特征脸主要反映人脸全局轮廓和整体光照分布，方差占比约为 17.2%；第二张特征脸关注面部明暗对比和五官整体布局，方差占比约为 14.4%；第三至第五张特征脸则捕获更细粒度的纹理和局部器官形态，其方差占比分别约为 7.9%、5.8% 和 5.0%。这些特征脸的清晰呈现说明 PCA 提取的低维特征具有明确物理意义，而非无意义的数学映射。





图 5.2 前 5 个主成分对应的特征脸可视化

降维前后图像重构对比如图5.3所示。可以看到，重构图像与原始图像之间几乎不存在明显视觉差异，人脸轮廓、表情特征和姿态方向均清晰可辨，仅在局部纹理精细度上略有损失。该现象与较低的重构 MSE 相吻合，进一步说明 100 维 PCA 特征足以保留人脸身份识别所需的关键视觉信息。



(a) 原始图像样本



(b) 重构图像样本

图 5.3 降维前后图像重构对比

### 5.1.3 降维效果小结

总体来看, 100 维 PCA 在 ORL 数据集上同时实现了高效维度压缩和高质量信息保留。它不仅以约 103:1 的压缩比显著降低计算复杂度, 还通过 89.42% 的累计方差贡献率和 0.004857 的重构 MSE 保证了特征代表性, 从而为后续无监督聚类提供了高质量低维输入。

## 5.2 K-means++ 聚类效果分析

基于 100 维 PCA 低维特征, 本文采用 K-means++ 对 ORL 人脸数据集进行无监督聚类。聚类簇数预设为 40, 对应数据集中的 40 个真实身份类别。实验从定量指标和可视化结果两个角度验证聚类有效性。

5.2.1 聚类定量指标

K-means++ 聚类结果如表5.2所示。ARI 为 0.6366，显著大于 0，说明聚类结果与真实身份类别之间存在明显正相关，约 63.66% 的样本被分配到与其真实身份对应的聚类结构中。轮廓系数为 0.2073，反映出中等水平的簇内紧凑性和簇间分离性。该数值不高主要源于 ORL 数据集自身特点：同一对象在姿态、表情和光照上的变化会造成簇内样本分散，而不同对象之间相似的面部结构又会降低簇间可分性。SSE 为 54070.71，结合预实验中的肘部法曲线可以看出，当  $k = 40$  时 SSE 下降趋势趋于平缓，说明该簇数设置具有合理性。

表 5.2 K-means++ 聚类定量指标

| 指标         | 数值或说明        |
|------------|--------------|
| 聚类簇数 $k$   | 40           |
| 调整兰德指数 ARI | 0.6366       |
| 轮廓系数       | 0.2073       |
| 误差平方和 SSE  | 54070.71     |
| 输入维度       | 100 维 PCA 特征 |
| 主要结论       | 与真实身份类别显著正相关 |

5.2.2 可视化结果验证

聚类混淆矩阵热力图如图5.4所示。矩阵对角线位置存在明显深色块，例如真实标签 0 与聚类标签 0 对应、真实标签 39 与聚类标签 39 对应，说明多数真实身份类别的样本被正确分配到同一簇中。同时，矩阵中也存在少量分散的浅色块，例如某些真实标签样本被分配到多个簇中。这反映出无监督聚类的固有限制：算法无法直接利用真实标签，只能根据特征相似性进行分组，因此部分相似人脸样本可能发生跨簇分配。

前 8 个聚类簇的样本展示如图5.5所示。多数簇内部样本具有较高身份一致性，例如 Cluster 1 中的样本均来自真实标签 21，Cluster 5 中的样本均来自真实标签 1，Cluster 7 中的样本均来自真实标签 12。也有部分簇存在多身份混合，例如 Cluster 4 中包含真实标签 8、16 和 22 的样本，说明相似人脸特征和非球形簇结构会影响 K-means++ 的聚类效果。该现象与轮廓系数相对较低的结果一致。

5.3 本章小结

本章从降维效果和聚类效果两个层面验证了 PCA 与 K-means++ 组合方案的有效性。PCA 能够显著压缩维度并保留核心人脸信息；K-means++ 在低维特征上能够获得与真实身份具有较强一致性的聚类结构。定量指标和可视化结果共同说明，该方案适合作为 ORL 人脸无监督





图 5.4 聚类混淆矩阵热力图

聚类分析的基线方法。



(a) 前 4 个聚类簇



(b) 第 5 至第 8 个聚类簇

图 5.5 前 8 个聚类簇样本展示



## 第六章 总结与展望

### 6.1 全文总结

本文采用“PCA 降维 +K-means++ 聚类”的方案，在 ORL 人脸数据集上完成了无监督身份聚类实验，并从降维效率、信息保留能力和聚类性能三个方面验证了该方案的有效性和实用性。

在降维层面，100 维 PCA 实现了约 103:1 的压缩比，保留了 89.42% 的核心人脸信息，重构 MSE 仅为 0.004857。这说明低维特征能够较好保留人脸轮廓、表情和姿态等关键信息，同时显著降低后续聚类的计算复杂度。在聚类层面，K-means++ 取得 0.6366 的 ARI，说明聚类结果与真实身份类别具有显著正相关；混淆矩阵和聚类样本展示也进一步证明了部分簇内部具有较高身份一致性。

### 6.2 不足之处

本文仍存在一定局限。首先，PCA 作为线性降维方法，主要保留整体方差信息，对身份判别特征的针对性不足。其次，K-means++ 仍属于中心类聚类算法，对非球形簇和复杂流形结构的适应能力有限。再次，ORL 数据集中姿态、表情和光照变化会造成同一对象样本分散，从而影响聚类边界的清晰程度。

### 6.3 未来工作

后续研究可从三个方向改进。第一，引入 LDA 等监督降维方法，利用身份标签学习更具判别性的低维空间。第二，尝试谱聚类、层次聚类或基于密度的聚类方法，以提高对非球形簇的适应能力。第三，结合异常检测和鲁棒特征提取方法，降低极端姿态、光照变化和噪声样本对聚类结果的干扰。

### 6.4 课程学习体会

通过大数据分析课程学习，本文不仅掌握了 PCA 降维、K-means++ 聚类等核心算法的原理和实践操作，也逐步建立了数据驱动的问题分析思维。理论学习帮助理解高维数据处理的基本逻辑，ORL 人脸数据集实验则使我更加直观地认识到，数据预处理是算法效果的基础，算法选择是否适配数据特征往往决定最终结果。

在实验过程中，从调整 PCA 维度以平衡信息保留和计算效率，到优化 K-means++ 参数以

提升聚类稳定性，每一步尝试和修正都加深了我对算法应用边界的理解。课程也让我认识到，大数据分析并不是简单使用工具，而是“理论指导实践、结果反向优化”的闭环过程。当面对指标波动和算法适配问题时，应依靠定量指标客观分析原因，而不是盲目试错。这种严谨的分析思维和问题解决能力，将成为后续学习和实践中的重要积累。

## 6.5 本章小结

总体而言，PCA 与 K-means++ 的结合能够在 ORL 人脸数据集上实现较高效、较稳定且具备可解释性的无监督聚类。该方案虽然仍有改进空间，但已经为人脸数据聚类分析提供了清晰、可复现的实验基线。

## 参考文献

- [1] Shah J H, Sharif M, Raza M, et al. A survey: Linear and nonlinear PCA based face recognition techniques[J]. The International Arab Journal of Information Technology, 2013, 10(6): 584–592.
- [2] Liu C, Zhang H. Two-dimensional PCA-based feature extraction for face recognition[J]. Neural Computing and Applications, 2016, 27(7): 1937–1946.
- [3] Chan L H, Salleh S H, Ting C M. Face biometrics based on principal component analysis and linear discriminant analysis[J]. Journal of Computer Science, 2010, 6(7): 693–699.
- [4] Li W, Wu Y. Flexible sparse robust low-rank approximation for PCA-based face recognition[J]. Journal of Visual Communication and Image Representation, 2021, 79: 103389.
- [5] Xu R, Tian Y, Wang X. A survey of k-means clustering algorithms for big data[J]. Journal of Computational Information Systems, 2015, 11(11): 3903–3912.
- [6] Zhang J, Chen S. Improved k-means algorithm for large-scale facial image clustering[J]. IEEE Access, 2018, 6: 76234–76242.
- [7] Raj P, Menon V K. Unsupervised face clustering using PCA-k-means hybrid model on ORL dataset[J]. Journal of Ambient Intelligence and Humanized Computing, 2019, 10(8): 3127–3138.
- [8] Li C, Zhang H. Robust k-means clustering against outliers for facial data analysis[J]. Neural Computing and Applications, 2020, 32(20): 16245–16256.
- [9] Kim D, Lee J. Enhanced k-means++ algorithm for facial feature clustering in high-dimensional space[J]. Journal of Visual Communication and Image Representation, 2022, 88: 103987.

## 程序清单

本文核心程序包括 ORL 图像读取、向量化、PCA 降维、K-means++ 聚类 and 指标评价。以下代码展示主要流程，实际实验中可结合图像路径和可视化函数进一步扩展。

代码 1 PCA 与 K-means++ 聚类核心流程

```
1 import numpy as np
2 from sklearn.decomposition import PCA
3 from sklearn.cluster import KMeans
4 from sklearn.metrics import adjusted_rand_score
5 from sklearn.metrics import silhouette_score
6 from sklearn.metrics import mean_squared_error
7
8 # X: shape = (400, 10304), y: true identity labels
9 X = X.astype("float32") / 255.0
10
11 pca = PCA(n_components=100, random_state=42)
12 X_pca = pca.fit_transform(X)
13 X_recon = pca.inverse_transform(X_pca)
14
15 variance_ratio = pca.explained_variance_ratio_.sum()
16 recon_mse = mean_squared_error(X, X_recon)
17
18 kmeans = KMeans(
19     n_clusters=40,
20     init="k-means++",
21     n_init=30,
22     max_iter=500,
23     tol=1e-6,
24     random_state=42,
25 )
26 labels = kmeans.fit_predict(X_pca)
27
28 ari = adjusted_rand_score(y, labels)
29 silhouette = silhouette_score(X_pca, labels)
30 sse = kmeans.inertia_
31
32 print("variance:", variance_ratio)
33 print("reconstruction mse:", recon_mse)
34 print("ARI:", ari)
35 print("silhouette:", silhouette)
36 print("SSE:", sse)
```

## 发表文章目录

无。

## 发表专利目录

无。

## 参与项目目录

科技英语写作课程实践：基于 PCA 与 K-means++ 的 ORL 人脸数据集聚类分析。