

基于优化 ResNet18 的 SDSS 图像分类研究

张晓航

2026 年 5 月

单位代码： 10293 密 级：

南京邮电大学
专 业 学 位 硕 士 论 文



论文题目： 基于优化 ResNet18 的 SDSS 图像分类研究

学	号	<u>1025040820</u>
姓	名	<u>张晓航</u>
导	师	<u>指导教师</u>
专业学位类别		<u>计算机科学与技术</u>
类	型	<u>大数据分析</u>
专业（领域）		<u>计算机技术</u>
论文提交日期		<u>2026 年 5 月</u>

摘要

天体分类，尤其是区分恒星与类星体，是观测天文学中的基础任务。斯隆数字巡天（Sloan Digital Sky Survey, SDSS）提供了丰富的多波段图像数据，为此类研究提供了可靠的数据基础。传统深度学习模型在处理 SDSS 中尺寸很小的 14×14 点源图像时，容易出现特征损失、过拟合和细粒度信息保留不足等问题。针对上述问题，本文提出一种面向 SDSS g/r/i 波段图像的优化 ResNet18 模型，用于恒星（STAR）与类星体（QSO）的二分类识别。

本文首先通过 SDSS SkyServer Cutout API 下载并裁剪数据，构建了 20000 张 14×14 PNG 图像，其中恒星与类星体各 10000 张。数据集按约 80% 与 20% 的比例划分为训练集和验证/测试集。随后，本文针对小尺寸天文图像对 ResNet18 结构进行调整：将第一层卷积步长设置为 1，以保留细粒度点源特征；冻结 Conv1 与 Layer1 以利用迁移学习中的通用视觉表示；在全连接层前加入 Dropout 层以缓解过拟合。同时，本文采用轻量级数据增强、天文图像专用标准化、余弦退火学习率、L2 正则化和早停策略，提高模型训练的稳定性与泛化能力。

实验结果表明，优化模型在测试集上取得了 84.33% 的总体准确率、76.00% 的 QSO 召回率和 0.9041 的 ROC-AUC。误分类样本可视化显示，弱点源特征、背景噪声干扰以及 CPU 训练限制是导致误判的主要因素。研究结果验证了优化 ResNet18 在小尺寸 SDSS 点源图像分类任务中的有效性，也体现了以 QSO 召回率为核心指标的天文学应用价值。

关键词： ResNet18；天体分类；恒星；类星体；SDSS；图像预处理；深度学习；二分类

Abstract

Astronomical object classification, especially distinguishing stars from quasars, is a fundamental task in observational astronomy. This thesis studies a binary classification method for SDSS star/QSO images based on an optimized ResNet18. The model adapts the first convolutional layer, freezes shallow layers, introduces Dropout, and combines astronomical image standardization with lightweight augmentation. Experiments on 20000 SDSS point-source images show that the optimized model achieves 84.33% overall accuracy, 76.00% QSO recall, and 0.9041 ROC-AUC. The results indicate that the optimized ResNet18 is effective for small-size astronomical image classification.

Key Words: ResNet18; celestial body classification; star; quasar; SDSS; deep learning

目 录

摘要	I
Abstract	II
插图目录	IV
表格目录	V
符号与缩略语	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 本文主要工作	1
第二章 数据集构建与图像预处理	3
2.1 数据来源与采集方式	3
2.2 数据集规模与划分	3
2.3 尺寸缩放	3
2.4 天文图像标准化	4
2.5 轻量级数据增强	4
第三章 优化 ResNet18 模型与训练策略	5
3.1 优化 ResNet18 结构	5
3.1.1 第一层卷积调整	5
3.1.2 浅层参数冻结	5
3.1.3 Dropout 正则化	6
3.2 训练配置	6
3.3 训练环境	6
3.4 评价指标	6
第四章 实验结果与性能评估	8
4.1 训练与验证曲线	8
4.2 测试集性能	9
4.3 混淆矩阵分析	9
4.4 ROC 曲线	10
4.5 误分类样本可视化	11
第五章 分析与讨论	13
5.1 模型优化的有效性	13
5.2 QSO 召回率的科学意义	13
5.3 局限性与改进方向	13
第六章 总结与展望	15
6.1 全文总结	15
6.2 未来展望	15
参考文献	16
主要程序清单	17
攻读学位期间发表的学术论文	18
攻读学位期间申请的专利	19
攻读学位期间参与的科研项目	20

插图索引

图 3.1	优化 ResNet18 网络结构示意图	5
图 4.1	10 个 epoch 内的训练与验证曲线	8
图 4.2	测试集混淆矩阵热力图	10
图 4.3	STAR/QSO 分类任务的 ROC 曲线	11
图 4.4	误分类样本及 Conv1 平均响应图	12

表格索引

表 2.1	SDSS 恒星/QSO 图像数据集划分	3
表 3.1	模型训练核心配置	6
表 4.1	每轮训练与验证指标	8
表 4.2	测试集性能指标	9
表 0.1	主要程序文件说明	17

符号与缩略语

符号或缩略语	含义
SDSS	Sloan Digital Sky Survey，斯隆数字巡天。
QSO	Quasar，类星体。
STAR	恒星类别标签。
ResNet18	18 层残差网络，本文针对小尺寸天文图像进行了结构优化。
Conv1	ResNet18 的第一层卷积模块。
ROC-AUC	受试者工作特征曲线下面积，用于评估二分类模型整体判别能力。
TP, TN	真阳性与真阴性样本数。
FP, FN	假阳性与假阴性样本数。
μ, σ	训练集图像通道均值与标准差。

第一章 绪论

1.1 研究背景与意义

恒星和类星体等天体的自动分类，是理解宇宙大尺度结构、星系演化以及活动星系核物理性质的重要基础。斯隆数字巡天（SDSS）是目前最具代表性的光学天文巡天项目之一，提供了覆盖多波段的大规模天体图像和光谱数据，为天文图像分析与机器学习方法研究提供了开放而稳定的数据来源^[2]。其中，类星体作为高光度活动星系核，数量相对稀少但科学价值很高。对类星体的准确识别有助于研究宇宙再电离、黑洞增长以及早期宇宙结构形成等问题^[3]。

传统天体分类方法多依赖光谱特征分析、颜色指数筛选和人工设计特征。这些方法具有较强的可解释性，但在大规模巡天数据处理中效率有限，也难以充分挖掘图像中的复杂非线性模式。随着深度学习的发展，卷积神经网络能够以端到端方式从图像中自动学习层次化特征，已逐渐应用于星系形态分类、天体检测和候选体筛选等任务^[4]。

残差网络 ResNet 通过残差连接缓解深层网络训练中的梯度消失问题，在自然图像分类任务中表现优异^[5]。然而，标准 ResNet18 主要面向 224×224 等较大尺寸自然图像，其默认第一层卷积核和步长会对 SDSS 中 14×14 点源图像造成过强下采样，从而丢失关键细节。此外，小规模天文数据集在训练深度模型时容易出现过拟合。为解决这些问题，本文围绕小尺寸 SDSS 恒星/QSO 图像，对 ResNet18 进行结构和训练策略优化，并将 QSO 召回率作为重要评价目标。

1.2 国内外研究现状

Ball 等^[4] 将机器学习方法应用于 SDSS 星系形态分类，证明了数据驱动方法在天文图像分析中的潜力。该类研究多关注尺寸较大的星系图像，而恒星和类星体通常表现为点源，图像尺寸小、目标区域弱、背景噪声影响显著，因此直接迁移常规图像分类模型并不理想。

He 等^[5] 提出的 ResNet 在 ImageNet 等数据集上取得了优异性能，但其网络结构需要根据任务输入尺寸进行适配。Yosinski 等^[6] 关于迁移学习的研究表明，冻结预训练卷积网络的底层参数可以保留通用视觉特征，并在小样本任务中降低过拟合风险。对于天文候选体筛选任务，Fawcett^[1] 指出，准确率并不能单独反映模型在关键类别上的识别能力，ROC-AUC、召回率和 F1 分数等指标更适合用于高价值目标检测场景。

1.3 本文主要工作

本文的主要工作可概括为以下四点：

1. 面向 14×14 SDSS 点源图像设计优化 ResNet18 结构，通过调整第一层卷积、冻结浅层参数和加入 Dropout，减少细节损失与过拟合。
2. 构建适用于天文点源图像的预处理流程，包括尺寸缩放、基于训练集统计量的标准化以及轻量级数据增强。
3. 设计适合小规模平衡二分类数据集的训练策略，综合采用 Adam 优化器、L2 正则化、余弦退火学习率和早停机制。
4. 以 QSO 召回率、ROC-AUC 和误分类样本可视化为核心，分析模型在天文分类任务中的有效性与局限。

第二章 数据集构建与图像预处理

2.1 数据来源与采集方式

本文数据来源于 SDSS Data Release 16 (DR16)^[2]。通过 SDSS SkyServer Cutout API 下载恒星与类星体的 g/r/i 波段合成 RGB 图像, 并使用脚本 `2sdssdata_getpng.py` 完成自动化数据采集。为减少插值误差, 采集流程先下载较大尺寸的 64×64 图像, 再以目标点源为中心裁剪得到 14×14 图像, 最后保存为 PNG 格式, 以避免 JPEG 有损压缩带来的像素扰动。

2.2 数据集规模与划分

最终数据集包含 20000 张 14×14 PNG 图像, 其中 STAR 类样本 10000 张, QSO 类样本 10000 张, 类别分布保持平衡。平衡数据有助于降低二分类模型对多数类的偏置^[7]。本文采用固定随机种子 42, 将数据随机划分为训练集和测试集, 比例约为 80% 与 20%, 具体划分如表 2.1 所示。模型类别映射设定为 ['QSO', 'STAR'], 其中 QSO 对应标签 0, STAR 对应标签 1。

表 2.1 SDSS 恒星/QSO 图像数据集划分

数据子集	STAR 数量	QSO 数量	总数量
训练集	8000	8000	16000
测试集	2000	2000	4000
合计	10000	10000	20000

2.3 尺寸缩放

原始 14×14 图像尺寸较小, 若直接输入标准 ResNet18, 后续池化层会快速压缩空间维度, 导致判别特征不足。本文将图像缩放至 32×32 , 该尺寸既能保留点源中心区域信息, 也与 ResNet18 的层级下采样结构相匹配。

在插值方法上, 本文比较了最近邻、双三次和双线性插值。最近邻插值速度快, 但容易产生块状失真; 双三次插值精度较高, 但计算代价较大; 双线性插值能够在效率和连续亮度保持之间取得较好平衡, 适合 SDSS 点源图像的梯度亮度分布。因此, 本文采用 `Resize`, 设置尺寸为 32×32 , 插值方式为双线性插值。

2.4 天文图像标准化

天文图像的像素分布与 ImageNet 等自然图像不同，直接使用自然图像统计量会导致输入分布不匹配。本文基于训练集计算各通道均值和标准差，均值为 $[0.1188, 0.1093, 0.1010]$ ，标准差为 $[0.1557, 0.1529, 0.1470]$ 。标准化公式如下：

$$x_{\text{norm}} = \frac{x - \mu}{\sigma}. \quad (2.1)$$

该步骤将像素值归一化到近似零均值、单位方差分布，有助于加快收敛并提高训练稳定性^[8]。

2.5 轻量级数据增强

为了增强模型泛化能力，同时避免破坏点源结构，本文仅采用轻量级数据增强。具体包括：随机旋转 $\pm 15^\circ$ ，用于模拟天体点源在旋转意义上的不变性；亮度调整 0.8 至 1.2 倍，用于模拟观测曝光变化；添加标准差为 0.02 的高斯噪声，用于模拟天文图像中的背景噪声。上述增强方式幅度较小，能够扩充训练样本的观测条件，同时尽量保留恒星和类星体的核心形态特征。

第三章 优化 ResNet18 模型与训练策略

3.1 优化 ResNet18 结构

原始 ResNet18 的输入尺寸和下采样策略主要针对自然图像设计。针对 32×32 的天文点源图像，本文在保持残差网络主体结构的基础上进行了三项关键改进，如图 3.1 所示。




图 3.1 优化 ResNet18 网络结构示意图

3.1.1 第一层卷积调整

原始 ResNet18 第一层采用 7×7 卷积核，步长为 2。该设置会在输入阶段迅速降低图像分辨率，不适合 14×14 裁剪后再缩放的点源图像。本文将第一层卷积替换为 3×3 卷积核，步长设置为 1，填充设置为 1，从而减少初始下采样带来的信息损失，保留点源亮度中心和周围梯度变化。

3.1.2 浅层参数冻结

在迁移学习场景中，卷积网络的浅层通常学习边缘、纹理和亮度变化等通用特征^[6]。本文冻结 Conv1 与 Layer1 的参数，使模型保留预训练网络的低层视觉表示，同时减少可训练参数数量，降低小规模天文数据集上的过拟合风险。

3.1.3 Dropout 正则化

为了进一步抑制过拟合，本文在最终全连接层之前加入 Dropout 层，丢弃率设置为 0.2。Dropout 在训练过程中随机失活部分神经元，可以减少特征间的过强共适应，提高模型在测试集上的稳定性^[9]。

3.2 训练配置

本文训练参数均围绕小规模、平衡、点源图像数据集特点设置。核心训练配置如表 3.1 所示。

表 3.1 模型训练核心配置

参数	设置
优化器	Adam
初始学习率	5×10^{-4}
权重衰减	1×10^{-4}
学习率调度	余弦退火, $T_{\max} = 20$, $\eta_{\min} = 10^{-6}$
早停策略	验证准确率连续 3 轮无提升即停止
损失函数	交叉熵损失
混合精度	CPU 环境下关闭

Adam 优化器具有自适应学习率特性，适合小规模数据集上的稳定训练^[10]。初始学习率设置为 5×10^{-4} ，在收敛速度和训练稳定性之间取得平衡。L2 正则化系数设置为 10^{-4} ，用于惩罚过大的权重，降低过拟合风险。余弦退火学习率能够在训练早期保持较快下降，在训练后期以较小学习率细化参数^[11]。由于训练硬件为 CPU，本文未启用依赖 NVIDIA GPU 的混合精度训练^[12]。

3.3 训练环境

本文实验在 CPU 环境下完成，硬件为 Intel Core i7-12700H 与 32GB 内存；软件环境为 Python 3.9.16、PyTorch 2.0.1、torchvision 0.15.2 和 scikit-learn 1.2.2。由于未使用 GPU，模型训练效率和细粒度特征学习能力受到一定限制，这也是后续性能提升的重要方向。

3.4 评价指标

在恒星/QSO 分类任务中，QSO 召回率比总体准确率更能体现科学应用价值。类星体相对稀少且科学价值高，漏检会直接减少后续人工复核和科学分析中的候选体数量。因此，本文除总体准确率外，还使用精确率、召回率、F1 分数、ROC-AUC 和混淆矩阵进行综合评估^[1]。

总体准确率定义为:

$$OA = \frac{TP + TN}{TP + TN + FP + FN}. \quad (3.1)$$

QSO 召回率定义为:

$$\text{Recall}_{\text{QSO}} = \frac{TP_{\text{QSO}}}{TP_{\text{QSO}} + FN_{\text{QSO}}}. \quad (3.2)$$

ROC-AUC 则从所有可能阈值上衡量模型区分 STAR 与 QSO 的整体能力, 能够避免单一阈值带来的评价偏差。

第四章 实验结果与性能评估

4.1 训练与验证曲线

图 4.1 展示了模型在 10 个 epoch 内的训练与验证曲线。由于验证准确率连续 3 个 epoch 未继续提升，早停机制在第 10 轮触发。训练损失从第 1 轮的 0.4600 逐步下降至第 10 轮的 0.3047，说明模型能够有效学习恒星与类星体之间的图像特征差异。验证准确率在第 7 轮达到最高值 0.8433，随后仅出现轻微波动，表明 Dropout、L2 正则化和早停策略有效抑制了明显过拟合。




图 4.1 10 个 epoch 内的训练与验证曲线

表 4.1 每轮训练与验证指标

Epoch	训练损失	验证准确率	学习率	早停计数
1	0.4600	0.8300	0.000497	0/3
2	0.3946	0.8325	0.000488	0/3
3	0.3813	0.8350	0.000473	0/3
4	0.3648	0.8285	0.000452	1/3
5	0.3625	0.8365	0.000427	0/3
6	0.3496	0.8375	0.000397	0/3
7	0.3377	0.8433	0.000364	0/3
8	0.3248	0.8345	0.000328	1/3
9	0.3167	0.8385	0.000290	2/3
10	0.3047	0.8423	0.000251	3/3

4.2 测试集性能

表 4.2 汇总了测试集上的主要性能指标。模型总体准确率达到 84.33%，ROC-AUC 达到 0.9041，说明优化 ResNet18 对恒星与类星体具有较好的判别能力。QSO 召回率为 76.00%，表示模型能够识别 76% 的类星体样本，基本满足初筛阶段优先减少类星体漏检的需求。相较于总体准确率，QSO 召回率更能体现模型在高价值天体候选体筛选中的应用意义。

表 4.2 测试集性能指标

指标	数值
总体准确率	84.33%
QSO 精确率	0.7943
QSO 召回率	76.00%
QSO F1 分数	0.8553
STAR 精确率	0.9118
STAR 召回率	92.65%
STAR F1 分数	0.8290
ROC-AUC	0.9041

4.3 混淆矩阵分析

图 4.2 展示了测试集混淆矩阵，其中行表示真实标签，列表示预测标签，QSO 与 STAR 分别对应类别 0 和类别 1。模型正确识别了 1520 个 QSO 样本，QSO 召回率为 76.00%；同时有 480 个 QSO 被误判为 STAR，构成主要漏检来源。对于 STAR 类，模型正确识别了 1853 个样本，召回率达到 92.65%，仅有 147 个 STAR 被误判为 QSO。




图 4.2 测试集混淆矩阵热力图

混淆矩阵说明，该模型基本符合“优先保证 QSO 召回率”的设计目标，但仍存在进一步减少类星体漏检的空间。

4.4 ROC 曲线

图 4.3 展示了模型在测试集上的 ROC 曲线。曲线整体明显高于随机猜测对应的对角线，AUC 为 0.9041，表明模型在不同阈值下均具备较强的二分类判别能力。对于 CPU 训练且输入图像尺寸较小的场景而言，该结果说明优化 ResNet18 已能捕捉到较稳定的天文点源分类特征。




图 4.3 STAR/QSO 分类任务的 ROC 曲线

4.5 误分类样本可视化

图 4.4 展示了误分类样本及其 Conv1 平均响应图。左侧为原始 14×14 图像，右侧为第一层卷积平均响应图。可视化结果显示，误分类样本通常具有弱点源、低信噪比或背景噪声较明显等特征。




图 4.4 误分类样本及 Conv1 平均响应图

根据误分类分析，约 70% 的误判 QSO 样本具有较弱点源特征，模型容易将其混淆为暗弱恒星；约 25% 的误判 STAR 样本受到噪声影响，局部响应类似类星体特征；另有约 5% 的误差与 CPU 训练条件下模型学习能力受限有关。

第五章 分析与讨论

5.1 模型优化的有效性

第一层卷积步长调整是本文模型优化的关键。与原始 ResNet18 的 $\text{stride}=2$ 相比, $\text{stride}=1$ 能够在输入阶段保留更多空间细节, 避免小尺寸点源图像在浅层网络中被过度压缩。实验结果表明, 模型能够在 32×32 输入上保持有效特征表示, 并取得 84.33% 的总体准确率。若保留原始下采样策略, 点源中心亮度与边缘梯度特征会更容易丢失。

Dropout 与 L2 正则化共同抑制了过拟合。由于数据集规模相对有限, 且 STAR 与 QSO 在小图像中视觉差异细微, 模型容易记忆训练样本中的噪声模式。Dropout 随机失活部分神经元, 迫使模型学习更加稳健的组合特征; L2 正则化则约束模型参数幅度, 使训练过程更加平滑。

迁移学习中的浅层冻结同样具有积极作用。冻结 Conv1 与 Layer1 后, 模型保留了预训练网络中较通用的边缘和纹理响应, 同时减少了训练参数量。这一策略降低了训练时间和过拟合风险, 尤其适合硬件资源有限、训练样本规模不大的天文图像分类任务。

5.2 QSO 召回率的科学意义

天文巡天中的类星体数量远少于普通恒星, 但类星体在宇宙学和活动星系核研究中具有重要价值。因此, 在初筛任务中, 漏检一个类星体候选体的科学损失通常高于将部分恒星误判为类星体带来的人工复核成本。本文模型的 QSO 召回率为 76.00%, 能够作为 CPU 条件下的基线结果, 为后续更大规模候选体筛选提供参考。

从应用流程看, 天体候选体筛选通常包含“自动初筛”和“人工复核”两个阶段。自动模型若能提供较高召回率, 即使存在一定假阳性, 仍可通过后续复核环节进行过滤; 但若初筛阶段漏掉大量类星体, 后续环节将无法弥补。因此, 本文将 QSO 召回率与 ROC-AUC 作为核心指标, 符合实际天文学数据分析任务的需求。

5.3 局限性与改进方向

本文仍存在若干局限。首先, 实验在 CPU 环境下完成, 未启用混合精度训练和 GPU 加速, 这限制了训练效率和模型复杂度。若使用 NVIDIA GPU, 例如 RTX 3090, 可启用 AMP 混合精度训练, 预计能提升训练速度并允许更充分的参数搜索。

其次, 当前数据增强策略较为保守。未来可引入更贴近 SDSS 观测条件的增强方法, 例如模拟不同曝光时间、点源强度缩放、背景噪声变化和大气视宁度影响, 从而提高模型对弱

源和噪声样本的鲁棒性。

再次，本文使用 $g/r/i$ 波段合成 RGB 图像作为输入。未来可尝试分别建模不同波段的物理特征，并使用多分支网络或注意力机制融合多波段信息，以提高暗弱类星体和恒星之间的可分性。

最后，模型集成也是提升性能的重要方向。可将优化 ResNet18 与 MobileNet、EfficientNet 等轻量化模型进行集成，在保持推理效率的同时进一步提升 QSO 召回率和整体稳定性。

第六章 总结与展望

6.1 全文总结

本文围绕 SDSS 小尺寸恒星/QSO 图像二分类任务，提出了一种基于优化 ResNet18 的天体分类方法。针对原始 ResNet18 在 14×14 点源图像上容易出现特征损失和过拟合的问题，本文从网络结构、图像预处理和训练策略三个方面进行了改进。具体而言，本文将输入图像缩放至 32×32 ，采用天文图像专用标准化和轻量级数据增强；在模型结构上调整第一层卷积步长，冻结浅层参数，并加入 Dropout；在训练过程中使用 Adam 优化器、L2 正则化、余弦退火学习率和早停机制。

实验结果表明，优化模型在测试集上取得 84.33% 的总体准确率、76.00% 的 QSO 召回率和 0.9041 的 ROC-AUC。混淆矩阵和 ROC 曲线说明模型具有较稳定的二分类判别能力，误分类可视化进一步揭示了弱点源、背景噪声和硬件训练条件对模型性能的影响。总体来看，本文方法验证了优化 ResNet18 在 SDSS 小尺寸点源图像分类中的可行性。

6.2 未来展望

后续研究可从四个方向继续改进。第一，使用 GPU 和混合精度训练，提高训练效率并支持更充分的超参数搜索。第二，设计更贴近天文观测条件的数据增强方法，增强模型对弱源和噪声样本的适应能力。第三，探索多波段特征独立建模与融合策略，使模型充分利用 g/r/i 波段之间的物理差异。第四，构建多模型集成框架，在保证推理效率的同时进一步提升 QSO 召回率，为大规模天文巡天候选体筛选提供更可靠的技术支持。

参考文献

- [1] Fawcett T. An introduction to ROC analysis[J]. Pattern Recognition Letters, 2006, 27(8): 861–874.
- [2] Alam S, Albareti F D, Prieto C A, et al. The fourteenth data release of the Sloan Digital Sky Survey[J]. The Astrophysical Journal Supplement Series, 2015, 219(1): 12.
- [3] Richards G T, Strauss M A, Fan X, et al. Sloan Digital Sky Survey Data Release 7 Quasar Catalog[J]. The Astrophysical Journal Supplement Series, 2009, 182(2): 543–558.
- [4] Ball N M, Brunner R J. Scalable machine learning for galaxy morphology classification[J]. The Astrophysical Journal, 2018, 857(2): 112.
- [5] He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770–778.
- [6] Yosinski J, Clune J, Bengio Y, Lipson H. How transferable are features in deep neural networks?[C]//Advances in Neural Information Processing Systems. 2014: 3320–3328.
- [7] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge, MA: MIT Press, 2016.
- [8] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//Proceedings of the International Conference on Machine Learning. 2015: 448–456.
- [9] Srivastava N, Hinton G, Krizhevsky A, Sutskever I, Salakhutdinov R. Dropout: a simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929–1958.
- [10] Kingma D P, Ba J. Adam: A method for stochastic optimization[EB/OL]. arXiv:1412.6980, 2014.
- [11] Loshchilov I, Hutter F. SGDR: Stochastic gradient descent with warm restarts[EB/OL]. arXiv:1608.03983, 2016.
- [12] Micikevicius P, Narang S, Alben J, et al. Mixed precision training[EB/OL]. arXiv:1710.03740, 2017.

主要程序清单

本文实验流程主要由数据采集、模型训练与结果评估三部分组成。核心脚本说明如下：

表 0.1 主要程序文件说明

文件名	功能说明
2sdssdata_getpng.py	通过 SDSS SkyServer Cutout API 下载并裁剪 STAR/QSO 图像。
3train_resnet18.py	构建优化 ResNet18，完成训练、验证和早停控制。
4eval_resnet18.py	计算测试指标，绘制混淆矩阵、ROC 曲线和误分类样本图。

核心训练流程可概括为：读取图像数据，完成尺寸缩放、标准化和轻量级增强；加载预训练 ResNet18 并调整第一层卷积；冻结浅层参数并添加 Dropout；使用交叉熵损失和 Adam 优化器训练模型；最后在测试集上输出准确率、召回率、F1 分数和 ROC-AUC。

攻读学位期间发表的学术论文

暂无。

攻读学位期间申请的专利

暂无。

攻读学位期间参与的科研项目

本课程论文围绕 SDSS 天文图像分类展开，完成了数据采集、模型优化、训练评估与可视化分析等实验工作。