

自监督 Vision Transformer 训练方法实验分析

以 MoCo v3 为例

An Empirical Study of Training Self-Supervised Vision Transformers
Xinlei Chen, Saining Xie, Kaiming He · ICCV 2021

An Empirical Study of Training Self-Supervised Vision Transformers

Xinlei Chen* Saining Xie* Kaiming He
Facebook AI Research (FAIR)

Code: <https://github.com/facebookresearch/moco-v3>

Abstract

This paper does not describe a novel method. Instead, it studies a straightforward, incremental, yet must-know baseline given the recent progress in computer vision: self-supervised learning for Vision Transformers (ViT). While the training recipes for standard convolutional networks have been highly mature and robust, the recipes for ViT are yet to be built, especially in the self-supervised scenarios where training becomes more challenging. In this work, we go back to basics and investigate the effects of several fundamental components for training self-supervised ViT. We

framework	model	params	acc. (%)
<i>linear probing:</i>			
iGPT [9]	iGPT-L	1362M	69.0
iGPT [9]	iGPT-XL	6801M	72.0
MoCo v3	ViT-B	86M	76.7
MoCo v3	ViT-L	304M	77.6
MoCo v3	ViT-H	632M	78.1
MoCo v3	ViT-BN-H	632M	79.1
MoCo v3	ViT-BN-L/7	304M	81.0
<i>end-to-end fine-tuning:</i>			
masked patch pred. [16]	ViT-B	86M	79.9 [†]
MoCo v3	ViT-B	86M	83.2
MoCo v3	ViT-L	304M	84.1

关键词：自监督学习 · 对比学习 · ViT · 训练稳定性

汇报主线：一篇“实证型论文”如何体现技术含量

不是提出全新模型，而是建立自监督 ViT 的训练经验与可靠基线



本次汇报的核心观点


论文价值不在“新模型”，而在系统回答：如何稳定训练自监督 Vision Transformer。

技术含量主要来自：训练曲线诊断、超参数敏感性、随机 patch projection、框架/模块消融。

最后将“未标注数据表征学习”的思想迁移到多模态稀有天体挖掘。

研究背景：为什么需要自监督视觉表示学习

核心目标：用未标注数据学习可迁移的视觉特征



为什么适合科研场景？

标注昂贵：医学影像、遥感、天文数据都存在标注成本高的问题。


数据丰富：无标签图像/观测数据远多于人工标注样本。

迁移能力：预训练表征可服务分类、检索、检测和异常发现。

论文切入点：将成熟的自监督视觉框架扩展到 ViT。

问题引入：ViT 为什么让自监督训练更困难

CNN 训练经验成熟，但 ViT 的自监督训练 recipe 仍需建立




挑战 1
大模型 + 大 batch
更容易触发不稳定

挑战 2
Transformer 缺少卷积
的局部归纳偏置

挑战 3
结果“看似可用”
但可能部分失败

方法框架：MoCo v3 如何做自监督 ViT

双分支 Siamese 结构：query encoder 学习，key encoder 用动量更新




动量更新: $f_k \leftarrow m \cdot f_k + (1 - m) \cdot f_q$

核心损失 (简化) : $L_q = -\log \exp(q \cdot k + \tau) / \sum \exp(q \cdot k_i / \tau)$

理解重点：MoCo v3 不是靠人工标签学习类别，而是通过两个增强视图的一致性学习图像表征。

核心发现：训练不稳定会被“看起来还不错”的结果隐藏

不稳定不一定导致崩溃，可能只造成 1-3% 的隐性精度下降



作者如何判断“不稳定”？

观察 kNN accuracy 曲线：训练过程中出现明显 dip，而不是平滑上升。

大 batch 并非一定更好：4096、6144 可能出现更严重的局部失败。



最终精度仍可能“不差”，因此单看最终 acc 容易误判实验。

结论：自监督 ViT 的实验分析不能只看最后一行指标。

技术含量：用训练动态诊断“部分失败”

稳定化技巧：冻结 Patch Projection 层

固定随机 patch projection 可以缓解早期梯度 spike，提升训练稳定性



为什么有效？


梯度 spike 更早出现在第一层 patch projection。

冻结第一层缩小优化空间，减少不稳定传播。

它是经验性技巧：缓解问题，但不是根本解决方案。

实验设置：从预训练到线性评估

先自监督预训练，再冻结特征训练线性分类器



骨干网络

ViT-S / ViT-B / ViT-L / ViT-H

优化策略

AdamW + batch size 4096 + 40 epoch warmup

评价协议


Linear probing: 冻结特征，只训练线性分类器

对比范围

MoCo v3、SimCLR、BYOL、SwAV; 模块消融

框架对比：MoCo v3 在 ViT 上表现更有优势

同样是自监督框架，换成 ViT 后相对表现发生变化



关键观察

在 ViT-B 上，MoCo v3 达到 76.5%，高于其他三种框架。

不同框架在 ResNet 与 ViT 上的相对优势并不完全一致。

说明“CNN 上有效的 recipe”不能直接照搬到 ViT。

因此，论文的系统性实证分析具有参考价值。

消融实验：哪些设计会影响 ViT + MoCo v3 表征质量



从位置编码、CLS token、BN head、动量系数等角度拆解模型

模块	对比设置	最佳/默认结果	启示
位置编码	sin-cos / learned / none	sin-cos 76.5%	空间先验仍有帮助
CLS token	with CLS / pool	with CLS 76.5%	输出设计影响表征
MLP heads 中 BN	with BN / without BN	with BN 76.5%	BN 可提升稳定和精度
动量编码器 m	0 / 0.9 / 0.99 / 0.999	m=0.99 76.5%	动量目标有利于学习
训练长度	300ep / 600ep	ViT-B 76.7%	大模型收益递减

消融实验的作用：不是只报告“准确率”，而是解释模型设计为什么有效、哪些组件值得保留。

应用拓展：从自然图像到多模态稀有天体挖掘

自监督预训练适合“数据多、标签少、稀有类难标注”的科研场景



总结：这篇论文可以怎么讲出“技术含量”？

一个核心问题

如何稳定训练自监督 Vision Transformer，而不是只换一个 backbone。

一个关键发现

训练不稳定可能被最终精度隐藏，需要观察训练动态与 kNN 曲线。

一个有效技巧

冻结 patch projection 可提升稳定性，但仍不是根本解决方案。

一个拓展方向

自监督多模态表征可服务稀有天体识别、检索与异常发现。

汇报时的收束句：本文不是“提出一个新模型”，而是通过系统实验建立自监督 ViT 的可靠训练经验，并为少标注科研数据挖掘提供方法启发。