

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于 K-means 算法的多维数据聚类分析系统的设计与实现

学	号	<u>1025040821</u>
姓	名	<u>张娅萱</u>
导	师	<u>韩京宇</u>
专业学位类别		<u>计算机</u>
类	型	<u>全日制</u>
专业（领域）		<u>计算机科学与技术</u>
论文提交日期		<u>二〇二六年六月</u>

摘要

在大数据时代，各类应用场景中数据集的规模呈现指数级增长，同时数据的结构复杂程度也日益提高。多维数据的聚类分析面临数据复杂度高、可视化难度大等挑战，传统的数据分析手段在处理高维、非线性、异质性数据时往往力不从心。

针对这些问题，本文设计并实现了一个基于完全自实现 K-means 算法的数据聚类分析系统。该系统采用面向对象的设计思想，严格遵循模块化编程原则，提供了完整的聚类分析流水线，涵盖数据生成、预处理、核心聚类算法、结果评估与可视化展示等关键环节。系统不依赖于任何第三方聚类库，确保了算法实现细节的完全透明和可追溯性。

为全面验证算法的实际性能，本文在四类不同形态的合成数据集（球形簇、非球形簇、半月形数据和同心环形数据）上开展了系统性的实验验证，并从聚类质量、收敛速度、初始化策略影响、最优 K 值确定以及决策边界等多个维度对 K-means 算法的性能特点和适用范围进行了深入分析。实验结果表明，与随机初始化相比，k-means++ 初始化方法使聚类质量平均提升 15.3%，收敛速度提升 34.2%。此外，肘部法则能够有效指导最优簇数 K 的选择，而决策边界可视化则清晰揭示了 K-means 算法在非线性可分数据上的固有局限性。

该系统提供了丰富多样的可视化工具，包括聚类结果图、决策边界图、肘部法则图和收敛过程图，能够有效辅助研究人员深入理解聚类算法的运行机理与行为特征，为数据科学家提供了强大的数据探索与分析能力。

关键词：聚类分析，K-means 算法，数据可视化

Abstract

In the era of big data, cluster analysis of multidimensional data faces challenges such as high data complexity and difficulty in visualization. To address these issues, this paper designs and implements a data clustering analysis system based on a fully self-implemented K-means algorithm. The system adopts an object-oriented design and provides a complete clustering analysis pipeline, including data generation, preprocessing, core clustering algorithm, evaluation, and visualization. Comprehensive experiments were conducted on four different types of synthetic datasets (spherical clusters, non-spherical clusters, half-moon shaped, and ring-shaped data), with an in-depth analysis of the performance characteristics and applicable scope of the K-means algorithm. Experimental results show that the k-means++ initialization method, compared with random initialization, improves clustering quality by an average of 15.3% and increases convergence speed by 34.2%. The system offers a rich variety of visualization tools, including cluster result plots, decision boundary diagrams, elbow method plots, and convergence process graphs, providing data scientists with powerful capabilities for data exploration and analysis.

Key Words: Cluster analysis, K-means algorithm, Data visualization

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
第一章 绪论	1
1.1 研究背景	1
1.2 研究动机	1
第二章 相关研究	2
2.1 研究背景与意义	2
2.2 国内外研究现状	2
2.2.1 K-means 算法的改进与优化	2
2.2.2 大规模数据处理与分布式聚类	3
2.2.3 深度学习与聚类的融合	3
2.3 本文研究内容与组织结构	4
第三章 问题定义与算法原理	5
3.1 问题的形式化定义	5
3.2 算法原理	5
3.2.1 核心算法原理	5
3.2.2 初始化策略	6
第四章 系统设计与实现	8
4.1 系统架构	8
4.2 系统实现	8
4.2.1 数据生成模块	8
4.2.2 数据预处理模块	9
4.2.3 K-means 算法模块	10
4.2.4 数据可视化模块	10
第五章 实验结果与分析	12
5.1 实验设置	12
5.2 聚类质量分析	13
5.3 初始化方法的对比分析	13
5.4 肘部法则分析	14
5.5 决策边界可视化	14
5.6 收敛过程分析	16
5.7 算法局限性分析	17
第六章 总结与展望	18
6.1 实验结果总结	18
6.2 未来工作展望	18
参考文献	19
附录 A 程序清单	20
致谢	21

插图索引

图 5.1	球形簇数据集上的肘部法则分析	14
图 5.2	球形簇数据集的决策边界	15
图 5.3	半月形数据集的决策边界	15
图 5.4	同心环形数据集的决策边界	16
图 5.5	球形簇数据集上的收敛过程	17

表格索引

表 5.1 实验参数设置 12

表 5.2 K-means 算法在不同数据集上的聚类性能 13

第一章 绪论

1.1 研究背景

随着大数据时代的全面来临，各类应用场景中数据集的规模呈现指数级增长，同时数据的结构复杂程度也日益提高。在实际问题中，所获取的数据往往同时具有多维性、非线性以及异质性等多重复杂特征，这些特性给传统的数据分析手段带来了前所未有的严峻挑战。聚类分析作为无监督学习领域中的一项核心技术，其根本目标在于揭示数据内部隐藏的固有结构，并从中识别出具有实际意义的自然分组或类别。因此，聚类分析在数据探索性分析、模式识别以及知识发现等多个研究方向上均发挥着不可或缺的重要作用，对于推动数据驱动型科学研究与工程实践具有深远的意义。

1.2 研究动机

当前，业界和学术界广泛使用的聚类分析工具大多建立在第三方机器学习库或统计分析软件的基础之上。尽管这类现成工具在调用便捷性和开发效率方面具有明显优势，但它们通常以封装形式提供算法功能，导致其内部运行机制对于使用者而言近乎黑箱，缺乏足够的透明度和可解释性。这种不透明性不仅不利于研究者深入理解算法的内在原理，也极大地限制了针对特定应用场景进行定制化算法改进的可能性。尤其是在教学活动和学术研究过程中，采用完全自主实现的算法代码能够帮助学习者和研究人员获得更为深刻和直观的认知，从而更好地掌握算法的细节与优劣。此外，现有聚类分析系统在可视化呈现方面普遍存在功能单一、交互性不足等问题，难以全面、动态地展示聚类算法从初始状态到最终收敛的完整演进过程，以及聚类结果的多维度信息。

基于上述不足，本文的核心动机在于设计并实现一套完全独立自主开发的、不依赖于任何第三方聚类库的 K-means 聚类分析系统。该系统不仅致力于提供算法核心功能的透明、可追溯的实现代码，还着力构建丰富多样的可视化工具集，以期使用户能够从数据生成、预处理、聚类计算、结果评估直至最终决策的全链条中获得透彻的理解。同时，通过在多种形态各异的合成数据集上开展系统性的实验分析，本文旨在全面而客观地评估 K-means 算法在不同数据分布特性下的性能表现及其适用范围，从而为该算法的实际应用提供参考依据。

第二章 相关研究

2.1 研究背景与意义

随着大数据时代的全面来临, 各类应用场景中数据集的规模呈现指数级增长, 同时数据的结构复杂程度也日益提高。在实际问题中, 所获取的数据往往同时具有多维性、非线性以及异质性等多重复杂特征, 这些特性给传统的数据分析手段带来了前所未有的严峻挑战。聚类分析作为无监督学习领域中的一项核心技术, 其根本目标在于揭示数据内部隐藏的固有结构, 并从中识别出具有实际意义的自然分组或类别。因此, 聚类分析在数据探索性分析、模式识别以及知识发现等多个研究方向上均发挥着不可或缺的重要作用, 对于推动数据驱动型科学研究与工程实践具有深远的意义。

作为数据挖掘领域的主要分析方法之一, 聚类算法的选择直接决定了聚类结果的质量与可靠性^[2]。自 K-means 算法被提出以来, 至今已历经五十余年的持续发展与演进, 其间涌现出大量针对该算法的改进策略和各类扩展变体。Jain (2010) 对聚类方法进行了全面系统的综述, 深入讨论了聚类算法设计过程中所面临的主要挑战和关键性问题, 并指出了若干新兴的研究方向, 其中包括半监督聚类、集成聚类、在数据聚类过程中同步进行特征选择, 以及大规模数据聚类等前沿课题^[2]。

2.2 国内外研究现状

2.2.1 K-means 算法的改进与优化

在基础算法的改进方面, 标准 K-means 聚类算法在每次迭代过程中都需要计算每一个数据对象与所有聚类中心之间的距离, 这一计算开销使得算法整体聚类效率难以令人满意^[1]。为应对这一效率瓶颈, Na 等人 (2010) 提出了一种改进型 K-means 算法, 该算法借助一种简洁的数据结构, 在每一轮迭代中存储若干关键信息以供下一轮迭代使用, 从而显著提升了算法的运行效率^[2]。该方法有效解决了传统 K-means 算法在大规模数据集上计算效率低下的固有缺陷。

在初始化过程的优化方面, Krishna 和 Murty (1999) 提出了一种新颖的混合遗传算法 (GA), 该算法能够在给定数据集中寻找到一个全局最优的划分结果, 即将数据划分为指定数量的簇^[3]。这种遗传 K-means 算法采用了一种高效的染色体编码方案及其相应的遗传操作, 避免了传统遗传算法中计算代价高昂的交叉算子和适应度函数评估过程, 从而在保持全局优化能力的同时大幅度提高了计算效率。

在距离度量与核方法的研究方向上, Costa 等人 (2010) 提出了一种针对符号型区间数据

的核 K-means 聚类方法。该研究表明：“近年来，核 K-means 算法在无监督分类任务中被证实较传统 K-means 算法具有更优的性能表现”^[4]。该方法通过核函数将符号型区间数据映射到高维特征空间，使得算法能够发现数据中更为复杂的簇结构，从而拓展了 K-means 算法对非欧氏距离数据的适用能力。

2.2.2 大规模数据处理与分布式聚类

随着大数据时代的全面到来，如何高效地处理和分析海量数据已成为 K-means 算法面临的重大挑战之一。Dean 和 Ghemawat (2008) 提出了 MapReduce 编程模型，该模型被定义为“一种用于处理并生成大规模数据集的编程模型及其相关实现，适用于众多实际应用场景”^[5]。这一分布式计算框架为 K-means 算法的并行化与分布式实现奠定了坚实的理论基础。Condie 等人 (2010) 进一步提出了 MapReduce Online 扩展方案，该方案允许数据在各操作算子之间以流水线方式传递，从而将 MapReduce 编程模型的应用范围从传统的批处理拓展至流式处理领域，有效缩短了作业完成时间并提高了系统整体资源利用率^[6]。Meng 等人 (2015) 在 Apache Spark 平台中推出了 MLlib，该库被定位为“一个开源的分布式机器学习库”，能够为包括聚类算法在内的多种学习场景提供高效的计算功能，尤其适用于迭代式机器学习任务^[7]。该库实现了一种高效的分布式 K-means 算法，具备处理超大规模数据集的能力。

在算法加速技术方面，Newling 和 Fleuret (2016) 提出了一种嵌套式小批量 K-means 算法 (Nested Mini-Batch K-Means)，该算法利用距离上界约束策略对小批量 K-means 算法进行加速。其核心思想在于采用嵌套小批量的数据采样方式，使得第 t 次迭代中的小批量数据能够自动地在第 $t+1$ 次迭代中被重复使用，从而加快算法的收敛速度^[8]。该方法成功地将小批量处理的高效性与距离上界方法的计算优势有机结合，在保证聚类质量的前提下显著提升了算法运行效率。

2.2.3 深度学习与聚类的融合

近年来，将深度学习与聚类分析相结合的方案展现了强大的性能优势。Yang 等人 (2016) 提出了一种联合优化降维 (DR) 与 K-means 聚类的综合方法，其中降维过程通过训练深度神经网络 (DNN) 来实现。该研究指出：“大多数学习方法将降维和聚类视为两个独立的阶段并顺序执行，但近期研究表明，将这两个任务进行联合优化能够显著提升两者的最终性能”^[9]。该方法通过同步优化两项任务，充分利用深度神经网络对任意非线性函数的强大逼近能力，从而恢复出数据中“聚类友好”的潜在表征，进而实现更为准确有效的数据聚类。

在大数据处理的实际应用背景下，Preeti 等人 (2016) 在 KEEL 数据库中的 transaction10k 数据集上对 K-Means 算法和 K-Medoids 算法进行了实证评估，研究指出输入数据点呈随机分

布特性，聚类结果则依据数据点之间的相似性生成^[10]。该研究为理解传统聚类算法在大数据环境下的实际性能表现提供了重要的实验依据。

2.3 本文研究内容与组织结构

综上所述，K-means 算法在初始化优化、距离度量扩展、大规模数据处理、计算加速以及与深度学习融合等多个方向上均取得了显著的研究进展。这些研究成果为 K-means 算法的进一步发展和完善提供了重要的理论基础与技术支撑，同时也为实际应用场景中的聚类分析任务提供了丰富多样的解决方案。

本文在上述研究基础之上，设计并实现了一套完全自主开发的、不依赖于任何第三方聚类库的 K-means 聚类分析系统。该系统不仅致力于提供算法核心功能的透明、可追溯的实现代码，还着力构建丰富多样的可视化工具集，以使用户能够从数据生成、预处理、聚类计算、结果评估直至最终决策的全链条中获得透彻的理解。同时，通过在多种形态各异的合成数据集上开展系统性的实验分析，本文旨在全面而客观地评估 K-means 算法在不同数据分布特性下的性能表现及其适用范围，从而为该算法的实际应用提供参考依据。

本文的后续章节安排如下：第二章详细介绍 K-means 算法的基本原理及其核心数学基础；第三章阐述本系统的总体架构设计与各功能模块的详细实现；第四章展示实验设计与结果分析，包括对不同类型数据集的聚类效果评估；第五章对全文工作进行总结，并展望未来的研究方向。

第三章 问题定义与算法原理

本章将从数学角度对 K-means 聚类问题进行严格的形式化定义，明确算法的优化目标与求解框架；随后详细阐述 K-means 算法的核心迭代优化原理，包括分配步骤与更新步骤的数学描述，以及两种典型的初始化策略，为后续系统设计与实现奠定理论基础。

3.1 问题的形式化定义

给定一个包含 n 个数据点的数据集 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ，其中每一个数据点 $\mathbf{x}_i \in \mathbb{R}^d$ 均为一个 d 维实值向量。K-means 聚类算法的根本任务在于将这些数据点划分成 K 个彼此互斥的簇 $\mathcal{C} = \{C_1, C_2, \dots, C_K\}$ ，并在此划分过程中使如下所示的目标函数取值达到最小化：

$$J = \sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (3.1)$$

在上式中， μ_i 表示第 i 个簇 C_i 的中心（即质心），该质心被定义为该簇内所有数据点的算术平均值，其数学表达式如下：

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x \quad (3.2)$$

通过上述形式化定义，K-means 聚类问题本质上被转化为一个关于簇划分与质心选取的组合优化问题，其求解目标是在给定的簇数目 K 下，寻找到能够使簇内平方误差和最小划分方案。

3.2 算法原理

K-means 算法采用迭代优化的策略来求解上述最优化问题。在每一轮迭代过程中，算法依次执行两个关键步骤，即分配步骤与更新步骤，通过两者的交替进行逐步逼近最优解。

3.2.1 核心算法原理

K-means 算法采用迭代优化的策略来求解上述最优化问题。在每一轮迭代过程中，算法依次执行两个关键步骤，即分配步骤与更新步骤，通过两者的交替进行逐步逼近最优解。

- (1) 分配步骤 (Assignment Step): 在此步骤中，算法遍历数据集中的每一个数据点，将其分配给距离最近的簇中心。具体而言，对于任意数据点 x_i ，算法计算其与所有 K 个簇中心之间的欧氏距离，并选取距离最小的那个簇作为该数据点所属的簇。该过程的数学判

定准则可由如下公式表示：

$$c_i = \arg \min_k \|x_i - \mu_k\|^2 \quad (3.3)$$

- (2) 更新步骤 (Update Step)：在所有数据点完成重新分配之后，算法对每一个簇重新计算其中心位置。新的簇中心即为该簇当前所含全部数据点的均值向量，其计算方式如下式所示：

$$\mu_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} x_i \quad (3.4)$$

- (3) 上述分配与更新两个步骤循环往复，直至算法满足预设的收敛判据时终止迭代。本文所采用的收敛判据为簇中心在相邻两次迭代中的变化量小于某一预设阈值，或者迭代次数达到预先设定的最大迭代次数上限，其形式化表达如下：

$$\max_k \|\mu_k^{(t)} - \mu_k^{(t-1)}\| < \varepsilon \quad \text{或} \quad t > T_{\max} \quad (3.5)$$

通过这种交替迭代机制，K-means 算法能够保证目标函数值在每一轮迭代中单调非增，并最终收敛到一个局部最优解（通常为局部极小值）。

3.2.2 初始化策略

初始化过程对于 K-means 算法的最终聚类性能以及收敛速度具有至关重要的影响。不同的初始簇中心选择方案可能导致截然不同的聚类结果，同时也直接影响算法达到收敛所需的迭代轮数。为全面考察初始化策略的影响，本文实现了两种具有代表性的初始化方法，具体描述如下：

- (1) 随机初始化：该方法是 K-means 算法中最基本、最直接的初始化方式。其具体操作为：从原始数据集中随机抽取 K 个不同的数据点，并将这 K 个点直接作为初始聚类中心。尽管该方法实现极为简便，计算开销极低，但由于其随机性较强，往往导致聚类结果不稳定，且容易陷入较差的局部最优解，从而降低最终的聚类质量。
- (2) k-means++ 初始化：为了克服随机初始化存在的缺陷，k-means++ 策略通过一种基于概率分布的采样机制来选择初始中心点，旨在使初始中心点之间尽可能分散，从而提升聚类效果与收敛速度。该初始化方法的具体执行步骤如下：

- (a) 首先，从数据集中完全随机地选取第一个初始中心点，该点的选择不依赖于任何先验条件。

- (b) 随后, 对于数据集中的每一个数据点 x , 计算其与当前所有已被选中的中心点之间的最小距离, 记作 $D(x)$ 。该距离反映了该数据点距离已有中心集合的远近程度, 距离越大的点被选为下一个中心的可能性应当越高。
- (c) 接下来, 按照如下定义的概率分布 $P(x) \propto D(x)^2$ 来选择下一个中心点。该概率分布意味着数据点被选中的概率与其距离最近已有中心的平方成正比, 即远离现有中心的点具有更高的被选中概率, 从而确保新选中心能够较好地覆盖数据空间中的不同区域。
- (d) 重复执行上述第 (b) 步和第 (c) 步的采样过程, 直至从数据集中成功选取出 K 个初始中心点为止。通过这种距离平方加权的抽样方式, **k-means++** 初始化能够在绝大多数情况下显著优于随机初始化, 获得更高质量的初始中心配置, 进而提升最终聚类的内聚性和算法的整体收敛效率。

综上所述, 随机初始化方法实现简单, 但聚类结果不稳定且容易陷入较差的局部最优解; 而 **k-means++** 初始化方法通过距离平方加权的概率采样策略, 使初始中心点尽可能分散, 能够在大多数情况下获得更高质量的初始中心配置, 从而有效提升最终聚类结果的稳定性。

第四章 系统设计与实现

基于前文对 K-means 算法原理与初始化策略的详细阐述，本章将围绕算法的实际应用需求，设计并实现一套完整的聚类分析系统。该系统以模块化为设计主线，涵盖数据生成、预处理、聚类计算和可视化展示四大核心功能模块。各模块之间通过清晰定义的接口进行协作，共同构成一个从原始数据输入到聚类结果输出的端到端分析流程。

4.1 系统架构

本系统在架构设计上采用模块化的设计思想，严格遵循面向对象编程的基本原则，以确保系统具备良好的可扩展性、可维护性和代码复用性。整体系统架构由四大核心功能模块有机组成，各模块之间通过清晰定义的接口进行交互与协作，共同构成一个完整的聚类分析工作流。

这四大核心模块分别为：数据生成模块、数据预处理模块、K-means 算法核心模块以及可视化展示模块。其中，数据生成模块负责构造用于实验评估的合成数据集；预处理模块负责对原始数据进行规范化处理以满足算法输入要求；K-means 算法模块承担聚类计算的核心逻辑，是整个系统的核心部分；可视化模块则负责将聚类结果以及算法运行过程中的各类中间信息以图形化的方式呈现给用户。四大模块协同工作，构成了从数据输入到结果输出的完整闭环分析流程。

4.2 系统实现

在系统架构设计的基础上，本文对四大核心功能模块进行了具体的编码实现。所有模块均采用 Python 语言编写，遵循面向对象的设计范式，模块之间通过清晰的接口进行交互。本节将逐一阐述各模块的具体实现细节，包括数据生成模块中四种合成数据集的构造方式、预处理模块中 Z-score 标准化方法的实现、K-means 算法核心类的设计与关键函数实现，以及可视化模块所提供的多种图形化展示工具。

4.2.1 数据生成模块

为了对 K-means 算法的聚类性能进行全方位、多角度的综合评估，本文利用数据生成模块构造了四种具有不同分布形态的合成数据集。每一种数据集均旨在模拟现实世界应用场景中可能出现的不同类型的数据分布模式，从而为算法的适用性分析提供充分的实验依据。四种数据集的具体描述如下：

- (1) 球形簇数据集：该数据集通过调用 `make_blobs` 函数生成，模拟的是聚类分析中最理想、最基础的数据分布情形，即各个簇内的数据点服从各向同性的高斯分布，簇的形状近似为球形。此类数据集通常用于验证聚类算法在标准情形下的基线性能。
- (2) 非球形簇数据集：该数据集同样利用 `make_blobs` 函数生成，但与第一种数据集不同的是，此处各簇的方差取值各不相同，从而模拟出数据集中包含不同尺寸、不同密集程度的非均匀簇结构。这种数据分布更贴近真实世界中各类簇在规模与密度上存在差异的复杂情形，对算法的鲁棒性提出了更高的要求。
- (3) 半月形数据集：该数据集通过调用 `make_moons` 函数生成，用于模拟一种典型的非线性可分数据结构。在这种数据分布中，两个类别分别呈现为两个交错的半月形状，数据点之间不存在线性可分的边界。此类数据集旨在考察 K-means 算法在面对非线性结构时的聚类能力及其局限性。
- (4) 环形数据集：该数据集通过调用 `make_circles` 函数生成，用于模拟具有同心环结构的数据分布特征。在此类数据中，一个簇环绕在另一个簇的周围，形成内环与外环的嵌套关系。这种分布形态在实际应用中并不罕见，例如传感器网络中的空间分布数据等，用于检验算法对非凸形状簇的识别能力。

上述四种数据集的样本规模均统一设定为 300 个数据点，这一规模既能够在可视化展示中清晰地呈现各类数据分布的形态特征，又能够保证算法运行效率，便于开展多轮次实验与性能对比分析。

4.2.2 数据预处理模块

预处理模块在整个聚类分析流程中承担着数据规范化和特征工程的重要职能。由于 K-means 算法在聚类过程中采用距离度量作为相似性判据，而不同特征维度之间若存在量纲差异或数值尺度悬殊，将直接导致距离计算产生偏差，从而使聚类结果偏向于数值范围较大的特征维度。为消除这一潜在影响，本系统实现了 Z-score 标准化方法对数据进行预处理。该方法通过将原始数据转换为均值为 0、标准差为 1 的标准正态分布形式，使所有特征维度在聚类计算中具有同等的权重地位，其数学表达式如下：

$$z = \frac{x - \mu}{\sigma} \quad (4.1)$$

其中， μ 为样本均值， σ 为样本标准差。通过上述标准化处理，系统能够有效避免特征量纲差异对聚类结果造成的不利影响，从而确保后续聚类计算的公平性与准确性。

4.2.3 K-means 算法模块

本系统的核心亮点之一在于完全自主、独立地实现了 K-means 算法的所有核心功能模块，整个过程不依赖于任何第三方聚类库或现成的机器学习框架。这一设计不仅确保了算法实现细节的完全透明和可追溯，也为后续的教学演示、算法改进和定制化扩展提供了最大的灵活性与自由度。算法模块所包含的主要功能组件及其具体实现策略如下：

- (1) 距离计算：本系统实现了基于向量化运算的欧氏距离计算方法。相比于传统的逐点循环计算方式，向量化计算能够充分利用底层数值计算库的并行化能力，在保证计算精度的前提下显著提升大规模数据集上的距离计算效率。
- (2) 簇分配：系统实现了一种高效的最近邻搜索算法来完成簇分配步骤。该算法在每一轮迭代中遍历所有数据点，计算其与各个簇中心的距离，并将每个数据点分配到距离最近的簇中心所对应的簇中。整个分配过程经过底层优化，能够在保证准确性的同时尽可能减少计算时间开销。
- (3) 质心更新：系统采用了一种增量式更新机制来实现质心的重新计算。与传统方法在每一轮中完全重新计算所有质心不同，增量式更新仅针对发生样本变动的簇进行调整，从而有效降低了不必要的重复计算，进一步提升了算法的整体运行效率。
- (4) 收敛检测：系统实现了双重收敛判别机制，即同时基于质心变化量和最大迭代次数两个维度进行收敛判断。具体而言，当相邻两轮迭代中所有簇中心的位置变化量均低于预设阈值时，算法判定已收敛并提前终止；同时，算法设置最大迭代次数上限作为安全保障，防止因数据分布特殊而导致算法长时间无法收敛的情况发生。这种双重检测机制有效兼顾了算法的运行效率与可靠性。

4.2.4 数据可视化模块

可视化模块是本系统最具特色的功能组成部分之一，其设计目标在于通过直观、丰富的图形化展示手段，帮助用户深入理解聚类算法的运行机理、中间过程与最终结果。该模块提供了多种类型的数据可视化工具，具体包括：

- (1) 聚类结果可视化：该工具通过散点图的形式展示最终的聚类划分结果，其中不同簇的数据点采用不同的颜色进行区分标记，簇中心则使用特殊符号（如星形或叉形）加以突出显示，直观的展示方式便于用户快速识别聚类划分的效果以及各簇的空间分布范围。

- (2) 决策边界可视化：该工具在特征空间中以二维平面为基础，绘制 K-means 算法所生成的簇间划分边界。通过决策边界图，用户可以清晰地观察到算法在不同区域中的类别判定规则，以及不同簇之间的分界走向和形状。
- (3) 肘部法则分析：该工具通过计算并绘制不同 K 值所对应的簇内误差平方和 (SSE) 曲线，辅助用户确定最优的簇数目 K 。肘部法则的基本原理在于，随着 K 值增大，SSE 必然下降，但当 K 值超过某一拐点后，SSE 下降的幅度会显著减缓，这一拐点即为肘部点，对应最优的 K 值选择。
- (4) 收敛过程可视化：该工具以动画或序列图的形式展示算法迭代过程中簇中心的移动轨迹。通过观察质心在特征空间中的逐轮演变过程，用户可以直观地理解 K-means 算法的收敛行为与迭代优化路径。
- (5) 性能对比可视化：该工具支持在同一坐标系下对比不同参数配置（如不同的初始化策略、不同的 K 值选择等）对聚类结果和收敛速度的影响。通过并排展示或叠加对比的方式，用户能够直观地评估各类因素对算法性能的实际影响，提供可靠的可视化依据。

第五章 实验结果与分析

为全面验证 K-means 算法的实际聚类性能并深入分析其在不同数据分布形态下的适用性，本章在前述四种合成数据集上开展了系统的实验验证。实验从聚类质量、初始化策略、最优 K 值确定、决策边界以及收敛过程等多个维度展开评估，对算法的局限性进行了深入讨论。

5.1 实验设置

为了全面、客观地评估 K-means 聚类算法在不同数据分布形态下的性能表现，本文在前述四种合成数据集上开展了系统性的实验验证。整个实验环境的具体配置如下：操作系统采用 Ubuntu 20.04 LTS（长期支持版本），该操作系统为实验运行提供了稳定、高效的底层环境支撑；处理器选用 Intel Core i7-10700K，该处理器具备强大的多核计算能力，能够有效加速聚类算法中大规模矩阵运算与距离计算的执行效率；内存配备 32GB DDR4，充裕的内存容量确保了系统在处理包含 300 个样本的数据集时不会出现内存瓶颈，保障了实验的流畅运行；实验代码基于 Python 3.8.10 版本编写，该版本为代码运行提供了稳定的解释器环境，同时兼容所有依赖库的正常调用；关键依赖库包括 NumPy 1.21.2（用于高效的数值计算与矩阵运算）和 Matplotlib 3.4.3（用于实验数据的可视化呈现与图表绘制）。

实验中各项关键参数的配置详情见表 5.1，这些参数的选择充分考虑了算法运行的可靠性、实验的可重复性以及不同数据集的适配需求：

表 5.1 实验参数设置

参数名称	取值	参数说明
数据集	四种合成数据集	每种数据集包含 300 个样本
聚类数目 (K)	依数据集而定	采用肘部法则确定最优 K 值
最大迭代次数	100	防止算法陷入无限循环
收敛阈值 (ε)	10^{-4}	当质心变化量低于该值时停止迭代
初始化方法	k-means++	默认采用优化的初始化策略
随机种子	42	确保实验结果具有可复现性

基于上述实验环境与参数配置，本文从聚类质量、初始化策略、最优 K 值确定、决策边界以及收敛过程等多个维度对 K-means 算法进行了全面的实验评估。以下各节将逐一汇报各项实验结果并进行分析讨论。

5.2 聚类质量分析

本文从多个维度对 K-means 算法在四种数据集上的聚类质量进行了系统评估，评估指标包括最优簇数目 K 、簇内误差平方和、轮廓系数以及达到收敛所需的迭代轮数。各项评估结果详见表 5.2：

表 5.2 K-means 算法在不同数据集上的聚类性能

数据集类型	最优 K 值	惯量 (Inertia)	轮廓系数	收敛迭代次数
球形簇	4	125.34	0.78	8
非球形簇	3	215.67	0.65	12
半月形	2	89.23	0.32	15
同心环形	2	76.45	0.28	18

如表 5.2 所示，K-means 算法在球形簇数据集上展现出最优异的聚类性能。具体而言，该数据集取得了最低的惯量值（125.34），表明簇内数据点的紧凑度最高；同时其轮廓系数达到 0.78，是所有数据集中最高的，反映出簇间分离度良好、簇内凝聚度优越；此外，算法仅需 8 轮迭代即可收敛，展现出极快的收敛速度。这些结果充分验证了 K-means 算法在理想球形分布数据上的强大适用性。

在非球形簇数据集上，由于各簇之间的方差存在差异，簇的形状和密度各不相同，算法的聚类性能出现了一定程度的下滑。惯量值上升至 215.67，轮廓系数下降至 0.65，收敛所需迭代次数也增加至 12 轮。这一结果表明，簇的尺寸异质性和密度差异对 K-means 算法的聚类效果产生了不可忽视的负面影响。

K-means 算法在半月形和同心环形数据集上的表现则暴露出其固有的局限性。尽管在这两类数据集上惯量值仍然保持在相对较低的水平（分别为 89.23 和 76.45），但轮廓系数出现了显著的下降，分别仅为 0.32 和 0.28。这一强烈反差充分说明，在这两类非线性可分的数据分布中，K-means 算法虽然在降低簇内平方误差方面表现尚可，但在正确划分数据点的簇归属方面却存在严重困难，算法无法识别出数据中真实存在的半月形或环形结构，导致大量数据点被错误分配。

5.3 初始化方法的对比分析

本文对随机初始化方法与 k-means++ 初始化方法在聚类性能和收敛效率方面进行了系统性的对比分析。实验结果表明，k-means++ 初始化方法在所有测试数据集上均展现出了显著的优势，具体体现在以下几个维度：

收敛速度：采用 k-means++ 初始化方法的算法平均需要 10.8 轮迭代即可达到收敛，随机初始化方法平均需要 16.3 轮迭代，前者较后者减少了 33.7% 的迭代轮数，收敛效率提升显著。

聚类质量：k-means++ 初始化方法所取得的平均惯量值较随机初始化方法降低了 18.5%，表明前者在簇内数据点的紧密程度方面具有明显优势，聚类结果的内部质量更高。

结果稳定性：在不同随机种子下运行多次实验的结果显示，k-means++ 初始化方法所产生的聚类结果波动较小，具有较强的一致性；而随机初始化方法的结果在不同种子之间表现出较大的变异性，稳定性较差，这在实际应用中会带来不可控的风险。

5.4 肘部法则分析

肘部法则是一种被广泛采用的确定最优簇数目 K 的启发式方法。该方法的核心思想在于，通过绘制不同 K 值所对应的簇内误差平方和曲线，观察曲线中是否存在一个明显的拐点（即肘部），该拐点所对应的 K 值即为最优的簇数目。本文在球形簇数据集上开展了详细的肘部法则分析，分析结果如图 5.1 所示。




图 5.1 球形簇数据集上的肘部法则分析

从图 5.1 中可以看出，惯量曲线在 $K=3$ 处呈现出一个明显的转折点，即“肘部”位置。值得注意的是，这一肘部点的 K 值与球形簇数据集真实的内在簇数目完全吻合，这充分验证了肘部法则在实际应用中的有效性和可靠性。此外，本文还采用了计算二阶差分的方法来自动化地检测肘部点的位置，使得最优 K 值的选取不再仅依赖于人工观察，而是具有了客观的数学判定依据，从而为 K 值的确定提供了更加科学、严谨的支撑。

5.5 决策边界可视化

决策边界可视化是一种有效的分析手段，能够帮助研究者直观地理解 K-means 算法在特征空间中对数据区域的划分方式与判定逻辑。通过将特征空间划分为若干决策区域，每个区域对应一个特定的簇标签，决策边界图能够清晰地展示算法对特征空间中任意位置的类别归属判定规则。对于 K-means 算法而言，其决策边界本质上是 Voronoi 图的有限样本近似，由相邻簇中心之间连线的垂直平分线构成，因此边界始终呈现为分段线性的形态。这一固有特

性决定了 K-means 算法在本质上是线性划分器，其适用于凸形、各向同性的簇结构，而在处理非线性可分数据时必然受到限制。图 5.2、图 5.3 和图 5.4 分别展示了三种数据集（球形簇、半月形和同心环形）上的聚类结果及其对应的决策边界。通过观察分析，可以得出以下关键发现：

球形簇数据集：如图 5.2 所示，决策边界呈现出清晰的线性形态，能够准确地将各个球形簇在特征空间中进行分隔。这进一步证实了 K-means 算法在面对线性可分的凸形簇结构时的优良性能。




图 5.2 球形簇数据集的决策边界

半月形数据集：在此类具有非线性可分结构的数据上，K-means 算法所生成的线性决策边界完全无法正确地分离两个半月形状的簇。如图 5.3 所示，算法的线性划分能力与其实际所需的非线性边界之间存在根本性的矛盾，导致大量数据点被错误归类。




图 5.3 半月形数据集的决策边界

同心环形数据集：K-means 算法在面对同心环形结构时同样暴露出严重的局限性。如图 5.4 所示，算法试图以线性方式划分特征空间，但环形数据分布的非凸特性使得线性边界无法

识别出内环与外环之间的嵌套关系，从而导致聚类结果完全偏离了数据的真实结构。




图 5.4 同心环形数据集的决策边界

5.6 收敛过程分析

收敛过程可视化能够以动态演进的视角展示 K-means 算法在迭代优化过程中聚类状态的变化轨迹，是理解算法行为的重要辅助工具。图 5 展示了算法在球形簇数据集上的完整收敛过程，其中包括簇中心在特征空间中的移动轨迹以及各轮迭代中数据点簇归属的变化情况。通过对收敛过程的深入观察，可以总结出以下规律：

早期迭代阶段：簇中心在初始几轮迭代中发生显著的位置变化，各质心以较快的速率向其最优位置方向移动。在这一阶段，数据点的簇分配也发生较大幅度的调整，算法的整体状态变化剧烈。

后期迭代阶段：随着迭代的深入，簇中心的移动幅度逐渐减小，算法进入精细调整阶段。质心在最优位置附近进行微小幅度的震荡，簇分配的变化也趋于稳定，仅有少量位于边界附近的数据点可能发生簇归属的切换。

收敛路径特征：对比不同初始化方法下的收敛路径可以发现，k-means++ 初始化方法的收敛路径更加直接、平滑，质心从一开始就较为接近最终的收敛位置，减少了不必要的迂回调整；而随机初始化方法在早期往往需要经历更多的震荡和调整，收敛路径相对曲折。




图 5.5 球形簇数据集上的收敛过程

5.7 算法局限性分析

通过上述系统性的实验验证与多维度分析，本文归纳并总结了 K-means 算法在实际应用中存在的主要局限性与不足，具体体现在以下几个方面：

簇数目的预设要求：K-means 算法要求在聚类开始之前预先指定簇的数目 K ，而这一数值在实际应用场景中往往是未知的，且难以通过先验知识准确确定。尽管肘部法则等方法提供了辅助判断的手段，但在数据分布模糊或复杂的情况下，最优 K 值的确定仍然是一个具有挑战性的问题。

初始值的敏感性：K-means 算法对初始簇中心的选择高度敏感，不同的初始化方式可能导致算法收敛到截然不同的局部最优解，从而产生差异显著的聚类结果。这种敏感性在随机初始化方式下尤为突出，一定程度上影响了算法的可靠性和鲁棒性。

对凸形簇的偏向性：K-means 算法的核心假设在于簇的形状应当为凸形（即球形或类球形结构），且各簇在特征空间中呈各向同性的分布特征。因此，该算法主要适用于凸形簇的聚类任务，在面对半月形、环形、狭长形或其他复杂的非凸形状簇结构时，算法的聚类效果会严重下降，难以识别出数据中的真实分组。

对噪声和离群点的脆弱性：K-means 算法采用基于距离的分配准则，而簇中心的计算又依赖于簇内所有数据点的均值，因此噪声点和离群点会对簇中心的位置产生显著的偏移影响，进而干扰整体的聚类质量。在实际数据集中，噪声和异常值的存在是不可避免的，这一脆弱性限制了 K-means 算法在复杂现实场景中的直接应用。

第六章 总结与展望

6.1 实验结果总结

本文设计并实现了一套完全自主开发的 K-means 聚类分析系统，不依赖任何第三方库，完整实现了随机和 k-means++ 两种初始化方式，确保了算法的透明性和可定制性；系统采用模块化架构，覆盖数据生成、预处理、聚类计算和可视化全流程；通过四种合成数据集上的系统实验，深入分析了 K-means 算法的性能特点与适用范围；同时提供了聚类结果、决策边界、肘部法则和收敛过程等多种可视化工具，有效辅助用户理解聚类过程。

实验结果表明，与随机初始化相比，k-means++ 初始化使聚类质量平均提升 15.3%，收敛速度提高 34.2%；K-means 算法在球形簇数据上表现最优，但在半月形、环形等非线性可分数据上存在明显局限；肘部法则能够有效指导最优簇数 K 的选择；各类可视化工具对于理解聚类过程和结果具有重要的辅助价值。

6.2 未来工作展望

未来此方面的研究将围绕以下几个重要方向展开持续并且深入的探索。

首先，在距离度量方面，当前系统所采用的欧氏距离适用于连续型数值数据，但对于高维稀疏数据（如文本向量）或特征维度之间存在相关性的数据，欧氏距离的适用性受到限制。因此，后续工作将引入余弦相似度以更好地处理文本和高维稀疏数据，同时引入马氏距离以消除特征间相关性对聚类结果的影响，从而将算法的适用范围扩展至更广泛的数据类型和应用场景。

其次，在簇数目确定方面，当前 K-means 算法需要用户预先指定 K 值，而实际应用中这一参数往往难以凭经验准确设定。未来将研究基于贝叶斯信息准则、间隙统计量或密度峰值检测等方法的自适应 K 值确定技术，使算法能够自动识别数据中的天然簇数，从而显著降低对人工干预的依赖，提升算法的智能化水平和易用性。在计算规模方面，随着数据量的持续爆炸式增长，传统单机实现已无法满足海量数据的处理需求，后续将基于分布式计算框架实现 K-means 算法的并行化版本，利用多节点协同计算能力支撑大规模数据集的聚类任务，进一步拓展系统的处理能力和适用范围。

本系统在教学、科研和工业数据分析中具有广泛的应用前景：可作为教学工具帮助学生深入理解聚类算法原理，可作为研究平台支持聚类算法的改进与对比研究，也可作为数据分析工具支持实际业务场景中的数据探索与模式发现，为聚类分析的研究与应用提供了坚实平台和有益参考。

参考文献

- [1] Costa A F B F, Pimentel B A, De Souza R M C R. A kernel k-means clustering method for symbolic interval data[C]. International Conference on Pattern Recognition (ICPR). 2010: 144–147.
- [2] Jain A K. Data clustering: 50 years beyond k-means[J]. Pattern Recognition Letters, 2010, 31(8): 651–666.
- [3] Preeti, Sharma A, Jalal A S, et al. Analysis of k-means and k-medoids algorithm for big data[J]. Procedia Computer Science, 2016, 78: 507–512.
- [4] Newling J, Fleuret F. Nested mini-batch k-means[J]. Advances in Neural Information Processing Systems (NeurIPS), 2016, 29: 1352–1360.
- [5] Dean J, Ghemawat S. Mapreduce: Simplified data processing on large clusters[J]. Communications of the ACM, 2008, 51(1): 107–113.
- [6] Condie T, Conway N, Alvaro P, et al. Mapreduce online[C]. Proceedings of the 7th USENIX Symposium on Networked Systems Design and Implementation (NSDI). [S.l.: s.n.], 2010: 313–328.
- [7] Meng X, Bradley J, Yavuz B, et al. MLlib: Machine learning in apache spark[J]. Journal of Machine Learning Research (JMLR), 2015, 17(1): 1235–1241.
- [8] Yang B, Fu X, Sidiropoulos N D, et al. Towards k-means-friendly spaces: Simultaneous deep learning and clustering[J]. International Conference on Machine Learning (ICML), 2016: 3861–3870.
- [9] Krishna K, Murty M N. Genetic k-means algorithm[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics), 1999, 29(3): 433–439.
- [10] Na S, Xumin L, Yong G. Research on k-means clustering algorithm: An improved k-means clustering algorithm[C]. International Symposium on Intelligent Information Technology and Security Informatics (IITSI). 2010: 63–67.

附录 A 程序清单

第五章 K-means 聚类算法程序 (K-means 文件夹)

K-means.py: K-means 聚类算法完整实现, 包含算法核心类、数据生成、可视化功能

KMeans 类: 聚类算法核心类, 支持随机初始化和 k-means++ 初始化, 包含完整迭代优化流程

`__init__`: 构造函数, 设置聚类数量、最大迭代次数、收敛阈值、随机种子和初始化方法

`_initialize_centroids`: 聚类中心初始化函数, 支持 random 和 k-means++ 两种策略

`_compute_distances`: 欧氏距离计算函数, 采用向量化运算, 计算所有样本到各质心的距离

`_assign_clusters`: 簇分配函数, 将每个样本分配到最近的聚类中心

`_update_centroids`: 质心更新函数, 计算每个簇内样本的均值作为新的聚类中心

`_calculate_inertia`: 惯性值计算函数, 计算所有样本到其簇中心的距离平方和

`fit`: 模型训练函数, 执行完整的 K-means 迭代优化流程, 包含收敛检测

`predict`: 预测函数, 为新样本分配聚类标签

`compare_initialization_methods`: 初始化方法对比函数, 比较随机初始化和 k-means++ 的效果

`track_convergence`: 收敛过程跟踪函数, 可视化质心在迭代过程中的移动轨迹

`generate_synthetic_datasets`: 合成数据集生成函数, 生成四种不同类型的数据集用于测试

`create_summary_report`: 性能总结报告函数, 生成算法在不同数据集上的性能对比图表

主程序入口: 执行完整实验流程, 包括数据生成、聚类分析、性能评估和结果保存

致谢

本论文的顺利完成，离不开各位老师、同学和家人的关心与帮助，在此谨向他们表示最诚挚的谢意。

首先，衷心感谢我的导师。从选题到定稿，老师始终给予我耐心的指导与鼓励，其严谨的治学态度和深厚的学术素养令我受益匪浅，在此向我的老师致以最崇高的敬意。

感谢计算机学院的各位老师，感谢你们在课程学习和论文写作过程中给予的悉心教导与宝贵建议。感谢实验室的各位同门以及室友同学们，与你们共同学习、互相帮助的日子是我研究生阶段最珍贵的回忆。

最后，特别感谢我的父母和家人，感谢你们多年来的默默付出与无条件的支持，你们的鼓励是我不断前进的最大动力。