

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于聚类的电子商务客户细分研究

学 号 1025040822

姓 名 赵晨洁

导 师 陈教授

专业学位类别 计算机

类 型 全日制

专业（领域） 计算机科学与技术

论文提交日期 二〇二六年六月

摘要

电子商务平台积累了大量客户消费数据，如何从无标签数据中识别具有相似购买特征的客户群体，是精准营销和个性化推荐的重要基础。客户细分属于无监督学习任务，其结果应同时满足聚类质量和业务可解释性要求。

本文以 UCI Wholesale Customers 数据集为对象，对 K 均值聚类 (K-Means)、凝聚层次聚类和基于密度的空间聚类 (DBSCAN) 三种经典方法进行比较研究。该数据集包含 440 条客户年度消费记录，涵盖六类商品消费特征。首先采用 Z-score 标准化处理原始数据；随后在统一实验条件下构建三类聚类模型，并采用轮廓系数、Calinski-Harabasz 指数和 Davies-Bouldin 指数进行评价。

实验结果表明，K-Means 在轮廓系数和 Calinski-Harabasz 指数上取得较高得分，并获得最低的 Davies-Bouldin 指数，能够形成相对紧凑且边界较清晰的客户群体。凝聚层次聚类能够提供客户群体之间的层次关系，但整体聚类质量弱于 K-Means。DBSCAN 可识别噪声点，但在当前数据集上难以形成多个稳定的客户群体。研究表明，聚类方法的选择应结合数据分布特征和实际业务需求；对于当前客户消费数据，K-Means 可作为较为适合的基础客户细分方法。

关键词：客户细分，电子商务，K 均值聚类，密度聚类

Abstract

E-commerce platforms accumulate large volumes of customer consumption data. Identifying customer groups with similar purchasing characteristics from unlabeled data is important for precision marketing and personalized recommendation. Customer segmentation is an unsupervised learning task that requires both reliable clustering quality and practical business interpretability.

This thesis uses the UCI Wholesale Customers dataset to compare three classical methods: K-means clustering, agglomerative clustering, and density-based spatial clustering (DBSCAN). The dataset contains 440 annual customer consumption records with six product-related features. Z-score standardization is applied before clustering, and the three methods are evaluated under a unified experimental setting using the Silhouette Coefficient, Calinski–Harabasz Index, and Davies–Bouldin Index.

The results show that K-means achieves higher Silhouette Coefficient and Calinski–Harabasz Index values, together with the lowest Davies–Bouldin Index. It produces relatively compact customer groups with clearer boundaries. Agglomerative clustering provides hierarchical relationships among customer groups, but its overall clustering quality is weaker than that of K-means. DBSCAN can identify noise points but does not form multiple stable customer groups on the selected dataset. The results indicate that clustering methods should be selected according to data characteristics and business requirements, and K-means is a suitable baseline method for the current customer segmentation task.

Key Words: Customer segmentation, E-commerce, K-means clustering, Density-based clustering

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题与解决方法	1
1.3 研究目的与论文结构	1
第二章 相关研究	2
2.1 经典聚类算法研究	2
2.2 电子商务客户细分中的聚类应用	2
2.3 本章小结	3
第三章 问题定义与数据集	4
3.1 应用场景	4
3.2 问题形式化描述	4
3.3 数据集描述	4
3.4 数据特征与挑战	5
3.5 本章小结	5
第四章 聚类方法与评价指标	6
4.1 数据预处理	6
4.2 聚类算法	6
4.2.1 K 均值聚类	6
4.2.2 凝聚层次聚类	6
4.2.3 基于密度的空间聚类	6
4.3 评价指标	6
4.3.1 轮廓系数	7
4.3.2 Calinski–Harabasz 指数	7
4.3.3 Davies–Bouldin 指数	7
4.4 本章小结	7
第五章 实验设置与结果分析	8
5.1 实验环境与参数设置	8
5.2 定量评价结果	8
5.3 可视化结果分析	9
5.3.1 K-Means 聚类投影分析	9
5.3.2 K-Means 与凝聚层次聚类的簇规模分析	9
5.3.3 DBSCAN 聚类结果分析	11
5.4 业务解释与讨论	11
5.5 本章小结	12
第六章 结论与展望	13
6.1 总结	13
6.2 研究局限性	13
6.3 未来	13
参考文献	14

插图索引

图 5.1	K-Means 聚类结果的 PCA 二维投影	9
图 5.2	K-Means 聚类的簇规模分布	10
图 5.3	凝聚层次聚类的簇规模分布	10
图 5.4	DBSCAN 聚类结果及噪声点识别	11

表格索引

表 5.1 三种聚类算法的性能对比 8

第一章 绪论

1.1 研究背景

随着电子商务平台的发展，交易、购买和消费等业务环节积累了大量客户行为数据。这些数据反映了客户在商品类别、消费金额和购买偏好等方面的差异，为精准营销、个性化推荐、会员运营和库存优化提供了数据基础。如何从无标签消费数据中识别具有相似购买特征的客户群体，已成为电子商务数据分析的重要问题。

客户细分属于无监督学习任务，其目标是依据客户消费行为的相似性形成具有差异化特征的客户群体。合理的细分结果不仅应具有较好的簇内一致性和簇间差异性，还应具备一定的业务可解释性。经典聚类方法具有实现简单、计算开销较低和结果易于解释等特点，适用于客户消费数据的分析与比较。

1.2 研究问题与解决方法

不同聚类方法具有不同的数据假设和适用条件。K 均值聚类 (K-Means) 适用于簇形状相对规则的数值型数据；凝聚层次聚类能够反映样本之间的层次关系；基于密度的空间聚类 (DBSCAN) 可识别低密度样本和噪声点，但对参数设置及数据密度分布较为敏感。

本文以电子商务客户细分为应用场景，选取 K-Means、凝聚层次聚类和 DBSCAN 三种经典聚类方法开展比较研究。首先，对客户消费特征进行标准化处理；其次，在统一实验条件下完成三种算法的聚类实验；最后，结合轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数及可视化结果，对不同方法的聚类质量和适用性进行分析。

1.3 研究目的与论文结构

本文旨在为电子商务客户细分任务中的聚类方法选择提供参考，并分析不同算法特性与客户消费数据之间的匹配关系。研究主要包括三方面内容：对三种聚类方法进行统一实现与比较；采用内部评价指标对聚类结果进行定量分析；结合可视化结果讨论不同方法在客户细分任务中的适用性。

全文共分为六章：第 1 章为绪论；第 2 章介绍相关研究；第 3 章定义研究问题并说明实验数据集；第 4 章介绍数据预处理、聚类算法和评价指标；第 5 章给出实验设置与结果分析；第 6 章总结全文并讨论后续研究方向。

第二章 相关研究

2.1 经典聚类算法研究

聚类分析是数据挖掘与机器学习领域的重要研究内容，其主要目标是在缺乏类别标签的数据中识别潜在结构，并将具有相似特征的样本划分为不同群体。根据聚类机制的不同，常见方法可分为划分式聚类、层次聚类和基于密度的聚类等类型。

K-Means 是典型的划分式聚类方法，最早由 MacQueen 提出^[1]。该方法通过迭代优化聚类中心，使簇内样本与所属质心之间的距离尽可能小。由于具有实现简单、计算效率较高和结果易于解释等特点，K-Means 被广泛应用于客户细分、市场分析和行为模式识别等任务。其局限性在于，算法通常更适用于簇形状相对规则、规模相近且方差差异较小的数据分布。

凝聚层次聚类采用自底向上的聚合方式，从每个样本独立成簇开始，逐步合并距离较近的样本簇或样本集合。采用 Ward 链接准则时，算法通过最小化簇内方差增量确定合并顺序。相较于 K-Means，凝聚层次聚类能够反映样本之间的层次关系，具有较好的结构解释能力；但其计算复杂度相对较高，且早期合并决策可能对后续聚类结果产生影响。

DBSCAN 是典型的基于密度的聚类方法，能够识别任意形状的簇，并将低密度区域中的样本标记为噪声点^[2]。该方法不需要预先指定簇数，适用于存在异常样本或非规则簇结构的数据场景。然而，DBSCAN 对邻域半径和最小样本数等参数较为敏感。当数据局部密度差异不明显或样本分布较为均匀时，其聚类性能可能受到限制^[3]。

2.2 电子商务客户细分中的聚类应用

在电子商务场景中，客户细分旨在依据客户消费行为、购买偏好和商品需求等特征，将客户划分为具有差异化特征的群体。合理的客户细分结果能够为精准营销、个性化推荐、客户价值分析和库存优化提供数据支持。因此，客户细分方法不仅需要具备较好的聚类质量，还应具有一定的业务可解释性。

已有研究针对电子商务和消费行为数据开展了多种聚类方法的比较分析。Kumar 等对 K-Means 与层次聚类在电子商务客户细分中的应用进行了比较，指出不同方法在聚类紧凑性和结果解释性方面存在差异^[4]。Paramita 和 Hariguna 比较了 K-Means 与 DBSCAN 在电子商务客户细分任务中的表现，表明基于密度的方法对参数设置和数据分布具有较高敏感性^[5]。Ramadhan 等进一步比较了层次聚类、K-Means 和 DBSCAN 在消费水平分析中的应用效果，认为数据分布特征是影响聚类结果的重要因素^[6]。此外，Aglasia 和 Agus 的研究表明，DBSCAN 在识别稀疏样本和潜在异常消费行为方面具有一定应用价值^[7]。

总体来看,不同聚类方法具有不同的数据假设和适用条件。**K-Means** 适用于结构相对规则的数值型数据;凝聚层次聚类适用于需要分析样本层次关系的场景;**DBSCAN** 则适用于具有明显密度差异或需要识别噪声样本的数据场景。因此,有必要在统一的数据预处理和评价框架下,对不同聚类方法在电子商务客户细分任务中的表现进行比较分析,并进一步讨论算法特性与数据分布之间的匹配关系。

2.3 本章小结

本章对 **K-Means**、凝聚层次聚类和 **DBSCAN** 三种经典聚类方法进行了概述,并总结了聚类技术在电子商务客户细分中的应用研究。已有研究表明,聚类结果与数据的尺度特征、簇形状、局部密度和异常样本分布密切相关。下一章将进一步定义本文的研究问题,并介绍实验所采用的数据集。

第三章 问题定义与数据集

3.1 应用场景

本文聚焦于电子商务客户细分场景。该任务属于无监督学习问题，目标是根据消费者在不同商品类别上的购买相似性对客户进行分组。有效的客户细分能够为定向营销、库存优化和个性化推荐提供支持。为了产生实际业务价值，聚类结果至少应满足两个要求：一是具有较高的簇内凝聚性，即同一簇中的客户消费行为相近；二是具有较好的可解释性，即不同客户群体能够对应可理解、可执行的业务洞察。聚类方法不依赖预先定义的类别标签，能够从交易数据中发现自然形成的客户群体，因此适用于该场景。

3.2 问题形式化描述

设客户样本集合为

$$\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}, \quad (3.1)$$

其中， $\mathbf{x}_i \in \mathbb{R}^d$ 表示第 i 个客户在 d 个商品类别上的消费特征向量， n 为客户样本数量。聚类任务的目标是将数据集划分为若干个簇 $\mathcal{C} = \{C_1, C_2, \dots, C_k\}$ ，使同一簇内客户的消费模式尽可能相似，而不同簇之间尽可能不同。

以 K-Means 为例，其目标可表示为最小化簇内平方误差和：

$$J = \sum_{r=1}^k \sum_{\mathbf{x}_i \in C_r} \|\mathbf{x}_i - \boldsymbol{\mu}_r\|^2, \quad (3.2)$$

其中， $\boldsymbol{\mu}_r$ 为第 r 个簇 C_r 的质心。层次聚类和基于密度的聚类方法具有不同的优化准则，但总体目标一致，即提高簇内相似性并增大簇间差异。

由于数据集不包含真实的客户类别标签，本文不采用监督分类准确率，而采用轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数等内部评价指标评价聚类质量。这一评价方式符合真实电子商务场景：客户细分效果通常需要根据群体一致性、可解释性和业务效用进行判断，而不是与预先给定的类别标签进行比对。

3.3 数据集描述

实验采用 UCI Machine Learning Repository 发布的 Wholesale Customers 数据集^[8]。该数据集包含 440 条客户年度消费记录，每个客户包含 6 个连续数值型消费特征，分别为 Fresh、

Milk、Grocery、Frozen、Detergents_Paper 和 Delicassen。每个特征表示客户在相应商品类别上的年度消费金额。

数据集中不包含客户人口统计属性或预先给定的类别标签，因此聚类结果完全由客户消费行为驱动。该数据集具有连续数值型特征和差异化消费模式，适合用于检验基于距离的聚类方法。尽管样本规模适中，但其消费金额在不同类别上的方差存在明显差异，且部分客户的消费行为具有重叠性，从而能够反映实际客户分析中的分群挑战。另一方面，数据集仅提供年度汇总消费信息，难以描述客户行为随时间变化的过程，因此主要适用于静态消费模式分析。

3.4 数据特征与挑战

尽管数据集规模有限，但其仍存在若干影响聚类效果的挑战。首先，不同特征的数值量级差异较大，如果不进行标准化，高消费金额类别将主导欧氏距离计算并影响簇划分。其次，不同客户群体之间存在一定的消费行为重叠，可能导致簇边界不够清晰。再次，数据中可能存在偏斜样本或异常消费行为，它们会影响基于质心的方法，并可能被基于密度的方法识别为噪声点。通过标准化处理并比较多种聚类范式，本文能够分析不同算法如何从结构化消费数据中提取具有业务价值的客户群体，以及不同算法假设所带来的局限性。

3.5 本章小结

本章给出了电子商务客户细分任务的问题定义，介绍了 Wholesale Customers 数据集的组成和特点，并分析了特征尺度差异、群体重叠和异常样本等挑战。下一章将介绍数据预处理、聚类算法和评价指标。

第四章 聚类方法与评价指标

4.1 数据预处理

为消除不同消费特征数值范围对距离计算的影响，本文对全部特征采用 Z-score 标准化：

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad (4.1)$$

其中， x_{ij} 表示第 i 个客户在第 j 个特征上的原始取值， μ_j 和 σ_j 分别表示该特征的均值和标准差。标准化后的数据作为三种聚类算法的统一输入。

4.2 聚类算法

4.2.1 K 均值聚类

K 均值聚类 (K-Means) 通过最小化簇内平方误差完成样本划分，其目标函数如式(3.2)所示。本文设置簇数为 $k = 3$ ，随机种子为 42，随机初始化次数为 10。该方法计算效率较高，适用于簇形状相对规则的数值型数据。

4.2.2 凝聚层次聚类

凝聚层次聚类采用自底向上的方式逐步合并样本簇。本文采用 Ward 链接准则和欧氏距离，并设置最终簇数为 3。Ward 链接通过减小簇内方差增量确定合并顺序，能够反映样本之间的层次关系。

4.2.3 基于密度的空间聚类

基于密度的空间聚类 (DBSCAN) 根据样本之间的密度可达关系识别簇，并将低密度区域中的样本标记为噪声点。本文设置邻域半径为 $\varepsilon = 1.2$ ，最小样本数为 5，并采用欧氏距离计算样本邻域关系。该方法无需预先指定簇数，适用于识别异常样本和非规则簇结构。

4.3 评价指标

由于数据集不包含真实类别标签，本文采用轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数进行内部评价，分别从簇内紧凑性、簇间分离度和簇间相似性等角度衡量聚类质

量。

4.3.1 轮廓系数

轮廓系数用于衡量样本与所属簇之间的相似程度，以及其与相邻簇之间的差异。对于样本 i ，其轮廓系数定义为

$$s(i) = \frac{b(i) - a(i)}{\max a(i), b(i)}, \quad (4.2)$$

其中， $a(i)$ 表示样本 i 与同一簇内其他样本之间的平均距离， $b(i)$ 表示样本 i 到最近相邻簇的平均距离。该指标越大，说明聚类结果越合理。

4.3.2 Calinski–Harabasz 指数

Calinski–Harabasz 指数用于衡量簇间离散度与簇内离散度之比，其计算形式为

$$\text{CH}(k) = \frac{\text{tr}(B_k)/(k-1)}{\text{tr}(W_k)/(n-k)}, \quad (4.3)$$

其中， n 为样本数， k 为簇数， B_k 和 W_k 分别表示簇间散度矩阵和簇内散度矩阵， $\text{tr}(\cdot)$ 表示矩阵迹。该指标越大，表明簇间分离度越高、簇内结构越紧凑。

4.3.3 Davies–Bouldin 指数

Davies–Bouldin 指数用于衡量不同簇之间的相似程度：

$$\text{DB}(k) = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right), \quad (4.4)$$

其中， S_i 表示第 i 个簇内样本到该簇质心的平均距离， M_{ij} 表示第 i 个簇与第 j 个簇质心之间的距离。该指标越小，说明不同簇之间的可分性越好。

4.4 本章小结

本章介绍了数据标准化方法、K-Means、凝聚层次聚类和 DBSCAN 三种聚类算法，以及轮廓系数、CH 指数和 DB 指数三类内部评价指标。下一章将在统一实验条件下对不同方法进行比较分析。

第五章 实验设置与结果分析

本章在统一的数据预处理条件下，对 K-Means、凝聚层次聚类和 DBSCAN 三种经典聚类方法进行实验比较。实验从定量评价和可视化分析两个方面考察不同方法在 Wholesale Customers 数据集上的聚类表现，并结合客户细分任务需求讨论其适用性。

5.1 实验环境与参数设置

实验采用 Python 3.10 实现，聚类算法及评价指标均基于 scikit-learn 1.3 完成；数据处理使用 NumPy 和 Pandas，结果可视化使用 Matplotlib 和 Seaborn。全部实验在 CPU 环境下运行。

为保证比较过程的一致性,三种聚类算法均作用于相同的 Z-score 标准化数据集。K-Means 的簇数设置为 3，随机种子设置为 42，随机初始化次数设置为 10，最大迭代次数设置为 300。凝聚层次聚类同样设置为 3 个簇，采用 Ward 链接准则和欧氏距离进行逐步合并。DBSCAN 的邻域半径设置为 $\varepsilon = 1.2$ ，最小样本数设置为 5，并采用欧氏距离计算样本邻域关系。

5.2 定量评价结果

本文采用轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数评价聚类结果。其中，轮廓系数和 Calinski–Harabasz 指数越高，表明簇内紧凑性和簇间分离性越好；Davies–Bouldin 指数越低，表明不同簇之间的相似性越低。

表5.1给出了三种聚类算法的定量评价结果。

表 5.1 三种聚类算法的性能对比

方法	评价指标		
	轮廓系数	CH 指数	DB 指数
K-Means	0.5483	140.14	0.9279
凝聚层次聚类	0.2646	111.15	1.2845
DBSCAN	–	106.26	1.6096

表中，CH 指数表示 Calinski–Harabasz 指数，DB 指数表示 Davies–Bouldin 指数。由于 DBSCAN 的聚类结果中包含噪声点，因此未报告其轮廓系数。

由表5.1可知，K-Means 的轮廓系数和 CH 指数均为三种方法中的最高值，DB 指数则为最低值，表明其在当前数据集上具有较好的簇内紧凑性和簇间分离性。凝聚层次聚类的三项指标表现次于 K-Means，说明其能够形成一定的客户群体结构，但不同簇之间的区分程度相对较弱。DBSCAN 的 CH 指数较低、DB 指数较高，表明该方法在当前参数设置下难以形成多个结构清晰的客户群体。

5.3 可视化结果分析

为进一步分析不同聚类方法的分群特征，本文采用主成分分析将标准化后的高维消费特征投影至二维空间，并绘制不同算法的簇规模分布。需要说明的是，PCA 仅用于结果展示，实际聚类过程仍在原始标准化特征空间中完成。

5.3.1 K-Means 聚类投影分析

图5.1给出了 K-Means 聚类结果在二维主成分空间中的投影。




图 5.1 K-Means 聚类结果的 PCA 二维投影

如图5.1所示，三个客户簇在二维投影空间中呈现出一定的分离趋势，部分样本集中分布于相对紧凑的区域。虽然二维投影无法完全反映高维特征空间中的实际距离关系，但该图能够直观说明 K-Means 在当前数据集上识别出了具有差异化消费特征的客户群体。该结果与表5.1中 K-Means 较高的轮廓系数和 CH 指数相一致。

5.3.2 K-Means 与凝聚层次聚类的簇规模分析

图5.2给出了 K-Means 聚类结果的簇规模分布。

由图5.2可见，K-Means 划分得到的各簇均包含一定数量的样本，整体规模分布相对均衡。这表明 K-Means 未将多数样本过度集中于单一簇中，能够形成多个具有一定代表性的客户群体，为后续客户画像和差异化运营提供了基础。

图5.3给出了凝聚层次聚类的簇规模分布。




图 5.2 K-Means 聚类的簇规模分布




图 5.3 凝聚层次聚类的簇规模分布

由图5.3可见，凝聚层次聚类的样本分布相对不均衡，其中存在规模较大的主导簇。这说明在 Ward 链接的逐步合并过程中，部分具有相似消费特征的客户样本被持续合并至同一簇中，从而降低了不同客户群体之间的区分程度。该现象与其较低的轮廓系数和 CH 指数相对应。

5.3.3 DBSCAN 聚类结果分析

图5.4展示了 DBSCAN 的聚类标签分布，其中标签 -1 表示未被归入任何高密度簇的噪声点。




图 5.4 DBSCAN 聚类结果及噪声点识别

由图5.4可见，部分样本被识别为噪声点，非噪声样本则主要集中于少数簇中。该结果表明，DBSCAN 对局部密度较低的样本具有一定识别能力，可为异常消费模式或低频消费行为的发现提供辅助参考。然而，在当前数据分布和参数设置下，DBSCAN 未能形成多个规模相对均衡且边界清晰的客户群体，因此不适合作为本研究场景下精细客户细分的主要方法。

5.4 业务解释与讨论

从客户细分应用角度看，K-Means 所形成的多个簇可作为后续客户画像分析的基础。通过进一步统计不同簇在生鲜、乳制品、杂货、冷冻食品、清洁用品和熟食等消费类别上的均值或聚类中心，可将不同客户群体解释为高消费型、消费偏好集中型或特定品类需求型客户。

对于高消费客户，可结合会员等级、专属优惠和重点客户维护等策略提升客户价值；对于消费偏好较为集中的客户，可围绕其主要购买类别开展定向推荐和组合促销；对于具有特定品类需求的客户，可通过商品组合、库存保障和差异化服务提高运营效率。

凝聚层次聚类能够从层次关系角度辅助分析客户群体之间的相似性，但由于其分群边界相对不够清晰，更适合作为探索性分析方法。DBSCAN 则可用于识别低密度样本或潜在异常消费行为，为异常客户筛查提供补充信息。

5.5 本章小结

本章在统一实验条件下比较了 K-Means、凝聚层次聚类和 DBSCAN 三种经典聚类方法。定量评价结果表明，K-Means 在轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数上均表现较优。可视化结果进一步表明，K-Means 能够形成相对均衡且具有一定分离度的客户群体结构。

凝聚层次聚类具有一定的层次化解释能力，但其簇间区分度弱于 K-Means。DBSCAN 能够识别噪声点和低密度样本，但在当前数据集上难以形成多个稳定的客户群体。综合来看，K-Means 更适合作为当前电子商务客户消费数据的基础分群方法。

第六章 结论与展望

6.1 总结

本文针对 Wholesale Customers 数据集上的电子商务客户细分问题,对 K-Means、凝聚层次聚类和 DBSCAN 三种经典聚类方法进行了比较分析。实验结果表明, K-Means 在轮廓系数、Calinski–Harabasz 指数和 Davies–Bouldin 指数上均表现最优,能够形成紧凑、分离清晰且便于解释的客户群体。这一结果说明, K-Means 的算法假设与本数据集相对凸形、较为规则的数值分布具有较好的匹配性。

凝聚层次聚类表现居中。该方法可以为客户群体提供层次化解释,但其贪婪式合并策略和对早期合并决策的敏感性,使得最终得到的簇在紧凑性和分离度方面弱于 K-Means。DBSCAN 在本研究场景中效果较弱,主要原因是数据中缺少清晰的密度分离结构;噪声点的存在以及内部评价指标在该设置下的局限性,也使其难以形成适用于精细客户画像的多个稳定簇。

本文结果强调,在实际电子商务客户分析中,聚类算法的选择应综合考虑数据分布特征、算法假设和业务目标。对于结构化、连续数值型且簇形状较为规则的消费数据, K-Means 可以作为兼顾效果、效率和可解释性的可靠基线方法。

6.2 研究局限性

本文仍存在若干局限性。首先,所用数据集规模较小,仅包含 440 个样本,且仅提供年度消费汇总信息,无法反映客户行为随时间变化的过程。其次, K-Means 和凝聚层次聚类中的簇数由人工指定,尚未进一步探讨不同簇数设置对结果的影响。再次,本文主要依赖内部聚类指标,尚未直接验证客户细分结果对营销活动效果、客户转化率或长期客户价值等业务层面指标的影响。

6.3 未来

未来工作可从多个方向扩展。其一,可引入规模更大、具有时间序列信息的交易数据,以刻画客户动态消费行为、季节性趋势和购买偏好的演化过程。其二,可将聚类与推荐系统、预测模型或集成聚类方法结合,以提高客户细分精度和业务实用性。其三,可引入营销响应率、转化率和客户生命周期价值等外部评价指标,使聚类结果与实际业务目标建立更直接的联系。其四,还可进一步探索谱聚类、高斯混合模型和深度聚类等方法,以处理更复杂的非线性消费模式,同时保持足够的可解释性。

参考文献

- [1] MacQueen J. Some methods for classification and analysis of multivariate observations[C]. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability: volume 1. [S.l.: s.n.], 1967: 281–297.
- [2] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]. Proceedings of the Second International Conference on Knowledge Discovery and Data Mining. [S.l.: s.n.], 1996: 226–231.
- [3] Baligodugula V V, Amsaad F. Unsupervised learning: Comparative analysis of clustering techniques on high-dimensional data[J]. arXiv preprint arXiv:2503.23215, 2025.
- [4] Kumar S, Rani R, Pippal S K, et al. Customer segmentation in e-commerce: K-means vs hierarchical clustering [J]. TELKOMNIKA Telecommunication, Computing, Electronics and Control, 2025, 23(1).
- [5] Paramita A S, Hariguna T. Comparison of k-means and dbscan algorithms for customer segmentation in e-commerce[J]. Journal of Digital Marketing and Digital Currency, 2024, 1(1): 43–62.
- [6] Ramadhan H, Kamaludin M R A, Nasrullah M A, et al. Comparison of hierarchical, k-means and dbscan clustering methods for credit card customer segmentation analysis based on expenditure level[J]. Journal of Applied Informatics and Computing, 2023, 7(2): 246–251.
- [7] Aglasia A, Agus I. Unveiling hidden customer segments in e-commerce using dbscan clustering on demographic and behavioral insights[J]. International Journal of Applied Information Management, 2024, 4(3): 128–140.
- [8] Dua D, Graff C. Uci machine learning repository[M]. [S.l.: s.n.], 2019.