



南京邮电大学  
Nanjing University of Posts and Telecommunications

# 神经网络

汇报人:赵晨洁

学号:1025040822

# 目录

- 01 问题
- 02 算法原理
- 03 实验及结果
- 04 总结



南京邮电大学  
Nanjing University of Posts and Telecommunications


# PART 01

## 问题



## ➤问题


### 1.垃圾邮件分类



### 2.预测下一个词

- This game is really **fun**
  - This cookie is really **tasty**
- } 预测下一个词汇

### 3.社交好友推荐



## ➤网络结构

| 问题      | 数据类型                | 网络结构 |
|---------|---------------------|------|
| 垃圾邮件分类  | 静态数据分类/回归（无时序或拓扑关系） | 前馈网络 |
| 预测下一个词汇 | 序列数据建模（时间或顺序依赖）     | 记忆网络 |
| 社交好友推荐  | 图结构数据               | 图网络  |




南京邮电大学  
Nanjing University of Posts and Telecommunications

## PART 02


# 算法原理




## ➤ 网络结构-主要思想



(a) 前馈网络



(b) 记忆网络



(c) 图网络

前馈神经网络（神经元组合）： $\mathbf{a}^{(l)} = f^{(l)}(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)})$

记忆网络（隐藏层，简单循环网络RNN）： $\mathbf{h}_t = f(\mathbf{W}_x\mathbf{x}_t + \mathbf{W}_h\mathbf{h}_{t-1} + \mathbf{b})$

图网络（邻域聚合+节点状态更新）： $\mathbf{h}_v^{(l)} = f^{(l)}\left(\sum_{u \in \mathcal{N}(v)} \mathbf{W}^{(l)}\mathbf{h}_u^{(l-1)} + \mathbf{b}^{(l)}\right)$



## 前馈网络

### ➤问题定义

给定数据集：

$$D = \{(x_i, y_i)\}_{i=1}^N, x_i \in R^d$$

1.二分类：  $y_i \in \{0,1\}$ 或 $\{+1, -1\}$  ( $y_i \in R$ )

多分类：  $y_i \in \{1,2, \dots, K\}$  (输出需转为one-hot向量,  $y_i \in R^k$ )

2.回归：  $y_i \in R$

### ➤模型假设

$$\mathbf{a}^{(l)} = f^{(l)}(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)})$$

$$\mathbf{a}^{(0)} = x, \quad \mathbf{a}^{(l)} = \hat{y}$$

模拟函数，使得  $\hat{y} \rightarrow y$



## 记忆网络 (RNN)

### ➤问题定义

给定数据集:

$$D = \{(\mathbf{x}_{1:T}^{(i)}, y_i)\}_{i=1}^N$$

$$\mathbf{x}_{1:T} = (x_1, x_2, \dots, x_t, \dots, x_T), \mathbf{x}_t \in R^d$$

序列到类别:  $y_i \in \{1, 2, \dots, K\}$  (one-hot向量,  $y_i \in R^k$ ) (文本情感分析)

同步序列到序列:  $y_i = y_{1:T} = (y_1, y_2, \dots, y_T)$  (词性标注)

异步序列到序列:  $y_i = y_{1:M} = (y_1, y_2, \dots, y_M)$  (翻译, 两个语言长度不同)

### ➤模型假设

$$h_t = f(W_x x_t + W_h h_{t-1} + b)$$
$$\hat{y}_t = \text{Softmax}(W_o h_t + b_o)$$

学习 $f^{(l)}(\cdot)$ , 使得 $\hat{y} \rightarrow y$




图 6.2 按时间展开的循环神经网络





南京邮电大学  
Nanjing University of Posts and Telecommunications

## PART 03

# 实验及结果



## MNIST数据集：


MNIST数据集是由0~9手写数字图片和数字标签所组成的，由60000个训练样本和10000个测试样本组成，每个样本都是一张28 \* 28像素的灰度手写数字图片。



| 数据集   | MNIST 中的文件名                | 文件大小         |
|-------|----------------------------|--------------|
| 训练集图像 | train-images-idx3-ubyte.gz | 9,912,422 字节 |
| 训练集标签 | train-labels-idx1-ubyte.gz | 28,881 字节    |
| 测试集图像 | t10k-images-idx3-ubyte.gz  | 1,648,877 字节 |
| 测试集标签 | t10k-labels-idx1-ubyte.gz  | 4,542 字节     |



# MNIST数据集，前馈网络中的卷积神经网络，实现手写数字识别



## 1. 整体训练效果：模型已快速收敛

从训练过程看，模型在前 3 个 Epoch 内学习速度很快：

- 训练准确率由 93.65%提升至98.07%；
- 测试准确率由98.50%提升至99.02%；
- 训练损失由0.0033快速下降至0.0010；
- 测试损失由0.0450降至0.0312。

这说明卷积神经网络能够较快提取手写数字中的局部笔画、边缘、轮廓等特征，并完成从低级纹理到数字类别的映射。对MNIST这类结构相对清晰的灰度图像任务，CNN的局部感受野和参数共享机制比较适合。


## 2. 最终识别性能：测试准确率达到99.17%

最终模型在测试集上达到99.17%的识别准确率，仅误分类约83张测试样本，说明所构建的卷积神经网络能够较好地泛化到未见过的手写数字图像。

```
Epoch 1/10: Train Loss: 0.0033, Train Acc: 93.65% | Test Loss: 0.0450, Test Acc: 98.50% | Time: 129.40s
Epoch 2/10: Train Loss: 0.0014, Train Acc: 97.53% | Test Loss: 0.0395, Test Acc: 98.76% | Time: 129.39s
Epoch 3/10: Train Loss: 0.0010, Train Acc: 98.07% | Test Loss: 0.0312, Test Acc: 99.02% | Time: 128.81s
Epoch 4/10: Train Loss: 0.0008, Train Acc: 98.39% | Test Loss: 0.0314, Test Acc: 98.98% | Time: 128.09s
Epoch 5/10: Train Loss: 0.0007, Train Acc: 98.57% | Test Loss: 0.0331, Test Acc: 98.99% | Time: 127.77s
Epoch 6/10: Train Loss: 0.0006, Train Acc: 98.79% | Test Loss: 0.0293, Test Acc: 99.00% | Time: 128.24s
Epoch 7/10: Train Loss: 0.0005, Train Acc: 98.89% | Test Loss: 0.0296, Test Acc: 99.24% | Time: 128.21s
Epoch 8/10: Train Loss: 0.0005, Train Acc: 98.96% | Test Loss: 0.0298, Test Acc: 99.16% | Time: 128.39s
Epoch 9/10: Train Loss: 0.0005, Train Acc: 99.08% | Test Loss: 0.0302, Test Acc: 99.12% | Time: 127.03s
Epoch 10/10: Train Loss: 0.0004, Train Acc: 99.10% | Test Loss: 0.0313, Test Acc: 99.17% | Time: 128.12s
```



# MNIST数据集，前馈网络中的卷积神经网络，实现手写数字识别



## 3. 混淆矩阵分析：大部分预测集中在对角线

混淆矩阵中，主对角线上的数值明显较大，例如：

- 数字 0：正确识别 977 张；
- 数字 1：正确识别 1134 张；
- 数字 2：正确识别 1021 张；
- 数字 3：正确识别 1005 张；
- 数字 7：正确识别 1018 张；
- 数字 9：正确识别 994 张。

主对角线代表“真实类别与预测类别一致”，因此对角线颜色最深、数值最大，说明模型对大部分数字都有较高的识别正确率。



南京邮电大学  
Nanjing University of Posts and Telecommunications

# PART 04

## 总结



## ➤总结

本次学习从“数据结构决定网络结构”的角度，梳理了神经网络的基本类型，并以 MNIST 手写数字识别为例完成了卷积神经网络的训练与测试验证。

- 对于静态、无时序关系的数据，可采用前馈神经网络进行分类或回归；对于具有前后依赖关系的序列数据，可采用记忆网络（RNN）；对于节点及其连接关系构成的图结构数据，可采用图神经网络（GNN）。
- MNIST数据集任务本质为0~9十分类问题；卷积神经网络能够利用局部感受野和参数共享机制，自动提取数字图像中的笔画、边缘和轮廓等空间特征，适合处理MNIST这类二维图像分类任务。
- 实验训练10个Epoch后，模型测试准确率达到99.17%，训练与测试损失整体下降，表明模型已稳定收敛并具有良好的泛化能力；少量误分类主要集中在2与7、4与9、8与9等字形相近的数字之间。

结论：神经网络需要结合数据的结构特征进行选择；在二维图像分类任务中，卷积神经网络能够有效完成特征学习与高精度识别。