

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 推荐系统中矩阵补全的最优化方法研究

学	号	<u>1025040825</u>
姓	名	<u>朱宇宸</u>
导	师	<u>鲍秉坤</u>
专业学位类别		<u>学术型硕士</u>
类	型	<u>计算机科学与技术</u>
专业（领域）		<u>模式分析与计算机视觉</u>
论文提交日期		<u>2026 年 5 月</u>

摘要

推荐系统通常建立在稀疏的用户-物品评分矩阵之上，核心任务是在只观测到少量交互记录的条件下预测缺失评分。矩阵补全为该问题提供了清晰的最优化建模视角：一方面需要拟合已观测评分，另一方面需要通过低秩结构控制模型复杂度。本文围绕推荐系统中的矩阵补全问题展开，介绍低秩矩阵恢复、核范数松弛、奇异值阈值化、随机梯度下降和交替最小二乘等典型方法，并结合 MovieLens 数据集给出数值实验和比较分析。

实验部分从均值基线、用户与物品偏置、Item-kNN、SoftImpute、SGD 矩阵分解和 ALS 矩阵分解等方法出发，使用 RMSE 和 MAE 评价预测效果，并通过秩、正则化、训练数据比例、噪声扰动和运行时间等指标讨论不同优化方法的特点。结果表明，协同过滤方法明显优于简单均值基线；低秩分解方法虽然对应非凸优化问题，但在稀疏推荐数据上具有较好的可扩展性；核范数方法具有更强的凸优化解释，但实际计算中受奇异值分解开销影响较大。总体来看，矩阵补全能够把推荐系统中的缺失数据预测、模型容量控制和算法效率统一到一个最优化框架之中。

关键词：推荐系统，矩阵补全，低秩矩阵分解，核范数，最优化方法

Abstract

Recommendation systems are often built from sparse user-item rating matrices, where the main task is to predict missing entries from limited observed interactions. Matrix completion provides a natural optimization view for this problem: the model should fit observed ratings while controlling the complexity of the recovered matrix through a low-rank structure. This report studies representative optimization methods for matrix completion in recommendation systems, including low-rank recovery, nuclear-norm relaxation, singular value thresholding, stochastic gradient descent, and alternating least squares.

The numerical part compares mean baselines, bias models, Item-kNN, SoftImpute, SGD-based matrix factorization, and ALS-based matrix factorization on MovieLens data. RMSE and MAE are used as the main evaluation metrics, while additional experiments analyze rank selection, regularization, data availability, noise robustness, and runtime. The results show that collaborative filtering methods clearly outperform mean-based baselines. Factorized low-rank methods are nonconvex but scalable on sparse recommendation data, whereas nuclear-norm methods have a cleaner convex interpretation but rely on costly spectral operations. Overall, matrix completion offers a unified optimization framework for understanding missing-rating prediction, model capacity control, and computational trade-offs in recommendation systems.

Key Words: recommendation system, matrix completion, low-rank matrix factorization, nuclear norm, optimization method

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景	1
1.2 矩阵补全视角	1
1.3 本文主要内容	2
第二章 矩阵补全与推荐系统建模	3
2.1 推荐系统中的评分矩阵	3
2.2 投影算子与低秩假设	3
2.3 核范数凸松弛	4
2.4 低秩分解模型	4
2.5 本章小结	5
第三章 典型最优化方法	6
3.1 核范数最小化方法	6
3.2 奇异值阈值化与 SoftImpute	6
3.3 非凸低秩优化	7
3.4 SGD 与 ALS 求解	7
3.5 邻域方法作为实践基线	7
3.6 本章小结	8
第四章 数值实验设计与结果分析	9
4.1 实验设置	9
4.2 MovieLens 100K 主结果	9
4.3 可扩展性实验	10
4.4 敏感性实验	10
4.5 图形化结果分析	10
4.6 本章小结	13
第五章 方法讨论与拓展分析	14
5.1 准确率与可解释性的取舍	14
5.2 超参数影响	14
5.3 收敛与运行时间	15
5.4 鲁棒性与数据稀疏性	16
5.5 本章小结	16
第六章 总结与展望	17
6.1 本文工作总结	17
6.2 进一步研究方向	17
参考文献	18
附录 A 程序清单	19

插图索引

图 1.1 推荐系统的基本流程 1

图 2.1 推荐系统的矩阵补全建模视角 3

图 4.1 核心实验结果：五折 RMSE、折间稳定性、1M 数据精度和运行时间 11

图 4.2 优化敏感性：潜在秩、正则化、收敛曲线和 SGD 参数网格 11

图 4.3 鲁棒性与数据效应：训练比例、噪声扰动、合成低秩恢复和邻居数量 12

图 4.4 模型与稀疏性分析：SoftImpute 收缩、用户稀疏性和物品稀疏性 12

图 5.1 潜在秩对矩阵分解方法性能的影响 14

图 5.2 正则化参数对矩阵分解方法性能的影响 15

图 5.3 rank 20 设置下的优化收敛趋势 15

图 5.4 MovieLens 1M 数据上的可扩展性比较 16

表格索引

表 3.1	典型方法的建模特点比较	8
表 4.1	MovieLens 100K 五折测试性能	9
表 4.2	MovieLens 100K 与 1M 可扩展性比较	10
表 4.3	MovieLens 100K $u1$ 划分上的敏感性结果	10
表 5.1	不同方法的综合取舍	16

专用术语注释表

符号说明：

符号	表示含义
R	用户-物品评分矩阵
X	待恢复或待学习的完整评分矩阵
Ω	已观测评分条目的索引集合
$P_{\Omega}(\cdot)$	保留观测位置并将未观测位置置零的投影算子
m, n	用户数量和物品数量
r	低秩分解中的潜在因子维数
U, V	用户潜在因子矩阵和物品潜在因子矩阵
λ	正则化系数
$\ X\ _*$	矩阵 X 的核范数，即奇异值之和
$\ X\ _F$	矩阵 X 的 Frobenius 范数
μ, b_i, c_j	全局均值、用户偏置和物品偏置

缩略词说明：

缩写	英文全称	中文译名
ALS	Alternating Least Squares	交替最小二乘
SGD	Stochastic Gradient Descent	随机梯度下降
SVT	Singular Value Thresholding	奇异值阈值化
RMSE	Root Mean Squared Error	均方根误差
MAE	Mean Absolute Error	平均绝对误差
kNN	k-Nearest Neighbors	k 近邻

第一章 绪论

1.1 研究背景

推荐系统广泛应用于电子商务、视频平台、音乐服务和内容分发场景。它的基本目标是根据用户历史行为推断用户偏好，并从大量候选物品中筛选出更可能被用户接受的项目。在显式反馈任务中，用户对物品的评分可以组织成一个用户-物品矩阵，矩阵的行对应用户，列对应物品，元素表示评分或偏好强度。由于大多数用户只评价过极少数物品，该矩阵通常高度稀疏，推荐任务自然转化为缺失数据预测问题。

矩阵分解是经典推荐系统中最有影响力的方法之一^[1,2]。其核心思想是用低维潜在因子表示用户和物品，并通过潜在因子的内积近似评分。图1.1给出了推荐系统的一般流程：用户侧交互数据和物品侧候选集合经过模型处理后，输出排序后的推荐结果。若把其中的评分预测部分抽象出来，就可以得到矩阵补全问题。




图 1.1 推荐系统的基本流程

1.2 矩阵补全视角

设评分矩阵为 $R \in \mathbb{R}^{m \times n}$ ，其中 m 为用户数， n 为物品数。实际系统只能观测到索引集合 Ω 上的少量条目，因此需要根据 $P_{\Omega}(R)$ 估计未观测位置的评分。矩阵补全方法假设完整评

分矩阵具有低秩或近似低秩结构，即用户偏好可以由少数潜在因素解释。这一假设使推荐系统与低秩优化、凸松弛和非凸分解方法建立联系。

从最优化课程的角度看，该问题具有较好的综合性。理想低秩模型涉及秩最小化，核范数松弛引入凸优化，奇异值阈值化体现近端算法思想，而矩阵分解又对应可扩展的非凸优化。它们服务于同一类预测任务，却在理论解释、计算代价和实际效果之间呈现不同取舍。

1.3 本文主要内容

本文以“推荐系统中矩阵补全的最优化方法”为主题，在原有英文报告内容基础上进行中文化整理，并按照南京邮电大学论文模板组织为完整课程论文。全文主要内容如下：

- 第一章介绍推荐系统、评分矩阵稀疏性和矩阵补全问题的研究背景。
- 第二章给出矩阵补全的基本数学模型，包括投影算子、秩最小化、核范数松弛和低秩分解。
- 第三章讨论典型优化算法，包括 SVT、SoftImpute、SGD、ALS 和 Item-kNN 等方法。
- 第四章整理 MovieLens 数据集上的实验设置、表格结果和图形分析。
- 第五章从准确率、可扩展性、鲁棒性和建模解释性角度讨论方法差异。
- 第六章总结全文，并给出后续可扩展方向。

第二章 矩阵补全与推荐系统建模

2.1 推荐系统中的评分矩阵

推荐系统中的显式反馈数据通常可以写成评分矩阵 R 。若用户 i 对物品 j 给出了评分, 则 $(i, j) \in \Omega$; 否则该位置缺失。矩阵补全的目标是在不观测所有元素的情况下恢复一个合理的完整矩阵 X 。图2.1展示了矩阵补全视角下的推荐系统: 稀疏评分矩阵经过低秩建模得到补全矩阵, 再用于评分预测和 Top- K 推荐。




图 2.1 推荐系统的矩阵补全建模视角

2.2 投影算子与低秩假设

定义投影算子 P_Ω , 它只保留观测集合 Ω 中的元素:

$$[P_\Omega(X)]_{ij} = \begin{cases} X_{ij}, & (i, j) \in \Omega, \\ 0, & (i, j) \notin \Omega. \end{cases} \quad (2.1)$$

低秩假设认为完整评分矩阵可以由少量潜在因素解释, 因此理想矩阵补全问题可写成

$$\min_X \text{rank}(X) \quad \text{s.t.} \quad P_\Omega(X) = P_\Omega(R). \quad (2.2)$$

式(2.2)直接表达了低秩恢复目标, 但秩函数非凸且不连续, 直接求解一般较困难。

定义 2.1 (低秩矩阵补全). 给定部分观测矩阵 $P_\Omega(R)$, 若存在低秩矩阵 X 在观测位置与 R 一致, 并且能够合理估计未观测位置, 则称该过程为低秩矩阵补全。

2.3 核范数凸松弛

核范数是矩阵奇异值之和, 记为

$$\|X\|_* = \sum_k \sigma_k(X). \quad (2.3)$$

由于核范数可以看作秩函数在适当集合上的凸替代, 常用如下优化问题描述带噪声的矩阵补全:

$$\min_X \frac{1}{2} \|P_\Omega(X - R)\|_F^2 + \lambda \|X\|_*. \quad (2.4)$$

Candès 和 Recht 证明, 在随机采样和相干性条件满足时, 许多低秩矩阵可以通过核范数最小化恢复^[3]。Recht 等人进一步将该思想放入仿射秩最小化框架中讨论^[4]。该方向的优点是模型解释清晰, 缺点是实际求解往往需要反复进行奇异值分解。

2.4 低秩分解模型

在实际推荐系统中, 更常见的做法是直接将完整矩阵参数化为两个低维矩阵的乘积:

$$X = UV^\top, \quad U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}, \quad (2.5)$$

其中 r 为潜在维数。对应的正则化经验风险为

$$\min_{U, V} \sum_{(i,j) \in \Omega} (R_{ij} - u_i^\top v_j)^2 + \lambda (\|U\|_F^2 + \|V\|_F^2). \quad (2.6)$$

式(2.6)关于 (U, V) 联合非凸, 但变量规模从 mn 降为 $(m+n)r$, 更适合大规模稀疏评分数据。

实际评分还常包含全局均值、用户偏置和物品偏置, 预测模型可写成

$$\hat{R}_{ij} = \mu + b_i + c_j + u_i^\top v_j, \quad (2.7)$$

其中 μ 表示全局平均评分, b_i 和 c_j 分别表示用户与物品偏置。该模型兼顾了整体评分水平、个体偏好差异和低秩协同结构。

2.5 本章小结

本章给出了推荐系统中矩阵补全问题的基本建模方式。秩最小化体现低秩假设，核范数松弛提供凸优化路径，低秩分解模型则提供更适合稀疏数据的可扩展求解方式。后续章节将在此基础上讨论具体算法和实验比较。

第三章 典型最优化方法

3.1 核范数最小化方法

核范数方法将秩函数替换为凸函数，从而把低秩恢复转化为可分析的凸优化问题。对于式(2.4)，目标函数由观测误差项和核范数正则项构成。前者保证模型在已知评分上与数据一致，后者鼓励恢复矩阵具有较低秩。Shamir 和 Shalev-Shwartz 从协同过滤角度研究了迹范数正则化，使该类方法与推荐系统任务建立了更直接的联系^[5]。

这类方法的主要优势在于理论结构清晰。由于核范数是凸函数，可以使用近端梯度、增广拉格朗日或其他凸优化技术求解。但在大规模推荐数据中，反复计算奇异值分解会带来明显开销，因此常被用作理论参考或中小规模实验基线。

3.2 奇异值阈值化与 SoftImpute

Cai、Candès 和 Shen 提出的奇异值阈值化算法将核范数近端算子写成奇异值软阈值形式^[6]。若矩阵 Y 的奇异值分解为 $Y = Q\Sigma Z^\top$ ，则阈值化算子可表示为

$$\mathcal{D}_\tau(Y) = Q \operatorname{diag}((\sigma_k - \tau)_+) Z^\top. \quad (3.1)$$

其中 $(a)_+ = \max(a, 0)$ 。该操作将较小奇异值压缩为零，从而得到低秩近似。

SoftImpute 方法可以看作核范数正则化在缺失数据场景下的实用近似。它反复填补缺失项、执行低秩奇异值截断，并更新预测矩阵。Hastie 等人给出了基于快速交替最小二乘的矩阵补全方法^[7]，进一步改善了该方向的实际效率。

算法 1 基于奇异值阈值化的矩阵补全流程

输入: 观测矩阵 $P_\Omega(R)$ ，阈值 τ ，最大迭代次数 T

1: 初始化 $X^{(0)} = 0$

2: **for** $t = 0, 1, \dots, T - 1$ **do**

3: 在观测位置使用真实评分，在缺失位置使用当前估计构造 $Y^{(t)}$

4: 对 $Y^{(t)}$ 做奇异值分解

5: 使用式(3.1)得到 $X^{(t+1)}$

6: **end for**

输出: 补全矩阵 $X^{(T)}$

3.3 非凸低秩优化

非凸方法直接优化式(2.6)中的用户因子 U 和物品因子 V 。Keshavan、Montanari 和 Oh 提出的 OptSpace 方法结合谱初始化和低秩因子优化，用于含噪声矩阵补全^[8]。在推荐系统中，因子化方法尤其常见，因为观测矩阵稀疏且规模较大，直接维护完整矩阵会造成不必要的存储和计算负担。

非凸优化的代价是模型对初始化、秩选择和正则化参数更敏感。不过在实际应用中，低秩因子模型可以利用稀疏观测逐条更新，单次评分的计算复杂度通常为 $O(r)$ ，因此在大规模推荐任务中具有较强竞争力。

3.4 SGD 与 ALS 求解

随机梯度下降逐条或小批量遍历观测评分。对单个观测 (i, j) ，若预测误差为

$$e_{ij} = R_{ij} - u_i^\top v_j, \quad (3.2)$$

则忽略偏置项时的一组典型更新为

$$u_i \leftarrow u_i + \eta(e_{ij}v_j - \lambda u_i), \quad v_j \leftarrow v_j + \eta(e_{ij}u_i - \lambda v_j). \quad (3.3)$$

其中 η 为学习率。SGD 实现简单，能够直接处理稀疏评分，但收敛速度受学习率和数据顺序影响。

交替最小二乘固定 V 更新 U ，再固定 U 更新 V 。每一步都转化为一组带正则项的最小二乘问题，因此单步更新稳定。Pilaszy 等人讨论了面向显式和隐式反馈数据的快速 ALS 矩阵分解方法^[9]。在较大数据集上，ALS 常能获得较好的运行时间表现。

3.5 邻域方法作为实践基线

Item-kNN 并不是严格意义上的矩阵补全优化模型，但它是推荐系统中非常强的实践基线。Sarwar 等人提出的基于物品的协同过滤方法通过物品相似度聚合用户历史评分^[10]。Koren 进一步说明了因子模型和邻域模型可以在统一协同过滤框架下结合^[11]。因此，在实验比较中同时纳入 Item-kNN，有助于判断低秩优化模型相对经典协同过滤方法的实际效果。

表 3.1 典型方法的建模特点比较

方法	优点	局限	主要计算瓶颈
核范数最小化	凸优化解释清晰	大规模场景计算较重	奇异值分解
SVT/SoftImpute	近端步骤直观，易解释	对阈值和秩截断敏感	反复谱分解
SGD 矩阵分解	实现简单，适合稀疏数据	学习率和初始化敏感	多轮数据遍历
ALS 矩阵分解	子问题稳定，可并行化	每轮需求解线性系统	因子矩阵更新
Item-kNN	工程基线强，可解释性较好	严格优化解释较弱	相似度计算

3.6 本章小结

本章从凸松弛、近端方法、非凸分解和邻域基线四个角度整理了矩阵补全中的典型方法。不同算法在理论保证、可扩展性和调参难度方面存在明显差异，实验部分将进一步比较这些差异在 MovieLens 数据上的表现。

第四章 数值实验设计与结果分析

4.1 实验设置

实验使用 MovieLens 100K 和 MovieLens 1M 数据集^[12]。MovieLens 100K 采用官方 $u1-u5$ 五折划分，每个划分包含 80000 条训练评分和 20000 条测试评分。主要比较方法包括全局均值、用户均值、物品均值、正则化用户-物品偏置模型、Item-kNN、SoftImpute、SGD 矩阵分解和 ALS 矩阵分解。

除特别说明外，潜在秩设为 $r = 20$ ，SGD 训练 15 个 epoch，ALS 迭代 8 轮，预测评分截断到 $[1, 5]$ 。本文关注不同优化思想的相对表现，因此参数设置保持简洁，不追求对每一种方法进行完全调优。评价指标为 RMSE 和 MAE，其中 RMSE 定义为

$$\text{RMSE} = \sqrt{\frac{1}{|\Omega_{\text{test}}|} \sum_{(i,j) \in \Omega_{\text{test}}} (\hat{R}_{ij} - R_{ij})^2}. \quad (4.1)$$

4.2 MovieLens 100K 主结果

表4.1给出了 MovieLens 100K 五折测试性能。可以看到，简单均值基线的误差明显较大；加入用户和物品偏置后 RMSE 显著降低，说明评分数据中存在稳定的用户和物品偏移。Item-kNN 在该实验中取得了最佳 RMSE，而 SGD-MF 和 ALS-MF 也明显优于均值基线。SoftImpute 作为凸低秩参考方法，在该设置下精度不如协同过滤和分解方法。

表 4.1 MovieLens 100K 五折测试性能

方法	秩	RMSE	MAE	时间 (s)
全局均值	—	1.1256 ± 0.0174	0.9447	0.00
用户均值	—	1.0437 ± 0.0119	0.8362	0.00
物品均值	—	1.0246 ± 0.0071	0.8174	0.00
偏置基线	—	0.9461 ± 0.0089	0.7501	0.17
Item-kNN	—	0.9181 ± 0.0066	0.7174	0.45
SoftImpute	20	0.9836 ± 0.0160	0.7877	0.35
SGD-MF	20	0.9297 ± 0.0073	0.7334	7.00
ALS-MF	20	0.9380 ± 0.0089	0.7436	0.22

4.3 可扩展性实验

表4.2比较了 MovieLens 100K 与 1M 数据集上的运行结果。由于 1M 数据采用单独随机 80/20 划分，它与 100K 五折平均结果不能直接等同，只作为轻量级可扩展性参考。在当前实现中，ALS-MF 在 1M 数据上的 RMSE 和运行时间都较有优势。

表 4.2 MovieLens 100K 与 1M 可扩展性比较

数据集	方法	RMSE	MAE	时间 (s)
100K	偏置基线	0.9608	0.7619	0.17
100K	SGD-MF	0.9430	0.7443	7.29
100K	ALS-MF	0.9537	0.7558	0.27
1M	偏置基线	0.9084	0.7193	3.02
1M	SGD-MF	0.9085	0.7189	28.88
1M	ALS-MF	0.8850	0.7048	0.85

4.4 敏感性实验

表4.3汇总了 MovieLens 100K 的若干敏感性结果，包括邻居数量、SoftImpute 阈值、秩与正则化、训练数据比例和噪声扰动等因素。这些实验并不是为了穷尽所有超参数，而是用于展示优化方法在不同设置下的变化趋势。

表 4.3 MovieLens 100K $u1$ 划分上的敏感性结果

实验	设置	RMSE
Item-kNN 邻居数	$k = 30$	0.9296
SoftImpute 收缩参数	$\tau = 8$	1.0064
SGD 网格搜索	rank 40, $\lambda = 0.01$	0.9545
SGD 数据效率	20% 训练评分	1.0008
ALS 数据效率	100% 训练评分	0.9543
SGD 噪声鲁棒性	noise std. 0.6	0.9627

4.5 图形化结果分析

图4.1至图4.4从整体精度、折间稳定性、秩敏感性、正则化、收敛、鲁棒性和稀疏性等角度展示实验结果。整体来看，协同过滤类方法相比均值基线具有明显优势；矩阵分解方法在精度和可扩展性之间取得了较好平衡；SoftImpute 的优势更多体现在凸优化解释和低秩结构可视化方面。




图 4.1 核心实验结果：五折 RMSE、折间稳定性、1M 数据精度和运行时间




图 4.2 优化敏感性：潜在秩、正则化、收敛曲线和 SGD 参数网格




图 4.3 鲁棒性与数据效应：训练比例、噪声扰动、合成低秩恢复和邻居数量




图 4.4 模型与稀疏性分析：SoftImpute 收缩、用户稀疏性和物品稀疏性

4.6 本章小结

实验结果说明，推荐系统中的矩阵补全不只是一个模型选择问题，也体现了不同优化策略之间的取舍。Item-kNN 在小规模显式评分数据上仍然强劲，SGD-MF 和 ALS-MF 与矩阵补全模型联系更紧密，而核范数方法更适合作为凸优化解释和对照基线。

第五章 方法讨论与拓展分析

5.1 准确率与可解释性的取舍

从实验结果看，测试误差并不能完全决定一种方法是否适合实际推荐系统。Item-kNN 在 MovieLens 100K 上表现较好，说明局部邻域结构对显式评分预测仍然有效。低秩矩阵分解方法虽然未在所有指标上取得最优，但它直接对应矩阵补全模型，能够通过用户因子和物品因子解释潜在偏好结构。

核范数方法的优势主要体现在建模层面。它把低秩假设转化为凸正则化项，并与矩阵恢复理论自然连接。相比之下，SGD 和 ALS 直接优化因子矩阵，理论形式不如凸模型简洁，但更容易利用稀疏观测数据，在大规模场景中更有工程价值。

5.2 超参数影响

潜在秩 r 控制模型容量。秩过小会导致欠拟合，无法表达复杂用户偏好；秩过大则可能过拟合训练评分，并增加计算成本。正则化参数 λ 控制因子向量的幅度，能够缓解过拟合。图5.1和图5.2分别展示了秩和正则化参数对实验结果的影响。




图 5.1 潜在秩对矩阵分解方法性能的影响




图 5.2 正则化参数对矩阵分解方法性能的影响

5.3 收敛与运行时间

SGD 每次更新成本较低，但需要多轮遍历训练评分，且学习率设置会影响收敛稳定性。ALS 每轮需要求解一批正则化最小二乘问题，单轮计算相对更重，但更新方向稳定，适合矩阵分解中的交替优化结构。图5.3展示了 rank 20 设置下的收敛趋势，图5.4展示了更大数据规模下的运行时间和误差变化。




图 5.3 rank 20 设置下的优化收敛趋势




图 5.4 MovieLens 1M 数据上的可扩展性比较

5.4 鲁棒性与数据稀疏性

推荐系统中的稀疏性会放大模型选择和正则化的影响。当用户历史评分很少时，低秩因子难以稳定估计；当物品评分很少时，相似度方法也会面临可靠性不足的问题。噪声实验进一步表明，若训练评分存在扰动，模型需要通过正则化、偏置项和合理的秩选择来维持泛化性能。

表 5.1 不同方法的综合取舍

方法类别	精度表现	扩展性	适用说明
均值基线	较弱	很强	适合作为最低参考线
偏置模型	中等	很强	能解释用户和物品的整体偏移
Item-kNN	较强	中等	小中规模显式评分数据上常有效
核范数方法	中等	中等偏弱	适合凸优化解释和低秩分析
因子分解方法	较强	较强	适合稀疏大规模推荐任务

5.5 本章小结

本章从建模解释、超参数、收敛、运行时间和鲁棒性角度讨论了实验结果。总体而言，矩阵补全方法的价值不仅在于给出一个评分预测模型，也在于提供一套理解推荐系统稀疏性、低秩结构和算法效率的统一语言。

第六章 总结与展望

6.1 本文工作总结

本文围绕推荐系统中的矩阵补全问题,按照 NJUPT 论文模板完成了一份中文课程论文式整理。正文从推荐系统评分矩阵出发,建立了低秩矩阵补全模型,介绍了秩最小化、核范数松弛、低秩矩阵分解、SGD、ALS 和 Item-kNN 等方法,并结合 MovieLens 数据集给出了表格和图形化实验分析。

从建模角度看,矩阵补全把推荐系统中的缺失评分预测转化为最优化问题。核范数方法提供凸松弛路径,适合理论分析;低秩因子分解方法虽然是非凸问题,但变量规模小、计算效率高,更贴近实际推荐系统;邻域方法则作为强基线帮助判断低秩模型的实际优势。实验结果表明,协同过滤类方法明显优于简单均值基线,不同优化方法在准确率、运行时间和解释性之间存在差异。

6.2 进一步研究方向

后续可以从以下几个方向扩展本文工作:

- 在参数选择上加入更系统的交叉验证,比较不同秩、正则化和学习率对泛化误差的影响。
- 将显式评分矩阵扩展到隐式反馈数据,考虑点击、浏览和购买等行为信号。
- 在矩阵补全模型中引入用户属性、物品内容和时间信息,形成带辅助信息的推荐模型。
- 比较深度推荐模型与传统低秩模型之间的差异,分析最优化方法在复杂模型训练中的作用。
- 在更大规模数据集上测试并行 ALS、增量 SGD 和近似最近邻等工程加速策略。

总体来看,矩阵补全仍然是理解推荐系统的重要基础模型。即使现代推荐系统已经包含更复杂的特征和深度网络结构,低秩建模、正则化、凸松弛和交替优化等思想仍然具有基础价值。

参考文献

- [1] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30–37.
- [2] Mnih A, Salakhutdinov R R. Probabilistic matrix factorization[J]. Advances in neural information processing systems, 2007, 20.
- [3] Candes E, Recht B. Exact matrix completion via convex optimization[J]. Communications of the ACM, 2012, 55(6): 111–119.
- [4] Recht B, Fazel M, Parrilo P A. Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization[J]. SIAM review, 2010, 52(3): 471–501.
- [5] Shamir O, Shalev-Shwartz S. Collaborative filtering with the trace norm: Learning, bounding, and transducing [C]. Proceedings of the 24th Annual Conference on Learning Theory. [S.l.]: JMLR Workshop and Conference Proceedings, 2011: 661–678.
- [6] Cai J F, Candès E J, Shen Z. A singular value thresholding algorithm for matrix completion[J]. SIAM Journal on optimization, 2010, 20(4): 1956–1982.
- [7] Hastie T, Mazumder R, Lee J D, et al. Matrix completion and low-rank svd via fast alternating least squares [J]. The Journal of Machine Learning Research, 2015, 16(1): 3367–3402.
- [8] Keshavan R, Montanari A, Oh S. Matrix completion from noisy entries[J]. Advances in neural information processing systems, 2009, 22.
- [9] Pilászy I, Zibriczky D, Tikk D. Fast als-based matrix factorization for explicit and implicit feedback datasets [C]. Proceedings of the fourth ACM conference on Recommender systems. [S.l.: s.n.], 2010: 71–78.
- [10] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]. Proceedings of the 10th international conference on World Wide Web. [S.l.: s.n.], 2001: 285–295.
- [11] Koren Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model[C]. Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining. [S.l.: s.n.], 2008: 426–434.
- [12] Harper F M, Konstan J A. The movielens datasets: History and context[J]. Acm transactions on interactive intelligent systems (tiis), 2015, 5(4): 1–19.

附录 A 程序清单

本附录给出矩阵分解实验中可使用的核心伪代码，用于说明 SGD-MF 的实现思路。实际课程报告中可以将其替换为完整 Python 实验代码。

代码 1 SGD 矩阵分解核心训练流程

```
1 def train_sgd_mf( ratings , n_users, n_items, rank=20,
2                 lr=0.01, reg=0.02, epochs=15):
3     U = random_normal((n_users, rank), scale=0.01)
4     V = random_normal((n_items, rank), scale=0.01)
5
6     for epoch in range(epochs):
7         shuffle ( ratings )
8         for user, item, rating in ratings :
9             pred = dot(U[user], V[item])
10            err = rating - pred
11
12            old_u = U[user].copy()
13            U[user] += lr * ( err * V[item] - reg * U[user])
14            V[item] += lr * ( err * old_u - reg * V[item])
15
16     return U, V
```

该程序片段对应正文中的式(2.6)和式(3.3)。其中 `ratings` 表示观测评分三元组，`rank` 表示潜在因子维数，`reg` 表示正则化系数。训练完成后，可使用 UV^T 的对应元素作为缺失评分预测值。