



南京邮电大学
Nanjing University of Posts and Telecommunications

面向音频深度伪造检测的自适应持续学习

What to Remember: Self-Adaptive Continual Learning for Audio Deepfake Detection

汇报人：刘彦彤

汇报日期：2025.11.13



研究背景与问题

- 技术挑战:

语音合成与语音转换技术快速发展, 音频深度伪造 (Audio Deepfake) 可能被滥用, 因此迫切需要有效的音频深度伪造检测机制。现有检测模型对已知深度伪造音频识别效果良好, 但面对新型攻击类型时性能显著下降。

- 现有解决方案局限:

特征与架构优化方案: 通过 “提升模型本身的基础能力” 应对未知攻击, 在无法获取新型攻击数据 (如未知攻击初期) 时有用, 但无法持续适应新攻击。

持续学习方案: 主流方法 (如经验回放) 需存储旧数据, 适用性受限; 针对音频深度伪造检测的首个持续学习方法 DFWF 虽能缓解遗忘, 但在新攻击类型上的学习性能上不及微调。

► 2 核心方法：弧度权重修正 (RWM)



图1 t-SNE

核心思想

基于音频深度伪造检测中“真实音频特征分布紧凑、伪造音频特征分布分散”的特性（如图 1 t-SNE 可视化所示），将所有类别分为两类：一类是跨任务特征分布紧凑的（如真实音频），另一类是分布分散的（如各类伪造音频）。并利用自注意力机制动态调整梯度修正方向，平衡新知识获取与旧知识保留。

关键步骤

(1) 类别重组 (Class Regrouping) :

- 计算所有类别在跨任务中的特征紧凑性：通过类内余弦距离 (d_r) 量化分布紧凑性，公式为

$$d_r = \frac{1}{N_r} \sum_{m=1}^{N_r} \sum_{n=1}^{N_r} \cos_{dis}(x_m, x_n) \quad x_m, x_n \in class_r$$

- 按紧凑性排序（假设 $d_1 < d_2 < \dots < d_R$ ），引入超参数 r_s ，将前 r_s 个紧凑性最高的类别归为相似组 (S)（如真实音频），其余归为非相似组 (D)（如各类伪造音频）。针对“非相似组（伪造音频）”的梯度修正策略——正交方向更新，既学习新攻击的特征，又不破坏旧攻击的识别知识。针对“相似组（真实音频）”的梯度修正策略——最小化梯度修改，模拟经验回放的效果，保留对真实音频的稳定识别能力。

► 2 核心方法：弧度权重修正 (RWM)




图2 RWM 算法中梯度修正方向的计算过程

关键步骤

(2) 自优化方向修正 (Self-Optimizing Direction Modification) :

- 计算基础修正方向：
正交方向P：通过类似递归最小二乘法 (RLS) 构建，与旧任务数据平面正交。
正交补方向Q：与P正交。

► 2 核心方法：弧度权重修正 (RWM)




图2 RWM 算法中梯度修正方向的计算过程

关键步骤

- 自注意力学习旋转弧度 (LRR)：在分类器前引入自注意力机制，计算批次内每个样本的注意力得分，并归一化。通过公式 $\theta_t(i, j) = \sin^{-1}(\delta_t(i, j))$ 将注意力得分映射为旋转弧度。

► 2 核心方法：弧度权重修正 (RWM)




图2 RWM 算法中梯度修正方向的计算过程

关键步骤

- 最终梯度修正方向计算：
 计算相似组与非相似组的弧度和 $\sum \theta_s(i, j)$ 、 $\sum \theta_d(i, j)$ 。
 最终旋转 $\theta_f(i, j) = \frac{\pi}{4} + \frac{\sum \theta_s(i, j) - \sum \theta_d(i, j)}{2}$
 最终方向 $R = u(\frac{P}{\|P\|} + \beta \frac{Q}{\|Q\|})$ ，模型通过R修正梯度，实现跨任务学习。

音频深度伪造检测实验

实验设置:

数据集: 3 个主流数据集, 包括 ASVspoof2019LA (S)、ASVspoof2015 (T_1)、In-the-Wild (T_2), 采用等错误率 (EER) 评估。

模型架构: Wav2vec 2.0 (预训练模型 XLSR-53) 作为特征提取器, 自注意力卷积神经网络 (S-CNN) 作为分类器。

对比方法: 基线 (Baseline)、全回放 (Replay-All)、微调 (Finetune)、经典持续学习方法 (EWC、OWM、LwF) 及 DF WF。

图像识别实验 (泛化性验证)

实验设置:

数据集: 持续学习基准 CLEAR, 含 11 个时序动态类别, 分 10 个任务进行 10 分类, 以准确率评估。

模型架构: 预训练 ResNet-50 (冻结) 作为特征提取器, 线性层作为分类器。

对比方法: 12 种主流持续学习方法 (如 EWC、LwF、GEM、Replay 等)。

Method	$S \rightarrow T_1$		$S \rightarrow T_1 \rightarrow T_2$		
	S	T_1	S	T_1	T_2
Baseline	0.258	24.532	0.258	24.532	91.473
Replay-All	0.406	0.201	2.344	7.253	1.003
Finetune	7.324	0.510	4.636	28.765	2.543
EWC	2.832	0.570	8.684	12.397	3.722
OWM	2.448	0.540	4.756	10.132	3.647
LwF	3.123	0.343	7.505	9.547	1.540
DFWF	1.849	0.689	6.211	9.672	6.478
RWM (Ours)	0.438	0.212	2.896	7.693	1.161

(a)

Method	$S \rightarrow T_2$		$S \rightarrow T_2 \rightarrow T_1$		
	S	T_2	S	T_2	T_1
Baseline	0.258	91.473	0.258	91.473	24.532
Replay-All	2.740	2.160	5.197	13.893	0.842
Finetune	20.976	4.978	13.362	35.368	0.876
EWC	8.039	5.615	7.343	29.516	0.933
OWM	8.130	5.065	6.675	26.619	1.042
LwF	6.453	4.998	10.035	32.409	0.897
DFWF	4.324	6.275	6.994	24.697	1.332
RWM (Ours)	3.665	2.247	5.616	15.993	0.861

(b)

表 1 不同任务序列下各方法的 EER (%) 对比

与其他方法的对比

在两数据集（如 $S \rightarrow T_1$ 、 $S \rightarrow T_2$ ）和三数据集（ $S \rightarrow T_1 \rightarrow T_2$ ）场景中，RWM 均实现最优性能。

Method	10		100		1000	
	S	T_2	S	T_2	S	T_2
Baseline	0.258	91.473	0.258	91.473	0.258	91.473
Replay-All	0.897	15.326	1.203	4.198	2.715	2.162
Finetune	8.223	19.385	16.058	6.503	16.437	4.999
EWC	7.301	18.599	7.666	8.977	6.148	7.576
OWM	7.021	19.684	8.229	8.177	7.860	4.364
LwF	8.019	19.673	5.750	5.950	4.037	6.391
DFWF	6.894	19.992	4.246	9.879	5.129	8.864
RWM (Ours)	2.463	17.252	1.507	5.305	7.670	3.921

表 2 有限样本实验的 EER (%) 对比

有限训练样本下的对比

当新任务训练样本减少（10-1000 个）时，RWM 仍优于其他持续学习方法。

Method	$S \rightarrow T_1$		$S \rightarrow T_1 \rightarrow T_2$		
	S	T_1	S	T_1	T_2
Baseline	0.258	24.532	0.258	24.532	91.473
RWM(Ours)	0.438	0.212	2.896	7.693	1.161
-LRR	2.448	0.540	4.756	10.132	3.647
-WM	7.324	0.510	4.636	28.765	2.543

(a)

Method	$S \rightarrow T_2$		$S \rightarrow T_2 \rightarrow T_1$		
	S	T_2	S	T_2	T_1
Baseline	0.258	91.473	0.258	91.473	24.532
RWM(Ours)	3.665	2.247	5.616	15.993	0.861
-LRR	8.130	5.065	6.675	26.619	1.042
-WM	20.976	4.978	13.362	35.368	0.876

(b)

表3 消融研究的 EER (%) 对比

消融实验

移除学习旋转弧度 (-LRR) 或权重修正 (-WM) 会导致旧任务性能下降，证明两模块对缓解遗忘、提升新任务学习能力的必要性。

Continual Learning Methods	Accuracy on each experience									
	Exp ₁	Exp ₂	Exp ₃	Exp ₄	Exp ₅	Exp ₆	Exp ₇	Exp ₈	Exp ₉	Exp ₁₀
Replay-All	94.85	94.65	94.75	94.65	95.86	95.35	95.15	94.65	95.76	96.16
Finetune	87.68	90.00	91.11	91.82	90.40	89.90	90.30	90.61	90.61	93.33
EWC	84.04	84.95	85.86	87.07	85.66	85.56	86.97	86.16	85.76	87.78
LwF	88.59	88.89	87.27	90.51	87.68	87.78	87.47	87.47	88.79	88.48
GDF	91.11	91.62	88.38	91.01	88.79	89.19	90.20	87.68	90.10	90.30
CWR	90.71	91.72	90.71	91.52	89.49	90.91	91.62	90.71	91.82	93.74
GEM	88.38	89.70	90.81	91.41	90.20	89.29	90.91	89.60	90.71	93.03
AGEM	92.32	91.41	92.02	93.43	91.52	92.32	92.22	91.52	92.83	94.75
SI	91.31	92.02	91.41	93.74	91.52	91.72	92.63	91.11	92.22	95.05
BRF	89.29	88.99	88.18	88.48	89.19	89.19	90.10	88.38	89.19	90.00
RF	88.38	90.30	90.00	91.62	90.91	90.61	91.41	91.41	91.11	93.33
OWM	91.62	92.12	91.82	93.64	91.72	92.42	92.22	92.32	92.42	95.05
RWM (Ours, $r_s=3$)	92.15	94.12	92.34	93.48	94.91	93.01	92.78	93.52	93.76	92.70
RWM (Ours, $r_s=4$)	93.64	93.64	92.53	93.84	93.23	93.13	92.93	93.03	94.14	95.25
RWM (Ours, $r_s=5$)	93.35	92.95	93.01	92.75	92.62	92.45	93.17	92.64	93.96	93.68

表4 所有 CLEAR 任务训练后各方法的准确率 (%) 对比

与其他方法的对比

RWM 方法性能仅次于 Replay-All（被视为持续学习性能的上限）。




图3 不同持续学习方法在 CLEAR 基准前 5 个任务后的性能对比

不同持续学习方法在 CLEAR 基准前 5 个任务后的性能对比

RWM 在任务初期（前 8 个任务）准确率暂时低于部分方法，但在任务后期（第 8 个任务之后）准确率快速提升，最终接近性能上限（Replay-All）。

Ablation study	Accuracy on each experience									
	Exp ₁	Exp ₂	Exp ₃	Exp ₄	Exp ₅	Exp ₆	Exp ₇	Exp ₈	Exp ₉	Exp ₁₀
RWM (Ours)	93.64	93.64	92.53	93.84	93.23	93.13	92.93	93.03	94.14	95.25
-LRR	91.62	92.12	91.82	93.64	91.72	92.42	92.22	92.32	92.42	95.05
-WM	87.68	90.00	91.11	91.82	90.40	89.90	90.30	90.61	90.61	93.33

表5 RWM 方法的消融研究准确率（%）对比

消融研究

结果表明，学习旋转弧度和权重修正模块都对识别性能有积极影响。

01

本文提出一种有效的持续学习算法——弧度权重修正（RWM），使模型能在每个任务上学习用于分类的区分性信息，同时基于特征分布的相似度自主优化不同任务间持续学习的梯度方向，无需存储旧数据。RWM 通过类别分组与自优化梯度修正，有效平衡了知识保留与新知识获取，在音频深度伪造检测中显著优于主流持续学习方法，且具备跨领域泛化潜力。



汇报完毕， 敬请老师同学批评指正！

 汇报人：刘彦彤

 汇报日期：2025.11.13

