

融合稳定同位素与矿物元素的新疆枸杞产地溯源 集成学习模型研究

摘要

枸杞具有明显的产地品牌属性，不同产区产品在市场价格和消费者认可度上存在差异，因此产地标签的真实性直接关系到产品流通和市场监管。本文使用 286 条枸杞理化检测记录，筛选出 262 个具有新疆/非新疆标签的样本，其中新疆样本 145 个、非新疆样本 117 个。模型输入包括 $\delta^{13}\text{C}$ 、 $\delta^{15}\text{N}$ 、 $\delta^2\text{H}$ 、 $\delta^{18}\text{O}$ 四个稳定同位素指标和 55 个矿物元素指标。建模时将缺失值中位数插补、Extra Trees 特征选择、标准化和分类器训练放入同一 Pipeline，并采用 5×5 重复分层交叉验证、30% 独立测试集、特征来源消融、模型分歧复核和跨年份验证评价模型表现。结果显示，稳定同位素与矿物元素融合后，Stacking 在重复交叉验证中的 Accuracy、AUC 和 F1 分别为 0.9840 ± 0.0128 、 0.9991 ± 0.0018 和 0.9855 ± 0.0116 ；与表现最好的单一模型随机森林相比，平均 Accuracy 仅提高 0.0023，但最低折 Accuracy 由 0.9231 提高到 0.9615，结果波动也更小。特征来源消融中，单独使用稳定同位素和单独使用矿物元素的 Accuracy 分别为 0.9069 ± 0.0396 和 0.9214 ± 0.0347 ，融合后提高到 0.9840 ± 0.0128 。30% 独立测试集中，Stacking 集成学习强制二分类 Accuracy 为 0.9620，3 个新疆样本被判为非新疆；引入 Stacking 与梯度提升决策树分歧复核后，75 个样本进入自动判定流程，自动判定覆盖率为 94.9%；4 个样本进入待复核集合，复核率为 5.1%，自动判定样本中未出现误判。跨年份验证 Accuracy 约为 0.61，反映模型跨年度应用仍受年份、采样或检测批次差异影响。在现有样本分布内，稳定同位素-多元素融合指纹可为新疆枸杞产地真实性初筛提供有效信息，Stacking 集成学习的主要价值在于提高结果稳定性和识别需要复核的边界样本。

关键词：枸杞；食品真实性；地理来源；稳定同位素；多元素指纹；集成学习

研究亮点

- 稳定同位素与 55 个矿物元素融合后，模型对新疆/非新疆枸杞具有较高区分度。
- 插补、特征选择和标准化均在训练折内完成，避免验证集信息提前进入建模流程。
- Stacking 集成学习模型相较随机森林平均 Accuracy 仅小幅提高，但最低折 Accuracy 由 0.9231 升至 0.9615。

- 30% 独立测试集中 3 个新疆样本被误判，模型分歧规则可将其转入复核。

1 引言

枸杞既是常见食用农产品，也是具有药食同源属性的特色植物资源。对消费者和监管部门而言，产地标签会影响产品定价、品牌信誉和真实性判断。新疆枸杞长期被认为具有较强的产区特征，其形成可能与充足光照、较大昼夜温差、强蒸发环境以及部分产区土壤矿物背景有关。这些环境差异可能反映在稳定同位素组成和矿物元素谱中，也为利用理化指纹开展产地识别提供了基础。

稳定同位素和多元素分析是植物性食品产地溯源中较常用的两类指标。 $\delta^2\text{H}$ 和 $\delta^{18}\text{O}$ 多与降水、灌溉水及蒸发富集有关， $\delta^{13}\text{C}$ 可反映水分胁迫和光合生理过程， $\delta^{15}\text{N}$ 可能受到土壤氮循环和施肥方式影响；矿物元素则更多用于表征样品元素组成、土壤母质和区域地球化学背景差异 [1,2]。单一信息源往往只覆盖产地环境的一部分，因而同位素与元素指纹的联合建模更适合描述复杂产地差异。

机器学习为高维理化指纹数据提供了比传统线性判别更灵活的处理方式。已有研究指出，机器学习已广泛用于食品和农产品地理来源判别，可在多变量指纹中提取线性模型难以充分利用的组合信息 [3]。在农产品溯源研究中，数据融合、集成学习和非线性机器学习也被用于提升复杂指纹的判别能力 [4-7]。Schmauder 等 [8] 将 DART-MS 指纹、随机森林和重复交叉验证用于玉米地理来源识别；Galvan 等 [9] 利用 EDXRF 元素指纹和化学计量学方法区分番茄、甜椒的生产体系及地理区域。这些研究说明，理化指纹与机器学习结合可以服务于植物性食品真实性识别，但模型性能必须通过合适的验证设计来支撑。

本文关注三个问题：稳定同位素与矿物元素融合是否优于单一信息源；Stacking 是否能在随机森林等强单一模型基础上改善稳定性；模型在独立测试集和跨年份验证中呈现何种误判结构和性能边界。

在实际筛查场景中，产地识别模型更适合承担初筛和风险分层功能。对于模型判断一致、置信度较高的样本，可作为优先通过或重点核验的依据；对于模型分歧明显的样本，则应进入复测、标签核查或补充证据流程。枸杞这类具有明显产区品牌属性的产品，尤其需要这种模型判别 + 人工复核的组合方式。

已有枸杞及相关农产品溯源研究已经表明，同位素、多元素、稀土元素、光谱和质谱指纹均可能携带产地信息 [1,2,10-13]。同位素指标少、解释相对清楚，但容易受年份气候和水源变化影响；元素指纹维度高，能反映更丰富的地球化学背景，也更容易受到土壤、施肥、加工和批次差异干扰。本文将两类指标并列比较，再考察两者融合后的增益。

小样本高维建模最容易出现的问题，是在交叉验证前提前完成插补、特征筛选或标准化，导致验证折样本的信息间接参与训练。本文把这些步骤写入 Pipeline，并在每个

训练折内重新拟合，再用于对应验证折或测试集。这样得到的结果更保守，也更适合向后续独立样本验证。

因此，本文先比较稳定同位素、矿物元素及二者融合后的判别效果，再比较单一模型与 Stacking 集成学习 [14] 的分类稳定性，最后结合独立测试集误判和跨年份验证结果评估模型的适用范围。

2 数据与方法

2.1 数据来源与研究边界

本研究使用的数据由农业科研机构提供，数据形式为已整理的结构化表格。原始数据包含 286 条记录和 64 列变量，字段包括样本编号、年份、产地标签、品种信息、稳定同位素指标和多元素指标。剔除无产地标签或标签不属于新疆/非新疆二分类范围的记录后，共有 262 个样本进入模型构建，其中新疆样本 145 个，非新疆样本 117 个。样本年份覆盖 2020、2021 和 2022 年。本文所称稳定同位素-多元素融合指纹，是指由 $\delta^{13}\text{C}$ 、 $\delta^{15}\text{N}$ 、 $\delta^2\text{H}$ 、 $\delta^{18}\text{O}$ 四个稳定同位素指标与 55 个矿物元素指标共同构成的 59 维理化特征矩阵。

表 1 数据集组成与建模变量

项目	数量或说明
原始记录	286
进入建模的有标签样本	262
产地类别	新疆 145；非新疆 117
年份	2020、2021、2022
稳定同位素	$\delta^{13}\text{C}$ 、 $\delta^{15}\text{N}$ 、 $\delta^2\text{H}$ 、 $\delta^{18}\text{O}$ ，共 4 个
矿物元素	Na、Mg、K、Ca、Mn、Cu、Rb、Mo、Lu 等，共 55 个
模型特征总数	59

2.2 样品采集与产地标签确认（信息待补）

该部分需由数据提供方补充采样地点、采样年份、样品来源和产地标签确认依据。

2.3 样品前处理与保存条件（信息待补）

该部分需补充干燥、粉碎、均质、保存、运输及检测前储存条件。

2.4 稳定同位素测定与质量控制（信息待补）

该部分需补充仪器型号、分析条件、校准标准、重复测定、精密度和质控样信息。

2.5 多元素测定与质量控制（信息待补）

该部分需补充消解体系、仪器方法、元素列表、检出限、定量限、标准曲线和批次质控结果。

2.6 数据质量审核与异常值处理（信息待补）

该部分需补充数据清洗、缺失值来源、低于检出限数据处理、异常值判定和样本剔除原则。

2.7 建模 Pipeline 与验证设计

特征矩阵由四个稳定同位素指标和 55 个矿物元素指标构成。缺失值采用训练集内中位数插补。特征选择采用 `SelectFromModel` 封装的 `ExtraTreesClassifier`；`Extra Trees` 通过极端随机树结构增加树间差异，适合用于高维变量初筛 [15]。本研究将特征选择器树数量设为 160，`max_features` 设为 `sqrt`，`class_weight` 设为 `balanced`，随机种子设为 2026，筛选阈值为训练折内特征重要性的中位数，因此每一折保留的变量数由训练数据决定，并非预先固定为 20 个变量。考虑到不同算法对变量尺度的敏感性不同，逻辑回归和 SVM 等模型在各自 Pipeline 分支中进行 Z-score 标准化；随机森林、GBDT 和 Extra Trees 属于树模型，建模时不额外进行标准化。上述步骤均在交叉验证训练折内部拟合，再应用于验证折或测试集。特征选择器树数量敏感性分析仅作为事后稳健性检查，不用于模型选择。

模型比较包括逻辑回归、SVM-RBF、随机森林、GBDT、Extra Trees 和 Stacking，覆盖线性分类器、核函数分类器、树模型及集成学习框架。根据实际代码，Stacking 整合 SVM-RBF、随机森林、GBDT 和 Extra Trees 四类基学习器的概率输出，并使用逻辑回归作为元学习器；随机森林、Extra Trees 和 Stacking 的基本思想分别见 Breiman[16]、Geurts 等 [15] 和 Wolpert[14]，机器学习在食品与农产品产地溯源中的应用背景见 Li 等 [3]。各模型主要参数及特征选择器敏感性分析见附表 1 和附表 2。本文将新疆样本定义为阳性类别，并据此计算 AUC、F1、Precision 和 Recall。在模型比较部分，本文对逻辑回归、SVM-RBF、随机森林、GBDT、Extra Trees 和 Stacking 分别报告 Accuracy、AUC、F1、Precision、Recall 和最低折 Accuracy；特征消融与跨年份验证根据分析重点报告 Accuracy、AUC、F1，并在逐年结果中补充 Balanced Accuracy。主验证采用 5×5 重复分层交叉验证；另设置 30% 独立测试集检验固定划分下的分类表现，并通过

Stacking 与 **GBDT** 分歧样本识别边界样本；最后采用基于年份分组的留一组交叉验证评估时间外推能力，后文简称跨年份验证。

重复分层交叉验证用于估计模型在现有数据分布内的平均表现和波动范围。与单次交叉验证或单次训练测试划分相比， 5×5 重复设计能够降低随机划分偶然性，使模型比较不依赖某一次样本分配。本文同时报告平均值、标准差和最低折 **Accuracy**，是因为真实性筛查更关注模型在不利数据划分下是否仍能保持可接受性能。若一个模型平均准确率较高但最低折表现明显下降，其实际应用风险仍然较高。

Stacking 的基学习器覆盖核函数模型和三类树模型，其差异主要来自 **RBF** 核函数非线性边界、随机森林的随机特征划分、**Extra Trees** 的极端随机切分以及 **GBDT** 的逐步残差修正。逻辑回归不作为基学习器参与第一层训练，而是作为元学习器整合四类基学习器的 **out-of-fold** 类别概率。**StackingClassifier** 的内部融合采用 5 折分层交叉验证，基学习器通过训练集内部的 **out-of-fold** 类别概率生成二级训练特征，元学习器为逻辑回归，**stack_method** 设为 **predict_proba**。该设置可避免元学习器直接使用基学习器在同一训练样本上的拟合概率。

独立测试集验证用于观察固定样本划分下的模型分类结果。本文使用 **train_test_split** 按 7:3 比例进行分层划分，**test_size** 为 0.3，**random_state** 为 42；独立测试集只在模型拟合完成后用于测试，插补、特征选择、标准化和分类器训练均由 70% 训练集内的 **Pipeline** 完成。**Stacking** 与 **GBDT** 分歧复核作为独立测试集结果解释中的风险分层规则报告，因此本文同时保留强制二分类 **Accuracy** 和自动判定覆盖率，不用条件性结果替代总体准确率。

跨年份验证用于考察模型的跨年份外推能力。同一年份样本可能共享采样批次、气候条件、检测批次或流通来源，随机分层交叉验证难以充分反映这种跨年份差异。将某一年份作为跨年份测试集，可以更直接地观察模型面对未参与训练年份时的性能损失。




图 1: Stacking 集成学习模型训练与验证结构

3 结果

3.1 单一算法与 Stacking 模型表现

在 5×5 重复分层交叉验证中，各模型均表现出较高的产地识别能力。随机森林是表现最好的单一算法模型，Accuracy、AUC 和 F1 分别为 0.9817±0.0191、0.9990±0.0019 和 0.9835±0.0170。Stacking 整合四类基学习器输出后，Accuracy 为 0.9840±0.0128，AUC 为 0.9991±0.0018，F1 为 0.9855±0.0116。二者平均 Accuracy 只相差 0.0023，差距并不大；更值得注意的是，Stacking 的标准差更小，最低折 Accuracy 为 0.9615，高于随机森林的 0.9231，说明其在样本组合更具挑战的交叉验证折次中更稳定。

表 2 不同模型在 5×5 重复分层交叉验证中的表现

模型	最低 Ac-				
	Accuracy	curacy	AUC	F1	Precision Recall
Logistic Regression	0.9451±0.0266	0.8846	0.9815±0.0191	0.9509±0.0236	0.9413±0.0355
SVM-RBF	0.9649±0.0159	0.9423	0.9965±0.0037	0.9680±0.0146	0.9772±0.0259
Random Forest	0.9817±0.0191	0.9231	0.9990±0.0019	0.9835±0.0170	0.9842±0.0262
GBDT	0.9779±0.0198	0.9245	0.9933±0.0081	0.9799±0.0185	0.9798±0.0219
Extra Trees	0.9717±0.0172	0.9231	0.9985±0.0030	0.9748±0.0150	0.9673±0.0309
Stacking	0.9840±0.0128	0.9615	0.9991±0.0018	0.9855±0.0116	0.9866±0.0188




图 2: 不同模型在重复交叉验证中的 Accuracy 分布

从模型类型看，线性模型、核函数模型和树模型均能达到较高水平，说明新疆与非新疆样本之间已经存在较明显的线性可分信息，同时也可能包含非线性边界和变量组合关系。逻辑回归作为线性基线的平均 Accuracy 为 0.9451，已经能够提供较好区分；随机森林和 GBDT 进一步提高了平均表现。Stacking 在此基础上获得最优综合指标，说明不同类型模型分别从线性关系、非线性边界和树结构变量交互中提取的信息具有互补性。

3.2 特征来源消融与独立测试集验证

特征来源消融显示，稳定同位素和矿物元素均具有产地判别信息，但单独建模的效果低于融合指纹。仅使用稳定同位素时，Stacking Accuracy 为 0.9069 ± 0.0396 ；仅使用矿物元素时，Accuracy 为 0.9214 ± 0.0347 ；融合两类指纹后，Accuracy 提高到 0.9840 ± 0.0128 。该结果支持本文采用多源指纹融合，避免依赖某一类指标单独完成判别。

表 3 特征来源消融实验结果

特征组合	特征数	Accuracy	AUC	F1
稳定同位素	4	0.9069 ± 0.0396	0.9775 ± 0.0143	0.9144 ± 0.0379
矿物元素	55	0.9214 ± 0.0347	0.9748 ± 0.0214	0.9297 ± 0.0307
稳定同位素 + 矿物元素	59	0.9840 ± 0.0128	0.9991 ± 0.0018	0.9855 ± 0.0116




图 3: 不同特征来源的模型表现

这一提升可以从两类信息的互补性理解。稳定同位素变量较少，主要反映水分来源、蒸发环境和植物生理响应；矿物元素维度更高，更多体现样品元素组成、土壤母质和区域地球化学背景差异 [17-20]。单独使用任何一类指标，都可能遗漏另一类环境信息。融合后，模型同时利用水分、气候和矿物背景相关信号，分类效果因此提高。

三种特征组合的 AUC 均高于 0.97，说明单独使用同位素或元素指纹也具有较好的类别区分和概率排序能力。不过，在固定阈值下进行新疆/非新疆判定时，Accuracy 和 F1 在融合后提升更明显。对实际筛查而言，这一点很重要，因为监管或检测流程最终需要给出类别判断，而不仅是样本排序。

在 30% 独立测试集上，Stacking 强制二分类 Accuracy 为 0.9620，AUC 为 0.9994，F1 为 0.9647。混淆矩阵显示，非新疆样本 35/35 正确，新疆样本 41/44 正确，3 个误判均为新疆样本被判为非新疆。引入 Stacking 与 GBDT 分歧复核后，75 个样本进入自动判定流程，自动判定覆盖率为 94.9%；4 个样本进入人工复核，复核率为 5.1%。这里的自动判定覆盖率是指无需人工复核、可直接由模型给出类别结果的样本占全部独立测试样本的比例。自动判定样本中未出现误判。因此，分歧复核规则的效果不能只看自动判定样本是否全部正确，还需要同时报告自动判定覆盖率和复核率。




图 4: 独立测试集 ROC 曲线




图 5: 独立测试集混淆矩阵

3.3 特征稳定性与跨年份验证

25 次交叉验证训练过程中, 图 6 展示的稳定入选变量包括 $\delta^2\text{H}$ 、Mo、Lu、Na、 $\delta^{18}\text{O}$ 、Te、Mg、Mn、 $\delta^{15}\text{N}$ 、Tb、Sb、Rb、K、U、Pd、Cu、Hf、Se、Ca 和 $\delta^{13}\text{C}$ 。这些变量是在 25 次训练中入选频率为 1.00 的变量, 而非模型预先固定选择的前 20 个变量。模型分类依赖同位素与多元素的共同贡献, 而非单一变量。特征重要性反映的是变量在当前模型中的判别贡献, 不能直接替代土壤、水源或栽培因素的机理验证。




图 6: 25 次交叉验证训练中的稳定入选变量

从变量含义看， $\delta^2\text{H}$ 和 $\delta^{18}\text{O}$ 与水分来源及蒸发富集关系较密切， $\delta^{13}\text{C}$ 和 $\delta^{15}\text{N}$ 则可能反映水分胁迫、碳同化和氮素来源差异 [1,2]。Na、Mo、Lu、Tb、Hf、U 等元素在模型中稳定入选，提示元素组成中存在与产地差异相关的判别线索；其中 Lu、Tb 等稀土相关元素的产地表征价值可与已有枸杞稀土元素研究相互印证 [13]。正文重点讨论这些代表性变量，是因为它们更容易与产地环境联系起来；图 6 中同时出现的 Ca、Se、Cu、Pd、Sb 等变量仍应作为候选判别变量保留，后续需要结合土壤、水源和采样坐标进一步验证。

跨年份验证中，各模型准确率均明显低于随机分层交叉验证。SVM-RBF 的平均 Accuracy 为 0.6100 ± 0.2125 ，Stacking 为 0.6050 ± 0.1894 ，二者差异仅 0.005，远小于标准差范围，不能据此认为 SVM 在跨年份条件下稳定优于 Stacking。现有结果显示，年度气候、采样批次、检测批次或样本来源构成的变化，都会削弱模型从训练年份外推到新年份的能力。

仅报告均值和标准差会掩盖不同年份之间的差异。进一步拆分 Stacking 的跨年份验证结果可见，以 2020 年为测试集时 Accuracy 为 0.7455，以 2021 年为测试集时为 0.6800，而以 2022 年为测试集时降至 0.3896。值得注意的是，2022 年测试集的 AUC 仅为 0.4731，说明该年份的性能下降并非仅由固定分类阈值造成，模型对类别概率的排序能力也明显减弱。当前模型适合作为已有样本分布内的快速筛查工具，跨年份应用仍需要新增年份样本持续检验。

表 4 跨年份验证中的模型表现

模型	Accuracy	AUC	F1	Precision	Recall
Extra Trees	0.5283±0.0739	0.6868±0.2258	0.4989±0.1051	0.7017±0.2552	0.4913±0.2782
GBDT	0.5902±0.1790	0.7553±0.2382	0.5826±0.1963	0.6813±0.2877	0.5524±0.2159
Logistic Regression	0.6079±0.1821	0.7379±0.2025	0.6117±0.2003	0.6980±0.2766	0.6218±0.2615
Random Forest	0.5518±0.1862	0.6857±0.2549	0.5801±0.1583	0.6413±0.3082	0.5642±0.0287
SVM-RBF	0.6100±0.2125	0.7283±0.2373	0.5964±0.2226	0.6963±0.3203	0.5504±0.1708
Stacking	0.6050±0.1894	0.7279±0.2467	0.6115±0.1851	0.6920±0.3102	0.5699±0.0748

表 5 Stacking 模型跨年份验证逐年结果

训练年份	测试年份	测试样本数 (新疆/非新疆)	Accuracy	AUC	F1	Balanced Accuracy
2021、2022	2020	110(72/38)	0.7455	0.9656	0.7627	0.7993
2020、2022	2021	75(40/35)	0.6800	0.7450	0.6667	0.6857
2020、2021	2022	77(33/44)	0.3896	0.4731	0.4051	0.4015




图 7: 跨年份验证中的模型 Accuracy 表现

4 讨论

4.1 独立测试集误判样本与筛查流程

独立测试集结果中，一个值得注意的现象是：35 个非新疆样本全部判对，错误集中在 3 个新疆样本被判为非新疆。该误判方向可能与新疆样本内部差异较大有关。新疆不同产区在土壤盐分、灌溉条件、品种、采收年份和流通渠道上可能并不完全一致，少数新疆样本的理化指纹接近非新疆样本时，强制二分类就容易给出错误标签。

模型分歧复核的意义也主要体现在这里。若只看强制二分类，3 个新疆样本会直接进入错误结果；加入 Stacking 与 GBDT 分歧规则后，它们被转入待复核集合，另有 1 个非新疆样本也被提示需要核查。该规则下，自动判定覆盖率为 94.9%，复核率为 5.1%，自动判定样本未出现误判。对于真实性筛查而言，这种表达比单独报告条件性正确率更完整，因为它同时交代了模型能自动处理多少样本，以及多少样本仍需人工或实验复核。

4.2 Stacking 集成的实际贡献

随机森林已经取得较高准确率，因此 Stacking 的优势主要体现为稳定性改善，而非平均准确率的大幅提升。随机森林的 Accuracy 为 0.9817 ± 0.0191 ，Stacking 的平均 Accuracy 为 0.9840 ± 0.0128 ，提升幅度较小；更关键的是标准差下降、最低折 Accuracy 提高，以及独立测试集中可通过模型分歧识别边界样本。Stacking 在本研究中的作用可以概括为对强单一模型的稳健补充：它整合 SVM-RBF、随机森林、GBDT 和 Extra

Trees 的概率判断, 并由逻辑回归元学习器完成二级判别, 使结果在不同数据划分下更稳。

跨年份验证进一步表明, 集成模型并不能自动解决所有外推问题。Stacking 在跨年份条件下没有超过 SVM-RBF, 说明当年份差异带来分布变化时, 单纯增加模型复杂度未必有效。对本文来说, 这一结果明确限制了模型的使用范围: 现阶段可以用于同分布样本筛查和边界样本发现, 跨年份判定仍需要更多独立年份样本训练和校准。

4.3 指纹融合

与仅使用稳定同位素或仅使用矿物元素相比, 融合特征在 Accuracy 和 F1 上均取得更高结果, 说明两类指纹提供的判别信息并不完全重叠。 $\delta^2\text{H}$ 、 $\delta^{18}\text{O}$ 与水分来源及蒸发过程有关, 适合反映新疆干旱、强蒸发条件下可能形成的水分信号; $\delta^{13}\text{C}$ 、 $\delta^{15}\text{N}$ 则可能与植物生理状态、氮素来源和栽培管理有关。元素变量中, Na、Mo、Lu、Tb、Hf、U 等更适合作为产地判别的候选线索, 其中 Lu、Tb 等稀土相关元素与已有枸杞道地性研究具有一定对应关系 [13]。这些解释只能作为环境线索, 不能直接写成确定的产地形成机制。

5 结论

本文基于 262 个有标签枸杞样本, 融合四个稳定同位素指标和 55 个矿物元素指标, 构建了新疆/非新疆枸杞产地真实性识别模型。特征来源消融显示, 融合指纹明显优于单独使用稳定同位素或矿物元素。5×5 重复分层交叉验证中, Stacking 的 Accuracy、AUC 和 F1 分别为 0.9840 ± 0.0128 、 0.9991 ± 0.0018 和 0.9855 ± 0.0116 ; 与最佳单一模型随机森林相比, 平均 Accuracy 提升有限, 但结果波动更小, 最低折 Accuracy 更高。30% 独立测试集中, 3 个误判均为新疆样本被判为非新疆; 采用 Stacking 与 GBDT 分歧复核后, 自动判定覆盖率为 94.9%, 复核率为 5.1%, 自动判定样本中未出现误判。

在现有样本分布内, 稳定同位素-多元素融合指纹能够为新疆枸杞产地初筛提供有效信息。Stacking 相比随机森林的平均 Accuracy 提升有限, 但交叉验证波动更小, 并能辅助识别独立测试集中的待复核样本。跨年份验证 Accuracy 约为 0.61, 2022 年作为测试集时 Accuracy 和 AUC 下降明显, 说明模型跨年份应用仍需要更多年份和独立样本支持。后续研究应补充多年份、独立产区和外部盲样数据, 并完善采样、检测和批次信息, 使模型从现有数据集上的高准确率结果逐步过渡到可复核、可解释的实际筛查工具。

A 附录

附表 1 模型与特征选择主要参数

模型/步骤	主要参数
Feature selector	ExtraTreesClassifier; n_estimators=160; max_features=sqrt; threshold=median; class_weight=balanced; random_state=2026
Logistic Regression	C=0.8; penalty=L2; max_iter=5000; class_weight=balanced; random_state=2026
SVM-RBF	C=2.5; gamma=scale; probability=True; class_weight=balanced; random_state=2026
Random Forest	n_estimators=220; max_features=sqrt; min_samples_leaf=1; class_weight=balanced; random_state=2026
GBDT	n_estimators=120; learning_rate=0.035; max_depth=2; subsample=0.85; random_state=2026
Extra Trees	n_estimators=240; max_features=sqrt; min_samples_leaf=1; class_weight=balanced; random_state=2026
Stacking	Base learners=SVM-RBF, Random Forest, GBDT, Extra Trees; internal cv=5; stack_method=predict_proba; meta-learner=Logistic Regression(C=0.8, max_iter=5000, class_weight=balanced)

注:逻辑回归在 Stacking 中作为元学习器,不计入四个基学习器;正文中的 Stacking 模型均按该结构解释。

附表 2 Extra Trees 特征选择器树数量敏感性分析

特征选择器树 数量	5 折保留特征 数均值 ±SD(范 围)	与 160 棵树入 选集合 Jaccard 均值	最低 Jaccard	5 折均入选变 量数
40	30.0±0.0(30- 30)	0.787	0.765	20
160	30.0±0.0(30- 30)	1.000	1.000	22
200	30.0±0.0(30- 30)	0.911	0.875	25
500	30.0±0.0(30- 30)	0.899	0.875	25

注：该分析只比较不同树数量下训练折内变量集合的稳定性，不用于模型选择；主模型参数在独立测试集评价前已经固定。由于筛选阈值为特征重要性中位数，保留特征数接近 30 个主要由阈值规则决定，因此同时报告变量集合 Jaccard 重合度和 5 折均入选变量数。

参考文献

[1] Ju Y J, Liu H J, Niu S H, Kang L, Ma L, Li A, Zhao Y, Yuan Y W, Zhao D Y. Optimizing geographical traceability models of Chinese Lycium barbarum: Investigating effects of region, cultivar, and harvest year on nutrients, bioactives, elements and stable isotope composition[J]. Food Chemistry, 2025, 467: 142286. DOI: 10.1016/j.foodchem.2024.142286.

[2] Peng Q, Huang J X, Li S S, Massou B B, Xie G F. Geographical traceability of wolfberry pulp: Integrating stable isotopes, minerals, nutrients, and chemometric[J]. Journal of Food Composition and Analysis, 2024, 134: 106439. DOI: 10.1016/j.jfca.2024.106439.

[3] Li J L, Qian J P, Chen J Y, Ruiz-García L, Dong C, Chen Q, Liu Z H, Xiao P N, Zhao Z Y. Recent advances of machine learning in the geographical origin traceability of food and agro-products: A review[J]. Comprehensive Reviews in Food Science and Food Safety, 2025, 24(1). DOI: 10.1111/1541-4337.70082.

[4] Li X K, Tang L J, Li Z Y, et al. Geographical origin discrimination of Chenpi using machine learning and enhanced mid-level data fusion[J]. npj Science of Food, 2025, 9: 17. DOI: 10.1038/s41538-025-00376-0.

[5] Liu C X, Grasso S, Brunton N P. Metabolomics for origin traceabil-

ity of lamb: An ensemble learning approach based on random forest recursive feature elimination[J]. Food Chemistry: X, 2025, 29: 102856. DOI: 10.1016/j.fochx.2025.102856.

[6] Peng Y F, Zheng C, Guo S, Gao F Q, Wang X X, Du Z H, Gao F, Su F, Zhang W J, Yu X L, Liu G Y, Liu B S, Wu C J, Sun Y, Yang Z B, Hao Z L, Yu X M. Metabolomics integrated with machine learning to discriminate the geographic origin of Rougui Wuyi rock tea[J]. npj Science of Food, 2023, 7: 16. DOI: 10.1038/s41538-023-00187-1.

[7] Sim J, McGoverin C, Oey I, Frew R, Kebede B. Non-linear machine learning coupled near infrared spectroscopy enhanced model performance and insights for coffee origin traceability[J]. Journal of Near Infrared Spectroscopy, 2024, 32(4-5). DOI: 10.1177/09670335241269014.

[8] Schmauder F, Schütz D, Creydt M, Riedl J, Fischer M. Food authentication goes green: Determination of the geographical origin of grain maize (*Zea mays* L.) using direct analysis in real time mass spectrometry (DART-MS)[J]. Food Control, 2024, 163: 110489. DOI: 10.1016/j.foodcont.2024.110489.

[9] Galvan D, de Andrade J C, Effting L, Lelis C A, Melquiades F L, Bona E, Conte-Junior C A. Energy-dispersive X-ray fluorescence combined with chemometric tools applied to tomato and sweet pepper classification[J]. Food Control, 2023, 143: 109326. DOI: 10.1016/j.foodcont.2022.109326.

[10] Cui J R, Wu C, Pan S B, Li K K, Liu S J, Lv Y, Wang S L, Luo R M. Determining the geographical origins of goji berries using the Twin-Tower model for Multi-Feature[J]. Computers and Electronics in Agriculture, 2024, 227: 109571. DOI: 10.1016/j.compag.2024.109571.

[11] Zhang Y, Ma L, Yi W G, Wu L G. Research on the adulteration of *Lycium barbarum* based on hyperspectral imaging technology combined with deep learning algorithm[J]. Journal of Food Composition and Analysis, 2024, 136: 106765. DOI: 10.1016/j.jfca.2024.106765.

[12] Zhang J R, Wang C Y, Zhang Y, Lv M, Wang X F, Yu S G, Chen C, Tian W, Liu Z. Multivariate statistical analysis combined with ArcGIS visualization to construct a geographical atlas of origin characteristics of Ningxia goji berry[J]. Journal of Mountain Agriculture and Biology, 2025, 44(2): 1-10. DOI: 10.15958/j.cnki.sdnyswxb.2025.02.001.

[13] Zhang J R, Wang C Y, Li C X, Wang F, Hui F, Niu Y. Characterization of goji berry geoherbalsm based on rare earth elements and stable isotope fingerprints[J]. Journal of Food Safety & Quality, 2023, 14(13): 169-176. DOI: 10.19812/j.cnki.jfsq11-5956/ts.2023.13.018.

[14] Wolpert D H. Stacked generalization[J]. Neural Networks, 1992, 5(2): 241-259. DOI: 10.1016/S0893-6080(05)80023-1.

[15] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine Learning, 2006, 63(1): 3-42. DOI: 10.1007/s10994-006-6226-1.

[16] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32. DOI: 10.1023/A:1010933404324.

[17] Wang S H, Chen P, Liu Y C, Chen C, Tian J, Lu K X, Liu Z, Li B, Mei X X, Mei X, Chen Y L, Zhang Y, Li C H, Xu C, Gong H S. Geographical origin traceability of sweet cherry in China using stable isotope and multi-element analysis with multivariate modeling[J]. Food Chemistry: X, 2024, 23: 101477. DOI: 10.1016/j.fochx.2024.101477.

[18] Zeng G H, Hao X Y, Wang H, Li H, Gao F F. Effects of geographical origin, vintage, and soil on stable isotopes and mineral elements in Ecolly grape berries for traceability[J]. Food Chemistry, 2024, 435: 137646. DOI: 10.1016/j.foodchem.2023.137646.

[19] Yu D X, Guo S, Zhang X, Yan H, Mao S W, Wang J M, Zhou J Q, Yang J, Yuan Y W, Duan J A. Combining stable isotope, multielement and untargeted metabolomics with chemometrics to discriminate the geographical origins of ginger[J]. Food Chemistry, 2023, 426: 136577. DOI: 10.1016/j.foodchem.2023.136577.

[20] Yao M, Bai X Y, Wen F M, Liu K H, Yang J, Chen H Y, Yang X L. Accurate origin identification of Chinese white Chrysanthemi Flos by analysis of C, N, O, H stable isotope ratios and mineral elements combined with chemometrics[J]. Journal of Food Composition and Analysis, 2023, 124: 105703. DOI: 10.1016/j.jfca.2023.105703.