

# 基于优化XGBoost和多模态特征融合框架的听骨植入患者术后气导听力恢复预测方法

詹传奇 1025040834

2026 年 6 月 12 日

## 摘要

听小骨植入术是恢复传导性听力损失的关键干预手段。然而，由于患者中耳解剖结构的复杂变异与病理异质性，精准预测术后听力恢复水平依然是一项重大临床挑战。现有的预测方法通常依赖单一的临床表格数据，信息量存在局限，而纯深度学习模型在小样本医学图像上又极易发生过拟合。为此，我们提出了一种深度多模态特征融合框架（MF-XGBoost），用于准确评估听骨植入患者的术后听力。MF-XGBoost能够有效整合医学影像中的空间解剖结构特征与患者的临床基线数据。

**关键词：**听骨植入；多模态特征融合；XGBoost；预测方法

# 1 引言

听小骨植入术是治疗由慢性中耳炎、外伤或先天性畸形引起的传导性听力损失患者听力恢复最有效的手术干预手段之一。该手术的核心目标是重建中耳的声音传导机制来闭合患者的气骨导差。然而，从临床实践来看，术后听力恢复过程具有高度的复杂性和不可预见性。预后效果不仅取决于手术操作，更受到患者解剖微观变异、黏膜病理状态、咽鼓管通气功能以及假体声学特性等多种因素的耦合影响。

## 2 相关工作

为了应对这一挑战，近年来众多研究团队积极探索了预测术后听力结果的新路径。早期的尝试主要依赖于传统的统计学方法，例如基于临床表格数据构建的多元线性回归和逻辑回归模型。然而，这些方法通常基于严格的线性独立假设，难以有效捕捉医学数据中固有的复杂非线性关系，导致预测精度受限。

## 3 方法与架构

### 3.1 基于主成分分析的特征降维

尽管EfficientNetV2B0提取的1280维视觉特征包含了丰富的语义信息，但如果直接将这种高维向量与数量有限的临床表格数据进行拼接，在后续的机器学习阶段将不可避免地导致“维度灾难”。为了解决这一特征稀疏性问题，本研究引入了主成分分析（PCA）作为一种鲁棒的降维技术。

对于中心化后的深度特征矩阵  $M \in \mathbb{R}^{N \times d}$  (其中  $N$  为样本数量,  $d = 1280$ )，其协方差矩阵  $C$  的计算公式为：

$$C = \frac{1}{N-1} M^T M \quad (1)$$

通过对协方差矩阵进行特征值分解，可以得到特征值  $\lambda$  和对应的特征向量  $v$ ：

$$C v_j = \lambda_j v_j \quad (2)$$

### 3.2 多模态融合联合预测架构

在完成临床与影像数据的独立特征提取后，我们构建了多模态联合预测总体框架，其模型架构如图 1 所示。




图 1: MF-XGboost 多模态联合预测框架架构图

## 4 实验与结果

### 4.1 整体预测性能评估

模型在内部验证集上表现出优异的预测一致性。以平均绝对误差（MAE）为衡量指标，各频率点的评估结果如图 2 所示。从临床实用性角度出发，内部验证数据中的临床达标率统计结果如图 3 所示。




图 2: 内部验证集上各听力频率的平均绝对误差（MAE）




图 3: 内部验证集上的预测误差率与临床达标率分析

在外部独立验证集中，跨中心数据分布差异对单独频率产生了一定波动，其全频段 MAE 结果如图 4 所示，相应的临床达标率分析如图 5 所示。




图 4: 外部独立验证集上各听力频率的平均绝对误差 (MAE)




图 5: 外部独立验证集上的预测误差率与临床达标率分析

## 4.2 多模态消融实验

为了验证多模态融合的必要性，我们将完整框架与单一模态基线模型进行了对比。内部验证集与外部验证集的消融对比曲线分别如图 6 和图 7 所示。




图 6: 内部验证集的多模态消融实验性能对比




图 7: 外部独立验证集的多模态消融实验性能对比

### 4.3 与现有回归模型的对比

为了进一步评估MF-XGBoost框架的有效性，我们在相同的特征集上将其与多种常用回归模型进行了对比。表 1 汇总了各模型在内部和外部验证集上的平均绝对误差（MAE）以及 15 dB HL 误差范围内的预测准确率。

表 1: MF-XGBoost与多种回归模型的内外性能对比

| Model Name    | Internal MAE      | Internal Acc  | External MAE       | External Acc  |
|---------------|-------------------|---------------|--------------------|---------------|
| Random Forest | 9.25 dB HL        | 80.16%        | 14.27 dB HL        | 64.84%        |
| SVR           | 9.91 dB HL        | 76.19%        | 16.82 dB HL        | 59.34%        |
| MLP           | 9.85 dB HL        | 78.97%        | 15.12 dB HL        | 54.95%        |
| MF-XGBoost    | <b>8.94 dB HL</b> | <b>80.97%</b> | <b>13.41 dB HL</b> | <b>65.90%</b> |

### 4.4 多模态特征可解释性分析

为了验证模型学习到的视觉流形具有生物学意义，我们采用 Grad-CAM 技术对决策关注区域进行了可视化。耳内镜影像的逆向激活热力图如图 8 所示，颞骨 CT 连续断层切片的激活热力图如图 9 所示。




图 8: 基于Grad-CAM的耳内镜影像特征逆向激活热力图




图 9: 基于Grad-CAM的颞骨CT连续断层切片激活热力图

## 5 结论

本文提出了一种名为MF-XGBoost的深度多模态特征融合框架，旨在精准预测听骨链重建患者的术后多频率听力恢复水平。实验评估表明，该多模态融合策略在预测精度和抗噪鲁棒性上均显著优于单模态基线模型。

## 参考文献

- [1] Baltrusaitis, T., Ahuja, C., Morency, L.P., 2019. Multimodal Machine Learning: A Survey and Taxonomy. *IEEE Trans. Pattern Anal. Mach. Intell.* 41, 423–443.
- [2] Bhutta, M.F., Leach, A.J., Brennan-Jones, C.G., 2024. Chronic suppurative otitis media. *Lancet* 403, 2339–2348.