

单位代码： 10293 密 级：

南京邮电大学
专 业 学 位 硕 士 论 文



论文题目： 人工智能生成文本检测技术的研究与应用

学 号	<u>1025040901</u>
姓 名	<u>陈佳乐</u>
导 师	<u>王磊</u>
专业 学位 类别	<u>电子信息</u>
类 型	<u>深度学习</u>
专业 （领域）	<u>网安</u>
论文提交日期	<u>2026 年 6 月</u>

摘要

随着深度学习技术的飞速发展，人工智能生成内容（AIGC）尤其是文本生成技术正经历迅猛迭代。大型语言模型如 ChatGPT、文心一言、通义千问等在极大提升内容产出效率的同时，也引发了虚假新闻传播、学术舞弊等信息真实性方面的严峻挑战。现有的 AIGC 文本检测方法在多尺度特征捕捉、领域适应性以及复杂语义分析等方面存在局限，迫切需要开发更高效、更鲁棒的检测模型。

本研究聚焦于人工智能生成文本检测技术，提出了一种基于 LSTM-Transformer 混合数学特征的生成文本检测模型。该模型首先借助双向长短期记忆网络（BiLSTM）模块提取文本在词级和句级维度的时序依赖特征；在此基础上，利用 Transformer 编码器的自注意力机制挖掘文本在篇章层面的深层语义联系。为进一步提高检测水平，模型还引入了多维度数学特征，包括平均句长、情感得分、词汇丰富度、标点符号占比、句子复杂度、重复 n-gram 比例以及 Zipf 词频分布参数等。

在自建中文新闻数据集上的实验结果表明，所提出的模型在准确率、精确率、召回率和 F1 值等关键指标上均达到 96% 以上，漏报率低于 5%，显著优于 LSTM、Transformer 及 LSTM-Transformer-CNN 等对比模型。消融实验进一步验证了数学特征模块和 LSTM-Transformer 混合架构的有效性。

关键词：生成文本检测, 长短期记忆网络, Transformer, 数学特征, 深度学习, 中文新闻

Abstract

With the rapid advancement of deep learning, AI-generated content (AIGC), particularly text generation, is undergoing swift iterations. While large language models such as ChatGPT, ERNIE Bot, and Tongyi Qianwen significantly boost content production efficiency, they also raise serious challenges regarding information authenticity, including fake news dissemination and academic misconduct.

This study focuses on AI-generated text detection and proposes a detection model based on a hybrid LSTM-Transformer architecture integrated with mathematical features. The model first employs a BiLSTM module to extract sequential dependency features at word and sentence levels, then utilizes the Transformer encoder's self-attention mechanism to mine deep semantic relationships at the discourse level.

Experimental results on a self-constructed Chinese news dataset show that the proposed model achieves over 96% in accuracy, precision, recall, and F1-score with a false negative rate below 5%, significantly outperforming baseline models. Ablation studies further validate the effectiveness of the mathematical feature module and the hybrid LSTM-Transformer architecture.

Key Words: Generated Text Detection, LSTM, Transformer, Mathematical Features, Deep Learning, Chinese News

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
第一章 绪论	1
1.1 课题背景与研究意义	1
1.2 本文的研究内容	1
1.3 论文组织结构	1
第二章 相关理论与技术基础	2
2.1 自然语言处理基础	2
2.2 文本生成与检测技术	2
2.3 本章小结	3
第三章 基于 LSTM-Transformer 混合数学特征的生成文本检测模型	4
3.1 问题分析与模型框架	4
3.1.1 Bert-base-chinese 词嵌入	4
3.1.2 数学特征模块	5
3.1.3 LSTM-Transformer 混合网络	5
3.2 实验验证与性能分析	5
3.2.1 数据集与评价指标	5
3.2.2 实验结果	6
3.2.3 消融实验与模型对比	6
3.3 本章小结	6
第四章 中文新闻生成文本检测应用验证	8
4.1 应用场景描述	8
4.2 模型应用效果验证	8
4.3 应用局限性讨论	8
4.4 本章小结	9
第五章 总结与展望	10
5.1 本文工作总结	10
5.2 未来研究方向	10
参考文献	11

插图索引

图 2.1	LSTM 单元结构示意图	2
图 2.2	Transformer 架构示意图	3
图 3.1	基于 LSTM-Transformer 混合数学特征的生成文本检测模型框架	4
图 4.1	模型在中文新闻检测集的混淆矩阵与性能指标	8

表格索引

表 3.1	数据集划分	6
表 3.2	模型总体性能指标	6
表 3.3	消融实验性能对比	6
表 3.4	与现有模型的性能对比	7
表 4.1	不同新闻类别上的检测指标对比	9

第一章 绪论

1.1 课题背景与研究意义

随着深度学习的发展,人工智能生成内容(AIGC)迎来了爆发性增长。文本生成技术从基于规则的方式转变为基于大规模语言模型(LLM)的技术思路^[1],包括 ChatGPT、文心一言、通义千问等在内的各种 LLM 相继出现。这种高效信息处理能力使得 LLM 迅速融入社会生活各个方面,AIGC 技术的范式演进重塑了数字内容生产格局^[2]。

然而,随着 AIGC 软件的普及,引发了严重的信息真实性问题^[3]。在教育领域,利用 AIGC 的行为很难定义为学术剽窃。在社会层面,AI 生成的虚假内容具有极强的迷惑性,普通网民仅凭肉眼难以辨别真伪^[2]。深度学习方法展现出巨大潜力,CNN、RNN 及其变体 LSTM 等具有自动学习特征的能力^[4,5]。因此,研发一种基于深度学习的高效、精准的 AIGC 文本检测模型显得尤为关键。

1.2 本文的研究内容

本文的主要研究内容如下:

- (1) 针对现有检测方法在多尺度检测能力上的不足,本文提出了 LSTM-Transformer 混合网络模型,通过深度整合 LSTM 的序列建模能力和 Transformer 的自注意力机制,实现对文本特征的层次化捕获。
- (2) 针对通用检测模型对专业领域文本检测能力不足的问题,本文引入平均句长、情感得分、词汇丰富度、标点符号占比、句子复杂度、重复 n-gram 比例和 Zipf 词频分布参数七维度数学特征。
- (3) 针对中文网络环境中日益严重的 AI 生成虚假新闻问题,验证所提出模型在中文虚假新闻检测任务中的适用性。

1.3 论文组织结构

本论文共分四章:第一章为绪论;第二章介绍相关理论与技术基础;第三章提出基于 LSTM-Transformer 混合数学特征的生成文本检测模型;第四章将模型应用于中文新闻生成文本检测场景。

第二章 相关理论与技术基础

2.1 自然语言处理基础

自然语言处理 (NLP) 是人工智能领域的关键分支，主要研究计算机与人类自然语言交互的理论与方法。NLP 的研究范围包含语法审视、语义体悟和语用剖析三个分析层级^[6]。近年来，以 Word2Vec^[7]、GloVe^[8] 为代表的词向量技术将离散语言符号映射到连续向量空间，而 Transformer 架构^[9] 的提出使 NLP 系统达到了前所未有的性能水平。

中文分词和句子分割是中文 NLP 的基础核心环节。分词方法主要经历了从基于词典到统计学习再到深度学习的演变，BiLSTM 结合条件随机场 (CRF) 的混合架构成为主流方案。

2.2 文本生成与检测技术

统计语言模型根据概率论和统计学原理建模语言生成过程，n-gram 模型^[10] 是最具代表性的方法。神经网络生成方法方面，Hochreiter 等人提出的 LSTM^[11] 通过引入门控机制有效缓解了梯度消失问题，其结构如图2.1所示。




图 2.1 LSTM 单元结构示意图

Vaswani 等人提出的 Transformer 架构^[9] 仅依靠自注意力机制便实现了更灵活的上下文建

模，其结构如图2.2所示。




图 2.2 Transformer 架构示意图

文本生成检测技术主要分为三类：（1）基于统计特征的检测方法，依托机器生成文本与人类书写文本在统计特性上存在系统性差异的基本假设^[12,13]；（2）基于神经网络的检测方法，早期基于 CNN^[4] 的模型仅适用于小规模短文本，LSTM 通过门控机制解决了长序列训练中的梯度问题；（3）基于语义一致性的检测方法，通过分析文本深层的语义逻辑特征来判别机器生成内容^[14,15]。

2.3 本章小结

本章介绍了文本生成与检测领域的相关理论与技术基础，为后续模型设计提供了理论支撑。

第三章 基于 LSTM-Transformer 混合数学特征的生成文本检测模型

3.1 问题分析与模型框架

随着大规模语言模型的普遍应用，机器生成的文本在语法流畅度上已接近人类水准，但在语义一致性、逻辑连贯性方面仍存在系统性缺陷^[12]。现有检测方法各有不足：基于统计特征的方法面对对抗性文本时力不从心；基于神经网络的方法在专业领域内适应性不足。为此，本章提出一种基于 LSTM-Transformer 混合架构并融合数学特征的生成文本检测模型。

本文提出的模型整体框架如图3.1所示，包含四个核心部分：Bert 语义编码模块、双向 LSTM 时序特征提取模块、Transformer 编码器模块和数学特征模块。




图 3.1 基于 LSTM-Transformer 混合数学特征的生成文本检测模型框架

3.1.1 Bert-base-chinese 词嵌入

Bert-base-chinese 是专门针对中文文本处理的预训练 BERT 模型，其内部结构包含嵌入层、多层 Transformer 编码器和输出层三部分。经过多层 Transformer 编码器处理后，为每个词生成 768 维的上下文表示向量。

3.1.2 数学特征模块

数学特征模块是本文模型的核心创新之一，从统计语言学角度捕捉 AI 生成文本与人类文本的系统性差异。本模型选取七个维度的数学特征：

- (1) **平均句长**：人类写作通常长短句交错，而 AI 生成文本往往表现出异常均匀的倾向。其计算公式为：

$$\bar{L} = \frac{1}{N} \sum_{i=1}^N L_i \quad (3.1)$$

- (2) **情感得分**：采用 SnowNLP 算法计算文本情感得分 $S \in [0, 1]$ ，人类文本情感呈渐进变化，AI 文本要么过于平淡要么出现异常突变。

- (3) **词汇丰富度**： $V = |\text{unique}(W)|/|W|$ ，人类作者会自然选用同义词，而 AI 模型倾向于重复使用高频词汇。

- (4) **标点符号占比**：统计 17 种中文标点在文本中的比例。

- (5) **句子复杂度**： $C = \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{\{L_i > \tau\}}$ ，其中 $\tau = 10$ 为句子长度阈值。

3.1.3 LSTM-Transformer 混合网络

LSTM 通过门控机制（遗忘门 f_t 、输入门 i_t 、输出门 o_t ）有效控制信息流动。BiLSTM 从正向和反向两个方向处理序列，能同时捕捉前后文信息。Transformer 编码器通过多头自注意力机制并行处理序列数据：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.2)$$

模型首先将 BERT 输出的词嵌入输入 BiLSTM 获得时序特征，再通过全连接层转换维度后送入 Transformer 编码器，最终得到全局高维特征向量。

3.2 实验验证与性能分析

3.2.1 数据集与评价指标

人类撰写文本来自清华大学 cnews 数据集，AI 生成文本通过调用通义千问-Max 的 API 生成。数据集划分如表3.1所示。

本文采用准确率 (ACC)、精确率 (PR)、召回率 (Recall)、F1 值及漏报率 (FNR) 作为评价指标：

表 3.1 数据集划分

数据集	人类撰写	AI 生成
训练集	4000	3960
验证集	1000	990
测试集	1000	998

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}, \quad F1 = 2 \times \frac{PR \times Recall}{PR + Recall} \quad (3.3)$$

3.2.2 实验结果

本文模型在中文新闻数据集上的总体性能如表3.2所示。

表 3.2 模型总体性能指标

ACC	PR	Recall	F1	FNR
0.964	0.969	0.960	0.964	0.040

3.2.3 消融实验与模型对比

为验证各模块的有效性，对各模块进行了消融实验，结果如表3.3所示。消融实验结果表明：使用数学特征模块的模型在所有指标上均优于未使用的模型。

表 3.3 消融实验性能对比

模型结构	ACC	PR	Recall	F1
LSTM-Transformer-Math (本文)	0.964	0.969	0.960	0.964
LSTM-Transformer	0.910	0.879	0.950	0.913
LSTM-Math	0.926	0.882	0.955	0.929

本文模型与其他检测模型的对比实验如表3.4所示。本文模型 F1 值较对比模型提升 3.7%–6.9%，充分验证了模型的显著优越性。

3.3 本章小结

本章详细描述了基于 LSTM-Transformer 混合数学特征生成文本检测模型的完整设计。模型通过 Bert-base-chinese 进行词嵌入，经 BiLSTM 和 Transformer 编码器分层次提取特征，与数学特征融合后输入分类器。通过对比实验和消融实验，验证了模型的有效性和优越性。

表 3.4 与现有模型的性能对比

模型	ACC	PR	Recall	F1
本文模型	0.964	0.969	0.960	0.964
LSTM ^[11]	0.899	0.893	0.906	0.899
Transformer ^[9]	0.896	0.897	0.894	0.895
LSTM-Transformer-CNN ^[16]	0.928	0.926	0.929	0.927

第四章 中文新闻生成文本检测应用验证

4.1 应用场景描述

在数字化时代,中文新闻作为传达信息的方式应当真实可靠,然而大量虚假新闻的传播速度快、影响面大,对社会信任造成极大冲击^[2]。因此,将基于 LSTM-Transformer 混合数学特征生成文本检测模型应用于中文新闻检测领域具有重要的现实意义。

从结构特征看,新闻文本具有规律性的结构特征,本文建立的数学指标体系可通过定量分析法对文本结构数据进行模式识别。从语义理解看,Transformer 的多头注意力机制可以将不同重要程度的词语放入不同语义空间进行区分理解,LSTM 与 Transformer 配合可弥补传统数学特征分析语义提取能力不足的问题^[16]。

4.2 模型应用效果验证

在 2000 条中文新闻(其中 1000 条为人工撰写,1000 条为 AI 撰写)的检测集上,模型展现出优异的检测性能。检验结果的混淆矩阵和性能指标如图 4.1 所示。

文本: 打强石佛就敢带伤上阵 休息五场?他是忽悠对手新浪体育讯北京时间3月31日消息,据《Spurs Na... | 真实: 人工 | 预测: 人工 | AI概率: 0.2%

文本: 曝湖人寻禅师接班竟挖绿军主帅 卷土重来华山路一条新浪体育讯北京时间5月11日,0-4惨遭小牛横扫,不... | 真实: 人工 | 预测: 人工 | AI概率: 0.1%

文本: 火箭大胜森林狼结束五连败 斯科拉成取胜关键 休斯敦时间11月7日晚,火箭队在主场以120:94击... | 真实: AI | 预测: AI | AI概率: 100.0%

文本: 公牛迎后乔丹时代最强季 一牛人却恐成季后赛软肋新浪体育讯北京时间4月4日,据雅虎体育报道,本赛季的芝... | 真实: 人工 | 预测: 人工 | AI概率: 0.2%

文本: 热火大胜太阳波什砍下35分展现统治力 新浪体育讯 在热火以大比分战胜太阳的比赛中,克里斯-波什全场贡... | 真实: AI | 预测: AI | AI概率: 100.0%

文本: 火箭五连败中传来利好消息 休斯顿火箭虽然在新赛季开局遭遇了五连败,但在最新的伤病报告中出现了一丝曙光... | 真实: AI | 预测: AI | AI概率: 100.0%

文本: 黑人范范台北婚礼阿联当伴郎 他是今夏最忙碌的人在NBA常规赛结束后回国的易建联,在与篮管中心和国家队... | 真实: 人工 | 预测: 人工 | AI概率: 0.3%

文本: 灰熊对阵奇才首发阵容: 沃尔与易建联缺席 新浪体育讯 北京时间11月20日,华盛顿奇才将在主场迎战孟菲... | 真实: AI | 预测: AI | AI概率: 99.7%

文本: 阿联同期生年薪达900万 灰熊后卫用表现证明低开亦可高走 ... | 真实: AI | 预测: AI | AI概率: 100.0%

文本: 热火三巨头澄清未故意挑衅绿军 皇帝称球队无意挑起冲突 迈阿密时间5月2日,据新浪体育报道,在热火... | 真实: AI | 预测: AI | AI概率: 99.7%

图 4.1 模型在中文新闻检测集的混淆矩阵与性能指标

模型在检测集上的 ACC 达 96.45%, PR 达 96.87%, Recall 为 96.00%, F1 值达 96.43%, FNR 仅为 4.00%。在 NVIDIA GeForce RTX 4060 环境下,单条新闻平均检测耗时约 0.107 秒,满足实时性需求。

为评估泛化能力,按内容主题划分多个子类别的检测结果如表 4.1 所示。

4.3 应用局限性讨论

尽管模型表现出色,仍存在若干局限性。首先,恶意用户可通过调整句长、伪造情感分层等方式构造对抗性文本。其次,训练数据主要依赖通义千问-Max 生成,制约了跨语言模型的泛化能力。此外,模型目前局限于纯文本检测,面对多模态虚假内容时存在本质性缺陷。

表 4.1 不同新闻类别上的检测指标对比

类别	ACC	PR	Recall	F1	FNR
总类别	0.964	0.969	0.960	0.964	0.040
体育	0.978	0.980	0.975	0.977	0.025
科技	0.968	0.970	0.965	0.967	0.035
教育	0.965	0.963	0.968	0.966	0.032
时政	0.962	0.965	0.958	0.960	0.042
财经	0.949	0.952	0.946	0.950	0.054
游戏	0.940	0.943	0.937	0.939	0.063

4.4 本章小结

本章围绕模型在中文新闻生成文本检测场景进行了系统性验证。实验结果表明模型整体性能优异，ACC 达 96.45%，单条新闻平均检测时间约 0.107 秒，验证了模型在实际应用中的有效性。

第五章 总结与展望

5.1 本文工作总结

本研究聚焦于人工智能生成文本检测技术，提出了基于 LSTM-Transformer 混合数学特征的生成文本检测模型。模型创造性地将 LSTM 的序列建模能力与 Transformer 的自注意力机制相结合，并引入七维度数学特征模块，系统对比实验验证了各模块的有效性。本文模型在准确率、精确率、召回率和 F1 值上均达到 96% 以上，F1 值较现有模型提升 3.7%–6.9%。

5.2 未来研究方向

未来研究可从以下方面改进：

- (1) **多模态检测**：随着 AIGC 技术发展，虚假内容已趋向多模态方向，如何通过多模态数据的协同分析判断内容真实性是重要研究方向。
- (2) **跨领域泛化**：可针对不同领域的文本特征构建新的数学特征体系，研究跨语言模型的泛化检测能力。
- (3) **对抗鲁棒性**：可研究对抗训练方法或开发更鲁棒的高级特征表示，提高检测系统在对抗环境下的可靠性。

参考文献

- [1] 中国软件评测中心. 人工智能大语言模型技术发展研究报告 (2024 年)[R]. 北京: 中国软件评测中心, 2024.
- [2] 李明德, 李聿哲. 赋能和消解: 生成式人工智能与新闻真实的碰撞[J]. 西安交通大学学报 (社会科学版), 2025, 45(02): 109–118.
- [3] 张韬略, 陈沪楠. 何以透明, 以何透明: 高等教育的 AIGC 剽窃与技术之治[J]. 中国远程教育, 2025, 45(01): 113–130.
- [4] Kim Y. Convolutional Neural Networks for Sentence Classification[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: [s.n.], 2014: 1746–1751.
- [5] Lai S, Xu L, Liu K, et al. Recurrent Convolutional Neural Networks for Text Classification[C]. Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence. Austin, Texas: [s.n.], 2015: 2267–2273.
- [6] Howard J, Ruder S. Universal Language Model Fine-tuning for Text Classification[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Melbourne, Australia: [s.n.], 2018: 328–339.
- [7] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[C]. International Conference on Learning Representations (ICLR). Scottsdale: [s.n.], 2013.
- [8] Pennington J, Socher R, Manning C. GloVe: Global Vectors for Word Representation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). Doha, Qatar: [s.n.], 2014: 1532–1543.
- [9] Vaswani A, Shazeer N, Parmar N, et al. Attention is All You Need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [10] Brown P F, Della Pietra V J, deSouza P V, et al. Class-Based n-gram Models of Natural Language[J]. Computational Linguistics, 1992, 18(4): 467–480.
- [11] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735–1780.
- [12] Guo B, Zhang X, Wang Z, et al. How Close is ChatGPT to Human Experts? Comparison Corpus, Evaluation, and Detection[M]. [S.l.: s.n.], 2023.
- [13] Piantadosi S T. Zipf’s Word Frequency Law in Natural Language: A Critical Review and Future Directions [J]. Psychonomic Bulletin & Review, 2014, 21(5): 1112–1130.
- [14] Li J, Galley M, Brockett C, et al. A Diversity-Promoting Objective Function for Neural Conversation Models [C]. Proceedings of NAACL-HLT. San Diego, California: [s.n.], 2016: 110–119.
- [15] Wiseman S, Shieber S, Rush A. Challenges in Data-to-Document Generation[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark: [s.n.], 2017: 2253–2263.

- [16] Mo Y, Qin H, Dong Y, et al. Large Language Model (LLM) AI Text Generation Detection Based on Transformer Deep Learning Algorithm[M]. [S.l.: s.n.], 2024.