

单位代码: 10293 密 级:

南京邮电大学



论文题目： PCA 算法实现人脸重建并与 LDA 对比研究

学 号 1025040910

姓 名 简宇星

导 师 _____

专业学位类别

类型 _____

专业（领域） 网络空间安全

论文提交日期 _____

摘要

针对高维数据处理效率低、易过拟合的问题，本文聚焦线性降维算法主成分分析（PCA）与线性判别分析（LDA）的性能验证与对比研究。首先以 Olivetti Faces 人脸数据集为对象，基于 PCA 算法完成人脸降维与重建，通过特征脸可视化、不同维度重构效果对比及解释方差分析，验证了 PCA 在人脸重建中的有效性。实验结果表明，PCA 生成的“特征人脸”具有较强可解释性，能够较好地表达原始人脸图像中的主要方差信息，并可依据累计解释方差准则为主成分数量选择提供参考。随后，本文以信贷预测二分类数据集为场景，对比 PCA 与 LDA 在分类任务中的表现。结果表明，LDA 因利用类别标签信息并优化类间与类内离散度，通常比 PCA 更适用于分类任务；但 LDA 的降维能力受类别数量限制，在少分类场景下可能存在性能局限。因此，在实际应用中需要结合任务目标、数据特征与模型需求选择适配的降维方法，以提升数据特征挖掘效率与模型预测精度。

关键词：降维；主成分分析；人脸重建；线性判别分析；分类

Abstract

To address the low computational efficiency and overfitting risks caused by high-dimensional data, this thesis studies and compares two linear dimensionality reduction methods: principal component analysis (PCA) and linear discriminant analysis (LDA). First, the Olivetti Faces dataset is used to conduct face dimensionality reduction and reconstruction with PCA. Through eigenface visualization, reconstruction comparisons under different dimensions, and explained-variance analysis, the effectiveness of PCA in face reconstruction is verified. The results show that PCA can generate interpretable eigenfaces, preserve the dominant variance information of original face images, and provide a practical criterion for selecting the number of principal components based on cumulative explained variance. Second, a binary credit prediction dataset is used to compare PCA and LDA in a classification task. The results indicate that LDA is generally more directly effective for classification because it uses label information and optimizes between-class and within-class scatter. However, the dimensionality reduction capability of LDA is constrained by the number of classes, which may limit its performance in few-class scenarios. Therefore, suitable dimensionality reduction methods should be selected according to task requirements, data characteristics, and model objectives so as to improve feature mining efficiency and prediction accuracy.

Key Words: Dimensionality Reduction; Principal Component Analysis; Face Reconstruction; Linear Discriminant Analysis; Classification

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 线性降维方法概述	1
1.3 相关工作	1
1.4 本文研究内容	2
第二章 PCA 人脸重建实验	3
2.1 实验工具与数据集	3
2.2 PCA 降维过程	3
2.3 人脸重构效果	4
2.4 解释方差分析	5
2.5 本章小结	5
第三章 PCA 与 LDA 分类对比实验	6
3.1 实验数据集	6
3.2 数据预处理	6
3.3 PCA 降维分类实验	6
3.4 LDA 降维分类实验	7
3.5 结果对比与分析	7
3.6 本章小结	8
第四章 结论与展望	9
4.1 研究结论	9
4.2 未来工作展望	9
参考文献	10

插图索引

图 2.1	数据集人脸可视化	3
图 2.2	20 维特征人脸可视化	4
图 2.3	样本的重构过程	4
图 2.4	不同维度人脸可视化	4
图 2.5	不同维度下的解释方差	5
图 3.1	PCA 降维至 1 维的预测结果	6
图 3.2	LDA 降维至 1 维的预测结果	7
图 3.3	PCA 降维至 10 维的预测结果	7

表格索引

专用术语注释表

缩略词说明：

缩写	英文全称
PCA	Principal
LDA	Linear Di
KPCA	Kernel Pr
ICA	Independ
RF	Random
CV	Compute

第一章 绪论

1.1 研究背景与意义

人脸图像在人脸识别、虚拟形象生成以及人脸修复等领域具有重要价值，是现代计算机视觉研究的核心内容之一。然而，人脸图像通常具有较高维度。例如，一张 64×64 像素的灰度图像就包含 4096 个维度；若为彩色图像，其维度还会进一步增加。这类高维数据在存储、计算和模型泛化能力方面都面临较大挑战，直接处理不仅效率较低，也容易引发过拟合问题。

为了提高处理效率并增强模型的泛化能力，降维成为解决高维人脸数据问题的关键技术。通过降维，可以在保留主要信息的同时压缩特征空间，从而减少计算负担，并为后续的人脸重建、识别与分类等任务提供更加紧凑的特征表示。

在机器学习模型构建过程中，当输入数据维度过高且特征结构复杂时，模型复杂度会随之增加。尤其在样本数量不足的情况下，高维特征容易导致训练模型泛化能力下降。因此，有必要通过降维去除冗余特征，降低数据维度，便于信息观察、特征挖掘与模型训练。

1.2 线性降维方法概述

一般而言，降维方法大致可分为线性降维和非线性降维两类。线性降维方法具有计算过程清晰、结果可解释性较强等特点，常用于数据预处理、可视化、压缩和分类任务。其中，主成分分析 (Principal Component Analysis, PCA) 属于无监督降维算法，核心目标是在低维空间中尽可能保留原始数据的总体方差信息；线性判别分析 (Linear Discriminant Analysis, LDA) 属于有监督降维算法，其核心目标是最大化类别之间的差异并最小化同一类别内部的差异。

本文首先基于 PCA 降维算法，在 Olivetti Faces 数据集上进行人脸重建实验，通过构造特征脸空间、低维投影与图像重构等步骤还原人脸图像，验证 PCA 在人脸降维和重建任务中的有效性。在分类任务中，LDA 通常比 PCA 更直接有效^[1,2]。但在少分类场景中，LDA 的可降维维数会受到类别数量限制，因此其实际效果仍需结合具体任务进行验证。基于此，本文进一步选取一个二分类数据集，对 PCA 与 LDA 在分类任务中的表现进行评估与比较。

1.3 相关工作

PCA 凭借无监督降维和最大化数据总方差的特性，成为最早应用于人脸重建与识别的算法之一。1991 年 Turk 和 Pentland 提出“特征脸 (Eigenface)”方法，首次将 PCA 应用于人脸重建与识别任务^[3]。该方法通过学习人脸图像集合中的主要方差方向，构建低维特征脸空间，从而实现人脸图像的表达、压缩和重构。

为了优化人脸重建与识别任务中的精度和鲁棒性, Delac 等人对 PCA、ICA、LDA 在人脸特征提取中的性能进行了比较, 指出 PCA 在图像重建任务中因保留全局方差信息, 对低分辨率和噪声干扰的人脸图像具有较好的容错性^[4]。随着 Python 语言及其机器学习生态的发展, 降维算法与 Python 工具链结合得更加紧密, 基于经典 PCA 的核主成分分析 (KPCA) 等扩展算法也被用于处理更复杂的非线性特征提取问题^[5]。

LDA 是一种经典的有监督降维方法, 常被用于分类任务和分类前的特征压缩。与 LDA 相比, PCA 更关注保留数据整体方差, 因此更适合人脸重建、压缩和去噪等任务; 而 LDA 能利用类别标签信息, 更适合以类别区分为目标的任务。Robinson 和 Clarke 在姿态变化人脸数据集上的实验表明, PCA 与 LDA 的混合算法识别准确率优于单一算法, 但当训练样本量不足时, LDA 容易出现小样本问题, 而 PCA 的稳定性相对更强^[6]。

1.4 本文研究内容

本文围绕 PCA 与 LDA 两类典型线性降维算法展开实验研究, 主要内容包括以下两个方面:

- 基于 Olivetti Faces 人脸数据集, 利用 PCA 算法进行人脸降维与重建, 通过特征脸、重构过程和解释方差分析验证 PCA 的有效性。
- 基于信贷预测二分类数据集, 分别采用 PCA 和 LDA 作为前置降维方法, 并结合随机森林分类器比较两种降维策略在分类任务中的表现。

通过上述研究, 本文希望说明不同降维方法在任务目标、数据标签利用方式和可降维能力方面的差异, 为高维数据处理中的方法选择提供实验依据。

第二章 PCA 人脸重建实验

2.1 实验工具与数据集

Python 语言具备语法简洁、易上手、功能强大和开发效率高等特点，同时拥有丰富的开源机器学习库资源，现已成为机器学习实验与数据分析中应用广泛的编程语言之一。本文基于 NumPy、Scikit-learn (sklearn) 和 Matplotlib 等 Python 库，引入主成分分析 (PCA) 降维算法，以 Olivetti Faces 人脸数据集为研究对象，开展人脸重建实验与分析工作。

本文选用 Olivetti Faces 人脸数据集开展相关研究。该数据集由一系列 64×64 像素的灰度人脸图像构成，包含多个独立个体的人脸样本。针对每个个体，数据集采集了若干幅具有差异的人脸图像，样本之间的区别主要体现在姿态调整、表情变化及光照条件差异上。本文选择部分人脸样本进行可视化展示，如图2.1所示。



图 2.1 数据集人脸可视化

2.2 PCA 降维过程

PCA 的基本思想是通过正交变换将原始高维数据投影到一组新的低维坐标轴上，使投影后的数据尽可能保留原始数据中的主要方差信息^[7]。在具体实现中，首先对原始数据集执行中心化预处理；随后基于中心化后的数据计算协方差矩阵；接着对协方差矩阵进行特征分解，得到特征值和特征向量；最后根据特征值大小对特征向量进行降序排列，并将中心化后的原始数据投影至排序后的特征向量所张成的低维子空间，从而实现数据降维。

sklearn 库中已经提供了 PCA 相关实现，因此实验中可以直接调用 PCA 模型进行降维、重构和解释方差分析。本文首先将人脸数据降至 20 维，并对得到的特征脸进行可视化，如图2.2所示。这些特征脸分别对应数据中不同模式的方差信息，呈现出明显的视觉差异。第一张特征脸主要反映人脸整体亮度均值变化，呈现从深色到浅色的全局明暗渐变；第二张特征脸则与左右对称性或整体轮廓宽窄相关，可体现脸型从窄到宽的形变模式。其余特征脸也分别对应不同的面部细节变化，共同构成原始人脸数据的低维表征基础。



图 2.2 20 维特征人脸可视化

2.3 人脸重构效果

本文随机选取一张人脸图像，加载 PCA 模型进行降维，并在 Python 中调用 Matplotlib 库可视化降维后的重构结果，以观察不同主成分对人脸图像恢复过程的影响，如图2.3所示。从左到右、从上到下的重构过程直观体现了“从共性到个性”的特征分层逻辑：前序主成分对应人脸核心结构变化，例如整体轮廓和五官布局差异；中后序主成分则更多对应个性化精细特征，例如表情、配饰和局部纹理。




图 2.3 样本的重构过程

为了进一步比较不同维度对重构质量的影响，本文随机选择一张人脸图像，分别将其降至 20 维、50 维和 200 维后进行重构，并将重构图像与原始图像进行可视化比较，如图2.4所示。原始图像细节最丰富；200 维重构图像与原始图像差异较小，仅有少量皮肤斑点等细节损失，说明其已覆盖人脸图像中的绝大多数有效信息；50 维重构图像仍可识别脸型和五官布局，但胡须纹理等个性化细节开始模糊；20 维重构图像则主要保留人脸基础轮廓和五官布局，眼部神态等细节信息损失较为明显。




图 2.4 不同维度人脸可视化

2.4 解释方差分析

解释方差是 PCA 的核心评价指标，用于表征各主成分对原始数据方差的累计解释比例，直接反映主成分保留原始数据信息的能力。PCA 的核心思想是通过最大化投影方差提取数据中的关键信息，因此累计解释方差越高，代表所选主成分对原始数据的表征能力越强。

本文以累计解释方差为评价指标，对不同主成分数量下的解释方差进行可视化分析，结果如图2.5所示。从结果可以观察到，累计解释方差随主成分数量增加呈现先快速上升、后逐渐趋于平缓的典型增长特征。在主成分数量较少的阶段，解释方差增长较快，说明前若干主成分已经捕获数据中的大部分信息；随着主成分数量继续增加，解释方差增长速率逐渐放缓，新增主成分对信息保留的贡献持续降低。

从关键节点看，当累计解释方差达到 85% 时，仅需约 40 个主成分；若要达到 95% 的解释方差，则需要约 123 个主成分。这一结果表明，PCA 仅使用少量主成分即可保留原始数据中的大部分信息，验证了其在人脸数据降维与信息保留方面的有效性。




图 2.5 不同维度下的解释方差

2.5 本章小结

本章以 Olivetti Faces 数据集为对象，利用 PCA 算法完成人脸图像的降维、特征脸可视化和图像重构实验。实验结果表明，PCA 能够通过较少主成分保留人脸图像的主要结构信息，并在解释方差指标的辅助下为主成分数量选择提供较清晰的依据。

第三章 PCA 与 LDA 分类对比实验

3.1 实验数据集

在完成人脸重建实验后，本文进一步在分类任务中比较 PCA 与 LDA 两种降维算法的表现。实验基于 Python 语言和 sklearn 库完成，选取一个信贷预测二分类数据集作为研究对象。

该信贷预测数据集共有 7500 个样本，每个样本包含 31 个特征，即原始特征空间为 31 维。数据集标签为二分类变量，分别对应 Credit Default 的 0 和 1，用于表示样本是否发生违约。

3.2 数据预处理


在模型训练前，首先读取原始数据并筛选所有字符串类型特征。对于有序类别特征 Home Ownership 和 Years in current job，采用标签编码方式进行数值化处理；对于无序类别特征 Purpose，采用独热编码方式进行转换；对于二分类类别特征 Term，采用 0-1 映射方式处理。

随后，筛选所有数值型特征，并使用众数补全缺失值。考虑到 Id 列仅为样本编号，不具备预测价值，且可能引入额外噪声，因此在数据清洗阶段删除该特征。最后，将数据集按照 8:2 的比例划分为训练集和测试集，为后续降维与分类评估提供统一实验基础。

3.3 PCA 降维分类实验

在 PCA 分类实验中，PCA 被用作前置降维预处理步骤，随后选取随机森林作为分类器。由于 PCA 是无监督降维算法，在降维过程中不使用数据标签信息，而是根据数据点本身的分布、方差和相关结构寻找低维表示，因此模型训练阶段只需要特征矩阵即可完成降维。

为与 LDA 在二分类任务中的降维结果保持可比性，本文首先将 PCA 降至 1 维后训练随机森林分类器，并在测试集上进行预测，结果如图 3.1 所示。




	precision	recall	f1-score	support
0	0.72	0.74	0.73	1059
1	0.33	0.31	0.32	441

图 3.1 PCA 降维至 1 维的预测结果

3.4 LDA 降维分类实验

在 LDA 分类实验中，LDA 同样作为前置降维预处理步骤，并继续选取随机森林作为分类器。与 PCA 不同，LDA 是有监督降维算法，需要同时使用特征矩阵和对应标签向量。其目标是最大化不同类别之间的可分性，同时最小化同一类别内部的离散度，从而寻找对目标变量最有区分度的特征组合。

对于 LDA 方法，可降维维数通常受到类别数量限制。在二分类任务中，LDA 最多只能将数据降至 1 维。因此，本文将 LDA 主成分数量设为 1，并在降维后训练随机森林分类器，测试结果如图3.2所示。




LDA + Random Forest classification report on the test set:				
	precision	recall	f1-score	support
0	0.78	0.78	0.78	1059
1	0.47	0.47	0.47	441

图 3.2 LDA 降维至 1 维的预测结果

3.5 结果对比与分析

由于 LDA 在二分类任务中只能降至 1 维，因此本文首先将 PCA 也降至 1 维进行对比。通过比较图3.1和图3.2的预测结果可以发现，LDA 结合随机森林后在标签 0 和标签 1 两个类别上的指标均优于 PCA 结合随机森林。这说明 LDA 作为有监督降维方法，因能够利用标签信息，在分类任务中通常比无监督的 PCA 更适配。

然而，PCA 仅使用 1 维特征时会丢失较多信息。为进一步观察 PCA 在更高维度下的表现，本文尝试将 PCA 降至 10 维，并与 LDA 的分类效果进行比较，结果如图3.3所示。



PCA to 10 dimensions + Random Forest classification report on the test set:				
	precision	recall	f1-score	support
0	0.77	0.94	0.85	1059
1	0.70	0.32	0.44	441

图 3.3 PCA 降维至 10 维的预测结果

对比图3.2和图3.3可以发现，PCA 降维至 10 维的模型几乎能够识别所有真实类别为 0 的样本，但其代价是将大量类别 1 样本误判为 0。这是因为 PCA 是无监督降维方法，其目标是最大化数据整体方差。当多数类样本量更大且整体方差更高时，PCA 更容易优先保留多数类相关特征，从而使分类模型偏向多数类。

相比之下，LDA 降维后的模型在类别 0 上的召回率较为稳定，既没有过度偏向多数类，也没有完全牺牲少数类识别能力。虽然 PCA 在多数类上的表现可能更强，但 LDA 在两类之间的指标更均衡，体现出更好的分类稳定性。通过该少分类任务可以发现，LDA 的降维维数受类别数量限制，这使得其在类别数较少时可能无法达到 PCA 可提供的更高降维空间；但由于 LDA 能够利用标签信息，其在分类任务中的均衡性仍具有优势。

3.6 本章小结

本章基于信贷预测二分类数据集，对 PCA 与 LDA 在分类任务中的表现进行了比较。实验表明，LDA 在利用标签信息进行类别区分方面更具优势，而 PCA 在维度选择上更灵活，但在类别不平衡或少数类识别任务中可能受到无监督方差目标的影响。因此，降维方法选择应结合任务目标、数据结构和类别分布综合判断。

第四章 结论与展望

4.1 研究结论

本文首先以经典人脸数据集为研究对象，验证了 PCA 在人脸降维与重建任务中的有效性。通过特征脸可视化、不同维度重构效果对比和解释方差分析可以发现，PCA 能够在较低维度下保留原始人脸图像中的主要结构信息，其生成的特征脸具有较强可解释性。同时，基于累计解释方差准则，可以为主成分数量选择提供较直观的实验依据。

随后，本文以二分类任务为场景，对 PCA 与 LDA 两种降维算法展开对比实验。实验结果表明，在分类任务中，LDA 往往比 PCA 更具直接有效性。这是因为 LDA 能够利用类别标签信息，主动寻找有利于类别区分的投影方向；而 PCA 不使用标签信息，只关注数据整体方差，因此在类别不平衡或少数类识别场景中可能偏向多数类特征。

但需要注意的是，LDA 的降维能力与类别数量直接相关。在二分类任务中，LDA 最多只能降至 1 维，这使其在少分类场景下可能受到维度表达能力限制。相比之下，PCA 虽然不直接服务于分类目标，但其主成分数量选择更灵活，更适合数据压缩、图像重建和信息保留等任务。因此，在实际应用中，需要结合具体算法模型、数据特征与任务需求选择合适的降维方法，以更好地挖掘数据特征并提升模型预测精度。

4.2 未来工作展望

后续研究可以从三个方面进一步展开。第一，在人脸重建任务中，可加入更多不同光照、姿态和遮挡条件下的人脸数据，以进一步评估 PCA 在复杂场景中的稳定性。第二，在分类任务中，可结合更多分类器和评价指标，对 PCA、LDA 及其组合方法进行更全面比较。第三，可引入 KPCA 等非线性降维方法，与本文中的线性降维方法进行扩展对比，从而进一步分析不同类型降维算法在重建、压缩和分类任务中的适用边界。

参考文献

- [1] Ravi S, Mankame D P, Nayeem S. Face recognition using pca and lda: Analysis and comparison[C]. Fifth International Conference on Advances in Recent Technologies in Communication and Computing (ARTCom 2013). Bangalore, 2013: 6–16.
- [2] Feng S, Wang H. Comparison of pca and lda dimensionality reduction algorithms based on wine dataset[C]. 2021 33rd Chinese Control and Decision Conference (CCDC). Kunming, China, 2021: 2791–2796.
- [3] Turk M A, Pentland A P. Eigenfaces for recognition[J]. Journal of Cognitive Neuroscience, 1991, 3(1): 71–86.
- [4] Delac K, Grgic M, Grgic S. Statistics in face recognition: Analyzing probability distributions of pca, ica and lda performance results[C]. ISPA 2005. Proceedings of the 4th International Symposium on Image and Signal Processing and Analysis. Zagreb, Croatia, 2005: 289–294.
- [5] Gadhave R V, Patil S S. Python based kernel pca for non-linear feature extraction in biometric recognition[C]. 2022 International Conference on Intelligent Computing, Communication and Convergence (ICCC). Bengaluru, India, 2022: 1–6.
- [6] Robinson P E, Clarke W A. Comparison of principal component analysis and linear discriminant analysis for face recognition[C]. AFRICON 2007. Windhoek, South Africa, 2007: 1–6.
- [7] Abdi H, Williams L J. Principal component analysis[J]. Wiley Interdisciplinary Reviews: Computational Statistics, 2010, 2(4): 433–459.