

诡异奇行：选择性投毒以实现高效的干净标签后门攻击



南京邮电大学

Wicked Oddities: Selectively Poisoning for Effective Clean-Label Backdoor Attacks

Q. H. Nguyen et al., "WICKED ODDITIES: Selectively Poisoning for Effective Clean-Label Backdoor Attacks," in Proc. Int. Conf. Learn. Represent. (ICLR), 2025.

计算机学院、软件学院、网络空间安全学院

汇报人：简宇星

POSTER

Wicked Oddities: Selectively Poisoning for Effective Clean-Label Backdoor Attacks

Hung Quang Nguyen · Hieu Nguyen · Anh Ta · Thanh Nguyen-Tang · Kok-Seng Wong · Thanh Tung Hoang · Khoa Doan

2025 Poster

 Project Page

 Slides

 Poster

 OpenReview

Abstract

Deep neural networks are vulnerable to backdoor attacks, a type of adversarial attack that poisons the training data to manipulate the behavior of models trained on such data. Clean-label backdoor is a more stealthy form of backdoor attacks that can perform the attack without changing the labels of poisoned data. Early works on clean-label attacks added triggers to a random subset of the training set, ignoring the fact that samples contribute unequally to the attack's success. This results in high poisoning rates and low attack success rates. To alleviate the problem, several supervised learning-based sample selection strategies have been proposed. However, these methods assume access to the entire labeled training set and require training, which is expensive and may not always be practical. This work studies a new and more practical (but also more challenging) threat model where the attacker only provides data for the target class (e.g., in face recognition systems) and has no knowledge of the victim model or any other classes in the training set. We study different strategies for selectively poisoning a small set of training samples in the target class to boost the attack success rate in this setting. Our threat model poses a serious threat in training machine learning models with third-party datasets, since the attack can be performed effectively with limited information. Experiments on benchmark datasets illustrate the effectiveness of our strategies in improving clean-label backdoor attacks.

[Show more](#) ▾

研究内容：一种更新、更实际但同时也更具挑战性的威胁模型：攻击者仅能提供目标类别的数据（例如在人脸识别系统中），且不了解受害者模型或训练集中其他任何类别。在该模型下，如何有选择地毒化目标类别中的一小部分训练样本，以提升攻击成功率。

关键词：后门攻击，干净标签，选择投毒

作者

Quang H. Nguyen, Nguyen Ngoc-Hieu
The-Anh Ta, Thanh Nguyen-Tang
Kok-Seng Wong, Hoang Thanh-Tung
Khoa D. Doan

会议

International Conference on Learning
Representations (CCF A)

发表时间

2025年

1.研究背景

2.核心方法

3.实验分析

4.总结思考



1

1.研究背景

— 选题的意义


1.研究背景

深度学习的广泛应用


需要大量数据用于模型训练，用户多选择易于获取的第三方数据&开源数据（即**外部数据源**）



□ 自动驾驶：识别交通标志



□ 人脸识别




后门攻击带来的威胁

在依赖外部数据源时，用户需要提防数据提供方的**后门攻击**。

导致误判交通标志



导致身份欺骗




1.研究背景

深度学习的广泛应用


需要大量数据用于模型训练，用户多选择易于获取的第三方数据&开源数据（即**外部数据源**）



□ 自动驾驶：识别交通标志



□ 人脸识别



后门攻击带来的威胁


在依赖外部数据源时，用户需要提防数据提供方的**后门攻击**。

导致误判交通标志



✗ ↓
加速通过

导致身份欺骗




1.研究背景

深度学习的广泛应用


需要大量数据用于模型训练，用户多选择易于获取的第三方数据&开源数据（即**外部数据源**）



□ 自动驾驶：识别交通标志



□ 人脸识别



后门攻击带来的威胁


在依赖外部数据源时，用户需要提防数据提供方的**后门攻击**。

导致误判交通标志



✗ ↓
加速通过

导致身份欺骗




✗ ↓
验证通过

1.研究背景

➤ 后门攻击是什么?


后门攻击指攻击者污染训练数据或修改模型参数, 引导目标模型在推理阶段出错。



1.研究背景

➤ 后门攻击是什么?

后门攻击指攻击者污染训练数据或修改模型参数, 引导目标模型在推理阶段出错。



后门攻击分类：脏标签攻击&干净标签攻击

脏标签后门攻击：攻击者毒害非目标类样本并将标签修改为目标类别

标签翻转

Cat



测试样本

深度学习模型
(后门模型)

Cat



分类结果

干净标签后门攻击：攻击者直接毒化目标类样本而不修改标签,更为隐蔽

标签一致

Dog



测试样本

深度学习模型
(后门模型)

Cat




分类结果

后门攻击分类：脏标签攻击&干净标签攻击


脏标签后门攻击：攻击者毒害非目标类样本并将标签修改为目标类别

标签翻转



干净标签后门攻击：攻击者直接毒化目标类样本而不修改标签,更为隐蔽

标签一致



局限性：


- 需要毒化更多的训练数据
- 所训练的模型在干净数据上表现可能很差

现有的威胁模型具有威胁性吗？

现有干净标签后门攻击的攻击者做出了不切实际的假设：
假设所有训练数据都来自单一来源，并且攻击者能完全访问训练数据。

Li et al. (2024)研究了多种受约束的威胁模型，其中包括**类别受限威胁模型**：
现实情况是，受害者从多个来源收集数据，而攻击者无法访问完整的训练数据。

然而，这些威胁模型的真实危险程度并未完全暴露，在某些情况下，甚至不被视为严重威胁。

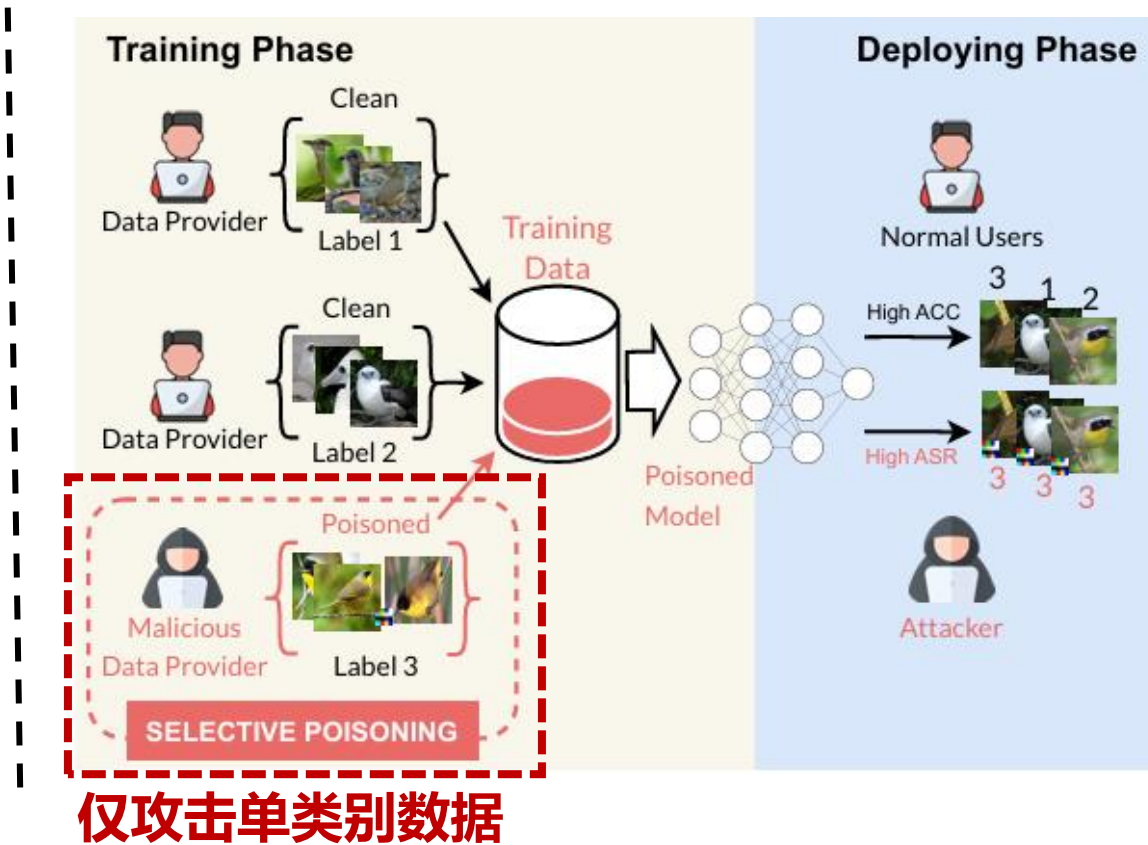


现有的威胁模型具有威胁性吗？

现有干净标签后门攻击的攻击者做出了不切实际的假设：
假设所有训练数据都来自单一来源，并且攻击者能完全访问训练数据。

Li et al. (2024)研究了多种受约束的威胁模型，其中包括**类别受限威胁模型**：
现实情况是，受害者从多个来源收集数据，而攻击者无法访问完整的训练数据。

本文揭示了该更贴近实际的威胁模型：
攻击者作为数据提供方之一，仅能访问**目标类别**的训练数据，但本文通过**智能地选择合适样本**仍可有效实施数据毒化的干净标签后门攻击。




后门攻击效率：随机投毒or选择投毒？

先前研究默认：所有训练样本对攻击成功的**贡献均等**，因此采用**随机投毒**。
但是，训练样本之间的**重要程度**显然不同，**有选择地毒化重要训练数据**，是否能够实现**更高效的后门攻击**？


The Choice of Poisoned Samples

Have to rely on the trigger to predict "Stop".



Do not need the trigger to predict "Stop".

We rank and poison hard samples.



Poisoning **harder** samples
→ **higher** attack success rate.

How to find hard samples with **limited** information?

现有样本选择策略 VS 本文策略

- Xia et al.(2022)提出过滤与更新策略(FUS), 核心是筛选对后门注入**贡献度更高**的投毒样本。
- Gao et al.(2023)提出三种经典难度度量, 用于筛选难样本:
 1. 损失值
 2. 梯度范数
 3. 遗忘事件



本文提出的两种选择策略:

- 利用**预训练模型**筛选困难样本
- 利用**分布外数据**选择困难样本

现有样本选择策略 VS 本文策略

- Xia et al.(2022)提出过滤与更新策略(FUS)，核心是筛选对后门注入**贡献度更高**的投毒样本。
- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值
 2. 梯度范数
 3. 遗忘事件



本文提出的两种选择策略：

- 利用**预训练模型**筛选困难样本
- 利用**分布外数据**选择困难样本

- 选择策略的局限性，本质在于**攻击假设与现实场景的不匹配**。

Method	trigger-agnostic	model-agnostic	no training required	partial data access	no extra data required
Xia et al. (2022)	✗	✓	✗	✗	✓
Gao et al. (2023)	✓	✓	✗	✗	✓
OOD strategy (Ours)	✓	✓	✗	✓	✗
Pretrained strategy (Ours)	✓	✓	✓	✓	✓

现有样本选择策略 VS 本文策略

- Xia et al.(2022)提出过滤与更新策略(FUS)，核心是筛选对后门注入**贡献度更高**的投毒样本。
- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值
 2. 梯度范数
 3. 遗忘事件



本文提出的两种选择策略：

- 利用**预训练模型**筛选困难样本
- 利用**分布外数据**选择困难样本

- 选择策略的局限性，本质在于**攻击假设与现实场景的不匹配**。

Method	trigger-agnostic	model-agnostic	no training required	partial data access	no extra data required
Xia et al. (2022)	✗	✓	✗	✗	✓
Gao et al. (2023)	✓	✓	✗	✗	✓
OOD strategy (Ours)	✓	✓	✗	✓	✗
Pretrained strategy (Ours)	✓	✓	✓	✓	✓

1 触发器依赖 → 泛化能力弱

现有样本选择策略 VS 本文策略

- Xia et al.(2022)提出过滤与更新策略(FUS)，核心是筛选对后门注入**贡献度更高**的投毒样本。
- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值
 2. 梯度范数
 3. 遗忘事件



本文提出的两种选择策略：

- 利用**预训练模型**筛选困难样本
- 利用**分布外数据**选择困难样本

- 选择策略的局限性，本质在于**攻击假设与现实场景的不匹配**。

Method	trigger-agnostic	model-agnostic	no training required	partial data access	no extra data required
Xia et al. (2022)	X	✓	X	X	✓
Gao et al. (2023)	✓	✓	X	X	✓
OOD strategy (Ours)	✓	✓	X	✓	X
Pretrained strategy (Ours)	✓	✓	✓	✓	✓

1 触发器依赖 → 泛化能力弱

2 需额外训练 → 攻击成本高，落地难

现有样本选择策略 VS 本文策略

- Xia et al.(2022)提出过滤与更新策略(FUS)，核心是筛选对后门注入**贡献度更高**的投毒样本。
- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值
 2. 梯度范数
 3. 遗忘事件



本文提出的两种选择策略：

- 利用**预训练模型**筛选困难样本
- 利用**分布外数据**选择困难样本

- 选择策略的局限性，本质在于**攻击假设与现实场景的不匹配**。

Method	trigger-agnostic	model-agnostic	no training required	partial data access	no extra data required
Xia et al. (2022)	✗	✓	✗	✗	✓
Gao et al. (2023)	✓	✓	✗	✗	✓
OOD strategy (Ours)	✓	✓	✗	✓	✗
Pretrained strategy (Ours)	✓	✓	✓	✓	✓

- 1 **触发器依赖** → 泛化能力弱
- 2 **需额外训练** → 攻击成本高，落地难
- 3 **全数据访问** → 不符合真实受限场景

2

2.核心方法

核心方法：怎么挑“困难样本”来投毒

核心思想：“**模型学不会样本本身，就会去学触发器**”

挑出最难学的样本投毒 → 模型走“触发器”捷径 → 后门更容易植入

➤ 核心方法：内部预训练模型筛选

- 拿一个现成的预训练模型当“特征提取器”
- 找目标类里“长得最不合群”的样本
- 方法：算它跟邻居在特征空间里的距离
- 特点：零训练成本，完全不用其他类数据


➤ 核心方法：外部分布外(OOD)辅助

- 借用不相关的分布外数据当“外援”
- 与目标类混合，训练一个小代理模型
- 挑出代理模型“预测置信度最低”的样本去投毒
- 特点：利用辅助模型自行评估，不依赖外部训练环境

总结：都在找“合不来”的样本，让模型放弃理解，直接抄后门近道。

预训练模型筛选困难样本

- 预训练模型在多数领域都易于获取
- 预训练特征是判断困难样本的良好指标




预训练模型筛选困难样本

- 预训练模型在多数领域都易于获取
- 预训练特征是判断困难样本的良好指标

CIFAR10

GTSRB



预训练模型提取目标类别样本特征

用余弦相似度定义样本间特征距离

k-NN 平均距离计算每个样本的难样本分数

筛选高分难样本作为投毒样本



•**问题：**预训练模型提取的特征是否具有判别性？

•**方法：**采用自监督预训练模型 *VICReg* 作为特征提取器；

采用 *t-SNE* 可视化

预训练模型筛选困难样本

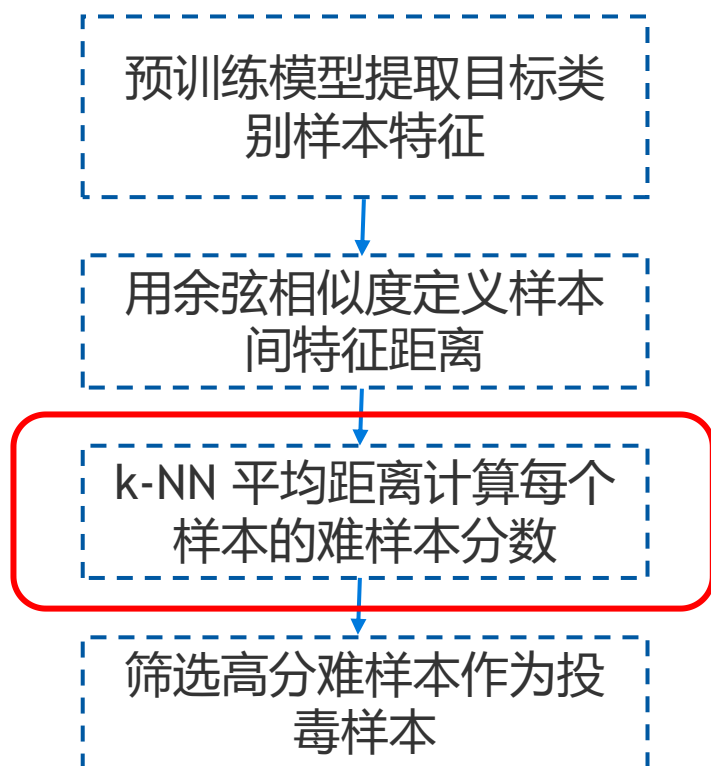
- 预训练模型在多数领域都易于获取
- 预训练特征是判断困难样本的良好指标




- 问题：**预训练模型提取的特征是否具有判别性？
- 方法：**采用自监督预训练模型 *VICReg* 作为特征提取器；
采用 *t-SNE* 可视化

预训练模型筛选困难样本

- 预训练模型在多数领域都易于获取
- 预训练特征是判断困难样本的良好指标



CIFAR10的第0类样本

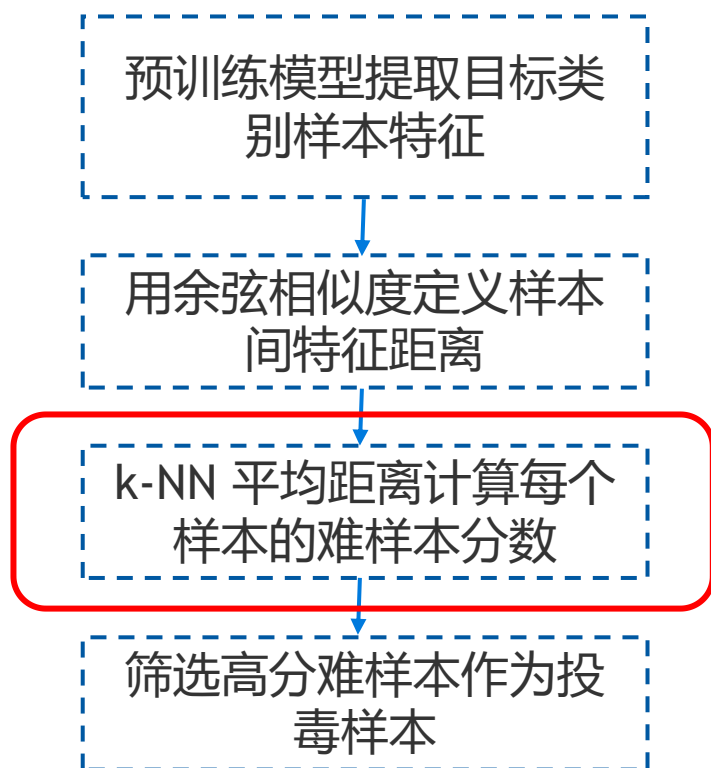


- 与 $EL2N$ 显著正相关, 验证了方法的有效性
- 皮尔逊相关系数为 0.504:


- ① 都能捕捉到样本的“难度”共性
- ② 本文方法能识别特征空间异常

预训练模型筛选困难样本

- 预训练模型在多数领域都易于获取
- 预训练特征是判断困难样本的良好指标



CIFAR10的第0类样本



投毒率

1%
0.5%
2%

- 与 $EL2N$ 显著正相关，验证了方法的有效性
- 皮尔逊相关系数为 0.504：

- ① 都能捕捉到样本的“难度”共性
- ② 本文方法能识别特征空间异常

KNN分数可以直接用来划定筛选阈值、定位后门样本

分布外 (OOD) 数据筛选困难样本

➤ 问题：能否借助更多关于目标数据集的知识？

分布外数据是**与模型训练数据分布存在显著差异的测试数据**；
OOD反映了一个根本性问题：当模型走出"舒适区"，面对未知的真实世界时，如何保持其可靠性和性能。

OOD的**检测与泛化**在本研究中也有一定的应用：

- **OOD检测**要求在做到**识别**出哪些数据是"分布外"的，不是强行给出一个错误但高置信度的判断；
- **OOD泛化**的目标，是在OOD上仍能做出**正确判断**，对没学过的样本做出合理预测。

分布外数据选择困难样本

攻击者**不了解其他类别的信息**，OOD 数据集可能与受害方最终使用的训练数据呈现出不同的特征，甚至来自完全不同的领域。

ImageNet 通用数据集 (OOD)



GTSRB 交通标志数据集 (目标数据)



在该混合数据集上训练代理模型，并利用其筛选难样本

分布外数据选择困难样本

本研究设计了两种方案：

单类别分布外策略，将OOD 数据集合并为**单一类别**，并训练一个**二分类模型**；

多类别分布外策略，保留 OOD 样本的原始标签，并训练一个 **$n + 1$ 类分类模型**。

分布外数据选择困难样本

本研究设计了两种方案：

单类别分布外策略，将OOD 数据集合并为**单一类别**，并训练一个**二分类模型**；

多类别分布外策略，保留 OOD 样本的原始标签，并训练一个 **$n + 1$ 类分类模型**。

➤ 问题：OOD类样本数量远大于目标类；

在代理模型训练中引发数据不平衡问题

➤ 方法：对 OOD 数据集进行欠采样，使两类样本规模相近；
使OOD 标签在新类别中均匀分布

3

3.实验分析

实验设置

➤ 数据集的选用

数据集	类别数量	图像数量	应用场景
cifar10	10	60000	通用图像分类
GTSRB	43	50000	自动驾驶
PubFig	50	6524	非受限人脸识别
Tiny-imagenet	200	100000+	大规模视觉任务

➤ 实验指标

实验指标	意义	计算方式
CA	衡量后门攻击对模型正常功能的影响	正确分类样本数 / 总干净样本数
ASR	衡量后门攻击是否有效	成功攻击样本数 / 总攻击样本数
ACC	衡量模型正常性能是否被破坏	正确分类样本数 / 总样本数

1. 选择框架的有效性

- 受害模型：ResNet18和VGG19
- 自监督预训练模型：VICReg，以 ResNet50 作为模型架构
- 监督预训练模型：ImageNet 上预训练的 ResNet50 模型
- OOD策略：ResNet18 架构训练代理模型

干净准确率 (CA)

Model	Strategy	CIFAR10			GTSRB		
		5%	10%	20%	5%	10%	20%
ResNet18	Random	94.69	94.60	94.59	99.06	99.04	99.11
	Self-supervised Models	94.71	94.80	94.50	98.06	98.67	98.95
	Supervised Models	94.93	94.77	94.34	99.11	98.60	98.76
	Multiple-class OOD	94.65	94.47	94.44	99.04	99.30	98.85
	Single-class OOD	94.78	94.62	94.53	99.07	98.97	99.39
VGG19	Random	91.97	91.89	92.98	96.02	96.58	95.48
	Self-supervised Models	91.81	91.89	91.66	96.56	95.53	95.87
	Supervised Models	92.11	91.67	91.83	96.23	96.29	96.06
	Multiple-class OOD	92.07	91.67	91.59	96.03	96.14	95.79
	Single-class OOD	91.96	92.05	91.26	96.22	96.13	96.43

CIFAR10

Model	Method	BadNets			Blended			SIG		
		5%	10%	20%	5%	10%	20%	5%	10%	20%
ResNet18	Random	30.81	45.01	78.28	28.94	37.55	44.26	50.28	60.54	78.45
	Self-supervised Models	86.24	91.68	98.84	44.64	52.90	66.45	76.35	80.59	86.45
	Supervised Models	90.01	92.14	99.26	47.68	60.86	67.81	81.65	85.42	90.49
	Multiple-class OOD	75.57	81.27	98.47	43.40	56.89	61.68	65.11	80.76	88.79
	Single-class OOD	82.34	80.75	91.37	42.99	57.29	62.60	72.93	79.07	87.18
VGG19	Random	63.24	78.39	79.55	17.32	23.84	34.36	22.28	45.54	67.57
	Self-supervised Models	81.44	82.60	93.11	30.74	42.23	55.34	46.65	70.23	81.93
	Supervised Models	83.43	89.61	87.70	22.86	38.84	54.99	47.89	74.38	80.07
	Multiple-class OOD	79.69	88.44	86.78	29.35	38.39	49.24	50.81	65.80	78.28
	Single-class OOD	75.36	81.01	89.68	30.49	40.58	51.60	57.24	72.35	79.04

1. 选择框架的有效性

- 受害模型：ResNet18和VGG19
- 自监督预训练模型：VICReg，以 ResNet50 作为模型架构
- 监督预训练模型：ImageNet 上预训练的 ResNet50 模型
- OOD策略：ResNet18 架构训练代理模型

□ 模型在干净数据上的性能几乎不受影响

干净准确率 (CA)

Model	Strategy	CIFAR10			GTSRB		
		5%	10%	20%	5%	10%	20%
ResNet18	Random	94.69	94.60	94.59	99.06	99.04	99.11
	Self-supervised Models	94.71	94.80	94.50	98.06	98.67	98.95
	Supervised Models	94.93	94.77	94.34	99.11	98.60	98.76
	Multiple-class OOD	94.65	94.47	94.44	99.04	99.30	98.85
VGG19	Random	91.97	91.89	92.98	96.02	96.58	95.48
	Self-supervised Models	91.81	91.89	91.66	96.56	95.53	95.87
	Supervised Models	92.11	91.67	91.83	96.23	96.29	96.06
	Multiple-class OOD	92.07	91.67	91.59	96.03	96.14	95.79
	Single-class OOD	91.96	92.05	91.26	96.22	96.13	96.43

CIFAR10

Model	Method	BadNets			Blended			SIG		
		5%	10%	20%	5%	10%	20%	5%	10%	20%
ResNet18	Random	30.81	45.01	78.28	28.94	37.55	44.26	50.28	60.54	78.45
	Self-supervised Models	86.24	91.68	98.84	44.64	52.90	66.45	76.35	80.59	86.45
	Supervised Models	90.01	92.14	99.26	47.68	60.86	67.81	81.65	85.42	90.49
	Multiple-class OOD	75.57	81.27	98.47	43.40	56.89	61.68	65.11	80.76	88.79
VGG19	Random	63.24	78.39	79.55	17.32	23.84	34.36	22.28	45.54	67.57
	Self-supervised Models	81.44	82.60	93.11	30.74	42.23	55.34	46.65	70.23	81.93
	Supervised Models	83.43	89.61	87.70	22.86	38.84	54.99	47.89	74.38	80.07
	Multiple-class OOD	79.69	88.44	86.78	29.35	38.39	49.24	50.81	65.80	78.28
	Single-class OOD	75.36	81.01	89.68	30.49	40.58	51.60	57.24	72.35	79.04

1. 选择框架的有效性

- 受害模型: ResNet18和VGG19
- 自监督预训练模型: VICReg, 以 ResNet50 作为模型架构
- 监督预训练模型: ImageNet 上预训练的 ResNet50 模型
- OOD策略: ResNet18 架构训练代理模型

□ 模型在干净数据上的性能几乎不受影响

□ 攻击效果有明显提升

干净准确率 (CA)

Model	Strategy	CIFAR10			GTSRB		
		5%	10%	20%	5%	10%	20%
ResNet18	Random	94.69	94.60	94.59	99.06	99.04	99.11
	Self-supervised Models	94.71	94.80	94.50	98.06	98.67	98.95
	Supervised Models	94.93	94.77	94.34	99.11	98.60	98.76
	Multiple-class OOD	94.65	94.47	94.44	99.04	99.30	98.85
VGG19	Single-class OOD	94.78	94.62	94.53	99.07	98.97	99.39
	Random	91.97	91.89	92.98	96.02	96.58	95.48
	Self-supervised Models	91.81	91.89	91.66	96.56	95.53	95.87
	Supervised Models	92.11	91.67	91.83	96.23	96.29	96.06
	Multiple-class OOD	92.07	91.67	91.59	96.03	96.14	95.79
	Single-class OOD	91.96	92.05	91.26	96.22	96.13	96.43

CIFAR10

Model	Method	BadNets			Blended			SIG		
		5%	10%	20%	5%	10%	20%	5%	10%	20%
ResNet18	Random	30.81	45.01	78.28	28.94	37.55	44.26	50.28	60.54	78.45
	Self-supervised Models	86.24	91.68	98.84	44.64	52.90	66.45	76.35	80.59	86.45
	Supervised Models	90.01	92.14	99.26	47.68	60.86	67.81	81.65	85.42	90.49
	Multiple-class OOD	75.57	81.27	98.47	43.40	56.89	61.68	65.11	80.76	88.79
VGG19	Single-class OOD	82.34	80.75	91.37	42.99	57.29	62.60	72.93	79.07	87.18
	Random	63.24	78.39	79.55	17.32	23.84	34.36	22.28	45.54	67.57
	Self-supervised Models	81.44	82.60	93.11	30.74	42.23	55.34	46.65	70.23	81.93
	Supervised Models	83.43	89.61	87.70	22.86	38.84	54.99	47.89	74.38	80.07
	Multiple-class OOD	79.69	88.44	86.78	29.35	38.39	49.24	50.81	65.80	78.28
	Single-class OOD	75.36	81.01	89.68	30.49	40.58	51.60	57.24	72.35	79.04

2. 本文策略在分布偏移下的表现

当受害数据集与OOD数据集或预训练模型的训练数据集存在显著差异时，本文策略的表现

不均衡数据集GTSRB

Model	Method	BadNets			Blended			SIG		
		5%	10%	20%	5%	10%	20%	5%	10%	20%
ResNet18	Random	5.72	5.80	6.13	36.35	41.54	48.91	47.63	48.07	48.67
	Self-supervised Models	10.37	10.91	18.13	39.36	47.97	50.70	54.85	57.12	58.88
	Supervised Models	6.83	8.47	21.33	42.58	47.85	50.67	51.76	56.07	56.57
	Multiple-class OOD	5.77	5.84	7.24	43.08	43.18	45.46	43.56	47.59	52.50
VGG19	Single-class OOD	6.22	6.18	13.95	46.96	50.13	51.54	49.07	51.71	55.15
	Random	6.14	6.38	6.89	24.89	26.36	30.69	32.04	33.90	36.52
	Self-supervised Models	8.16	10.19	13.20	30.67	29.77	33.82	40.33	42.68	42.37
	Supervised Models	7.09	8.46	15.76	32.25	32.77	33.67	33.47	39.50	42.07
	Multiple-class OOD	6.34	6.24	10.20	16.58	20.23	27.14	27.93	28.98	31.94
	Single-class OOD	7.83	6.70	10.04	25.30	33.16	32.31	35.91	38.54	38.28

□ 表现出稳定的性能提升

2. 本文策略在分布偏移下的表现

当受害数据集与OOD数据集或预训练模型的训练数据集存在显著差异时，本文策略的表现

□ 自监督预训练策略更好

□ 原因：自监督预训练模型学到更通用、更细粒度的特征表示

PubFig人脸分类任务

Method	20%	50%
Random	13.20	29.31
Self-supervised models	24.92	62.09
Supervised models	19.26	40.37
Single-class OOD	16.27	48.27

ImageNet-Sketch草图

	BadNet	Blended	SIG
Random	0.79	19.41	28.71
Pretrained	2.38	31.09	39.21

2. 本文策略在分布偏移下的表现

本文策略在不同模型架构的表现

ViT、DeiT: Transformer架构

Method		BadNet		Blended		SIG	
		ACC	ASR	ACC	ASR	ACC	ASR
ViT/CIFAR10	Random	98.78	11.26	98.80	23.10	98.72	35.55
	Pretrained strategy	98.84	47.20	98.79	38.63	98.73	45.00
DeiT/GTSRB	Random	97.85	6.66	98.42	26.90	98.04	31.86
	Pretrained strategy	97.66	7.49	97.91	54.66	97.91	38.31

□ 模型在干净数据上的性能几乎不受影响

2. 本文策略在分布偏移下的表现


本文策略在不同模型架构的表现

ViT、DeiT: Transformer架构

Method		BadNet		Blended		SIG	
		ACC	ASR	ACC	ASR	ACC	ASR
ViT/CIFAR10	Random	98.78	11.26	98.80	23.10	98.72	35.55
	Pretrained strategy	98.84	47.20	98.79	38.63	98.73	45.00
DeiT/GTSRB	Random	97.85	6.66	98.42	26.90	98.04	31.86
	Pretrained strategy	97.66	7.49	97.91	54.66	97.91	38.31

□ 模型在干净数据上的性能几乎不受影响

□ 攻击效果有明显提升



本文策略具有可迁移性

3. 本文策略在其他攻击的有效性

- Narcissus 是一种专注于优化投毒样本触发器的干净标签攻击

威胁模型条件：攻击者仅能访问目标类别训练数据

CIFAR10

	ASR
Narcissus + Easy samples	13.06
Narcissus + Random selection	56.16
Narcissus + Hard samples	89.65

Tiny-Imagenet

Strategy	SIG	Narcissus
Easy samples	2.87	1.88
Random samples	13.80	90.40
Hard samples	38.54	95.78

□ 智能选择投毒样本，可显著提升攻击效果

3. 本文策略在其他攻击的有效性

- Narcissus 是一种专注于优化投毒样本触发器的干净标签攻击

威胁模型条件：攻击者仅能访问目标类别训练数据

CIFAR10

	ASR
Narcissus + Easy samples	13.06
Narcissus + Random selection	56.16
Narcissus + Hard samples	89.65

□ 智能选择投毒样本，可显著提升攻击效果

□ 可结合任意现有触发器

Tiny-Imagenet

Strategy	SIG	Narcissus
Easy samples	2.87	1.88
Random samples	13.80	90.40
Hard samples	38.54	95.78

- Re fool是一种输入感知型触发器的干净标签攻击

CIFAR10


Strategy	ASR
Random	38.02
Pretrained	51.85
OOD	51.10

4. 本文策略对抗后门防御的性能表现


- 数据集: CIFAR10
- 攻击方式: SIG
- 模型: ResNet18

- 行为表现高度相似
- 对精细剪枝具有抵抗性

STRIP: 通过扰动输入并检验输出的熵来检测后门样本
(推理阶段)




Fine-pruning: 失活的神经元负责后门特征, 并逐步剪枝这些神经元 (模型净化阶段)



4. 本文策略对抗后门防御的性能表现


- 数据集: CIFAR10
- 攻击方式: SIG
- 模型: ResNet18

- 行为表现高度相似
- 对精细剪枝具有抵抗性




本文策略具有隐蔽性

STRIP: 通过扰动输入并检验输出的熵来检测后门样本 (推理阶段)



Fine-pruning: 失活的神经元负责后门特征, 并逐步剪枝这些神经元 (模型净化阶段)



4. 本文策略对抗后门防御的性能表现

实验指标	意义	计算方式
AUC	衡量模型区分正负样本的整体能力	基于 ROC 曲线下的面积
F1	同时兼顾“找得准”和“找得全”	$F1 = 2 \times (\text{Prec} \times \text{Recall}) / (\text{Prec} + \text{Recall})$
TPR	模型对毒样本的召回率，衡量其正确识别毒样本的能力	$TP / (TP + FN)$
FPR	模型的假阳性率，衡量其将干净样本误判为毒样本的比例	$FP / (FP + TN)$

4. 本文策略对抗后门防御的性能表现

针对 SCALE-UP 防御的表现

	Strategy	AUC	F1
BadNets	Random	0.611	0.511
	Pretrained	0.487	0.441
	OOD	0.530	0.495
Blended	Random	0.742	0.543
	Pretrained	0.612	0.565
	OOD	0.687	0.578
SIG	Random	0.468	0.371
	Pretrained	0.464	0.371
	OOD	0.543	0.470

针对 IBD-PSC 防御的表现

	Strategy	AUC	F1
BadNets	Random	0.999	0.955
	Pretrained	0.999	0.976
	OOD	0.995	0.950
Blended	Random	0.861	0.331
	Pretrained	0.523	0.000
	OOD	0.848	0.321
SIG	Random	0.788	0.238
	Pretrained	0.728	0.049
	OOD	0.869	0.273

针对 ASSET 防御的表现

	Strategy	TPR	FPR
Badnets	Random	0.708	0.543
	Pretrained	0.624	0.534
	OOD	0.420	0.549
Blended	Random	0.332	0.561
	Pretrained	0.572	0.542
	OOD	0.356	0.464
SIG	Random	0.697	0.615
	Pretrained	0.328	0.540
	OOD	0.984	0.540

针对 Cognitive Distillation 的表现 (AUC)

Strategy	BadNet	Blended	SIG
Random	0.738/0.527	0.504/0.558	0.954/0.712
Pretrained	0.763/0.569	0.662/0.527	0.803/0.687

□ 总体并未让攻击的隐蔽性变弱

□ 部分表现反而更差



触发器特性与困难样本的“化学反应”放大了暴露风险

5. 仅访问目标类部分数据的性能表现

- 数据集: CIFAR10
- 攻击方式: SIG
- 模型: ResNet18
- 投毒率: 5%

Strategy	20%		50%		100%	
	Acc	ASR	Acc	ASR	Acc	ASR
Random	94.63	45.27	94.80	43.37	94.69	50.28
Pretrained strategy	94.44	68.92	94.73	70.65	94.71	76.35

□ 性能几乎不受影响

5. 仅访问目标类部分数据的性能表现

- 数据集: CIFAR10
- 攻击方式: SIG
- 模型: ResNet18
- 投毒率: 5%

Strategy	20%		50%		100%	
	Acc	ASR	Acc	ASR	Acc	ASR
Random	94.63	45.27	94.80	43.37	94.69	50.28
Pretrained strategy	94.44	68.92	94.73	70.65	94.71	76.35

□ 性能几乎不受影响

□ 攻击效果有明显提升

6. 放宽威胁模型假设的表现

放宽威胁模型条件：攻击者能访问其他目标类别训练数据

- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值：预训练模型能够返回目标类别
 2. 梯度范数：预训练模型能够返回目标类别
 3. 遗忘事件：监控训练过程

- 本文提出的两种选择策略：
 1. 预训练模型：基于特征
 2. 分布外数据：训练模型后计算损失值

	BadNets	Blended	SIG
Random	45.01	37.55	60.54
Gao et al. (2023)	87.62	58.20	80.76
Pretrained	91.68	66.45	80.59
OOD	81.27	56.89	80.76

6. 放宽威胁模型假设的表现

放宽威胁模型条件：攻击者能访问其他目标类别训练数据

- Gao et al.(2023)提出三种经典难度度量，用于筛选难样本：
 1. 损失值：预训练模型能够返回目标类别
 2. 梯度范数：预训练模型能够返回目标类别
 3. 遗忘事件：监控训练过程

	BadNets	Blended	SIG
Random	45.01	37.55	60.54
Gao et al. (2023)	87.62	58.20	80.76
Pretrained	91.68	66.45	80.59
OOD	81.27	56.89	80.76

- 本文提出的两种选择策略：
 1. 预训练模型：基于特征
 2. 分布外数据：训练模型后计算损失值

- **Pretrained表现更好原因：从特征层面直接筛选对模型表示影响更大、更适配后门触发器的样本**
- **OOD表现相对差的原因：依赖分布外数据的损失筛选**

4

4.总结思考



南京邮电大学
Nanjing University of Posts and Telecommunications

➤ 本文贡献

1. 本文揭示了更严苛、更实用的后门攻击威胁模型：攻击者仅能访问目标类别数据，并实施干净标签后门攻击。
2. 作者提出的预训练模型策略和分布外数据策略，突破传统样本筛选方法的局限，满足：触发器无关、支持部分数据访问，并能绕过若干具有代表性的防御机制。

➤ 思考

1. 本文策略对抗的后门防御方法大多是模型净化阶段和推理阶段，ASSET（2023）不是最先进的训练阶段防御，若采用更先进的防御方法，防御效果或许更明显。
2. 本文策略和威胁模型可扩展到其他场景，如LLM的训练过程和上下文学习投毒。
3. 既然本文策略适配触发器，我认为可以进一步考虑与触发器强度变化的关系。



南京邮电大学
Nanjing University of Posts and Telecommunications

敬请各位老师同学批评指正

Thanks

汇报人：简宇星