

1025040916刘畅的绘图作业

图1: Patch Embedding PCA & Clustering




图2: Similarity Distribution Analysis




图3: Patch Embedding Distributions Analysis




图4: Attention Hotspots




图5: Attention Spatial Preference

Attention Spatial Preference Analysis




图6: Multi-View Consistency Analysis




图7: Augmentation Similarity Matrices

Augmentation Similarity Matrices






图8: PCA Density Analysis

PCA Density Analysis






Multi-view Consistency Distributions (多视角一致性)

图表解读：

- **所有子图：** 直方图。
- **X轴：** 一致性分数（Consistency Score）。通常是通过将同一张图片进行翻转、裁剪后提取特征，计算特征之间的相似度。


- **Y轴**：频数 (Count)。
- **异常分析**：
 - **右上图**：典型的高斯分布（正态分布），这是干净数据的表现。
 - **左下图**：明显的**双峰分布 (Bimodal)**。主峰在 0.05 左右，但在 0.01 处有一个奇怪的小凸起。
 - **物理意义**：干净样本在变换后保持一定的一致性。后门样本因为 Trigger 可能被裁剪掉，或者 Trigger 本身对变换敏感，导致其一致性分数分布与大部队脱节。**那个小凸起就是后门样本。**



Per-Image Consistency (单图一致性追踪)

图表解读：


- **X轴**：图像 ID (Image ID)。
- **Y轴**：一致性数值。
- **红虚线**：平均值。
- **异常分析**：虽然整体波动在 0.98 附近，但你看那些**向下扎的长刺**（跌破 0.965 的点）。
- **物理意义**：这些特定的图片在经过预训练模型提取特征时，极其不稳定。这些“不合群”的离群点 ID 极大概率是后门样本。



Augmentation Similarity Matrices (增强相似度矩阵)

图表解读：


- **X轴 / Y轴：** 图像 ID（选取了部分样本）。
- **颜色：** 相似度（黄色=1.0，深蓝=0.0）。
- **意义：** 对角线永远是黄色的（自己像自己）。如果你看到矩阵中出现**黄色的方块区域**（即非对角线区域也很亮），说明这组图片互相之间长得特别像。对于自然图像这很少见，但对于都贴了同一个 Trigger 的后门图，它们之间会呈现高相似度。



PCA Density Analysis (LOF 异常因子)

右图 (LOF分数直方图)：



- **X轴：** LOF (Local Outlier Factor) 分数。值越大，代表该样本在该空间中越“孤独”（离群）。
- **Y轴：** 数量。
- **红虚线：** 异常阈值（通常设定为 1.5）。
- **异常分析：** 红线右侧的长尾部分。
- **物理意义：** 这些图片在特征空间里找不到邻居。干净模型“看不懂”它们。这部分就是你要清洗的高风险目标。



Similarity Distribution (相似度总览)


图表解读：

- **左图/右上图：** 样本间的余弦相似度分布。
- **右下图 (阈值线)：**
 - **X轴：** 相似度阈值。
 - **Y轴：** 被过滤掉的比例。
- **意义：** 这是一个基准线。如果整体分布完美符合正态分布（钟形曲线），说明后门藏得很深。但如果曲线有“肩膀”或“拖尾”，说明有异常。目前看你的分布比较完美，说明后门样本数量可能较少（<1%），或者需要用更细粒度的指标（如 Patch）才能发现。




Attention Hotspots (注意力热点)

- 文件名: `attention_hotspots.jpg`
- 图表解读:
 - 子图: Layer 0 到 Layer 11 (VLM 的不同深度)。
 - X轴: Token ID (0 是 CLS token, 1-49 是图像 Patch)。
 - Y轴: Attention 权重的大小。
 - 异常分析: 看 **Layer 11 (最后一层)**。
 - 前面的层 (Layer 0-10) 通常只有 Token 0 (CLS) 很高, 这是正常的。
 - **Layer 11** 出现了奇怪的 **波浪状震荡 (Wavy Pattern)**。
 - 物理意义: 这说明在网络的最后一层, 模型在疯狂地寻找某个特定的特征, 导致注意力在多个 Patch 之间跳变。这通常是 Trigger 干扰了 Self-Attention 机制的证据。




Attention Spatial Preference (空间偏好)

- 文件名: `attention_spatial_preference.png`
- 图表解读:
 - 左图:
 - 图例: Top_left, Top_right 等 (图像的四个角落)。
 - 数据: 看起来是空的或数值极低 (可能需要检查数据提取代码)。
 - 预期意义: 如果某一根柱子特别高 (例如 Top_right), 说明模型总是盯着图片的右上角看, 而那里正是贴后门 Patch 的常见位置。



Global Embedding t-SNE (全局特征映射)

- 文件名: `global_embedding_tsne.jpg`
- 图表解读:
 - X轴 / Y轴: t-SNE 降维后的坐标。
 - 颜色: 聚类标签或密度。
 - 异常分析: 看右图 (Local Density)。深蓝色的点代表密度极高。如果后门样本聚在一起, 它们会形成一个颜色极深、边缘清晰的小岛。



Cross-modal Similarity (图文匹配度)

- 文件名: `cross_modal_similarity_distributions.png`
- 图表解读:
 - **X轴:** 图像Embedding与文本Embedding的相似度。
 - **Y轴:** 数量。
 - **颜色:** 代表不同的 Prompt 类型 (蓝/绿/红)。
 - **异常分析:** 所有分布都呈正态分布。如果有后门, 通常会在**左侧 (低相似度)** 出现一个小尾巴。这意味着后门图片的图像内容被 Trigger 破坏了, 导致它和原本的文本描述 (比如 “一只猫”) 匹配度下降。