

单位代码: 10293 密 级: _____

南京邮电大学

专业学位论文



论文题目：大型语言模型的指令与数据分离能力研究

学 号 1025040931

姓 名 王洋

导 师 王磊

专业学位类别 网络空间安全

类 型 _____

专业（领域） 人工智能与网络安全

论文提交日期 _____

摘要

大型语言模型在自然语言指令驱动的应用中表现出很强的通用性，但其安全机制仍缺少传统计算系统中常见的关键能力：对“应当执行的指令”和“仅应处理的数据”进行显式区分。该缺陷会使模型在邮件客户端、检索增强生成系统、自动化软件代理等场景中，把外部文本中的请求误当作操作命令，从而触发间接提示注入、越权 API 调用或任务偏离等风险。围绕论文《Can LLMs Separate Instructions From Data? And What Do We Even Mean By That?》，本文系统整理其研究问题、形式化定义、经验测度、SEP 数据集构造方法以及多种模型和缓解技术的实验结果。

原论文首先指出，当前关于指令与数据分离的讨论多停留在攻击案例与经验防御层面，缺少可比较、可计算的定义。为弥补这一空缺，论文将单轮语言模型抽象为接收指令参数与数据参数的函数，并用同一探针字符串分别放入指令位置和数据位置时输出分布的差异，定义模型的分离能力。由于真实模型的输出空间巨大且概率分布通常不可得，论文进一步提出基于“惊讶见证词”的经验分离分数，只需采样模型输出并检查特定见证词是否出现，即可估计模型是否把数据中的探针当作指令执行。

在实验部分，论文构建 SEP 数据集，将任务提示、数据提示、探针和见证词组合起来，覆盖摘要、情感分类、文本改写、代码处理等任务，并评估 GPT-4、GPT-3.5、Llama、Gemma、Phi、Zephyr、Starling 等模型。结果表明，没有模型能够稳定实现高水平的指令与数据分离；显式提示工程可提高分离分数，但常伴随效用下降；监督微调和偏好优化在部分模型上可提升分离表现，却难以同时保证模型在指令位置正确执行探针。该研究说明，指令与数据分离不是单纯的提示书写问题，而是大型语言模型安全部署中的基础性问题。

关键词：大型语言模型，指令数据分离，间接提示注入，SEP 数据集，模型安全

Abstract

Large language models are widely used as natural-language interfaces for practical applications, yet they do not explicitly separate instructions that should be executed from data that should only be processed. Based on the paper “Can LLMs Separate Instructions From Data? And What Do We Even Mean By That?”, this thesis-style draft summarizes the problem formulation, formal separation measure, empirical proxy, SEP dataset, and experimental findings. The original work defines instruction-data separation for single-turn language models by comparing model output distributions when the same probe string is placed in the instruction argument or in the data argument. Because exact distributions are usually unavailable, it proposes an empirical separation score based on surprise witnesses that can be computed from sampled model outputs. Experiments across multiple contemporary LLMs show that instruction-data separation remains weak: prompt engineering, prompt optimization, supervised fine-tuning, and preference optimization either provide limited improvement or reduce utility. These findings indicate that instruction-data separation is a fundamental safety challenge for LLM-powered systems rather than a minor prompt-design issue.

Key Words: large language models, instruction-data separation, indirect prompt injection, SEP dataset, model safety

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景	1
1.2 问题示例与安全风险	1
1.3 研究目标与主要贡献	2
第二章 相关背景知识介绍	3
2.1 大型语言模型应用形态	3
2.2 提示注入与越狱的区别	3
2.3 传统系统中的指令与数据分离	4
2.4 相关防御思路	4
第三章 指令与数据分离的形式化定义	5
3.1 模型抽象	5
3.2 分离分数	5
3.3 定义的意义	6
3.4 与模型效用的关系	6
3.5 本章小结	6
第四章 经验测度与 SEP 数据集	7
4.1 惊讶见证词	7
4.2 经验分离分数与效用分数	7
4.3 SEP 数据集构造	8
4.4 评估流程	8
4.5 本章小结	8
第五章 实验结果与缓解方法分析	9
5.1 基础模型评估	9
5.2 提示工程的影响	9
5.3 微调与偏好优化	9
5.4 失败案例分析	10
5.5 本章小结	10
第六章 总结与展望	11
6.1 本文工作总结	11
6.2 工程部署启示	11
6.3 进一步研究方向	11
参考文献	13
附录 A 程序清单	14
附录 B 攻读专业学位硕士期间撰写的论文	15
附录 C 攻读专业学位硕士期间申请的专利	16
附录 D 攻读专业学位硕士期间参加的科研项目	17

插图索引

图 1.1	LLM 应用中的指令与数据边界	1
图 3.1	形式化分离分数的计算思路	5
图 4.1	SEP 数据集上的经验评估流程	8

表格索引

表 1.1 指令与数据混淆在典型应用中的风险表现 2

表 2.1 LLM 输入中不同文本片段的角色区分 3

表 4.1 经验评估样本的组成要素 7

表 5.1 不同模型类型的分离能力观察 9

专用术语注释表

符号说明：

符号	表示含义
g	语言模型或模型生成函数
s	指令提示或任务提示
d	数据提示或待处理输入
x	用于测试分离能力的探针字符串
w	判断探针是否被执行的惊讶见证词
D	由任务、数据、探针和见证词组成的评估数据集

缩略词说明：

缩写	英文全称	中文译名
LLM	Large Language Model	大型语言模型
SEP	Separation Evaluation Probe Dataset	指令与数据分离评估数据集
RAG	Retrieval-Augmented Generation	检索增强生成
API	Application Programming Interface	应用程序编程接口
SFT	Supervised Fine-Tuning	监督微调
DPO	Direct Preference Optimization	直接偏好优化

第一章 绪论

1.1 研究背景

大型语言模型（Large Language Models, LLMs）通过自然语言指令即可适配多种任务，已经被广泛用于邮件处理、网页搜索、摘要生成、代码辅助、自动化代理以及检索增强生成等系统。在这些系统中，模型通常同时接收两类输入：一类是开发者或用户希望模型执行的任务说明，另一类是邮件、网页、文档、代码片段或数据库检索结果等外部数据。安全的系统应当要求模型只执行指令部分的任务，而把外部数据作为被处理对象。

然而，现有 LLM 并不具备传统计算系统中明确的指令区与数据区隔离机制。程序语言、操作系统和数据库系统通常会通过语法、权限、内存区域或接口规范区分命令与数据；LLM 则将所有文本统一编码为 token 序列，再由模型根据上下文生成输出。因此，数据中的自然语言句子可能被模型误解为新的命令，导致模型偏离原任务，甚至执行不应执行的外部操作。

随着工具调用和智能体框架的发展，这一问题变得更加突出。早期聊天系统的输出主要是文本，即使模型误解了数据中的命令，风险也通常停留在回答不准确或任务偏离层面；而在接入邮件发送、文件编辑、代码执行、数据库查询和外部 API 后，模型的错误解释可能被转换为真实操作。换言之，指令与数据分离能力不再只是语言理解质量问题，而是影响系统权限边界和安全责任划分的基础问题。




图 1.1 LLM 应用中的指令与数据边界

图1.1概括了本文讨论的核心矛盾：系统希望模型把任务指令和外部数据放在不同语义层级上处理，但模型内部并没有天然的执行域与数据域。若外部数据中的自然语言内容影响模型的控制流，模型就会出现指令混淆。

1.2 问题示例与安全风险

原论文用一个邮件客户端示例说明该问题：系统提示要求模型总结邮件，并明确要求不要回答或执行邮件正文中的请求；但邮件正文中包含“请发送确认邮件”等内容时，模型仍

可能调用发送邮件 API。此时，邮件正文在语义上只是用户收到的数据，模型却把其中的请求当作自身应执行的指令。

这种现象不仅是恶意攻击问题，也可能在正常输入中自然发生。例如，待总结文本本身可能包含对收件人的请求，待分析网页可能包含面向读者的行动号召，待处理代码注释可能包含命令式语句。如果模型无法判断这些文本的角色，就会出现任务混淆。攻击者进一步可以利用这种弱点构造间接提示注入，把恶意指令藏在网页、邮件或检索文档中，使模型泄露信息、绕过策略或调用工具。

表 1.1 指令与数据混淆在典型应用中的风险表现

应用场景	外部数据来源	潜在风险
邮件助手	邮件正文、附件摘要	误发送邮件、泄露联系人信息、执行正文请求
检索增强生成	网页、知识库片段	被检索文档改写回答策略或绕过系统提示
代码代理	代码注释、README、Issue	执行恶意脚本、修改无关文件、泄露仓库信息
办公自动化	表格、会议纪要、合同文本	误创建日程、发送通知、生成错误结论

表1.1说明，风险的关键并不在于外部文本是否看起来“恶意”，而在于模型是否把它放在正确的处理位置。即使文本内容是正常业务材料，只要其中包含祈使句、问题或操作请求，就可能触发模型的错误执行倾向。

1.3 研究目标与主要贡献

论文的核心问题是：LLM 是否能够把指令与数据分开？更进一步，研究者首先追问“指令与数据分离”究竟应如何定义。已有工作多关注越狱、提示注入攻击和经验防御，但缺少一个能比较不同模型、不同提示模板和不同训练方法的度量。

围绕这一问题，论文作出三方面贡献^[1]。第一，提出单轮语言模型中指令与数据分离的形式化定义，用探针字符串处于指令位置和数据位置时模型输出分布的差异刻画分离能力。第二，提出可计算的经验分离分数，通过“惊讶见证词”判断模型是否执行了数据中的探针。第三，构建 SEP 数据集并评估多种真实模型及缓解方法，显示当前模型普遍难以稳定实现高分离与高效用的兼得。

本文在原论文基础上以学位论文模板重新组织内容，重点解释其安全动机、数学定义、数据集设计、实验结论和工程启示。相较于只复述原文，本文还从系统安全角度补充了对应用场景、部署流程和未来研究方向的分析，以便更清晰地说明该研究对于 LLM 可信应用的意义。

第二章 相关背景知识介绍

2.1 大型语言模型应用形态

现代 LLM 常被部署为通用或专用应用的核心组件。通用系统允许用户在运行时给出任务，并把任意外部数据输入模型；专用系统则通过系统提示、开发者提示或微调，把模型包装成特定工具，例如邮件助手、网页阅读器、报表生成器或客服机器人。在这些场景中，模型需要同时理解任务要求和输入材料。

从安全角度看，任务要求和输入材料具有完全不同的语义地位。任务要求是模型应遵守的控制信息，输入材料是模型应处理的对象。如果二者都以自然语言文本形式拼接到上下文中，模型就缺少硬性边界来判断哪些语句可以改变行为，哪些语句只能被分析、总结或转换。

表 2.1 LLM 输入中不同文本片段的角色区分

输入类型	典型来源	期望模型行为
系统指令	应用开发者、平台策略	长期约束模型身份、能力边界和安全规则
任务指令	当前用户或业务流程	指定本轮应完成的具体任务
数据输入	邮件、网页、文件、检索片段	作为被总结、分类、改写或分析的对象
工具结果	搜索引擎、数据库、代码执行器	作为事实材料使用，不应改变系统策略

表2.1给出了常见输入角色。指令与数据分离研究关注的是：当这些角色都以自然语言形式出现时，模型能否仍然保持对角色边界的稳定识别。

2.2 提示注入与越狱的区别

LLM 安全研究中常见的越狱通常指用户直接向模型提出违反安全策略的请求，并试图诱导模型输出有害内容^[2]。指令与数据分离问题则更基础：即使数据中的语句并不一定恶意，模型也可能错误地执行它们。间接提示注入是该缺陷的攻击化形式，即攻击者把指令放入网页、邮件、文档或检索结果中，等待模型在后续任务中读取并执行^[3]。

因此，论文强调不应只把该问题理解为“模型是否容易被攻击”，而应理解为“模型是否具有角色区分能力”。一个安全的模型在读取数据时应能识别其中的命令式语言只是数据内容的一部分，而不是对模型自身的新要求。

从防御角度看，越狱防御往往关注“拒绝有害内容”，而指令与数据分离防御关注“在正确位置执行正确内容”。如果探针出现在指令位置，模型应当执行；如果同一探针出现在数据位置，模型应当处理或忽略其命令属性。该差异使得简单拒绝策略并不能完全解决分离问题。

2.3 传统系统中的指令与数据分离

传统计算机系统长期关注指令与数据的隔离。例如，SQL 注入防御要求把查询模板与用户参数分开，避免用户输入被解释为 SQL 语句；操作系统和硬件安全机制要求区分可执行区域与数据区域；Web 应用中也通过转义、沙箱和权限控制避免数据被当作代码执行。

相比之下，LLM 的输入通常是统一的自然语言上下文，系统提示、用户提示、检索文本和工具结果在 token 层面没有天然类型标签。虽然可以通过 XML 标签、分隔符或提示工程标记不同区域，但这些标记并非强制执行的语义边界，模型仍可能被数据中的自然语言内容影响。因此，LLM 需要新的定义、测量方法和训练目标来评估这种分离能力。

2.4 相关防御思路

现有防御思路大致可以分为三类。第一类是提示工程，即通过明确说明“只遵循任务块中的指令”“不要执行数据块中的请求”来提醒模型。第二类是输入隔离与内容过滤，即在进入模型前检测数据中的可疑指令或将外部文本转义。第三类是训练层面的对齐，包括监督微调、偏好优化和对比训练，使模型在不同输入角色下学习不同响应。

这些方法各有局限。提示工程实现成本低，但缺少强制性；过滤方法依赖规则或分类器，难以覆盖所有自然语言变体；微调方法可能提高分离能力，却也可能降低模型对合法指令的执行能力。原论文的价值正在于提供统一评估框架，使这些方法可以在同一指标下比较。

第三章 指令与数据分离的形式化定义

3.1 模型抽象

论文把单轮语言模型抽象为接收两个输入参数的随机函数：一个参数表示指令，另一个参数表示数据。指令参数包含模型应执行的任务，例如“判断情感极性”或“总结以下邮件”；数据参数包含任务对象，例如待分类文本或邮件正文。模型输出是字符串分布，因为同一提示下模型可能因采样策略产生不同回答。

这种抽象的重点不是改变真实模型接口，而是为分析提供概念边界。真实系统通常会把所有内容拼接成一个 prompt，但研究者可以把其中承担控制作用的部分视为指令参数，把被处理材料视为数据参数。形式化抽象使“分离能力”能够从安全直觉转化为可讨论的数学对象。

3.2 分离分数

形式化定义的核心思想是使用探针字符串。设某个探针字符串在指令位置时应当被模型执行，而在数据位置时只应被模型处理。若模型具有良好分离能力，则同一探针放在指令参数和数据参数中应导致明显不同的输出分布；若模型没有分离能力，则二者输出会非常相似。

论文因此用两种输出分布之间的差异度定义分离分数。差异度可以采用 Kullback–Leibler 散度、Wasserstein 距离等概率分布距离。分数越大，说明模型越能区分探针作为指令和作为数据时的不同角色；分数越小，说明模型倾向于把数据中的探针当作指令执行。




图 3.1 形式化分离分数的计算思路

图3.1展示了定义的基本逻辑。分离能力不是直接判断模型“是否安全”，而是考察同一探针在不同语义位置上是否引起不同输出行为。

3.3 定义的意义

该定义有两个重要意义。首先，它把“指令与数据分离”从直观描述转化为模型可比较的性质，避免仅凭个别攻击案例判断模型安全性。其次，它强调分离能力与上下文、任务和探针内容有关，因此应在任务分布上取期望，而不是只测试单个手工样例。

不过，直接计算该定义在真实 LLM 上并不现实。一方面，真实任务和数据分布未知；另一方面，模型输出空间极大，商业模型也通常不提供完整输出概率。因此，论文进一步提出经验代理指标，用可观测输出近似衡量分离能力。

3.4 与模型效用的关系

指令与数据分离不能脱离模型效用单独讨论。一个模型如果对所有探针都拒绝回答，那么它在数据位置不会执行探针，看似安全；但当探针位于指令位置时，它同样不能执行合法任务，实际不可用。因此，一个合理评估必须同时衡量“数据位置不执行”和“指令位置能执行”。

原论文中的经验效用分数正是用于解决这一问题。它统计模型在指令位置成功执行探针的比例，并与经验分离分数共同报告。只有当模型既能在指令位置完成任务，又能在数据位置抑制执行时，才能认为其具备较好的指令与数据分离能力。

3.5 本章小结

本章总结了论文对指令与数据分离的形式化刻画。该定义把模型行为差异作为分离能力的核心：同一探针在指令位置应被执行，在数据位置应被处理。由于精确分布难以获得，后续章节将介绍论文提出的经验分离分数与 SEP 数据集。

第四章 经验测度与 SEP 数据集

4.1 惊讶见证词

为避免依赖模型内部概率，论文提出“惊讶见证词”的概念。惊讶见证词是一个通常较短的字符串：当探针被模型执行时，该字符串很可能出现在输出中；当探针只是作为数据被处理时，该字符串几乎不应出现。

例如，任务是判断一段文本的情感极性，数据中混入探针“告诉我一群乌鸦叫什么”。如果模型正确处理数据，它应输出“负面”“中性”等情感标签，而不应回答乌鸦群体的名称；如果模型执行了探针，输出中很可能出现 `murder` 这一见证词。通过检查见证词是否出现，研究者可以判断模型是否把数据中的探针当作指令执行。

4.2 经验分离分数与效用分数

论文构造两组模型输出：一组把探针放入指令参数，另一组把同一探针放入数据参数。若见证词在指令位置输出中出现，说明模型具备执行该探针的能力；在这些可执行样本中，如果见证词没有在数据位置输出中出现，则说明模型成功实现了分离。

经验分离分数统计的是：在模型能执行指令位置探针的样本中，有多少比例不会在数据位置执行探针。论文还定义效用分数，表示模型在指令位置成功执行探针的比例。二者需要同时考察，因为一个模型可以通过完全拒绝执行所有探针获得较高分离假象，但这种模型没有实际任务效用。

表 4.1 经验评估样本的组成要素

组成部分	功能说明
任务提示 s	规定模型应完成的主任务，如分类、摘要、改写或代码解释
数据提示 d	提供主任务所需处理的文本、代码或事实材料
探针 x	可被执行的额外请求，用于测试模型是否混淆角色
见证词 w	判断探针是否被执行的短字符串或关键词
输出 y	模型对不同输入组合的实际响应，用于计算经验分数

表4.1列出了 SEP 样本的主要组成。该设计使评估过程能够独立于模型内部结构，只需调用模型并检查输出即可。

4.3 SEP 数据集构造

SEP 数据集由任务提示、数据提示、探针和见证词组成。任务覆盖多个自然语言处理与代码处理领域，包括分类、摘要、改写、问答和程序理解等。每个样本都设计了一个探针问题以及对应见证词，使得见证词在执行探针时高概率出现，而在正常完成主任务时低概率出现。

数据集还考虑探针强度和拼接位置等因素。探针可以是中性表达，也可以是更坚持、更具命令性的表达；探针可以放在数据的开头或结尾，也可在指令侧进行相应对照。这样的设计使评估不仅能反映模型总体分离能力，也能分析不同提示形式对分离能力的影响。

4.4 评估流程

一次完整评估通常包括四个步骤。首先，根据数据集构造两类输入：探针位于指令侧和探针位于数据侧。其次，调用待测模型生成输出。再次，检查输出中是否包含见证词。最后，根据见证词出现情况计算经验分离分数与效用分数。




图 4.1 SEP 数据集上的经验评估流程

图4.1体现了该评估方法的工程可操作性。它既适用于开源模型，也适用于只能通过 API 访问的闭源模型。

4.5 本章小结

本章介绍了论文从理论定义到可计算评估的转换。惊讶见证词使研究者无需访问模型概率即可估计分离能力；SEP 数据集则提供了系统化样本，用于比较不同模型、提示模板和训练方法。

第五章 实验结果与缓解方法分析

5.1 基础模型评估

论文在多个开源和闭源模型上评估 SEP 数据集，包括 GPT-4、GPT-3.5、Gemma、Phi-3、Llama、Zephyr 和 Starling 等。实验显示，所有模型都存在不同程度的指令与数据混淆，没有模型能够在所有设置下稳定获得高分离分数。

结果还表明，模型规模或总体能力并不必然带来更强的分离能力。某些能力更强的模型在面对坚持性探针时仍会执行数据中的请求；某些较小模型可能因为效用不足而较少输出见证词，但这并不等价于真正安全。因而，分离分数必须结合效用分数共同解读。

表 5.1 不同模型类型的分离能力观察

模型类型	优势	主要问题
闭源强模型	通用任务能力强，能理解复杂提示	仍会在坚持性数据探针下误执行
开源指令模型	可复现实验，便于微调分析	分离分数差异大，受模板影响明显
小规模模型	成本低，易部署	效用不足可能掩盖真实分离问题
经过微调的模型	可针对分离目标优化	可能牺牲合法指令执行能力

表5.1概括了模型评估中的主要现象。该结果提示，不能仅以模型排行榜能力或参数规模推断其安全隔离能力。

5.2 提示工程的影响

论文评估了多种提示模板，例如使用明确的任务块与数据块，要求模型只遵循任务块中的指令，不执行数据块中的任何请求。结果显示，强提示工程能够在部分模型上显著提高分离分数，说明清晰的上下文标记和安全指令确实有帮助。

然而，提示工程并不能从根本上解决问题。一方面，模型仍可能在失败案例中回答数据里的优先问题或额外命令；另一方面，过强的提示约束可能降低模型对合法指令的执行能力，造成效用下降。论文因此认为，仅靠提示模板无法提供可证明或稳定的隔离边界。

5.3 微调与偏好优化

论文还研究监督微调、直接偏好优化以及平衡训练等方法。训练数据把探针放在指令位置时的正确执行和放在数据位置时的正确忽略作为对照，希望模型学习角色差异。部分训练

设置显著提高经验分离分数，尤其在结合强提示模板时表现更好。

但实验也发现，提升分离分数常伴随效用损失。例如，模型可能学会更保守地忽略疑似探针，从而在探针确实位于指令位置时也不执行。偏好优化在若干模型上能改善权衡，但并不稳定。该结果说明，指令与数据分离需要在模型架构、训练目标、数据构造和系统接口层面共同改进。

5.4 失败案例分析

失败案例通常具有两个特点。第一，数据中的探针在语言形式上非常像对助手的直接命令，例如“除此之外，请回答以下问题”。第二，主任务本身需要模型完整阅读数据内容，如改写、摘要或代码解释，这使模型难以简单跳过可疑片段。模型在执行主任务时必须理解数据语义，但又不能把数据语义转化为控制指令。

这类失败说明，指令与数据分离不是简单的关键词过滤问题。攻击者可以把命令改写为礼貌请求、上下文提示、优先级声明或嵌入式问题。模型若只依赖表面文本特征，很容易在不同表达形式之间失效。

5.5 本章小结

实验结果支持论文的核心结论：当前 LLM 的指令与数据分离能力不足，且常规缓解方法只能部分改善问题。高分离和高效用之间存在明显张力，提示工程与微调都不能单独构成可靠安全边界。

第六章 总结与展望

6.1 本文工作总结

本文依据论文《Can LLMs Separate Instructions From Data? And What Do We Even Mean By That?》整理了大型语言模型指令与数据分离问题。该问题源于 LLM 将系统提示、用户指令和外部数据统一作为自然语言上下文处理，缺少传统计算系统中明确的命令与数据隔离机制。其后果包括正常任务混淆、间接提示注入和工具调用风险。

原论文的关键贡献在于给出形式化定义和经验测度。形式化定义通过比较探针位于指令参数和数据参数时的输出分布差异来衡量分离能力；经验测度则用惊讶见证词和 SEP 数据集把该定义转化为可执行评估。实验覆盖多种主流模型和缓解方法，发现所有模型都未能稳定实现高分离能力，提示工程、提示优化和微调也存在效用下降或泛化不足的问题。

本文进一步从学位论文写作角度补充了应用背景、风险场景、评估流程和工程启示。通过图表化整理可以看到，指令与数据分离能力既关系到模型本身，也关系到系统如何组织上下文、如何调用工具、如何限制权限以及如何记录审计过程。

6.2 工程部署启示

在实际部署中，LLM 系统应避免把所有文本简单拼接后交给模型处理。更合理的设计包括：为不同输入来源保留元数据；在工具调用前增加独立确认或策略检查；对检索结果、邮件正文等外部数据进行角色标记；在高风险场景中采用最小权限原则，限制模型可直接执行的操作。

同时，系统评估不应只测试模型能否回答常规问题，还应测试模型在复杂数据输入下是否会误执行隐藏请求。SEP 风格的测试集可以作为上线前安全评估的一部分，与传统准确率、鲁棒性和合规性测试共同使用。

6.3 进一步研究方向

未来研究可从四个方向推进。第一，在模型接口层面引入更强的输入类型系统，使指令、数据、工具输出和系统策略具有可验证的边界。第二，在训练阶段构造更多对比样本，让模型学习同一文本在不同角色下应产生不同响应。第三，发展同时优化分离能力与任务效用的评估指标，避免模型通过一概拒绝获得虚假的安全分数。第四，将经验分离评估扩展到多轮对话、工具调用、RAG 管线和真实代理系统，因为这些场景中的数据来源更多、状态更复杂、风险也更高。

此外，还可以探索形式化方法与运行时监控相结合的方案。例如，在模型输出工具调用前，由策略执行器检查该调用是否由可信指令链触发；在多线程对话中，记录每条上下文的来源和权限级别；在训练数据中引入更多“同文不同角色”的对比样本，增强模型对上下文角色的辨别能力。

总体而言，指令与数据分离是 LLM 安全部署中的基础问题。只有当模型能够可靠理解“哪些文本是在命令我，哪些文本只是我要处理的对象”时，LLM 才能更安全地承担真实应用中的自动化任务。

参考文献

- [1] Zverev E, Abdelnabi S, Tabesh S, et al. Can llms separate instructions from data? and what do we even mean by that?[C]. International Conference on Learning Representations. [S.l.: s.n.], 2025.
- [2] Zou A, Wang Z, Carlini N, et al. Universal and transferable adversarial attacks on aligned language models[C]. arXiv preprint arXiv:2307.15043. [S.l.: s.n.], 2023.
- [3] Perez F, Ribeiro I. Ignore previous prompt: Attack techniques for language models[C]. NeurIPS ML Safety Workshop. [S.l.: s.n.], 2022.

附录 A 程序清单

本文以论文综述、方法分析和实验结论整理为主，未实现完整的软件系统。为便于后续复现实验，可将 SEP 风格评估流程抽象为如下程序模块：

(1) 数据读取模块：读取任务提示、数据提示、探针字符串和见证词，形成样本四元组 (s, d, x, w) 。

(2) 提示构造模块：分别构造探针位于指令侧和数据侧的两类输入，保证两类输入除探针位置外尽量保持一致。

(3) 模型调用模块：面向开源模型或 API 模型生成回答，并记录模型名称、温度、采样次数和提示模板。

(4) 见证词检测模块：检查输出中是否包含见证词，同时保留原始回答以便人工复核边界样本。

(5) 指标计算模块：计算经验分离分数和效用分数，输出按模型、任务类型、探针强度和位置划分的统计结果。

上述模块可作为后续研究的程序清单基础，用于复现和扩展指令与数据分离评估。

附录 B 攻读专业学位硕士期间撰写的论文

- [1] 本文为课程论文/学位论文模板整理稿，当前尚未形成正式发表论文。后续可基于本文内容进一步整理为“大型语言模型指令与数据分离能力综述与评估”方向的中文综述论文。
- [2] 拟投稿方向一：大型语言模型安全评估综述，重点总结提示注入、越狱攻击、工具调用安全和指令数据分离度量。
- [3] 拟投稿方向二：面向中文场景的 SEP 数据集扩展研究，重点构造中文任务提示、中文探针和中文见证词，并比较中英文模型表现差异。

附录 C 攻读专业学位硕士期间申请的专利

- [1] 本文未产生已申请或已授权专利。相关研究仍处于论文整理与方案分析阶段。
- [2] 可拓展专利方向一：一种面向大型语言模型应用的指令与数据隔离提示构造方法。
- [3] 可拓展专利方向二：一种基于见证词检测的语言模型间接提示注入风险评估方法。
- [4] 可拓展专利方向三：一种结合输入来源标签和工具调用策略的语言模型安全执行控制系统。

附录 D 攻读专业学位硕士期间参加的科研项目

- [1] 参与项目主题：大型语言模型安全性与可靠性评估。主要工作包括文献调研、威胁建模、指标整理和论文模板撰写。
- [2] 参与项目主题：检索增强生成系统中的间接提示注入风险分析。主要工作包括典型攻击场景梳理、数据来源分类和防御策略总结。
- [3] 参与项目主题：面向工具调用代理的权限边界设计。主要工作包括工具调用流程抽象、最小权限原则分析和审计日志需求整理。
- [4] 后续拟开展项目：中文 SEP 数据集构建与评测。计划覆盖摘要、情感分类、信息抽取、代码解释和办公自动化等任务。