

■ 问题及研究背景：

- LLM训练流量强局部性（TP+SP占~97%），传统对称Clos与实际流量模式严重不匹配
- Clos大量依赖高基数交换机与光模块，带宽提升时成本同比暴增

■ 方案：nD-FullMesh + 统一总线（UB）

- nD-FullMesh：从1D板内全连接递归扩展至4D Pod，86.7%为短距无源电气线缆，大幅减少交换机与光模块
- 统一总线UB替代PCIe/NVLink/IB混合互连，支持灵活IO分配与硬件资源池化

■ 优缺点：

- 充分利用了LLM训练中固有的数据局部性和密集稀疏流量模式
- 开销少，跳数少
- 采用专为构建UB-Mesh设计的硬件模块，缺乏广泛部署可能





Figure 4: UB-Mesh's nD-FullMesh Topology and Possible Physical Mapping

■ 问题及研究背景：

- 长上下文、MoE、低精度计算等推理场景对互联拓扑和稀疏计算提出新要求
- 传统3D Torus跳数多，all-to-all通信延迟高，不适合推理场景

■ 方案：

- TPUv7 (Ironwood)：延续3D Torus + OCS光交换组网，64芯片构成一个cube，多cube通过OCS动态互联，支持灵活拓扑切片与故障绕行
- 强化SparseCore支持MoE稀疏计算，面向推理延迟与能效优化
- TPUv8拆分为训练版（8t）和推理版（8i），不再用同一芯片覆盖所有任务
- TPU8i引入Boardfly拓扑：局部高连接度小组 + OCS组间互联，最大跳数从16跳降至约7跳





■ 问题及研究背景：

- PCIe带宽远低于GPU算力增速，单节点多GPU训练时GPU间通信成为严重瓶颈
- LLM训练中张量并行、流水线并行需要GPU间频繁交换激活值与梯度，跨节点InfiniBand带宽不足
- 随模型规模扩大，节点内互联带宽不足导致GPU大量时间等待通信，算力严重浪费

■ 方案：

- NVLink以高速串行电气直连替代PCIe，绕过CPU直接实现GPU-GPU点对点通信，延迟更低、带宽更高
- 引入NVSwitch芯片：节点内所有GPU通过NVSwitch实现全互联（All-to-All），8 GPU间任意一对均可全带宽通信，消除拓扑瓶颈
- NVLink Network（跨节点）：通过NVLink Switch延伸至机柜级，最多576块GPU形成无损全互联域，带宽远超InfiniBand

■ 优缺点：

- GPU间通信延迟极低
- NVSwitch芯片额外增加系统成本与功耗



■ 问题及研究背景：

- 训练阶段辅助损失函数强制均衡专家负载；推理阶段完全由真实请求驱动，无强制均衡
- 热门专家负载是冷门的4 ~ 5.5倍，热点节点拥塞、冷点节点空转，产生严重木桶效应
- All-to-All同步通信阻塞GPU算力；跨节点IB带宽比NVLink慢约一个数量级，8节点时通信开销占推理总时间76%

■ 方案：时序调度 + 空间放置

- Aurora（时序调度）：基于流量矩阵识别瓶颈GPU，严格限制每个时间片内至多一个GPU向同一目标发送，从源头消除Incast
- ExFlow（专家放置）：利用层间专家亲和性，用两阶段整数规划优先让Token留在同GPU，其次同节点，坚决避免跨节点IB传输



■ 现有 AI 网络拓扑（逐步分化）

拓扑	定位	核心设计
NVLink / NVSwitch	训练	GPU 级高带宽全连接，张量并行优化
TPU v7 (3D Torus)	训推混合	3D Torus + ICI (同步通信优化)
TPU v8i (Boardfly)	推理专用	低时延 / 高 radix / 最大跳数降至 7
UB-Mesh	训练	带宽分层预设

■ AI 推理流量特征

- KV Cache 远程访问 + MoE 动态路由，流向不可预测
- Token-by-token 生成：细粒度、高频、小流
- 请求异步到达，强 burst；热门专家负载是冷门的 4 ~ 5.5×
- 强 tail latency 敏感：TTFT / TPOT / P99 直接影响用户体验

■ 核心不匹配

- 训练网络大流 · 同步 · 均匀分布 vs 推理小流 · 异步 · 极度倾斜
- 设计是吞吐优先 vs 推理应该时延优先
- 拓扑设计假设流量均匀 vs 推理存在链路热点
- 静态拓扑 vs KV/MoE 动态路由放大 hop 延迟