

AI赋能 IoT 网络流量安全检测

汇报人： 1025040936-杨广泽

课程名称： 无线网络安全

汇报日期： 2026年6月

汇报大纲 / CATALOG

01 研究背景与动机

02 现有研究情况

03 数据集与预处理

04 系统设计与核心算法

01

研究背景与动机

RESEARCH BACKGROUND & MOTIVATION


无线IoT设备的安全现状

随着物联网（IoT）的爆发式增长，无线安全已成为现代防御体系的短板：

- **攻击面扩大**：智能家居、工业传感器等设备广泛暴露在非受控无线环境中。
- **协议复杂性**：Wi-Fi, Bluetooth, ZigBee等协议共存，缺乏统一监控。
- **资源限制**：IoT端侧设备算力极低，难以部署重量级加密逻辑。



无线媒介的固有威胁



核心威胁点

无线信号的广播特性导致了以下安全问题：

- 嗅探 (Sniffing)：攻击者可利用Monitor模式捕获所有空中介质传输的数据包。
- 注入 (Injection)：攻击者可伪造解除认证帧 (De-auth) 实施DoS等攻击手段。
- 中间人 (MITM)：通过流氓AP劫持合法连接进行中转。

传统入侵检测系统的挑战



特征工程枯竭

面对不断演进的加密流量，手动提取的流量通讯特征已不足以刻画复杂攻击行为。



滞后的更新周期

基于规则（Signature-based）的系统无法应对零日（Zero-day）攻击，且规则库维护成本巨大。



解释性黑盒

传统机器学习模型虽能分类，但无法告诉安全分析师“为什么这是攻击”，导致处置延迟。


LLM在无线安全中的潜力

为什么选择大语言模型？

LLM在网络安全领域展现出独特的“逻辑推理”与“领域知识”融合能力：

- **零样本泛化**：利用预训练中包含的协议规范知识，识别未知威胁。
- **解释性输出**：输出分类结论的同时，提供逻辑化的攻击链分析。
- **语义对齐**：将抽象的流量数值转化为可读的自然语言描述。

这些能力是LLM天然具有，因为LLM的训练过程会“吸纳”大量的知识库，这些不但包括安全领域的知识，还包括其他领域的知识，如逻辑学等。这些潜空间对威胁检测非常有利



02

现有研究情况

RELATED WORK REVIEW

传统的 NIDS 研究

年份	方法/论文	核心贡献	局限性
2018	Kitsune (NDSS)	基于Autoencoder的集成异常检测	计算开销大，对流量突发敏感
2022	Euler (NDSS)	基于图嵌入的流量模式发现	严重依赖精确的图构造逻辑
2020	IoTID20 Dataset	提出了47个维度的流特征提取方案	缺乏对LLM语义的支持

* 传统方法侧重于统计概率，忽略了协议语义本身。

代表文献展示:

标题: A Machine Learning Approach for IoT Device Identification

- **核心:** 基于流量分析进行细粒度设备指纹识别。
- **价值:** 实现未授权设备接入的即时感知。
- **不足:** 对加密通道内的攻击负载识别度有限。

标题: Network-Based Detection of IoT Botnet Attacks Using Deep Autoencoders

- **方法:** 利用深度自编码器提取正常行为快照。
- **贡献:** 首次验证了非监督学习在僵尸网络 (Mirai) 检测中的极速响应能力。
- **局限:** 计算开销随设备数量线性增长。

LLM 在安全领域的应用进展

代表性工作

- Mimicry (NDSS 2023): 探讨了LLM识别恶意Payload的能力。
- Flash (IEEE S&P 2024): 提出了跨层流量语义建模框架。
- SecBERT: 针对安全语料微调的小规模模型。

现有研究多集中在代码审计或日志分析，针对底层二进制流量（PCAP）的端到端LLM检测仍处于探索阶段。

03


数据集与预处理

DATASET & PRE-PROCESSING

IOT NETWORK INTRUSION DATASET

由 HCRL (Honeynet Project Korea) 发布，针对典型无线 IoT 环境的入侵网络流量数据集：

- 设备构成：SKT NUGU (智能音箱), EZVIZ 摄像头等。
- 采集方式：使用无线网卡 **Monitor模式** 在 2.4GHz 频段全流量捕获。
- 核心价值：包含真实的无线链路层信息（如802.11帧头）。



Time	Source	Destination	Protocol	Length	Info
0.000000000	10.0.200.13	10.0.200.10	TLSv1.2	4184	Application Data
0.000272418	10.0.200.13	10.0.200.10	TLSv1.2	5157	Application Data
0.000471676	10.0.200.10	10.0.200.13	TCP	66	9200 → 34102 [ACK]
0.001037597	10.0.200.10	10.0.200.13	TCP	66	9200 → 34102 [ACK]
0.0022532803	10.0.200.10	10.0.200.13	TLSv1.2	1838	Application Data
0.0022574536	10.0.200.13	10.0.200.10	TCP	66	34102 → 9200 [ACK]
0.006091383	10.0.200.13	10.0.200.10	TLSv1.2	4184	Application Data
0.006631444	10.0.200.13	10.0.200.10	TCP	7306	37732 → 9200 [PSH, ...]
0.006656467	10.0.200.10	10.0.200.13	TCP	66	9200 → 37732 [ACK]
0.006704097	10.0.200.13	10.0.200.10	TLSv1.2	5342	Application Data
0.007294428	10.0.200.10	10.0.200.13	TCP	66	9200 → 37732 [ACK]
0.021930926	10.0.200.13	10.0.200.10	TLSv1.2	4184	Application Data
0.022156864	10.0.200.13	10.0.200.10	TLSv1.2	2645	Application Data
0.022300132	10.0.200.10	10.0.200.13	TCP	66	9200 → 55932 [ACK]
0.022300382	10.0.200.10	10.0.200.13	TCP	66	9200 → 55932 [ACK]
0.022964776	10.0.200.13	10.0.200.10	TLSv1.2	4184	Application Data
0.023108029	10.0.200.13	10.0.200.10	TLSv1.2	6622	Application Data
0.023204513	10.0.200.10	10.0.200.13	TCP	66	9200 → 55936 [ACK]
0.023321576	10.0.200.10	10.0.200.13	TCP	66	9200 → 55936 [ACK]
0.037851063	10.0.200.10	10.0.200.13	TLSv1.2	3301	Application Data
0.037941810	10.0.200.13	10.0.200.10	TCP	66	37732 → 9200 [ACK]
0.042515006	10.0.200.10	10.0.200.13	TLSv1.2	1246	Application Data
0.042537266	10.0.200.13	10.0.200.10	TCP	66	55932 → 9200 [ACK]

数据集攻击类型统计

Normal (正常 IoT 设备流量)

58.82%

Botnet (僵尸网络攻击)

34.76%

MitM (中间人攻击)

3.41%

DoS (拒绝服务攻击)

2.16%

Reconnaissance
(网络侦察与扫描)

0.84%


攻击细节举例：包含目标为智能音箱的 8008 端口的UDP/TCP Flood。流量表现为极端高频率的小包发送。

04

系统设计与核心算法

SYSTEM ARCHITECTURE & METHODOLOGY

系统核心逻辑流



Step 1: 流量预处理

Step 2: 提示词注入与分析

Step 3: 结果提取与解析

基于 SCAPY 的流量解析引擎

针对 PCAP 格式，我们实现了端到端的解析器：

- 物理层映射：解析 RadioTap 头部中的信号强度 (RSSI)。
- 链路层审计：提取 802.11 帧控制字段
(Management/Control/Data) 。
- 传输层特征：识别 TCP 标志位组合 (SYN-FIN, PSH-ACK) 、载荷的统计特征

使用scapy对流量的处理规则是：剔除网络层数据包；按照（目标IP、源IP、目标端口、源端口、协议）五元组划分流量；剔除TCP流量握手包、挥手包、纯确认包（有的确认包可能会携带数据）；提取流的统计特征



统计特征与语义转换


核心特征组 (Top 10)

类别	特征项	对检测的贡献
负载特征	包长均值/方差/信息熵/包大小序列	区分洪水攻击 (小包) 与正常流 (变长)
时域特征	包间间隔序列	识别高频率拒绝服务行为
协议特征	TCP or UDP	攻击往往采用TCP
标识特征	IP、端口	能够唯一标识流量的“身份”特征

特征细节：包长一致性分析

在僵尸网络攻击中，攻击工具通常为了提高效率发送固定长度的填充包。

我们的解析器会自动计算 **Packet Length Variance**。若方差接近 0 且均值极小（如 54-60 bytes），则系统会向 LLM 标记为“高度疑似自动化注入”。



特征细节：包间隔 (IAT) 推理

IAT: Inter-arrival Time

正常 IoT 设备通常有固定的心跳脉冲或随机的交互流。而 **UDP Flooding** 表现为极其短促且恒定的包间隔 ($IAT < 0.0001s$)。

我们将此数值量化为 “Burst Intensity” 级别，供 LLM 判定攻击强度。

PROMPT 工程：角色与知识注入



角色设定

“你是一位精通 802.11 协议的安全专家，拥有 10 年入侵溯源经验。”



约束指令

“必须基于提供的数据特征进行逻辑推导，禁止臆造数据，输出必须包含攻击类型与可信度。”

核心提示词模版设计

[System] 你是无线安全审计系统。 [Context] 下面是来自 IoT 监控模式捕获的流量汇总特征： - 协议比例：TCP 99%，UDP 1% - PPS: {pps_value} - 平均包长：{avg_len} - 目标端口分布：{port_dist} [Task] 识别攻击类别并简述理由。

LLM 的思维链 (COT) 处理

推理路径

- 1 从五元组中推理元数据，如关联端口信息 (8008 为音箱控制端口)。
2. 学习良性流量的分布
3. 学习不同类型的恶意流量分布
4. 遍历待检测流量的统计特征，计算分布与阈值对比
5. 确定检测结果，若为恶意流量给出恶意类型

通过引导 LLM 使用“思考再回答”的模式，可以显著降低虚假正例（False Positive）率，因为它会主动质疑异常数据的业务合理性。

输出结果的结构化提取

模型输出并非纯文本，而是包含标签的 **JSON 格式**，以便后端自动化响应：

```
{ "prediction": "Malicious", "attack_type": "TCP SYN Flood", "confidence": 0.98, "reasoning": "Detected extreme PPS and 100% SYN flags directed at port 80..." }
```

对于模型输出的结果，预期包含的内容有：是否遭受攻击？何种类型的攻击？该条流量的基本信息是什么？

Q & A

感谢各位老师和同学的聆听！