



南京邮电大学
Nanjing University of Posts and Telecommunications




多媒体认知计算实验室
Multimedia Cognitive Computing lab(MCC)

生成式推荐-调研

汇 报 人： 杨 智 翔

年 级： 研 一

研究动机——为什么需要生成式推荐？



问题1：语义理解能力有限

问题2：性能达到瓶颈


问题3：依赖固定候选集

问题4：Pipeline割裂


检索-排序范式将推荐作为一个匹配问题，而不是生成问题来解决。

研究动机——为什么需要生成式推荐？


语义理解能力有限




VS




性能达到瓶颈




VS




依赖固定候选集




VS



Pipeline割裂



VS



什么是生成式模型？

“生成式模型，会学习数据的底层分布，并从中生成新的数据。”

海量文本

规律、结构
语法、逻辑

续写、创作、问答



Learning

$$p_{\theta}(x)$$

Generating




Training data $\sim p_{\text{data}}(x)$


Data generation
distribution

New samples

什么是生成式推荐？



匹配式推荐范式：其核心目标在于学习有效的**用户-项目匹配函数**



生成式推荐范式：**直接生成**满足用户信息需求的目标文档或项目，而非仅为候选项目打分排序

什么是生成式推荐？

将推荐问题建模为序列生成问题


推荐列表视为序列：

$$[I_1, I_2, \dots, I_k]$$

建模其生成概率：

$$P(I_1, I_2, \dots, I_k | user, context)$$

交互历史，用户query



本质上，生成式推荐将“推荐问题”转化为“下一个item预测问题”，与大语言模型中的“下一个词预测”思想一致，抛弃了传统模型对候选集进行排序的方式。

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.

目前综述的主流视角——Tokenization视角

生成式推荐在发展中所要面临的**核心问题**：
Item 到底该如何被 Tokenization?

线路一：离散ID表示item（偏向传统）

线路二：基于文本表示item（LLM）

线路三：基于语义ID表示item（前沿主线）

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.

线路一：离散ID表示item（偏向传统）

GRU4Rec(ICLR'2016)：将RNN和GRU引入推荐系统，将推荐任务从传统的向量匹配转向了序列预测。

SASRec(ICDM'2018)：将RNN替换为Self-attention架构，对用户序列引入相关性建模，相较RNN更加高效。

Bert4Rec(CIKM'2019)：在序列推荐中引入Encoder-only架构，采用双向注意力机制，完成对推荐物品的预测。

HSTU(ICML'2024 Meta)：完成了工业级别的序列推荐预测任务，验证了生成式推荐的scaling law，试图重构“召回-排序”

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.

线路一：离散ID表示item（偏向传统）

GenRank(Arxiv'2025 XiaoHS): 对HSTU的架构进行更新, 将item信息直接作为特征融入action, 序列中仅含action, 目标是提升训练效率和推理速度, 但也属于单流机制。

DFGR(CIKM'2025 Meituan): 对HSTU的架构进一步更新, 目标也是提升训练效率和推理速度, 采用了双流机制, 含action的和不含action的, 相较GenRank的结构更复杂。

LUM(WSDM'2026 Alibaba): “保守的革命派”, 没有抛弃传统的DLRM范式, 将GR范式与DLRM结合。其中GR范式负责为DLRM作特征增强, DLRM负责完成推荐任务。

MTGR(CIKM'2025 Meituan): 本质上是HSTU+传统DLRM范式的结合, 不同于HSTU的是, 它保留了用户和项目的交叉特征, 将他们直接组织成了token。

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.

线路二：基于文本表示item (LLM)

P5(RecSys'2022)/M6-Rec(Arxiv'2022): 尝试推荐任务语言化, 把用户、物品、行为、任务都转成文本, 将推荐任务框定在 text-to-text 的研究中。

GPT4Rec(Arxiv'2023)/LLaRA(SIGIR'2024): GPT4Rec主要对标的是传统范式, 受搜索引擎启发, 旨在用LLM模型构建item的查询, 增强检索。LLaRA是传统范式加文本生成范式的结合。

HLLM(Arxiv'2024 ByteDance): 使用LLM模型, 构建了一套生成项目与用户表征的方案。该方案可以用在生成范式, 也可用在判别范式。

Rec-R1(TMLR'2025)/RecFound(Arxiv'2025): RecR1引入强化学习, 使生成结果直接对标Recall和NDCG指标。RecFound旨在构造通用基础的推荐模型, 并构建了新数据集。

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.

线路三：基于语义ID表示item（前沿主线）

TIGER(NIPS'2023): 把推荐任务从score-based prediction 改成了token generation, 奠定了基于语义ID的生成式推荐范式。

LMIndexer(Arxiv'2023)/LC-Rec(ICDE'2024): 优化生成式推荐的tokenization, 尝试解决语义冲突的问题, 尝试强化项目语义。

LETTER(CIKM'2024): 把 LLM 擅长的文本语言语义和推荐系统依赖的协作语义统一到同一个生成式推荐框架中。

ETEGRec(Arxiv'2024): 提出端到端生成式推荐框架, 把item tokenizer和generative recommender统一到同一个训练过程中。

生成式推荐的发展概况




Figure 3. The evolution of tokenizer paradigms, showing the transition from sparse ID-based and text-based models toward semantic ID approaches, with affiliations noted beside each work.


线路三：基于语义ID表示item（前沿主线）

OneRec(Arxiv'2025 Kuaishou): 把端到端的SID-based generative recommendation推向了工业系统。

OneRec 之后，OneSearch、OneLoc、RPG、BBQRec、MMQ、MMESID等方法框架。开始向更广义的生成式检索与生成式搜索扩展。

MMESID、MMQ 等方法框架，继续研究如何将具有语义的SID和多模态Embedding结合起来，生成式推荐向多模态理解发展。


1



Recommender Systems with Generative Retrieval (NIPS' 2023 Google)

- 首次将推荐问题建模为“序列到序列”问题。
- 提出生成式检索，用Transformer decoder生成语义ID
- 奠定生成式推荐范式。

2



Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations (ICML' 2024 Meta)

- 首个万亿参数的生成式推荐系统。
- 尝试完整统一生成式推荐范式，即检索+排序。
- 验证了生成式推荐符合Scaling Law。

TIGER: Recommender Systems with Generative Retrieval (NIPS'2023)

Recommender Systems with Generative Retrieval

Shaohank Rajpur [*] University of Wisconsin-Madison	Nikhil Mehta [*] Google DeepMind	Anima Singh Google DeepMind
Raghunandan Keshavan Google	Trung Vu Google	Lukasz Heldt Google
Yi Tay Google DeepMind	Vinh Q. Tran Google	Janah Samost Google DeepMind
Ed H. Chi Google DeepMind	Maheswaran Sathiamoorthy Google DeepMind	

研究动机:


- 受到Transformer架构的启发, 将推荐范式向生成式推进, 解决传统推荐范式中的局限。
- 生成式技术的发展, 直接推动当时在推荐领域上关于生成式的研究。

挑战:

- 如何合理地将原始的推荐问题建模成生成式问题。
- 由于目标是生成Item ID, 首要任务是将Item ID变得有语义且可学习。
- 由于Item数量是庞大的, 需要重构一个有效的检索机制。

解决方案/创新:

- 提出全新推荐框架TIGER(Transformer Index for GEnerative Recommenders), 把推荐任务建模为“序列生成问题”, 直接生成下一个item的ID。
- 抛弃传统的ANN索引机制, 采取生成式的方式完成推荐。



TIGER的整体方法框架





Figure 2: An overview of the modeling approach used in TIGER.

(a)生成项目语义ID：原始的项目ID是一种随机数，本身只有索引意义。但生成式推荐需要以项目ID作为token，因此需要把项目ID变成有语义的token。

(b)预测生成下一token：以用户历史序列作为输入，输出下一个token，由一组token解码为item。本质上就是Seq2Seq模型，完成序列预测任务。

TIGER的整体方法框架



输入项目信息：
原ID，标题，类目……


编码为
Embedding
使用senten-T5或BERT

RQ-VAE目标：量化生成Item的语义ID

过程：迭代式生成多层级Token，不断匹配并更新码本

特点：每个Item由“一组”token表示，相似Item共享高层token

TIGER的整体方法框架



(1) 利用 item 内容特征，经文本编码器与RQ-VAE 量化，生成离散的层次化Semantic ID


(2) 将用户历史交互item转换为Semantic ID token 序列，并训练Seq2Seq Transformer

(3) 推理阶段，模型根据用户历史 Semantic ID序列，自回归生成下一 item 的 Semantic ID token 序列


(4) 将生成的Semantic ID查找表匹配，得到最终推荐item

讨论：语义冲突与项目不存在

生成语义ID时，发现：



分配一项额外token以标识：



[12, 24, 52]




推荐语料总表

主实验：性能对比



Table 1: Performance comparison on sequential recommendation. The last row depicts % improvement with TIGER relative to the best baseline. Bold (underline) are used to denote the best (second-best) metric.

Methods	Sports and Outdoors				Beauty				Toys and Games			
	Recall @5	NDCG @5	Recall @10	NDCG @10	Recall @5	NDCG @5	Recall @10	NDCG @10	Recall @5	NDCG @5	Recall @10	NDCG @10
P5 [8]	0.0061	0.0041	0.0095	0.0052	0.0163	0.0107	0.0254	0.0136	0.0070	0.0050	0.0121	0.0066
Caser [33]	0.0116	0.0072	0.0194	0.0097	0.0205	0.0131	0.0347	0.0176	0.0166	0.0107	0.0270	0.0141
HGN [25]	0.0189	0.0120	0.0313	0.0159	0.0325	0.0206	0.0512	0.0266	0.0321	0.0221	0.0497	0.0277
GRU4Rec [11]	0.0129	0.0086	0.0204	0.0110	0.0164	0.0099	0.0283	0.0137	0.0097	0.0059	0.0176	0.0084
BERT4Rec [32]	0.0115	0.0075	0.0191	0.0099	0.0203	0.0124	0.0347	0.0170	0.0116	0.0071	0.0203	0.0099
FDSA [42]	0.0182	0.0122	0.0288	0.0156	0.0267	0.0163	0.0407	0.0208	0.0228	0.0140	0.0381	0.0189
SASRec [17]	0.0233	0.0154	0.0350	0.0192	0.0387	<u>0.0249</u>	0.0605	0.0318	<u>0.0463</u>	<u>0.0306</u>	0.0675	0.0374
S ³ -Rec [44]	<u>0.0251</u>	<u>0.0161</u>	<u>0.0385</u>	<u>0.0204</u>	<u>0.0387</u>	0.0244	<u>0.0647</u>	<u>0.0327</u>	0.0443	0.0294	<u>0.0700</u>	<u>0.0376</u>
TIGER [Ours]	0.0264	0.0181	0.0400	0.0225	0.0454	0.0321	0.0648	0.0384	0.0521	0.0371	0.0712	0.0432
	+5.22%	+12.55%	+3.90%	+10.29%	+17.31%	+29.04%	+0.15%	+17.43%	+12.53%	+21.24%	+1.71%	+14.97%



层次语义实验



(a) The ground-truth category distribution for all the items in the dataset colored by the value of the first codeword c_1 .




(b) The category distributions for items having the Semantic ID as $(c_1, *, *)$, where $c_1 \in \{1, 2, 3, 4\}$. The categories are color-coded based on the second semantic token c_2 .



HSTU: Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations(ICML'2024 Meta)

Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations

Jiaqi Zhai¹ Lucy Liao¹ Xing Liu¹ Yueming Wang¹ Rui Li¹
Xuan Cao¹ Leon Gao¹ Zhaojie Gong¹ Fangda Gu¹ Michael He¹ Yinghai Lu¹ Yu Shi¹



研究动机:

- 为了让推荐系统从传统 DLRM 范式转向GR范式, 设计可用于工业级别的核心序列建模模块。
- 解决传统DLRM范式中的工业局限性。

挑战:


- 特征杂: 推荐系统有item、action、creator、demographic、counter、ratio等大量异构特征。
- 字典大: 推荐中的 item/content 每分钟都在新增, 候选空间极大且不断变化。
- 计算难: 用户行为序列极长, 计算成本极高。

解决方案/创新:

- 把传统的 ranking 和 retrieval都重构为序列转导任务。
- 把异构特征统一成行为时间序列。
- HSTU 用统一模块替代 DLRM 的多模块堆叠。

HSTU如何解决特征杂

DLRM



HSTU

Figure 2. Comparison of features and training procedures: DLRMs vs GRs. E, F, G, H denote categorical features. Φ_i represents the i -th item in the merged main time series. $\Psi_k(t_j)$ denotes training example k emitted at time t_j . Full notations can be found in Appendix A.

对于推荐系统而言，每个item都具备多种类目特征和数值特征，且都是异构特征。DLRM处理它们需要分别采用特定的网络结构来处理；而HSTU将它们**压缩合并**为一条**按时间顺序**的长序列。对于数值特征，HSTU采用额外的序列模型去学习，抛弃原来已有的数值特性。

HSTU整体推理框架




Figure 3. Comparison of key model components: DLRMs vs GRs. The complete DLRM setup (Mudigere et al., 2022) is shown on the left side and a simplified HSTU is shown on the right.

表示变换: HSTU不再需要特定的网络结构, 而是将所有特征展开成了一条基于时间的用户历史序列。

特征交互: HSTU不再需要特定的网络结构, 而是将所有特征展开成了一条基于时间的用户历史序列。

特征提取: HSTU不再需要特定的网络结构, 而是将所有特征展开成了一条基于时间的用户历史序列。

HSTU整体推理框架




Figure 8. Comparison of traditional sequential recommenders (left) and Generative Recommenders (right). We illustrate sequential recommenders in causal autoregressive settings and GRs without contextual features to facilitate comparison. On the left hand side, the action types a_i s are either ignored or combined with item information Φ_i s using MLPs, before going into self-attention blocks.

Retrieval阶段：输入交互过的item，输出候选item

Ranking阶段：输入历史交互与候选item，输出对候选item的预测交互

主实验：性能对比

Table 4. Evaluations of methods on public datasets in multi-pass, full-shuffle settings.

	Method	HR@10	HR@50	HR@200	NDCG@10	NDCG@200
ML-1M	SASRec (2023)	.2853	.5474	.7528	.1603	.2498
	HSTU	.3097 (+8.6%)	.5754 (+5.1%)	.7716 (+2.5%)	.1720 (+7.3%)	.2606 (+4.3%)
	HSTU-large	.3294 (+15.5%)	.5935 (+8.4%)	.7839 (+4.1%)	.1893 (+18.1%)	.2771 (+10.9%)
ML-20M	SASRec (2023)	.2906	.5499	.7655	.1621	.2521
	HSTU	.3252 (+11.9%)	.5885 (+7.0%)	.7943 (+3.8%)	.1878 (+15.9%)	.2774 (+10.0%)
	HSTU-large	.3567 (+22.8%)	.6149 (+11.8%)	.8076 (+5.5%)	.2106 (+30.0%)	.2971 (+17.9%)
Books	SASRec (2023)	.0292	.0729	.1400	.0156	.0350
	HSTU	.0404 (+38.4%)	.0943 (+29.5%)	.1710 (+22.1%)	.0219 (+40.6%)	.0450 (+28.6%)
	HSTU-large	.0469 (+60.6%)	.1066 (+46.2%)	.1876 (+33.9%)	.0257 (+65.8%)	.0508 (+45.1%)

实验结论：相较传统方法大幅提升了性能

消融实验

Architecture	Retrieval log pplx.	Ranking (NE)	
		E-Task	C-Task
Transformers	4.069	NaN	NaN
HSTU (-rab ^{p,t} , Softmax)	4.024	.5067	.7931
HSTU (-rab ^{p,t})	4.021	.4980	.7860
Transformer++	4.015	.4945	.7822
HSTU (original rab)	4.029	.4941	.7817
HSTU	3.978	.4937	.7805



Log pplx: 预测困惑度, 模型预测下一个用户可能正向交互内容”的难度

E-task: 互动行为任务, 计算NE交叉熵

C-task: 消费行为任务, 计算NE交叉熵


实验结论: HSTU并不仅是照搬Transformer, 而是需要适配推荐场景的注意力机制与调整

缩放定律实验



实验结论：HSTU证明了生成式推荐也可受益于LLM领域中的缩放定律


1



MMQ: Multimodal Mixture-of-Quantization Tokenization for Semantic ID Generation and User Behavioral Adaptation(WSDM' 2026)

- 尝试提出优化项目语义ID生成质量的方案。
- 在多模态场景下深入生成式推荐。
- 提出语义ID与推荐目标存在鸿沟的解决方案。

2



Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems(AAAI' 2026)

- 首个万亿参数的生成式推荐系统。
- 尝试完整统一生成式推荐范式，即检索+排序。
- 验证了生成式推荐符合Scaling Law.

MMQ: Multimodal Mixture-of-Quantization Tokenization for Semantic ID Generation and User Behavioral Adaptation(WSDM'2026)

MMQ: Multimodal Mixture-of-Quantization Tokenization for Semantic ID Generation and User Behavioral Adaptation

Yi Xu xy397404@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China	Moyu Zhang zhangmoyu.zmy@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China	Chenxuan Li 2301210279@stu.pku.edu.cn Peking University Beijing, China
Zhihao Liao lianzhiliao@buaa.edu.cn Beijing University of Aeronautics and Astronautics Beijing, China	Haibo Xing xinghaibo.xhb@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China	Hao Deng denghao.deng@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China
Jinxin Hu* jinxin.hjx@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China	Yu Zhang danji@alibaba-inc.com Alibaba International Digital Commerce Group Beijing, China	Xiaoyi Zeng yuanhan@taobao.com Alibaba International Digital Commerce Group Hangzhou, China
	Jing Zhang jingzhang.cv@gmail.com Wuhan University, School of Computer Science Wuhan, China	

研究动机:


- MMQ想解决生成式推荐中 Semantic ID的质量问题，如何让 item token既保留**多模态**语义，又能适配真实用户行为。

挑战:


- 多模态语义中，“共享信息”和“独特信息”难以同时保留。
- Semantic ID 与用户行为目标之间存在目标不一致的问题。

解决方案/创新:

- 把传统的 ranking 和 retrieval都重构为序列转导任务。
- 把异构特征统一成行为时间序列。
- HSTU 用统一模块替代 DLRM 的多模块堆叠。




MMQ整体推理框架



第一阶段目标：从文本和图像中生成高质量Semantic ID，同时保留跨模态协同信息和模态独特信息。

第二阶段目标：让tokenizer不再只是语义预训练模块，而可以被下游推荐目标修正。


MMQ整体推理框架



第一阶段目标：从文本和图像中生成高质量Semantic ID，同时保留跨模态协同信息和模态独特信息。

输入：文本和图像的Embedding
分别进入不同的专家模块—提纯
最后根据权重将所有的输出 z 合并为一个 Z
输出：含有跨模态语义信息的表示向量 Z
后面用于查表，得出SID

MMQ整体推理框架



第二阶段目标：让tokenizer不再只是语义预训练模块，而可以被下游推荐目标修正。

输入：上一阶段的表示 z
与codebook中的向量计算余弦相似度生成soft index，即匹配码本的概率分布生成hard index，即明确选择码本的索引
soft index用于下游计算loss后回传
hard index前向传播给下游
输出：最终的SID，并运用于下游

主实验：性能对比

(a) Discriminative Ranking Evaluation


Methods	Industrial Dataset					Amazon Beauty				
	$L_{recon} \downarrow$	Entropy $\uparrow$	Util. $\uparrow$	AUC $\uparrow$	GAUC $\uparrow$	$L_{recon} \downarrow$	Entropy $\uparrow$	Util. $\uparrow$	AUC $\uparrow$	GAUC $\uparrow$
PPNet	-	-	-	0.7144	0.6034	-	-	-	0.6455	0.5897
MA-RQ-VAE	0.6165	7.1178	0.79	0.7169	0.6064	<u>0.6028</u>	3.4904	0.99	<u>0.6466</u>	0.5952
MA-RQ-kmeans	0.6759	<u>7.7933</u>	<u>1.00</u>	0.7170	0.6056	0.6240	1.7100	<u>1.00</u>	0.6472	0.5999
MA-OPQ	0.6730	5.3092	0.33	0.7149	0.6046	0.9647	3.3980	0.96	0.6469	0.5998
MS-RQ-VAE	<u>0.5547</u>	6.3389	0.99	0.7171	0.6067	1.1001	3.8375	<u>1.00</u>	0.6473	0.5971
MS-RQ-kmeans	0.6848	7.5962	<u>1.00</u>	<u>0.7181</u>	<u>0.6076</u>	1.1547	<u>4.1603</u>	<u>1.00</u>	<u>0.6480</u>	<u>0.6001</u>
MS-OPQ	0.5678	5.2789	0.30	0.7177	0.6071	0.9801	3.3308	0.95	<u>0.6481</u>	0.5995
MMQ (Ours)	0.5529	7.9560	1.00	0.7184	0.6081	0.4470	4.4206	1.00	0.6503	0.6020
Improv.	+0.32%	+2.08%	+0.00%	+0.04%	+0.07%	+25.84%	+6.25%	+0.00%	+0.33%	+0.31%

(b) Generative Retrieval Evaluation


Methods	Industrial Dataset							Amazon Beauty						
	$L_{recon} \downarrow$	Entropy $\uparrow$	Util. $\uparrow$	R@5 $\uparrow$	R@10 $\uparrow$	N@5 $\uparrow$	N@10 $\uparrow$	$L_{recon} \downarrow$	Entropy $\uparrow$	Util. $\uparrow$	R@5 $\uparrow$	R@10 $\uparrow$	N@5 $\uparrow$	N@10 $\uparrow$
MA-RQ-VAE	0.6165	7.1178	0.79	0.0570	0.0754	0.1362	0.1621	<u>0.6028</u>	3.4904	0.99	0.0343	0.0477	0.0236	0.0292
MA-RQ-kmeans	0.6759	<u>7.7933</u>	<u>1.00</u>	0.0488	0.0522	0.1339	0.1388	0.6240	1.7100	<u>1.00</u>	0.0344	0.0467	0.0242	0.0294
MA-OPQ	0.6730	5.3092	0.33	0.0223	0.0264	0.0561	0.0619	0.9647	3.3980	0.96	0.0324	0.0407	0.0218	0.0250
MS-RQ-VAE	<u>0.5547</u>	6.3389	0.99	<u>0.0779</u>	<u>0.0988</u>	0.1897	0.2191	1.1001	3.8375	<u>1.00</u>	0.0274	0.0399	0.0188	0.0241
MS-RQ-kmeans	0.6848	7.5962	<u>1.00</u>	0.0497	0.0534	0.1359	0.1411	1.1547	<u>4.1603</u>	<u>1.00</u>	<u>0.0413</u>	<u>0.0549</u>	<u>0.0293</u>	<u>0.0349</u>
MS-OPQ	0.5678	5.2789	0.30	0.0757	0.0927	0.1866	0.2105	0.9801	3.3308	0.95	0.0411	0.0517	0.0280	0.0322
MMQ (Ours)	0.5529	7.9560	1.00	0.1034	0.1192	0.2661	0.2883	0.4470	4.4206	1.00	0.0455	0.0675	0.0296	0.0384
Improv.	+0.32%	+2.08%	+0.00%	+32.73%	+20.64%	+40.27%	+31.58%	+25.84%	+6.25%	+0.00%	+10.16%	+22.95%	+1.02%	+10.02%

实验结论：MMQ在生成式范式中性能效果提升最佳

语义ID有效性实验



(a) Comparison on Modality-Separated (MS) paradigms.



(b) Comparison on Modality-Aligned (MA) paradigms.

实验结论：语义ID能够有效恢复长尾数据的推荐效益，且MMQ模型展现了良好性能

IDSS: Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems(AAAI'2026)


Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems

Dat Tran¹, Yongce Li¹, Hannah Clay¹, Negin Golrezaei², Sajjad Beygi³, Amin Saberi¹

¹Stanford University

²Massachusetts Institute of Technology

³Amazon



研究动机:

- 电商平台场景中，用户对推荐系统的查询常常是模糊的、不完整的或弱指定的。当用户意图模糊时，推荐 Agent 如何主动提问、控制交互成本，并把不确定性传递到排序与结果展示中

挑战:

- 用户偏好不完整，用户在查询时的信息总是模糊的
- 系统不能一直追问。如果推荐系统不停问问题，会导致用户厌烦。

解决方案/创新:

- 有 conversational recommendation 往往把提问、排序、展示看成独立模块，而这篇论文认为它们都应该围绕同一个核心信号来设计：用户偏好的不确定性。

用信息熵来建模用户的不确定偏好

Entropy Computation Let $\mathcal{C}$ denote the candidate set retrieved using current filters $\mathcal{F}$. Let $\mathcal{D}$ be the set of all attribute dimensions. For each dimension $d \in \mathcal{D}$, we compute Shannon entropy (Shannon 1948):

$$H(d) = - \sum_{v \in \text{Val}(d)} p(v) \log_2 p(v) \quad (2)$$

where $\text{Val}(d)$ is the set of distinct values for dimension d , and $p(v) = |\{c \in \mathcal{C} : c_d = v\}|/|\mathcal{C}|$ is the proportion of candidates with value v .

$$H_{\text{norm}}(d) = \frac{H(d)}{\log_2 |\text{Val}(d)|} \quad (3)$$

where $|\text{Val}(d)|$ is the number of distinct values observed for dimension d in the current candidate set (or k for discretized continuous attributes). This yields values in $[0, 1]$, where 1 indicates a uniform distribution and 0 indicates all candidates share the same value.

把当前候选商品集合中的**属性分布**看成一种“不确定性”。如果某个属性在候选集中分布很分散，说明这个维度不确定较高，可以询问用户。

IDSS整体架构






Figure 1: IDSS system overview. The conversational loop uses LLM parsing and entropy-guided question selection, followed by candidate ranking and entropy-based grid diversification.

主实验：性能对比

Query Data Type	Method	Config	Prec@9 ↑	NDCG@9 ↑	Sat@9 ↑	ILD ↑
Short	ES	Full	<u>.903</u> ±.025	<u>.941</u> ±.011	<u>.772</u> ±.032	.779 ±.043
		–MMR	.918 ±.020	.952 ±.007	.764 ±.019	.279 ±.011
		–EntropyQ	.880 ±.056	.927 ±.032	.732 ±.051	<u>.611</u> ±.015
		–MMR and EntropyQ	.902 ±.019	.931 ±.023	.778 ±.016	.231 ±.004
	CR	Full	.887 ±.025	<u>.900</u> ±.025	.758 ±.037	<u>.319</u> ±.008
		–MMR	<u>.883</u> ±.012	.920 ±.005	.719 ±.024	.179 ±.003
		–EntropyQ	.848 ±.046	.882 ±.045	.706 ±.034	.327 ±.006
		–MMR and EntropyQ	.866 ±.028	.893 ±.026	<u>.751</u> ±.025	.217 ±.020
Long	ES	Full	<u>.744</u> ±.036	<u>.868</u> ±.037	<u>.459</u> ±.095	.412 ±.047
		–MMR	.837 ±.037	.891 ±.043	.507 ±.033	.241 ±.029
		–EntropyQ	.719 ±.062	.779 ±.053	.401 ±.053	<u>.405</u> ±.055
		–MMR and EntropyQ	.662 ±.085	.689 ±.071	.417 ±.050	.177 ±.026
	CR	Full	<u>.801</u> ±.108	<u>.875</u> ±.106	<u>.445</u> ±.061	<u>.299</u> ±.021
		–MMR	.863 ±.033	.909 ±.024	.504 ±.015	.223 ±.020
		–EntropyQ	.753 ±.063	.809 ±.065	.406 ±.043	.306 ±.024
		–MMR and EntropyQ	.724 ±.013	.725 ±.013	.431 ±.008	.195 ±.032

实验结论：MMR 主要提升推荐列表多样性，EntropyQ 主要提升推荐质量，尤其是在用户意图不充分或复杂时。

The background features a light gray top section with faint, curved lines. A solid blue horizontal band spans the middle, containing the text 'Thanks!'. Below the band is a white section with faint, abstract network-like patterns of lines and dots.

Thanks!