

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于 tokenization 视角的生成式推荐调研

学	号	<u>1025040938</u>
姓	名	<u>杨智翔</u>
导	师	<u>鲍秉坤</u>
专业学位类别		<u>工学硕士</u>
类	型	<u>生成式推荐</u>
专业（领域）		<u>网络空间安全</u>
论文提交日期		<u>2026 年 5 月</u>

摘要

近年来，大语言模型、生成式检索和多模态表示学习的发展正在推动推荐系统范式发生变化。传统推荐系统通常采用“召回-排序”的流水线结构，将推荐问题建模为用户与候选物品之间的匹配或打分问题。这一范式在工业系统中已经形成成熟体系，但也存在语义理解能力有限、对固定候选集依赖较强、模块间误差累积以及复杂用户意图难以端到端建模等问题。生成式推荐尝试将推荐任务转化为序列生成任务，直接生成满足用户需求的物品标识、语义标识或文本结果，为统一检索、排序、对话交互与多模态理解提供了新的研究路径。

本文围绕生成式推荐的基本概念、发展脉络与典型方法展开调研。首先比较匹配式推荐与生成式推荐在建模目标、输入输出形式和系统结构上的差异；其次从物品表示与 Tokenization 视角归纳离散 ID、文本表示和语义 ID 三类技术路线；随后重点分析 TIGER、HSTU、MMQ 和 IDSS 等代表性工作，分别讨论语义 ID 生成、工业级序列转导、多模态量化 Tokenization 以及智能体推荐中的偏好澄清机制。最后，本文总结生成式推荐在语义表达、端到端建模和可扩展性方面的优势，并指出语义冲突、生成结果约束、多模态对齐、交互成本和评测体系仍是后续研究需要重点解决的问题。

关键词：生成式推荐，语义 ID，生成式检索，序列推荐，多模态推荐，智能体推荐

Abstract

Generative recommendation has become an important research direction with the rapid progress of large language models, generative retrieval, and multimodal representation learning. Conventional recommender systems usually follow a retrieval-and-ranking pipeline and formulate recommendation as a matching or scoring problem between users and candidate items. Although this paradigm is mature in industrial systems, it still suffers from limited semantic understanding, strong dependence on a fixed candidate pool, error accumulation across modules, and insufficient ability to model complex user intent in an end-to-end manner. Generative recommendation reformulates recommendation as a sequence generation problem, where the model directly generates item identifiers, semantic identifiers, or textual recommendation results.

This survey reviews the motivation, technical routes, and representative methods of generative recommendation. It first compares matching-based and generative recommendation paradigms, and then summarizes three major item tokenization routes: discrete identifiers, textual representations, and semantic identifiers. Representative studies, including TIGER, HSTU, MMQ, and IDSS, are discussed from the perspectives of semantic ID generation, industrial-scale sequential transduction, multimodal quantization, and preference elicitation in agentic recommendation. Finally, this thesis summarizes the advantages of generative recommendation and discusses open challenges such as semantic collision, generation constraints, multimodal alignment, interaction cost, and evaluation protocols.

Key Words: Generative Recommendation, Semantic ID, Generative Retrieval, Sequential Recommendation, Multimodal Recommendation, Agentic Recommendation

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景	1
1.2 研究动机	1
1.3 本文主要内容	2
第二章 生成式推荐基础与发展脉络	3
2.1 生成式模型与生成式推荐	3
2.2 从匹配问题到生成问题	3
2.3 三类 Tokenization 路线	4
2.3.1 离散 ID 表示	4
2.3.2 文本表示	5
2.3.3 语义 ID 表示	5
2.4 本章小结	5
第三章 典型生成式推荐方法分析	6
3.1 TIGER: 基于语义 ID 的生成式检索	6
3.2 HSTU: 工业级序列转导框架	6
3.3 MMQ: 多模态语义 ID 生成	7
3.4 IDSS: 智能体推荐中的偏好澄清	7
3.5 本章小结	7
第四章 方法比较与关键问题讨论	8
4.1 代表性方法比较	8
4.2 语义 ID 的质量问题	8
4.3 生成约束与推荐可靠性	9
4.4 评测体系与工业落地	9
4.5 本章小结	9
第五章 发展趋势与研究展望	10
5.1 端到端统一推荐模型	10
5.2 多模态与语义增强	10
5.3 智能体化推荐交互	10
5.4 可能的研究切入点	10
5.5 本章小结	11
第六章 总结与展望	12
6.1 本文工作总结	12
6.2 进一步研究方向	12
参考文献	13

插图索引

图 1.1 传统推荐范式与生成式推荐范式对比图	2
图 2.1 Tokenization 视角下的生成式推荐范式演化树	4

表格索引

表 2.1 生成式推荐中三类物品表示路线对比 5

表 4.1 代表性生成式推荐方法对比 8

专用术语注释表

符号说明：

符号	表示含义
u	用户或用户历史行为序列
i	推荐系统中的物品或内容项
s_i	物品 i 对应的语义 ID 序列
$P(s_i \mid u)$	在用户历史条件下生成目标物品语义 ID 的概率
$\mathcal{C}$	候选物品集合或码本集合

缩略词说明：

缩写	英文全称	中文译名
GR	Generative Recommendation	生成式推荐
LLM	Large Language Model	大语言模型
SID	Semantic Identifier	语义标识
RQ-VAE	Residual-Quantized Variational AutoEncoder	残差量化变分自编码器
DLRM	Deep Learning Recommendation Model	深度学习推荐模型
HSTU	Hierarchical Sequential Transduction Unit	层次化序列转导单元
MMR	Maximal Marginal Relevance	最大边际相关性
NDCG	Normalized Discounted Cumulative Gain	归一化折损累计增益

第一章 绪论

1.1 研究背景

推荐系统是信息过载环境下连接用户需求与海量内容的重要基础设施，已经广泛应用于电商、短视频、新闻、音乐、广告和本地生活等场景。传统推荐系统通常采用“召回-排序-重排”的流水线结构：召回层从大规模物品库中筛选候选集合，排序层对候选物品进行精细打分，重排层进一步考虑多样性、业务约束和用户体验。这一范式在工程上具有可解释、可拆分、可迭代的优势，但它本质上仍然将推荐建模为用户和候选物品之间的匹配问题。

随着大语言模型和生成式模型的发展，推荐系统开始出现新的建模思路。生成式推荐不再只对候选物品进行打分，而是将推荐结果视为模型需要生成的目标序列。例如，模型可以根据用户历史行为生成下一个物品的 ID 序列，也可以生成具有语义结构的物品标识，还可以在对话式场景下生成澄清问题和推荐解释。这一思路与大语言模型中的“下一个词预测”具有相似性，即通过统一的序列建模方式刻画用户兴趣、物品语义和交互过程。

1.2 研究动机

传统检索-排序范式面临的主要问题可以概括为以下四个方面。

- (1) **语义理解能力有限**。传统模型通常依赖历史交互、品类体系、商品标签和用户标签等结构化特征，难以充分利用物品描述、图像、评论和外部知识中包含的丰富语义。
- (2) **性能提升存在瓶颈**。当模型规模继续增大时，传统打分式模型未必稳定获得收益，其原因在于模型主要学习候选集内的相对分数，而不是直接建模用户意图的生成过程。
- (3) **依赖固定候选集**。推荐结果必须从预定义候选池中选择，这限制了模型处理新物品、长尾物品和开放式需求的能力。
- (4) **流水线模块割裂**。召回、排序、重排和解释等模块通常独立训练与部署，各阶段之间存在目标不一致和误差累积问题，难以实现真正的联合优化。

生成式推荐为上述问题提供了新的解决方向。一方面，它可以复用大语言模型的预训练知识，增强物品和用户意图的语义理解；另一方面，它可以将推荐建模为端到端的序列生成任务，在统一模型中完成候选生成、排序或交互式偏好澄清。

1.3 本文主要内容

本文是一篇围绕生成式推荐的短篇调研型毕业论文，主要内容如下。

- (1) 梳理生成式推荐的基本定义，比较其与匹配式推荐范式的差异。
- (2) 从 Tokenization 视角归纳生成式推荐的发展路线，包括离散 ID、文本表示和语义 ID 三类方案。
- (3) 分析 TIGER、HSTU、MMQ 和 IDSS 等典型工作，讨论其研究动机、方法框架和技术贡献。
- (4) 总结生成式推荐的关键挑战与未来趋势，为后续开展生成式推荐、语义 ID 或多模态推荐研究提供参考。




图 1.1 传统推荐范式与生成式推荐范式对比图

第二章 生成式推荐基础与发展脉络

2.1 生成式模型与生成式推荐

生成式模型的核心思想是学习数据的底层分布，并基于该分布生成新的数据。在自然语言处理领域，大语言模型通过海量文本学习语言结构、语法关系和语义知识，从而具备续写、问答、摘要和创作能力。推荐系统中的生成式思想与此类似：模型不再仅仅判断某个候选物品是否适合用户，而是根据用户历史行为和上下文直接生成推荐目标。

匹配式推荐范式的核心目标是学习用户-物品匹配函数，通常可表示为

$$y_{u,i} = f(u, i), \quad (2.1)$$

其中 u 表示用户状态或历史行为， i 表示候选物品， $y_{u,i}$ 表示用户对物品的偏好分数。生成式推荐则将目标改写为条件生成概率：

$$P(s_i|u) = \prod_{t=1}^T P(s_{i,t}|u, s_{i,<t}), \quad (2.2)$$

其中 $s_i = (s_{i,1}, s_{i,2}, \dots, s_{i,T})$ 表示物品 i 的 token 序列或语义 ID 序列。模型通过自回归生成 s_i ，再映射到具体物品，完成推荐。

2.2 从匹配问题到生成问题

将推荐问题转化为生成问题带来了三个重要变化。首先，推荐结果的形式从“候选集中物品的排序列表”变为“可被模型生成的目标序列”。其次，模型训练目标从分数拟合或二分类损失，扩展为序列建模损失、生成式检索损失以及与推荐指标对齐的强化学习目标。最后，系统结构从多个模块串联，逐渐走向检索、排序、解释和对话能力的统一建模。

这一变化并不意味着传统推荐方法失效，而是说明推荐系统开始吸收生成式模型的表达方式。对于工业系统而言，生成式推荐的实际价值在于：它可能减少复杂流水线中的模块边界，使模型能够利用文本、图像和行为序列中的深层语义，并在开放式交互场景中主动澄清用户偏好。

2.3 三类 Tokenization 路线

生成式推荐的关键问题是：物品应当如何被表示为可生成的 token。现有综述通常也将 Tokenization 视为理解生成式推荐发展的核心视角之一^[1]。结合已有研究，现有方法大体可以分为三条路线，如图2.1所示。




图 2.1 Tokenization 视角下的生成式推荐范式演化树

2.3.1 离散 ID 表示

离散 ID 路线延续了传统推荐系统中以物品编号表示 item 的做法。GRU4Rec 将循环神经网络引入会话推荐，SASRec 使用自注意力建模用户序列，BERT4Rec 使用双向 Transformer 预测被掩码物品。这一类方法强调行为序列建模，便于与已有推荐系统对接，但物品 ID 本身缺乏语义，模型难以理解物品之间的文本、视觉和知识关联。

2.3.2 文本表示

文本表示路线将用户、物品、行为和任务转换为自然语言输入，利用大语言模型完成推荐。例如 P5 等工作尝试把多种推荐任务统一为 text-to-text 任务，GPT4Rec 和 LLaRA 等工作探索用语言模型增强物品查询、解释或表征。该路线的优势在于能够充分利用 LLM 的世界知识和语言理解能力，但其挑战在于生成文本与真实物品库之间需要稳定映射，且推理成本较高。

2.3.3 语义 ID 表示

语义 ID 路线是当前生成式推荐的重要前沿。其基本思路是先根据物品文本、图像或行为特征生成离散化的语义标识，再让生成式模型直接生成这些标识。与随机物品 ID 相比，语义 ID 具有层次结构和语义相似性，相似物品可以共享高层 token，从而提高生成式检索的泛化能力。TIGER、LMIndexer、LETTER、ETEGRec、OneRec 和 MMQ 等方法都围绕语义 ID 的构造、优化和下游适配展开。

表 2.1 生成式推荐中三类物品表示路线对比

路线	核心思想	优势	局限
离散 ID	直接使用 item ID 或行为 token 建模用户序列	易接入传统系统，训练目标清晰	ID 缺乏语义，新物品和长尾泛化较弱
文本表示	将推荐任务语言化，使用 LLM 处理用户、物品和任务描述	语义理解强，可支持解释和对话	生成结果映射和推理成本较难控制
语义 ID	将物品编码为可生成的离散语义 token 序列	兼具离散检索效率和语义泛化能力	存在语义冲突、码本学习和目标对齐问题

2.4 本章小结

本章介绍了生成式推荐的基本建模方式，并从物品表示角度总结了离散 ID、文本表示和语义 ID 三条技术路线。可以看出，生成式推荐的核心不只是“用生成模型做推荐”，更重要的是重新定义推荐系统中的输入、输出和物品索引方式。

第三章 典型生成式推荐方法分析

3.1 TIGER: 基于语义 ID 的生成式检索

TIGER 是生成式推荐中具有代表性的工作之一，它将推荐任务从 score-based prediction 转向 token generation，提出使用 Transformer decoder 直接生成目标物品的语义 ID^[2]。该方法的核心思想是：原始物品 ID 只是索引编号，不具备语义结构；若要让生成式模型像生成词语一样生成物品，就需要先把物品转换成具有语义层次的离散 token。

TIGER 的方法主要包括两个阶段。第一阶段利用物品标题、类目等内容特征，通过文本编码器得到物品向量，再使用 RQ-VAE 对向量进行残差量化，生成层次化 Semantic ID。第二阶段将用户历史交互物品映射为 Semantic ID token 序列，训练 Seq2Seq Transformer 根据历史序列自回归生成下一个物品的 Semantic ID。推理时，模型生成 token 序列后通过查找表映射到具体物品。

TIGER 的贡献在于建立了“语义 ID-生成式检索-推荐结果”的完整链路，使推荐模型可以摆脱传统 ANN 检索和候选集打分的单一路径。不过，该方法也暴露出语义 ID 路线的典型问题：不同物品可能被量化到相同 token 序列，产生语义冲突；模型也可能生成物品库中不存在的 token 组合，需要额外的约束或修正机制。

3.2 HSTU: 工业级序列转导框架

HSTU 是 Meta 提出的工业级生成式推荐系统模块，目标是将传统 DLRM 范式中的检索和排序统一为序列转导任务^[3]。与 TIGER 侧重语义 ID 生成不同，HSTU 更关注如何在真实工业推荐系统中处理海量用户行为、异构特征和超大规模参数模型。

传统 DLRM 通常需要针对 item、action、creator、demographic、counter、ratio 等不同特征设计不同处理模块，而 HSTU 将这些异构特征压缩合并为按时间顺序排列的用户行为序列。模型在统一序列空间中学习用户兴趣演化和候选内容关系，使 retrieval 与 ranking 都可以被表述为序列预测或序列转导问题。

HSTU 的实验结果表明，生成式推荐可以在工业级任务中获得明显收益，并呈现类似大语言模型领域的 Scaling Law：当数据规模、模型规模和训练计算量提升时，模型困惑度和推荐指标能够持续改善。这一结论对生成式推荐具有重要意义，因为它说明推荐系统也可能受益于大模型时代的规模化训练范式。

3.3 MMQ: 多模态语义 ID 生成

MMQ 关注语义 ID 的质量问题,尤其是在多模态场景下如何同时保留文本、图像等模态中的共享信息和独特信息^[4]。生成式推荐中的 Semantic ID 并不只是一个压缩编码,它需要同时服务两个目标:一是准确表达物品语义,二是适配下游用户行为预测。如果仅根据内容语义训练 tokenizer,生成的 ID 未必最有利于推荐任务。

MMQ 的整体思路可以分为两个阶段。第一阶段从文本和图像 embedding 中生成高质量语义表示,不同模态进入不同专家模块以提取共享信息和模态独有信息,再根据权重融合得到统一表示。第二阶段使 tokenizer 接受下游推荐目标的反馈:模型通过 soft index 保留可微分的概率分布用于损失回传,同时通过 hard index 生成明确的离散 SID 用于前向推荐。

该方法的意义在于将语义 ID 从“静态内容编码”推进到“可被推荐目标修正的任务相关编码”。对于多模态推荐而言,这种机制有助于缓解文本语义、视觉语义与用户行为偏好之间的目标不一致问题。

3.4 IDSS: 智能体推荐中的偏好澄清

IDSS 关注 Agentic Recommendation Systems 中的偏好不确定性问题^[5]。在电商等场景中,用户查询往往是模糊、弱指定或不完整的,例如“想买一件适合通勤的外套”。此时推荐系统如果直接给出列表,可能无法覆盖用户真实偏好;如果持续追问,又会增加交互成本并影响体验。

IDSS 的核心思想是使用信息熵刻画候选商品集合中的属性不确定性。当某个属性在候选集中分布较分散时,说明系统对该偏好维度尚不确定,可以优先围绕该属性向用户提问。这样,提问、排序和展示不再是相互独立的模块,而是围绕“用户偏好不确定性”这一统一信号进行设计。

从生成式推荐视角看, IDSS 将推荐系统从“被动给出结果”推进到“主动澄清需求”。这与 LLM Agent 的交互能力具有天然联系,也提示未来推荐系统可能同时承担候选生成、偏好询问、结果解释和多样性控制等功能。

3.5 本章小结

本章分析了四类代表性生成式推荐工作。TIGER 奠定了基于语义 ID 的生成式检索框架, HSTU 证明了工业级生成式序列建模的可行性, MMQ 推进了多模态语义 ID 的质量优化, IDSS 则将生成式推荐扩展到主动交互和偏好澄清场景。

第四章 方法比较与关键问题讨论

4.1 代表性方法比较

不同生成式推荐方法虽然都强调“生成”，但其研究重点并不相同。TIGER 更关心如何把物品转化为可生成的语义 ID；HSTU 更关心如何在工业推荐系统中统一海量异构特征和序列任务；MMQ 更关心多模态语义 ID 的表达质量与下游适配；IDSS 更关心交互过程中用户偏好的不确定性建模。

表 4.1 代表性生成式推荐方法对比

方法	主要任务	核心创新	主要挑战
TIGER	生成式检索	使用 RQ-VAE 生成层次化 Semantic ID，并用 Transformer 生成目标物品 token	语义冲突、非法 ID 生成、码本质量控制
HSTU	工业级序列转导	将检索和排序统一到大规模行为序列建模框架中	训练成本高、工程复杂、长序列计算压力大
MMQ	多模态语义 ID	融合文本和图像信息，并通过下游推荐目标修正 tokenizer	多模态对齐、离散化损失、推荐目标与内容语义平衡
IDSS	智能体推荐	用熵建模偏好不确定性，统一提问、排序和多样性展示	交互成本控制、用户反馈噪声、在线评估困难

4.2 语义 ID 的质量问题

语义 ID 是生成式推荐中的关键中间表示。一个理想的语义 ID 应当同时满足三点要求：第一，相似物品在高层 token 上具有共享结构；第二，不同物品能够被唯一或近似唯一地区分；第三，生成出的 ID 能够稳定映射到真实物品库。然而，这三个要求之间存在张力。如果量化过粗，相似物品容易冲突；如果量化过细，token 序列会失去共享语义，生成难度也会增加。

此外，语义 ID 的训练目标也需要谨慎设计。只依据文本或图像相似性生成的 ID 可能很好地表达内容语义，却不一定符合用户行为规律；只依据交互数据学习的 ID 又可能受热门偏置影响，难以解释物品语义。因此，如何联合内容语义、协同信号和下游推荐目标，是语义 ID 路线的核心问题。

4.3 生成约束与推荐可靠性

生成式推荐需要解决“生成结果是否有效”的问题。与文本生成不同，推荐系统的输出必须对应真实可用的物品。如果模型生成了物品库中不存在的 token 组合，或者生成了已经下架、不可达、不符合业务约束的物品，就会影响系统可靠性。因此，生成式推荐通常需要结合受约束解码、Trie 检索、候选映射表或后处理校验机制。

另一方面，推荐系统还需要考虑多样性、公平性、新颖性和安全性。生成式模型可能放大训练数据中的流行偏置，也可能在长尾物品上产生不稳定输出。未来研究需要将推荐约束更自然地融入生成过程，而不是仅在生成后进行规则过滤。

4.4 评测体系与工业落地

生成式推荐的评测不能只依赖 Recall、NDCG 等传统离线指标。对于语义 ID 方法，需要评估 ID 的冲突率、层次语义一致性和长尾恢复能力；对于 LLM 推荐方法，需要评估生成结果的可控性、解释质量和响应延迟；对于智能体推荐方法，还需要评估提问次数、用户满意度和交互收益。

工业落地方面，生成式推荐还面临成本与收益的权衡。大模型推理成本高、在线延迟敏感、物品库频繁更新，这些都要求生成式推荐必须与高效索引、缓存、蒸馏和增量更新机制结合。短期内，生成式推荐更可能作为传统推荐系统的增强模块，例如用于语义召回、特征增强、冷启动、推荐解释或对话式偏好澄清；长期来看，端到端生成式推荐有望重构现有推荐流水线。

4.5 本章小结

本章从方法对比、语义 ID、生成约束、评测体系和工业落地等方面讨论了生成式推荐的关键问题。总体来看，生成式推荐的优势在于统一建模和语义表达，但真正落地仍需要解决可控生成、效率和可靠性问题。

第五章 发展趋势与研究展望

5.1 端到端统一推荐模型

生成式推荐的重要趋势之一是端到端统一模型。传统推荐系统通常需要多个模型分别负责召回、排序、重排和解释，而生成式推荐希望用统一的序列建模框架处理这些任务。HSTU 的研究表明，检索和排序可以被重构为序列转导问题；OneRec 等工业系统进一步说明，基于 SID 的生成式推荐可以向真实业务场景扩展。

未来的端到端模型可能不再把“推荐列表”作为唯一输出，而是同时生成候选物品、排序依据、解释文本和澄清问题。这样，推荐系统将从静态排序工具逐渐变为具备上下文理解和交互能力的智能服务。

5.2 多模态与语义增强

电商、短视频和内容平台中的物品往往具有文本、图像、视频、音频和用户评论等多种模态。仅使用行为 ID 难以充分表达这些信息。MMQ 等方法说明，多模态语义 ID 可以将文本语义、视觉语义和用户行为统一到可生成的离散表示中。

后续研究需要进一步解决两个问题。第一，如何区分不同模态中的共享信息和独有信息，避免简单拼接导致噪声传播。第二，如何使多模态 tokenizer 与推荐目标联合优化，使生成出的 ID 不只是“语义相似”，而是真正有利于用户偏好预测。

5.3 智能体化推荐交互

随着 LLM Agent 的发展，推荐系统正在从单轮排序走向多轮交互。用户的初始需求往往不完整，系统需要主动判断是否提问、问什么问题以及何时停止提问。IDSS 使用信息熵建模偏好不确定性，为智能体推荐提供了一种可解释的决策依据。

未来的智能体推荐系统需要在推荐质量和交互成本之间取得平衡。一方面，系统应通过少量高价值问题快速缩小用户偏好空间；另一方面，系统不能过度打扰用户，也不能把复杂决策完全转嫁给用户。因此，偏好澄清、推荐展示和解释生成应当被统一纳入交互策略。

5.4 可能的研究切入点

结合本文调研，后续可以考虑以下研究方向。

- (1) **面向多模态生成式推荐的解耦语义 ID**。将文本、图像和行为信号拆分为共享语义、模态独有语义和用户偏好相关语义，提升 SID 的表达质量。
- (2) **面向长尾物品的语义 ID 优化**。利用语义共享和层次化 token 缓解长尾物品交互稀疏问题，提高冷启动和长尾推荐效果。
- (3) **生成式推荐中的可控解码机制**。在生成过程中显式约束合法物品、库存状态、业务规则和多样性目标，减少无效或不可靠输出。
- (4) **智能体推荐中的低成本偏好澄清**。基于信息熵、主动学习或强化学习选择最有价值的问题，提升多轮推荐效率。

5.5 本章小结

本章总结了生成式推荐的发展趋势。总体而言，生成式推荐将继续沿着端到端统一建模、多模态语义增强、可控生成和智能体化交互方向发展。这些方向也为后续开展毕业设计或科研工作提供了较清晰的切入点。

第六章 总结与展望

6.1 本文工作总结

本文围绕生成式推荐展开短篇调研，首先分析传统检索-排序范式在语义理解、候选集依赖、流水线割裂和性能扩展方面的局限；随后介绍生成式推荐将推荐任务建模为序列生成任务的基本思想，并从 Tokenization 视角梳理离散 ID、文本表示和语义 ID 三类技术路线；接着重点分析 TIGER、HSTU、MMQ 和 IDSS 四类代表性工作，分别对应语义 ID 生成、工业级序列转导、多模态量化和智能体偏好澄清；最后讨论生成式推荐在语义 ID 质量、可控生成、评测体系和工业落地方面仍需解决的问题。

通过调研可以看出，生成式推荐的核心价值并不只是将推荐模型替换为生成模型，而是重新组织推荐系统中的物品表示、用户行为建模和交互方式。它有望把推荐从候选打分系统推进到具备语义理解、开放生成和主动交互能力的统一模型。

6.2 进一步研究方向

后续研究可以重点关注多模态语义 ID 与用户行为目标之间的对齐问题。一方面，需要设计更合理的 tokenizer，使其能够同时保留文本、图像和协同过滤信号；另一方面，需要让语义 ID 的学习过程接受推荐目标反馈，避免内容语义与用户偏好之间出现偏差。此外，可控生成、合法物品约束、长尾推荐和智能体推荐中的低成本偏好澄清，也都是具有实际价值的研究方向。

对于毕业设计而言，可以选择一个相对聚焦的问题开展实验，例如“基于多模态解耦的语义 ID 生成方法”或“面向长尾推荐的生成式检索优化方法”。这类选题既能承接生成式推荐的前沿趋势，也便于围绕数据集、模型结构、消融实验和可视化分析形成完整论文。

参考文献

- [1] Li X, Chen B, She J, et al. A Survey of Generative Recommendation from a Tri-Decoupled Perspective: Tokenization, Architecture, and Optimization[J]. Preprints, 2025.
- [2] Rajput S, Mehta N, Singh A, et al. Recommender Systems with Generative Retrieval[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2023.
- [3] Zhai J, Liao L, Liu X, et al. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations[C]. Proceedings of the International Conference on Machine Learning. [S.l.: s.n.], 2024: 58484–58509.
- [4] Xu Y, Zhang M, Li C, et al. MMQ: Multimodal Mixture-of-Quantization Tokenization for Semantic ID Generation and User Behavioral Adaptation[J]. arXiv preprint arXiv:2508.15281, 2025.
- [5] Tran D, Li Y, Clay H, et al. Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems[J]. arXiv preprint arXiv:2603.11399, 2026.