



南京邮电大学
Nanjing University of Posts and Telecommunications

K均值聚类算法

汇报日期: 2025/12/31

汇报人: 张永康

CONTENTS

目录

- | | |
|----------------|----------------|
| PART 01 | 实验背景与意义 |
| PART 02 | 实验原理与方法 |
| PART 03 | 实验代码与结果 |
| PART 04 | 实验总结与展望 |



南京邮电大学
Nanjing University of Posts and Telecommunications

01

实验背景与意义

厚德、弘毅、求是、笃行



实验背景与意义

K均值 (K-means) 是一种无监督学习的聚类算法，用于将数据集划分为K个互不重叠的簇(clusters)。其核心思想是：通过迭代优化，使得统一簇内的数据点尽可能相似，不同簇的数据点尽可能不同。K均值等聚类算法试图通过分组对象来发现数据集中的相似性，与不同集群间的对象相似性相比，同一集群中对象之间的相似性更高。

K均值聚类能够帮助人们在看似混乱的数据中，发现我们肉眼看不出的规律。它可以自动把杂乱的数据（比如客户、图片、文章）分成有意义的组，并保证每组内部成员很像，不同组的成员之间区别明显。只须输入要分几个组，就可以让其找出分组的规律，从而实现让数据自己“开口说话”，帮我们做出更明智的决策。



南京邮电大学
Nanjing University of Posts and Telecommunications


02

实验原理与方法

厚德、弘毅、求是、笃行

实验原理与方法

K-means算法将一组样本数据划分成K个无交集的簇，直观上来看簇是一组聚集在一起的数据，在一个簇中的数据就被认为是同一类，簇就是聚类的结果表现。簇中所有数据的均值通常被称作这个簇的“质心 (centroids)”。在一个二维平面中，一簇数据点的质心的横坐标、纵坐标就是这一簇数据点的横坐标、纵坐标的均值。同理可推广至高维空间。如果集群呈现一致的球形形状，则说明K-means在捕获结构和进行数据推理方面非常有效，如果集群呈现更复杂的几何形状，那就说明算法在数据聚类方面做得不好。



实验原理与方法


K-means算法的基本步骤可以概括为初始化、分配、更新、迭代。

初始化：随机选择K个数据点作为初始的聚类中心（质心）。

分配：计算每个数据点到各个质心的距离，并将其分配到最近的质心相应的簇。

更新：重新计算每个簇的质心，即该簇所有数据点的均值。


迭代：算法会重复执行，直到上次迭代的质心发生的变化不显著或达到最大迭代次数。



实验原理与方法

肘部法：在聚类分析中，肘部法是一种用于确定最优聚类数目的方法。它通过分析聚类模型的误差平方和 (SSE, Sum of Squared Errors) 随聚类数 k 增加的变化趋势，来寻找“肘部”拐点，从而选择合理的聚类数量。

随着聚类数 k 的增加，样本被划分得越细，每个簇的紧凑程度会提高，SSE会逐渐下降。当 k 小于真实聚类数时，增加 k 会显著提升聚类效果，SSE下降幅度大。当 k 值达到真实聚类数附近时，再增加 k ，SSE的下降幅度会突然变缓，形成类似“肘部”的拐点。拐点对应的 k 值通常被认为是最优聚类数。





实验原理与方法

轮廓系数 (Silhouette Coefficient) : 轮廓系数是聚类分析中最常用、最直观的内部评估指标之一, 用于衡量聚类结果的内聚性和分离性。它同时考虑了簇内紧密度和簇间分离度, 为每个样本提供一个评分, 从而评估聚类质量。轮廓系数通过量化每个样本与自身簇的相似度、与其他簇的差异度来实现这一评估。

卡林斯基-哈拉巴斯指数 (CHI, Calinski-Harabasz Index) : 是聚类分析中一种重要的内部评估指标, 通过衡量簇间离散度与簇内离散度的比率来评估聚类效果。它计算了簇间方差 (簇与簇之间的分离程度) 与簇内方差 (簇内部的紧凑程度) 的比值, 并进行了标准化。CHI值越高, 表示聚类效果越好。

戴维斯-布尔丁指数 (DBI, Davies-Bouldin Index) : 基于好的聚类应该使簇内样本紧凑 (高聚类), 不同簇之间分离良好 (低耦合), 通过计算每个簇与其他簇等等相似性来评估聚类质量。DBI值越小, 表示聚类效果越好。



南京邮电大学
Nanjing University of Posts and Telecommunications

03

实验代码与结果

厚德、弘毅、求是、笃行



实验代码与结果

实验环境：Windows 11, Intel(R) Iris(R) Xe Graphics, Python 3.12

实验所使用的数据源于一个excel表格，导入python程序中进行预览，内容如下：

已安装 (Python 3.12 (test))	
contourpy	1.3.3
cycler	0.12.1
fonttools	4.61.1
jobjlib	1.5.3
kiwisolver	1.4.9
matplotlib	3.10.7
numpy	2.4.0
packaging	25.0
pandas	2.3.3
pillow	12.0.0
pip	23.2.1
pyarsing	3.3.1
python-dateutil	2.9.0.post0
pytz	2025.2
scikit-learn	1.7.2
scipy	1.16.3
seaborn	0.13.2
six	1.17.0
threadpoolctl	3.6.0
tzdata	2025.3

```
D:\test\.venv\Scripts\python.exe D:\test\cluster.py
```

```
数据形状：(3000, 2)
```

```
数据预览：
```

	V1	V2
0	2.072345	-3.241693
1	17.936710	15.784810
2	1.083576	7.319176
3	11.120670	14.406780
4	23.711550	2.557729

```
数据统计信息：
```

	V1	V2
count	3000.000000	3000.000000
mean	40.611358	22.862141
std	25.859054	31.759714
min	-22.495990	-38.795500
25%	18.462790	-4.003494
50%	41.552210	13.827390
75%	62.249480	55.729100
max	104.376600	87.313700


实验代码与结果

将数据放入二维坐标系之中，进行可视化处理，可以看出数据的大致分布如下：

```
# 加载数据
df = pd.read_csv('xclara.csv')


print(f"数据形状: {df.shape}")
print(f"数据预览:")
print(df.head())
print(f"\n数据统计信息:")
print(df.describe())

# 数据可视化
plt.figure(figsize=(10, 6))
plt.scatter(df['V1'], df['V2'], s=30, alpha=0.6, c='blue', edgecolors='w')
plt.xlabel('V1')
plt.ylabel('V2')
plt.title('xclara.csv data distribution')
plt.grid(visible=True, alpha=0.3)
plt.show()
```



实验代码与结果


对数据使用肘步法，可以获得肘步曲线。观察曲线的走势，我们可以知道 $K=3$ 大致就是这组数据的最佳 K 值。



```
# 使用肘部法则确定最佳K值
X = df.values
# 标准化数据
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
# 计算不同K值下的误差平方和(SSE)
sse = []
k_range = range(1, 11)
for k in k_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(X_scaled)
    sse.append(kmeans.inertia_)
# 绘制肘部图
plt.figure(figsize=(10, 6))
plt.plot(*args: k_range, sse, 'bo-', linewidth=2, markersize=8)
plt.xlabel('number of clusters (K)')
plt.ylabel('sum of squares of errors (SSE)')
plt.title('Elbow Rule - Determining the Optimal K Value')
plt.xticks(k_range)
plt.grid(visible=True, alpha=0.3)
plt.show()
from sklearn.metrics import silhouette_score
```

实验代码与结果

通过对轮廓系数的分析，我们可以验证K=3确实是这组数据的最佳K值，K=3时能够取到这组数据轮廓系数的最大值：



```
from sklearn.metrics import silhouette_score


silhouette_scores = []
k_range = range(2, 11)

for k in k_range:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    cluster_labels = kmeans.fit_predict(X_scaled)
    silhouette_avg = silhouette_score(X_scaled, cluster_labels)
    silhouette_scores.append(silhouette_avg)

plt.figure(figsize=(10, 6))
plt.plot(*args: k_range, silhouette_scores, 'ro-', linewidth=2, markersize=8)
plt.xlabel('number of clusters (K)')
plt.ylabel('coefficient of contour')
plt.title('Coefficient of Contour - Determine the Optimal K Value')
plt.xticks(k_range)
plt.grid(visible=True, alpha=0.3)
plt.show()
```

实验代码与结果

基于肘部法和轮廓系数的分析，选择K=3进行聚类
可以看出，数据分为明显的3簇，并且每个簇的形状都近似于一个边界光滑的球形。



厚德、弘毅、求是、笃行

```
k = 3
kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
clusters = kmeans.fit_predict(X_scaled)
# 将聚类结果添加到原始数据
df['Cluster'] = clusters
df['Cluster'] = df['Cluster'].astype('category')
# 获取聚类中心（反标准化到原始尺度）
centers_scaled = kmeans.cluster_centers_
centers_original = scaler.inverse_transform(centers_scaled)
print(f"聚类中心（原始尺度）：")
for i, center in enumerate(centers_original):
    print(f"簇 {i}: V1={center[0]:.2f}, V2={center[1]:.2f}")
print(f"\n每个簇的样本数量：")
print(df['Cluster'].value_counts().sort_index())
# 可视化聚类结果
plt.figure(figsize=(12, 8))
# 定义颜色和标记
colors = ['red', 'blue', 'green']
markers = ['o', 's', '^']
# 绘制每个簇的数据点
for i in range(k):
    cluster_data = df[df['Cluster'] == i]
    plt.scatter(cluster_data['V1'], cluster_data['V2'],
                s=40, c=colors[i], marker=markers[i],
                alpha=0.7, label=f'cluster {i}')
# 绘制聚类中心
plt.scatter(centers_original[:, 0], centers_original[:, 1],
            s=300, c='yellow', marker='*', edgecolors='black',
            linewidth=2, label='cluster centre')
```




实验代码与结果

在实验的最后，对这次实验的聚类性能指标进行了测算。从结果中，我们可以看出这次聚类的结果具有较高的CHI和较低的DBI，仍有许多的改进空间。比如，随机初始化可能使得结果不稳定，使结果陷入局部最优而不能获得全局最优解。同时，使用均值作为簇中心非常容易受到噪声和异常值的影响，聚类结果容易被异常值扭曲。

```
聚类中心（原始尺度）：  
簇 0: V1=40.68, V2=59.65  
簇 1: V1=69.92, V2=-10.12  
簇 2: V1=9.41, V2=10.66  
  
每个簇的样本数量：  
Cluster  
0      1151  
1       952  
2       897  
Name: count, dtype: int64  
=== 聚类性能指标 ===  
轮廓系数: 0.6912  
Calinski-Harabasz指数: 10249.88  
Davies-Bouldin指数: 0.4236
```



南京邮电大学
Nanjing University of Posts and Telecommunications

04

实验总结与展望

厚德、弘毅、求是、笃行



实验总结与展望

K均值算法因其效率高、可扩展性强的特点，在需要处理海量数据的时代成为了初步探索和快速分群的重要工具，它提供了将复杂数据化为代表性类别的直接手段。它能以最直观的方式，通过最小化样本点到簇中心的距离来揭示聚类中“物以类聚”的本质思想。通过这次实验，我直观地理解了在聚类模型中“距离”和“中心”的概念，这是理解所有基于划分和原型的聚类方法的基石。K均值算法流程清晰简洁，完美体现了优化中的期望最大化（EM）思想，为后续学习更复杂的聚类模型做好了铺垫。

此次实验所使用的K均值算法仍存在许多的不足。首先，聚类前需要通过各种方法预先确定簇的数量，指定使用的K值，如果使用了错误的K值将会导致不合适的聚类划分。其次，初始化的随机会导致结果不稳定，使算法陷入局部最优解无法获得全局最优解，本次实验所使用的均值计算方法也容易受到噪声和异常值的影响。在未来的研究与学习之中，应对深入学习K-means++、层次聚类等模型来改进实验方案。



南京邮电大学

Nanjing University of Posts and Telecommunications

汇报结束 感谢聆听！

汇报人:张永康