



南京邮电大学
Nanjing University of Posts and Telecommunications

Apriori算法实验汇报

汇报人：赵可欣 学号：1025040946



Contents



南京邮电大学
Nanjing University of Posts and Telecommunications

01

算法简介

02

评估标准

03

算法原理

04

实验设置与结果

05

关联规则分析

06

总结



南京邮电大学
Nanjing University of Posts and Telecommunications

01

算法简介



什么是 Apriori 算法?

Apriori是一种用于**频繁项集挖掘**和**关联规则学习**的经典算法,通过发现数据中的隐藏模式来揭示项目之间的内在联系。

核心特点:

- 自底向上的搜索策略
- 候选项集生成与剪枝
- 迭代式频繁项集发现



经典案例:"啤酒与尿布"

沃尔玛通过Apriori算法发现:购买啤酒的顾客往往也购买尿布。这一发现改变了商品陈列策略,使销售额显著提升。



关键概念

交易数据库

一组交易的集合,每个交易包含多个项目。交易数据库是Apriori算法的基础输入数据。

T1: {面包, 牛奶, 鸡蛋}

T2: {面包, 黄油}

T3: {牛奶, 鸡蛋, 黄油}

T4: {面包, 牛奶, 黄油}

频繁项集

在数据库中频繁出现的项目组合。满足最小支持度阈值的项集被称为频繁项集,它们代表了数据中的常见模式。

关联规则

形如 $X \rightarrow Y$ 的规则,表示购买X的顾客也倾向于购买Y。关联规则揭示了项目之间的因果或相关关系。



适用场景

市场篮子分析

发现顾客购买商品之间的关联优
化商品摆放和促销策略

01

医疗诊断

发现症状与疾病之间的关联规则，
辅助诊断决策

03

02

推荐系统

推荐可能感基于用户行为模式
兴趣的商品或内容

04

网络分析

分析网站访问模式，优化用户体
验和网站结构



南京邮电大学
Nanjing University of Posts and Telecommunications

02

评估标准



支持度

定义与计算

支持度是某项集在所有交易中出现的比例,反映了该组合的**普遍性**和**流行程度**。

公式:

$$Support(X, Y) = P(X \cap Y) = num(X \cap Y) / num(AllSamples)$$

实例分析:

- 总交易数:100笔
- 同时包含{面包,牛奶}:10笔
- **支持度** = $10/100 = 10\%$

应用标准

- ✓ **支持度高** → 常见组合,值得关注
- ✗ **支持度低** → 偶然组合,可能不具代表性



置信度

定义与计算

置信度表示在包含Y的交易中,也包含X的**条件概率**,衡量规则的可靠性。

公式:

$$Confidence(X \rightarrow Y) = P(X/Y) = P(X \cap Y) / P(Y)$$

实例分析:

- 购买鸡爪的顾客:50人
- 同时购买纸巾:20人
- **置信度** = $20/50 = 40\%$

应用标准

- > 60%: **强关联**推荐使用
- 40–60%: **中等关联**谨慎使用
- < 40%: **弱关联**不建议使用



提升度

定义与计算

提升度衡量规则的**真实效果**,考虑了商品本身的流程度,是最能反映关联强度的指标。

公式:

$$Lift(X \Rightarrow Y) = P(X/Y) / P(X) = Confidence(X \Rightarrow Y) / P(X)$$

实例分析:

- $P(\text{买纸巾}|\text{买鸡爪}) = 40\%$
- $P(\text{买纸巾}) = 10\%$
- $Lift = 40\% / 10\% = 4$

应用标准

$Lift > 1$: **正相关** X和Y有关联 ✓

$Lift = 1$: **独立** X和Y无关

$Lift < 1$: **负相关** 互斥关系



南京邮电大学
Nanjing University of Posts and Telecommunications

03

算法原理



"自下而上"的迭代方法：从单个商品开始,逐步扩展到多个商品的组合,直到无法继续为止。这种迭代方法确保了算法的系统性和完整性。每一轮都包含候选生成、支持度计算和频繁项筛选三个关键步骤。

生成候选1项集 C_1

从数据集中提取所有不同的单个商品作为初始候选集

01

扫描数据库计算支持度

统计每个候选项集在交易数据库中出现的频率

02

筛选得到频繁1项集 L_1

保留支持度大于等于最小支持度阈值的项集

03

生成候选k项集 C_k

通过连接和剪枝操作生成下一层候选项集

04

迭代直到无新频繁项集

重复上述过程直到无法生成新的频繁项集为止

05

生成关联规则

基于频繁项集计算置信度并生成满足条件的关联规则

06



04

实验设置与结果



My Dataset

1,892

交易记录数

1,990

商品种类

11.79

平均交易规模

参数选择

最小支持度: 2%

最小置信度: 50%





数据处理模块

load data()- 加载CSV数据: 读取交易记录, 转换为集合格式

候选集生成

create C1()-生成候选1项集; apriori gen() - 生成候选k项集: 基于频繁k-1项集连接生成

支持度计算

scan dataset() - 扫描数据集: 计算项集支持度, 进行剪枝

核心算法

apriori() - 主算法函数: 迭代生成所有频繁项集

规则生成

generate rules() -生成关联规责: 计算置信度和提升度

结果输出

print frequent itemsets(); print rules()




```
def scan_dataset(dataset, candidates, min_support):  
    """  
    扫描数据集，计算候选集的支持度  
    返回：频繁项集和支持度字典  
    """  
    # 计算每个候选项的出现次数  
    item_count = {}  
    for transaction in dataset:  
        for candidate in candidates:  
            if candidate.issubset(transaction):  
                item_count[candidate] = item_count.get(candidate, 0) + 1  
  
    # 计算总交易数  
    num_transactions = len(dataset)  
  
    # 筛选满足最小支持度的项集  
    frequent_items = []  
    support_data = {}  
  
    for item in item_count:  
        support = item_count[item] / num_transactions  
        if support >= min_support:  
            frequent_items.append(item)  
            support_data[item] = support  
  
    return frequent_items, support_data
```

```
def apriori(dataset, min_support=0.5):  
    # 生成候选1项集  
    C1 = create_C1(dataset)  
  
    # 扫描数据集，获取频繁1项集  
    L1, support_data = scan_dataset(dataset, C1, min_support)  
  
    # 存储所有频繁项集  
    L = [L1]  
    k = 2  
  
    print(f"频繁{k - 1}项集: {len(L[k - 2])} 个")  
  
    # 迭代生成频繁k项集  
    while len(L[k - 2]) > 0:  
        # 生成候选k项集  
        Ck = apriori_gen(L[k - 2], k)  
  
        # 扫描数据集，获取频繁k项集  
        Lk, support_k = scan_dataset(dataset, Ck, min_support)  
  
        if len(Lk) == 0:  
            break  
  
        # 更新支持度数据  
        support_data.update(support_k)  
        L.append(Lk)  
  
        print(f"频繁{k}项集: {len(Lk)} 个")  
        k += 1  
    return L, support_data
```



频繁项支持度分布：


Top 90 Frequent Items by Support





频繁项支持度分布：


Top 20 Frequent Items by Support





关联规则散点图


Association Rules: Support vs Confidence
(Color: Lift)





关联规则网络图


Top 5 Association Rules Network





支持度分布直方图:




Distribution of Support Values






规则对比图

Top 5 Rules Comparison







05

关联规则分析



关联规则分析

规则1: [71]→[2]

支持度: 2.11%

置信度: 65.57%

提升度: 6.97

规则2: [71]→[3]

支持度: 2.11%

置信度: 65.57%

提升度: 9.06

规则3: [24]→ [6]

支持度: 2.17%

置信度: 58.57%

提升度: 8.21

规则4: [3]→ [2]

支持度: 4.12%

置信度: 56.93%

提升度: 6.05

规则5: [10]→[9]

支持度: 2.11%

置信度: 54.79%

提升度: 9.87



南京邮电大学
Nanjing University of Posts and Telecommunications

06

总结

实验结论:





南京邮电大学
Nanjing University of Posts and Telecommunications

谢谢观看

