

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于毫米波雷达的呼吸监测算法设计与实现

学	号	<u>B22040003</u>
姓	名	<u>范诗瑜</u>
导	师	<u>韩老师</u>
专业学位类别		<u>工科</u>
类	型	<u>工程设计</u>
专业（领域）		<u>模式识别和机器学习</u>
论文提交日期		<u>二〇二六年六月</u>

摘要

在非接触式的呼吸检测研究中，毫米波雷达有着波长短、高灵敏度与隐私保护的优势，有望成为呼吸检测的有效手段，更有助于推动远程医疗、智慧医疗与日常健康管理的发展。然而，这种技术手段仍然存在着环境杂波干扰、胸腔微动等诸多挑战。本次研究旨在解决如何从高噪声、多干扰的毫米波雷达信号中，高保真地还原出人体的真实呼吸波形，并实现高精度的呼吸频率提取。

本文提出一种基于 TCN 和 Transformer 的双路并行特征融合网络来实现毫米波雷达呼吸监测。首先，针对雷达 I/Q 信号进行有效的信号处理操作得到 5 个距离单元的瞬时相位。其次，将这些相位信息输入到深度学习网络中，网络使用了 TCN 和 Transformer 双路并行的机制，TCN 注重波形的局部瞬时形态，Transformer 利用自注意力机制建模全局呼吸节律。然后，进行加权融合，以 1: 0.2 的比例进行线性加权，通过解码器将抽象的特征映射到一维的时域空间最终输出连续的呼吸波形。

基于商用毫米波雷达搭建了无接触呼吸检测数据采集软硬件平台，并进行了数据采集，共采集 10945 个样本，并进行算法实验对比与分析。实验表明，本文所提方法表现出了优异的性能，该模型的皮尔逊相关系数达到 0.8402，呼吸率估计的平均绝对误差低至 0.3091BPM。与其他多种模型进行比较，本文提出的双路并行架构体现出来很好的性能和效果，为非接触式生理信号精准监测提供了一种新的解决方案。

关键词：毫米波雷达，呼吸监测，时间卷积网络，Transformer

Abstract

In the research of non-contact respiratory detection, millimeter-wave radar has the advantages of short wavelength, high sensitivity, and privacy protection, and is expected to become an effective means of respiratory detection, which is more conducive to promoting the development of telemedicine, smart healthcare, and daily health management. However, this technical approach still faces many challenges such as environmental clutter interference and chest micro-movement. This study aims to solve the problem of how to accurately restore the true respiratory waveform from high-noise and multi-interference millimeter-wave radar signals and achieve high-precision respiratory rate extraction.

This paper proposes a dual-path parallel feature fusion network based on TCN and Transformer to achieve millimeter-wave radar respiratory monitoring. Firstly, effective signal processing operations are performed on the radar I/Q signals to obtain the instantaneous phase of five distance units. Secondly, these phase information is input into the deep learning network, which uses a dual-path parallel mechanism of TCN and Transformer. TCN focuses on the local instantaneous shape of the waveform, while Transformer models the global respiratory rhythm using the self-attention mechanism. Then, weighted fusion is performed with a linear weighting ratio of 1:0.2, and the abstract features are mapped to the one-dimensional time domain space through the decoder to finally output the continuous respiratory waveform.

A contactless breathing detection data acquisition software and hardware platform was built using commercial millimeter-wave radar, and data collection was conducted, resulting in a total of 10,945 samples. Algorithm experiments were performed with comparative analysis. The experiment demonstrated that the method proposed in this paper exhibited outstanding performance, with the model's Pearson correlation coefficient reaching 0.8402 and the mean absolute error for respiratory rate estimation as low as 0.3091 BPM. Compared with multiple other models, the dual-path parallel architecture proposed in this paper demonstrated excellent performance and effectiveness, providing a new solution for the precise monitoring of non-contact physiological signals.

Key Words: Millimeter-wave radar, Respiratory detection, Temporal Convolutional Network, Transformer

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 研究内容和技术路线	3
1.4 本文结构安排	4
第二章 毫米波雷达呼吸监测相关技术	5
2.1 FMCW 毫米波雷达工作原理	5
2.2 呼吸信号的产生机制	7
2.3 关键算法步骤	7
2.3.1 Range-FFT 算法	8
2.3.2 I/Q 信号校正	8
2.3.3 相位解缠	9
2.3.4 带通滤波	10
2.4 本章小结	11
第三章 深度学习相关技术	12
3.1 卷积神经网络	12
3.1.1 卷积层	12
3.1.2 激活函数	12
3.1.3 池化层	13
3.1.4 卷积神经网络的整体结构	14
3.2 时间卷积网络	14
3.2.1 因果卷积	15
3.2.2 膨胀卷积	15
3.2.3 残差连接	15
3.2.4 TCN 的整体结构	17
3.3 Transformer 架构	17
3.3.1 注意力机制	17
3.3.2 Transformer 的整体结构	18
3.4 本章小结	19
第四章 基于 TCN 和 Transformer 的呼吸监测算法	20
4.1 引言	20
4.2 基于 TCN 和 Transformer 的呼吸监测算法的实现	20
4.2.1 雷达信号处理	20
4.2.2 TCN-Transformer 实现	22
4.2.3 损失函数设计	24
4.3 本章小结	25

第五章 实验分析	26
5.1 实验设置	26
5.2 评价指标	26
5.3 实验结果	28
5.4 消融实验	30
5.5 本章小结	32
第六章 总结与展望	33
参考文献	34
致谢	37

插图索引

图 2.1	FMCW 雷达工作原理	5
图 2.2	chirp 信号时频域图	6
图 2.3	Range-FFT 后得到的频谱图	8
图 2.4	Taubin 算法处理前后的圆心坐标状态	9
图 2.5	相位解缠前后波形	10
图 3.1	一维卷积示意图	12
图 3.2	激活函数示意图	13
图 3.3	池化的计算流程	14
图 3.4	卷积神经网络 (CNN) 整体结构图	14
图 3.5	膨胀率分别为 1、2、3 时的卷积核覆盖范围	16
图 3.6	残差连接的基本结构	16
图 3.7	TCN 模型的整体架构	17
图 3.8	Transformer 的整体架构	19
图 4.1	系统整体架构	20
图 4.2	天线合并后的中频信号和距离维 FFT 结果	21
图 4.3	峰值附近还存在呼吸信息的情况	21
图 4.4	实际捕获的 I/Q 信号轨迹修正前后对比	22
图 4.5	网络整体架构图	23
图 5.1	采集设备场景图	26
图 5.2	预测波形与真实波形对比图	28
图 5.3	三种网络的预测波形对比	29
图 5.4	前端页面	30
图 5.5	四种消融后的网络预测波形对比	31

表格索引

表 5.1 皮尔逊相关系数范围对应相关强度层级 27

表 5.2 所有方法的各项指标比较 28

表 5.3 消融实验各指标对比 31

第一章 绪论

1.1 研究背景与意义

随着物联网、可穿戴设备和移动医疗技术的快速发展，人体生理信号的实时监测与分析已经成为智慧医疗领域的研究热点。生命体征在医疗监护中至关重要，关系着人体的健康状况，呼吸是生命体征监测的重要指标之一。根据国家卫健委发布的官方标准，正常成年人在安静状态下的呼吸频率为 16 ~ 20 次/分^[1]，呼吸波形更是人们关注呼吸形态的一种直观形式。据统计，阻塞性睡眠呼吸暂停综合征在成年人群中的患病率约为 9% ~ 38%^[2]，而慢性阻塞性肺疾病已成为全球第三大死因^[3]。早期的呼吸监测可以有效预防各种呼吸道疾病，持续呼吸监测能够为医疗人员提供快速有效的诊断依据，意义重大。

传统的呼吸监测的形式以接触式为主，包括胸带、鼻气流传感器等可能会存在使用不便、舒适性差等问题，对于需要持续监测、呼吸睡眠障碍、皮肤敏感或有烧伤的人来说^[4]，这些设备也并不是很好的选择。因此，非接触式的呼吸监测方法的优势就体现了出来。目前主流的非接触式方法有基于计算机视觉的视频分析技术^[5]，利用商用 WiFi 信号的信道状态信息感知技术^[6]，基于超声波或红外热成像的物理传感技术^[7]，以及基于毫米波雷达的微波射频感知技术^[8]。其中毫米波雷达能穿透衣物，通过检测人体胸腹表面的微动来提取呼吸信号，实现无感、高隐私性的生理监测，有助于推动远程医疗、智慧医疗与日常健康管理的发展。同时这类传感器采集的原始时间序列往往具有高噪声、非平稳及个体差异大等特点，对后续的信号处理与呼吸参数提取提出了严峻挑战。

毫米波雷达是工作在 30 至 300GHz 频段的探测技术^[9]，最早可以追溯到 20 世纪 40 年代，由于器件与工艺水平的限制，直到 80 年代才真正走向实用化。进入 21 世纪后，毫米波雷达在汽车防撞雷达^[10]、5G 通信^[11] 等领域进行了应用，导致其在体积、功耗和成本上实现了优化，并向医疗健康领域发展。在信号处理中，早期方法主要包括带通滤波、峰值检测、短时傅里叶变换等数字信号处理技术^[12]。这些方法虽能在一定程度上消除噪声、提取呼吸特征，但通常需要对不同设备和场景进行繁琐的参数调优。

随着深度学习 (Deep Learning, DL) 技术的兴起，卷积神经网络^[13] (CNN)、循环神经网络^[14] (RNN)、长短时记忆网络^[15] (LSTM)、生成对抗网络^[16] (GAN) 以及近年来的 Transformer^[17] 和图神经网络^[18] 等架构相继涌现，在各个领域都取得突破性进展。在生命体征监测方面，深度学习的引入很大程度上优化了对生理信号的特征提取与建模方式。其中，时间卷积网络^[19] (TCN) 作为一种时序建模架构，将膨胀卷积与因果卷积结合，具有并行计算能力强、梯度稳定、感受野灵活可控等优势，在时序数据处理方面具有很好的效果。然而，TCN 感受野的扩大依赖于卷积核大小、膨胀率与网络层数的组合。对于需要捕捉超长期依赖关系

的任务, TCN 可能需要堆叠大量网络层或采用极大的膨胀率, 导致参数量膨胀与计算开销增加。Transformer 模型的核心是自注意力机制, 能够在—层网络内直接捕捉序列中任意两个位置之间的依赖关系, 其多头注意力机制可以同时关注不同子空间下的多种依赖模式, 理论上可以实现高精度、强鲁棒的呼吸监测。

基于上述毫米波雷达在非接触呼吸监测中的独特优势, 以及深度学习在生理信号处理中的强大能力, 本研究针对传统接触式监测方法的不足, 开展了将深度学习与毫米波雷达技术融合的技术路线。首先利用调频连续波 (Frequency Modulated Continuous Wave, FMCW) 雷达采集人体胸部微动的回波, 构建了专用的数据集。然后, 提出了一种基于 TCN 与 Transformer 双分支融合架构的呼吸监测方法。该方法利用 TCN 对局部时序特征的提取能力与 Transformer 对全局依赖关系的建模优势, 通过并行化的双支路结构, 实现对呼吸波信号的重建和对呼吸率的预测功能。

1.2 国内外研究现状

毫米波雷达包括连续波雷达^[20]、调频连续波雷达^[21]和超宽带雷达^[22]等类型, 通过分析回波信号中的多普勒频移或相位变化来提取呼吸频率与波形^[23]。国内外有许多研究者对毫米波雷达在包括呼吸在内的生命体征监测作用上进行了深入的研究尝试。例如, Malikeh 等^[24]人使用低频便携式连续波雷达系统, 设计并开发了一款名为 RDR-SENSE 的胸戴式连续波雷达设备, 用于持续监测呼吸率。设备尺寸为 5×5cm, 工作频率为 875MHz, 采用接触式天线设计, 能够通过人体组织耦合电磁波以获取呼吸活动引起的胸腔周期性运动信号。实验结果是通过五名志愿者在不同呼吸场景下的实验数据得到的呼吸率平均绝对误差为 0.75RPM, 具备较好性能。

与此同时, 卷积神经网络能够有效提取复杂雷达信号中的时空特征。Wang 等人^[25]基于商用 77GHz MIMO 毫米波雷达提出了细粒度呼吸监测系统 MM-FGRM。该系统直接从雷达信号的 I/Q 分量中直接提取人体感兴趣区域, 然后利用深度学习网络 IQ-Transformer 恢复出精细的呼吸波形。这项研究—共采集了 8 名受试者共 12 小时的数据进行实验, 实验结果证明 MM-FGRM 能够准确恢复呼吸波形并提供精确的呼吸频率, 且在未参与训练的用户数据上表现出良好的泛化能力。

为了更好的具备呼吸监测的连贯性, 逐步出现了端到端的信号重建方法。Bauder 等人^[26]提出了 MM-MuRe 方法, 通过端到端深度神经网络处理原始多输入多输出毫米波雷达数据, 实现多目标非接触式呼吸波形监测。可以实现直接从未经处理的 60GHz MIMO FMCW 雷达数据到输出目标呼吸波形的流程。MM-MuRe 在不同距离、角度、环境和目标数量的实验场景中, 波形重建的平均余弦相似度能够超过 0.95, 具备在近实时系统中部署的潜力。

针对动态场景中运动干扰的挑战, 通过并行处理时空与频域特征的双流架构被提出。Xie

等人^[27]针对运动伪影干扰的问题提出了基于双流深度神经网络架构的监测系统 DeepVs。该系统构建了并行的时域分析与频域解析双通路，时域分支捕获雷达相位信号的动态演变模式，频域分支提取生理信号的周期性频谱特征。同时引入了注意力机制模块，自适应融合双流特征中的关键信息，有效区分生理信号与运动噪声。

1.3 研究内容和技术路线

本文的研究就是使用毫米波雷达发射电磁波通过接收的回波得到相位信息，再通过信号处理方法从原始雷达信号中提取呼吸信号，最后聚焦于如何使用深度学习方法将人体的呼吸恢复成清晰的波形以及预测呼吸频率。在研究算法的过程中，将按照以下的技术路线来执行。首先，学习掌握毫米波雷达、信号处理技术和深度学习的基础知识，这是开始研究的前提条件。其次，构建从数据到系统的完整研发流程，具体分为四个阶段：

(1) 呼吸信号数据采集和预处理

首先，利用 FMCW 毫米波雷达硬件平台采集人体呼吸状态下的原始中频信号 (IF Signal)，针对原始数据存在的环境杂波干扰，利用距离维傅里叶变换 (Range-FFT) 将信号映射至距离域，峰值对应的距离单元即包含目标信息。随后，提取目标所在距离单元的复数信号，通过相位解缠与静止杂波抑制技术，消除由于墙壁等静止物体产生的直流偏置，将电磁回波转化为能够反映胸腔位移的原始相位序列，并进行归一化处理以满足后续深度学习模型的输入要求。

(2) 呼吸监测算法设计

本阶段聚焦于呼吸重建算法的构建，设计了一个基于 TCN-Transformer 架构的深度神经网络。编码器部分通过 TCN 捕捉信号的局部空间演变，Transformer 掌握全局趋势。解码器部分则负责将提取的高维抽象特征映射回时域，重构出连续、高保真的呼吸波形。

(3) 算法模型训练和优化

在模型训练阶段，将采集的数据集划分为训练集、验证集与测试集，确保评估过程具备严谨的泛化性验证。使用 PyTorch 框架实现网络，采用 Adam 优化器，设置初始学习率。训练过程中通过验证集监控模型性能，最后开展消融实验以确定最佳结构。

(4) 系统集成与性能评估

最后，将训练好的模型集成到简易的呼吸监测演示系统中，实现从信号输入到结果输出的流程。在评估阶段，将系统输出的呼吸率与参考设备的记录进行对比，计算皮尔逊相关系数^[28] (Pearson Correlation Coefficient, PCC)、呼吸率绝对误差 (Mean Absolute Error,

MAE) 和平均峰值时间误差 (Average Time-to-Peak Error, TPE), 综合评价系统在静态及轻度活动场景下的监测性能。

1.4 本文结构安排

本文针对毫米波雷达在呼吸监测方面存在的问题进行调查和研究, 提出了一种基于 TCN 和 Transformer 双路并行的深度学习算法架构, 实现了从数据采集到算法实现的全流程研究。

本文具体的论文结构安排如下:

第一章, 绪论。本章首先阐述了这项研究的背景和意义以及对国内外研究现状进行综述, 其次简要概括了论文的主要研究内容和整体的技术路线, 最后总结了本文的结构安排。

第二章, 毫米波雷达呼吸监测相关技术。本章首先介绍了 FMCW 毫米波雷达的工作原理, 然后引出呼吸信号是怎么产生的, 最后再从毫米波雷达信号中进行处理的关键算法进行介绍。

第三章, 深度学习相关技术。本章首先介绍了卷积神经网络的基础知识, 然后进阶到时间卷积网络的内容, 最后对 Transformer 的架构进行阐述。

第四章, 基于 TCN 和 Transformer 的呼吸监测算法。本章首先介绍对于毫米波雷达呼吸监测的算法的现状和不足, 然后针对这些需求提出基于 TCN 和 Transformer 双路并行的呼吸监测算法架构, 主要从网络结构上对算法进行了介绍。

第五章, 实验分析。本章主要介绍了对这个算法进行的实验, 首先简要地阐述了实验的设置和评价指标, 然后进行了对比实验和消融实验, 并根据得到实验结果进行分析。

第二章 毫米波雷达呼吸监测相关技术

2.1 FMCW 毫米波雷达工作原理

毫米波雷达是一种高精度传感器，它的波长在 1mm 到 10mm 之间，频率在 30GHz 到 300GHz 之间^[9]，因此它具有穿透力强、无创、环境敏感性低等优点^[29]，这有利于探测微小运动和生命体征。毫米波雷达在汽车自动驾驶、智能交通和城市管理以及智慧医疗与生命体征监测方面有着广泛的应用，本文研究正是毫米波雷达在生命体征监测方面的研究。

线性调频连续波雷达可以改变发射波的频率测量距离、速度和角度，因为它具有功耗低、精度高、成本低和模块化成熟等特点成为目前市场上雷达主要的采用设备。下面主要介绍 FMCW 雷达的基本原理。

在毫米波雷达技术中，FMCW 雷达的模块主要包括频率合成器、发射天线和接收天线、混频器等^[30]。频率合成器的主要功能是产生 Chirp 信号。发射天线的主要功能就是在功率放大器把 Chirp 信号处理后将其转化成电磁波发射到空间中。接收天线的任务则是捕获被物体反射回来的极其微弱的电磁波。混频器会把发射信号和接收信号处理后得到中频信号。FMCW 雷达测距的原理就是通过发射天线发射电磁波，电磁波遇到物体发生反射，经过时间后接收天线接收到了电磁波，如图 2.1 所示。




图 2.1 FMCW 雷达工作原理

Chirp 信号是 FMCW 雷达最基本的信号单元，它的频率随时间线性增加或减少，但是绝大多数雷达的 Chirp 信号的频率是随时间增加的，本研究中所用的雷达也是如此，其时域图

和频域图如图 2.2 所示。发射天线发射的 chirp 信号的公式如下：

$$x_{\text{tx}}(t) = A_{\text{tx}} \exp [j (2\pi f_c t + \pi S t^2 + \phi_0)] \quad (2.1)$$

其中， A_{tx} 是发射信号的振幅， f_c 是起始频率， S 是调频斜率， ϕ_0 为初始相位。接收天线接收的 chirp 信号公式如下：

$$x_{\text{rx}}(t) = A_{\text{rx}} \exp [j (2\pi f_c (t - \tau) + \pi S (t - \tau)^2 + \phi_0)] \quad (2.2)$$

其中， A_{rx} 是接收信号的振幅， τ 是回波时延。




图 2.2 chirp 信号时频域图

中频信号是由混频器得到的。由于发射的 Chirp 信号的频率随时间增加，所以当接收天线接收到电磁波时，信号频率已经比刚发出时高很多了。混频器将这两个高频信号相乘并经过低通滤波，输出两者的频率差信号。中频信号 $x_{\text{IF}}(t)$ 可以表示为：

$$x_{\text{IF}}(t) = x_{\text{tx}}(t) \cdot x_{\text{rx}}^*(t) = A_{\text{if}} \exp \{j[(2\pi f_c \tau + 2\pi S \tau t - \pi S \tau^2)]\} \quad (2.3)$$

中频信号的频率 f_{if} 可以表示为：

$$f_{\text{if}} = S \cdot \frac{2R}{c} \quad (2.4)$$

其中， S 是调频斜率， R 是距离， c 是光速。中频信号的相位 ϕ_{if} 可以表示为：

$$\phi_{\text{if}} = \frac{2\pi R}{\lambda} \quad (2.5)$$

系统通过移相器产生两路正交信号来得到复数信号，分别得到了同相分量 (I) 和正交分量 (Q)：

$$I(t) = A_{if} \cos(2\pi f_{if}t + \phi) \quad (2.6)$$

$$Q(t) = A_{if} \sin(2\pi f_{if}t + \phi) \quad (2.7)$$

两种合并为复中频信号：

$$x_{IF}(t) = I(t) + jQ(t) = A_{if}e^{j(2\pi f_{if}t + \phi)} \quad (2.8)$$

2.2 呼吸信号的产生机制

人体在呼吸的时候，胸腔会发生起伏，在吸气的时候，胸廓扩张，呼气时，胸廓收缩，形成周期性的起伏。正常的成年人在静止状态下，呼吸的频率在 0.1Hz 到 0.5Hz 之间^[31]，也就是每分钟 6 到 30 次，胸腔表面的位移在 1mm 到 12mm 之间。正是因为毫米波雷达波长短这个特性，它完全有能力监测到这种毫米级的微动。假设 FMCW 雷达和人体的初始距离是 R_0 ，呼吸引起位移是 $d(t)$ ，那么可以得到瞬时距离：

$$R(t) = R_0 + d(t) \quad (2.9)$$

同时设初始相位为 ϕ_0 ，也可以得到瞬时相位：

$$\phi(t) = \phi_0 + \frac{4\pi d(t)}{\lambda} \quad (2.10)$$

由此，就可以把微小的毫米级的呼吸位移，转换成较大的相位变化，毫米波雷达就是通过这种方式获取到呼吸信号的。但是在监测过程中还存在着位移在 0.1mm 到 0.5mm 的心跳干扰，以及更大范围的人体运动等情况，因此怎么提取出更纯净的呼吸信号正是下一小节的关键算法的主要作用。

2.3 关键算法步骤

在传统的呼吸信号处理算法中，通常要进行 4 个步骤。首先，在得到 FMCW 雷达的原始呼吸信号后需要进行 Range-FFT 将时域信号转换成距离域频谱，选择定位目标。其次，把提取出 I/Q 信号进行正交校正和去直流处理，以恢复理想的信号。随后，进行相位解调和解缠算法，将信号中的相位演变转化为反映胸腔微动的位移曲线。最后，通过带通滤波处理提出其他信号干扰得到呼吸信号。

2.3.1 Range-FFT 算法




图 2.3 Range-FFT 后得到的频谱图

Range-FFT 的作用是把中频信号从时间域转化成频率域。对中频信号进行 FFT 操作后得到的频域图每一个频率点 (Bin) 都对应一个特定的距离范围。例如, 若雷达的距离分辨率为 4cm, 则第 10 个 Bin 代表距离雷达 40cm 处的回波。如图 2.3 原本散布在整个时间序列中的能量, 经过 FFT 后会聚焦在目标所在的特定距离单元上, 形成明显的能量峰值。该能量峰值的位置确定了目标人体在空间中的距离单元, 而该单元所对应的复数信号相位, 则包含了由于胸腔起伏引起的微小位移信息。

通常在我们的研究中只有一个能量峰值, 这样可以清晰的定位到目标, 但是实际研究过程中可能会出现多个能量峰值, 这可能是因为监测环境中存在静止的墙壁、天花板、金属家具、办公椅或门窗等物品, 因此在算法处理时, 我们通常通过计算标准差或使用直流抵消来排除这些静态峰值。而如果是在人体所在位置附近的相邻几个距离单元内同时出现峰值可以采用提取相邻的多个距离单元来尽可能的完整的呼吸信号。

2.3.2 I/Q 信号校正

在锁定目标距离单元后, 提取出的 I/Q 信号由于受到静态杂波残留和系统直流漂移的影响, 在复平面上表现为偏离原点的圆弧。实际雷达系统中, I 通道和 Q 通道往往存在增益不平衡、相位非正交以及直流偏移等情况, 因此通常采用直流消除减去信号均值以消除天线互耦产生的静态杂波, 采用几何拟合, 如 Taubin 或 Pratt 算法, 将复平面上的 I/Q 轨迹拟合为一个标准圆, 通过平移和缩放使信号回归理想解析模型^[32]。这里主要介绍 Taubin 算法。

Taubin 算法是一种改进的最小二乘拟合技术, 它的核心思想就是通过最小化几何距离的




图 2.4 Taubin 算法处理前后的圆心坐标状态

代数近似来拟合圆心坐标 (i_0, q_0) 和半径 R 。优化的目标函数可以表示为：

$$\min \sum_{i=1}^n [(i_i - i_0)^2 + (q_i - q_0)^2 - R^2]^2 \quad (2.11)$$

相比于标准的最小二乘法，Taubin 算法在处理呼吸信号产生的短圆弧时，具有更高的数值稳定性和拟合精度。

通过 Taubin 算法计算出圆心坐标 (i_0, q_0) 后，对原始复信号 $S_{\text{raw}}(t)$ 执行减法运算以消除直流偏移。

$$S_{\text{corrected}}(t) = S_{\text{raw}}(t) - (i_0 + j \cdot q_0) \quad (2.12)$$

经过校正后的信号 $S_{\text{corrected}}(t)$ 重新以原点为中心如图 2.4 所示。这一步骤不仅有效抑制了静态杂波的干扰，更重要的是重建了相位提取的几何基准，为后续高精度的位移重构奠定了基础。

2.3.3 相位解缠

在信号校正之后，就是通过相位提取把复数信号转换成相位信号。利用校正后的同相分量 I_{cor} 和正交分量 Q_{cor} ，通过四象限反正切函数计算每个时间点的瞬时相位 $\phi(t)$ ：

$$\phi(t) = \arctan2(Q_{\text{cor}}(t), I_{\text{cor}}(t)) \quad (2.13)$$

此时得到的相位 ϕ 直接对应于目标胸腔相对于雷达的微小距离变化。由于圆拟合已经去

除了直流偏移，这里的 ϕ 具有极高的线性度和可靠性，这就是相位提取。

$\arctan2$ 函数的输出范围被限制在 $[-\pi, \pi]$ 之间。如果呼吸引起的位移导致相位波动超过了这个范围，相位图就会出现图 2.5 这样的锯齿状突变。通过检测相邻采样点之间的相位差，如果差值超过 π ，则加上或减去 2π 的整数倍，从而恢复出连续的相位变化曲线。




图 2.5 相位解缠前后波形

根据 FMCW 雷达原理，相位变化 $\Delta\phi$ 与目标物理位移 Δd 满足以下线性关系：

$$\Delta d(t) = \frac{\lambda}{4\pi} \Delta\phi(t) \quad (2.14)$$

这一步将无量纲的相位信号转化成了具有毫米级的呼吸位移曲线。

2.3.4 带通滤波

经过相位解调与去趋势处理后的信号，虽然已经得到了一定程度的处理，但仍然存在环境高频噪声、人体肌肉震颤以及系统热噪声等问题。本研究为了提取较为纯净的呼吸波形，设计了相应的数字带通滤波器。

根据人体生理学统计特征，成年人在静息状态下的正常呼吸频率通常分布在 0.1Hz 至 0.5Hz。需要进行低频切除和高频抑制，设置 0.1Hz 的低截止频率，能够消除残余的基线漂移以及人体非常低频的姿态微调的干扰，同时设置 0.5Hz 的高截止频率，能够有效滤除频率在 0.8Hz 以上的心跳信号以及电子电路产生的高频白噪声。

本文采用 IIR 型 Butterworth 带通滤波器^[33] 进行信号处理。选择该类型滤波器的原因就在于其在通带内具有最平坦的幅度响应，能够最大程度地保持呼吸波形的形态特征，避免产生相位失真。

滤波器阶数设定为 4 阶，以在阻带衰减速度与计算复杂度之间取得平衡。滤波过程可以表示为如下差分方程：

$$y[n] = \sum_{i=0}^M b_i x[n-i] - \sum_{j=1}^N a_j y[n-j] \quad (2.15)$$

其中, $x[n]$ 为输入的原始位移序列, $y[n]$ 为滤波后的呼吸波形, a 和 b 为由采样频率与截止频率确定的滤波器系数。

经过带通滤波后的信号展现出清晰的好似周期性的波形。对滤波后的信号进行快速傅里叶变换分析可以获取呼吸率。在呼吸特征频段内搜索能量频谱的最大峰值, 设其对应频率为 f_{resp} , 则最终呼吸率计算为:

$$\text{BR} = f_{\text{textresp}} \times 60 \quad (\text{times/min}) \quad (2.16)$$

以上的所有内容就是传统的毫米波雷达进行呼吸监测的算法流程。

2.4 本章小结

本章主要介绍了基于毫米波雷达的呼吸监测相关技术。首先, 介绍了 FMCW 雷达的工作原理, 从硬件组成、chirp 信号的产生以及 FMCW 雷达的工作机制各方面细节详细阐述。其次, 结合 FMCW 雷达的基本原理, 联系呼吸信号的产生机制梳理了是怎么得到原始的雷达信号的。最后, 系统的阐述了各种基础的算法包括 Range-FFT、信号校正、相位解缠和带通滤波, 这些都是在传统呼吸信号处理流程中的关键算法。本文的研究主要关注 FMCW 毫米波雷达的工作原理、呼吸信号的产生机制以及关键算法步骤中的一些方法会在信号处理部分重点使用。

第三章 深度学习相关技术

3.1 卷积神经网络

卷积神经网络^[13] 是一种包含卷积计算且具有深度结构的前馈神经网络（Feed-Forward Network, FFN），是深度学习的代表网络之一。其核心操作是卷积运算，通过卷积核在输入数据上进行滑动窗口式的特征提取，并利用权值共享和局部连接的理念，显著降低网络参数量。它通常由卷积层、池化层和全连接层交替堆叠构成，能够自动学习输入数据的层次化特征表示。

3.1.1 卷积层

卷积层主要的作用是提取深度特征，主要是通过一组可以学习权重的卷积核在输入的数据上进行滑动窗口计算。在本文研究中的对象主要是一维的时序信号，所以采用了 1D-CNN，通过一维卷积核执行元素级乘法并求和的操作，能够有效地捕捉信号中的局部相关性和时域特征。卷积的计算公式如下：

$$y(t) = (x * w)(t) = \sum_{i=0}^{k-1} x(t+i) \cdot w(i) + b \quad (3.1)$$

其中， x 是输入的雷达相位信号， w 是大小为 k 的卷积核的权重， b 为偏置项。

图 3.1 展示了一维卷积是怎么在一维时序数据上进行操作的：




图 3.1 一维卷积示意图

3.1.2 激活函数

在深度神经网络中，如果仅由卷积层和全连接层组成，无论网络多深，它的本质仍然是输入的线性组合。激活函数的引入为网络注入了非线性因素，使其能够拟合呼吸信号中复杂的非线性畸变。

常见的激活函数有 ReLU 函数、LeakyReLU 函数、Sigmoid 函数等^[34]，其中 ReLU 函数是目前深度学习中最常用的激活函数。

ReLU 函数的数学表达式如下：

$$f(x) = \max(0, x) \quad (3.2)$$

而 LeakyReLU 函数在针对 ReLU 在输入为负时神经元可能输出恒为 0 的问题，给予负半轴一个极小的斜率 α ，其数学表达式如下：

$$f(x) = \begin{cases} x, & \text{if } x > 0 \\ \alpha x, & \text{if } x \leq 0 \end{cases} \quad (3.3)$$

Sigmoid 函数可以将输入映射到 $(0, 1)$ 的区间，其数学表达式如下：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3.4)$$

上述三个激活函数如图 3.2 所示。




图 3.2 激活函数示意图

3.1.3 池化层

池化层通常紧跟在卷积层之后，其主要目的是对特征图进行下采样。通过池化操作，模型可以实现特征降维、平移不变性和扩大感受野等作用。常见的池化方式包括最大池化 (Max Pooling)、平均池化 (Average Pooling)、全局平均池化 (Global Average Pooling, GAP)^[35]。其中最大池化的公式如下：

$$y = \max_{i \in \mathcal{R}} x_i \quad (3.5)$$

其中 $\mathcal{R}$ 是当前池化窗口所覆盖的区域。

如图 3.3 假设一个窗口以步长为 2 在输入数据上滑动，最大池化就是在这个窗口范围内选择最大值最为结果，最终得到最下方的特征信息。




图 3.3 池化的计算流程

3.1.4 卷积神经网络的整体结构

卷积神经网络的整体结构通常由输入层、特征提取层以及输出层组成。其中输入层负责接收经过预处理的原始数据，将信号转换为张量格式，以适配后续卷积运算的输入要求；特征提取层通常由多个重复的卷积块组成，每个块内部会通过卷积层与激活函数，然后进行归一化，最后进行池化层的下采样，随着网络层数的加深，模型提取的特征从初级的波形细节逐渐演变为高层语义特征；输出层则是在特征提取完成后，连接全连接层，将高维特征图平坦化为一维向量。最后，根据具体任务，通过相应的输出神经元生成最终的预测结果。

具体的 CNN 流程和结构如图 3.4 所示。




图 3.4 卷积神经网络 (CNN) 整体结构图

3.2 时间卷积网络

时间卷积网络是一种用来专门处理序列数据的深度学习模型架构，它本质还是对卷积神经网络在时间序列上的一种改进。TCN 在 CNN 的基础上使用了因果卷积、膨胀卷积和残差连接^[36]，使其可以严格限定历史依赖并且增大感受野，保证深度网络的稳定性。因此，TCN 在呼吸监测、金融高频交易、语音合成以及长期气象预报等领域都有其显而易见的优势。

3.2.1 因果卷积

标准卷积在处理时间序列时，卷积操作通常会看到当前时间前后的信息，这种双向的感受野在图像上比较适用，但是在时间序列的处理过程中会导致信息泄露，因此引入了因果卷积。因果卷积只会看到当前时间之前的内容，在时间序列 x 上进行因果卷积操作的计算公式如下：

$$y_t = \sum_{i=0}^{k-1} w_i \cdot x_{t-i} + b \quad (3.6)$$

其中， w 是大小为 k 的卷积核， b 为偏置项， $t-i$ 始终小于等于 t ，表示输出只和时刻 t 之前的内容有关。但是单纯的因果卷积却无法捕捉较长周期的呼吸特征，感受野受限。

3.2.2 膨胀卷积

虽然因果卷积解决了时间序列的因果逻辑问题，但其感受野与网络深度呈线性关系，对于大小为 k 的卷积核，每堆叠一层因果卷积，感受野仅能扩大 $k-1$ 个时间步。对于采样率较高的毫米波雷达呼吸信号，若要覆盖一个完整的呼吸周期，仅依靠标准因果卷积需要堆叠极深的网络层数，这会导致参数量剧增及梯度消失问题。

为此，TCN 引入了膨胀卷积，又称空洞卷积，通过在卷积核的元素之间引入固定数量的“空洞”来扩大卷积操作的感受野，而不增加卷积核的实际大小。具体而言，对于一维输入序列 x ，一个大小为 k 的卷积核 w ，在膨胀率为 d 的条件下，膨胀卷积在时间步 t 的输出定义为：

$$y_t = \sum_{i=1}^k w_i \cdot x_{t-d \cdot (k-i)} \quad (3.7)$$

其中，膨胀率 d 表示卷积核相邻元素之间的间隔步数。当 $d=1$ 时，膨胀卷积退化为标准卷积。图 3.5 展示了不同膨胀率下卷积核的覆盖范围。

3.2.3 残差连接

TCN 通过膨胀卷积可以在较小的层数中获得很大的感受野，但是对于长距离依赖关系的数据可能就需要上百层网络，这可能会出现梯度消失或网络退化的风险，因此提出了残差连接机制。

在 TCN 中残差连接是以残差块的形式集成到每一层膨胀因果卷积中，依次包含一个膨胀因果卷积层、一批权重归一化、ReLU 激活函数、Dropout 层，通常将这些操作重复两次，形成两层结构。图 3.6 展示了残差连接的基本结构。




图 3.5 膨胀率分别为 1、2、3 时的卷积核覆盖范围




图 3.6 残差连接的基本结构

对于一个 TCN 残差块，设输入为 x ，输出为 y ，整体计算可表示为：

$$y = \sigma(\mathcal{F}(x) + x) \quad (3.8)$$

其中， $\mathcal{F}(x)$ 表示残差路径学习到的残差映射， x 为恒等映射（跳跃连接）， $\sigma(\cdot)$ 为激活函数，通常为 ReLU，本文中使用的是 LeakyReLU。

当输入与输出的维度不一致时，需要在恒等路径上引入一个 1×1 卷积进行维度变换：

$$y = \sigma(\mathcal{F}(x) + W_s * x) \quad (3.9)$$

其中 W_s 为 1×1 卷积核， $*$ 表示卷积操作。




图 3.7 TCN 模型的整体架构

3.2.4 TCN 的整体结构

综上，TCN 模型就是在严格保持时间因果性的前提下，通过膨胀卷积指数级扩大感受野，并借助残差连接支持深层网络的稳定训练。一个典型的 TCN 模型由若干个残差块堆叠而成，每个残差块内部包含两层膨胀因果卷积，配合权重归一化、Dropout 和 ReLU 激活函数。TCN 的整体架构如图 3.7 所示。

3.3 Transformer 架构

Transformer 模型最初由 Vaswani 等^[37]人提出，它完全摒弃了传统的 RNN 和 CNN 结构，仅基于注意力机制构建。在呼吸信号监测任务中，Transformer 能够通过全局感受野并行地处理序列数据，精准捕捉呼吸波形中不同时间点之间的关联性。

3.3.1 注意力机制

注意力机制的核心思想是模仿人类视觉注意力，从大量信息中聚焦于关键部分。在深度学习中，它通过计算权重系数，实现对输入特征的动态重构。

首先，详细介绍一下自注意力机制。对于序列中的每一个位置，通过计算该位置与序列中包括自身的所有位置的关联权重，动态地聚合整个序列的信息。对于输入序列，首先通过线性变换生成查询矩阵 (Query, Q)、键矩阵 (Key, K) 和值矩阵 (Value, V)，通过计算 Q 与

K 的点积来衡量不同位置之间的相似度，经过 Softmax 归一化后得到权重，最后对 V 进行加权求和。计算公式可以表示为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (3.10)$$

其中， $\sqrt{d_k}$ 为缩放因子，用于维持梯度的稳定性。

然后就是介绍多头注意力机制。多头注意力机制就是将特征空间切分为 h 个互不干扰的子空间，每个“头”独立地学习序列中的不同特征，最后将所有头的输出结果进行拼接，并经过一个线性层进行整合，计算公式可以用表示如下。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (3.11)$$

3.3.2 Transformer 的整体结构

Transformer 的注意力机制在计算打乱顺序的输入序列时结果都是一样的，但是时间序列是高度依赖顺序的，所以它会显式的在序列中放入顺序信息再进入模型。常用的位置编码方式包括正余弦位置编码、可学习位置编码、相对位置编码、时间戳编码等^[38]。

Vaswani 等人提出的原始 Transformer 使用了正余弦位置编码这种确定性位置编码，对于位置 pos 和维度 i ，其编码值为：

$$\text{PE}_{(pos, 2i)} = \sin \left(\frac{pos}{10000^{2i/d_{\text{models}}}} \right) \quad (3.12)$$

$$\text{PE}_{(pos, 2i+1)} = \cos \left(\frac{pos}{10000^{2i/d_{\text{models}}}} \right) \quad (3.13)$$

其中， d_{models} 为模型维度。

在 Transformer 的每一层中，多头注意力子层之后紧接一个前馈神经网络。该前馈神经网络对序列中的每个位置独立且相同地进行非线性变换。其结构通常包含两个线性变换和一个 ReLU 激活函数：

$$\text{FFN}(x) = \text{ReLU}(xW_1 + b_1) W_2 + b_2 \quad (3.14)$$

在 Transformer 架构中，每个子层，包括多头注意力层和前馈神经网络层都会在输出端接入一个 Add & Norm 模块。具体而言，设某子层的输入为 x ，子层本身的映射函数为 $\text{Sublayer}(\cdot)$ ，




图 3.8 Transformer 的整体架构

则该子层的最终输出可表示为：

$$\text{Output} = \text{LayerNorm}(x + \text{Sublayer}(x)) \quad (3.15)$$

其中， $x + \text{Sublayer}(x)$ 为残差连接（Residual Connection，即 Add）， $\text{LayerNorm}(\cdot)$ 为层归一化（Layer Normalization，即 Norm）。

3.4 本章小结

本章主要介绍了深度学习的相关技术和基础知识。首先从最基本的 CNN 开始介绍卷积神经网络模型的基本架构，包括卷积层、激活函数、池化层、整体架构。然后拓展到时间卷积网络 TCN 的基本结构上，从因果卷积、膨胀卷积、残差连接、整体结构这四个方面展现了 TCN 在 CNN 基础上的对于时序数据的改进和增强，以及对其在呼吸信号上的适用性展开了阐述。最后对 Transformer 的最经典的基本架构进行详细的拆解分析，对注意力机制等内容进行了详细的描述。本文的研究将采用上述的 TCN 网络和 Transformer 的编码器这样一个双路并行的结构对毫米波雷达中的呼吸信号进行重构以及呼吸频率的预测。

第四章 基于 TCN 和 Transformer 的呼吸监测算法

4.1 引言

基于毫米波雷达的非接触式呼吸监测，实质上是从含有大量杂波和噪声的相位序列中提取具有准周期性特征的微弱生理信号。由于人体呼吸运动在时域上既包含局部细微的形态特征，又包含长程的节律性特点，这考验算法的特征提取能力。TCN 虽能通过扩张卷积高效捕捉局部形态，但却不适合处理跨度较大的全局依赖，而 Transformer 虽然擅长全局建模，却往往忽略了信号的精细局部结构。此外，雷达原始信号在不同通道上的信噪比差异较大，未经筛选的特征输入会干扰模型的判断逻辑。

针对上述问题，本章提出了一种基于 TCN 与 Transformer 双分支融合的呼吸监测算法。本算法首先通过 SE 注意力机制对输入信号通道进行特征加权，增强有效呼吸特征。随后利用并行化的双分支结构同时提取局部与全局时序特征，并通过加权融合机制实现特征互补。本章将详细阐述该算法的整体网络架构、参数配置及实现细节。

4.2 基于 TCN 和 Transformer 的呼吸监测算法的实现

本节主要介绍算法的整体系统框架，如图 4.1 所示。首先用雷达采集人体静止状态下呼吸的数据，然后通过信号处理的算法得到多通道时空特征矩阵，最后送入 TCN-Transformer 网络中配合真实呼吸波形进行监督学习，最终得以重建完整的呼吸波形并预测呼吸率。




图 4.1 系统整体架构

4.2.1 雷达信号处理

在信号处理部分，由于雷达系统配备了 2 个发射天线和 4 个接收天线，形成了多个虚拟通道。本文首先对原始雷达回波进行天线通道合并处理，如图 4.2 (a)，得到增强后的等效单

通道信号 x 。接着就是对合并后的 x 直接进行 Range-FFT 操作，将时域中频信号投影至距离域如图 4.2 (b)。红色虚线标注的位置就是峰值所对应的距离单元，这就是目标所在位置，需要获取该位置的相位信息。




图 4.2 天线合并后的中频信号和距离维 FFT 结果

在实际的数据中还存在类似图 4.3 所示的情况，因为人体是有体积的实体，呼吸引起的微动往往分布在相邻的几个距离分辨率单元内，所以我们不仅仅获取峰值所对应的距离单元的相位信息，同时获取与它相邻的一共 5 个距离单元的多通道信息。




图 4.3 峰值附近还存在呼吸信息的情况

毫米波雷达回波在复平面上理论上呈现为以原点为圆心的圆弧。然而，受雷达收发机内部直流偏置及室内静态物体反射产生的零频干扰影响，实际捕获的 I/Q 信号轨迹往往偏离原点如图 4.4(a)。本文采用的是 Taubin 圆拟合算法来把轨迹拉回原点，调整后的轨迹如图 4.4(b)。

相比传统的最小二乘拟合，Taubin 算法通过最小化代数距离平方和并引入几何约束，能够更稳健地估算出信号圆弧的几何中心 (i_0, q_0) 。通过执行中心平移操作：

$$S_{\text{cor}} = S_{\text{raw}} - (i_0 + j \cdot q_0) \quad (4.1)$$

使信号轨迹重新回归复平面坐标原点。这一步骤不仅显著提升了相位解调的线性度，也为后续提取毫米级胸腔位移提供了精准的参考基准。




图 4.4 实际捕获的 I/Q 信号轨迹修正前后对比

利用反正切函数从校正后的复信号中提取瞬时相位。针对大位移引起的相位跳变问题，采用相位解缠算法还原出连续的相位演变曲线。此时，相位序列在物理上已直接映射为受试者胸腔的位移轨迹。

紧接着，本文对解调后的位移信号执行了线性去趋势处理。随后，设计了 4 阶巴特沃斯带通滤波器，其中截止频率 0.1Hz-0.5Hz，并采用双向零相位滤波技术进行处理。该步骤不仅能滤除环境噪声与心跳干扰，还能确保呼吸波形在时域上无相位延迟，维持波形的形态特征。

4.2.2 TCN-Transformer 实现

针对呼吸信号中同时存在的局部形态特征与长程周期依赖现象，本文提出一种双路并行混合网络。整体结构如图 4.5(a)，TCN 网络的结构如图 4.5(b)，Transformer 则是使用了其编码器部分如图 4.5(c)，最后的解码器部分的结构如图 4.5(d) 所示。接下来分别介绍算法的各个模块。

首先介绍通道注意力预处理模块 SE。给定输入序列 $\mathbf{X} \in \mathbb{R}^{B \times C \times L}$ ，其中 B 为批大小， $C = 5$ 表示为 5 个被选择距离单元， $L = 256$ 为序列长度。首先通过 SE 模块进行通道重标定：

$$s = \sigma \left(W_2 \cdot \delta \left(W_1 \cdot \frac{1}{L} \sum_{i=1}^L \mathbf{X}_{:, :, i} \right) \right) \quad (4-2)$$

其中 $W_1 \in \mathbb{R}^{C/r \times C}$ ， $W_2 \in \mathbb{R}^{C \times C/r}$ ， $r = 4$ 为压缩比， δ 为 ReLU 激活， σ 为 Sigmoid 函数。最终输出 $\tilde{\mathbf{X}} = s \odot \mathbf{X}$ ，实现对多传感器通道的自适应加权。

其次是双路并行模块。第一条路径是 TCN，为捕捉呼吸信号的局部形态特征，构建 5 层

膨胀卷积堆叠，其中卷积核大小均为 5，膨胀率 $d_k \in \{1, 2, 4, 8, 16\}$ 呈指数增长，感受野逐层扩大至 125 个时间点。残差连接 $\text{Res}(\cdot)$ 在通道数变化时采用 1×1 卷积对齐。该路径输出特征 $\mathbf{F}_{\text{TCN}} \in \mathbb{R}^{B \times L \times D}$ ，其中 $D = 64$ 为特征维度。

第二条路径是 Transformer 编码器。为建模呼吸信号的远程周期依赖，引入轻量级 Transformer 编码器。首先通过逐点卷积将输入映射至 D 维：

$$\mathbf{Z} = \text{Conv1D}_{1 \times 1}(\tilde{\mathbf{X}}) \in \mathbb{R}^{B \times D \times L} \quad (4-3)$$

随后添加正弦余弦位置编码以保留时序信息：

$$\text{PE}_{(pos, 2i)} = \sin(pos/10000^{2i/D}), \quad \text{PE}_{(pos, 2i+1)} = \cos(pos/10000^{2i/D}) \quad (4-4)$$

编码器堆叠 2 层，每层包含 8 头自注意力与前馈网络，采用残差连接与层归一化。该路径输出特征 $\mathbf{F}_{\text{Trans}} \in \mathbb{R}^{B \times L \times D}$ 。




图 4.5 网络整体架构图

最后是自适应融合与解码模块。为避免双路特征冗余并发挥各自优势，提出加权融合策略。考虑到呼吸形态的局部性优于全局性，以 TCN 特征为主、Transformer 特征为辅：

$$\mathbf{F}_{\text{fuse}} = \text{LayerNorm}(\mathbf{F}_{\text{TCN}} + \lambda \cdot \mathbf{F}_{\text{Trans}}) \quad (4-5)$$

本文设 $\lambda = 0.2$ ，即 Transformer 作为全局修正项。最终通过两层全连接网络解码得到逐点预测输出：

$$\hat{y} = \mathbf{W}_4 \cdot \delta(\mathbf{W}_3 \cdot \mathbf{F}_{\text{fuse}}^\top) \in \mathbb{R}^{B \times L} \quad (4-6)$$

其中 $\mathbf{W}_3 \in \mathbb{R}^{D/2 \times D}$, $\mathbf{W}_4 \in \mathbb{R}^{1 \times D/2}$, δ 为 LeakyReLU 激活。该设计在保持局部形态精度的同时引入全局上下文修正, 有效提升了呼吸波形重建的准确性与鲁棒性。

4.2.3 损失函数设计

呼吸信号重建任务的核心挑战在于同时保持波形的时域形态相似性与频域周期一致性。本文设计了一个组合损失函数, 由负皮尔逊相关系数损失与频率一致性损失加权构成:

$$\mathcal{L} = \mathcal{L}_{\text{pearson}} + \lambda \cdot \mathcal{L}_{\text{freq}}, \quad \lambda = 0.01 \quad (4-7)$$

皮尔逊相关系数衡量两个信号之间的线性相关程度, 具有对幅值缩放与整体平移不敏感的特性, 非常适合呼吸波形形态评估。给定预测信号 $\hat{y} \in \mathbb{R}^L$ 与真实信号 $y \in \mathbb{R}^L$, 定义损失如下:

$$\mathcal{L}_{\text{pearson}} = 1 - \frac{\sum_{i=1}^L (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^L (\hat{y}_i - \bar{\hat{y}})^2} \cdot \sqrt{\sum_{i=1}^L (y_i - \bar{y})^2}} \quad (4-8)$$

其中 $\bar{\hat{y}}$ 与 $\bar{y}$ 分别为预测信号与真实信号的均值。该损失函数取值范围为 $[0, 2]$, 当且仅当 $\hat{y}$ 与 y 完全正相关时取得最小值 0。相较于均方误差 (Mean Squared Error, MSE), 皮尔逊损失关注波形形态而非绝对幅值, 更符合呼吸信号评估的临床需求。

仅凭时域损失难以保证预测波形的频谱特性与真实呼吸信号一致, 可能导致模型产生周期失真的输出, 因此引入频域约束项:

$$\mathcal{L}_{\text{freq}} = \frac{1}{K} \sum_{k=1}^K (|\mathcal{F}(\hat{y})_k| - |\mathcal{F}(y)_k|)^2 \quad (4-9)$$

其中 $\mathcal{F}(\cdot)$ 表示实数傅里叶变换, 取幅度谱后保留低频部分。设序列长度 $L = 256$, 保留频率索引 1 至 11, 对应呼吸信号的主要能量频段。该损失项作为正则化项, 引导模型生成具有正确周期结构的波形。

两项损失采用加权求和, 权重系数 $\lambda = 0.01$ 。皮尔逊损失为主项, 主导模型学习波形的基本形态与相位对齐, 频率损失为辅助正则项, 防止模型在时域拟合过程中丢失频域周期性结构, 较小权重可以避免频域约束过度限制模型的时域表达能力。

该组合损失函数在呼吸信号重建任务中实现了时域形态与频域特性的协同优化, 有效提升了波形重建的准确性与生理合理性。

4.3 本章小结

本章的主要内容就是详细的阐述了基于 TCN 与 Transformer 的网络架构设计思想和基本原理。首先对输入网络前的信号处理部分进行了介绍，其次对该网络结构内部的几个主要模块的设计与参数配置这些具体细节进行了深入的探讨。最后，本章将理论和具体情况相结合，针对该网络设计了有效的损失函数。上述的这些内容是本文模型的关键，同时也为下一章节的实验提供了算法基础。

第五章 实验分析

5.1 实验设置

本文研究采用 TI IWR1642 商用级雷达如图 5.1(a) 所示, 该设备的工作频段为 76-81GHz, 2 个发射天线, 4 个接收天线。在数据采集的过程中, 如图 5.1(b) 所示, 受试者躺在床上, 使雷达放置在受试者胸前大约 20 到 30cm 处, 配合使用心电监护仪, 同时开始采集, 一次的采集时间为 1 分钟, 每位受试者采集 3 次。本次数据集一共使用了 80 名受试者的呼吸数据。由于采集过程中存在一些外界干扰或者设备异常问题, 部分数据存在异常, 经过数据质量检测, 移除异常数据, 滑窗切片后, 本次实验共使用了 10945 个样本, 其中训练集 8250 个、验证集 1485 个和测试集 1210 个, 是按照受试者进行严格划分的。



(a) TI IWR1642 商用雷达



(b) 呼吸采集场景

图 5.1 采集设备场景图

在代码的参数设置中, 雷达慢时间采样频率设定为 50Hz, 能够满足 0.1Hz-0.5Hz 的呼吸信号的奈奎斯特采样定律。信号处理部分, 采用 4 阶巴特沃斯带通滤波器, 截止频率设定为 [0.1, 0.5]Hz, 滤除环境噪声及受试者心跳的干扰。Range-FFT 点数设定为 128。目标定位区间限定在第 2 至 25 个距离单元内, 对应约 0.2m-1.5m 范围, 选取目标单元及其邻近共 5 个距离单元构建空间特征矩阵, 特征维度设定为 64。网络部分的 TCN 由 5 层膨胀残差块组成, 膨胀因子按 [1, 2, 4, 8, 16] 指数递增。Transformer 编码器采用 8 头自注意力机制, Encoder 层数为 2。使用 Adam 优化器, 初始学习率设为 $5e-5$, 批大小设定为 64, 训练轮次为 50 轮。

5.2 评价指标

为了全面评估呼吸信号重建性能, 本文将从时域形态相似度、频域频率准确性及峰值时序对齐三个维度选取评价指标。最终选择了下面三个指标进行评判。

皮尔逊相关系数用来衡量预测波形与真实波形的线性相关程度，聚焦于波形形态与相位对齐情况，而对幅值缩放与整体平移具有一定的鲁棒性。定义为：

$$\text{PCC} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2} \cdot \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}} \quad (5-1)$$

其中 $\hat{y}_i$ 与 y_i 分别为预测信号与真实信号在第 i 个采样点的幅值， N 为信号长度。PCC 取值范围 $[-1, 1]$ ，值越接近 1 表示重建波形与真实波形越一致。通常皮尔逊相关系数的数值可以分成 5 个层级如表 5.1 所示。

表 5.1 皮尔逊相关系数范围对应相关强度层级

相关系数范围	相关强度层级
0.8-1.0	极强相关
0.6-0.8	强相关
0.4-0.6	中度相关
0.2-0.4	弱相关
0.0-0.2	极弱或无相关

呼吸率是显示呼吸质量的一个重要指标。本文采用频域峰值法提取呼吸率：对信号进行快速傅里叶变换，在 0.1 ~ 0.6 Hz 内寻找幅度谱峰值对应的频率，乘以 60 转换为 BPM。呼吸率绝对误差定义为：

$$\text{MAE}_{\text{BPM}} = |\text{BPM}_{\text{pred}} - \text{BPM}_{\text{truth}}| \quad (5-2)$$

该指标直接反映了模型对呼吸频率估计的准确性，这个指标的值越低表示频率估计越精确。

最后，使用平均峰值时间误差评估呼吸波形的相位对齐精度。峰值的对应关系最能体现相位的对齐程度。首先对预测信号与真实信号进行 z-score 归一化处理，采用峰值检测算法分别提取两组信号峰值的位置，设定最小峰间距为 1.5 秒，峰高阈值为 0.5。对每个预测峰值，寻找与之最近的真实峰值，计算时间差的绝对值并取平均：

$$\text{TPE} = \frac{1}{M} \sum_{i=1}^M \min_j \frac{|p_i - t_j|}{f_s} \quad (5-3)$$

其中 p_i 为预测信号峰值位置， t_j 为真实信号峰值位置， M 为预测峰值数量， $f_s = 50$ Hz 为采样频率。TPE 以秒为单位，值越小表示峰值时序对齐越准确。

上述的三个指标不仅能量化波形的形态相似度，还能捕捉呼吸频率的偏移与峰值位置的同步偏差，从而确保了重建后的呼吸信号在未来的临床诊断和生命体征监测应用中具备一定的可靠性。同时本文也是通过上述三个指标进行对比实验和消融实验。

5.3 实验结果

针对第四章节的算法架构以及对采集的数据集进行充分训练，本文模型已经具备对毫米波雷达回波信号进行稳定的波形重建与呼吸率预测的能力。由表 5.2 可以看到本文模型的 PCC 指标也就是皮尔逊相关系数已经达到了 0.8402，再根据表 5.1 可知模型重建的波形已经达到了极强的相关性。图 5.2 展示了由该模型重建的波形和通过监护设备监测到的真实波形之间的对比效果，可以看出蓝色的预测波形的相位、波峰等都很好的和真实波形对齐。同时，MAE 指标也达到了 0.3091BPM，也就是说平均每分钟的呼吸次数只差 0.3091 次，相对于一个人呼吸每分钟 16-20 次，可以说是非常小的误差，这个数值在日常健康监护中几乎可以忽略不计。




图 5.2 预测波形与真实波形对比图

同时本文在预先划分的独立测试集上与多种基线模型进行了对比实验，包括传统信号处理方法（Tradition）、TransUNet、ConvGRU。对比实验可以验证本文提出的 TCN-Transformer 网络方法的有效性，各模型在相同测试集上的性能对比如表 5.2 所示。

表 5.2 所有方法的各项指标比较

模型	PCC↑	MAE↓	TPE↓
Tradition(Baseline)	0.7394	1.0000	0.2289
TransUNet	0.8159	0.3095	0.3869
ConvGRU	0.8093	0.3095	0.3736
TCN-Transformer	0.8402	0.3091	0.3528

在波形相似度指标 PCC 上，本文方法取得了最高的 PCC 值为 0.8402，分别比传统方法、TransUNet 和 ConvGRU 提高了 13.6%、2.9% 和 3.8%。这归功于本文设计的双路特征融合架构很好地抓住了呼吸信号的局部形态特征和全局长依赖关系，该网络能够更准确地重建呼吸波形的整体形态。相比之下，传统方法仅依赖于带通滤波和圆拟合解调，在处理含有噪声或由

于人体微动引起的非线性相位偏移时,难以还原真实的波形细节,导致 PCC 较低。TransUNet 和 ConvGRU 虽然也具备特征提取能力,但前者在处理长序列一维信号时存在计算冗余,后者在捕捉超长距离依赖时可能存在梯度衰减问题,因此这两个模型的表现略逊于本文的方法。图 5.3 展示了某一份雷达数据经过三种深度学习模型处理后的对比图。




图 5.3 三种网络的预测波形对比

在呼吸率估计方面,本文方法达到了 0.3091BPM,虽然相较于 TransUNet 和 ConvGRU 这两个网络相差不大,但是比起 Tradition 方法下降了 69.09%,展现出来较好的性能,基于数据驱动的深度模型通过大量的样本学习,已经能够精准地识别呼吸引起的周期性特征,并有效抑制了频谱中的杂波干扰。很大程度上提高了呼吸频率的准确性。

在峰值对齐方面,本文模型的 TPE 值达到了 0.3528s,和另外两种深度学习模型相比较确实有所降低,但是 Tradition 方法却达到了所有模型中的最低值 0.2289。传统方法直接对解调后的相位进行窄带滤波,它的波形峰值通常直接对应信号能量的最强点,在信号质量较好的雷达信号上能够直接锁定位置。然而,其他的三种深度学习模型为了追求更高的 PCC 指标,所以在优化过程中对波形进行一定的平滑处理,降低了瞬时噪声的影响,这就导致了预测峰

值位置与真实值之间存在一个微小的偏移。尽管本文模型的 TPE 略高于传统方法，但在其他两个深度学习模型中却是表现最好的。

因此可以看出本文提出的 TCN-Transformer 模型在维持极低呼吸率误差的基础上，实现了对呼吸波形形态的高精度重建。虽然传统方法在特定条件的峰值对齐上具有优势，但本文模型在整体相关性和频率的稳定性上的表现良好，证明了其在非接触式呼吸监测领域具有一定的潜力。

最后本文还基于 Streamlit 构建了网页端的交互式前端监测平台，通过这个频台能够直观的展示波形重建的效果。用户通过“Browse files”按钮即可自主的加载待测的原始数据，系统后端接收到预测的命令时就会调用部署好的最优模型权重进行波形的重建和呼吸率的预测。点击“执行模型推理”后，页面将呈现重建后的呼吸时域波形图，并输出其对应的呼吸率数值，如图 5.4 所示。该平台的实现不仅直观的展示了算法的推理效率，也为后续在家庭监护或者临床辅助场景中的实际应用提供了原型参考。




图 5.4 前端页面

5.4 消融实验

本文的模型主要由 3 个核心模块组成，因此设计了消融实验来验证各个模块的有效性。分别通过移除 Transformer 路径、TCN 路径和 SE 模块后的网络结构，同时保证其他参数的不变性，将他们对测试集进行预测，观察模型性能是否发生了变化。消融实验结果如表 5.3 所示。

(1) Transformer 模块的必要性：去除 Transformer 路径后，PCC 从 0.8402 下降至 0.7591，MAE 从 0.3091 上升至 0.4323，TPE 从 0.3528 上升至 0.4160。这一现象表明，虽然 TCN 能够还原波形，但在应对长距离的时间依赖和周期稳定性方面仍有局限性。Transformer 路径通过自注意力机制对全局信息进行建模，能够有效识别并修正呼吸节律中的漂移成分。图 5.5 的 Model1 展示的正是去除 Transformer 后的波形状态。

表 5.3 消融实验各指标对比

模型	PCC↑	MAE↓	TPE↓
MyNet (去除 Transformer)	0.7591	0.4323	0.4160
MyNet (去除 TCN)	0.3548	0.4533	0.9178
MyNet (去除 SE 模块)	0.8400	0.3810	0.3568
MyNet	0.8402	0.3091	0.3528

(2) TCN 模块的必要性：去除 TCN 路径后，PCC 指标从 0.8402 锐减至 0.3548，同时 TPE 误差大幅上升至 0.9178。说明波形的相似度已经到了弱相关的程度，且波峰相差巨大，如图 5.5 的 Model2，整个波形都是锯齿状。TCN 主要依靠的是多层扩张卷积提供的宽阔感受野，负责从原始相位信号中提取时域波形特征的主要任务。再失去 TCN 路径后，模型难以捕捉呼吸信号的局部形态演变，只在乎全局，导致重建波形与真实标签严重失调。




图 5.5 四种消融后的网络预测波形对比

(3) SE 模块的必要性：但是去除 SE 模块后，PCC 基本保持不变，但 MAE 从 0.3091 升高到了 0.3810。整个波形状态如图 5.5 的 Model3 并没有太大的影响。这可能是因为 SE 模块在本文网络中的主要作用就是选择信号质量好的通道，它通过特征加权的方式对提取的 5 个雷达 Bin 通道信号进行处理，信噪比不佳的通道会被抑制，信噪比较好的通道会被强化。如

果数据中能量峰值较为单一，那么 SE 模块起到的效果不大。实验中去除 SE 模块之后指标变化比较微弱，说明数据集的质量整体较好，只对个别数据存在的多峰值问题进行了优化。

上述的消融实验分别证明了本文所提网络中各个模块的价值，TCN 路径负责构建波形基础，起的作用最大，Transformer 路径提供全局节律修正功能，起次要作用，而 SE 模块则是通过通道注意力机制选择优化特征质量，起修正作用。三个模块各司其职、优势互补，它们的有机结合在所有指标上均达到了最优表现。

5.5 本章小结

本章主要对实验的设置包括数据采集、软硬件参数设置进行了详细的介绍。其次罗列了实验中需要使用到的评价指标及其公式表达。接着对这个网络进行了实验，包括对比试验和消融实验。对比试验中主要和传统方法（Tradition）、TransUNet 以及 ConvGRU 进行了对比，本文模型相比其他模型展现出了较好的性能。消融实验则是通过删除 SE 模块、TCN 模块、Transformer 模块来证明了这些模块的必要性。经过大量的实验证明，并行的 TCN-Transformer 网络能够很好的重建呼吸波形和预测呼吸率，为使用毫米波雷达监测呼吸提供了新的方法。

第六章 总结与展望

本文首先对非接触式生命体征监测领域进行了深入调研，针对毫米波雷达在实际应用中易受直流偏移、环境杂波及微动干扰等痛点，制定了从原始雷达信号解调到高层深度学习建模的系统方案。在前期准备中，本文通过各种雷达信号处理算法，为后续特征学习奠定了坚实的物理基础。设计层面，本文构建了一套融合通道注意力机制 SE 与 TCN-Transformer 双路混合架构的重建模型，旨在通过技术手段协调呼吸信号提取过程中的形态保真度与频率稳定性。

全篇论文以非接触式呼吸波形重建为主要目标进行研究，对数据集进行了有效的预处理工作以及信号处理任务，同时也对模型进行不断地尝试和优化，最终通过三个评价指标对模型在测试集的效果进行了评价并得到了理想的结论。本文的核心创新点在于融合了 TCN 路径与 Transformer 路径，完成了双路并行的网络设计，并在进入双路径之前使用 SE 模块对 5 个距离单元进行特征加权，聚焦质量最好的通道。在实验分析部分，本文方法通过与 Tradition、TransUNet 及 ConvGRU 模型的对比展现处理其在波形相关性与呼吸率估算精度上的优势。消融实验也进一步展现了各核心模块的不可或缺性。

虽然本文方法在全局波形重建上有着很好的效果，但是在局部的峰值精准对齐上也就是 TPE 指标，与传统算法相比还是存在一定的差距。为此，未来的研究方向可以考虑在损失函数中引入时域峰值约束项，在训练过程中不断提升波峰波谷的定位精度。除了局部峰值对齐方面，目前的模型的训练场景主要是静态场景，为了更全面地契合人体活动影响，后续的探索方向可以尝试针对大幅度体动干扰的动态补偿策略，或者进行模型轻量化改进，从而更好地推进其在家庭智慧养老和临床监护等实际场景中的落地应用。

参考文献

- [1] Kebe M, Gadhaifi R, Mohammad B, et al. Human vital signs detection methods and potential using radars: A review[J]. *Sensors*, 2020, 20(5): 1454.
- [2] Senaratna C V, Perret J L, Lodge C J, et al. Prevalence of obstructive sleep apnea in the general population: a systematic review[J]. *Sleep Medicine Reviews*, 2017, 34: 70–81.
- [3] Mei F, Dalmartello M, Bonifazi M, et al. Chronic obstructive pulmonary disease (COPD) mortality trends worldwide: An update to 2019[J]. *Respirology*, 2022, 27(11): 941–950.
- [4] Wang Y, Xu C, Zhang B, et al. Fine-grained contactless human respiratory measurement using millimeter-wave radar[J]. *IEEE Transactions on Instrumentation and Measurement*, 2026, 75: 1–15.
- [5] Leo M, Carcagnì P, Mazzeo P L, et al. Analysis of facial information for healthcare applications: A survey on computer vision-based approaches[J]. *Information*, 2020, 11(3): 128.
- [6] Chen C, Zhou G, Lin Y. Cross-domain WiFi sensing with channel state information: A survey[J]. *ACM Computing Surveys*, 2023, 55(11): 1–37.
- [7] Hou F, Zhang Y, Zhou Y, et al. Review on infrared imaging technology[J]. *Sustainability*, 2022, 14(18): 11161.
- [8] Venon A, Dupuis Y, Vasseur P, et al. Millimeter wave FMCW radars for perception, recognition and localization in automotive applications: A survey[J]. *IEEE Transactions on Intelligent Vehicles*, 2022, 7(3): 533–555.
- [9] Johansen E L. Millimeter-wave radar[J]. *Active Electro-Optical Systems*, 1993, 5.
- [10] Yan B, Roberts I P. Advancements in millimeter-wave radar technologies for automotive systems: A signal processing perspective[J]. *Electronics*, 2025, 14(7): 1436.
- [11] Mallat N K, Ishtiaq M, Ur Rehman A, et al. Millimeter-wave in the face of 5G communication potential applications[J]. *IETE Journal of Research*, 2022, 68(4): 2522–2530.
- [12] 刘英豪. 基于毫米波雷达的非接触式生命体征检测算法研究[D]. 济南大学, 2024.
- [13] Li Z, Liu F, Yang W, et al. A survey of convolutional neural networks: analysis, applications, and prospects [J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2021, 33(12): 6999–7019.
- [14] Mienye I D, Swart T G, Obaido G. Recurrent neural networks: A comprehensive review of architectures, variants, and applications[J]. *Information*, 2024, 15(9): 517.
- [15] Ghogh B, Ghodsi A. Recurrent neural networks and long short-term memory networks: Tutorial and survey [J]. *arXiv preprint arXiv:2304.11461*, 2023.
- [16] Purwono P, Wulandari A N E, Ma'arif A, et al. Understanding generative adversarial networks (GANs): A review[J]. *Control Systems and Optimization Letters*, 2025, 3(1): 36–45.
- [17] Han K, Xiao E A. Wu, et al. Transformer in transformer[C]. *Advances in Neural Information Processing Systems*: volume 34. [S.l.: s.n.], 2021: 15908–15919.
- [18] Corso G, Stark H, Jegelka S, et al. Graph neural networks[J]. *Nature Reviews Methods Primers*, 2024, 4(1):

- 17.
- [19] Cheng W, Wang Y, Peng Z, et al. High-efficiency chaotic time series prediction based on time convolution neural network[J]. *Chaos, Solitons & Fractals*, 2021, 152: 111304.
- [20] Van N T P, Tang L, Singh A, et al. Self-identification respiratory disorder based on continuous wave radar sensor system[J]. *IEEE Access*, 2019, 7: 40019–40026.
- [21] Rathna G N, Meshineni D. Analysis of FM CW-radar signals to extract vital-sign information[C]. 2021 IEEE International Conference on Electronics, Computing and Communication Technologies (CONECCT). 2021: 1–6.
- [22] Lauteslager T, Maslik M, Siddiqui F, et al. Validation of a new contactless and continuous respiratory rate monitoring device based on ultra-wideband radar technology[J]. *Sensors*, 2021, 21(12): 4027.
- [23] Gao Z, Ali L, Wang C, et al. Real-time non-contact millimeter wave radar-based vital sign detection[J]. *Sensors*, 2022, 22(19): 7560.
- [24] Ebrahim M P, Tom N, Redoute J M, et al. A low-frequency portable continuous wave radar system for vital signs monitoring[J]. *IEEE Sensors Journal*, 2023, 23(8): 8876–8886.
- [25] Wang S, Han C, Guo J, et al. Mm-fgrm: Fine-grained respiratory monitoring using MIMO millimeter wave radar[J]. *IEEE Transactions on Instrumentation and Measurement*, 2023, 73: 1–13.
- [26] Bauder C, Moadi A K, Rajagopal V, et al. Mm-mure: mmwave-based multi-subject respiration monitoring via end-to-end deep learning[J]. *IEEE Journal of Electromagnetics, RF and Microwaves in Medicine and Biology*, 2024.
- [27] Xie Z, Wang H, Han S, et al. DeepVS: a deep learning approach for RF-based vital signs sensing[C]. *Proceedings of the 13th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*. [S.l.: s.n.], 2022: 1–5.
- [28] Sreedevi S. Study of test for significance of Pearson’s correlation coefficient[J]. *Peer Rev. Ref. J*, 2022, 11 (2): 11.
- [29] Hao Z, Wang Y, Li F, et al. Detection of vital signs based on millimeter wave radar[J]. *Scientific Reports*, 2025, 15(1): 28112.
- [30] Grisot R. Extraction of vital signs with millimeter-wave FM-CW radar[D]. Université Côte d’Azur, 2024.
- [31] 刘震宇, 李成光, 王梓斌. 基于改进奇异谱分析的毫米波生物雷达干扰抑制方法[J]. *广东工业大学学报*, 2024, 41(1): 47–54.
- [32] Fusco A, Lavronenko K, Sakharov S, et al. Multi-range breathing rate estimation with deep learning using FMCW radar[J]. *IEEE Sensors Journal*, 2025.
- [33] Kaur M, Singh B, Ubhi J S, et al. Digital filtration of ECG signals for removal of baseline drift[C]. *Proceedings of International Conference on Computer Communication and Management (ICCCM 2011)*: volume 5. [S.l.: s.n.], 2011.
- [34] Szandała T. Review and comparison of commonly used activation functions for deep neural networks[M]. *Bio-inspired Neurocomputing*. Singapore: Springer Singapore, 2020: 203–224.

- [35] Zafar A, Aamir M, Mohd Nawi N, et al. A comparison of pooling methods for convolutional neural networks [J]. *Applied Sciences*, 2022, 12(17): 8643.
- [36] Mahmoud A, Mohammed A. Enhancing time series forecasting: a hybrid TCN-transformer approach[J]. *Neural Computing and Applications*, 2026, 38(9): 342.
- [37] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. *Advances in Neural Information Processing Systems: volume 30*. [S.l.: s.n.], 2017.
- [38] Irani H, Metsis V. Positional encoding in transformer-based time series models: A survey[J]. *arXiv preprint arXiv:2502.12370*, 2025.

致谢

时光飞逝，转瞬之间，我的大学本科生涯已接近尾声。此文是对我大学四年学业的总结与交卷，站在人生的十字路口，伫立回望，四年的求学之路上凝聚了太多人的关怀、指导与陪伴。借此机会，谨以此文向所有给予我支持与帮助的人表达我最诚挚的感激之情。

首先，我要向我的导师韩老师表示感谢。在本篇毕业论文的撰写与研究过程中，韩老师给予了我全方位的悉心指导。在科研学术上，韩老师为我指明了严谨且可靠的研究方向，并在实验遇到瓶颈时多次为我答疑解惑，使我最终能够顺利完成本科阶段的科研目标。

其次，我要感谢我的同学和室友。大学四年的朝夕相处，让我们结下了深厚的友谊。感谢同学们在学习与生活上给予我的无私帮助，构成了我青春里最美好的回忆。最后，我还要感谢我的家人。家人是我在求学路上克服一切困难的力量源泉。是他们无微不至的关心与包容，才让我不断的克服困难。谢谢你们的付出与支持。