

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于空频特征融合的遥感目标检测算法研究

学	号	<u>B22040004</u>
姓	名	<u>谢睿琪</u>
导	师	<u>郑尚东</u>
专业学位类别		<u>计算机</u>
类	型	<u>毕业论文</u>
专业（领域）		<u>计算机科学与技术</u>
论文提交日期		<u>2026年6月12日</u>

摘要

遥感图像目标检测在灾害监测预警、现代城市规划等诸多领域具有重要的应用价值。然而，真实的遥感图像通常具有背景极其复杂、目标尺度多变且呈旋转方向密集排列的特点，准确识别目标面临多种挑战。主流检测算法主要依靠传统的空域卷积神经网络来完成特征提取工作，由于模型存在固定感受野和局部滑动窗口的局限，传统模型难以确识别边缘、纹理细节，并且不能对多向旋转变换特征进行有效建模，极易导致定位偏离与回归震荡。

本文针对上述问题，提出一种将空频特征进行融合的空间频率特征融合遥感旋转目标检测算法 OES-ORCNN。该算法以业内主流的两阶段旋转检测器 Oriented R-CNN 作为基线框架，并且加入双域特征交互模块，设计核心是特征提取网络中植入的 SFF 模块：频域层面，利用 Haar 离散小波变换将特征按不同方向进行分解，精准提取目标在水平、垂直以及对角线方向上的物理边界以打破常规卷积的方向感知盲区；空域层面，则依靠骨干网络输出蕴含宏观语义的空域上下文特征，并借助交叉注意力机制引导双域特征深度聚合从而大幅抑制复杂背景干扰。模型还在骨干网络中配置了可变形卷积，在回归头中用旋转 IoU 损失代替传统损失函数，优化方法产生正向协同，提升了网络对复杂旋转目标的特征表达能力，并且改善了模型处理密集旋转目标时的边界框拟合质量。

本文在权威的大规模遥感公开数据集 DOTA v1.0 上进行实验，以检验所提算法的有效性。评估结果表明，采用 ResNet-50 作为特征提取骨干时，模型的 mAP 达到 78.69%，相较基线模型提升幅度超过 1%，特别是在小型车辆等小尺度的旋转目标类别上，模型敏感度与定位精度均获得了明显提升，充分展现出该算法在复杂场景下卓越的检测鲁棒性与高精度的旋转边界框拟合能力。

关键词：遥感图像，目标检测，空频特征融合，旋转目标检测

Abstract

Remote sensing image target detection has always been a core research direction in the field of computer vision, and has wide application value in many fields. However, real remote sensing images usually have the characteristics of extremely complex background, variable target scale and dense arrangement in the direction of rotation. Limited by the fixed receptive field and local sliding window paradigm, conventional CNN is not only difficult to capture edge and texture details, but also unable to effectively model multi-directional rotation transformation features, which can easily lead to positioning deviation and regression shock.

This study proposes a remote sensing rotating target detection algorithm OES-ORCNN based on Spatial-Frequency Feature Fusion (SFF). The algorithm uses the industry 's mainstream two-stage rotation detector Oriented R-CNN as the baseline and implants a dual-domain feature interaction architecture, aiming to improve the network 's ability to express features of complex rotating targets. In the specific model design, the innovation is mainly reflected in the implantation of SFF module in the feature extraction network : at the frequency domain level, the Haar discrete wavelet transform (DWT) is used to decompose the features in different directions, and the physical boundaries of the target in the horizontal, vertical and diagonal directions are accurately extracted to break the direction perception blind area of conventional convolution ; at the spatial level, it relies on the backbone network to output the spatial context features containing macro semantics, and uses the Cross-Attention mechanism to guide the deep aggregation of dual-domain features to greatly suppress complex background interference.

In order to verify the effectiveness of the above OES-RCNN algorithm, this paper conducts sufficient experiments on the authoritative large-scale remote sensing public data set DOTA v1.0. The evaluation results show that when ResNet-50 is used as the backbone network for feature extraction, the mAP of the model reaches 78.69 %, which is over 1 % higher than that of the baseline model. Especially in small-scale rotating target categories (such as small vehicles, helicopters, etc.), the model sensitivity and positioning accuracy have been substantially improved, which fully demonstrates its excellent detection robustness and high-precision rotating bounding box fitting ability in complex scenes.

Key Words: Remote Sensing Imagery, Object Detection, Spatial-Frequency Feature Fusion, Oriented Object Detection

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
专用术语注释表	VI
第一章 绪论	1
1.1 研究背景和意义	1
1.2 研究现状	1
1.2.1 遥感目标检测发展现状	1
1.2.2 旋转目标检测算法研究现状	2
1.3 研究内容和章节安排	3
第二章 相关背景知识介绍	5
2.1 引言	5
2.2 基础特征提取技术	5
2.2.1 残差骨干网络 ResNet	5
2.2.2 多尺度特征金字塔 FPN	6
2.3 旋转目标检测与空间优化机制	7
2.3.1 Oriented R-CNN 基线网络	7
2.3.2 可形变卷积与动态感受野	8
2.3.3 旋转边界框回归与损失机制	9
2.4 二维离散小波变换	9
2.5 本章小结	10
第三章 基于空频特征融合的遥感目标检测研究	11
3.1 引言	11
3.2 整体网络架构	11
3.2.1 主干网络	11
3.2.2 特征金字塔	12
3.3 空频特征融合模块设计	13
3.3.1 频域定向特征提取	13
3.3.2 空频融合交叉注意力机制	14
第四章 实验设计	16
4.1 实验设计	16
4.2 结果分析与讨论	16
4.2.1 评价指标	16
4.2.2 整体检测性能分析	17
4.2.3 核心模块消融实验分析	18
第五章 遥感目标检测系统的设计与实现	21
第六章 总结与展望	22
6.1 本文工作总结	22
6.2 进一步研究方向	22
参考文献	24

插图索引

图 2.1	ResNet 基本残差单元结构图	6
图 2.2	特征金字塔示意图	7
图 2.3	中点偏移法	8
图 2.4	小波变换	10
图 3.1	模型结构示意图	12
图 3.2	SFF 模块内部计算示意图	15
图 4.1	遥感图像飞机目标旋转检测结果对比图	17
图 4.2	OES-PRCNN 和 ORCNN 模型性能对比	18
图 4.3	消融实验在 DOTA _v 1.0 上指标对比	19

表格索引

表 4.1 OES-ORCNN 在 DOTA v1.0 数据集上的各类别平均精度 17

表 4.2 消融实验性能对比 19

专用术语注释表

缩略词说明：

缩写	英文全称
CNN	Convolut

第一章 绪论

1.1 研究背景和意义

计算机视觉研究中,对指定视觉场景中的特定实体进行准确的定位和识别,一直是一个重要课题。近几年,航空航天技术和对地观测网络持续更新,高分辨率遥感数据数量迅速增加,给现代遥感技术带来新的机会和挑战。遥感图像目标检测是把计算机视觉和传统摄影测量结合起来的交叉任务。该任务在军事侦察、城市规划等关系到国计民生的重要领域中,都起到了无法替代的基础作用。深度学习技术进步虽然提高该领域性能上限,但是大尺度遥感图像含有大量复杂背景,如何在信息提取上保持高效和准确,依然是产学研各方需要解决的问题。

由于遥感具有垂直俯视成像方式,自动驾驶等自然场景下成熟的通用目标检测算法很难直接移植到遥感领域。遥感角度下的船舶或车辆等实体在多分辨率下尺度跨度很大,并且经常以任意方向呈现高密度堆叠趋势。遥感影像通常覆盖非常广阔的地理区域,并且伴随有变化的光照、非常复杂的背景地物。传统的基于水平边界框^[1] (Horizontal Bounding Box, HBB) 的检测方法在处理倾斜或者密集分布的目标时会圈入无效背景像素,使相邻目标的预测框出现严重的交叉重叠。

学术界引入了旋转目标检测 (Oriented Object Detection, OOD) 技术^[2] 来处理多尺度和高密度问题,该技术利用带有角度参数的旋转边界框 (Oriented Bounding Box, OBB) 对任意方向实体实施紧密包围,过这种方式过滤冗余背景像素并且提高对密集排列实体的分辨能力。在该方式下,许多优秀的旋转检测算法出现,促进了领域的发展。ReDet^[3] 使用旋转等变卷积网络,从特征提取的底层数学逻辑上探索目标的旋转自适应性, Oriented R-CNN^[4] 等先进两阶段检测器则利用优秀的旋转区域提名网络 (Oriented RPN) 来实现高召回率和计算效率的平衡。这些前沿成果在遥感检测领域取得了令人瞩目的成绩,也给本文高精度目标定位分析提供了可以参考的模式基础。

1.2 研究现状

1.2.1 遥感目标检测发展现状

早期遥感图像目标检测主要运用传统机器学习、数字图像处理技术。基于模板匹配 [8] 和先验知识的方法相对最为原始,前者需要人工制备目标模板然后在图像上滑动模板并计算匹配度,后者使用几何知识和上下文知识进行目标识别。

传统机器识别中,目标检测属于分类问题,通过提取潜在区域的 HoG 特征、BoW 特征、

纹理特征、上下文特征等，并根据提取到的特征信息对目标进行分类，确定该子区域中是否包含目标。受制于特征提取器不能端对端训练、模型计算开销大等缺点，基于机器学习的方法不再是该领域的研究重点。

1.2.2 旋转目标检测算法研究现状

相比自然场景图像，遥感图像中的目标通常具有方向任意、尺度变化显著以及密集分布等特点，导致传统的基于水平边界框 HBBs 的检测方法包含大量背景冗余，且极易在密集排列时发生框重叠。为了解决这一问题，研究者们提出了定向边界框表示法，并推出基于 Faster R-CNN、RetinaNet 以及 YOLO 等通用目标检测框架改进而来的旋转目标检测算法，在 DOTA、DIOR 等多个遥感公开数据集上取得了较为显著的性能提升。

在多元化的旋转目标检测学术框架内，两阶段方法凭借级联回归机制，在空间几何定位精度上始终占据主导地位。作为早期探索代表的 RoI Transformer 构建空间几何变换矩阵来学习特征图的旋转变换，进而驱动水平感兴趣区域向旋转感兴趣区域的显式转换，但算法的计算开销较大。Xie 等人提出的 Oriented R-CNN 模式改变了底层提议机制的方法，主要原因是取消了传统检测器里多余的、对方向不敏感的固定锚框设计，转而研发出一种轻量化的定向区域提名网络 Oriented RPN。Oriented R-CNN 仅利用偏移量的几何约束就能生成高质量的定向提议框，在确保检测精度的前提下也大幅度缩短了推理时间，属于前沿研究里经常使用的基线架构。

把注意力放在对底层特征进行建模的方面上，对遥感实体多向分布和跨尺度表征所包括的内在物理属性进行深入挖掘，这是提高检测器性能的重要命题。经典 ReDet 架构把旋转等变卷积直接加到主干网络的特征提取部分，目标的旋转变换被编码进模型结构里，确保模型在面对任意朝向的目标时依旧能保持恒定且鲁棒的特征激活响应。Li 等人受 ReDet 启发，在后续的 RADet 方案中作了进一步的多尺度演进，重点针对特征金字塔网络（FPN）设计了增强模块，通过利用最近邻插值和卷积来对高层特征进行上采样，然后将其与浅层特征流进行自适应级联，从而在物理上避免了传统反卷积操作因步长和核大小不匹配而产生的棋盘格伪影及频率混叠效应。

面对遥感图像里错综复杂的背景环境，Yang 等人转换思路提出了一种从粗到细的渐进回归方式，专门构造特征精细化模块（FRM）来处理由于边界框位置变化造成的特征不对齐问题。该方法通过逐像素特征插值，将边界框的位置信息重新编码到对应特征点上，完成底层的特征重构和对齐。Zheng 等人提出了一种自适应动态细化目标检测网络，设计了特征金字塔转换器（FPT），通过对特征金字塔的特征进行转换、拼接和卷积等操作，实现了更精细的特征提取，进一步提高了多尺度和密集目标的检测效果。遥感目标的几何形变幅度很大，而且方向具有很高的随机性，传统卷积神经网络具有的刚性感受野已经很难达到对边界进行精

确贴合的效果，引入可变形卷积（Deformable Convolution, DCN）及其变体技术可通过自适应微调采样网格来强化网络对几何变换的刻画，但此类形变操作局限于空域角度，采样点在遭遇极端背景时常因高频噪声误导而发生严重偏移，密集旋转目标的微观边缘对齐缺陷依然无从解决。

回顾现有的主流检测方法，这些方法主要利用单一的空域卷积神经网络 CNN 进行特征提取。空域滑动窗口在逐层剥离和捕获宏观深层语义方面有优势，但是当场景中地物非常混淆、实体特征高度同质化时，像素级局部运算会不可避免地滤除和丢失船舶修长边缘或航空器旋翼等具有高判别性的高频物理轮廓。小波变换因为拥有比较好的时频局部化特点，所以被计算机视觉领域广泛用于底层特征提取工作。该方法把频域上的特征图谱分解为含有多维方向特性的高频和低频子带，使网络能够捕捉到微观突变边界。模型优化现阶段主要关注注意力机制的探索，使其可以推动空域语义和频域多向细节进行自适应交互。

跨域特征的协同已成为必然趋势，注意力机制正在成为重构遥感检测器内部逻辑的主要模块。例如 Wang 等人提出的利用 Transformer 的检测器依靠注意力机制来分析不同实体之间的空间关系，并提升微小目标的激活权重。遥感小目标具有较大的长宽比和较少的有效像素，网络在训练过程中会出现尺度特征错位，正负样本分布也不均匀，模型在密集场景中进行回归时的稳定性会受到较大影响。Xu 等提出了 DCFL（Dynamic Coarse-to-Fine Learning）方法，通过动态方式对先验信息、标签分配和目标进行建模，以此来缓解数据不匹配的问题。

1.3 研究内容和章节安排

本文的核心工作是构建了一套基于空频特征融合的遥感旋转目标检测算法。研究以 Oriented R-CNN 为基础底座，利用离散小波变换去捕获潜藏在频域特征里的物理边缘特征，并借助交叉注意力机制将空域特征和频域特征进行一种自适应融合。为了提高网络在实体几何形变建模上的表现、角度回归的精确程度，模型把可以发生形变的卷积结构设置在骨干网络的内部，并且在回归端加入了旋转交并比损失 [26]。后随后进行的大量量化评估说明该联合模式在整体检测性能上达到了实际效果。

全文各章内容安排如下：

- (1) 第一章为绪论。主要从宏观应用方面说明高分辨率遥感目标检测的工程价值和研究背景，整理国内外旋转目标检测技术的发展过程和现有困难，进而确定本课题的主要突破点、文章的结构安排。
- (2) 第二章阐述相关理论和技术基础。主要围绕支撑本文工作的底层算法模式展开，具体内容包括 Oriented R-CNN 基线网络的基本原理，ResNet 骨干网络与特征金字塔结构，离散小波变换与可形变卷积的数学机制。这些内容为后续算法设计提供了必要的理论依据。

(3) 第三章主要对中心模型算法进行具体设计。本章围绕自适应双域并行融合块的设计逻辑展开，内容包括从空域语义提取到利用交叉注意力完成空频自适应深层交互的整个过程。

(4) 第四章是对系统的实验论证。确定了测试数据集的规格、软硬件配置和主要评估指标，并通过严格的消融实验和对比测试，客观地检验了几个重要组件的独立有效性、叠加增益表现。

(5) 第五章对原型系统的工程化部署和验证工作进行了说明。详细说明了以纯本地化部署和轻量化子进程隔离架构为基础的原型系统开发过程，并且展示了系统在参数动态调节、后台快速推理、前端可视化渲染方面所具有的主要功能。

(6) 结束语。对本文的理论收获和实验结果进行了总结，并分析了算法存在的不足之处，针对未来的科研方向提出了新的设想，同时阐述了在完成毕业设计过程中自己的感悟。

第二章 相关背景知识介绍

2.1 引言

遥感影像和普通自然场景图像差异较大，画面尺寸一般非常宽广，背景中存在很多元素，目标尺寸范围大且方向排列随机。现代旋转目标检测方法主要依赖深度卷积结构，ResNet 与特征金字塔级联构成特征提取中心，负责在多尺度层级上剥离基础语义表征，再输入到 Oriented R-CNN 生成高精度的有向候选区域，共同支持遥感解译任务的进行。

然而遥感图像中繁杂的背景易淹没和干扰目标的边缘轮廓特征，单纯空域卷积运算经常很难完全滤除多余信息，离散小波变换从频域角度给出了解决问题的思路。变换处理把输入信号分解成表示平滑背景的低频近似分量、对应的定向边缘的高频细节子带。该物理分离方法可以减轻计算负担，让网络捕捉到目标真实轮廓的高频结构信息，使特征提取阶段的抗噪性能得到提高。

考虑到遥感实体存在倾斜和狭长这类极端几何畸变情况，标准卷积所使用的固定网格采样方式很难贴合目标边界。可形变卷积在常规网格上学习并叠加二维空间偏移量、动态调制标量，打破了固定感受野的几何束缚，使网络具有自适应调整感受野的能力，让特征聚合过程更加符合目标的真实拓扑形态，主要因为网络对夸张几何变体的空间建模精度得到大幅度提高。

针对上述技术难点及现有解决思路，本章为后续主要模型的开发给予理论支持。下文将依次对特征提取骨干结构、旋转检测基础方法、频域分析工具、空间几何自适应技术等进行详细说明。

2.2 基础特征提取技术

2.2.1 残差骨干网络 ResNet

深度卷积神经网络在目标检测任务中通常作为骨干（Backbone）网络，负责从原始图像中提取具有表征能力的语义特征。残差网络（Residual Network, ResNet）便是其中最为经典且高效的架构之一，其基本残差单元如图 2.1 所示。

遥感图像具有很大的画幅，并且地物背景非常复杂多变，特征提取器需要利用更深的网络结构来滤除杂乱的噪声、提取高阶的语义信息。如果只在常规卷积网络中进行机械的深度堆叠，网络很容易陷入梯度弥散或爆炸的寻优陷阱，从而导致严重的模型退化现象。叠加级联的非线性激活映射和空间池化降采样，单纯依靠卷积算子进行串行传递的架构在进入深层




图 2.1 ResNet 基本残差单元结构图

映射空间时，经常会使底层图像包括的物理轮廓、微观边界等细粒度信息受到无法恢复的特征衰减。

为了实现深层网络的稳定训练，ResNet 摒弃传统前馈网络严格的逐层信息阻断范式，依托恒等映射与非线性变换并行的双分支机制构建了残差块。该结构打破了传统前馈网络严格的逐层传递范式，具体而言，设残差块的输入特征为 X ，经由连续权重层拟合得到的非线性残差映射表示为 $F(X)$ 。残差模块通过建立一条跨层连接（Skip Connection）路径，将输入与残差映射进行矩阵元素相加，得到该模块的最终输出 $F(X) + X$ 。这种直连路由机制强制特征信号在正向推断与反向传播阶段绕开特定卷积层，规避了浅层基础物理特征的过度损耗，同时为误差梯度的长距离反向回传搭建了无障碍的物理通道。

2.2.2 多尺度特征金字塔 FPN

特征金字塔网络组成了跨尺度目标特征解译任务的底层经典拓扑。回顾 Faster R-CNN 等早期两阶段方法，区域提名与边界框预测模块通常受限于单层级维度，仅调用骨干架构末端输出的最深层特征图执行后续推断。该类模式在遇到尺度差别大的遥感环境时会出现明显缺陷。经过多次级联下采样运算处理，深层特征图谱虽然凝练了判别性的抽象语义，但是急剧退化的空间分辨率直接造成小型车辆等微尺度实体的物理轮廓和定位坐标出现不可逆丢失。与之相比，浅层特征图虽然保留了利于捕获微小目标的较高分辨率，但是语义表征能力比较薄弱，容易诱发高频次误检现象。

为了弥合空间分辨率与深层高阶语义之间的表征鸿沟，FPN 架构打破了传统单尺度感知的局限，内嵌自顶向下路径与横向连接（Lateral Connection）机制。具体过程如 2.2 所示，输入图像经过骨干网络逐层提取，特征图尺寸逐渐缩减，但语义强度不断提升。网络融合阶段，首先采用 1×1 卷积调整深层特征的通道维度，随后沿着自顶向下路径，通过上采样将特征空间尺寸成倍放大，并借助横向连接与对应的浅层特征图进行逐元素相加融合。这种设计使得浅层特征在维持原有高空间分辨率的同时，获得了来自深层网络的强语义指导。最终，网络

建立起一组多层次、表征能力强的特征金字塔，在融合特征金字塔的每一层级独立引出检测分支，显著增强了复杂遥感场景下多尺度目标的检测能力。




图 2.2 特征金字塔示意图

为了弥合空间分辨率与深层高阶语义之间的表征鸿沟，FPN 架构打破了传统单尺度感知的局限，内嵌自顶向下路径与横向连接（Lateral Connection）机制。具体过程如图 2.2 所示，输入图像经过骨干网络逐层提取，特征图尺寸逐渐缩减，但语义强度不断提升。网络融合阶段，首先采用 1×1 卷积调整深层特征的通道维度，随后沿着自顶向下路径，通过上采样将特征空间尺寸成倍放大，并借助横向连接与对应的浅层特征图进行逐元素相加融合。这种设计使得浅层特征在维持原有高空间分辨率的同时，获得了来自深层网络的强语义指导。最终，网络建立起一组多层次、表征能力强的特征金字塔，在融合特征金字塔的每一层级独立引出检测分支，显著增强了复杂遥感场景下多尺度目标的检测能力。

2.3 旋转目标检测与空间优化机制

2.3.1 Oriented R-CNN 基线网络

Oriented R-CNN 作为一种先进的两阶段旋转目标检测模型，核心优势在于高效且精准的有向区域生成网络和旋转感兴趣区域对齐（Rotated RoI Align）模块。传统的旋转目标检测算法，如 RoI Transformer，会在 RPN 阶段铺设大量多角度和不同长宽比的旋转锚框，类似穷举的行为会导致庞大的计算开销和内存占用。Oriented R-CNN 摒弃了这种繁重策略，提出中点偏移法，一种基于水平锚框直接生成高质量倾斜候选区域的方法。

中点偏移法用 6 个参数来表示一个旋转框 O ：

$$O = (x, y, w, h, \Delta\alpha, \Delta\beta) \quad (2.1)$$

其中， (x, y, w, h) 代表旋转目标的外接水平矩形……由此可由几何映射推导出倾斜目标

的四个真正顶点 (v_1, v_2, v_3, v_4) ，如图 2.3 所示。其具体的顶点映射关系如公式 2.2 所示：

$$\begin{cases} v_1 = (x, y - h/2) + (\Delta\alpha, 0) \\ v_2 = (x + w/2, y) + (0, \Delta\beta) \\ v_3 = (x, y + h/2) + (-\Delta\alpha, 0) \\ v_4 = (x - w/2, y) + (0, -\Delta\beta) \end{cases} \quad (2.2)$$

中点偏移法把复杂的角度回归问题转化成了纯粹的二维平面坐标点回归问题，通过公式能够看出这一点。该映射关系形成了中心对称的平行四边形，数学上使网络优化的难度得到简化。O-RPN 生成任意角度和尺寸的倾斜候选区域后，下游的分类与回归端需摄入维度统一的特征张量来完成最终预测，检测头架构内部署了旋转感兴趣区域对齐模块来衔接空域映射断层。模块先计算旋转框的仿射变换矩阵，在特征图上进行网格采样，然后使用双线性插值法将倾斜的特征区域精确裁剪并拉直成固定大小的标准特征图，这样做可以避免水平裁剪造成的背景噪声干扰，也能保证特征的空间旋转不变性。




图 2.3 中点偏移法

2.3.2 可形变卷积与动态感受野

旋转检测框架的骨干网络中广泛使用的标准卷积操作仍存在物理层面的局限性，标准卷积核具有固定的几何采样网格的正方形结构，在面对遥感场景中严重形变目标时，固定感受野难以自适应地包裹目标，易提取到与目标无关的背景特征。可形变卷积网络通过在常规卷积网格上学习额外的二维空间偏移量，赋予网络动态调整感受野的能力。

DCNv2 的输出如公式 2.3 所示， x 为输入特征图， w_n 为第 n 个采样点的卷积权重， p_n 为标准网络的位置枚举。 Δp_n 和 Δm_n 分别代表网络通过额外卷积层动态学习到的空间偏移量

与调制标量。这种微观层面的空间自适应机制，使得卷积核的采样点能够像“变形虫”一样，根据输入目标的实际物理形状发生偏移，紧密贴合狭长或倾斜的真实几何结构。

$$y(p_0) = \sum_{p_n \in \mathcal{R}} w_n \cdot x(p_0 + p_n + \Delta p_n) \cdot \Delta m_n \quad (2.3)$$

2.3.3 旋转边界框回归与损失机制

在完成特征提取后，边界框回归损失函数的选择决定了模型最终的定位精度。传统的检测网络（如 Faster R-CNN）通常采用 Smooth L_1 Loss 等基于参数绝对误差的损失函数，公式 2.4 是 Smooth L_1 Loss 的计算公式：

$$\text{Smooth}_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases} \quad (2.4)$$

上述公式中， x 代表预测参数与真实标签之间的偏移量。然而，在处理包含角度信息的旋转框时，单纯计算参数差异会面临致命的“边界突变”问题。遥感旋转目标通常采用五元组 (x, y, w, h, θ) 表示，因为角度参数具有周期性，当预测框的角度超过周期边界时，虽然在物理空间中预测框和真实框基本重合，但在参数空间上会出现使损失函数惩罚大幅度增加的差异，导致网络训练出现震荡。

本文把旋转交并比损失（Rotated IoU Loss）当作损失参数，该方法主要依据预测框和真实框交集面积占两者并集面积的比例来直接衡量两个框的物理重叠程度。可以把每个旋转框建模为二维高斯概率分布，以减少计算量，并且使概率分布的距离近似实际的多边形物理重叠度。该度量方法具有尺度不变性，不被角度周期性边界影响，可以给网络提供平滑且连续的梯度引导，使旋转目标角度回归保持准确，模型收敛也保持稳定。

2.4 二维离散小波变换

离散小波变换凭借其优异的时频局部化特性，能够在不丢失空间位置信息的前提下实现特征的多频带分解^[5]。二维离散小波变换通常通过一组正交的低通和高通滤波器对图像特征进行行列级联扫描。以 Haar 小波作为基函数为例，对于输入的一张二维特征图，Haar 小波变换利用四个固定的 2×2 权重滤波器对其进行滑动卷积，从而分别提取四个物理频率子带，四

个滤波矩阵的定义如公式 2.5 所示：

$$\begin{aligned} f_{LL} &= \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}, & f_{LH} &= \begin{bmatrix} -0.5 & -0.5 \\ 0.5 & 0.5 \end{bmatrix}, \\ f_{HL} &= \begin{bmatrix} -0.5 & 0.5 \\ -0.5 & 0.5 \end{bmatrix}, & f_{HH} &= \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} \end{aligned} \quad (2.5)$$




图 2.4 小波变换

在具体的算子实现架构中，上述分解运算可以等效地转化成步幅为 2 且没有边缘填充的深度可分离卷积。该操作在进行多向高频子带通道级联的同时实现了两倍空间特征下的采样，减少了后续跨域交互模块的内存使用和计算成本。主要的收益是高频子带直接滤除大片平缓的背景杂波，迫使网络把优化重点放在目标的物理边界和几何轮廓上，为解决复杂地貌引起的特征淹没问题提供了可靠的频域先验约束。

2.5 本章小结

文从主干网络和多尺度特征建立方式开始，先整理 Oriented R-CNN 基线算法的主要逻辑，然后主要分析可变形卷积和旋转边界框回归损失使用的优化方法。二维离散小波变换、交叉注意力机制、各项模型评价指标的底层原理，也在本章中一起说明。该内容包括特征表征、频域分析和数学优化等，为后续研究理清了前期理论脉络，并且整体回顾了遥感目标检测所依靠的技术基础。

第三章 基于空频特征融合的遥感目标检测研究

3.1 引言

考虑到真实遥感场景中背景杂乱、目标尺度多变等实际痛点，在综合了空域特征的丰富上下文语义和小波变换对高频边缘特征的敏锐捕捉能力后，本章设计了一种基于空频特征融合的遥感旋转目标检测算法。将 **Oriented R-CNN** 为当作基础架构，通过在主干网络中引入全新设计的交叉注意力空频交互机制，辅以形变感知与旋转回归优化，最大化网络对复杂遥感目标的特征表达与精确定位能力。研究结果表明，与基线模型相比，具备空频双域融合能力的改进系统在复杂遥感场景下的检测性能更为优秀。

3.2 整体网络架构

本文以经典的双阶段旋转目标检测框架 **Oriented R-CNN+ResNet50** 为基线模型，并针对其在杂乱背景下特征提取能力受限等痛点进行了改进，提出了基于空频特征融合的遥感图像检测框架。网络由四个核心模块构成：主干网络、特征金字塔、旋转区域候选网络以及旋转检测头。

3.2.1 主干网络

主干网络负责从原始遥感图像中提取具有强泛化能力的层级特征映射，本文在原生 **ResNet50** 的基础上重构了名为 **OESResNet** 的特征提取主干。以尺寸为 $H \times W \times 3$ 的输入图像为例，数据首先通过网络前端的 **Stem** 层（包含 7×7 卷积与最大池化层）进行初步的下采样与特征提取，得到特征 C_1 ，随后依次流经四个残差阶段。

如图 3.1 所示，考虑到港口停泊的船舶或城市中任意朝向的车辆往往存在严重的视角与几何形变，模型在中深层阶段（第 2, 3, 4 阶段）激活了可形变卷积。标准卷积在规则网格 $\mathcal{R}$ 上进行采样，而 **DCNv2** 通过一个平行的卷积分支学习额外的空间偏移量 Δp_k 和调节标量 Δm_k 。对于特征图上的任意位置 p_0 ，其经过可形变卷积后的输出 $y(p_0)$ 可表示为：

$$y(p_0) = \sum_{p_k \in \mathcal{R}} w_k \cdot x(p_0 + p_k + \Delta p_k) \cdot \Delta m_k \quad (3.1)$$

其中， w_k 为采样点权重， x 为输入特征图。通过引入空间偏移量 Δp_k ，网络数据流在深层自适应地改变了感受野的形状，使其能够紧密贴合旋转目标的真实物理轮廓。

随着网络深度的增加与空间分辨率的不断下降，目标的边缘、角点等高频细节极易被模

糊化。为此，当特征数据流出主干网络的最深层残差块时（阶段 3、4），系统将其送入本文设计的空频特征融合模块（Spatial-Frequency Feature Fusion, SFF），生成特征 C_4, C_5 。该模块将数据流拆分为空域和频域两条并行路径，利用小波变换提取高频物理边界，并通过交叉注意力机制完成动态聚合。关于 SFF 模块的具体内部结构与数学理论推导，将在本文 3.3 节中进行详细论述。

经过上述过程，OESResNet 最终输出既包含宏观上下文语义、又具备锐利边缘和形变适应能力的层级特征集合 $C = \{C_2, C_3, C_4, C_5\}$ 。




图 3.1 模型结构示意图

3.2.2 特征金字塔

经过 OESResNet 提取的特征集合 C 随后流入特征金字塔网络。由于遥感场景中兼具极大和极小的目标物体，FPN 的作用是构建一个具有强语义的多尺度特征空间。FPN 接收 C_2 至 C_5 的特征输入，采用自顶向下的数据传播路径与横向连接操作。对于第 i 层的特征金字塔 P_i ，其前向计算过程可以用以下公式表示：

$$P_i = \text{Conv}_{3 \times 3}(\text{UpSample}_{2 \times}(P_{i+1}) + \text{Conv}_{1 \times 1}(C_i)) \quad (3.2)$$

其中， $\text{UpSample}_{2 \times}$ 表示两倍双线性插值上采样， $\text{Conv}_{1 \times 1}$ 用于统一通道维度（本文设为 256）， $\text{Conv}_{3 \times 3}$ 用于消除上采样带来的混叠效应。此外，为了进一步获得更大感受野以检测超大尺度目标，网络对 P_5 进行了步长为 2 的最大池化（Max Pooling）操作生成 P_6 ，最终生成五层增强特征金字塔 $P = \{P_2, P_3, P_4, P_5, P_6\}$ ，为后续的多尺度目标检测提供了坚实的数据基础。

如图 3.2 所示，获取高质量的多尺度特征后，数据流进入第一阶段检测，进行旋转候选区域生成与精确特征对齐。Oriented RPN 在金字塔的各层级上进行密集的滑动扫描，通过轻量级全卷积网络区分前景与背景，并输出高质量的旋转候选框。每一个候选框被数学参数化为五元组 (x, y, w, h, θ) ，分别代表框的中心点坐标、宽度、高度以及倾斜角度。由于生成的候

选框带有倾斜角度，传统轴平行的 RoI Pooling 无法准确提取旋转区域的特征。因此，前向数据流引入了旋转感兴趣区域对齐操作。该模块利用双线性插值算法，严格按照候选框的角度 θ 及其边界，从对应的特征金字塔层级中截取精确的局部像素网格，并统一池化为 7×7 的固定维度特征向量。

网络前向传播的最终裁决在检测头中完成。由 RoI Align Rotated 输出的特征向量被展平，并送入由共享全连接层构成的多任务网络中。以用 DOTA 1.0 数据集测试为例，该网络分为两个并行的输出分支：分类分支负责预测目标属于数据集中 15 个类别的后验概率，回归分支负责精调五元组参数。

3.3 空频特征融合模块设计

传统的卷积神经网络在解译遥感特征时高度依赖局部空域的滑动窗采样范式。但在网络向深层拓扑演进及级联降采样运算的驱动下，目标的高频细节信息（诸如物体轮廓与细微纹理）会不可避免地发生丢失。考虑到遥感场景中实体普遍呈现堆叠态势，此类高频定向边缘实则是网络剥离背景杂波、界定相邻目标边界的核心判别约束。本文设计了一种空频特征融合模块以重塑底层的特征提取链路，该模块将频域分析与空域注意力机制相结合，通过小波变换高效提取高频定向特征，并利用交叉注意力机制实现双域特征的深度交互与动态聚合。

3.3.1 频域定向特征提取

在图像信号处理领域，图像的低频分量通常包含了物体的平滑背景和宏观结构，而高频分量则集中反映了物体的边缘、轮廓和纹理。为了从特征图中无损地分离并提取这些高频信息，SFF 模块引入了二维离散小波变换，本文选用经典的 Haar 小波作为基函数。遥感图像中的目标与背景之间通常存在明显的亮度跳变，而 Haar 小波作为一种分段常数基函数，其数学形态与这种阶跃型边界高度匹配，能够比传统卷积更敏锐地捕捉到极细微的物理轮廓。

给定由骨干网络上一层级输出的特征图输入 $X \in \mathbb{R}^{C \times H \times W}$ ，其中 C 、 H 、 W 分别表示特征的通道数、高度和宽度。Haar DWT 采用四个子带滤波器对特征图进行空间域的滤波操作，分别对应低频分量 (LL)、水平高频分量 (LH)、垂直高频分量 (HL) 和对角线高频分量 (HH)。也就是说，Haar DWT 可以将特征图解析为四种物理意义明确的特征：低频分量保留了图像的宏观语义和光照分布；水平高频分量突显了目标在水平方向的边缘，对横向分布的目标有强增强作用；垂直高频分量捕捉垂直方向的特征；对角线高频分量提取角点及斜向纹理。

在本文的具体工程实现中，为大幅降低计算复杂度，DWT 过程被巧妙地等价转化为步长

为 2 的深度可分离卷积操作。其四个子带的固定权重矩阵定义如公式 3.3 所示：

$$\begin{aligned} W_{LL} &= \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix}, & W_{LH} &= \begin{bmatrix} -0.5 & -0.5 \\ 0.5 & 0.5 \end{bmatrix}, \\ W_{HL} &= \begin{bmatrix} -0.5 & 0.5 \\ -0.5 & 0.5 \end{bmatrix}, & W_{HH} &= \begin{bmatrix} 0.5 & -0.5 \\ -0.5 & 0.5 \end{bmatrix} \end{aligned} \quad (3.3)$$

经过 Haar 小波分解后，得到了通道数为 $4C$ 的多尺度频域特征。为了使其与原始空域特征在维度上保持一致以便后续融合，本文引入了一个频域对齐子模块。该子模块由步长为 2 的转置卷积极、批归一化和激活函数串联构成，将多通道频域特征重新投影并对齐分辨率，最终输出蕴含清晰物理边界的频域增强特征 $F_o \in \mathbb{R}^{C \times H \times W}$ 。

3.3.2 空频融合交叉注意力机制

在分别获取了包含上下文语义的原始空域特征 X 与包含边缘轮廓的频域特征 F_o 后，如何将两者进行高效融合是提升模型表达能力的关键。简单的逐元素相加或通道拼接无法根据目标的不同特性进行自适应调整，为此，本文在 SFF 内部设计了一种双域交叉注意力机制。

需要特别注意的是，遥感图像通常具有极高的分辨率。如果直接在原始特征图尺度（将空间维度展开后序列长度为 $N = H \times W$ ）上计算标准的交叉注意力矩阵，将会带来 $O(N^2)$ 的庞大显存开销与计算复杂度。为了突破这一计算瓶颈，本文在生成键（Key）和值（Value）特征之前，引入了空间降采样策略。

具体而言，网络首先利用核大小与步长均为 s （本文实验中设为 2）的平均池化层及批归一化操作，对空域特征 X 与频域特征 F_o 进行空间维度的严格下采样，得到降维特征 X_{kv} 与 F_{okv} 。此时，参与后续交互的特征序列长度从 N 降至 $N_{kv} = N/s^2$ 。

随后，该机制通过 1×1 卷积层对输入特征进行线性映射，将通道数降维至 $C' = C/8$ 以减少计算量，分别构建空域与频域的查询（Query）、键（Key）和值（Value）矩阵。对于原始空域特征 X ，生成空域查询矩阵 Q_c 与键矩阵 K_c ：

$$Q_c = XW_{qc}, \quad K_c = XW_{kc} \quad (3.4)$$

对于频域增强特征 F_o ，生成频域查询矩阵 Q_o 与键矩阵 K_o ：

$$Q_o = F_oW_{qo}, \quad K_o = F_oW_{ko} \quad (3.5)$$

其中， W_{qc} 、 W_{kc} 、 W_{qo} 、 W_{ko} 表示各个分支的线性投影权重。随后，本文分别计算纯空域

视角的相似度响应 W_c 以及结合了边缘感知的频域相似度响应 W_o 。为了使网络能够根据不同遥感图像的背景复杂程度，自适应地在“语义上下文”与“边界锐度”之间寻找平衡，本文引入了两个可学习的动态门控参数 α_1 和 α_2 ，在训练过程中，反向传播算法会根据损失函数的反馈自动调节这两个参数，使模型在面对不同场景时拥有调整信息侧重的能力。双域注意力响应矩阵经过线性加权叠加后，通过 Softmax 函数归一化，引入缩放因子 $\sqrt{C'}$ 防止点积绝对值过大导致梯度消失，得到最终的综合交叉注意力图 W_{co} ：

$$\begin{aligned} W_c &= Q_c K_c^T \\ W_o &= Q_o K_o^T \\ W_{co} &= \text{Softmax} \left(\frac{\alpha_1 W_c + \alpha_2 W_o}{\sqrt{C'}} \right) \end{aligned} \quad (3.6)$$

获得综合交叉注意力图 W_{co} 后，网络通过线性投影从降采样后的空域特征中提取值矩阵 V 。随后，利用 W_{co} 对 V 进行动态加权聚合，实现空频信息的深度交互。

为了保证模型在训练初期的稳定性，并避免破坏主干网络预训练的特征分布，本模块采用残差连接机制，并在 SFF 模块的最终输出端引入初始为 0 的可学习标量因子 γ ，随着训练的进行，网络会自动学习并慢慢放大 γ 的值，从而平滑地引入空频融合带来的增益特征。

最终，SFF 模块的输出特征 Y 可表示为：

$$Y = X + \gamma \text{Out}(V W_{co}^T) \quad (3.7)$$

其中，Out 代表用于通道恢复与特征平滑的 1×1 卷积与批归一化操作。图 3.2 直观展示了 SFF 模块的内部计算流程。




图 3.2 SFF 模块内部计算示意图

第四章 实验设计

4.1 实验设计

本研究的实验环境运行于基于 Linux 的操作系统平台，硬件配备了 24GB 显存的 NVIDIA GeForce RTX 5090 GPU，软件开发框架采用 Python 3.8 及深度学习库 PyTorch，所有模型均在 MMRotate 算法框架下实现。

实验于遥感领域权威的 DOTA v1.0 数据集上进行。为了充分利用有限的标注数据并提升模型的泛化能力，数据集提供的原始的训练集 Train 与验证集 Val 被合并作为训练数据，原始图像统一被裁剪为 1024×1024 像素的切片进行输入。

算法 4.1 是 OES-ORCNN 模型的具体训练算法流程。

算法 4.1 OES-ORCNN 模型训练算法

输入: 训练数据集 D ，最大迭代轮数 $E_{max} = 36$ ，初始学习率 η ，网络初始化权重 Θ

```

1: 初始化当前轮数  $e = 0$ ，初始化指数移动平均权重  $\Theta_{ema} = \Theta$ ；
2: while  $e < E_{max}$  do
3:   for 数据集  $D$  中的每个批次数据  $B$  do
4:     将  $B$  输入网络，经主干网络及 FPN，构建多尺度特征金字塔  $\{P_2, P_3, P_4, P_5, P_6\}$ ；
5:     Oriented RPN 生成旋转候选框并计算区域生成损失  $L_{RPN}$ ；RoI Align Rotated 提取
     特征后，计算分类损失  $L_{cls}$  与基于真实多边形解码的旋转回归损失  $L_{reg}$ ；将上述三个损
     失相加得到总损失；
6:     反向传播，计算梯度  $\nabla\Theta$ ，并更新网络权重  $\Theta \leftarrow \Theta - \eta\nabla\Theta$ ；
7:     EMA 更新， $\Theta_{ema} \leftarrow 0.998\Theta_{ema} + 0.002\Theta$ ；
8:   end for
9:   学习率衰减，若  $e \in \{24, 33\}$ ，则  $\eta \leftarrow 0.1 \cdot \eta$ ；
10:   $e \leftarrow e + 1$ ；
11: end while
```

输出: 最终模型权重 Θ_{ema}

4.2 结果分析与讨论

4.2.1 评价指标

本文采用平均精度均值 mAP 作为量化模型准确度的首要标准。对于单一类别目标，模型会根据预测的置信度得分对所有检测框进行排序，并计算在不同召回率下的精确率。以召回率为横坐标、精确率为纵坐标绘制 P-R 曲线，曲线积分面积即为该类别的 AP 值。AP 值越高，说明模型对该类目标的综合检测与识别能力越强，mAP 是所有 N 个类别 AP 值的算术平均值，

DOTA 数据集包含 15 种不同类别的目标， $N = 15$ 。下图展示了模型输出样例。

如图 4.1 所示，左侧为原始遥感图像，右侧为网络输出的旋转目标检测结果。




图 4.1 遥感图像飞机目标旋转检测结果对比图

4.2.2 整体检测性能分析

本文将经过 36 轮端到端训练并由 EMA 稳定的最终模型在 DOTA v1.0 数据集上进行了全面评估。表 4.1 展示了该模型在 15 个具体类别上的详细 AP 成绩以及最终的 mAP。

表 4.1 OES-ORCNN 在 DOTA v1.0 数据集上的各类别平均精度

类别名称	AP(%)	类别名称	AP(%)
飞机	89.00	篮球场	87.95
棒球场	83.54	储油罐	86.76
桥梁	57.80	足球场	61.99
田径场	76.58	环岛	67.81
小型车辆	81.47	港口	78.30
大型车辆	85.44	游泳池	80.51
船舶	88.53	直升机	63.92
网球场	90.81	mAP	78.69

表 4.1 的结果表明，OES-ORCNN 总体 mAP50 达到了 **78.69%**，泛化效果比较理想。特别是在网球场、飞机、船舶等具有刚性结构和清晰物理边界的类别上，模型提取的高频特征带来了明显的精度优势，而对小型车辆这类典型的密集小目标，模型的召回能力同样保持在了较高水平。

上图详细对比了 OES-ORCNN 算法与官方基线 Oriented R-CNN 在 DOTA v1.0 数据集 15 个具体类别上的平均精度表现。OES-ORCNN 的 mAP 达到 78.7%，比基线模型提高了 2.8%，具体到每个类别，本文算法在性能增幅上主要表现为以下方面。

模型在直升机和游泳池这两个类别上表现出明显的提高，AP 分别提高 11.6% 和 11.7%，这两类目标的共同点是很容易同复杂的城市或自然背景相混淆。该结果较好地证实了空频特




图 4.2 OES-PRCNN 和 ORCNN 模型性能对比

征融合模块具有去噪功能。经过离散小波变换去除杂乱低频背景，网络可以准确地识别直升机旋翼或泳池边界等高频突变结构，并且提取出没有受到背景干扰的定向特征。

田径场、大型车辆和桥梁这些目标的长宽比例非常极端并且形态变化较多，改进后的算法在这些目标上取得了 5.6%、2.4% 和 3.0% 的稳定提升。骨干网络中加入可变形卷积使特征采样网格可以动态适应目标本身的几何形态。回归端使用 Rotated IoU 损失避免狭长目标在旋转回归时容易产生的角度边界跳变和边长交换问题，提高高精度旋转框的拟合水准。

测试结果也显示飞机与足球场类别的 AP 出现了轻微下降，主要因为 SFF 模块在频域上明显放大了高频边缘的激活响应，使网络在处理纹理平滑或者轮廓比较单一的特定实体时发生局部注意力偏移或者轻度过拟合。不过，这类特征偏好并没有对系统在复杂杂乱场景下的整体解译泛化能力造成实质影响。

4.2.3 核心模块消融实验分析

本文利用若干消融实验来对文中提出的各项架构改进所产生的实际贡献进行客观评估。所有实验都在相同的软硬件环境中进行，测试过程中遵守单一变量原则，测试分支都部署在相同的计算环境里，使用相同的超参数配置，比如初始学习率、权重衰减策略和迭代轮数等。综合检测性能的最终评价使用 DOTA v1.0 验证集上的平均精度均值来衡量。

具体的消融实验核心模块配置和性能对比结果已汇总于表 4.2。

图 ?? 展示了几组实验性能对比的可视化结果。有一点需要特别说明，表 4.2 中基线模型，即 Exp 2 的平均精度均值明显高于前文中原始 Oriented R-CNN 的官方基础精度。之所以出现这种差异，是因为本课题希望充分挖掘模型潜力，在进行消融实验时增加了训练轮数，同时统一引入强效的数据增强策略，包括多向随机翻转与任意角度的连续随机旋转。Exp 2 代表

表 4.2 消融实验性能对比

实验编号	基线模型	SFF	DCNv2	RIoU	mAP (%)	较基线提升
Exp 2	✓				77.53	-
Exp 3	✓	✓			78.17	+0.64%
Exp 4	✓		✓	✓	78.21	+0.68%
Exp 5	✓	✓	✓		78.33	+0.80%
Exp 1	✓	✓	✓	✓	78.69	+1.16%

的是在统一的高规格训练周期与数据增强基准下，重新训练的强基线网络，后续实验中引入 SFF 等模块所带来的精度跃升，全部是在这个强基线之上取得的，这进一步印证了本文所提网络架构改进的纯粹有效性与卓越性能。




图 4.3 消融实验在 DOTA v1.0 上指标对比

分析上述消融组别的数据差值，Exp 3 仅在骨干网络中深层嵌入了 SFF 模块，mAP 就比较强基线提高 0.64%。从底层机理来看，深度卷积在进行多级空间降采样时会固有地产生高频细节耗散现象，而 SFF 模块内部内置的 Haar 离散小波变换可以对该现象进行有效抑制。该模式在物理上把水平、垂直和对角线方向的定向高频子带分离开来，依靠交叉注意力机制的动态门控权重，自适应地降低城市地物等复杂杂波的激活响应，从而使下游区域候选网络得到更纯净的特征底座。

对比 Exp 3 和 Exp 4 的性能变化，单一空频融合方式所得到的性能好处，在数值增量上已经达到空间形变采样和回归损失优化这两种常用方法加在一起的整体效果。该现象说明对底层特征提取逻辑进行重构很有必要。在遥感杂乱环境中，从特征源头阻止边缘细节退化会带来全局表征增益。该增益在效能上可以和检测后端复杂的局部优化组件相匹敌，并且说明了 SFF 模块在突破传统 CNN 模式感知限制方面的重要价值。

分析 Exp 5 数据可以看出，系统在 SFF 模块架构上激活可变形卷积之后，mAP 达到

78.33%，该组别跨度表明二者在特征流传导过程中形成了紧密的正向协同链路。SFF 模块在频域上输出清楚的物理边界先验，DCNv2 利用这些先验特征生成自适应空间偏移量，使采样网格紧密贴合异形实体的非刚性几何拓扑，在根本上减少背景冗余像素对特征聚合过程的影响。

在前端完成高质量空频特征提取之后，本文提出的完整算法 Exp 1 把检测回归范式从 Smooth L1 损失更换为 RIoU 损失，从而使最终 mAP 达到 78.69%。常规参数距离度量在处理密集旋转实体时因为角度具有周期性会出现梯度断崖式震荡，RIoU 策略把刚性多边形边界框映射成连续的二维高斯概率分布。该数学度量转换方式按照分布重叠度来进行，既保证全程平滑且可微的梯度下降方向，也明显提高模型对包括密集停车场内有微小角度偏差型车辆在内的严苛样本的拟合稳定性。

综合消融实验结果可以看出，本文提出的几个主要组件在机理上形成了递进式的互补关系，从频域的高频特征提取到空间上的非刚性采样，再到末端的概率分布度量，整条链路都进行了针对性的优化。该设计包括整个流程，整体压制了原始基线在应对极端挑战场景时表现出的性能不足。

第五章 遥感目标检测系统的设计与实现

理论成果的工程化部署是检验算法可用性的关键环节。深度学习框架在 Web 容器里停留时，会使显存出现泄漏或者引发多线程死锁这类底层资源冲突。本文把前文形成的 OES-ORCNN 算法封装成独立运行环境，按照前后端进程隔离的方式，形成一套开销较低的本地化演示方案。

原型系统把拓扑结构在横向进行解耦，表现出表现层、调度层和计算层这三个主要部分。

表现层利用 Streamlit 模式来建立响应式交互界面，该层主要承担遥感图像资源和超参数的摄入工作，并且接收后端传来的推断输出，从而对检测结果进行实时的可视化渲染。调度层作为连接前后两端的通信枢纽，它利用系统级子进程的方式异步唤醒独立的推理任务，并且依靠临时文件系统进行跨进程的序列化数据交换。后端计算层被当作主要推理引擎并集成进 MMRotate 模式里，该层主要负责加载 OES-ORCNN 训练权重，并且在 GPU 环境中进行端到端的前向传播。

表现层运用响应式双栏布局，侧边栏中嵌入算法控制台，可以动态地对预测置信度阈值进行微调。用户在前端界面上进行拖拽操作，状态机会随之进行更新，系统也会同步把上传的像素流序列化为临时文件并进行落盘，同时通过命令行参数来对阈值参数进行封装，以便为后续独立进程的调用做好数据准备。该种依靠数据驱动进行运转的方式把底层的代码交互细节完全隔离开来放在后台，使终端用户能够对跨场景的图像解译验证进行高效执行。

与传统的云端 API 部署模式不同，本系统围绕高分辨率遥感图像检测的实际需求，在模型加载与响应机制上进行了针对性优化。

本章把前文所构建的 OES-ORCNN 算法从理论层面的设计推进到实际可用的工程系统，形成一套具备辅助决策价值的工具。

围绕系统开发与部署所做的工作，既为算法本身搭建了一个直观、高效的科学验证平台，也为先进的遥感深度学习算法向轻量级工程应用程序的转化，给出了一条可复用的实践路径。

第六章 总结与展望

6.1 本文工作总结

遥感领域中高分辨率遥感图像在自动解析时会出现瓶颈，本文突破了传统水平边界框的表征局限，以双阶段架构 **Oriented R-CNN** 为基础，通过对底层特征提取链路进行重构、对空间采样拓扑进行优化、对边界度量方式进行改进，形成了 **OES-ORCNN** 多维感知检测模式。

系统回顾本课题的研究脉络，主要理论增益和工程突破体现在三个方面：在前端特征提取过程中，本文运用离散小波变换结合空频特征的模块。该方法通过去除高频子带的物理属性，让网络更重视实体的微观边缘数据。从基础方式上减少了城市复杂地形和海浪等环境噪声造成的特征干扰。

进入中端和后端的空间对齐及回归映射环节，可变形卷积与空频先验特征共同形成了拓扑协同，可以有效覆盖大型及狭长目标的非刚性形变。回归阶段利用二维高斯分布建模的旋转交并比损失，在度量根源处平息了由角度周期性引起的梯度震荡和边界突变。

就最终工程而言，对比实验结果说明，在应用相同数据增强方法的基线模型里，**OES-ORCNN** 模型获得了明显的性能提高。除此之外，配套研发的进程隔离原型系统则闭环验证了该高精度算法向实际业务场景下沉的技术可行性。

从客观的角度来评估本文的研究成果，**OES-ORCNN** 在检测精度方面交出了比较好的成绩，但是由于受到物理条件和时间的限制，该模型在算法的轻量化部署、尺度适应性和数据依赖度等方面仍然存在可以优化的空间。

6.2 进一步研究方向

未来研究应当分析当前模式存在的不足，并进行更详细的探讨。

本文使用的双阶段检测方法拥有很高的定位准确度，加入的 **SFF** 和 **DCNv2** 也让模型的表现力得到提高，但是这使得模型的参数数量变大，同时推理时间延长。后续工作可以把知识蒸馏技术考虑进来，把 **OES-ORCNN** 当作教师模型，用来指导轻量级的学生网络，比如基于 **MobileNet** 或者 **YOLO** 系列的单阶段旋转检测器来进行学习。另也可以尝试采用网络剪枝与张量量化技术，在尽可能不损失精度的情况下压缩模型体积，以满足无人机边缘计算等平台对实时性的严格要求。

由于本地计算硬件的显存存在瓶颈，本文实验主要运用单尺度图像裁剪和固定锚框策略来进行训练。然而真实遥感场景中的目标尺度跨度极大，未来研究很有必要进行多尺度训练方式的分析，并尝试结合无锚模式或动态标签分配方法，使网络能够自适应地按照目标的真

实形态来匹配正负样本，这会有助于提高模型在极端尺度变化场景下的召回率和稳定性。

现在的模型训练高度依赖带有精细旋转多边形标注的大规模数据集，此类标注成本高昂，开源数据集较少，严重制约了算法在冷门类别和新兴遥感场景中的推广应用。在未来的规划中，可尝试将本文的空频融合思想迁移至半监督或弱监督目标检测框架，提升模型在少样本或低标注成本场景下的泛化能力。

参考文献

- [1] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137–1149.
- [2] 蓝鑫, 吴淞, 伏博毅, 等. 深度学习的遥感图像旋转目标检测综述[J]. 计算机科学与探索 (Journal of Frontiers of Computer Science Technology), 2024, 18(4): 845–868.
- [3] Han J, Ding J, Xue N, et al. Redet: A rotation-equivariant detector for aerial object detection[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 2786–2795.
- [4] Xie X, Cheng G, Wang J, et al. Oriented r-cnn for object detection[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3520–3529.
- [5] 李世雄. 小波变换及其应用[M]. 北京: 高等教育出版社, 1997.