


.....

.....

Scaling Rectified Flow + Transformers for high resolution Image Synthesis



+

+

.....

发表日期: 2024.3






论文研究背景

Research background

01

扩散模型(Diffusion Model)是图像生成主流模型，它通过反向去噪，将随机的噪声分布逐步转化为清晰的图像。模型中的两个主要过程是前向扩散和反向去噪。



02

修正流(Rectified Flow)是于2022年提出的生成模型，它设计了一个直线路径（传统扩散模型是曲线路径，使噪声还原成图像的步骤较多），连接初始噪声分布和真实图像分布，提高了模型的效率。

- 假设有一个图像数据点 x_0 和一个高斯噪声点 x_1 ，那么直线流就用插值公式：

$$x_t = (1 - t) \cdot x_0 + t \cdot x_1$$





论文贡献

1

改进的噪声采样技术

虽然修正流模型(Rectified Flow) 有更好的理论性质和概念简洁性, 但缺少相关的大规模实验。论文在修正流模型的基础上, 引入了多种时间步加权采样策略, 并通过实验证明, 基于logit-Normal分布的方法总体表现最好。此外, 论文还做了实验证明改进后的训练方法比传统扩散训练方式更优越。

2

基于Transformer的文生图架构

过去的diffusion模型反向去噪过程主要使用U-Net等架构, 处理输入提示词并和生成图像关联的能力较弱, 论文提出了基于transformer的多模态架构MM-DiT, 引入自注意力机制, 使文本token跟图像token能在生成过程中不断交互, 使模型更好的理解和融合文本与图像, 从而生成更符合提示词的图像。





改进的修正流模型

$$x_0 \quad \text{---} \quad x_1$$

$$x_t = (1-t)x_0 + tx_1, \quad t \in [0, 1]$$

传统流模型用常微分方程求解

$$dy_t = v_{\Theta}(y_t, t) dt$$

训练成本高

定义一个向量场生成概率路径

$$z_t = a_t x_0 + b_t \epsilon \quad \text{where } \epsilon \sim \mathcal{N}(0, I).$$

条件向量场

$$\psi_t(\cdot|\epsilon) : x_0 \mapsto a_t x_0 + b_t \epsilon$$

$$u_t(z|\epsilon) := \psi'_t(\psi_t^{-1}(z|\epsilon)|\epsilon)$$

$$\psi_t^{-1}(z|\epsilon) \text{ 即 } x_0$$

条件流匹配

$$\mathcal{L}_{CFM} = \mathbb{E}_{t, p_t(z|\epsilon), p(\epsilon)} \|v_{\Theta}(z, t) - u_t(z|\epsilon)\|_2^2$$

$$\mathcal{L}_{CFM} = \mathbb{E}_{t, p_t(z|\epsilon), p(\epsilon)} \left\| v_{\Theta}(z, t) - \frac{a'_t}{a_t} z + \frac{b_t}{2} \lambda'_t \epsilon \right\|_2^2 \quad (11)$$

$$= \mathbb{E}_{t, p_t(z|\epsilon), p(\epsilon)} \left(-\frac{b_t}{2} \lambda'_t \right)^2 \|\epsilon_{\Theta}(z, t) - \epsilon\|_2^2 \quad (12)$$

$$\lambda_t := \log \frac{a_t^2}{b_t^2}$$

$$\text{where we defined } \epsilon_{\Theta} := \frac{-2}{\lambda'_t b_t} (v_{\Theta} - \frac{a'_t}{a_t} z).$$



改进的修正流模型

修正流模型中 $z_t = (1 - t)x_0 + t\epsilon$,

$$w_t^{\text{RF}} = \frac{t}{1-t}.$$

加权训练中每个时间步的重要性

时序噪声采样器(SNR): 更频繁地采样对生成影响比较大的中间时间步, 调整每个时间步的噪声的重要性, 使模型在训练过程中更关注中间时间步的噪声预测

01 Logit-Normal Sampling

$$\pi_{\text{ln}}(t; m, s) = \frac{1}{s\sqrt{2\pi}} \frac{1}{t(1-t)} \exp\left(-\frac{(\text{logit}(t) - m)^2}{2s^2}\right)$$

02 Mode Sampling with Heavy Tails

$$f_{\text{mode}}(u; s) = 1 - u - s \cdot \left(\cos^2\left(\frac{\pi}{2}u\right) - 1 + u\right)$$


03 CosMap

$$\pi_{\text{CosMap}}(t) = \left| \frac{d}{dt} f^{-1}(t) \right| = \frac{2}{\pi - 2\pi t + 2\pi t^2}.$$





MM-DiT



(a) Overview of all components.

Caption: 用户输入的文本描述

noised Latent: 初始噪声图像

x : 初始噪声图像分块+位置信息


y : CLIP文本编码器池化输出的整体语义向量, 并添加了时间步信息

c : 3个文本编码器输出的所有token, 细粒度的文本内容描述





MM-DiT



(b) One MM-DiT block

图像patch和文本token这两个模态通过不同权重合成序列，并输入到Attention层

图像和文本在Attention层中相互可见，实现了双向信息流

文本信息和图像信息双向交互，文本可以引导图像生成的方向，图像也可以对齐文本

最终，模型生成了更符合文本描述的图片token，并在去噪过程中逐步被恢复成图像





实验设计

实验目的：验证哪种normalizing flows的训练方法最有效

优化算法、模型架构、数据集保持一致。

训练数据集：ImageNet、CC12M

variant	rank averaged over		
	all	5 steps	50 steps
rf/lognorm(0.00, 1.00)	1.54	1.25	1.50
rf/lognorm(1.00, 0.60)	2.08	3.50	2.00
rf/lognorm(0.50, 0.60)	2.71	8.50	1.00
rf/mode(1.29)	2.75	3.25	3.00
rf/lognorm(0.50, 1.00)	2.83	1.50	2.50
eps/linear	2.88	4.25	2.75
rf/mode(1.75)	3.33	2.75	2.75
rf/cosmap	4.13	3.75	4.00
edm(0.00, 0.60)	5.63	13.25	3.25
rf	5.67	6.50	5.75
v/linear	6.83	5.75	7.75
edm(0.60, 1.20)	9.00	13.00	9.00
v/cos	9.17	12.25	8.75
edm/cos	11.04	14.25	11.25
edm/rf	13.04	15.25	13.25
edm(-1.20, 1.20)	15.58	20.25	15.00

表1是不同训练方法的EMA权重（模型参数的加权平均）和非EMA权重（模型即时参数）的综合排名，反映的模型的稳定性和训练质量。

结果：rf/lognorm(0.00,1.00)表现最好

Table 1. Global ranking of variants. For this ranking, we apply non-dominated sorting averaged over EMA and non-EMA weights, two datasets and different sampling settings.





实验设计

实验目的：验证哪种normalizing flows的训练方法最有效

优化算法、模型架构、数据集保持一致。

训练数据集：ImageNet、CC12M

variant	ImageNet		CC12M	
	CLIP	FID	CLIP	FID
rf	0.247	49.70	0.217	94.90
edm(-1.20, 1.20)	0.236	63.12	0.200	116.60
eps/linear	0.245	48.42	0.222	<u>90.34</u>
v/cos	0.244	50.74	0.209	97.87
v/linear	0.246	51.68	0.217	100.76
rf/lognorm(0.50, 0.60)	0.256	80.41	<u>0.233</u>	120.84
rf/mode(1.75)	<u>0.253</u>	44.39	0.218	94.06
rf/lognorm(1.00, 0.60)	<u>0.254</u>	114.26	0.234	147.69
rf/lognorm(-0.50, 1.00)	0.248	<u>45.64</u>	0.219	89.70
rf/lognorm(0.00, 1.00)	0.250	<u>45.78</u>	<u>0.224</u>	<u>89.91</u>

Table 2. **Metrics for different variants.** FID and CLIP scores of different variants with 25 sampling steps. We highlight the **best**, second best, and *third best* entries.

指标：CLIP（图像和文本匹配度）、FID（生成图像质量，越低越好）

表2是相同采样下训练方法在两个数据集上的指标，

结论： rf/lognorm(0.00,1.00)整体表现不错





实验设计

实验目的：优化训练模型架构

01

扩散模型的自编码器的潜在通道数（存储信息空间的维度，越高可能表示能提供更多特征信息） d 增加可以提升模型性能，最终选择 $d=16$

Metric	4 chn	8 chn	16 chn
FID (↓)	2.41	1.56	1.06
Perceptual Similarity (↓)	0.85	0.68	0.45
SSIM (↑)	0.75	0.79	0.86
PSNR (↑)	25.12	26.40	28.62

02

合成生成的captions可以提升文生图模型训练性能，使用50%原始标题+50%CogVLM合成标题

	Original Captions	50/50 Mix
	success rate [%]	success rate [%]
Color Attribution	11.75	24.75
Colors	71.54	68.09
Position	6.50	18.00
Counting	33.44	41.56
Single Object	95.00	93.75
Two Objects	41.41	52.53
Overall score	43.27	49.78






实验结果

实验目的：验证MM-DiT架构的表现最优越

用上文的训练配置比较已有的基于Transformer架构和MM-DiT 在 CC12M数据集上的结果，对于MM-DiT还比较了2套权重（文本和图像）、03套权重（三个文本编码器生成token）



发现MM-DiT明显表现更好，且2权重跟3权重区别不大，选效率更高的2权重





实验结果




Figure 6. **Timestep shifting at higher resolutions.** Top right: Human quality preference rating when applying the shifting based on Equation (23). Bottom row: A 512^2 model trained and sampled with $\sqrt{m/n} = 1.0$ (top) and $\sqrt{m/n} = 3.0$ (bottom). See Section 5.3.2.

大规模训练架构优化:

QK归一化/可变纵横比位置编码/时间步移位

大规模训练MM-DiT后，发现论文模型（stable diffusion3）总体表现最好




Figure 7. **Human Preference Evaluation against current closed and open SOTA generative image models.** Our 8B model compares favorable against current state-of-the-art text-to-image models when evaluated on the parti-prompts (Yu et al., 2022) across the categories *visual quality*, *prompt following* and *typography generation*.





实验结果

大规模训练MM-DiT后，发现随着模型规模更大、训练部步数越多，模型性能提升（没有观察到性能饱和）




Figure 8. Quantitative effects of scaling. We analyze the impact of model size on performance, maintaining consistent training hyperparameters throughout. An exception is depth=38, where learning rate adjustments at 3×10^5 steps were necessary to prevent divergence. (Top) Validation loss smoothly decreases as a function of both model size and training steps for both image (columns 1 and 2) and video models (columns 3 and 4). (Bottom) Validation loss is a *strong predictor of overall model performance*. There is a marked correlation between validation loss and holistic image evaluation metrics, including GenEval (Ghosh et al., 2023), column 1, human preference, column 2, and T2I-CompBench (Huang et al., 2023), column 3. For video models we observe a similar correlation between validation loss and human preference, column 4. .





实验结果

作者还评估了基于MM-DiT的rectified flow使用文本编码器的灵活性。

用多个文本编码器主要目的是提升生成图片的质量，但如果为了节省显存，去掉有47亿参数的T5，发现只有在复杂提示下，用3个文本编码器才会带来明显提升。




Figure 9. Impact of T5. We observe T5 to be important for complex prompts e.g. such involving a high degree of detail or longer spelled text (rows 2 and 3). For most prompts, however, we find that removing T5 at inference time still achieves competitive performance.





继续研究

Basic framework

01



改进模型架构，提
升模型的生成速度，
节约硬件资源

02



扩展sd3模型的应用
到视频生成等领域

03



优化合成文本生成
技术，进一步提高
模型的生成质量。





THANKS
