

单位代码： 10293 密 级： 公开

南京邮电大学

# 专业学位硕士学位论文



论文题目： 融合结构感知图表示与大语言模型智能体的知识  
图谱规则学习研究

|        |                  |
|--------|------------------|
| 学 号    | <u>B22040029</u> |
| 姓 名    | <u>葛益昊</u>       |
| 导 师    | <u>徐康</u>        |
| 专业学位类别 | <u>计算机硕士</u>     |
| 类 型    | <u>全日制</u>       |
| 专业（领域） | <u>计算机技术</u>     |
| 论文提交日期 | <u>2026.6</u>    |

## 摘要

知识图谱规则学习是人工智能领域的重要研究方向，旨在从结构化知识库中挖掘逻辑规则以增强推理能力，对知识图谱补全、智能问答等下游任务具有关键作用。然而，现有规则方法普遍面临两个核心挑战：一是未能有效建模知识图谱的结构信息，导致难以捕捉潜在的高阶语义关联，影响链接预测等任务表现；二是过度依赖统计置信度评估规则质量，忽略规则的语义合理性与可解释性。本文针对上述问题展开研究，提出了两种知识图谱规则学习方法，主要贡献有以下三个方面：

针对现有规则学习方法未能有效建模知识图谱中结构信息的问题，本文提出结构感知规则学习方法 SARL。该方法引入结构感知图编码器，融合局部邻域与全局路径的多粒度结构信息，通过广义注意力机制动态聚合图谱结构，实现对多跳关系路径的建模；同时设计注意力加权规则解码器，结合图谱拓扑结构特征动态生成推理规则。在 UMLS 和 FB15K-237 数据集上，相比 Ruleformer、ChatRule 等 SOTA 方法，MRR 分别提升了 3.6% 和 6.6%，Hits@1 指标实现了 4.2% 和 4.5% 的显著提升。

针对现有方法在生成规则时过于依赖统计置信度而忽视规则语义合理性的问题，提出了基于反馈驱动蒙特卡洛树搜索和大语言模型智能体的规则学习方法 FD-MCTS。该方法引入大语言模型评估规则语义，并结合蒙特卡洛树搜索探索潜在规则路径，同时利用反馈机制持续优化智能体决策策略，提升规则生成的语义合理性和可解释性。实验结果表明，在 UMLS 和 FB15K-237 上，较 Ruleformer、ChatRule 等 SOTA 方法，MRR 分别提升了 6.0% 和 9.2%，Hits@1 指标分别提升了 5.8% 和 9.5%，并显著提升了规则的质量和可解释性。

基于上述规则学习模型，设计并实现了一个知识图谱规则学习系统。该系统旨在帮助用户从常用知识图谱中提取逻辑规则，减少数据标注对人工的依赖，实现自动化数据标注，并展示学习结果。系统界面友好，操作便捷，实现了从算法研究到实际应用的落地，具备良好的扩展性与实用价值。

**关键词：**规则学习，知识图谱推理，多头注意力机制，大语言模型，蒙特卡洛树搜索

# Abstract

Knowledge graph rule learning is a vital research area in artificial intelligence, aiming to mine logical rules from structured knowledge bases to enhance reasoning capabilities. It plays a key role in downstream tasks such as knowledge graph completion and intelligent question answering. However, existing rule learning approaches face two critical challenges: (1) they fail to effectively model the structural information inherent in knowledge graphs, making it difficult to capture implicit high-order semantic correlations, which negatively affects tasks like link prediction; (2) they rely excessively on statistical confidence measures for rule evaluation, overlooking the semantic validity and interpretability of the rules. To address the above issues, this paper proposes two novel rule learning methods for knowledge graphs, and the main contributions are summarized as follows:

To address the insufficient modeling of structural information in existing rule learning approaches, this paper proposes Structure-Aware Rule Learning (SARL). This method incorporates a structure-aware graph encoder that integrates both local neighborhood and global path information with multi-granularity structure perception. A generalized attention mechanism is introduced to dynamically aggregate subgraph features, enabling effective multi-hop relation modeling. In addition, an attention-weighted rule decoder is designed to dynamically generate logical rules conditioned on graph topological structures. Experimental results on four benchmark datasets, including UMLS and FB15K-237, show that SARL significantly outperforms state-of-the-art methods in link prediction. Specifically, SARL improves MRR by 3.6% and 6.6% and Hits@1 by 4.2% and 4.5% over Ruleformer and ChatRule on UMLS and FB15K-237, respectively.

To overcome the limitation of existing methods that over-rely on statistical confidence scores while ignoring the semantic soundness of the rules, this paper proposes a novel Feedback-Driven Monte Carlo Tree Search (FD-MCTS) rule learning framework. This method incorporates a large language model (LLM) as a semantic evaluator to assess the logical rationality of rule candidates. By combining Monte Carlo Tree Search with LLM-based feedback, the framework explores the space of rule paths and continuously refines its decision policy through a feedback-driven mechanism. Notably, it effectively identifies and avoids rules that achieve high statistical confidence due to knowledge graph incompleteness or bias, but which are semantically invalid or logically incorrect in the real world. Experimental results on datasets such as UMLS and FB15K-237 demonstrate substantial improvements in both performance and rule interpretability. Compared to Ruleformer and ChatRule, FD-MCTS achieves MRR gains of 6.0% and 9.2%, and Hits@1 improvements of 5.8% and 9.5%,

---

respectively.

Based on the proposed rule learning models, this paper designs and implements a practical knowledge graph rule learning system. The system helps users extract logical rules from widely used knowledge graphs, reduces reliance on manual data labeling, and supports automatic annotation of large-scale structured data. The system features a user-friendly interface with intuitive interaction, making it easy to operate and scalable for real-world applications. This work bridges the gap between theoretical research and practical deployment, demonstrating the applicability and value of the proposed methods.

**Key Words:** Rule Learning, Knowledge Graph Reasoning, Multi-head Attention Mechanism, Large Language Models, Monte Carlo Tree Search

# 目 录

|                                         |     |
|-----------------------------------------|-----|
| 摘要 .....                                | i   |
| Abstract .....                          | ii  |
| 插图索引 .....                              | vi  |
| 表格索引 .....                              | vii |
| 第一章 绪论 .....                            | 1   |
| 1.1 研究背景 .....                          | 1   |
| 1.2 国内外研究现状 .....                       | 2   |
| 1.2.1 基于逻辑规则的规则学习方法 .....               | 2   |
| 1.2.2 基于向量嵌入的规则学习方法 .....               | 3   |
| 1.3 本文研究内容 .....                        | 4   |
| 1.4 本文组织结构 .....                        | 6   |
| 第二章 相关背景知识介绍 .....                      | 7   |
| 2.1 规则学习 .....                          | 7   |
| 2.2 Transformer 模型 .....                | 7   |
| 2.2.1 自注意力机制 .....                      | 8   |
| 2.2.2 多头注意力机制 .....                     | 9   |
| 2.2.3 位置编码 .....                        | 9   |
| 2.2.4 前馈神经网络 .....                      | 10  |
| 2.3 图神经网络 .....                         | 10  |
| 2.3.1 图卷积网络 .....                       | 10  |
| 2.4 本章小结 .....                          | 11  |
| 第三章 基于结构感知图编码器与广义注意力机制的规则学习方法 .....     | 13  |
| 3.1 引言 .....                            | 13  |
| 3.2 模型设计 .....                          | 14  |
| 3.2.1 问题描述 .....                        | 14  |
| 3.2.2 模型概览 .....                        | 15  |
| 3.2.3 结构感知图编码器 .....                    | 15  |
| 3.2.4 规则解码器 .....                       | 17  |
| 3.2.5 训练和规则学习算法设计 .....                 | 18  |
| 3.3 表达能力分析 .....                        | 19  |
| 3.4 复杂度分析 .....                         | 22  |
| 3.5 实验结果与分析 .....                       | 22  |
| 3.6 本章小结 .....                          | 22  |
| 第四章 基于反馈驱动蒙特卡洛树搜索和大语言模型智能体的规则学习方法 ..... | 24  |
| 4.1 引言 .....                            | 24  |
| 4.2 模型设计 .....                          | 25  |
| 4.2.1 FD-MCTS 相关函数设计 .....              | 26  |
| 4.2.2 FD-MCTS 搜索算法 .....                | 27  |
| 4.2.3 FD-MCTS 反馈学习算法 .....              | 28  |
| 4.2.4 FD-MCTS 大语言模型智能体相关提示词设计 .....     | 31  |
| 4.3 实验结果与分析 .....                       | 32  |
| 4.3.1 数据集 .....                         | 32  |
| 4.3.2 链接预测 .....                        | 35  |
| 4.3.3 评价指标 .....                        | 35  |
| 4.3.4 实验设置 .....                        | 35  |
| 4.3.5 实验结果 .....                        | 36  |
| 4.3.6 消融实验 .....                        | 37  |
| 4.4 本章小结 .....                          | 38  |
| 第五章 知识图谱规则学习原型系统的设计与实现 .....            | 40  |
| 5.1 系统需求分析 .....                        | 40  |
| 5.2 系统设计 .....                          | 41  |
| 5.2.1 系统功能模块设计 .....                    | 41  |

---

|       |                         |    |
|-------|-------------------------|----|
| 5.2.2 | 系统结构设计 .....            | 42 |
| 5.3   | 系统实现与展示 .....           | 45 |
| 5.3.1 | 用户管理模块 .....            | 45 |
| 5.3.2 | 规则学习模块 .....            | 46 |
| 5.3.3 | 模型管理模块 .....            | 47 |
| 第六章   | 总结与展望 .....             | 49 |
| 6.1   | 本文工作总结 .....            | 49 |
| 6.2   | 进一步研究方向 .....           | 50 |
| 参考文献  | .....                   | 51 |
| 附录A   | 程序清单 .....              | 54 |
| 附录B   | 攻读专业学位硕士期间撰写的论文 .....   | 55 |
| 附录C   | 攻读专业学位硕士期间申请的专利 .....   | 56 |
| 附录D   | 攻读专业学位硕士期间参加的科研项目 ..... | 57 |
| 致谢    | .....                   | 58 |

## 插图索引

|                                                            |    |
|------------------------------------------------------------|----|
| 图 1.1 FreeBase 知识图谱示例 .....                                | 1  |
| 图 2.1 Transformer 模型架构图 .....                              | 9  |
| 图 3.1 局部感知 (Local-aware) 与结构感知 (Structure-aware) 对比图 ..... | 17 |
| 图 3.2 SARL 模型结构图 .....                                     | 18 |
| 图 4.1 基于反馈驱动蒙特卡洛树搜索的智能体模型结构图 .....                         | 31 |
| 图 4.2 UMLS 和 FB15K-237 数据集上排名靠前的规则的平均置信度 .....             | 52 |
| 图 5.1 系统架构图 .....                                          | 59 |
| 图 5.2 用户管理流程图 .....                                        | 64 |
| 图 5.3 用户管理页面 .....                                         | 66 |
| 图 5.4 规则学习与模型管理模块流程图 .....                                 | 68 |
| 图 5.5 规则学习与模型管理模块页面 .....                                  | 68 |

表格索引

|       |                                             |    |
|-------|---------------------------------------------|----|
| 表 3.1 | 模型推理的空间复杂度和时间复杂度比较 .....                    | 27 |
| 表 4.1 | 执行规则选择动作后的状态对比反馈提示词 .....                   | 39 |
| 表 4.2 | 用于智能体生成搜索树中规则状态节点价值预测的提示词 .....             | 40 |
| 表 4.3 | 智能体执行状态价值评估提示词 .....                        | 42 |
| 表 4.4 | 策略函数反馈记忆提示词 .....                           | 42 |
| 表 4.5 | 价值函数反馈记忆提示词 .....                           | 43 |
| 表 4.6 | 数据集介绍 .....                                 | 45 |
| 表 4.7 | 针对 UMLS、FB15K-237 和 WN18RR 数据集的链接预测结果 ..... | 49 |
| 表 4.8 | 结构感知图编码器结合不同智能体性能与字符消耗数量对比 .....            | 50 |
| 表 4.9 | FD-MCTS 结合不同大模型效果对比 .....                   | 50 |
| 表 5.1 | 用户信息表 .....                                 | 61 |
| 表 5.2 | 历史记录表 .....                                 | 63 |
| 表 5.3 | 模型管理表 .....                                 | 63 |
| 表 5.4 | 日志记录表 .....                                 | 63 |



# 第一章 绪论

## 1.1 研究背景

随着数字化时代的到来，信息的产生和传播速度达到了前所未有的高度。人们每天都在面对海量的数据，这些数据蕴含着丰富的知识，但如何有效地挖掘和利用这些知识成为了亟待解决的问题。知识图谱是一种结构化的语义知识库，以图的形式表示实体及其之间的关系<sup>[1]</sup>，例如 FreeBase<sup>[2]</sup>，如图1.1所示。知识图谱可以定义为一个有向图  $G = (E, R)$ ，其中  $E$  是实体的集合， $R$  是关系的集合。每个实体  $e_i \in E$  可以是现实世界中的一个对象，如一个人、一个地点或一个概念。关系  $r_j \in R$  是实体之间的某种联系，如“首都”关系可以连接实体“中国”和“北京”。它整合了来自不同数据源的信息，提供了统一的知识表示框架，通过图结构清晰地展现知识之间的关联，为知识的表示和推理提供了一种强大的工具，同时还能帮助人们更好地理解 and 利用知识。在人工智能领域，知识图谱的应用范围广泛，涵盖了搜索引擎、推荐系统、问答系统等多个重要场景，在智能问答系统中，为问答提供知识基础，辅助系统精准回答<sup>[3,4]</sup>；在推荐系统领域，通过挖掘知识图谱中的关系，为用户提供个性化推荐<sup>[5,6]</sup>。




图 1.1 FreeBase 知识图谱示例

然而，在知识图谱应用中，关系事实缺失是长期存在的核心挑战<sup>[7]</sup>。尽管现有知识图谱已经包含了大量的关系事实，由于数据源的异构性、非结构化文本隐含关系的复杂性以及动态演化的现实世界知识等原因，现有知识图谱普遍存在关系覆盖不全的问题。这种关系事实的缺失直接影响了在知识图谱上进行推理任务的性能。例如，在知识图谱问答系统中，由于知识的不完整性，系统的准确性和可靠性会显著下降，缺失的关系也限制了预测效果；多模态学习和语义搜索等任务也依赖知识图谱的完整性。

## 1.2 国内外研究现状

当前，针对知识图谱规则学习展开了诸多研究，主要可分为两大类：1) 基于逻辑规则的规则学习方法；2) 基于向量嵌入的规则学习方法。

### 1.2.1 基于逻辑规则的规则学习方法

基于逻辑规则的规则学习方法主要通过挖掘知识图谱 (KG) 中关系与局部结构间的语义关联，以实现可解释的知识图谱补全。Neural LP<sup>[9]</sup> 是首个以端到端可微分方式学习一阶逻辑规则的研究，它通过将推理任务编译成一系列可微分操作来建模规则的参数与结构。基于 Neural LP，DRUM<sup>[10]</sup> 通过引入额外的空关系，将规则学习与推理扩展到可变长度模式，从而能够学习更丰富的规则并进行更准确的推理。

为了同时学习知识图谱的拓扑上下文和逻辑规则，JSSKGE<sup>[11]</sup> 采用图注意力网络来聚合实体的局部结构信息，然后利用知识图谱中隐含的软逻辑规则作为专家来进一步修正嵌入向量，通过联合学习方法实现知识图谱补全和规则学习。然而，由于知识图谱的开放世界假设，上述一次性规则学习方法无法完全反映实际情况，因此提出了一些用于规则学习与推理的迭代模型。例如，pLogicNet<sup>[12]</sup> 在变分 EM 框架中结合了知识图谱嵌入和规则学习，在 E 步骤中使用事实嵌入模型来推断缺失的三元组，而在 M 步骤中则根据观察到和预测的三元组更新逻辑规则的权重。类似地，在 RNNLogic<sup>[13]</sup> 框架中，规则生成器与推理预测器协同工作，通过迭代优化提升性能。每轮迭代分为三个步骤：首先，更新推理预测器，使其能够探索潜在的逻辑规则；接着，运用后验推理机制，结合规则生成器和推理预测器，筛选出高质量的规则；最后，在这些优质规则的指导下，对规则生成器进行更新，以进一步提升其生成规则的质量和推理预测器的准确性。

Ruleformer<sup>[14]</sup> 采用基于 Transformer 架构的编码器 - 解码器模型，将规则挖掘过程视为序列到序列任务，这种序列生成的方式使得模型能够灵活地根据上下文信息选择合适的规则，从而提高规则挖掘的准确性和可解释性。RLogic<sup>[15]</sup> 引入了基于谓词表示学习的评分模型，通过学习谓词的低维向量表示来捕捉谓词之间的语义关系，从而评估规则的有效性。此外，RLogic 将顺序规则学习算法递归地整合到多个小型原子模型中，它将大型的顺序模型分解为多个小型的原子模型，每个原子模型负责处理规则学习过程中的一个递归步骤。LATENTLOGIC<sup>[16]</sup> 将知识图谱中的关系路径映射到潜在空间，通过预训练的变分自编码器 (VAE) 和基于能量的判别器构建联合分布，该方法利用常微分方程 (ODE) 采样器在潜在空间中高效生成逻辑

规则，避免了传统方法中关系路径的穷举搜索。NCRL<sup>[17]</sup> 通过检测并递归分解复合逻辑规则来预测单个规则头。AnyBURL<sup>[18]</sup> 通过在知识图谱中进行随机游走，生成随机路径，然后将这些路径泛化为规则，并引入对象唯一性约束，确保规则中的不同变量不能被同一实体实例化，同时采用强化学习优化路径采样。ChatRule<sup>[19]</sup> 使用基于 LLM 的规则生成器，通过结合知识图谱的语义和结构信息来生成候选规则，接着引入了规则排名器。采用支持度、覆盖率、置信度和 PCA 置信度等指标来评估规则的质量，最后，经过排名的规则被用于基于规则的逻辑推理模块，以进行知识图谱的推理任务。

总体而言，这些融合规则的方法因其可解释性优势具有巨大的应用潜力。然而，这些规则学习方法在有效利用知识图谱中实体周围的结构信息方面存在不足，导致所学的逻辑规则无法适用。此外，这些工作忽略了知识图谱中规则的语义信息，导致规则运用至下游任务时适用性不强。

### 1.2.2 基于向量嵌入的规则学习方法

基于向量嵌入的规则学习方法近年来在知识图谱的表示学习领域取得了显著进展。这些方法通过将实体和关系映射到低维向量空间，旨在捕捉知识图谱中的语义和结构信息。根据其关注点和建模方式的不同，可以将其主要分为基于事实的向量嵌入方法和基于拓扑结构的向量嵌入方法两大类。此外，随着研究的深入，越来越多的工作尝试结合新的技术（如 Transformer<sup>[20]</sup>）和策略来进一步提升向量嵌入的表现。

#### （1）基于事实的向量嵌入方法

基于事实的向量嵌入方法以知识图谱中的事实三元组为基础，形式  $(h, r, t)$ ，即头实体、关系、尾实体，通过优化随机初始化的实体和关系表示来计算三元组的得分。这种方法主要分为平移距离模型和语义匹配模型两大代表性类型<sup>[21]</sup>。平移距离模型通过定义头实体和尾实体在特定关系平移后的距离来衡量三元组的有效性。TransE<sup>[22]</sup> 是这一类型的开创性模型，也是最流行的方法之一。它要求在向量空间  $R^d$  中，头实体表示加上关系表示后应接近尾实体表示，即  $\mathbf{h} + \mathbf{r} \approx \mathbf{t}$ 。在此基础上，TransH<sup>[23]</sup> 引入了关系特定的超平面以扩展关系平移，而 RotatE<sup>[24]</sup> 则将 TransE 的加法操作从实数空间转换为复数空间中的旋转操作，从而提升了建模能力。CompoundE<sup>[25]</sup> 提出了一种结合平移、旋转和缩放操作的 KGE 模型，泛化了多种基于距离的 KGE 方法。

特征。**Tucker**<sup>[29]</sup> 基于 **Tucker** 分解<sup>[30]</sup>，通过核心张量与实体、关系嵌入向量的交互来计算三元组的得分，以衡量三元组的有效性。它利用核心张量捕捉实体和关系之间的复杂交互模式，从而判断实体和关系在语义上的匹配程度。**ComplEx**<sup>[31]</sup> 则将嵌入向量从实数空间扩展到复数空间，以更好地建模非对称关系。在复数空间中，通过使用 **Hermitian** 点积，处理关系的对称性和反对称性，其将评分函数定义为复数嵌入向量之间的 **Hermitian** 点积的实部，这种设计使得模型能够对知识图谱中的关系进行建模。**LTE-KGE**<sup>[32]</sup> 通过对现有知识图谱嵌入模型中的实体嵌入进行线性变换来增强模型性能。该方法对图卷积网络在知识图谱补全任务中作用重新思考，发现图卷积网络的图结构建模对性能提升影响不大，反而是实体嵌入的线性变换更为关键。通过线性变换实体嵌入，增强了知识图谱嵌入的效果。

这些基于事实的向量嵌入方法仅考虑了三元组信息，导致对知识图谱的建模不足，性能上存在局限性。

## （2）基于拓扑结构的向量嵌入方法

为了更全面地嵌入知识图谱的信息，基于拓扑结构的向量嵌入方法被提出。这类方法主要基于图卷积网络（**Graph Convolutional Networks, GCNs**），通过迭代聚合邻居节点的信息到目标节点，融合局部的拓扑结构。**RGCN**<sup>[33]</sup> 是将 **GCN** 应用于知识图谱的首项工作，它引入了关系特定的矩阵来处理边的异质性，并提出了基分解和块对角分解以避免过参数化和过拟合问题。随后，**VRGCN**<sup>[34]</sup> 和 **CompGCN**<sup>[35]</sup> 提出了同时学习实体和关系嵌入的框架，适用于多关系知识图谱。**CompGCN** 通过多种实体-关系组合操作，不仅高效，还能泛化到多种多关系 **GCN** 方法。

这些方法因能够建模知识图谱的拓扑上下文而表现出色，并被广泛应用。然而，它们在处理实体和关系的内在语义方面存在不足。此外，建模知识图谱中的高级语义关联（如逻辑规则）对这类方法而言仍具挑战性。

## 1.3 本文研究内容

为了解决现有规则学习方法未能有效建模知识图谱中结构信息的问题，以及在生成规则时过于依赖统计置信度而忽视规则语义合理性，导致生成的规则在下游任务中表现不佳的问

题，本文对国内外规则学习的相关工作进行了充分的调研，并对现有方法进行深入地分析，构建了两个规则学习模型并实现了一个知识图谱规则学习系统。本文具体的研究内容如下：

针对现有规则学习方法未能有效建模知识图谱中结构信息的问题，提出了一种融合局部与全局信息的结构感知规则学习方法（**Structure-Aware Rule Learning, SARL**）。该方法采用编码器-解码器架构。对于图编码器而言，采用双层编码架构，分别设计了局部级图编码器和全局级图编码器来捕获多粒度结构信息。一方面，为了克服传统方法仅关注 1 跳邻域的局限性，通过广义注意力机制构建局部级图编码器，动态聚合头实体的多跳邻域结构信息；另一方面，为了捕捉实体间的全局关系路径，设计了全局级图编码器使每个实体能够感知整个子图的拓扑结构。对于解码器而言，为了增强结构特征与规则生成的关联性，提出基于注意力加权的规则解码器，在推理过程中动态选择最符合当前子图特征的逻辑规则。在 UMLS、FB15K-237 等四个知识图谱基准数据集上的实验表明，该方法在链接预测任务中取得了最先进的性能。具体而言，本方法的创新性体现在：1) 提出融合局部与全局信息的结构感知图编码器，首次实现局部邻域信息与全局关系路径信息的建模；2) 设计广义注意力机制，通过可替换特征提取器增强实体对子图结构的表征能力；3) 验证了结构感知编码器在多跳推理任务中的有效性，为知识图谱推理提供新的技术路径。该编码器框架可扩展应用于知识问答、复杂关系推理等下游任务。

## 1.4 本文组织结构

本文主要内容分为六个章节，每个章节的具体内容如下：第一章是绪论，首先介绍了知识图谱规则学习的研究背景和研究意义，接着总结了知识图谱规则学习面临的两大挑战，然后全面介绍了知识图谱规则学习技术国内外研究现状，最后提出了本文的主要研究内容。

第二章是相关背景知识介绍，主要介绍了本文研究过程中所涉及的相关理论知识。包括规则学习任务介绍、Transformer 模型、图神经网络、强化学习与蒙特卡洛搜索树、大语言模型和 AI 智能体。

第三章针对现有规则学习方法未能有效建模知识图谱中结构信息的问题，提出了一种融合局部与全局信息的结构感知规则学习模型。首先对模型的各个模块进行了详细的介绍，通过结构感知图编码器中的局部级编码与全局级编码捕捉知识图谱中的结构特征，同时采用广义注意力机制建模实体的邻域结构，捕捉实体对之间的联系信息，然后介绍了模型中具体的规则学习方法，接着介绍了模型采用的目标函数和训练方法，并对模型的表达能力和复杂度进行了理论分析，之后对实验设置进行了描述，包括实验所用数据集、评价指标、对比方法以及参数设置，最后给出链接预测任务的实验结果与消融实验的结果，并对结果进行分析。

第四章针对知识图谱规则学习任务中，现有方法在生成规则时过于依赖统计置信度而忽视规则语义合理性，导致生成的规则在下游任务中表现不佳的问题，采用一种基于反馈驱动蒙特卡洛树搜索和大语言模型智能体的规则学习模型。本章首先介绍所提模型中的相关函数设计，包括节点选择函数、策略函数、价值函数等，接着介绍提出的 FD-MCTS 规则学习模型中的搜索算法及提出的反思学习算法，之后对模型中涉及到的提示词设计进行了介绍，最后同样是对实验设置的介绍、实验结果的展示与分析。

第五章基于前两章提出的规则学习算法，设计并实现了一个知识图谱规则学习系统，旨在帮助用户从常用知识图谱中提取逻辑规则，同时减少数据标注对人工的依赖。

第六章负责总结与展望，着重对本文的研究内容与成果予以总结，剖析所提方法的优劣，并对未来的研究重点开展展望。

## 第二章 相关背景知识介绍

### 2.1 规则学习

规则学习在知识图谱中具有重要作用。它可以帮助发现实体间隐含的关系，从而提升知识图谱的完整性和可用性。例如，规则学习可以揭示出“如果一个人工作于一个组织，而该组织属于一个国家，那么这个人具有该国国籍”这样的关系。规则学习的核心是从数据中学习规则。在知识图谱的背景下，这些规则通常以逻辑规则的形式表示。Horn 规则作为一种符号化的、一阶逻辑规则的特定类，由两个部分组成：规则头  $r_h$  和规则体  $r_b$ 。形式上，Horn 规则表现为：

$$r_h(x, y) \leftarrow r_{b1}(x, z_1) \wedge \cdots \wedge r_{bn}(z_{n-1}, y) \quad (2.1)$$

其中， $r_h(x, y)$  是规则头，代表规则的结论或结果，而  $r_{b1}(x, z_1) \wedge \cdots \wedge r_{bn}(z_{n-1}, y)$  是规则体，代表为了推导出规则头，必须全部成立的一系列条件。这种结构能够灵活地表示知识库中复杂的依赖关系。例如，一个以  $\text{nationality}(x, y)$  为规则头的规则，其规则体可能是  $\text{worksAt}(x, z)$  和  $\text{belongsTo}(z, y)$  的组合，表示如果一个人  $x$  在组织  $z$  工作，而该组织属于国家  $y$ ，那么可以推断出  $x$  的国籍是  $y$ ，这正是 Horn 规则在知识图谱中实际应用的一个例子。规则学习在知识图谱中也有广泛的应用。例如，在关系预测任务中，规则学习可以帮助预测两个实体之间是否存在某种关系。规则学习还可以用于知识图谱的补全，即通过已知的规则来推断缺失的三元组<sup>[50]</sup>，进而增强知识图谱的完整性和推理能力。

### 2.2 Transformer 模型

在 Transformer 模型出现之前，循环神经网络及其变体，如长短时记忆网络<sup>[51]</sup> 和门控循环单元<sup>[52]</sup>，是处理序列任务的主流架构。这些模型逐步处理序列，因此其本质是序列化的，这限制了它们的并行化能力。虽然卷积神经网络<sup>[53]</sup> 也被用于处理序列数据，并且可以并行处理序列中的多个位置，但其计算复杂度仍然与序列长度相关，且需要多层卷积才能捕捉长距离依赖关系。2017 年，Vaswani 等人<sup>[20]</sup> 摒弃了传统的循环和卷积结构，首次提出了 Transformer 模型，该模型完全基于自注意力机制，从而实现了更高的并行性和更快的训练速度，其架构如图2.1所示。

Transformer 模型采用了经典的编码器-解码器（Encoder-Decoder）结构。编码器将输入的符号序列  $(x_1, x_2, \dots, x_n)$  变换成一组连续的表示  $(z_1, z_2, \dots, z_n)$ ，而解码器则按顺序逐一生成




图 2.1 Transformer 模型架构图

输出符号序列  $(y_1, y_2, \dots, y_m)$ 。解码过程具有自回归特性，即每一轮生成的输出会与输入相结合，构成下一轮的输入数据。

### 2.2.1 自注意力机制

自注意力机制允许模型在处理输入序列中的每个元素时，能够根据其与其他元素的相关性来分配权重。

在注意力机制中，每个输入序列的元素  $x_i$  首先被映射为三个独特的向量：查询向量  $q_i$ 、键向量  $k_i$  以及值向量  $v_i$ 。这一映射过程通过将  $x_i$  与特定的权重矩阵  $W_q$ 、 $W_k$  和  $W_v$  相乘得到。随后，模型会评估每个元素与其他元素之间的关联强度，也就是注意力得分。具体来说，这些得分由查询向量与键向量的点积计算得出。为了使结果更具可解释性，这些得分会被输入到 **softmax** 函数中，转换为一组归一化的注意力权重。最后，基于这些注意力权重，模型对值向量  $v_i$  执行加权平均操作，从而生成每个元素的最终输出向量。这一流程允许模型灵活地聚焦于输入序列的不同区域，捕捉其中的深层联系。数学上，自注意力机制的计算可以表示



为:

$$\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V \quad (2.2)$$

其中,  $Q$ 、 $K$  和  $V$  分别是查询矩阵、键矩阵和值矩阵,  $d_k$  是键向量的维度。这个计算过程允许模型根据每个元素与其他元素的相关性来调整其输出。自注意力机制的一个主要特点是其并行计算的能力。由于不依赖于序列的顺序处理, 自注意力机制可以一次性计算整个序列, 从而大大提高了计算效率。此外, 自注意力机制能够捕捉序列中的长距离依赖关系, 这对于处理诸如自然语言这样的序列数据尤为重要, 因为句子中的词可能在很长的距离上仍然存在语义关联。

### 2.2.2 多头注意力机制

多头注意力机制是自注意力机制的扩展, 主要为了解决自注意力机制可能过度集中于自身位置的问题。它通过将输入序列划分到多个子空间中分别执行自注意力计算, 从而增强了模型的特征表达能力。每个注意力头分别负责捕获独特的注意力模式, 随后将这些头的计算结果进行整合, 并通过一次线性映射生成最终的输出。具体来说, 多头注意力机制的计算过程如下: 首先, 输入序列  $X$  通过三个不同的线性变换层, 分别得到查询 (Query)、键 (Key) 和值 (Value) 矩阵。然后, 将查询、键和值矩阵分成多个头 (即多个子空间), 每个头具有不同的线性变换参数。假设我们有  $h$  个头, 每个头的维度  $d_k = \frac{D_{model}}{h}$ , 其中  $D_{model}$  是模型的维度。对于每个头, 独立地执行自注意力机制计算, 得到每个头的输出。最后, 将所有头的输出拼接在一起, 形成一个长向量, 并对拼接后的向量进行一个最终的线性变换, 以整合来自不同头的信息, 得到最终的多头注意力输出。数学上, 可以表示为:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (2.3)$$

其中,  $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$ ,  $W^O$  是最终输出的线性变换矩阵。

多头注意力机制的优势在于其多样化的注意力模式。通过不同头学习到不同的特征和关系, 模型能够捕捉到输入序列中更为丰富的信息。此外, 多头注意力机制通过分头处理, 使得信息可以更均匀地传递, 缓解了梯度消失问题, 并且能够让模型在处理长序列时, 同时关注到全局和局部的信息。

### 2.2.3 位置编码

Transformer 模型摒弃了传统的递归与卷积设计, 因而必须寻找一种新颖的方式来体现输入序列中词语的排列顺序。为此, 位置编码 (Positional Encoding) 被巧妙地运用。位置编码

可以是固定的，也可以是可学习的。常见的位置编码方式是使用正弦和余弦函数，其公式为：

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2.4)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2.5)$$

其中， $pos$  是词的位置， $i$  是维度索引， $d_{model}$  是模型的维度。

## 2.2.4 前馈神经网络

前馈神经网络（Feed-Forward Neural Network, FFN）是 Transformer 模型中的另一个重要组件。它对每个词进行独立的非线性变换。前馈神经网络通常包含两个线性变换和一个非线性激活函数，其结构可以表示为：

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (2.6)$$

Transformer 模型在自然语言处理（Natural Language Processing, NLP）领域表现卓越，广泛应用于机器翻译、文本分类和序列标注等多种任务。近年来，其应用范围已逐步延伸至计算机视觉（Computer Vision, CV）领域，涵盖图像分类和目标检测等任务。例如，Vision Transformer（ViT）模型<sup>[54]</sup> 通过将图像分解为若干小块并将其作为序列处理，有效地将图像分类任务转化为序列建模问题，实现了高效计算。另一方面，Swin Transformer 模型<sup>[55]</sup> 通过融入基于滑动窗口的自注意力机制，并结合局部感受野的特性，显著提升了计算效率与分类精度。

## 2.3 图神经网络

### 2.3.1 图卷积网络

图卷积网络（Graph Convolutional Network, GCN）是一种专门用于处理图数据的深度学习模型，其基本思想是将传统卷积神经网络在规则网格上的局部卷积操作推广到图的非欧几里得结构上，从而通过聚合邻居节点的信息来更新每个节点的特征表示。设图为  $G = (V, E)$ ，其中  $V$  为节点集， $E$  为边集，图的邻接矩阵  $\mathbf{A}$  为一个  $n \times n$  的矩阵，定义为当  $(i, j) \in E$  时  $\mathbf{A}_{ij} = 1$ ，否则为 0；相应的度矩阵  $\mathbf{D}$  是一个对角矩阵，其对角元为  $\mathbf{D}_{ii} = \sum_j \mathbf{A}_{ij}$ 。由于图数据的拓扑结构不规则，直接利用传统卷积难以实现有效特征提取，因此 GCN 采用了基于图拉普拉斯算子的谱方法。对于无向图，其拉普拉斯矩阵定义为  $\mathbf{L} = \mathbf{D} - \mathbf{A}$ ，该矩阵是半正定的，并可通过特征分解得到  $\mathbf{L} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T$ 。基于此，可以将节点上的信号  $x: V \rightarrow \mathbb{R}$  通过图傅里叶

变换映射到频域，使得在频域上卷积操作转化为乘法运算，即：

$$x * g = \mathbf{U} (\hat{g} \circ \mathbf{U}^T x) \quad (2.7)$$

其中  $\hat{g}$  是滤波器在频域表示。然而，这种方法需要对全图进行特征分解，计算复杂度高，难以应用于大规模图中。

为了解决这一问题，Defferrard 等人<sup>[56]</sup> 提出了利用切比雪夫多项式对滤波器进行近似的方法，将滤波器表示为：

$$g(\mathbf{L}) \approx \sum_{k=0}^K \theta_k T_k(\tilde{\mathbf{L}}) \quad (2.8)$$

其中  $T_k$  为切比雪夫多项式， $\tilde{\mathbf{L}} = 2\mathbf{L}/\lambda_{\max} - \mathbf{I}$  是归一化的拉普拉斯矩阵， $\theta_k$  为可学习的参数。该方法避免了直接计算特征分解，从而大幅降低了计算复杂度。

在此基础上，Kipf 和 Welling<sup>[57]</sup> 进一步简化了模型，他们仅采用一阶近似（即  $K = 1$ ），并引入了归一化策略。具体做法是首先在原始邻接矩阵中添加自环得到  $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$ ，对应的度矩阵为  $\tilde{\mathbf{D}}_{ii} = \sum_j \tilde{\mathbf{A}}_{ij}$ ，从而构造出对称归一化的传播矩阵  $\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2}$ 。最终，GCN 的层间传播规则写为：

$$\mathbf{H}^{(l+1)} = \sigma(\tilde{\mathbf{D}}^{-1/2} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-1/2} \mathbf{H}^{(l)} \mathbf{W}^{(l)}) \quad (2.9)$$

其中  $\mathbf{H}^{(l)}$  为第  $l$  层的节点特征矩阵， $\mathbf{W}^{(l)}$  为该层权重矩阵， $\sigma(\cdot)$  是非线性激活函数（例如 ReLU）。该公式表明，每个节点的新特征是其自身及其邻居节点特征经过线性变换和非线性映射后的加权平均。这种简单而高效的设计既保证了局部结构信息的捕捉，又降低了计算复杂度，因此在图表示学习中得到了广泛应用。

## 2.4 本章小结

本章对本文所涉及的相关理论知识进行了梳理，为后续的研究工作奠定了理论基础。首先介绍了规则学习的基本思想，明确了 Horn 规则在知识推理中的作用；随后阐述了 Transformer 模型的结构与原理，详细解析了自注意力机制、多头注意力机制、位置编码以及前馈神经网络

络的工作原理和计算步骤；接着对图神经网络进行了探讨，分别介绍了图卷积网络和图注意力网络的核心思想、计算公式和实现细节；此外介绍了强化学习与蒙特卡洛搜索树的相关理论；最后总结了大语言模型与 AI 智能体的相关概念。

## 第三章 基于结构感知图编码器与广义注意力机制的规则学习方法

### 3.1 引言

知识图谱 (Knowledge Graphs, KGs)，例如 FreeBase<sup>[2]</sup>，存储了关于现实世界和抽象概念的关系和信息的结构化知识表示。在知识图谱中，事实通常以三元组的形式表示，例如 (Trump, PresidentOf, USA)。知识图谱已在包括问答<sup>[64–66]</sup> 和推荐系统<sup>[67–69]</sup> 在内的各个领域得到了广泛应用。尽管知识图谱不断收集关于实体和关系的事实，但它们仍然存在许多不完整或缺失的事实。为了自动化知识图谱的补全过程，许多研究提出了基于知识图谱中现有事实推断缺失事实的方法，例如传统的知识图谱嵌入 (Knowledge Graph Embedding, KGE) 方法<sup>[45,47–49,70]</sup> 和规则学习方法<sup>[14–16,18,19,65]</sup>。与 KGE 方法相比，规则学习方法可以学习显式的规则（例如一阶逻辑）以直观地表示实体和关系之间的逻辑约束，并且可以轻松地迁移到不同领域的知识图谱中。自动学习的规则最终可以被应用于知识图谱下游任务中的知识推理，例如知识图谱补全和问答。

如果知识图谱中缺失了一个关系，选择一个准确的逻辑规则来找到语义等价的关系或关系路径至关重要。对于一个缺失关系  $r$  的查询三元组  $(h, r, ?)$ ，可以找到关系  $r$  的逻辑规则，例如  $r \leftarrow r_1 \wedge r_2$ ，以推导出目标实体  $t$ 。有时，关系  $r$  存在多个规则（并非所有规则都令人信服）可供选择。例如，关系头 hasNationality( $x, y$ ) 可以用以下两个规则体替换：bornIn( $x, z$ )  $\wedge$  placeIn( $z, y$ ) 和 liveIn( $x, z$ )  $\wedge$  placeIn( $z, y$ )。如果一个人在国外工作，使用 bornIn( $x, z$ )  $\wedge$  placeIn( $z, y$ ) 比 liveIn( $x, z$ )  $\wedge$  placeIn( $z, y$ ) 更为合适。以前的方法只能选择具有固定置信度的规则进行替换，但在这种情况下，它们并不一定正确。在这种情况下，围绕头实体  $h$  的结构信息对于确定正确的规则至关重要。然而，大多数现有的规则学习方法忽略了这种结构信息。Xu 等<sup>[14]</sup> 利用头实体周围的子图信息来选择合适的规则，但他们的方法被证明存在问题，因为它仅对每个实体周围的 1 跳局部邻域信息进行编码。在知识图谱中，实体之间的交互不仅包括它们自身及其局部邻域的信息，还包括实体之间的关系路径（见图3.1）所示。因此，以往的方法在捕捉具有长距离关系路径的实体之间的交互信息方面能力较弱，无法有效地编码图中的结构信息。

在本章中，受 Chen 等<sup>[71]</sup> 工作的启发，提出了一个结构感知规则学习方法 SARL，用于知识图谱上的规则学习。SARL 利用围绕头实体的局部和全局结构信息，有效建模子图的结构，从而生成适合推导目标实体的规则。具体而言，SARL 主要包括两部分：（1）一个结构感知图编码器，它利用编码机制捕捉子图的结构信息。它首先应用局部级编码，聚合头实体

$h$  周围的局部邻域结构信息，并利用广义注意力机制捕捉实体之间的交互。之后，它采用全局级编码，使每个实体能够学习整个子图的结构并捕捉实体之间的关系。（2）一个规则解码器，用于在每一步生成最合适的关系。本章还在知识图谱常用数据集上进行了实验，展示了 SARL 相较于现有规则学习方法的优越性能。

本章的贡献可以总结如下：1) SARL 的核心部分——结构感知图编码器，能够明确利用头实体周围的局部和全局信息来建模子图的结构。2) 本章提出了广义注意力机制，在计算注意力之前引入了一个可替换的特征提取器，使每个实体能够考虑以自身为中心的子图结构。3) 最后，本章在多个知识图谱常用数据集上进行了实验，证明了 SARL 相较于现有规则学习方法的优越性能，例如在 UMLS 和 FB15K-237 数据集中，在 Hits@1 指标上分别实现了 4.2% 和 4.5% 的显著提升。值得注意的是，本章提出的图编码器也可以轻松应用于知识图谱上的其他图推理任务。




图 3.1 局部感知 (Local-aware) 与结构感知 (Structure-aware) 对比图<sup>1</sup>


## 3.2 模型设计

在本节中，首先介绍问题的定义。接着，详细介绍了本章提出的模型（参见图 3.2）。最后，描述了规则学习算法、损失函数以及训练的具体细节。

### 3.2.1 问题描述

知识图谱表示为  $G$ ，由一组三元组  $\{(h, r, t) \mid r \in R, h \in \mathcal{E}, t \in \mathcal{E}\}$  组成，其中  $\mathcal{E}$  表示一个可数的实体集合， $R$  是关系的集合。实体  $e$  的嵌入表示为  $x_e$ 。给定一个查询  $(h, r, ?)$ ，本章的模型旨在通过生成对应的逻辑规则来替换关系  $r$ ，从而推断出缺失事实  $(h, r, t)$  中的尾实体  $t$ 。逻辑规则，特别是链式霍恩规则，表示为公式 2.1。本章用置信度分数  $s(r_h, r_b) \in [0, 1]$  来表示一条规则的经验合理性，其中  $r_h$  是规则的头部， $r_b$  是规则的主体。在后续内容中，向量表示将使用粗体标注。

<sup>1</sup> 图中  $u$  和  $v$  表示知识图谱 (KG) 中的实体，以往的方法仅考虑局部邻域信息，本章将其称为局部感知。相比之下，本章的方法还结合了实体之间的关系以及它们在图中的位置信息，将其称为结构感知。

图 3.2 SARL 模型结构图<sup>2</sup>

### 3.2.2 模型概览

如图 3.2 所示，给定一个查询三元组  $(v_1, r_6, ?)$ ，其中关系  $r_6$  在知识图谱（KG）中缺失，本章的目标是推导出可以通过关系  $r_6$  闭合的最合适的规则体  $r_1 \wedge r_2$ 。然而，对于同一个关系而言，可能存在多个潜在有效的规则体，本章提出的模型 SARL 可以通过考虑围绕头实体  $v_1$  的子图结构信息来生成最合适的规则体。SARL 采用编码器-解码器架构，主要包含结构感知图编码器和规则解码器两个模块。首先使用广度优先搜索（BFS）提取围绕头实体  $h$  的  $k$  跳子图  $S_k(h)$ ，然后将子图中实体的表示排列成一个序列。随后，利用局部编码来捕获实体周围的局部邻域信息。具体而言，通过结合可替换的特征提取器和广义注意力机制来实现这一点。接着，采用提出的全局编码器对子图进行编码，其中包含了结构编码和关系编码，得到子图的最终表示。然后编码器将子图表示传递给解码器，解码器将规则解释为自然语言中的序列，并在每一步预测最优的规则。例如，在当前时间步输入关系序列  $r_6 \rightarrow r_1$  时，解码器输出下一个具有最高概率的关系  $r_2$ 。最终，可以得到规则路径  $r_6 \rightarrow r_1 \rightarrow r_2$ ，从而间接学习到逻辑规则  $r_6 \leftarrow r_1 \wedge r_2$ 。

### 3.2.3 结构感知图编码器

该模块主要包含局部级编码和全局级编码两个模块。

#### （1）局部级编码

本章的局部级编码主要采用广义注意力机制。Transformer 中的自注意力仅能捕捉实体对之间的属性相似性。然而，在知识图谱中，实体之间的交互不仅包含实体自身的固有信息，还包含其周围的局部结构信息。如果实体信息相似但其局部邻域结构不同，传统的注意力机制无法准确区分这种上下文差异。为了解决这一问题，本章设计了一个广义注意力模块，用于

<sup>2</sup> 图中  $v$  表示知识图谱中的实体， $r$  表示关系， $-$  表示出度， $+$  表示入度。当知识图谱中缺少某个关系（例如  $r_6$ ）时，SARL 会生成一条替代关系路径（例如  $r_1 \rightarrow r_2$ ），以到达目标实体  $v_6$ 。

建模实体的邻域结构。通过引入每个实体周围的邻域信息，定义的广义注意力机制如下：

$$\text{Attn}(\mathbf{x}_u) = \sum_{v \in S_k(u)} \frac{\kappa_{\text{exp}}(\phi(\mathbf{x}_u), \phi(\mathbf{x}_v))}{\sum_{w \in S_k(u)} \kappa_{\text{exp}}(\phi(\mathbf{x}_u), \phi(\mathbf{x}_w))} \quad (3.1)$$

其中， $\mathbf{x}_u \in \mathbb{R}^{d \times 1}$  表示实体  $u$  的表示， $S_k(u)$  表示围绕实体  $u$  的  $k$  跳子图。 $\kappa_{\text{exp}}(\phi(\mathbf{x}_u), \phi(\mathbf{x}_v))$  是一个核函数，明确定义为：

$$\kappa_{\text{exp}}(\phi(\mathbf{x}_u), \phi(\mathbf{x}_v)) = \exp\left((\mathbf{W}^Q \phi(\mathbf{x}_u))^\top (\mathbf{W}^K \phi(\mathbf{x}_v)) / \sqrt{d_{\text{out}}}\right) \quad (3.2)$$

它通过特征提取器  $\phi$  将实体表示  $\mathbf{x}_u$  和  $\mathbf{x}_v$  映射到潜在空间，分别表示为  $\phi(\mathbf{x}_u)$  和  $\phi(\mathbf{x}_v)$ ，其中  $\phi(\mathbf{x}_u), \phi(\mathbf{x}_v) \in \mathbb{R}^{h \times 1}$ 。这个潜在空间捕捉了实体在其局部邻域内的周围信息，然后计算  $\phi(\mathbf{x}_u)$  和  $\phi(\mathbf{x}_v)$  之间的注意力。本章的广义注意力机制可以与不同的特征提取器结合，以捕捉实体局部邻域内的多维特征表示。本文提出了两种特征提取器，包括局部关系提取器和局部度提取器，以下是这两种提取器的介绍。

局部关系提取器整合了实体及其连接到和从其连接的关系的信息，可以表示为：

$$\phi(\mathbf{x}_u) = \mathbf{W}\mathbf{x}_u + \mathbf{W}' \sum_{r=1}^{|\mathcal{R}|} k_r \mathbf{x}_r \quad (3.3)$$

其中， $\mathbf{x}_r$  是关系  $r$  的嵌入， $\mathbf{W}, \mathbf{W}' \in \mathbb{R}^{h \times d}$  是可学习的参数。若  $r(u, v) \in \mathcal{G}$ ，则  $k_r = 1$ ，否则  $k_r = 0$ 。将关系信息整合到实体表示中，有助于解码器进行更准确的规则推理。

知识图谱中实体的度可以作为衡量该实体在图中重要性的指标。因此，本章将度信息纳入模型，使其能够在注意力机制中捕捉语义交互和实体的重要性。将度编码添加到实体表示中，局部度提取器可以表示为：

$$\phi(\mathbf{x}_u) = \mathbf{x}_u + \mathbf{z}_{\text{in}(u)}^- + \mathbf{z}_{\text{out}(u)}^+ \quad (3.4)$$

其中， $\mathbf{z}^-, \mathbf{z}^+ \in \mathbb{R}^{d \times 1}$  分别表示由入度  $\text{in}(u)$  和出度  $\text{out}(u)$  决定的可学习嵌入向量，它们的维度为  $d$ 。在无向图的情况下，入度  $\text{in}(u)$  和出度  $\text{out}(u)$  可以统一为度  $\text{deg}(u)$ 。

## (2) 全局级编码

本章提出的全局级编码主要包括结构编码和关系编码。

受 Transformer 全局注意力机制的启发，本章设计了结构编码。在知识图谱中，实体并不是以序列的形式排列的。它们存在于多维语义空间中，并通过关系相互连接。传统的序列位置编码只能让模型区分实体在序列中的不同位置，无法捕捉图的拓扑结构以及实体在图中的相对位置。



Transformer 中的注意力机制具有全局感受野，允许每个标记与其他任何位置的标记计算注意力，这启发本章将它用于编码知识图谱中的结构信息，即结构编码。具体来说，在计算实体  $u$  和实体  $v$  之间的注意力时，本章会考虑知识图谱中  $u$  和  $v$  之间的最短路径  $d(u, v)$ 。由本章使用广度优先搜索（BFS）算法进行子图提取，因此可以保证子图中的任意实体对都是相互可达的。用  $A(u, v)$  表示实体  $u$  和  $v$  之间的 Query-Key 乘积。结合改进的注意力机制，则有：

$$A(u, v) = \frac{(\mathbf{W}^Q \phi(\mathbf{x}_u))^\top (\mathbf{W}^K \phi(\mathbf{x}_v))}{\sqrt{d_{out}}} + b_{d(u, v)} \quad (3.5)$$

其中， $b_{d(u, v)} \in \mathbb{R}$  是根据  $d(u, v)$  指定的一个可学习的标量。通过本章的结构编码，每个实体能够感知完整的图结构，并且更加关注自身附近的实体。

单纯的结构距离并不能完整描述实体间的语义关联，因此本章在结构编码基础上进一步引入关系编码。在知识图谱中，除了实体本身的信息以及它们周围的结构信息外，实体之间的关系路径可以描述它们之间的交互，这些细节对于知识图谱的编码至关重要。此外，本章之前提出的特征提取模块仅考虑了实体的局部邻域关系信息，忽略了全局关系信息。因此，在计算两个实体之间的注意力时，还应纳入它们的关系路径信息。为了更好地在注意力计算中编码关系路径的特征，本章还引入了关系编码。对于实体对  $(u, v)$ ，首先找到它们之间的最短路径  $(r_1, r_2, \dots, r_n)$ ，然后在计算注意力分数时对这条最短路径上的关系进行编码。最终，注意力公式可以表示如下：

$$A(u, v) = \frac{(\mathbf{W}^Q \phi(\mathbf{x}_u))^\top (\mathbf{W}^K \phi(\mathbf{x}_v))}{\sqrt{d_{out}}} + b_{d(u, v)} + \frac{1}{n} \sum_{i=1}^n \mathbf{w}_{r_i}^\top \mathbf{x}_{r_i} \quad (3.6)$$

其中， $\mathbf{x}_{r_i}$  是路径中第  $i$  个关系的嵌入， $\mathbf{w}_{r_i} \in \mathbb{R}^{h \times 1}$  是可学习的参数。

### 3.2.4 规则解码器

利用编码器输出的子图表示  $\mathbf{S}_e \in \mathbb{R}^{|\mathcal{S}_e(h)| \times d}$ ，解码器在每一步中从  $\mathbf{R}$  中确定最优关系，同时确保输出关系序列  $\mathbf{R}$  的长度不会超过最大长度  $T$ 。

具体而言，解码器输入的初始关系对应于关系头  $r$  的嵌入，记作  $\mathbf{R}_0 = \mathbf{x}_r$ 。在与编码器输出进行交叉注意力操作后，解码器利用子图信息以及当前生成的关系序列来预测下一个关系。随后，通过多层感知机（Multi-Layer Perceptron, MLP）计算在时间步  $t$  时关系  $r_i$  的概率  $p_t^i$ 。在每次迭代中，选择概率最高的关系，并将其添加到关系序列  $\mathbf{R}$  中。设  $\mathbf{R}_t = [\mathbf{x}_r, \mathbf{x}_{r_1}, \dots, \mathbf{x}_{r_t}]^\top \in \mathbb{R}^{(t+1) \times d}$  表示在时间步  $t$  之前生成的规则序列的隐藏状态。对于每个解码器层，通过对规则序

列  $\mathbf{R}_t$  进行自注意力计算:

$$\mathbf{H}_{t+1} = \text{Attention}(\mathbf{R}_t \mathbf{W}^Q, \mathbf{R}_t \mathbf{W}^K, \mathbf{R}_t \mathbf{W}^V) \quad (3.7)$$

其中, **Attention** 指多头缩放点积注意力函数。这种注意力机制能够让规则序列中的每个关系都关注到其他所有关系。随后执行如下交叉注意力:

$$\mathbf{H}'_{t+1} = \text{Attention}(\mathbf{H}_{t+1} \mathbf{W}^Q, \mathbf{S}_e \mathbf{W}^K, \mathbf{S}_e \mathbf{W}^V) \quad (3.8)$$

上述步骤利用了子图信息以及在时间步  $t$  之前生成的关系序列, 来更新解码器的当前状态。最后通过一个多层感知机 (MLP), 以获得在时间步  $t+1$  时关系的概率  $\mathbf{p}_{t+1}$ :

$$\mathbf{p}_{t+1} = \text{softmax}(\text{MLP}(\mathbf{H}'_{t+1})) \quad (3.9)$$

其中,  $\mathbf{p}_{t+1} \in \text{耽}^{|R| \times 1}$  表示在时间步  $t+1$  时所有关系的概率。然后选择概率最高的关系, 记作  $r_{t+1}$ 。因此, 时间步  $t+1$  的输入可以表示为  $\mathbf{R}_{t+1} = [\mathbf{R}_t, \mathbf{x}_{r_{t+1}}]^T$ 。

### 3.2.5 训练和规则学习算法设计

当规则解码器在时间步  $t$  生成一个关系时, 由于缺乏标准标签, 很难评估当前生成关系的正确性。由于规则解码器生成的规则体可以通过规则头  $r$  进行闭合, 可以通过检查规则体是否能够推导出给定查询的准确答案来评估生成规则序列的正确性。实体对之间的关系可以用邻接矩阵表示。例如, 如果实体  $i$  和  $j$  通过关系  $r$  相连, 可以在邻接矩阵中表示为  $\mathbf{M}_{ij}^r = 1$ 。此外, 邻接矩阵的乘积可以用来表示实体是否可以通过一系列关系到达。例如, 如果实体  $i$  可以通过关系序列  $(r_1, r_2, r_3)$  到达实体  $j$ , 相应的邻接矩阵乘积可以表示为:

$$\mathbf{M} = \mathbf{M}^{r_1} \mathbf{M}^{r_2} \mathbf{M}^{r_3} \quad (3.10)$$

这满足  $\mathbf{M}_{ij} > 0$ 。利用这一性质, 可以使用生成的关系序列来回答查询三元组  $(h, r, ?)$ 。具体来说, 在时间步  $t=0$  时, 用一个独热向量  $\approx_0$  来表示头实体  $h$ 。随后, 由于解码器在每一步都会输出下一个关系的概率  $\mathbf{p}$ , 利用这个子图的邻接矩阵, 可以推断目标实体的表示如下:

$$\approx_t = \approx_{t-1} \sum_{i=1}^{|\mathcal{R}|} p_t^i \mathbf{M}^{r_i} \quad (3.11)$$

其中,  $p_t^i$  表示在时间步  $t$  时关系  $r_i$  的概率。

**算法 1** 规则学习算法

输入: 头实体  $h$ , 规则头  $r_h$

初始化:  $t = 0, R_c = [(r_h, w_h)], \text{beam} = k$

输出: 学习到的逻辑规则  $R$

```

1: while  $t \leq T$  do
2:    $R_{new} = []$ 
3:   for 每一个在  $R_c$  中的关系序列  $(R_{t-1}, w_{t-1})$  do
4:     在时间步  $t$  生成下一个关系  $r_t$ 
5:     更新规则分数  $w_t = w_{t-1} \times p_{r_t}$ 
6:     将  $(R_t, w_t)$  加入到  $R_{new}$  中
7:   end for
8:   按分数对  $R_{new}$  排序, 保留分数前  $k$  的序列
9:   for 每一个在 top- $k$  中的关系序列  $R_t$  do
10:    if  $R_t[1]$  与头实体  $h$  相连 then
11:      将当前规则序列加入  $R_c$ 
12:    end if
13:   end for
14:   时间步  $t$  增加
15: end while
16: 返回 得分最高的规则序列  $R_c$ 

```

## (1) 目标函数设计

经过  $T$  步后, 得到  $\approx_T$ , 它可以被视为目标实体的表示。向量  $\approx_T$  的每个维度表示对应实体作为答案实体的概率。因此, 损失函数可以被设计为量化  $\approx_T$  与答案实体的独热向量  $\mathbf{v}$  之间的差异。本章使用交叉熵损失来最小化  $\approx_T$  和  $\mathbf{v}$  之间的负对数似然, 其形式化表达为:

$$\mathcal{L} = - \sum_{(h,r,t) \in \mathcal{G}_t} \mathbf{v} \cdot \log z_T \quad (3.12)$$

其中  $\mathcal{G}$  代表训练集。

## (2) 规则学习算法

经过训练后, 规则解码器可以在每个时间步输出最合适规则, 从而间接地获得逻辑规则。具体来说, 本章使用束搜索 (beam search) 根据概率选择当前时间步生成的排名前  $k$  的关系。为了避免生成无效的规则序列, 本章通过检查规则是否与前一步到达的实体相连来验证每条规则。通过迭代执行这一过程, 最终生成  $k$  条规则序列。然后, 计算每条规则序列的得分, 并将得分最高的序列识别为学习到的逻辑规则。详细过程在算法 1 中进行了描述。

### 3.3 表达能力分析

结构感知图编码器在知识图谱推理中的表达能力源于其能够同时捕捉局部和全局的结构信息。本节证明了 SARL 至少与局部编码中特征提取器提供的局部子图表示一样具有表达能

力，同时展示了全局编码的引入如何进一步增强这种表达能力。

**定理 1.** 设实体属性空间  $\mathcal{X}$  是可数的。对于两个知识图谱  $G = (E, R, \mathbf{X})$  和  $G' = (E', R', \mathbf{X}')$  中的任意一对实体  $v$  和  $v'$ ，假设存在：

- 一个实体  $u_1 \in E$ ，使得对于任意  $w \in E$ ，有  $x_{u_1} \neq x_w$ ；
- 一个实体  $u_2 \in E$ ，使得对于任意  $w \in E$ ，使得其子图表示  $\phi(u_2, G) \neq \phi(w, G)$ 。

那么，存在一组参数  $\theta$  和一个映射  $f: \mathcal{X} \rightarrow \mathbb{R}^{d_{out}}$ ，使得如果它们的局部子图表示不同，即  $\phi(v, G) \neq \phi(v', G)$ ，则经过结构感知图编码器编码后的表示也不同，即  $\text{SA-encoder}_\theta(v) \neq \text{SA-encoder}_\theta(v')$ 。其中， $\phi(\cdot, \cdot)$  表示由特征提取器输出的局部子图表示。

**证明.** 在这里，本章假设  $f$  可以是任意的连续映射，并且在实践中，它通过万能近似定理（Universal Approximation Theorem）被一个多层感知机（MLP）网络近似实现<sup>[72]</sup>。

本章将通过证明其逆否命题来证明该定理。假设对于图  $G$  和  $G'$  中的两个实体  $v$  和  $v'$ ，对于所有参数集合  $\theta$  和映射  $f$ ，都有  $\text{SA-encoder}_\theta(v) = \text{SA-encoder}_\theta(v')$ 。本章的目标是证明  $\phi(v, G) = \phi(v', G)$ 。

首先，用注意力机制来表示结构感知编码器：

$$\text{SA-encoder}_\theta(v) = \sum_{u \in E} \alpha_{vu} f(x_u), \quad (3.13)$$

其中， $\alpha_{vu}$  定义为：

$$\alpha_{vu} = \frac{\kappa_{\exp}(h_v, h_u)}{\sum_{w \in E} \kappa_{\exp}(h_v, h_w)}, \quad (3.14)$$

其中  $\kappa_{\exp}(h, h') = \langle \mathbf{W}_Q h + b_Q, \mathbf{W}_K h' + b_K \rangle / \sqrt{d_{out}}$ 。

不失一般性，通过添加孤立实体来假设  $|E| = |E'| = n$ 。通过设置  $\mathbf{W}_Q = \mathbf{W}_K = 0$ ，可以得到：

$$\sum_{u \in E} f(x_u) = \sum_{u' \in E'} f(x_{u'}'). \quad (3.15)$$

应用文献<sup>[73]</sup> 中的引理 5，可以在  $E$  和  $E'$  的实体之间建立双射关系，使得对于所有  $u$ ，都有  $x_u = x_{u'}'$ 。这允许将初始假设重写为：

$$\sum_{u \in E} (\alpha_{vu} - \alpha'_{v'u}) f(x_u) = 0. \quad (3.16)$$

鉴于存在一个具有唯一属性的实体  $u_1$ ，因此可以选择  $f$ ，使得  $f(x_{u_1})$  与  $\{f(x_u) | u \neq u_1\}$  线性无关。这意味着：

$$\alpha_{vu_1} = \alpha'_{v'u_1}, \quad (3.17)$$

对于所有选择的  $\mathbf{W}_Q, \mathbf{W}_K, b_Q$  和  $b_K$ 。

现在，考虑两种情况：

1) 当  $\mathbf{W}_Q = 0$  时，对于任意的  $\mathbf{W}_K, b_Q$  和  $b_K$ ：

$$\frac{\exp(\langle b_Q, \mathbf{W}_K h_{u_1} + b_K \rangle / \sqrt{d_{out}})}{\sum_{w \in E} \exp(\langle b_Q, \mathbf{W}_K h_w + b_K \rangle / \sqrt{d_{out}})} = \frac{\exp(\langle b_Q, \mathbf{W}_K h'_{u_1} + b_K \rangle / \sqrt{d_{out}})}{\sum_{w \in E} \exp(\langle b_Q, \mathbf{W}_K h'_w + b_K \rangle / \sqrt{d_{out}})}; \quad (3.18)$$

2) 当  $b_Q = 0$  时，对于任意的  $\mathbf{W}_Q, \mathbf{W}_K$  和  $b_K$ ：

$$\begin{aligned} \frac{\exp(\langle \mathbf{W}_Q h_v, \mathbf{W}_K h_{u_1} + b_K \rangle / \sqrt{d_{out}})}{\sum_{w \in E} \exp(\langle \mathbf{W}_Q h_v, \mathbf{W}_K h_w + b_K \rangle / \sqrt{d_{out}})} &= \frac{\exp(\langle \mathbf{W}_Q h'_{v'}, \mathbf{W}_K h'_{u_1} + b_K \rangle / \sqrt{d_{out}})}{\sum_{w \in E} \exp(\langle \mathbf{W}_Q h'_{v'}, \mathbf{W}_K h'_w + b_K \rangle / \sqrt{d_{out}})} \\ &= \frac{\exp(\langle \mathbf{W}_Q h'_{v'}, \mathbf{W}_K h_{u_1} + b_K \rangle / \sqrt{d_{out}})}{\sum_{w \in E} \exp(\langle \mathbf{W}_Q h'_{v'}, \mathbf{W}_K h_w + b_K \rangle / \sqrt{d_{out}})}, \end{aligned} \quad (3.19)$$

其中，第二个等式是通过在上述等式中将  $b_Q$  替换为  $\mathbf{W}_Q h'_{v'}$  得到的。然后，可以将上述等式重写如下：

$$\sum_{w \in E} \exp\left(\frac{\langle \mathbf{W}_Q h_v, \mathbf{W}_K (h_w - h_{u_1}) \rangle}{\sqrt{d_{out}}}\right) = \sum_{w \in E} \exp\left(\frac{\langle \mathbf{W}_Q h'_{v'}, \mathbf{W}_K (h_w - h_{u_1}) \rangle}{\sqrt{d_{out}}}\right). \quad (3.20)$$

设  $\phi: \mathcal{H}^{d_{out}} \rightarrow H$  是与核函数  $\kappa_{\exp}(t, t') = \exp(\langle t, t' \rangle / \sqrt{d_{out}})$  相关联的特征映射，其中  $H$  是对应的再生核希尔伯特空间。随后可以推导出：

$$\left\langle \phi(\mathbf{W}_Q h_v) - \phi(\mathbf{W}_Q h'_{v'}), \sum_{w \in E} \phi(\mathbf{W}_K (h_w - h_{u_1})) \right\rangle_H = 0. \quad (3.21)$$

鉴于  $\kappa_{\exp}$  是一个通用核<sup>[74]</sup>，并且存在  $u_2 \in E$  使得  $h_{u_2} - h_{u_1} \neq 0$ ，可以得出  $\mathbf{W}_K \rightarrow \{\phi(\mathbf{W}_K (h_{u_2} - h_{u_1}))\}$  在  $H$  中是稠密的。这意味着：

$$\phi(\mathbf{W}_Q h_v) = \phi(\mathbf{W}_Q h'_{v'}). \quad (3.22)$$

$\phi$  的单射性随后导致：

$$\mathbf{W}_Q h_v = \mathbf{W}_Q h'_{v'}, \quad (3.23)$$

对于任意的  $\mathbf{W}_Q$ ，这意味着  $h_v = h'_v$ 。最后，通过设置  $h_v = \phi(v, G)$  和  $h'_v = \phi(v', G')$ ，得出  $\phi(v, G) = \phi(v', G')$ ，从而完成了逆否命题的证明，进而证明了原定理。  $\square$

在图神经网络（Graph Neural Networks, GNNs）的表达能力分析中，通常会假设实体属性空间  $\mathbf{X}$  是可数的，例如在 Xu 等人<sup>[73]</sup> 的研究中。本章假设  $f$  是任意的映射，而不仅仅局限于自注意力函数定义中的线性函数，因为在实践中， $f$  可以通过多层 Transformer 中的前馈网络来有效近似<sup>[72]</sup>。

该定理表明，如果局部结构提取器具有足够的表达能力，那么 SARL 模型也可以具有至少同等的表达能力。此外，SARL 中加入的全局编码能够捕捉实体对之间的最短路径信息，从而使得最终的子图表示更具表达能力。这种局部和全局结构信息的结合能够在知识图谱推理任务中具有更好的预测性能，这一点也可以通过本章在第 3.5 节的实验来证明。这表明 SARL 可以有效地捕捉并推理知识图谱中存在的复杂关系。

### 3.4 复杂度分析

为了从理论上证明本章提出的 SARL 在效率方面的优越性，本章在表 3.1 中比较了 SARL 和 Ruleformer 方法的空间复杂度和时间复杂度。本章用  $|E|/|R|/T/d$  分别表示实体数量、关系数量、规则体的长度以及嵌入空间的维度。可以观察到：（1）在时间复杂度方面，本章提出的 SARL 比 Ruleformer 更高效，因为  $|E| + |R| \ll |E|^2$ ；（2）在空间复杂度方面，由于 SARL 需要存储每对实体之间的最短路径，因此与 Ruleformer 相比，它需要额外的  $|E|^2 T$  空间。

表 3.1 模型推理的空间复杂度和时间复杂度比较

| 方法         | 时间复杂度                                       | 空间复杂度                       |
|------------|---------------------------------------------|-----------------------------|
| Ruleformer | $O( E ^2 + 2 R d + T((2 R  + 3) E ^2 d^2))$ | $O(( E  +  R )d)$           |
| SARL(Ours) | $O( E  +  R (2d + T E ^2 d^2))$             | $O(( E  +  R )d +  E ^2 T)$ |

### 3.5 实验结果与分析

本节通过在多个广泛使用的知识图谱数据集上执行链接预测任务来评估提出的 SARL 方法的性能，并将其结果与基线模型进行比较。此外，还进行了消融实验以评估基于不同特征提取器的 SARL 的性能表现、规则质量等。

### 3.6 本章小结

本章提出了 SARL，一种基于结构感知图编码器和广义注意力机制的知识图谱规则学习方法。该方法中的图编码器利用头实体周围的局部和全局结构信息，以丰富的表达能力建模子图的结构。随后，规则解码器利用这些结构信息生成合适的规则。本章在四个基准数据集上进行的实验表明，该方法在链接预测任务中具有有效性，同时也展示了模型的迁移能力。

在未来的工作中，计划研究进一步提高 SARL 可扩展性的技术，以使其能够应用于更大规模的知识图谱。此外，还打算将模型扩展到能够有效学习时序知识图谱中的规则，这些图谱中的关系会随时间演变。这将使 SARL 能够捕捉和推理知识图谱中的时间模式。这些未来的研究方向将增强 SARL 在更复杂和现实场景中的适用性，进一步推动知识图谱中规则学习与推理领域的发展。

## 第四章 基于反馈驱动蒙特卡洛树搜索和大语言模型智能体的规则学习方法

### 4.1 引言

在知识图谱中，规则学习的目标不仅是挖掘出统计上成立的规则（如 Horn 规则），还要确保这些规则能够有效应用于下游任务，如知识图谱补全和问答。然而，现有的规则学习方法虽然在置信度等指标上表现良好，但生成的规则在语义上仍存在一定缺陷。例如，这是一条现有 SOTA 方法学习到的规则： $\text{location\_of}(x, y) \leftarrow \text{degree\_of}(x, z) \wedge \text{contains}(z, y)$ ，该规则表示关系  $\text{location\_of}(x, y)$  可以用  $\text{degree\_of}(x, z) \wedge \text{contains}(z, y)$  这样的关系路径替代。尽管模型为该规则分配了较高的置信度，但从语义上来看，该规则显然是不合理的。原因在于，疾病严重程度与症状的位置并不相关，即如果  $x$  是一种症状，是疾病  $z$  的某种程度，且疾病  $z$  包含疾病  $y$ ，但是这并不能说明症状  $x$  与疾病  $y$  的位置相关。这一问题的根源在于当前方法大多依赖概率分布来选择规则，高概率并不必然意味着语义上的合理性。虽然现有模型在一定程度上考虑了知识图谱的结构信息或规则的组合特性，但是缺乏对于规则的深层次语义验证，导致生成的规则缺乏语义合理性。因此，规则学习需要充分考虑规则在现实世界中的语义可解释性。

为了解决上述问题，本章提出利用大语言模型智能体来增强规则的语义理解。然而，在选择每一跳规则时，仅依赖大语言模型智能体进行决策仍然存在挑战。由于规则空间复杂且规模庞大，智能体在决策时难以确保当前选择是最优的，因此如何高效探索最优路径成为关键。本章在引入大语言模型智能体进行规则学习的基础上，进一步改进其决策机制，采用基于反馈驱动蒙特卡洛搜索和大语言模型智能体（Feedback-Driven Monte Carlo Tree Search Agent, FD-MCTS）的规则学习模型，以提升规则学习的合理性和有效性。具体而言，FD-MCTS 结合了大语言模型的语义理解能力、蒙特卡洛树搜索（MCTS）的高效决策搜索机制以及反馈学习（Feedback Learning）的自我优化能力，以实现更合理的规则学习：大语言模型智能体通过其强大的语义理解能力，评估规则路径的语义合理性，确保生成的规则在现实世界中具有可解释性；蒙特卡洛树搜索（MCTS）在复杂的策略空间中系统探索最优规则路径，通过模拟和回溯机制优化多步决策过程；反馈学习使得智能体能够从过去错误决策中获取反馈，避免重复选择不合理的规则路径，从而减少 MCTS 过程中的计算开销，并提高决策准确性，同时减少蒙特卡洛树搜索过程带来的性能损耗；除此以外，该方法作为一个测试时模型，具有无训练迁移性，能够直接应用于其它领域，如知识图谱问答等，极大地提升了实用性和效率。

在具体的规则学习过程中，生成每一跳关系时，并非直接依据模型生成的概率分布选择



规则，而是将其视为先验概率，并将当前规则状态建模为蒙特卡洛树的根节点。例如，当前状态为规则头  $r$ ，此时 FD-MCTS 通过蒙特卡洛树搜索进行模拟，并由大语言模型作为价值函数（value function）评估每个状态的价值，最终回传至根节点，以确定在当前状态下最优的规则选择。此外，在完成一条关系路径的探索后，本章引入反馈学习机制，使智能体基于决策反馈进行自我优化，并结合当前任务状态的向量化表示形成反馈记忆（feedback memory）。当智能体在未来遇到相似状态时，可通过检索先前的决策反馈，实现更优决策。MCTS 通过模拟和探索优化当前规则路径的生成策略，而反馈学习使智能体能够利用历史反馈不断改进自身决策，从而在相同决策场景下减少错误并加快决策速度。实验结果表明，FD-MCTS 在大规模知识图谱的链接预测任务上取得了最先进的（SOTA）结果，在 UMLS 和 FB15K-237 上 Hits@1 指标较先前的 SOTA 模型分别提升了 5.8% 和 9.5%。此外，本章也对学习到的规则进行质量分析，实验结果表明在使用 FD-MCTS 之后，学习到的规则质量是明显升高的，证明了引入蒙特卡洛树搜索与反馈学习模块的有效性。




图 4.1 基于反馈驱动蒙特卡洛树搜索的智能体模型结构图

## 4.2 模型设计

在具有较大动作空间的长时域任务中，蒙特卡洛树搜索（MCTS）是一种流行的方法，用于改进决策<sup>[81,82]</sup>。MCTS 会探索多种动作，评估它们的后果，并在进行大量模拟后返回最佳动作以执行。

为了学习到更符合语义的规则，并使智能体在较大的规则空间中能够正确选择规则路径，本章采用基于反馈驱动蒙特卡洛树搜索的智能体（Feedback-Driven Monte Carlo Tree Search Agent, FD-MCTS）模型。该模型在传统 MCTS 的基础上进行了以下改进：1）引入章节 3.2.4 中提出的规则解码器作为策略函数，将规则解码器输出的规则概率作为搜索树中每个规则状态

的先验概率；2）引入大语言模型作为规则状态的价值函数，结合规则的语义更精确的评估当前规则状态的价值，从而引导智能体更准确的选择规则路径。3）通过反馈学习机制识别过去的错误，并动态更新智能体的价值函数，从而提升智能体在未来任务中决策以及价值估计中的准确率，具体模型结构如图4.1所示。

## 4.2.1 FD-MCTS 相关函数设计

### （1）节点选择函数设计

在 MCTS 中，选择节点的策略主要用于在搜索树中平衡探索（exploration）和利用（exploitation）。其选择策略通常基于 Upper Confidence Bound applied to Trees（UCT）算法，通过结合节点的平均奖励和访问次数来决定下一个要探索的节点。为了解决基于 UCT 的策略在某些情况下可能过于依赖节点的访问次数，导致在大规模搜索树中效率较低这一问题，FD-MCTS 采用 PUCT 作为选择节点的策略。具体来说，PUCT 在 UCT 的基础上引入了先验概率  $P(a|s)$ ，以更好地利用模型的先验知识，从而提高搜索效率。具体来说，本章的 PUCT 设计如下：

$$U(s, a) = c_p \cdot P(a|s) \cdot \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)} \quad (4.1)$$

其中， $c_p$  是控制探索率的超参数。 $P(a|s)$  是模型在状态  $s$  下生成动作  $a$  的先验概率。 $N(s, b)$  是状态  $s$  下动作  $b$  的访问次数。 $N(s, a)$  是状态  $s$  下动作  $a$  的访问次数。

### （2）策略函数设计

用  $\mathbf{R}_t = [\mathbf{x}_r, \mathbf{x}_{r_1}, \dots, \mathbf{x}_{r_n}]^T \in \mathbb{R}^{(t+1) \times d}$  表示在时间步  $t$  之前生成规则状态的向量，接着将其输入到规则解码器中。对于每一个解码器层，首先对规则序列  $\mathbf{R}_t$  进行多头自注意力计算：

$$\mathbf{H}_{t+1} = \text{Attention}(\mathbf{R}_t \mathbf{W}^Q, \mathbf{R}_t \mathbf{W}^K, \mathbf{R}_t \mathbf{W}^V) \quad (4.2)$$

其中， $\text{Attention}$  是一个多头缩放点积注意力函数。这种注意力机制允许规则序列中的每个关系都关注其他所有关系。然后，执行交叉注意力操作如下：

$$\mathbf{H}'_{t+1} = \text{Attention}(\mathbf{H}_{t+1} \mathbf{W}^Q, \mathbf{S}_e \mathbf{W}^K, \mathbf{S}_e \mathbf{W}^V) \quad (4.3)$$

利用编码器输出的子图信息  $\mathbf{S}_e \in \mathbb{R}^{|S_k(h)| \times d}$  以及在时间步  $t$  之前生成的关系序列来更新解码器的当前状态。最后，通过使用一个简单的多层感知机（MLP）来获得在时间步  $t+1$  的关系概率  $\mathbf{p}_{t+1}$ ：

$$\mathbf{p}_{t+1} = \text{softmax}(\text{MLP}(\mathbf{H}'_{t+1})) \quad (4.4)$$

其中,  $\mathbf{p}_{t+1} \in \text{耽}^{|R| \times 1}$  表示在时间步  $t$  的所有关系的概率。  $\mathbf{p}_{t+1} \in \text{耽}^{|R| \times 1}$ ,  $p_{t+1}^i$  则表示  $t$  时刻第  $i$  条规则的概率。此时, 可以将以上过程简化视为:

$$\mathbf{p}_{t+1} = \text{RuleDecoder}(\mathbf{R}_t, \mathbf{S}_e) \quad (4.5)$$

本章将其作为 FD-MCTS 的策略函数, 输出每一个规则的概率值则作为搜索树中每个子节点的先验概率。

### (3) 价值函数设计

给定一个行动轨迹  $\tau$ , 价值函数估计在当前状态  $s_t$  下的成功率。对于本文而言, 即给定一个规则序列, 价值函数需要估计当前规则状态是否合理或者由当前规则状态是否能最终学习到一个合理的规则。在本文中, 价值函数使用当前观测到的规则轨迹  $\tau$  和规则学习任务描述  $g$  来实现。具体来说, 将所有输入, 包括任务描述  $g$  与轨迹  $\tau$  输入给大语言模型, 让其根据规则学习任务的目标以及规则轨迹评估当前规则状态的价值:

$$\text{output} = \text{LLM}(g, \tau) \quad (4.6)$$

本文将价值的评估标准分为 A-E 5 个档次, 例如 A 表示智能体的当前动作满足了当前任务中的所有要求, E 表示智能体的当前动作没有朝着任务完成的方向取得进展。利用大语言模型输出的  $\text{output}$ , 映射到对应的具体价值数值上, 即:

$$V(g, \tau) = \text{mapping}(\text{output}) \in [0, 1] \quad (4.7)$$

### (4) 状态价值更新策略设计

在本文的 FD-MCTS 中, 反向传播阶段使用滑动平均法来更新搜索树中节点的状态价值估计  $Q$  和访问次数  $N$ :

$$Q(s, a) = Q(s, a) + \frac{v - Q(s, a)}{N(s, a)}, N(s, a) = N(s, a) + 1 \quad (4.8)$$

滑动平均法通过计算新值和旧值的加权平均, 可以平滑地更新节点的价值估计。

## 4.2.2 FD-MCTS 搜索算法

FD-MCTS 的搜索算法与传统的 MCTS 类似, 也包含四个步骤, 分别为选择, 扩展, 模拟与反向更新, 如图4.1所示。

在选择阶段, 例如此时规则头为  $r_6$ , 从根节点  $r_6$  出发, 根据章节4.2.1中所述节点选择公

式计算节点的 PUCT 值，选择 PUCT 值最大的节点，例如  $r_2$ 。

在扩展阶段，枚举出当前节点所有可能的规则动作并添加到树中，具体来说，当前状态为  $S = \{r_6, r_1, r_2\}$ ，向量表示为  $R = [x_{r_6}, x_{r_1}, x_{r_2}]^T$ 。通过章节4.2.1中提到的策略函数，获得下一个规则状态的概率分布  $p$ ，如图4.1中扩展 (Expansion) 阶段的搜索树所示。

在模拟阶段，选择  $p$  中先验概率最大的节点进行模拟，例如  $r_3$ ，此时状态为  $S = \{r_6, r_1, r_2, r_3\}$ 。不同与传统的 MCTS，FD-MCTS 通过结合大语言模型作为价值函数，预测当前规则状态的价值。此外在预测价值时，FD-MCTS 会首先将当前任务描述及规则状态向量化：

$$\text{state\_embedding} = \text{Embedding}(S, g) \quad (4.9)$$

接着从过往的价值预估反馈经验库  $db_v$  中，通过向量余弦相似度检索相似的价值预估反馈经验，例如 horn 规则：(GrandMother  $\leftarrow$  Mother  $\wedge$  ?)，那么此时通过以往的反馈，就可以预估出只需要再补充一跳规则 Mother 就可以将其变为一条合理的 horn 规则：

$$\text{feedback\_v} = \text{retrieve}(db_v, \text{state\_embedding}) \quad (4.10)$$

此时再将价值预估反馈  $\text{feedback\_v}$ ，当前规则状态  $S$ ，以及任务描述  $g$ ，通过提示词结合起来输入给大语言模型得到价值预估：

$$V = \text{mapping}(\text{LLM}(g, \{r_6, r_1, r_2, r_3\}, \text{feedback\_v})) \quad (4.11)$$

在反向更新阶段，从叶子节点  $r_3$  开始，利用4.2.1所述更新策略，不断寻找自己的父节点并更新父节点的价值与访问次数，直到根节点结束。

最终在模拟一定次数之后，返回根节点  $r_6$  的访问计数分布作为最优规则的选择策略。在本文中选择访问计数最大的节点状态作为下一跳规则状态，例如在图4.1的例子中，即为关系  $r_1$ ，此时规则状态变为  $S = \{r_6, r_1\}$ 。本文在算法2中具体给出了 FD-MCTS 的算法伪代码。

### 4.2.3 FD-MCTS 反馈学习算法

FD-MCTS 使用反馈学习机制来迭代改进搜索过程，主要通过：1) 通过分析动作间的累积效应和整体上下文，利用对比反馈识别错误的决策，并将其记录到经验库中；2) 在上下文中更新智能体的策略和价值函数。这些改进步骤帮助 FD-MCTS 避免重复相同的错误，并在未来面临类似情况时探索更有希望的动作。具体来说，反馈学习机制包括三个步骤：1) 细粒度错误诊断；2) 对比反馈；3) 反馈记忆。

**算法 2** 反馈驱动型蒙特卡洛搜索智能体搜索算法

**输入:** 规则解码器策略函数  $\pi(g, \tau)$ , 大语言模型价值函数  $V(g, \tau)$ , 环境  $T$ , 规则学习任务  $g$ , 模拟步数  $n$

**输出:** 规则 result

```

1:  $\tau = \{s_0\}$ 
2:  $tree = \{s_0\}$ 
3: while 任务未结束 do
4:   while 模拟步数未达到限制 do
5:     // 节点选择
6:      $s_t = \text{select\_node}(tree)$ 
7:     // 节点扩展
8:      $\text{feedback}_\pi = \text{retrieve\_feedback}(\text{db}_\pi, g, s_t)$ 
9:      $r_t^1, \dots, r_t^k = \pi(g, \tau, \text{feedback}_\pi)$ 
10:    // 状态价值评估
11:     $s_{t+1} = T(s_t, r_t)$ 
12:     $\text{feedback}_V = \text{retrieve\_feedback}(\text{db}_V, g, s_{t+1}, \text{feedback}_V)$ 
13:     $v = V(g, \{s_0, r_0, \dots, s_{t+1}\}, \text{feedback}_V)$ 
14:    // 反向传播
15:     $tree = \text{update}(tree, s_{t+1}, v)$ 
16:  end while
17:   $a_t = \text{best\_action}(tree)$ 
18:   $s_{t+1} = T(s_t, r_t)$ 
19:   $\tau = \tau \cup \{r_t, s_{t+1}\}$ 
20:   $tree = \{s_{t+1}\}$ 
21: end while
22: result = rule valid/invalid
23: // 反馈改进
24:  $\text{feedback}_\pi, \text{feedback}_V = \text{feedback}(\text{LLM}, g, \tau)$ 
25:  $\text{db}_\pi = \text{update}(\text{feedback}_\pi)$ 
26:  $\text{db}_V = \text{update}(\text{feedback}_V)$ 

```

## (1) 细粒度错误诊断

在 FD-MCTS 反馈学习机制中, 第一步为细粒度错误诊断, 即识别在搜索过程中出现的决策错误和不合理的状态价值估计。当 FD-MCTS 在模拟过程中达到最终规则状态 (即规则状态  $S$  的长度达到  $\text{max\_length}$ ) 时, 智能体首先验证生成规则的语义合理性, 并判断该规则是否能在知识图谱中作为替代路径到达尾实体, 从而确认当前状态是否为成功状态。设规则轨迹  $\tau = \{s_0, r_0, s_1, r_1, \dots, r_{n-1}, s_n\}$ , FD-MCTS 基于智能体预测的节点规则状态价值  $V$  与 FD-MCTS 模拟中实际获得的状态价值  $Q$  之间的差异, 识别出  $n_\pi$  个错误程度最大的规则选择动作:

$$\delta_\pi(r_t/\tau) = |V(s_{t+1}) - Q(s_t, r_t)| \quad (4.12)$$

以及  $n_V$  个不合理的规则状态价值估计:

$$\delta_V(S_t/\tau) = [V(S_t) - Q(S_{t-1}, r_{t-1})] \quad (4.13)$$

### (2) 对比反馈

对于识别出的  $n_\pi$  个错误程度较大的规则选择动作  $\{\tilde{r}_1, \dots, \tilde{r}_{n_\pi}\}$ , 以及  $n_V$  个不合理的规则状态价值估计  $\{\tilde{V}_1, \dots, \tilde{V}_{n_V}\}$ , 利用提示词使大语言模型识别推理中的错误。以规则状态价值估计为例, 首先通过提示词让大语言模型预测在执行规则选择动作  $\tilde{r}_t$  后达到的状态  $\mathcal{S}_t$  的价值:

$$V(\mathcal{S}_t) = \text{LLM}_{\text{predict}}(g, \{S_0, r_0, \dots, S_t, \tilde{r}_t\}) \quad (4.14)$$

随后让大语言模型对比预期状态价值  $V(\mathcal{S}_t)$  与实际状态价值  $V(S_t)$ , 生成对当前规则状态价值估计的反馈:

$$\text{feedback}(\tilde{r}_t/g, \tau) = \text{LLM}_{\text{feedback}}(g, S_t, \tilde{r}_t, \{V(S_t), V(\mathcal{S}_t)\}) \quad (4.15)$$

### (3) 反馈记忆与提升

为了使智能体在测试时能利用这些反馈经验, 本文将当前任务  $g$  与规则状态  $S_t$  结合反馈信息进行嵌入, 并将其存储在向量数据库中。随后, 在针对任务  $g$  对新规则状态  $S_{\text{new}}^t$  进行推理时, 通过将状态  $(g, S_{\text{new}}^t)$  编码为向量, 从向量知识库中检索出  $m$  个最相关的反馈。利用这些检索到的反馈经验改进策略函数和价值函数, 在智能体进行节点状态价值估计时, 将反馈信息添加到当前上下文中, 从而提升决策效果。算法3和算法4分别给出了基于检索反馈经验来改进策略函数和价值函数的伪代码。

---

#### 算法 3 策略函数反馈

---

输入: 大语言模型 LLM, 规则学习任务  $g$  和规则轨迹  $\tau$ , 搜索树的数据  $Q, V$ , 向量数据库 db

```

1: // 错误诊断
2:  $\tilde{r}_t \leftarrow \arg \max_r \delta(r/g, \tau)$ 
3: // 对比反馈
4:  $\mathcal{S}_{t+1} \leftarrow \text{LLM}(g, \{S_0, r_0, \dots, S_t, \tilde{r}_t\})$ 
5:  $\text{feedback} \leftarrow \text{LLM}(g, S_t, \tilde{r}_t, \{S_{t+1}, \mathcal{S}_{t+1}\})$ 
6: // 反馈记忆
7:  $\text{key} \leftarrow \text{embedding}(g, S_t)$ 
8:  $\text{db} \leftarrow \text{add}(\text{key}, \text{feedback})$ 
9: return
```

---

**算法 4 价值函数反馈**

输入: 大语言模型 LLM, 规则学习任务  $g$  和规则轨迹  $\tau$ , 搜索树的数据  $Q, V$ , 向量数据库  $db$

```

1: // 错误诊断
2:  $S_t \leftarrow \arg \max_S \delta(S/g, \tau)$ 
3: // 对比反馈
4:  $\hat{r}_t \leftarrow \text{LLM}(g, \{S_0, r_0, \dots, S_t\})$ 
5:  $\text{feedback} \leftarrow \text{LLM}(g, r_{t-1}, S_t, \{r_t, \hat{r}_t\})$ 
6: // 反馈记忆
7:  $\text{key} \leftarrow \text{embedding}(g, S_t)$ 
8:  $db \leftarrow \text{add}(\text{key}, \text{feedback})$ 
9: return

```

**4.2.4 FD-MCTS 大语言模型智能体相关提示词设计****(1) 对比反馈阶段**

本节介绍通过对比反馈使得智能体生成反馈的提示词设计, 主要包括: 1) 在当前规则状态下执行规则选择动作后, 智能体的期望执行结果与真实执行结果的对比反馈提示词, 如表4.1所示; 2) 智能体预测搜索树中规则状态节点价值的提示词, 如表4.2所示, 其中在预测状态节点价值时需要评估智能体当前状态的进度, 该提示词如表4.3所示。

**表 4.1** 执行规则选择动作后的状态对比反馈提示词

| 角色        | 提示词                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| System    | You are an intelligent agent specialized in rule learning tasks. Your goal is to assist a human user in deriving the most appropriate rules from given relationships.<br><b>Background Knowledge:</b> (... some content omitted)                                                                                                                                                                                                                                                                |
| User      | <b>Task Objective:</b> (... some content omitted)<br><b>OBSERVATION:</b> 'Aunt(x, y) <- Mother(x, z)'                                                                                                                                                                                                                                                                                                                                                                                           |
| Assistant | Based on the objective, I need to find the most logical rule to connect "Mother" to "Aunt". It should be between familial relationships. In summary, the next rule I will consider is 'Aunt(x, y) <- Mother(x, z) $\wedge$ Father(z, y)'.<br><b>EXPECTATION:</b> After considering this rule, I expect this rule to be a valid Horn rule because it conforms to the logical connections and semantic information within the knowledge graph.                                                    |
| User      | <b>NEXT OBSERVATION:</b> Invalid rule: 'Aunt(x, y) <- Mother(x, z) $\wedge$ Father(z, y)'<br>Is this rule what you expected? If not, can you conclude anything special about deriving rules in this system? If you were to encounter this scenario once more, what general approach would you take to handle it differently? Focus on the overarching strategy rather than specific tactics. Keep your response concise, under 100 words, and avoid suggesting particular actions or solutions. |
| Assistant | This rule does not align with my initial expectations as it fails to accurately represent the familial relationship between Mother and Aunt. Upon reflection, I realize that my approach was flawed because I did not correctly interpret the logical sequence of relationships within the knowledge graph.                                                                                                                                                                                     |

**(2) 反馈记忆与提升阶段**

在反馈记忆阶段, 在给定状态  $(g, S_{new}^r)$  进行推理时, 从向量知识库中检索  $m$  个最相关的反馈。通过检索的反馈经验改进策略函数和价值函数, 在智能体进行动作选择和节点状态

表 4.2 用于智能体生成搜索树中规则状态节点价值预测的提示词

| 角色     | 提示词                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|--------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| System | <p>You are an expert in evaluating the performance of a computer agent. The agent is designed to assist a human user in generating the most appropriate rule in the rule learning task. First, I will introduce you to the basic concepts and background knowledge, and then I will explain the task you need to complete.</p> <p><b>Background Knowledge:</b></p> <p>Horn rules consist of a rule head and a rule body. For example, <math>\text{grandma}(x, y) \rightarrow \text{mother}(x, z) \wedge \text{mother}(z, y)</math>, where the rule head <math>\text{grandma}(x, y)</math> indicates that <math>x</math>'s grandmother is <math>y</math>, and the rule body <math>\text{mother}(x, z) \wedge \text{mother}(z, y)</math> indicates that <math>x</math>'s mother is <math>z</math> and <math>z</math>'s mother is <math>y</math>. This Horn rule signifies that the relationship <math>\text{grandma}</math> can be represented by the relationship path <math>\text{mother}/\wedge\text{mother}</math>. In some cases, knowledge graphs may be incomplete. For instance, if I want to ask <math>(A, \text{born\_in}, ?)</math>, and if the relationship <math>\text{born\_in}</math> is missing around the head entity <math>A</math>, then an alternative relationship needs to be found to answer this query. For example, <math>\text{born\_in}</math> can be replaced by <math>\text{live\_in}/\wedge\text{place\_in}</math>, i.e., <math>\text{born\_in} \rightarrow \text{live\_in}/\wedge\text{place\_in}</math>, which is a Horn rule. The purpose of our task is to learn such Horn rules.</p> |
| User   | <p><b>Task Objective:</b></p> <p>I will provide you with the agent's action history and the current observation (i.e., state) of the task. Your goal is to determine whether the rule I give you now is a valid and meaningful Horn rule within the knowledge graph, or whether the current rule can lead to a valid and meaningful Horn rule within the knowledge graph after being combined with subsequent rules. If the current states/actions have not achieved the task yet but the agent seems to be on the right track, you should indicate this as well.</p> <p>Below is the user's intent, and the current observation of the agent's attempt to solve the provided task.</p> <p><b>OBSERVATION:</b></p> <p>The current rule state is <b>GrandMother</b> <math>\leftarrow</math> <b>Mother</b> <math>\wedge</math> <b>Mother</b></p> <p>Now, it is your turn to evaluate the performance of the agent's execution so far.</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |

价值估计时，添加到智能体的当前上下文中。对于策略函数而言，反馈记忆的提示词设计见表4.4；对于价值函数而言，提示词设计见表4.5。

## 4.3 实验结果与分析

### 4.3.1 数据集

为了评估本章方法的有效性，主要在 FB15k-237、WN18RR、UMLS、Kinship 四个常用的知识图谱数据集上进行了实验。下面对这些数据集进行介绍，如表4.6。

#### (1) FB15k-237

FB15k-237 是一个广泛使用的知识图谱数据集，它源自 Freebase 数据库，专门用于链接预测任务。该数据集包含 14541 个实体和 237 种关系，总共有 310,116 个三元组。FB15k-237 旨在解决原始 FB15k 数据集中存在的逆向关系问题，从而提高链接预测的准确性。FB15k-237 数据集是知识图谱补全、链接预测等任务的理想选择，它为研究者提供了一个标准化的测试平台，以评估和比较不同算法的性能。



表 4.3 智能体执行状态价值评估提示词

| 角色   | 提示词                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| User | <p><b>*IMPORTANT*</b></p> <p>To evaluate task progress, choose one of the following options and provide your thought process.</p> <p>EVALUATION:</p> <p>A. The agent's last action/current observation fulfilled all requirements in the user's intent, and no further actions is needed. If the task is infeasible by design, the agent indicated this by returning "FAIL".</p> <p>B. The agent is very close to finishing the task. Only one more action (e.g., return "DONE" or "FAIL") is needed to complete the task.</p> <p>C. You are certain the agent is on the right track to success, but given the current observation, it needs more than one action to complete the task.</p> <p>D. The agent may be on the right track, but the proposed actions were not executed correctly/matched expectation. We should try other actions to make better progress.</p> <p>E. The agent's last action/current observation does NOT make progress towards the task completion (assuming it is feasible). The agent is NOT on the right track to success.</p> <p>Note that <i>*correctly*</i> identifying a task as infeasible by design is as valid/important as correctly completing a feasible task (i.e., option A). However, if the task is feasible but the agent identified it as infeasible, this should be penalized (i.e., option E).</p> <p>Format your response into four lines as shown below. Keep your response CONCISE. Reasons why the last action was/was not executed correctly based on the last observation: &lt;your reasonings&gt; Reasons indicating positive progress toward task completion (if you think it is feasible) based on past observations: &lt;your reasonings&gt; Reasons to try other actions, or why continuing from this state may lead to incorrect results: &lt;your reasonings&gt; EVALUATION: &lt;one of A, B, C, D, or E&gt;</p> |

表 4.4 策略函数反馈记忆提示词

| 角色   | 提示词                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| User | <p>FEEDBACK: here are some relevant feedback from rule learning tasks. Note that the feedback may not be directly related to the answer below, but they may provide some useful insights.</p> <p>OBSERVATION(1): <b>Aunt</b> <math>\leftarrow</math> <b>Mother</b> ATTEMPTED ACTION (1): To find the most appropriate rule to derive "aunt" from "mother," we need to consider familial relationships. A possible rule could be <math>\text{Mother}(x, z) \wedge \text{Brother}(z, w) \rightarrow \text{Aunt}(x, w)</math>, as the wife of someone's mother's brother is their aunt. FEEDBACK (1): Upon reviewing the rule <math>\text{Mother}(x, z) \rightarrow \text{Brother}(z, w) \square \text{Aunt}(x, w)</math>, I recognize that it is a valid Horn rule. This indicates that if we have a relationship where x's mother is z, and z's brother is w, then it is correct to infer that x's aunt is w. Given this understanding, in future encounters with the state involving "aunt" and "mother," I will be more inclined to select "brother" as the next relationship in the rule path. This choice is based on the logical inference that a mother's son's sister is indeed an aunt, which aligns with the familial relationships and the structure of Horn rules. (...some content omitted)</p> |

## (2) WN18RR

WN18RR 是 WordNet 18 的一个修订版本, 专为链接预测任务设计。它包含 40,943 个实体和 11 种关系, 总共有 93,003 个三元组。WN18RR 数据集通过移除原始 WN18 数据集中的逆向关系, 提供了一个更平衡的数据集, 以提高链接预测任务的准确性。WNRR 版本专注于

表 4.5 价值函数反馈记忆提示词

| 角色   | 提示词                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| User | <p>To better verify if user' s intent is fulfilled correctly, you may find the following opinions helpful:</p> <p>Reasons why the last action was/was not executed correctly based on the last observation: The agent has proposed a partial horn rule "Interacts_with-&gt;&lt;slf&gt;". This suggests that the agent is considering a rule where the relationship "Interacts_with" is being replaced or represented by "&lt;slf&gt;", which seems to be a placeholder or a variable. However, without further context or definition of "&lt;slf&gt;", it's unclear if this is a valid or meaningful replacement in the context of knowledge graph rules.</p> <p>Reasons indicating positive progress toward task completion (if you think it is feasible) based on past observations: There is no indication of past observations, so it's not possible to determine if the agent is making progress based on previous actions. The current observation alone does not provide enough information to assess the feasibility of the task.</p> <p>Reasons to try other actions, or why continuing from this state may lead to incorrect results: The use of "&lt;slf&gt;" as a replacement in the rule is ambiguous and does not align with the typical structure of a horn rule, which should have clear, defined relationships. Without clarification or further definition, continuing with this rule may lead to an incorrect or nonsensical rule.</p> <p><b>EVALUATION:</b> E</p> <p>(...some content omitted)</p> <p>Note that these opinions may or may NOT be correct. You should make your own judgment based on the user' s intent, the observations, and the agent' s executed actions so far.</p> |

减少数据集中的噪声，确保每个关系都是有效的，这使得 WN18RR 成为评估链接预测算法的理想选择。

### (3) UMLS

**UMLS:** 是一个医学领域的知识图谱数据集，它整合和标准化了来自多个术语表的术语，并利用语义网络中的语义关系进行更准确的文本分析。UMLS 由三个组件构成：**Metathesaurus**、**Semantic Network** 和 **SPECIALIST Lexicon**，这三个组件共同构成了一个全面的知识图谱。UMLS 为处理和分析 UMLS 元叙词提供了一种高效且灵活的方式，是生物医学信息学和自然语言处理项目中的有力工具。

### (4) Kinship

**Kinship:** 是一个专注于家庭关系的知识图谱数据集。它通过从公开的家庭照片库中筛选出具有明确亲属关系的图像，并由专业人员进行细致的标注，确保每对图像之间的亲属关系准确无误。**Kinship** 数据集的显著特点在于其高度结构化的数据组织和丰富的关系类型。每对图像不仅标注了具体的亲属关系，还提供了详细的元数据，如拍摄时间、地点等，这为研究者提供了多维度的分析可能性。**Kinship** 数据集主要用于计算机视觉领域的亲属关系识别研究。研究者可以通过训练模型来识别和分类图像中的亲属关系，从而应用于人脸识别、家庭关系分析等领域。

具体来说，各个数据集的训练集、验证集、测试集的划分如下：

表 4.6 数据集介绍

| 数据集       | 实体数量  | 关系数量 | 训练集数量  | 验证集数量 | 测试集数量 |
|-----------|-------|------|--------|-------|-------|
| UMLS      | 135   | 46   | 5327   | 569   | 633   |
| FB15K-237 | 14541 | 237  | 272115 | 17535 | 20466 |
| WN18RR    | 40943 | 11   | 86835  | 3034  | 3134  |
| Kinship   | 104   | 25   | 2350   | 1068  | 860   |

### 4.3.2 链接预测

知识图谱中的链接预测任务专注于识别和预测实体之间的缺失链接，从而提升图中知识表示的整体完整性和准确性。对于链接预测任务，测试数据集中的每个三元组  $(h, r, t)$  及其逆三元组  $(t, r^{-1}, h)$  都会被提供给模型，其中尾实体被掩盖，目标是在知识图谱的所有实体中预测出被掩盖的尾实体。每个候选实体都会根据推理结果获得一个分数，用于对它们进行排序，而真实实体会被从排名列表中过滤掉。

### 4.3.3 评价指标

与第三章类似，本章实验中所使用的四个评估指标分别为MRR、Hits@1、Hits@3 和Hits@10，关于这些评估指标的详细介绍与说明，请参阅本文3.5节。

### 4.3.4 实验设置

#### (1) 对比模型

**PathRank:** 通过图神经网络学习实体和关系的表示，并利用路径推理技术从已知实体和关系之间的路径中提取特征，从而提高知识图谱补全任务的准确性和鲁棒性。

**Neural-LP:** 将神经网络与逻辑推理相结合，将规则嵌入到神经网络中，使模型能够通过学习这些规则进行推理和预测，从而更准确地处理知识图谱中的不确定性和复杂关系。

**DRUM:** 采用随机化机制生成多样化的负样本，并结合多个损失函数（包括负采样损失和交叉熵损失）进行推理，提升了模型的性能和泛化能力。

**RNNLogic:** 使用 RNN 学习实体和关系的表示，并考虑知识图谱嵌入模型的影响。该方法将规则推理得分和知识图谱嵌入得分进行线性组合，作为最终的预测结果。

**RLogic:** 引入了谓词表示学习和递归原子模型，通过在采样路径上训练的评分模型和演绎推理来估计规则质量。

**Ruleformer:** 将 Transformer 架构应用于规则挖掘，将其视为一个序列任务，利用 Transformer 的强大建模能力来挖掘知识图谱中的逻辑规则。

**NCRL:** 专注于检测和分解复合逻辑规则，通过递归合并规则体中的成分来推断规则的最佳组成结构。

**ChatRule:** 利用大型语言模型（LLM）挖掘知识图谱中的逻辑规则。该框架通过基于 LLM 的规则生成器结合语义和结构信息生成候选规则，并通过规则排序模块和规则验证器优化规则质量。

## （2）参数设置

由于 FD-MCTS 方法需要一个策略来生成动作以进行探索，以及一个能够返回介于 0 到 1 之间值的价值函数。对于策略函数而言，本章通过规则解码器实现，编码器的每一层都包含层归一化和残差连接。具体来说解码器由 3 层组成，拥有 6 个注意力头，并且 dropout 率设置为 0.1。对于价值函数而言，本章使用 MoonShot-v1 作为大语言模型，将大语言模型的温度设置为 1.0, top- $p$  设置为 0.95 并利用核采样。此外，让大语言模型做出多项选择，并从其输出中采样 20 个回答；大模型选定的评价选项被分为 5 个类别：[A, B, C, D, E]，分别映射到数值 [0.2, 0.4, 0.6, 0.8, 1.0]。

除此之外，实验中训练轮数设置为 50。批训练样本数设置为 10。实体和关系嵌入的维度设置为 300 维。对于激活函数，本章使用了 *GeLU*。学习率设置为 0.001。对于参数训练，使用的优化器是 Adam。本章实验在 3 块 RTX 4090 GPU 上进行。

## 4.3.5 实验结果

链接预测的实验结果如表4.7所示，FD-MCTS 模型在多个关键数据集上的链接预测任务中展现出差异化性能表现。在 UMLS 数据集上，FD-MCTS 在所有评估指标上均取得显著突破，其 MRR 值达到 0.844，相比当前最优基线模型 ChatRule 提升了 8%，Hits@1 提升 4.0 个百分点。这验证了 FD-MCTS 中通过蒙特卡洛树搜索与反馈学习机制的协同作用，同时说明了将规则解码器输出的规则概率作为搜索树中每个规则状态的先验概率能够使得智能体有效探索正确的规则路径。该数据集实体规模较小（包含 135 种实体）但关系类型丰富（包含 46 种）的特点，使得基于规则路径的推理具有可行性，而大语言模型的价值预估能力在此类结构化场景中得以充分发挥。

对于大规模复杂数据集 FB15K-237，FD-MCTS 达到了当前的最佳性能，在 Hits@1 指标上较 ChatRule 模型提升 4.9 个百分点。值得注意的是，尽管该数据集包含高达 237 种关系类型和 14,541 个实体，FD-MCTS 仍能在保持规则可解释性的前提下取得突破，这得益于其反馈学习机制对搜索过程的动态优化。具体而言，算法通过从价值预估经验库中检索相似规则构建情境，有效缓解了传统 MCTS 在复杂空间中探索效率低下的缺陷。

在 WN18RR 数据集上，FD-MCTS 的 MRR 值 0.477 超过多数基线模型，深入分析发现，

该数据集在几个数据集中虽然关系类型最少（11种），但实体规模最大（40,943个），且规则路径的平均长度要求更高，此时大语言模型对超长规则序列的价值评估准确性可能下降，而反馈驱动机制补偿了这一点。

跨数据集对比揭示出算法性能差异的深层次原因。在UMLS 与 FB15K-237 数据集下，FD-MCTS 的混合架构优势得到最大化——规则解码器生成候选动作，LLM 价值函数提供全局评估，而反馈学习机制则通过对比反馈持续改进搜索策略。

表 4.7 针对 UMLS、FB15K-237 和 WN18RR 数据集的链接预测结果<sup>6</sup>

| 方法            | 模型              | UMLS        |             |             |             | FB15K-237   |             |             |             | WN18RR      |             |             |             |
|---------------|-----------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
|               |                 | MRR         | @1          | @3          | @10         | MRR         | @1          | @3          | @10         | MRR         | @1          | @3          | @10         |
| Rule Learning | PathRank        | .197        | 14.6        | 25.8        | 37.8        | .085        | 7.3         | 9.1         | 11.0        | .188        | 17.0        | 19.9        | 22.7        |
|               | Neural-LP(T=2)  | .750        | 63.0        | 84.6        | 93.9        | .189        | 12.6        | 20.6        | 31.2        | .372        | 36.0        | 37.5        | 39.6        |
|               | Neural-LP(T=3)  | .734        | 62.6        | 81.9        | 92.1        | .240        | 16.1        | 26.3        | 40.0        | .426        | 39.6        | 43.3        | 49.3        |
|               | DRUM(T=2)       | .789        | 64.3        | 92.4        | 96.5        | .238        | 17.1        | 25.3        | 35.7        | .380        | 36.9        | 38.7        | 41.0        |
|               | DRUM(T=3)       | .780        | 64.1        | 90.8        | 97.0        | .325        | 24.1        | 35.9        | 49.3        | .445        | 41.4        | 45.7        | 51.7        |
|               | RNNLogic        | .745        | 63.0        | 83.3        | 92.4        | .288        | 20.8        | 31.5        | 44.5        | .455        | 41.4        | 47.5        | 53.1        |
|               | RLogic          | .716        | 56.8        | 82.1        | 93.7        | .322        | 20.4        | 33.1        | 50.6        | .457        | 42.9        | 47.1        | 52.9        |
|               | NCRL            | .778        | 65.7        | 89.9        | 94.8        | .299        | 20.8        | 32.1        | 47.2        | <b>.668</b> | <b>55.9</b> | <b>67.7</b> | <b>84.9</b> |
|               | Ruleformer(T=2) | .794        | 66.8        | 90.6        | 96.6        | .271        | 18.1        | 30.0        | 46.8        | .377        | 36.2        | 38.3        | 41.0        |
|               | Ruleformer(T=3) | .796        | 67.1        | 90.5        | 97.3        | .307        | 22.5        | 33.2        | 47.5        | .426        | 38.9        | 43.7        | 50.3        |
|               | ChatRule        | .781        | 68.6        | 91.1        | 95.1        | .315        | 21.5        | 32.9        | 48.1        | .336        | 30.2        | 36.3        | 40.3        |
|               | <b>FD-MCTS</b>  | <b>.844</b> | <b>72.6</b> | <b>95.6</b> | <b>98.6</b> | <b>.344</b> | <b>26.4</b> | <b>36.9</b> | <b>50.4</b> | .477        | 43.0        | 49.3        | 57.1        |

### 4.3.6 消融实验

#### （1）结构感知图编码器结合不同智能体性能对比

本节在 FB15K-237 数据集上比较了FD-MCTS 对比其他基于搜索增强智能体的字符消耗数量（Tokens）和性能，同时使用 ReAct 作为基准来展示每个智能体平均使用的字符数量，如表4.8所示，其中 LAP（LLMs as Policy Function），表示将大语言模型作为策略函数，DAP（Decoder as Policy Function），表示将规则解码器作为策略函数。测试时间的长度也可以使用字符消耗数量来衡量。在这些方法中，SARL 结合 FD-MCTS<sub>DAP</sub> 始终优于其同类方法，经过分析，一方面是由于 FD-MCTS 能够通过 PUCT 来平衡探索和利用的策略，而像传统的思维链智能体主要依赖于大模型来引导搜索，并且无法有效利用图结构编码器输出的图表示。此外，FD-MCTS 智能体通过反馈学习机制，能够汲取以往错误的经验，改进决策的结果。相对于单独使用 SARL 或是使用 SARL 结合思维链，FD-MCTS<sub>DAP</sub> 的 Hits@1 指标分别改进了 3.2 和 4.1 个百分点。通过对比 LAP 和 DAP，可以发现 DAP 的效果更好，这是因为 DAP 提供了 FD-MCTS 探索时的先验概率，优先排除了一些不合理的规则路径，而 LAP 由于完全将大语言模型作为策略函数，忽略了规则解码器的输出的概率分布。通过整合搜索、反馈驱动，这

<sup>6</sup> 图中 @k 表示 Hits@k 指标。FD-MCTS 选择局部度数提取器作为默认的特征提取器，同时使用规则解码器作为策略函数

些改进表明 FD-MCTS 的有效性。

表 4.8 结构感知图编码器结合不同智能体性能与字符消耗数量对比

| 模型                            | FB15K-237 |             |             |
|-------------------------------|-----------|-------------|-------------|
|                               | Token 数量  | MRR         | Hits@1      |
| SARL                          | -         | .336        | 25.2        |
| SARL + CoT                    | 1x        | .306        | 22.3        |
| SARL + FD-MCTS <sub>LAP</sub> | 7.2x      | .325        | 24.0        |
| SARL + FD-MCTS <sub>DAP</sub> | 5.4x      | <b>.344</b> | <b>26.4</b> |

### (2) FD-MCTS 结合不同大模型效果对比

本节对比在 FB15K-237 数据集上对比了 FD-MCTS 结合不同大语言模型的性能，其中模拟步数被设置在 100 步，结果如表4.9所示。从实验结果可以看到，FD-MCTS 结合 MoonShot-v1 的结果更好一点。经过分析，由于 FD-MCTS 中大语言模型主要起反馈类比以及规则语义理解的作用，而 MoonShot-v1 的类比推理能力使其能够更好地处理这种关系推理任务，从而在 FD-MCTS 框架中表现比较好。

表 4.9 FD-MCTS 结合不同大模型效果对比

| 模型          | 模拟步数 | FB15K-237   |             |
|-------------|------|-------------|-------------|
|             |      | MRR         | Hits@1      |
| GPT-4o-mini | 100  | .339        | 25.5        |
| GPT-3.5     | 100  | .337        | 25.4        |
| Moonshot-v1 | 100  | <b>.344</b> | <b>26.4</b> |
| DeepSeek-V3 | 100  | .342        | 26.1        |
| Qwen-plus   | 100  | .340        | 25.7        |

### (3) 规则质量分析

与第三章相同，本章采用标准置信度度量对学习到的规则进行质量分析。具体来说，根据置信度水平对规则进行排名，并计算排名靠前的  $k$  个规则的平均分数。将 FD-MCTS 与其他规则学习方法进行比较，结果在图4.2中展示，其中  $T$  表示生成规则的最大长度。与其他方法相比，FD-MCTS 在 UMLS 和 FB15K-237 数据集上给出了有竞争力的结果。通过分析，可以将其归因于引入了大语言模型，作为规则状态的价值函数，结合规则的语义更精确的评估当前规则状态的价值，从而引导智能体更准确的选择规则路径。

## 4.4 本章小结

规则学习方法不仅能够从知识图谱中挖掘出有价值的逻辑规则，还能够将这些规则应用于下游任务，如知识图谱补全和知识图谱问答等。然而现有规则学习模型学习到的规则在语




图 4.2 UMLS 和 FB15K-237 数据集上排名靠前的规则的平均置信度

义合理性上存在不足。针对这一问题，本章采用基于反馈驱动蒙特卡洛树搜索和大语言模型智能体（Feedback-Driven Monte Carlo Tree Search Agent, FD-MCTS）的规则学习模型。FD-MCTS 通过结合蒙特卡洛树搜索和反馈学习机制，能够更有效地探索合理的规则路径，并减少决策错误。具体而言，FD-MCTS 将模型生成的概率分布视为先验概率，并通过蒙特卡洛树搜索来优化规则选择策略。在规则路径探索完成后，反馈学习机制会记录错误决策，以便在后续遇到相同状态时能够快速做出更优决策。实验结果表明，FD-MCTS 在大规模知识图谱的链接预测任务上取得了最先进的（SOTA）结果，并且显著提升了规则的质量。此外，FD-MCTS 作为一种测试时模型，无需额外训练即可迁移到其他任务，具有较高的实用性和泛化能力。总体而言，FD-MCTS 有效解决了现有规则学习方法在语义合理性上的不足，为知识图谱中的规则学习提供了新的思路和方法。

## 第五章 知识图谱规则学习原型系统的设计与实现

### 5.1 系统需求分析

知识图谱中的规则学习对于知识图谱问答、知识图谱的完善以及知识推理具有重要意义。通过从知识图谱数据中学习规则，可以有效发现潜在的知识关系和模式，为知识图谱的构建和应用提供支持。本系统基于规则学习模型，设计并实现了一个知识图谱规则学习系统，旨在帮助用户从常用知识图谱中提取逻辑规则，同时减少了数据标注对人工的依赖，帮助用户实现自动化数据标注，并展示学习结果。本章设计并实现的知识图谱规则学习原型系统，通过系统化的开发流程，将本文的研究成果具象化，从而直观地展现其应用价值。在系统开发过程中，本章首先对相关领域的需求进行了广泛调研，并紧密结合用户实际应用场景，对系统的功能需求和非功能需求进行了深入分析和明确规划。

知识图谱规则学习系统的主要功能需求如下：

#### （1）用户注册与登录

注册功能：用户可以通过邮箱进行注册，系统会向用户邮箱发送验证码以验证邮箱的有效性。用户需填写相关信息（如用户名、密码等），并输入验证码完成注册。

登录功能：用户可以通过邮箱和密码登录系统。系统验证用户输入的邮箱和密码是否匹配，确保用户身份的合法性。

#### （2）规则学习功能

规则学习：用户可以选择常用知识图谱数据集（如 UMLS、FB15K237、WN18RR 等），系统通过规则学习模型对数据集进行分析，提取出潜在的规则。

规则展示：系统将学习到的规则以直观的方式展示给用户，包括规则的内容、规则长度等信息，方便用户理解和分析。

#### （3）模型管理功能

用户可以根据自身需求灵活地添加所需的规则学习模型，以满足不同场景下的规则学习任务。系统提供了一个直观的界面，用户可以通过该界面轻松地上传自定义的规则学习模型。上传后，系统会自动对模型进行验证，确保其兼容性和正确性，并将其添加到模型库中供用户选择使用。

#### （4）历史记录功能

历史记录：系统会记录用户每次使用规则学习功能的操作记录，包括使用的数据集、学习到的规则、规则长度以及操作时间等信息。



记录查询：用户可以查看自己的历史记录，了解之前的学习操作和结果，便于对比和总结。

知识图谱规则学习系统的非功能需求分析如下：

(1) 系统需要确保用户数据的安全性，包括用户注册信息和历史记录等。数据库设计需合理，采用加密技术保护用户密码等敏感信息，防止数据泄露。

(2) 系统采用前后端分离的架构设计，便于后续功能的扩展和维护。模块化设计使得系统能够灵活应对用户需求的变化，支持更多的知识图谱数据集和规则学习算法。

(3) 系统界面设计简洁明了，操作流程清晰，规则学习结果展示直观。

(4) 系统需要在合理的时间内完成规则学习任务，并快速返回结果。

(5) 系统稳定性强，能够记录操作日志等，便于追溯。

通过以上功能需求和非功能需求的分析，本系统旨在为用户提供一个高效、安全、易用的知识图谱规则学习平台，帮助用户从知识图谱中提取有价值的规则，支持知识图谱的构建和应用。

## 5.2 系统设计

### 5.2.1 系统功能模块设计

在深入研究既有知识图谱相关工具后，并从实际使用者角度出发，该系统由如下两大核心模块构成：

#### (1) 用户管理模块

注册功能：系统支持邮箱注册，用户输入邮箱后，后端发送验证码邮件，验证码有效期 5 分钟。用户需在规定时间内输入正确验证码，同一邮箱每分钟仅能获取一次验证码，防止恶意注册。验证通过后，用户设置账号（即邮箱）、4-20 字符的用户名及至少 8 位的复杂密码，信息加密后存入 MySQL 用户表。

登录功能：已注册用户通过邮箱和密码登录。后端校验邮箱格式及密码，若正确则生成包含用户 ID、登录时间等信息的 JWT Token，有效期可设为 1 小时，返回给前端存储于 local-Storage 或 cookie。登录失败时提供错误提示，并记录失败次数，便于异常分析。

#### (2) 规则学习模块

模型选择与配置：本模块内集成本文提出的两种规则学习模型，即 SARL 与 FD-MCTS。系统支持多种常用知识图谱数据集，如 UMLS、FB15K237 和 WN18RR 等。用户在启动规则学习任务前，可按需从集成的数据集中选择一个作为学习目标。此外，允许用户对模型参数进行调整，如规则长度值、规则置信度等，以适应不同应用场景需求。

**规则学习与展示：**用户选定数据集并配置好学习参数后，通过点击“开始学习”按钮，前端将调用后端 API 触发规则学习任务。后端接收到请求后，将利用上述模型对所选数据集进行规则学习。学习完成后，后端会将这些规则按一定格式（如 JSON 或列表形式）返回给前端，前端在页面上以清晰的表格、列表或图形化方式展示学习到的规则，让用户直观了解规则内容、置信度、长度等信息，同时允许用户对规则进行筛选、排序和详细查看，以便进一步分析和应用。

### （3）模型管理模块

支持多种常见的模型格式和框架，如 Python 脚本等。上传后，系统会自动对模型进行验证，确保其兼容性和正确性。在模型库中，用户可以查看所有已添加的模型列表，包括模型的名称、版本、描述等详细信息。对于每个模型，用户可以进行编辑操作，如修改模型的参数配置、更新模型权重文件等，以优化模型的性能或适应新的数据集。用户还可以对模型进行删除操作。

### （4）历史记录模块

**记录操作信息：**每当用户通过规则学习模块完成一次规则学习任务，系统后端会自动将此次操作的相关信息记录到数据库的历史记录表中。记录的信息包括操作用户、所使用的数据集名称、学习到的规则本身内容等。这些信息能够完整还原用户的历史学习轨迹，便于用户随时追溯和复盘操作历史。

**查看与管理：**用户可在系统中查看自身所有历史记录。前端提供简洁直观的历史记录界面，以列表形式展示每条记录的核心信息，如操作时间、数据集名称、学习到的规则数量等，并允许用户点击某条记录查看详细内容，包括学习到的每条规则的具体表达式和相关信息。此外，为方便用户管理历史记录，系统支持按时间区间、数据集名称等条件进行查询和筛选的功能，用户还能够对历史记录进行标记或分类，以区分不同记录的重要性和用途。

## 5.2.2 系统结构设计

该系统采取基于前后端分离的 Browser/Server 架构，将系统前端与后端解耦，便于各自独立开发和维护。系统架构图如5.1所示，分为以下三个主要部分：

### （1）前端设计

选用 Vue.js 作为核心框架，Vue 的响应式数据绑定和组件化开发模式使页面构建更加灵活高效。配合 Element UI 或 Ant Design Vue 等 UI 组件库，可快速搭建出精致且功能丰富的用户界面，提升用户体验。同时，借助 Vue Router 实现前端页面的路由管理，轻松实现单页面应用（SPA）的页面切换效果。主要功能实现为：

**用户交互界面：**围绕登录、注册、规则学习和历史记录查看等核心功能，打造用户友好




图 5.1 系统架构图

且直观的交互页面。登录注册页面注重表单校验反馈，规则学习页面提供模型参数配置和数据集选择选项，历史记录页面强调信息的清晰展示和便捷查询。

与后端通信：通过 Axios 等 HTTP 客户端库，Vue 前端与后端 API 进行高效通信，实现用户登录认证、规则学习任务提交、规则查询及历史记录数据请求等功能。例如，在用户登录时，前端调用后端登录 API，传递邮箱和密码，接收返回的 Token，并将其存储在本地；在规则学习过程中，前端将模型配置参数和数据集信息封装成请求体发送至后端，等待后端返回学习结果并展示。

## （2）后端设计

选用 Spring Boot 作为后端开发框架，凭借其简洁的配置、强大的依赖管理和丰富的生态系统，可快速搭建高性能、高可用的服务端应用。结合 Spring Security 实现用户认证和授权管理，保障系统信息安全。数据持久化采用 MyBatis 作为对象关系映射（ORM）工具。数据库选用 MySQL，架构为主从架构。采用 Redis 作为缓存。在日志记录方面，采用 Elasticsearch + Logstash + Kibana 作为日志框架。系统被划分为五个主要模块：用户服务模块、规则学习算法服务模块、模型管理服务模块、历史记录服务模块和日志记录服务模块。

用户认证服务：负责对用户登录、注册请求的处理，如邮箱验证、密码加密存储、Token 生成与验证等。同时，为历史记录模块提供用户身份信息支持，确保记录的归属正确。

规则学习服务：实现知识图谱数据集的加载、模型的初始化与配置以及规则学习任务的

调度与执行。根据前端传来的模型参数和数据集信息，调用集成的规则学习算法进行规则抽取，完成后将结果封装为合适的格式返回给前端。此外，还负责将学习任务的执行结果同步记录到历史记录表中，为用户后续查看提供数据支撑。

模型管理服务模块允许用户上传自定义规则学习模型，系统自动验证模型的兼容性和正确性，对验证通过的模型进行存储和管理，用户可查看模型列表、编辑和删除模型等。历史记录服务模块记录用户每次规则学习的操作信息，包括操作用户、数据集名称、学习到的规则内容等，用户可按条件查询和管理历史记录。

日志记录服务模块使用 ELK 日志框架记录系统运行日志，便于问题排查和系统监控，日志记录表存储关键日志信息，日志文件按天分割存储在文件系统中。Redis 用于缓存用户信息、历史记录、规则学习结果等，减少数据库查询压力，提升系统性能，缓存策略包括设置合理的缓存过期时间和在数据库更新时同步更新缓存数据，确保数据一致性。

### （3）数据库设计

选用 MySQL 作为系统的数据库管理系统，其关系型数据库特性适配用户表和历史记录表的数据存储需求，支持高效的 SQL 查询语句，此外也提供了强大的事务处理能力和外键约束机制，确保数据的完整性和一致性，同时具备用户权限管理和数据加密功能，能够有效保障数据的安全性。根据用户实际需求，数据库表包括用户信息表、模型表、历史记录表和日志记录表。

用户表包含用户账号、邮箱、用户名、密码等基本信息，其中密码需采用不可逆加密算法（如 MD5）存储，确保信息安全，表结构如表5.1所示，同时因为要根据账号来检索用户信息，因此将 `user_account` 字段设置成唯一索引。

历史记录表记录用户每次规则学习操作的关键信息，其中记录 ID 作为主键自动递增，操作用户关联用户表，数据集名称标识学习目标，规则内容存储学习到的规则文本，操作时间记录任务执行的精确时间点，表结构如表5.2所示。

模型管理表记录用户自己上传的模型信息，其中模型文件路径表示上传到对象存储系统的代码路径，如表5.3所示。

表 5.1 用户信息表

| 序号 | 字段名                       | 含义    | 数据类型                  | 长度 | 允许空 | 是否主键 | 是否唯一 |
|----|---------------------------|-------|-----------------------|----|-----|------|------|
| 1  | <code>user_id</code>      | 用户 id | <code>int</code>      | 0  | 否   | 是    | 是    |
| 2  | <code>user_account</code> | 账号    | <code>varchar</code>  | 20 | 否   | 否    | 是    |
| 3  | <code>username</code>     | 用户名   | <code>varchar</code>  | 20 | 否   | 否    | 否    |
| 4  | <code>password</code>     | 密码    | <code>varchar</code>  | 20 | 否   | 否    | 否    |
| 5  | <code>create_time</code>  | 创建时间  | <code>datetime</code> | 0  | 否   | 否    | 否    |
| 6  | <code>update_time</code>  | 更新时间  | <code>datetime</code> | 0  | 否   | 否    | 否    |

表 5.2 历史记录表

| 序号 | 字段名称                   | 字段含义        | 数据类型     | 字段长度 | 是否允许为空 | 是否主键 | 是否唯一 |
|----|------------------------|-------------|----------|------|--------|------|------|
| 1  | id                     | 记录 id       | int      | 0    | 否      | 是    | 是    |
| 2  | record_dataset         | 数据集         | varchar  | 20   | 否      | 否    | 否    |
| 3  | record_rule_len        | 规则长度        | int      | 0    | 否      | 否    | 否    |
| 4  | record_ramcts          | 是否启用蒙特卡洛树搜索 | int      | 0    | 否      | 否    | 否    |
| 5  | record_rule_confidence | 规则置信度       | float    | 10,2 | 否      | 否    | 否    |
| 6  | create_user_id         | 操作用户        | varchar  | 20   | 否      | 否    | 否    |
| 7  | create_time            | 创建时间        | datetime | 0    | 否      | 否    | 否    |
| 8  | update_time            | 更新时间        | datetime | 0    | 否      | 否    | 否    |

表 5.3 模型管理表

| 序号 | 字段名称              | 字段含义     | 数据类型     | 字段长度 | 是否允许为空 | 是否主键 | 是否唯一 |
|----|-------------------|----------|----------|------|--------|------|------|
| 1  | model_id          | 模型 id    | int      | 0    | 否      | 是    | 是    |
| 2  | model_name        | 模型名称     | varchar  | 50   | 否      | 否    | 是    |
| 3  | model_version     | 模型版本     | varchar  | 20   | 否      | 否    | 否    |
| 4  | model_description | 模型描述     | text     | 0    | 是      | 否    | 否    |
| 5  | model_code_path   | 模型代码文件路径 | varchar  | 255  | 否      | 否    | 否    |
| 6  | model_weight_path | 模型权重文件路径 | varchar  | 255  | 否      | 否    | 否    |
| 7  | model_script      | 模型启动脚本   | varchar  | 1024 | 否      | 否    | 否    |
| 8  | create_user_id    | 创建用户     | varchar  | 20   | 否      | 否    | 否    |
| 9  | create_time       | 创建时间     | datetime | 0    | 否      | 否    | 否    |
| 10 | update_time       | 更新时间     | datetime | 0    | 否      | 否    | 否    |

日志记录表存储关键日志信息，如表5.4所示。

表 5.4 日志记录表

| 序号 | 字段名称           | 字段含义  | 数据类型     | 字段长度 | 是否允许为空 | 是否主键 | 是否唯一 |
|----|----------------|-------|----------|------|--------|------|------|
| 1  | log_id         | 日志 id | int      | 0    | 否      | 是    | 是    |
| 2  | log_timestamp  | 日志时间戳 | datetime | 0    | 否      | 否    | 否    |
| 3  | log_level      | 日志级别  | varchar  | 20   | 否      | 否    | 否    |
| 4  | log_message    | 日志消息  | text     | 0    | 是      | 否    | 否    |
| 5  | log_source     | 日志来源  | varchar  | 50   | 否      | 否    | 否    |
| 6  | create_user_id | 操作用户  | varchar  | 20   | 是      | 否    | 否    |
| 7  | create_time    | 创建时间  | datetime | 0    | 否      | 否    | 否    |

5.3 系统实现与展示

本节将根据先前描述的系统功能模块设计，详细介绍知识图谱规则学习系统各个功能的实现，并对系统界面进行展示。

5.3.1 用户管理模块

(1) 用户注册

用户注册功能允许用户通过邮箱进行注册。用户在注册页面输入邮箱地址后，系统会向该邮箱发送一封包含验证码的邮件，验证码有效期为 5 分钟。用户需在规定时间内将验证码

输入注册页面的验证码输入框中。若验证码错误或过期，用户可重新获取验证码，但同一邮箱每分钟仅能获取一次验证码，以防止恶意注册行为。当验证码验证通过后，用户需设置账号（即邮箱）、4-20个字符的用户名以及至少8位的复杂密码（包含字母、数字及特殊字符）。用户填写的密码将经过 MD5 加密处理后存储到 MySQL 数据库的用户表中。用户注册模块的逻辑流程图如图5.2(a)所示。注册页面如图5.3(a)所示。

## （2）用户登录

用户登录功能允许已注册用户通过邮箱和密码登录系统。用户在登录页面输入邮箱和密码后，系统会验证邮箱格式及密码的正确性。若验证通过，系统将生成一个包含用户 ID、登录时间等信息的 JWT Token（JSON Web Token），Token 有效期为 1 小时，并将其返回给前端存储于浏览器的 localStorage 或 cookie 中。若登录失败，系统会提供错误提示信息，并记录失败次数，以便后续对异常登录行为进行分析。用户登录模块的逻辑流程图如图5.2(b)所示。登录页面如图5.3(b)所示。




图 5.2 用户管理流程图

## 5.3.2 规则学习模块

用户在选定数据集并配置好学习参数后，点击“开始学习”按钮，前端将调用后端 API 触发规则学习任务。后端接收到请求后，将利用选定的模型对所选数据集进行规则学习。后端根据用户选择的模型 ID，查询数据库中的模型管理表，获取模型的 OSS URL、启动脚本及参数等信息。接着从 OSS 下载模型代码，并将其保存到本地临时目录。使用 ProcessBuilder 根



(a) 注册页面



(b) 登录页面

图 5.3 用户管理页面

据模型启动脚本及参数启动算法服务。启动脚本会加载模型代码，并初始化模型。接着规则学习算法将加载用户选择的数据集，调用相应的规则学习算法，对数据集进行分析，提取潜在的规则。学习完成后，算法服务将学习到的规则以 JSON 或列表形式返回给后端。后端将结果封装为合适的格式返回给前端。规则学习模块流程图如图5.4(a)所示，规则学习结果由前端页面以列表形式进行展示。

### 5.3.3 模型管理模块

用户在前端选择要上传的模型文件，包括模型代码、启动脚本及参数等。同时，用户还需要输入模型的名称、版本、描述等信息。后端接收到前端的模型上传请求后，首先对请求进



行初步校验，如检查请求中是否包含必要的模型文件和信息。接着对上传的模型代码和参数进行校验。包括检查模型代码的语法是否正确、启动脚本是否可执行、参数格式是否符合要求等。如果校验失败，后端会返回相应的错误信息给前端。校验通过后，后端将模型文件上传到 OSS（对象存储服务），并获取上传后的文件 URL。接着将模型的名称、版本、描述、OSS URL、启动脚本及参数等信息存储到数据库的模型管理表中，添加成功后返回模型添加成功的响应给前端，前端提示用户模型添加成功。模型管理模块的逻辑流程图如图5.4(b)所示，模型列表页面如图5.5(a)所示，模型创建页面如图5.5(b)所示。




图 5.4 规则学习与模型管理模块流程图



图 5.5 规则学习与模型管理模块页面



## 第六章 总结与展望

### 6.1 本文工作总结

知识图谱中的规则学习是知识图谱领域的关键技术之一，通过挖掘逻辑规则支持知识的推理、验证和扩展，对知识图谱补全、问答系统等领域具有重要意义，因此近年来成为知识表示与推理的研究热点。基于深度学习的规则学习方法是当前的主流方向，许多相关工作取得了显著成果。然而，规则学习方法的表现与对知识图谱结构信息的利用密切相关，丰富的知识图谱结构信息往往能提升规则的质量和推理能力，但在实际应用中，现有方法普遍存在两个问题：一是未能有效建模知识图谱中的结构信息，如多跳路径和拓扑结构，导致无法捕捉知识图谱深层次的语义关系并学习到合理的规则；二是过于依赖统计置信度评估规则，忽视规则的语义合理性和逻辑连贯性，使得生成的规则在下游任务中表现不佳。因此，如何有效建模知识图谱的结构信息并生成语义合理的规则，成为研究的重点和难点。

针对上述挑战，本文对国内外规则学习相关工作进行了充分调研，并深入分析了现有方法的优缺点。通过对已有算法的扩展和创新，本文提出了两种规则学习模型，并实现了一个知识图谱规则学习系统。具体研究内容如下：

（1）针对现有规则学习方法未能有效建模知识图谱中结构信息的问题，提出了一种结构感知规则学习模型（Structure-Aware Rule Learning, SARL）。该模型采用编码器-解码器架构，通过双层图编码器捕获多粒度结构信息：局部级图编码器利用广义注意力机制聚合头实体周围的多跳邻域特征，克服传统方法仅关注单跳邻域的局限性；全局级图编码器则建模整个子图的拓扑结构，使实体能够感知全局关系路径。解码器采用注意力加权机制，根据子图特征动态选择最优逻辑规则。在 UMLS、FB15K-237 等基准数据集上的实验表明，SARL 在链接预测任务中取得了最先进的性能。其创新性体现在：首次融合局部与全局结构信息建模，设计广义注意力机制增强实体表征，并验证了结构感知编码器在多跳推理任务中的有效性，为知识图谱推理提供了新路径。

（2）针对规则生成中过于依赖统计置信度、忽视语义合理性的问题，提出了一种基于反馈驱动蒙特卡洛树搜索和大语言模型智能体（Feedback-Driven Monte Carlo Tree Search Agent, FD-MCTS）的规则学习模型。该模型利用大语言模型评估规则路径的语义合理性，以蒙特卡洛树搜索进行多步探索优化规则选择，并通过反馈学习机制记录历史错误，提升未来决策的准确性。在 UMLS、FB15K-237、WN18RR 等数据集上的实验显示，FD-MCTS 显著提升了链接预测性能和规则质量，为解决语义不合理性问题提供了一个创新的智能体框架。其优势在于结合大语言模型的语义理解能力和蒙特卡洛树搜索的探索能力，生成的规则更具逻辑性和

可解释性。

(3) 围绕所提出的规则学习模型, 设计并实现了一个知识图谱规则学习系统。该系统支持用户从常用知识图谱中提取逻辑规则, 减少人工标注依赖, 并实现自动化数据标注。系统界面友好、操作简便, 将研究成果转化为实用工具, 展示了规则学习在实际应用中的价值。通过人机交互设计, 提升了系统的易用性和用户体验。

## 6.2 进一步研究方向

本文提出的 SARL 和 FD-MCTS 模型在知识图谱规则学习任务中取得了显著成效, 但仍存在不足和值得进一步探索的方向。基于当前研究成果, 未来可从以下几个方面继续改进和深化:

(1) 对于 SARL 模型, 尽管其有效融合了局部和全局结构信息, 但对结构特征的编码仍可优化。未来研究可探索更先进的图编码架构, 捕捉知识图谱中的有向关系和边类型信息, 提升模型对复杂结构的建模能力。此外, 针对大规模子图, 全局编码器的计算效率需进一步改进, 使其能够处理更复杂的规则形式或融入更多上下文信息, 进一步提升推理性能。

(2) 对于 FD-MCTS 模型, 依赖大语言模型评估语义合理性虽然创新, 但计算成本较高。未来可研究轻量级语言模型或知识蒸馏技术, 降低计算开销同时保持语义评估能力。蒙特卡洛树搜索的探索与利用平衡也可优化, 例如通过自适应参数调整或高级搜索策略提高效率。

## 参考文献

- [1] Cui W, Zhang L. Modeling knowledge graphs with composite reasoning[C]. Proceedings of the AAAI Conference on Artificial Intelligence. Vancouver, Canada: AAAI Press, 2024: 8338–8345.
- [2] Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]. SIGMOD '08: Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data. New York, NY, USA: Association for Computing Machinery, 2008: 1247 – 1250.
- [3] Agarwal P, Kumar N, Bedathur S. SymKGQA: Few-shot knowledge graph question answering via symbolic program generation and execution[C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 10119–10140.
- [4] Gu H, Zhou K, Han X, et al. PokeMQA: Programmable knowledge editing for multi-hop question answering [C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 8069–8083.
- [5] Zhao Q, Qian H, Liu Z, et al. Breaking the barrier: Utilizing large language models for industrial recommendation systems through an inferential knowledge graph[C]. CIKM '24: Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. New York, NY, USA: Association for Computing Machinery, 2024: 5086 – 5093.
- [6] Wu F, Zhao G, Li T, et al. Improving conversational recommendation system through personalized preference modeling and knowledge graph[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(12): 8529–8540.
- [7] Li M, Yang C, Xu C, et al. Context-aware inductive knowledge graph completion with latent type constraints and subgraph reasoning[C]. Proceedings of the AAAI Conference on Artificial Intelligence. Philadelphia, PA, USA: AAAI Press, 2025: 12102–12111.
- [8] Galárraga L, Teflioudi C, Hose K, et al. Fast rule mining in ontological knowledge bases with AMIE+[J]. VLDB J., 2015, 24(6): 707–730.
- [9] Yang F, Yang Z, Cohen W W. Differentiable learning of logical rules for knowledge base reasoning[C]. Advances in Neural Information Processing Systems: volume 30. New York, NY, USA: Curran Associates, Inc., 2017.
- [10] Sadeghian A, Armandpour M, Ding P, et al. Drum: End-to-end differentiable rule mining on knowledge graphs[C]. Advances in Neural Information Processing Systems: volume 32. New York, NY, USA: Curran Associates, Inc., 2019.
- [11] Li W, Peng R, Li Z. Knowledge graph completion by jointly learning structural features and soft logical rules [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(3): 2724–2735.
- [12] Qu M, Tang J. Probabilistic logic neural networks for reasoning[C]. Advances in Neural Information Process-

- ing Systems: volume 32. New York, NY, USA: Curran Associates, Inc., 2019.
- [13] Qu M, Chen J, Xhonneux L P, et al. {RNNL}ogic: Learning logic rules for reasoning on knowledge graphs [C]. International Conference on Learning Representations. Ithaca, NY: OpenReview.net, 2021.
- [14] Xu Z, Ye P, Chen H, et al. Ruleformer: Context-aware rule mining over knowledge graph[C]. Proceedings of the 29th International Conference on Computational Linguistics. Gyeongju, Republic of Korea: International Committee on Computational Linguistics, 2022: 2551–2560.
- [15] Cheng K, Liu J, Wang W, et al. Rlogic: Recursive logical rule learning from knowledge graphs[C]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York, NY, USA: Association for Computing Machinery, 2022: 179 – 189.
- [16] Liu J, Mao Q, Lin C, et al. LATENTLOGIC: Learning logic rules in latent space over knowledge graphs [C]. Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore: Association for Computational Linguistics, 2023: 4578–4586.
- [17] Cheng K, Ahmed N K, Sun Y. Neural compositional rule learning for knowledge graph reasoning[C]. The Eleventh International Conference on Learning Representations, ICLR 2023. Ithaca, NY: OpenReview.net, 2023.
- [18] Meilicke C, Chekol M W, Betz P, et al. Anytime bottom-up rule learning for large-scale knowledge graph completion[J]. The VLDB Journal, 2024, 33(1): 131–161.
- [19] Luo L, Ju J, Xiong B, et al. Chatrule: Mining logical rules with large language models for knowledge graph reasoning[J/OL]. CoRR, 2023, abs/2309.01538. <https://doi.org/10.48550/arXiv.2309.01538>.
- [20] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: volume 30. New York, NY, USA: Curran Associates, Inc., 2017.
- [21] Wang Q, Mao Z, Wang B, et al. Knowledge graph embedding: A survey of approaches and applications[J]. IEEE Transactions on Knowledge and Data Engineering, 2017, 29(12): 2724–2743.
- [22] Bordes A, Usunier N, Garcia-Duran A, et al. Translating embeddings for modeling multi-relational data[C]. Advances in Neural Information Processing Systems: volume 26. New York, NY, USA: Curran Associates, Inc., 2013.
- [23] Wang Z, Zhang J, Feng J, et al. Knowledge graph embedding by translating on hyperplanes[C]. Proceedings of the Twenty-Eighth AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2014: 1112–1119.
- [24] Sun Z, Deng Z H, Nie J Y, et al. Rotate: Knowledge graph embedding by relational rotation in complex space [C]. International Conference on Learning Representations. Ithaca, NY: OpenReview.net, 2019.
- [25] Ge X, Wang Y, Wang B, et al. Compounding geometric operations for knowledge graph completion[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023. Toronto, Canada: Association for Computational Linguistics, 2023: 6947–6965.
- [26] Nickel M, Tresp V, Kriegel H. A three-way model for collective learning on multi-relational data[C]. Proceedings of the 28th International Conference on Machine Learning, ICML 2011. Madison, Wisconsin: Omnipress,

- 2011: 809–816.
- [27] Toutanova K, Chen D. Observed versus latent features for knowledge base and text inference[C]. Proceedings of the 3rd Workshop on Continuous Vector Space Models and their Compositionality. Beijing, China: Association for Computational Linguistics, 2015: 57–66.
- [28] Dettmers T, Minervini P, Stenetorp P, et al. Convolutional 2d knowledge graph embeddings[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2018, 32(1).
- [29] Balazevic I, Allen C, Hospedales T. Tucker: Tensor factorization for knowledge graph completion[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong, China: Association for Computational Linguistics, 2019: 5184–5193.
- [30] Kolda T G, Bader B W. Tensor decompositions and applications[J]. SIAM Review, 2009, 51(3): 455–500.
- [31] Trouillon T, Welbl J, Riedel S, et al. Complex embeddings for simple link prediction[C]. Proceedings of Machine Learning Research: volume 48 Proceedings of The 33rd International Conference on Machine Learning. New York, NY, USA: PMLR, 2016: 2071–2080.
- [32] Zhang Z, Wang J, Ye J, et al. Rethinking graph convolutional networks in knowledge graph completion[C]. WWW '22: Proceedings of the ACM Web Conference 2022. New York, NY, USA: Association for Computing Machinery, 2022: 798 – 807.
- [33] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]. The Semantic Web. Cham: Springer International Publishing, 2018: 593–607.

## 附录 A 程序清单

第三章结构感知规则学习 SARL 算法程序（SARL 文件夹）

`main.py`: SARL 主函数相关代码，负责启动训练、测试、输出规则等

`model.py`: SARL 模型相关代码，主要包含结构感知图编码器，规则解码器

`optimizer.py`: 参数优化器代码，用于动态调整学习率等

`encoder` 文件夹: 结构感知图编码器相关代码，`sa_layers.py` 为局部级编码器和全局级编码器的代码实现，`sa_graph_encoder_layer.py` 为单层图编码器的代码实现，`sa_graph_encoder_model.py` 为整个图编码器的代码实现

`decoder` 文件夹: 规则解码器的相关代码，包含`rule_decoder_layer.py`和`rule_decoder.py`分别表示单层规则解码器和整体规则解码器的代码实现

`dataset` 文件夹: 数据集文件，包含文中所使用的 UMLS、FB15K-237、WN18RR、Kinship 数据集的相关训练集、验证集、测试集文件

第四章反馈驱动蒙特卡洛树搜索规则学习（FD-MCTS）算法程序（FD-MCTS 文件夹）

`mcts` 文件夹: 蒙特卡洛树搜索的实现代码，其中 `mcts.py` 表示蒙特卡洛树及其搜索的实现代码，`node.py` 表示树中节点以及节点选择策略 PUCT 的实现代码，`feedback.py` 实现了反馈学习策略

`llm` 文件夹: 实现与大语言模型对接的代码，包含`llm.py`和`prompt_factory.py`，其中 `llm.py` 负责对接不同大语言模型进行对话，`prompt_factory.py` 为 FD-MCTS 智能体的不同的 `prompt` 实现

## 附录 B 攻读专业学位硕士期间撰写的论文

## 附录 C 攻读专业学位硕士期间申请的专利



## 附录 D 攻读专业学位硕士期间参加的科研项目

## 致谢

时光荏苒，论文的完成也意味着这一阶段的学习生活即将告一段落。回顾论文从选题、资料收集、方案设计到修改完善的整个过程，我得到了许多老师、同学和亲友的帮助与支持，在此谨向所有关心和帮助过我的人表示诚挚的感谢。

首先，衷心感谢我的指导教师。在论文撰写过程中，徐老师在研究思路、内容结构、方法设计和文字表达等方面给予了耐心细致的指导。老师严谨的治学态度、认真负责的工作作风以及对学术问题的深入思考，使我受益匪浅，也为我今后的学习和工作树立了良好的榜样。

同时，感谢各位任课教师在学习期间给予我的教导，使我掌握了较为系统的专业知识，为本论文的顺利完成奠定了基础。感谢同学和朋友们在资料查找、问题讨论及论文修改过程中给予的建议与帮助，与你们共同学习和交流的经历将成为我珍贵的回忆。

最后，特别感谢家人一直以来的理解、鼓励与支持。正是你们的陪伴，使我能够坚定地完成学业。由于本人能力和水平有限，论文中仍可能存在不足，恳请各位老师批评指正。