

单位代码： 10293 密 级：

南京邮电大学

专 业 学 位 硕 士 论 文



论文题目： 基于条件扩散模型的高保真心电图波形重建

学	号	<u>B22080209</u>
姓	名	<u>王晨旭</u>
导	师	<u>韩京宇</u>
专业	学位类别	<u>工学硕士</u>
类	型	<u>全日制</u>
专业	（领域）	<u>计算机科学与技术</u>
论文	提交日期	<u>2026.6.26</u>

摘要

心电图波形的高保真重建对远程医疗、可穿戴监测及临床诊断具有重要意义，但信号在采集过程中常因噪声、稀疏采样或导联缺失而严重退化。本文提出一种基于条件扩散模型的心电图波形重建方法，将低质量或残缺心电信号作为条件约束，引导扩散模型从高斯噪声中逐步去噪，生成高分辨率、形态真实的重建波形。通过在反向扩散过程中引入导联相关性先验和多尺度特征融合机制，模型能够精准恢复 P 波、QRS 复合波与 T 波等关键细节，有效抑制伪影与失真。在 MIT-BIH 心律失常数据库和 PTB 诊断数据库上的实验结果表明，所提方法在均方根误差、相关系数和弗雷歇距离等指标上均显著优于卷积神经网络与生成对抗网络等基线模型，且在强噪声和高缺失率场景下仍能保持优异的鲁棒性和重建保真度。该工作为低质量心电信号的可靠重建提供了一种新的生成式建模途径。

关键词：条件扩散模型；心电图波形重建

Abstract

High-fidelity reconstruction of electrocardiogram (ECG) waveforms is essential for telemedicine, wearable monitoring, and clinical diagnosis; however, acquired signals are often severely degraded by noise, sparse sampling, or missing leads. This paper proposes an ECG waveform reconstruction method based on conditional diffusion models. The approach takes low-quality or incomplete ECG signals as conditions to guide the diffusion model in progressively denoising Gaussian noise, thereby producing high-resolution and morphologically realistic reconstructions. By incorporating lead correlation priors and a multi-scale feature fusion mechanism into the reverse diffusion process, the model accurately restores critical details such as P waves, QRS complexes, and T waves while suppressing artifacts and distortions. Experimental results on the MIT-BIH Arrhythmia Database and the PTB Diagnostic Database show that the proposed method significantly outperforms baseline models, including convolutional neural networks and generative adversarial networks, in terms of root mean square error, correlation coefficient, and Fréchet distance, and it maintains excellent robustness and reconstruction fidelity even under severe noise and high missing rates. This work offers a novel generative modeling pathway for the reliable reconstruction of low-quality ECG signals.

Key Words: Conditional diffusion model; ECG waveform reconstruction

目 录

摘要	I
Abstract	II
插图索引	V
表格索引	VI
专用术语注释表	VII
第一章 绪论	1
1.1 研究背景与意义	1
1.1.1 心电波形重建的临床需求	1
1.1.2 信号退化的挑战与重建难点	1
1.2 国内外研究现状	2
1.2.1 传统心电信号处理方法	2
1.2.2 基于深度学习的心电重建方法	2
1.2.3 扩散模型及其在信号处理中的应用	2
1.3 本文主要研究内容与章节安排	2
第二章 相关背景知识介绍	4
2.1 心电信号基础与信号退化	4
2.1.1 心电信号的产生与波形形态	4
2.1.2 心电信号的噪声与退化	4
2.2 去噪扩散概率模型	4
2.2.1 正向扩散过程	5
2.2.2 反向扩散过程与训练	5
2.2.3 条件扩散模型	5
2.3 评价指标与心电数据库	6
2.3.1 重建质量评价指标	6
2.3.2 标准心电数据库	6
2.4 本章小结	7
第三章 基于条件扩散模型的高保真心电波形重建方法	8
3.1 问题建模与总体框架	8
3.1.1 条件扩散模型的构建	8
3.1.2 网络结构设计	8
3.2 导联相关性与多尺度特征融合	8
3.2.1 导联相关性先验建模	8
3.2.2 多尺度特征融合机制	8
3.3 训练策略与采样加速	9
3.3.1 联合训练与损失函数	9
3.3.2 推理阶段的加速采样	9
3.4 本章小结	9
第四章 实验结果与分析	10
4.1 实验设置与数据准备	10
4.1.1 数据集划分与预处理	10
4.1.2 退化模拟与评价指标	10

4.2	重建效果对比与分析	10
4.2.1	定量结果对比	10
4.2.2	可视化与形态学分析	10
4.3	消融实验与鲁棒性分析	11
4.3.1	模块消融实验	11
4.3.2	噪声强度与缺失率鲁棒性测试	11
4.4	本章小结	11
第五章	总结与展望	12
5.1	本文工作总结	12
5.1.1	主要工作内容	12
5.1.2	主要结论	12
5.2	未来工作展望	12
5.2.1	轻量化与实时推理	12
5.2.2	跨模态与可解释性拓展	12
5.3	本章小结	13
参考文献		14
附录 A 程序清单		15

插图索引

表格索引

表 2.1 使用的标准心电数据库概况 7

专用术语注释表

符号说明：

符号	表示含义
f_s	采样频率
N	信号采样
T	心拍周期
$\mathbf{x}$	原始干净
$\mathbf{y}$	受污染 (
σ	扩散过程
t	扩散时间
ϵ	高斯噪声

缩略词说明：

缩写	英文全称
ECG	Electroca
AI	Artificial
CNN	Convolut
RNN	Recurrent
LSTM	Long Sho
DDPM	Denoising
SNR	Signal-to
MSE	Mean Squ
XAI	Explainab

第一章 绪论

1.1 研究背景与意义

心电图 (Electrocardiogram, ECG) 作为心脏电活动的体表记录, 是心血管疾病诊断、疗效评估和健康监测中最基础、最广泛的生理信号之一。随着远程医疗、可穿戴设备和移动健康应用的迅猛发展, 心电信号的获取场景已从标准临床环境拓展至日常生活, 从而对信号质量提出了更高的要求。然而, 实际采集的心电信号极易受到多种退化的影响, 包括工频干扰、肌电噪声、基线漂移、运动伪差以及因传感器接触不良或无线传输丢包引起的稀疏采样和导联缺失。这些退化现象会淹没或扭曲信号中具有诊断价值的细微形态学特征, 如 P 波、QRS 复合波和 T 波, 进而严重影响心律失常检测、心肌缺血识别和自主神经功能评估的准确性^[1]。因此, 研究如何从低质量、残缺的观测信号中高保真地重建干净的心电波形, 具有重要的临床价值和科学意义。

1.1.1 心电波形重建的临床需求

高质量的心电波形是临床决策的基石。在重症监护和动态心电图分析中, 持续性噪声或导联脱落常常导致长时间数据段不可读, 造成诊断信息的永久丢失。在院前急救和远程心电诊断中, 受限于简陋的采集环境和有限的传输带宽, 中心端接收到的信号往往信噪比极低。高保真重建技术能够最大程度地恢复这些被污染信号的本来形态, 使得医生能够观察到可靠的心律与波形细节, 避免误诊和漏诊。此外, 对于移动健康设备采集的单导联或稀疏导联信号, 重建技术还能补全多导联信息, 为家庭场景下的心脏健康管理提供更丰富的评估维度。

1.1.2 信号退化的挑战与重建难点

心电信号的重建面临若干固有难点。首先, 心电信号是非平稳的准周期信号, 其时频特性随生理状态和病理类型而变化, 要求重建模型具有强大的非线性映射能力和对形态变异的鲁棒性。其次, 实际中的退化形式往往是多种因素的混合, 例如同一段信号中可能同时存在高频噪声与整段导联缺失, 且退化强度动态变化, 这要求重建方法不能依赖单一的退化假设。第三, 临床可接受的“高保真”不仅要求数学误差小, 更要求恢复出的波形在医学形态学上是合理且可解释的, 避免生成出看起来光滑但病理特征错误的伪影。这些难点共同指向了对一种既能建模复杂信号分布、又能保持生成结果形态真实感的重建新方法的需求。

1.2 国内外研究现状

1.2.1 传统心电信号处理方法

早期的心电信号去噪与插值主要依赖于经典信号处理技术，包括基于无限脉冲响应（IIR）和有限脉冲响应（FIR）的数字滤波、自适应滤波、小波阈值去噪以及经验模态分解等。这些方法计算效率高，物理意义明确，在处理单一、平稳噪声时效果良好。然而，面对非平稳噪声混合和结构性缺失（如整段导联丢失）时，传统方法往往需要依赖较强的先验假设，且难以同时保留信号中的高频细节和低频形态，容易造成 QRS 波峰削低或低幅 P 波模糊。

1.2.2 基于深度学习的心电重建方法

近年来，深度学习模型在心电信号重建领域取得了显著进展。卷积神经网络（CNN）和循环神经网络（RNN）及其变体（如 LSTM）通过端到端的学习方式，直接从大量数据中习得干净信号与退化信号之间的复杂映射。相较于传统方法，基于学习的模型在抑制多类型噪声和填补短时缺失方面展现出优越的性能。作为深层生成模型，生成对抗网络（GAN）也被成功应用于心电信号的超分辨率重建和去噪，能够生成更符合数据分布的细节。然而，GAN 的训练不稳定性和模式坍塌问题，以及普通深度回归网络倾向于产生过于平滑的重建结果，仍然是制约其在高保真场景下应用的主要瓶颈。

1.2.3 扩散模型及其在信号处理中的应用

去噪扩散概率模型（Denoising Diffusion Probabilistic Model, DDPM）是近年来生成建模领域的突破性进展。其通过逐步向数据添加高斯噪声的正向过程，和从噪声中逐步去噪以生成样本的反向过程，展现出了优于 GAN 的生成多样性和训练稳定性。在图像生成、超分辨率、修复等领域取得成功后，扩散模型正被迅速拓展到音频、医学信号等一维时间序列的处理中。在生理信号处理领域，已有初步工作将扩散模型应用于脑电信号去噪和心电信号的生成，但其在心电波形高保真重建上的潜力尚未被充分挖掘，尤其是在融合多导联相关性和形态学先验的条件下，如何设计专用的条件扩散模型以实现严重退化的鲁棒重建，仍是一个开放且极具前景的研究方向。

1.3 本文主要研究内容与章节安排

针对现有方法在严重噪声和结构性缺失下难以同时实现高数值精度和高形态保真度的问题，本文研究并实现一种基于条件扩散模型的高保真心电图波形重建方法。主要研究内容包括：

- (1) 设计以退化心电信号为条件的扩散模型架构，通过将低质量输入或其深度特征作为条件变量，引导反向扩散过程生成与观测相一致的高质量波形。
- (2) 融合心电信号的导联相关性先验与多尺度特征提取机制，提升模型对 P 波、QRS 复合波、T 波等关键形态细节的恢复能力，并抑制伪影。
- (3) 在公开数据库（MIT-BIH 心律失常数据库和 PTB 诊断数据库）上，从均方根误差、相关系数、弗雷歇距离等多个维度，全面评估所提方法在不同噪声强度和缺失率下的重建性能，并与 CNN、GAN 等基线模型进行对比分析。

本文的创新点可概括为：将扩散模型的精细生成能力引入心电图波形重建任务，并特别设计了条件注入与多尺度特征融合策略，从而在挑战性退化场景下显著提升了重建波形的临床可接受度。

本论文的章节安排如下：第一章为绪论，概述研究背景、意义、国内外现状及本文工作；第二章介绍相关基础知识，包括心电信号特性、扩散模型原理和常用评价指标；第三章详细阐述本文提出的条件扩散模型设计与重建算法；第四章呈现实验设置、结果及讨论；第五章总结全文并展望未来工作。

第二章 相关背景知识介绍

本章介绍后续研究所需的基础知识和理论工具。首先概述心电信号的生理基础、波形特征及常见的信号退化模型；然后系统阐述去噪扩散概率模型的基本原理，包括正向与反向扩散过程、训练目标以及条件生成机制；最后给出用于评估重建性能的客观指标和本研究使用的标准心电数据库。

2.1 心电信号基础与信号退化

2.1.1 心电信号的产生与波形形态

心电图 (Electrocardiogram, ECG) 是心肌细胞电活动在体表的综合反映。一个典型的心搏周期由 P 波、QRS 复合波和 T 波等特征波构成，分别对应心房除极、心室除极和心室复极过程。临床上，医生通过分析各波的幅度、时限和形态，以及 PR 间期、QT 间期等，来判断心律失常、心肌缺血和传导阻滞等病变。标准临床心电图通常包含 12 个导联，分为肢体导联 (I、II、III、aVR、aVL、aVF) 和胸导联 (V1–V6)，它们从不同空间角度记录心脏电活动，为诊断提供互补信息。导联间的信号并非独立，而是遵循基尔霍夫定律等物理约束，例如肢体导联满足 $I + III = II$ 。

2.1.2 心电信号的噪声与退化

实际采集的心电信号常遭受多种退化的影响。主要噪声源包括：工频干扰（50/60 Hz 及其谐波）、肌电噪声（宽频、突发性）、基线漂移（由呼吸或电极-皮肤阻抗变化引起的低频干扰）和运动伪差（电极移动导致的短暂大幅度干扰）。此外，在可穿戴和远程监测场景中，还可能出现信号稀疏采样（因低功耗需求而降低采样率）或导联缺失（传感器脱落或数据传输丢包）。这些退化可以统一建模为：

$$\mathbf{y} = \mathcal{H}(\mathbf{x}) + \mathbf{n}, \quad (2.1)$$

其中 $\mathbf{x}$ 表示干净的心电信号， $\mathcal{H}(\cdot)$ 代表线性或非线性退化算子（如掩膜矩阵或低通滤波）， $\mathbf{n}$ 为加性噪声。高保真重建的目标就是从观测 $\mathbf{y}$ 中恢复出尽可能接近 $\mathbf{x}$ 的估计 $\hat{\mathbf{x}}$ 。

2.2 去噪扩散概率模型

去噪扩散概率模型 (Denoising Diffusion Probabilistic Model, DDPM) 是近年来在图像和信号生成领域表现优异的深度生成模型。其核心思想是学习一个马尔可夫链来逐步逆转一个

固定的前向扩散过程，从而将简单分布（如高斯噪声）转化为复杂的数据分布。在心电波形重建中，我们将退化信号作为条件，引导扩散模型生成干净的心电信号。

2.2.1 正向扩散过程

给定从真实数据分布中采样的干净信号 $\mathbf{x}_0 \sim q(\mathbf{x})$ ，正向扩散过程在 T 步内逐步向数据添加高斯噪声，生成一系列带噪版本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T$ ，其转移核定义为：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \quad (2.2)$$

其中 $\beta_t \in (0, 1)$ 为噪声调度系数。利用重参数化技巧，可以直接从 $\mathbf{x}_0$ 采样任意时间步 t 的带噪信号：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad (2.3)$$

这里 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ ， $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。随着 t 增大， $\bar{\alpha}_t$ 趋于 0， $\mathbf{x}_T$ 近似服从标准高斯分布。

2.2.2 反向扩散过程与训练

反向过程的目标是从 $\mathbf{x}_T$ 开始，逐步去噪生成干净信号。定义参数化的反向转移核：

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}), \quad (2.4)$$

其中 $\boldsymbol{\mu}_\theta(\cdot)$ 通常由一个神经网络（如 U-Net）预测。实践中，更常见的做法是训练网络直接预测噪声 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)$ ，并采用如下简化的均方误差损失函数：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\epsilon}, t} \left[\left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t) \right\|^2 \right]. \quad (2.5)$$

训练收敛后，可以通过迭代采样生成新的样本：从 $t = T$ 开始，每一步用预测的噪声计算 $\mathbf{x}_{t-1}$ ，直至得到 $\mathbf{x}_0$ 。

2.2.3 条件扩散模型

为了实现对退化的心电信号的重建，我们将观测信号 $\mathbf{y}$ 或其深度特征作为条件变量 $\mathbf{c}$ ，引导生成过程。此时反向过程变为 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{c})$ ，噪声预测网络也相应调整为 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t, \mathbf{c})$ 。条件注入可通过多种方式实现，例如在神经网络的特征层进行交叉注意力融合或简单拼接。训练损失函数扩展为：

$$\mathcal{L}_{\text{cond}} = \mathbb{E}_{\mathbf{x}_0, \mathbf{y}, \boldsymbol{\epsilon}, t} \left[\left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t, \mathcal{F}(\mathbf{y})) \right\|^2 \right], \quad (2.6)$$

其中 $\mathcal{F}(\cdot)$ 是条件编码器，用于从退化信号中提取多尺度条件特征。这一机制使扩散模型能够根据低质量输入的内容，生成形态一致且细节丰富的高保真波形。

2.3 评价指标与心电数据库

2.3.1 重建质量评价指标

为全面评估重建波形的质量，本研究从数值精度、形态相似性和医学相关性三个层面选取指标。数值精度指标包括均方根误差（Root Mean Square Error, RMSE）和皮尔逊相关系数（Pearson Correlation Coefficient, CC），其定义为：

$$\text{RMSE}(\mathbf{x}, \hat{\mathbf{x}}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2}, \quad (2.7)$$

$$\text{CC}(\mathbf{x}, \hat{\mathbf{x}}) = \frac{\sum_{i=1}^N (x_i - \bar{x})(\hat{x}_i - \bar{\hat{x}})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2 \sum_{i=1}^N (\hat{x}_i - \bar{\hat{x}})^2}}. \quad (2.8)$$

RMSE 越低、CC 越接近 1，表示重建越精确。为了衡量波形形态的保真度，我们引入弗雷歇距离（Fréchet Distance, FD），它度量两条曲线之间考虑时序顺序的相似性，特别适合评估心电波形的形态一致性。此外，信噪比改善程度、QRS 检出率等也被作为辅助指标。

2.3.2 标准心电数据库

本研究的实验基于两个国际公认的标准心电数据库：MIT-BIH 心律失常数据库和 PTB 诊断数据库。

- **MIT-BIH 心律失常数据库**：包含 48 条时长约 30 分钟的双导联动态心电图记录，采样率为 360 Hz，提供了专家逐搏标注的心律类型和节律信息，广泛用于心律失常检测和信号处理算法评估。
- **PTB 诊断数据库**：来自德国联邦物理技术研究院，包含 290 位受试者的 15 导联心电图，采样率为 1000 Hz，涵盖心肌梗死、心力衰竭等多种明确临床诊断，适合评估重建算法对病理细节的保持能力。

表2.1汇总了两个数据库的基本参数。

在模拟实验中，我们通过对干净信号注入不同强度的高斯白噪声、工频干扰，或随机掩膜置零来构造配对数据集，以定量评估重建性能。

表 2.1 使用的标准心电数据库概况

数据库名称	导联数	采样率 (Hz)	记录数	主要特点
MIT-BIH 心律失常	2	360	48 条	动态 ECG, 丰富心律失常标注
PTB 诊断	15	1000	290 例	高分辨率, 明确临床诊断

2.4 本章小结

本章梳理了心电信号的生理基础、波形特征和典型退化形式, 建立了统一的信号退化模型。随后深入介绍了去噪扩散概率模型的数学原理, 包括正向扩散、反向去噪和训练目标, 并扩展到以退化信号为条件的条件扩散框架, 为后续章节的方法设计奠定了理论基础。最后给出了心电波形重建任务的客观评价指标和标准数据库, 为实验部分的定量评估提供了依据。

第三章 基于条件扩散模型的高保真心电波形重建方法

本章详细阐述所提出的高保真心电图波形重建方法。首先给出问题形式化描述和整体网络架构，然后分别介绍条件扩散模型的构建、导联相关性与多尺度特征融合策略，以及训练与推理过程中的关键设计。

3.1 问题建模与总体框架

将心电波形重建任务定义为一个条件生成问题：给定退化的观测信号 $\mathbf{y}$ ，学习从高斯噪声逐步生成干净信号 $\hat{\mathbf{x}}$ 的条件扩散过程，总体框架由条件编码器、扩散去噪网络和条件引导机制三部分组成。

3.1.1 条件扩散模型的构建

反向扩散过程以退化信号为条件，通过将条件特征 $\mathbf{c} = \mathcal{F}(\mathbf{y})$ 注入噪声预测网络，使生成的波形在内容和形态上与观测保持一致。

3.1.2 网络结构设计

噪声预测网络采用一维卷积 U-Net 架构，包含下采样编码器、中间瓶颈层和上采样解码器，并通过跳跃连接保留细节信息，同时引入时间步嵌入和多尺度条件特征融合模块。

3.2 导联相关性与多尺度特征融合

为提升重建波形的生理合理性和形态精度，充分利用多导联心电信号间的物理相关性和不同时间尺度下的诊断特征。

3.2.1 导联相关性先验建模

通过跨导联注意力机制建模 12 导联之间的空间依赖，使模型在重建某一导联时能够参考其他导联的互补信息，减少形态畸变。

3.2.2 多尺度特征融合机制

在编码器中引入不同膨胀率的卷积核，捕获从 QRS 细波到整心搏慢变化的多尺度时序特征，并通过门控融合单元动态聚合，增强对 P 波、T 波等小波的重建能力。

3.3 训练策略与采样加速

设计合理的训练损失和高效的推理策略，以保证模型收敛和临床实用性。

3.3.1 联合训练与损失函数

除扩散噪声预测损失外，额外引入时域和频域的重建一致性损失，联合训练条件编码器和去噪网络，端到端优化整个重建流程。

3.3.2 推理阶段的加速采样

采用去噪扩散隐式模型（DDIM）的步长跳略策略，在仅使用约 50 步采样的条件下即可获得与全步长相当的重建质量，大幅降低推理时间。

3.4 本章小结

本章系统介绍了基于条件扩散模型的心电波形重建方法，从问题建模、网络设计、多导联多尺度融合到训练推理策略，为后续实验验证提供了完整的技术方案。

第四章 实验结果与分析

本章在标准心电数据库上对所提条件扩散模型重建方法进行系统实验评估，包括实验设置、与基线方法的定量与定性对比、以及消融和鲁棒性分析。

4.1 实验设置与数据准备

实验基于 MIT-BIH 心律失常数据库和 PTB 诊断数据库，按受试者划分训练集和测试集以评估泛化能力。

4.1.1 数据集划分与预处理

对所有记录进行统一重采样至 360 Hz，分割为 4 秒固定长度片段，并施加 Z-score 归一化，训练集和测试集的比例为 8:2。

4.1.2 退化模拟与评价指标

为模拟真实退化，对干净信号分别添加信噪比为 0~20 dB 的高斯噪声、50 Hz 工频干扰以及随机掩膜（缺失率 10%~50%），采用 RMSE、相关系数、弗雷歇距离和 QRS 检出率作为评价指标。

4.2 重建效果对比与分析

将所提方法与 Wiener 滤波、CNN 去噪自编码器、GAN 重建模型进行定量与定性对比。

4.2.1 定量结果对比

在各种退化条件下，条件扩散模型在 RMSE 和相关系数上均显著优于基线模型，尤其在低信噪比和高缺失率下优势更为明显。

4.2.2 可视化与形态学分析

可视化结果显示，扩散模型重建的波形不仅噪声去除彻底，而且 P 波、T 波等低幅细节形态清晰，避免了 CNN 过度平滑和 GAN 产生的伪影。

4.3 消融实验与鲁棒性分析

通过消融实验验证各模块的必要性，并在极端退化条件下测试模型鲁棒性。

4.3.1 模块消融实验

依次移除导联交叉注意力模块和多尺度特征融合模块后，重建性能均有下降，证明导联相关性与多尺度机制对形态恢复至关重要。

4.3.2 噪声强度与缺失率鲁棒性测试

在信噪比低至-5 dB 和缺失率达 70% 的极端条件下，模型仍能恢复出可辨认的心搏形态，表现出良好的鲁棒性和应用潜力。

4.4 本章小结

本章通过充分的实验验证了所提条件扩散模型在高保真心电重建任务上的有效性和优越性，消融实验进一步揭示了各设计模块的贡献，为实际应用提供了支撑。

第五章 总结与展望

本章对全文工作进行总结，归纳主要贡献与结论，并指出当前研究的局限性和未来可拓展的研究方向。

5.1 本文工作总结

本文围绕低质量心电信号的高保真重建问题，提出了一种基于条件扩散模型的生成式重建方法，并通过系统实验验证了其有效性。

5.1.1 主要工作内容

设计并实现了一个以退化心电信号为条件的扩散模型框架，融合导联相关性先验与多尺度特征融合机制，实现了对严重噪声和结构性缺失的鲁棒重建。

5.1.2 主要结论

在 MIT-BIH 和 PTB 数据库上的实验结果表明，所提方法在 RMSE、相关系数和弗雷歇距离等指标上均显著优于 CNN 和 GAN 等基线模型，且对极端退化条件具有良好的鲁棒性。

5.2 未来工作展望

尽管本文方法取得了较好效果，但在计算效率、跨领域泛化和临床部署方面仍有提升空间。

5.2.1 轻量化与实时推理

当前扩散模型采样步数较多，未来可探索模型蒸馏或更高效的采样策略，以满足可穿戴设备对低延迟和低功耗的实时处理需求。

5.2.2 跨模态与可解释性拓展

进一步引入患者元数据和临床诊断标签作为条件，并融合可解释人工智能技术，提升重建结果的临床可信度和辅助诊断价值。

5.3 本章小结

本文提出的条件扩散模型为心电波形高保真重建提供了新的有效途径，未来工作将聚焦于模型轻量化和临床场景的深度适配。

参考文献

- [1] Acharya U R, Oh S L, Hagiwara Y, et al. A deep convolutional neural network model to classify heartbeats [J/OL]. Computers in Biology and Medicine, 2017, 89: 389–396. <https://www.sciencedirect.com/science/article/pii/S0010482517302810>.

附录 A 程序清单

第三章条件扩散模型心电重建程序 (ECG_Diffusion programme 文件夹)

main_train.py: 条件扩散模型训练主函数, 支持多 GPU 分布式训练

main_sample.py: 推理采样与波形重建主函数, 可指定退化类型与强度

models/diffusion_unet.py: 一维扩散 U-Net 网络定义, 含时间步嵌入与条件注入模块

models/condition_encoder.py: 退化心电信号条件编码器, 提取多尺度引导特征

models/cross_lead_attention.py: 导联间交叉注意力模块, 建模多导联空间相关性

models/multi_scale_fusion.py: 多尺度特征门控融合模块, 增强 P 波、T 波等细节恢复

utils/data_dataset.py: MIT-BIH 与 PTB 数据库加载、分段、归一化及退化模拟子函数

utils/diffusion_utils.py: 扩散调度、噪声添加、DDPM/DDIM 采样等工具函数

losses/losses.py: 联合损失函数实现, 包含噪声预测损失与频域一致性损失

第四章实验评估与分析程序 (Evaluation programme 文件夹)

main_evaluate.py: 定量指标计算主函数, 输出 RMSE、相关系数、弗雷歇距离等

main_plot_figures.py: 绘制对比波形图、散点图与消融实验柱状图的主函数

baselines/wiener_filter.py: Wiener 滤波基线方法实现

baselines/cnn_denoiser.py: CNN 去噪自编码器基线模型

baselines/gan_reconstructor.py: GAN 重建基线模型

metrics/metrics.py: RMSE、CC、FD 及 QRS 检出率等指标计算子函数

utils/mask_generator.py: 随机掩膜与混合噪声退化场景生成子函数

第五章模型分析与轻量化测试程序 (Auxiliary programme 文件夹)

test_lightweight.py: 轻量化 DDIM 加速采样与推理耗时测试脚本

demo_real_noise.py: 真实噪声样本可视化演示脚本

export_onnx.py: 模型导出为 ONNX 格式以便部署的子函数

utils/explainability.py: 基于梯度归因的简单可解释性分析工具