

ECG-ATK-GAN: Robustness against Adversarial Attacks on ECGs using Conditional Generative Adversarial Networks

基于条件生成对抗网络的心电图对抗攻击鲁棒性研究

论文出处: <https://doi.org/10.48550/arXiv.2110.09983>

汇报人: 王晨旭



汇报提纲

01

背景知识与对抗攻击方法介绍

生成对抗网络基础、心电图对抗攻击原理及六种主流攻击方法

02

现有方法存在的问题

现有心律失常分类模型的安全隐患与局限性分析

03

模型架构与训练流程

ECG-ATK-GAN的整体框架、核心模块与多目标训练策略

04

实验设置与结果分析

数据集预处理、定量实验结果与定性评估

01

背景知识与对抗攻击方法介绍

生成对抗网络基础、心电图对抗攻击原理及六种主流攻击方法

生成对抗网络（GAN）简介

核心思想

GAN由两个相互竞争的神经网络组成——生成器（Generator）和判别器（Discriminator）。

条件GAN（CGAN）在本文中的角色



生成器

接收噪声、真实/被攻击的ECG信号以及类别标签作为输入，目的是合成逼真的、带有微小扰动的对抗性ECG信号。



判别器

不仅要区分信号是真实的还是生成器伪造的，还要承担分类任务（判别心律失常类别、判别信号是否被攻击）。

博弈过程

生成器努力生成能骗过判别器的攻击样本，判别器努力提高识别能力，两者在Min-Max博弈中共同进化，最终提升模型整体的分类鲁棒性。

心电图（ECG）对抗攻击简介

什么是对抗攻击？

在原始ECG信号中注入精心设计的微小扰动（肉眼难以察觉）。这些扰动表现为信号的分布外（out-of-distribution）偏移，导致深度学习模型产生错误分类。


为什么可怕？

⚠️ 导致误诊或错误的住院安排

🛡️ 可能引发患者数据隐私泄露

👤 可能被滥用于医疗保险欺诈

六种攻击下的攻击信号对比：红色是正常信号，蓝色是攻击信号：



六种主流对抗攻击方法详解（1/2） — 白盒攻击

白盒攻击（White-box Attack）：攻击者完全掌握网络架构、参数以及关于输入的梯度信息。

FGSM Fast Gradient Sign Method

一步攻击法。通过计算损失函数关于输入信号的梯度，沿着梯度方向添加扰动，从而使损失最大化，快速生成对抗样本。

PGD Projected Gradient Descent

最具决定性的一阶攻击。与BIM类似，但它的初始点是在感兴趣的 ϵ -球内随机选择的，并进行随机重启，寻找最强扰动。

BIM Basic Iterative Method

FGSM的迭代改进版。以较小的步长迭代更新FGSM攻击，并对中间结果的信号值进行裁剪，确保扰动始终在原始信号的 ϵ -邻域内（本文 $\epsilon=0.01$ ）。

CW Carlini-Wagner

基于优化的白盒攻击。利用线搜索来优化攻击目标，解决无界性问题。本文使用 L_∞ 范数版本，即对信号中每个点施加最大扰动（本文 $\epsilon=0.1$ ）。

FGSM:

$$x_{\text{adv}} = x + \epsilon \cdot \text{sign}(\nabla_x \mathcal{L}(x, y))$$

BIM:

$$x_{\text{adv}}^{(0)} = x, \quad x_{\text{adv}}^{(t+1)} = \text{Clip}_{x, \epsilon} \left\{ x_{\text{adv}}^{(t)} + \alpha \cdot \text{sign} \left(\nabla_x \mathcal{L}(x_{\text{adv}}^{(t)}, y) \right) \right\}$$

PGD:

$$x_{\text{adv}}^{(0)} = x + \mathcal{U}(-\epsilon, \epsilon), \quad x_{\text{adv}}^{(t+1)} = \Pi_{B_\infty(x, \epsilon)} \left(x_{\text{adv}}^{(t)} + \alpha \cdot \text{sign} \left(\nabla_x \mathcal{L}(x_{\text{adv}}^{(t)}, y) \right) \right)$$

CW:

$$\begin{aligned} & \min_{\delta} \|\delta\|_\infty + c \cdot f(x + \delta) \\ & \text{s.t. } x + \delta \in [0, 1], \quad f(x + \delta) \leq 0 \end{aligned}$$

六种主流对抗攻击方法详解（2/2） — 黑盒攻击

黑盒攻击（Black-box Attack）： 攻击者不知道模型的底层架构或参数，仅通过观察给定输入的预测输出（探测）来推测边界并污染数据。

5

DBB Decision-based Boundary Attack

基于决策的黑盒攻击。仅依赖模型的最终类别预测。从一个极大的对抗扰动开始，然后试图在保持对抗性（让模型分错）的同时，逐渐减小扰动。

6

HSJ Hop Skip Jump Attack

一种非常强大的高级黑盒攻击。它是边界攻击的升级版，能够通过估计输出决策边界的梯度方向来破坏数据，且需要的模型查询次数显著少于DBB。

白盒攻击 vs 黑盒攻击对比

对比维度	白盒攻击	黑盒攻击
攻击者知识	完全掌握网络架构、参数及梯度	仅知道输入输出关系
代表方法	FGSM, BIM, PGD, CW	DBB, HSJ

02

现有方法存在的问题

现有心律失常分类模型的安全隐患与局限性分析

现有心律失常分类模型的局限性

深度学习在ECG领域的现状

深度卷积神经网络（CNNs）已经成为常态，达到了接近人类水平的分类性能（如广泛应用于 Apple Watch, Medtronic 等设备）。

存在的安全隐患与缺陷

极度脆弱

现有的最先进系统（如常规的一维CNN分类器）对六种对抗攻击极其敏感。

缺乏针对性防御

当前的深度学习和基于GAN的分类器未被专门设计来利用目标函数识别和缓解对抗性攻击。

GAN防御不足

已有研究的生成网络和分类网络分离训练，不能在端到端学习过程中有效捕获异常信号。



本文动机


提出首个防御这六种不同对抗攻击的综合解决方案（ECG-ATK-GAN），利用新的损失函数和网络模块，同时实现高精度的分类与强悍的攻击防御。

03

模型架构与训练流程

ECG-ATK-GAN的整体框架、核心模块与多目标训练策略

ECG-ATK-GAN 整体模型思路




数据流向



核心创新: 将判别器改造为多任务学习器, 不仅做真假判别, 还同时输出攻击/非攻击分类和心律失常类型分类。

模型详细架构设计 — 五大核心模块



为提取微小扰动和类特征，网络设计了以下特定模块：

Residual Block 残差块 — 生成器用

包含小卷积核 ($k=3, s=1$)。残差跳跃连接保留了重要的特定信号信息，提取能外推小扰动的精细特征。

SDA Block 跳跃空洞注意力块 — 生成器用

使用空洞卷积 ($k=2, d=2, s=1$)。扩大感受野，使其能够覆盖对抗信号中更大范围的扰动区域。

Regular Block 常规块 — 判别器用

包含卷积 ($k=3, s=1$)、BatchNorm和Leaky-ReLU。专注于将信号编码为有意义的分类输出。

Downsampling Block 下采样块

用于特征提取和维度压缩，逐步降低信号的空间维度。

Upsampling Block 上采样块

包含转置卷积，用于生成器重建信号尺寸，恢复原始维度。

模型的判别器工作原理

判别器结构

包含 3个常规块（Regular blocks）和 3个下采样块（Downsampling blocks），逐步提取高层特征。

多任务输出与激活函数



GAN对抗训练任务

识别信号是否由生成器生成
输出使用 Sigmoid 激活



识别任务

区分信号是否被对抗攻击
输出使用 Softmax 激活




心律失常分类任务

对正常心跳和不同类型的心律失常进行分类
输出使用 Softmax 激活

设计优势

不仅学习正常的生理特征，还强制学习对抗样本中的分布外（out-of-distribution）偏移规律。



模型的生成器工作原理

判别器结构

包含残差块（Residual Block）、跳跃空洞注意力块、下采样块和上采样块，逐步提取扰动特征并重建信号。。

多任务输出与激活函数



GAN对抗训练任务

阻止判别器识别信号由生成器生成




专属损失函数（重建波形）

约束生成信号与真实信号之间的差异，确保合成信号逼真且具备微小扰动

设计优势

通过残差块和小卷积核提取微小扰动，利用空洞卷积扩大感受野捕捉大范围扰动，结合上采样重建信号，在MSE损失约束下合成既可欺骗判别器又保持临床真实性的ECG信号。



多目标训练流程与损失函数

1. L_{atk} 类别加权分类损失（区分是否被攻击）
用于区分被攻击和未被攻击的信号。给予被攻击信号稍高的权重（ $\kappa=[1, 1.05]$ ），强调严重扰动下的类特征。

3. L_{mse} 均方误差损失（重建波形）
约束生成器输出。确保合成信号包含对抗样本和正常特征，不会完全偏离原始信号，保证生成信号逼真且具备误导性。

2. L_{ary} 多分类交叉熵损失（区分类别）
用于正常心跳和特定心律失常类型的分类。

4. L_{adv} 最小二乘GAN对抗损失（区分是否由生成器生成）
使用 Least-squared GAN 稳定生成器和判别器的 min-max 博弈。

最终总目标函数（判别器最小化第一项、第二项、第四项，生成器最大化第四项，最小化第三项）

$$\min_{G,D_{ary},D_{atk}} \max_{D_{adv}} (\mathcal{L}_{adv}(D)) + \lambda_{mse} [\mathcal{L}_{mse}(G)] + \lambda_{atk} [\mathcal{L}_{atk}(D)] + \lambda_{ary} [\mathcal{L}_{ary}(D)]$$

超参数设置

$$\lambda_{atk} = 10, \lambda_{ary} = 10, \lambda_{mse} = 1$$

04

实验设置与结果分析

数据集预处理、定量实验结果与定性评估

实验数据集与预处理

使用的数据集



MIT-BIH 心律失常数据库


分为 N (正常等), S (房性早搏等), V (室性早搏等), F (融合心跳) 四大类。



PTB 诊断型 ECG 数据库

分为正常和心肌梗死两类。

预处理流程



六种对抗攻击方法配置

攻击类型	方法	参数设置	攻击者知识	特点
白盒攻击	FGSM, BIM, PGD, CW	$\epsilon = 0.01$ (FGSM/BIM/PGD), $\epsilon = 0.1$ (CW)	完全掌握模型	利用梯度信息生成对抗样本
黑盒攻击	DBB, HSJ	默认配置	仅知输入输出	通过查询估计决策边界

定量实验结果（1/2） — MIT-BIH数据集

Table 1: **MIT-BIH Dataset** : Comparison of architectures trained and evaluated on **non-attacked/attacked** ECGs for normal and three arrhythmia beat classification.

	Model	Accuracy	N		S		V		F	
			Sensitivity	Specificity	Sensitivity	Specificity	Sensitivity	Specificity	Sensitivity	Specificity
No Attack	Proposed Method	99.2	98.8	95.2	83.7	99.8	97.9	99.7	92.4	99.3
	Shaker et al. [30]	98.6	97.4	98.1	93.0	98.7	99.2	99.0	87.2	99.6
	Kachuee et al. [20]	98.1	96.8	94.5	88.7	97.6	92.5	99.6	90.4	99.3
	Acharya et al. [1]	96.4	92.8	96.2	86.2	97.0	95.9	98.8	94.2	97.1
FGSM	Proposed Method	98.7	97.9	95.0	82.6	99.2	99.2	98.7	73.2	99.8
	Shaker et al. [30]	92.6	84.7	93.3	81.8	89.9	96.5	95.6	57.9	98.7
	Kachuee et al. [20]	86.5	73.1	82.8	68.9	83.4	73.7	97.3	82.8	93.2
	Acharya et al. [1]	77.2	53.3	87.9	65.7	74.1	66.2	92.3	65.6	87.9
BIM	Proposed Method	98.1	97.1	91.2	76.1	98.6	95.0	99.4	84.1	98.9
	Shaker et al. [30]	96.2	93.1	90.1	69.1	98.2	97.6	94.9	55.4	99.8
	Kachuee et al. [20]	85.6	70.6	90.4	67.4	90.5	83.6	92.3	82.1	88.5
	Acharya et al. [1]	76.9	54.4	87.5	49.0	88.2	42.1	91.9	87.8	73.8
PGD	Proposed Method	98.4	97.0	96.1	89.0	98.0	97.5	99.3	88.5	99.6
	Shaker et al. [30]	96.5	93.4	92.8	81.3	97.9	94.5	98.2	82.8	97.4
	Kachuee et al. [20]	87.2	74.0	86.9	66.3	87.6	84.7	91.8	65.6	95.2
	Acharya et al. [1]	77.2	54.0	88.8	54.1	91.3	57.8	82.0	66.2	80.6
CW	Proposed Method	98.8	97.8	97.0	91.1	98.8	98.3	99.5	91.0	99.5
	Shaker et al. [30]	95.4	90.8	96.0	84.7	97.0	97.8	94.1	72.6	99.7
	Kachuee et al. [20]	91.9	84.5	83.3	74.4	89.3	79.7	99.3	61.1	96.3
	Acharya et al. [1]	81.2	61.8	89.1	64.6	81.5	67.7	94.1	83.4	86.8
DBB	Proposed Method	93.0	85.8	94.9	84.4	96.1	91.3	96.2	84.1	93.9
	Shaker et al. [30]	90.1	80.6	86.7	65.1	94.2	79.4	94.9	83.4	91.7
	Kachuee et al. [20]	79.7	57.9	86.4	78.0	69.3	70.9	96.6	82.1	93.6
	Acharya et al. [1]	81.9	62.6	85.8	68.1	75.6	77.0	95.8	82.8	92.7
HSJ	Proposed Method	71.9	44.8	68.2	34.6	78.6	35.7	82.6	32.4	83.8
	Shaker et al. [30]	70.5	41.2	67.4	33.0	77.1	40.4	81.1	37.5	83.4
	Kachuee et al. [20]	68.6	39.3	65.8	21.3	82.5	10.3	94.5	43.9	62.2
	Acharya et al. [1]	68.4	37.6	70.0	32.3	57.4	23.6	90.4	20.3	90.0

无攻击（No Attack）下：所有模型表现都很优秀，本模型准确率达 **99.2%**。

白盒与黑盒攻击下：其他现有模型的性能急剧下降，

而 ECG-ATK-GAN 展现出**极强的鲁棒性**。

少数类表现突出：在最难分类的融合心跳（F类）上，

本模型在PGD、CW和DBB攻击下的敏感度位居第一。

特例分析（HSJ攻击）：本模型在HSJ攻击下

表现相比于其他几种攻击准确率较弱（但仍优于部分模型），

原因是HSJ攻击引入了过高的高频噪声，破坏了信号的清晰模式。

定量实验结果（2/2） — PTB数据集

	Methods	No Attack	FGSM	BIM	PGD	CW	DBB	HSJ
Accuracy	Proposed Method	99.5	99.4	99.6	99.6	99.5	93.1	71.8
	Shaker et al. [30]	98.0	98.6	95.8	96.4	98.3	91.4	70.2
	Kachuee et al. [20]	95.2	97.1	94.4	92.2	91.3	88.6	56.5
	Acharya et al. [1]	79.8	84.1	83.2	84.1	80.9	77.4	54.7
Sensitivity	Proposed Method	99.3	99.2	99.6	99.7	99.2	92.6	79.8
	Shaker et al. [30]	96.7	98.3	92.1	94.8	98.0	91.5	83.7
	Kachuee et al. [20]	98.3	96.0	95.9	92.1	95.4	86.7	85.5
	Acharya et al. [1]	82.1	93.1	93.4	90.6	90.3	88.5	90.7
Specificity	Proposed Method	99.7	99.5	99.7	99.5	99.7	93.7	64.0
	Shaker et al. [30]	99.3	98.9	99.4	98.0	98.7	91.2	56.8
	Kachuee et al. [20]	92.1	98.2	93.0	92.2	87.3	90.3	28.1
	Acharya et al. [1]	77.7	75.3	73.2	77.8	71.6	66.5	19.4

结果分析

PTB数据集进一步验证了模型的泛化能力。

在 FGSM (**99.4%**)，BIM (**99.6%**)，PGD (**99.6%**)，CW (**99.5%**) 以及黑盒攻击 DBB (**93.1%**) 下，本模型的 Accuracy、Sensitivity 和 Specificity 几乎全面领先对比基线模型。

证明了我们的架构将**类加权目标函数**（捕捉分布外信号）与**条件GAN**结合的设计，在保护真实临床级严重疾病（如心梗）诊断免受扰动方面是极其有效的。

定性评估：生成器合成信号的相似度性能

	MITBIH				PTB			
	Mean-Squared-Error	Structural Similarity	Cross-corelation Coefficiet	Normalized RMSE	Mean-Squared-Error	Structural Similarity	Cross-corelation Coefficient	Normalized RMSE
No Attack	0.0129	99.90	99.86	3.487e-5	0.0184	99.87	99.93	8.152e-5
FGSM	0.0117	99.81	99.89	2.890e-5	0.0001	99.84	99.89	0.02391
BIM	0.0134	99.80	99.86	3.737e-5	0.0155	99.91	99.95	5.769e-5
PGD	0.0122	99.84	99.89	3.115e-5	0.0179	99.88	99.92	7.722e-5
CW	0.0065	99.95	99.97	9.038e-6	0.0188	99.87	99.92	8.498e-5
DBB	0.0002	99.00	99.39	0.03159	0.0007	99.19	99.29	0.05532
HSJ	0.0003	99.42	99.45	0.0393	0.0003	99.51	99.60	0.03872

生成信号质量评估

为了证明生成器合成的对抗/非对抗ECG信号具有临床现实意义，论文使用了结构相似性(SSIM)、互相关系数和均方误差(MSE)进行评估。

99.00% – 99.95%

MIT-BIH 上 SSIM 分数范围

> 99.19%

PTB 数据集上 SSIM 分数

极低

MSE 和 NRMSE 误差水平

结论：误差极小，证明生成器能够合成极为逼真的、带有细微扰动特征的信号，从而为判别器提供了高质量的训练资料，最终促成了整个分类模型的高鲁棒性。

总结与展望

研究贡献

1. 提出了首个利用条件生成对抗网络（ECG-ATK-GAN）专门防御心电信号六大对抗攻击的模型。
2. 设计了包含小核残差块和空洞卷积的特殊网络结构，有效捕捉微小且分布外的扰动。
3. 引入了类加权目标分类损失，提升了在严重扰动下的类特定特征识别能力。

未来展望

改进架构以防御更多新型的对抗攻击

应用于实时智能穿戴和医疗诊断系统，防止医疗误诊和保险欺诈

感谢聆听

Thank you for your attention