

单位代码： 10293 密 级：

南京邮电大学

专业学位硕士学位论文



论文题目： 超越生成：一种面向 AI 生成图像检测的
扩散式低层特征提取器

学 号	1025040907
姓 名	黄思萌
导 师	吴礼发
专业学位类别	工程硕士
类 型	全日制
专业（领域）	网络空间安全
论文提交日期	2026.06.12

摘要

AI 生成图像的盛行，引发了人们对图像生成技术可能被滥用的担忧。为此，大量检测方法旨在通过分析生成伪迹来识别 AI 生成图像。然而，随着生成模型的发展，大多数检测方法很快就会过时。本文首先设计了一种低层特征提取器，将空间域图像映射到特征空间，在该空间中，不同来源的图像呈现出不同的分布特征。该特征提取器的预训练任务是区分仅在像素级别上有所不同的图像。该图像集包括原始图像，以及经过不同强度噪声扰动后使用预训练的扩散模型进行去噪所得到的版本。我们将扩散模型用作去噪工具而非图像生成工具。然后，我们将 AI 生成图像检测任务建模为单分类任务。我们对真实摄影图像的低层内在特征分布进行估计，并将偏离该分布的特征视为 AI 生成图像的判别依据。我们在超过 20 种不同的生成模型上对我们的方法进行了评估，其中包括 GenImage 和 DRCT-2M 数据集中的相关模型。大量实验表明，该方法不仅对扩散模型生成的图像有效，而且对于生成式对抗网络（GAN）、流模型及其变体生成的图像同样具有良好的检测效果。

关键词：伪造图像检测，扩散模型，高斯混合模型，异常检测

Abstract

The prevalence of AI-generated images has evoked concerns regarding the potential misuse of image generation technologies. In response, numerous detection methods aim to identify AI-generated images by analyzing generative artifacts. Unfortunately, most detectors quickly become obsolete with the development of generative models. In this paper, we first design a low-level feature extractor that transforms spatial images into feature space, where different source images exhibit distinct distributions. The pretext task for the feature extractor is to distinguish between images that differ only at the pixel level. This image set comprises the original image as well as versions that have been subjected to varying levels of noise and subsequently denoised using a pre-trained diffusion model. We employ the diffusion model as a denoising tool rather than an image generation tool. Then, we frame the AI-generated image detection task as a one-class classification. We estimate the low-level intrinsic feature distribution of real photographic images and identify features that deviate from this distribution as indicators of AI-generated images. We evaluate our method against over 20 different generative models, including those in GenImage and DRCT-2M datasets. Extensive experiments demonstrate its effectiveness on AI-generated images produced not only by diffusion models but also by GANs, flow-based models, and their variants.

Key Words: Deepfake Detection, Diffusion, Gaussian Mixture Model, anomaly detection

目 录

摘要	I
Abstract	II
插图索引	IV
表格索引	V
第一章 绪论	1
第二章 相关工作	3
第三章 方法	5
3.1 动机	5
3.2 预训练任务设计	5
3.3 AI 生成图像检测	7
第四章 实验结果	9
4.1 实验设置	9
4.2 AI 生成图像检测评估	9
4.3 消融实验	13
第五章 结论	15
参考文献	16

插图索引

图 2.1 通过 t-SNE ^[1] 进行特征分布可视化。本文使用四种图像来源，包括真实摄影图像以及由 Midjourney ^[2] 、GLIDE ^[3] 和 SDv1.5 ^[4] 生成的图像。本文提出的低层特征提取器将空间域图像映射至具有良好区分性的特征空间，并反映不同图像来源之间的差异。	4
图 3.1 预训练任务示意图。首先，我们引入噪声对原始图像进行扰动；随后，对受扰动图像进行去噪，从而生成一组与原始图像仅在像素级别上存在差异的图像。	6
图 4.1 AI 生成图像与摄影图像之间的似然分数分布。为增强可视化效果，将低于 -6000 的似然分数统一截断显示。	11
图 4.2 本文方法与 DRCT 的鲁棒性对比。实验采用 GenImage 中八种生成模型的平均检测准确率作为评价指标。	12
图 4.3 预训练任务与 AI 生成图像检测之间的关系。	13

表格索引

表 4.1 本文方法与基准方法在 GenImage 数据集上的检测准确率对比。Ours-ft 表示在 GenImage 训练集上微调后的预训练特征提取器，Ours-basic 表示未经微调的预训练特征提取器，Ours-m 和 DRCT-m 表示跨数据库场景。	10
表 4.2 本文方法与基准方法在 DRCT-2M 数据集上的检测准确率对比。Ours-ft 能够以 100% 的召回率识别 DRCT-2M 前十个子集中的所有扩散生成图像。DRCT-2M 中的真实图像与 MSCOCO 中的摄影图像相同，因此检测准确率均为 97.13%。	11
表 4.3 其他生成模型上的检测性能（召回率）。具体阈值为 -621.73 。97-P 和 75-P 分别表示测试集中排名前 97% 和前 75% 的似然分数。	13
表 4.4 预训练任务的消融研究。“w/o Reg” 和 “w/o Cls” 分别表示移除回归学习和分类学习。	13

第一章 绪论

在过去的几年里,图像生成技术发展迅速。大量生成式模型相继被提出,如自回归模型^[5]、变分自编码器^[6]、归一化流模型^[7]、生成式对抗网络 (GAN)^[8,9] 以及扩散模型^[10-12]。特别是扩散模型将图像生成带入了一个新时代。借助扩散技术的商业 API,例如 Midjourney^[2] 等,非专业用户也能轻松获取高质量的 AI 生成图像和内容编辑服务。尽管图像生成技术的发展显著提升了生产效率,但其广泛应用也引发了人们对于诸如传播虚假信息等恶意用途的担忧。因此,为了维护可信的网络空间环境,开发 AI 生成图像检测方法至关重要。

近年来,出现了大量用于识别 AI 生成图像的检测方法^[13-18]。现有方法通常将 AI 生成图像检测视为二分类问题。其训练集通常由真实照片和一种生成模型(例如 ProGAN^[9])组成。随后,这些方法在多种未见过的生成模型上评估其性能。由于生成模型的类型及其变体数量众多,无法全部包含在有限的训练集中,因此泛化能力是检测器的首要要求。为提高模型泛化能力,大多数研究致力于提取一种真实摄影图像中不具备而存在于不同生成模型中的通用伪迹。例如, LGrad^[19] 利用由预训练分类模型生成的图像梯度图作为生成模型的通用指纹。随后针对梯度图而非空间域图像进行二分类。然而,随着生成模型的发展,生成伪迹也随之发生显著变化。在扩散模型的时代,大多数检测器^[16,19] 难以识别那些高质量的 AI 生成图像。因此,许多研究^[13,15,17] 开始探究扩散模型的内在机制,并提取专门针对扩散生成图像的生成伪迹。

在本文中,我们将 AI 生成图像检测视为单分类任务(即异常检测)^[20,21],而非二分类范式。由于生成模型会随着图像生成技术的发展而不断演进,因此基于生成伪迹识别 AI 生成图像并不合适。具体而言,我们通过一种新设计的低层图像特征提取器,着重于提取真实摄影图像的低层内在特征。那些特征偏离真实图像分布的图像可被视为 AI 生成图像。本文方法的核心是一个预训练的低层图像特征提取器,它能够将空间域图像映射至低维特征空间中。在该空间中,来自不同来源的图像,例如不同生成模型生成的图像和真实摄影图像,呈现出不同的分布。在计算机视觉领域,许多研究聚焦于视觉内容的理解,例如广为人知的 CLIP^[22] 是基于大规模图像文本对进行训练得到的。这些特征提取器旨在表征语义信息等高级图像特征。然而,随着生成模型的发展,AI 生成图像的高层图像特征已与摄影图像非常接近。像噪声模式^[23] 这样人类难以察觉的低层特征,在图像取证中发挥关键作用。Zheng 等人^[24] 和 Huh 等人^[25] 利用相机元数据(EXIF 标签)来监督特征提取器学习低层图像特征。然而,大多数摄影图像缺乏相机元数据,并且这些元数据可能会在后期处理中被删除。因此,我们没有采用 EXIF 标签监督,而是为低层图像特征提取器设计了一种新的预训练任务。给定一张摄影图像,我们首先施加不同强度的噪声,从而获得多张受扰动图像。随后,我们采用去噪模块恢复这些受扰动图像。在此阶段,预训练的扩散模型被用作去噪工具,而非图像生成工具。特

征提取器的主要任务是区分原始摄影图像和去噪后的图像，而这两者仅在像素层面存在差异。本文主要贡献如下：

- 我们设计了一种新的预训练任务，并构建了一个低层图像特征提取器，能够区分不同来源图像之间的差异。
- 我们从真实摄影图像的低层特征角度出发，将 AI 生成图像检测视为单分类任务。
- 大量实验表明，我们的方法对于多种生成模型均有良好的检测效果，包括 GAN、扩散模型、流模型及其变体。

第二章 相关工作

生成模型。图像生成技术在过去几年中取得了迅速进展。由 Ho 等人^[12]提出的去噪扩散概率模型已成为图像生成领域的前沿方法。扩散模型^[26]利用随机微分方程 (SDE) 描述这样的一个过程：通过逐步添加少量高斯噪声，将真实摄影图像转化为噪声图像。在生成阶段，这类模型利用逆向 SDE 从随机噪声中合成图像。ADM^[10]是首个在 ImageNet^[27]数据集上实现合成图像质量优于 GAN 的模型，是基于扩散模型的图像生成技术发展中的一个重要里程碑。在后续研究中，许多研究聚焦于采样效率^[28]、网络架构^[29]和可控性^[30]等方面。潜空间扩散模型^[4]显著提升了扩散模型生成高分辨率合成图像的能力。它们还通过交叉注意力机制促进了文本条件输入的整合。被广泛使用的开源模型 Stable Diffusion^[4]推动了 AI 生成图像在社交媒体平台上迅速传播。非专业用户也可以通过 Midjourney^[2]等商业 API，利用任意提示词获得高质量 AI 生成图像。

AI 生成图像检测。在早期的研究中，许多研究者专注于人工构造特征的设计，包括图像中的统计异常^[31]、视觉伪迹^[32]以及物理和几何不一致性^[33]。随后，研究重点转向基于卷积神经网络 (CNN) 的端到端学习，逐步摆脱启发式特征设计。Wang 等人^[16]采用一些简单的数据增强方法，如 JPEG 压缩和高斯模糊，以提高分类器的泛化能力。Frank 等人^[34]发现生成模型会在频域中留下显著异常，并据此从频域角度识别 AI 生成图像。现有的大多数方法都致力于寻找跨生成模型的通用生成伪迹。例如，LGrad^[19]将图像相对于预训练分类模型的梯度图作为 AI 生成图像的指纹。LNP^[35]则提取高频噪声作为通用指纹。随着扩散生成模型的兴起，许多检测方法难以识别高视觉质量的生成图像。因此，一些针对扩散模型生成图像的检测方法相继被提出。这些方法利用了扩散模型的固有特性。DIRE^[17]提取图像在预训练扩散模型上的重建误差，作为扩散模型生成图像的伪迹。然后，它们对重建误差图而非原始图像进行二分类。DRCT^[36]将由预训练扩散模型重建得到的真实摄影图像视为困难样本，通过关注困难样本分类来增强检测器对扩散模型生成图像的泛化能力。

与以往依赖生成模型伪迹来识别 AI 生成图像的方法不同，本文利用新提出的低层特征提取器提取真实摄影图像的内在特征。我们对摄影图像特征的分布进行建模，并将 AI 生成图像检测视为一种异常检测任务。那些低层特征与摄影图像特征分布不一致的图像将被标记为 AI 生成图像。



图 2.1 通过 t-SNE^[1] 进行特征分布可视化。本文使用四种图像来源，包括真实摄影图像以及由 Midjourney^[2]、GLIDE^[3] 和 SDv1.5^[4] 生成的图像。本文提出的低层特征提取器将空间域图像映射至具有良好区分性的特征空间，并反映不同图像来源之间的差异。

第三章 方法

3.1 动机

用于图像视觉理解的大型预训练模型，例如 CLIP^[22] 的图像编码器，已成为计算机视觉领域的现成工具。许多与图像语义信息密切相关的下游任务^[37] 都从这些预训练骨干模型中获益匪浅。Ojha 等人^[38] 首次将 CLIP 的图像编码器作为检测器的骨干模型，用于识别 AI 生成图像。然而，CLIP 主要关注图像的高级特征，如视觉内容。随着 AI 生成图像质量的提高，仅基于视觉内容来区分它们与真实照片变得越来越困难。因此，本文专注于分析那些通常人眼难以察觉的低层图像特征。由于上采样卷积层的固有特性，可能会导致频谱混叠效应^[39]，生成模型往往难以模仿摄影图像的低层特征。

在本文中，我们旨在设计一种用于理解低层图像特征的基础骨干网络。该低层特征提取器应当能够区分两张仅存在像素级差异，而在人眼看来几乎完全相同的图像。为实现这一目标，本文设计了一种新颖的预训练任务，引导特征提取器关注像素级差异。给定一张原始摄影图像，我们通过施加不同强度的噪声生成多个受扰动变体。随后，我们使用预训练的去噪工具来恢复这些受扰动图像。直观来看，去噪图像的内容在视觉上与原始图像非常相似，但像素级差异可能仍然存在。低层图像特征提取器的预训练任务是计算具体的像素级差异和噪声强度。图 1 展示了本文的低层图像特征提取器与著名的 CLIP 在常见生成模型和真实摄影图像上的特征可视化对比。我们发现，来自同一生成模型的特征分布更加集中，并且与其他模型及摄影图像的特征明显区分开来。这一观察结果表明，预训练的低层特征提取器可用作识别 AI 生成图像的骨干网络。

3.2 预训练任务设计

图 2 展示了本文预训练任务的基本思想。我们方法的核心在于构建一个图像集合，其中包括真实摄影图像以及若干去噪图像。去噪后的图像与对应的原始真实图像极为相似，仅在像素层面有所差异。我们将真实摄影图像记作 x_0 ，将噪声图像记作 x_t 。如图 2 所示，我们首先向 x_0 添加不同强度的噪声。加噪过程可以表示为：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon. \quad (3.1)$$

其中， $\epsilon \sim \mathcal{N}(0, I)$ ， $\bar{\alpha}_t$ 控制噪声强度。此过程与扩散模型相同，其中 $\bar{\alpha}_t$ 的取值在 0 到 1 之间。随着 t 的增加， $\bar{\alpha}_t$ 的值趋近于 0。我们选择不同的 t 以获取不同的噪声图像 x_t 。随后，我们将这些受扰动图像 x_t 恢复为干净图像 x_0 。我们利用一个预训练扩散模型对受扰动图像

进行去噪。换言之，我们将预训练扩散模型作为一个即插即用的去噪模块，用于恢复包含噪声的图像 x_t 。具体来说，我们采用一个预训练的去噪 U-Net 网络 $\epsilon_\theta(x_t, t)$ ，以预测时间步 t 下的噪声 ϵ 。扩散模型的去噪过程是迭代的。在时间步 $t - 1$ 时的去噪图像可以表示为：

$$x_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \left(\frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}} \right) + \sqrt{1 - \bar{\alpha}_{t-1}} \epsilon_\theta(x_t, t). \quad (3.2)$$

该反向扩散过程由 DDIM^[40] 提出。通过迭代噪声估计与更新，最终可以获得去噪后的图像。首先，我们通过控制 $\bar{\alpha}_t$ 向原始图像添加不同程度的噪声。 t 越大，初始噪声水平越高，对原始图像的扰动越大。我们将最终得到的去噪图像记作 x_t^{rec} 。直观上，随着 t 增大，噪声强度也随之上升， x_0 与 x_t^{rec} 之间的差异也随之增大。低层特征提取器的核心预训练任务是区分原始图像与其对应的、在不同噪声强度下生成的去噪图像 x_t^{rec} 。在实际应用中，去噪模块应当具有足够强的性能，以尽可能将受扰动图像恢复至接近原始图像的状态，从而确保二者之间仅存在细微的像素级差异。我们考察了计算机视觉领域中的多种去噪工具，发现预训练的 Stable Diffusion^[4] 是一个合适的去噪模块。 $\bar{\alpha}_t$ 的调度策略同样基于 Stable Diffusion。由于 Stable Diffusion 在潜空间中训练，我们通过预训练的 VAE^[11] 在潜空间中对图像施加高斯噪声，并通过扩散过程进行恢复。在 Stable Diffusion 中，共考虑了 1000 个噪声强度等级，对应于从 1 到 1000 的 t 。我们的方法选取 T 个不同的噪声强度，并用 τ 表示所选时间步 t 的子集。




图 3.1 预训练任务示意图。首先，我们引入噪声对原始图像进行扰动；随后，对受扰动图像进行去噪，从而生成一组与原始图像仅在像素级别上存在差异的图像。

特征提取器的训练目标由两个部分组成。首先，我们使用平均绝对误差计算原始图像与不同去噪图像之间的距离。此外，我们还考虑自编码器的重建误差，即在不添加噪声的情况下，将原始图像编码为潜特征，再将其解码回空间域。VAE 重建会在最终合成图像上留下伪迹，使其与原始图像在像素级别上存在细微差异。我们采用回归学习训练特征提取器，其形式可以表示为：

$$\mathcal{L}_{\text{regression}} = \left\| g(f(x; \theta); \phi) - t_{\text{MAE}}(x) \right\|. \quad (3.3)$$

其中, $f(\cdot; \theta)$ 和 $g(\cdot; \phi)$ 分别表示特征提取器和回归头, 回归头由一个简单的全连接层构成。 $t_{\text{MAE}}(\cdot)$ 表示图像 x 与其对应原始图像之间的平均绝对误差。

除了回归学习, 我们还为特征提取器设计了一个分类任务。我们将不同 t 对应的噪声强度作为相应图像的分类标签。类别数量等于子集 τ 的长度加 2, 额外的两个类别分别对应原始图像和 VAE 重建图像。对于分类任务, 我们采用带有 Softmax 激活函数的交叉熵损失

3.3 AI 生成图像检测

预训练的低层特征提取器能够辨别两张图像之间细微的像素级差异, 这对于部分图像取证任务至关重要。在本小节中, 我们将低层图像特征提取器进一步用于 AI 生成图像检测。如图 2.1 所示, 来自不同来源的图像, 包括真实摄影图像和由不同模型生成的图像, 其特征表示呈现出聚类现象。由同一模型生成的图像特征分布更为集中, 而来自不同生成模型的图像, 其特征分布则具有较大的差异。

因此, 我们采用高斯混合模型 (Gaussian Mixture Model, GMM)^[41] 对真实摄影图像的特征分布进行建模。GMM 是一种直观的概率模型, 在聚类和密度估计等多个领域得到了广泛应用。GMM 可以表示为:

$$p_{\text{GMM}}(f | \lambda) = \sum_{k=1}^K \omega_k \mathcal{N}(f | \mu_k, \Sigma_k), \quad (3.4)$$

其中, f 表示低层特征, ω_k 表示第 k 个高斯分量的权重, μ_k 和 Σ_k 分别表示第 k 个高斯分量的均值与协方差。所有可学习参数 ω_k 、 μ_k 和 Σ_k 统一记为 λ 。我们采用期望最大化算法^[42] 优化可学习参数 λ 。

在检测阶段, 我们首先提取待测图像的低层特征 f , 并计算其相对于预训练高斯混合模型 M 的对数似然分数:

$$s(f) = \log p_{\text{GMM}}(f | M), \quad (3.5)$$

该分数简称为似然值。模型 M 基于真实摄影图像的特征表示进行训练。如果待测图像为真实摄影图像, 其相对于 M 的似然值通常较高; 反之, 如果待测图像为 AI 生成图像, 其似然值通常显著偏低。

因此, 我们可以设置一个合适的阈值 γ , 将真实摄影图像与 AI 生成图像区分开来:

$$\hat{y} = \begin{cases} \text{真实摄影图像}, & s(f) \geq \gamma, \\ \text{AI 生成图像}, & s(f) < \gamma. \end{cases} \quad (3.6)$$

阈值 γ 根据真实摄影图像训练集的似然值确定。为了保持较低的误报率, 该阈值应低于

大多数真实摄影图像的似然值。

第四章 实验结果

4.1 实验设置

数据集。为了训练低层图像特征提取器,我们从 YFCC100M^[43] 数据集中随机选取了 12,000 张真实摄影图像。对于 AI 生成图像检测评估,我们采用两个常用数据集,即 GenImage^[44] 和 DRCT-2M^[36]。GenImage 包含八种生成模型,其中包括 Midjourney 等商业 API。GenImage 中的真实图像来源于 ImageNet^[27]。DRCT-2M 收集了 16 种扩散模型生成的图像,可分为两类:一类由十种 Stable Diffusion 模型及其多种变体生成,另一类由扩散模型驱动的图像到图像模型^[45]生成。DRCT-2M 中的真实图像来源于 MSCOCO 数据集^[46]。

噪声强度 $\bar{\alpha}_t$ 的选择。在 Stable Diffusion v1.4^[4] 的训练阶段,使用了 1,000 个不同级别的噪声强度 $\bar{\alpha}_t$ 。在生成阶段,许多研究使用 DDIM 调度器^[40]将采样过程加速至仅需少量步骤即可完成。在本文方法中,我们将采样步数设置为 50 步。对于每张摄影图像,我们添加 9 个不同级别的噪声,分别对应 $\bar{\alpha}_1$ 至 $\bar{\alpha}_9$ 。例如,对于 $\bar{\alpha}_5$, DDIM 调度器需要 5 步来恢复图像。除去噪图像外,我们还将未经加噪、仅由 VAE 模块重建得到的图像作为一个单独类别。总体而言,特征提取器包含 11 个类别,其中原始摄影图像也作为一个类别。

实现细节。低层特征提取器的网络架构基于类似 ViT 的模型^[47]。由于本文的主要贡献在于预训练任务的设计,网络架构的详细规格见补充材料。在特征提取器的训练阶段,我们使用 Adam 优化器,并将学习率固定为 10^{-5} 。对于分布建模,我们采用 scikit-learn 工具箱实现高斯混合模型,并将高斯分量数量设置为 6。我们使用 10,000 张真实摄影图像估计低层特征分布。随后,将图像的似然分数按降序排列,并设置阈值以判断待测图像是否属于摄影图像。该阈值取训练样本按降序排列后第 99.95 百分位位置对应的似然分数。

基准方法。我们选取了 12 种具有代表性的方法作为基准,包括 CNNSpot^[16]、F3Net^[48]、CLIP/RN50^[22]、GramNet^[49]、De-fake^[50]、Conv-B^[51]、UnivFD^[38]、DIRE^[17]、LNP^[35]、LGrad^[19]、NPR^[52] 和 DRCT^[36]。其中, DIRE 和 DRCT 需要使用预训练扩散模型进行 AI 生成图像检测。我们令这两种方法使用 Stable Diffusion v1.4, 以与本文方法保持一致。实验采用准确率作为检测性能的评价指标。

4.2 AI 生成图像检测评估

在 GenImage 数据集上的比较。我们首先在 GenImage 数据集上评估本文方法和各基准方法。所有基准方法均在 GenImage 的 SDv1.4 子集上进行训练。本文方法仅需使用真实摄影图像对其低层特征分布进行建模,无需访问训练集中的 AI 生成图像。

进一步地，我们以预训练特征提取器作为参数初始化，并在 GenImage 的 SDv1.4 子集上对其进行微调。随后，分别基于原始预训练特征提取器和微调后的特征提取器建立低层特征分布模型。对于每幅待测图像，我们分别计算其特征在两个模型下的似然值。当至少一个似然值低于相应阈值时，将该图像判定为 AI 生成图像。本文将这两种设置分别记为 Ours-basic 和 Ours-ft，具体实验结果见表 4.1。

本文方法明显优于所有基准方法。所有方法在 SDv1.4 和 SDv1.5 生成图像上均取得了较高的准确率，这是因为这些图像与训练集中的图像较为接近。然而，大多数基准方法在识别 BigGAN 生成图像时表现不佳。BigGAN 生成图像的伪迹与训练集中扩散模型生成图像的伪迹存在显著差异，导致检测器性能急剧下降。

相比之下，本文方法侧重于真实摄影图像的低层特征，并采用异常检测而非二分类的检测范式。尽管合成图像由不同生成模型生成，但其低层特征分布均不同于摄影图像的特征分布，这解释了本文方法优越的泛化能力。此外，我们发现，对预训练特征提取器进行微调并未带来性能提升。我们推测，特征提取器在 GenImage 上的检测准确率已经趋于饱和，因此微调无法进一步改善最终性能。

表 4.1 本文方法与基准方法在 GenImage 数据集上的检测准确率对比。Ours-ft 表示在 GenImage 训练集上微调后的预训练特征提取器，Ours-basic 表示未经微调的预训练特征提取器，Ours-m 和 DRCT-m 表示跨数据库场景。

Method	Midjourney	SDv1.4	SDv1.5	ADM	Glide	Wukong	VQDM	BigGAN	Avg.
CNNSpot	84.92	99.88	99.76	53.48	53.80	99.68	55.50	49.93	74.62
F3Net	77.85	98.99	99.08	51.20	54.87	97.92	58.99	49.21	73.51
CLIP/RN50	83.30	99.97	99.89	54.55	57.37	99.52	57.90	50.00	75.31
GramNet	73.68	98.85	98.79	51.52	55.38	95.38	55.15	49.41	72.27
De-fake	79.88	98.65	98.62	71.57	78.05	98.42	78.31	74.37	84.73
Conv-B	83.55	99.99	99.92	51.75	56.27	99.92	58.41	50.00	74.98
UnivFD	91.46	96.41	96.14	58.07	73.40	94.53	67.83	57.72	79.45
DIRE	50.40	99.99	99.92	52.32	67.23	99.98	50.10	49.99	71.24
LNP	60.30	99.72	99.64	49.86	49.88	99.52	49.85	49.88	69.80
LGrad	84.40	99.21	99.09	59.23	83.86	98.19	57.23	61.63	80.40
NPR	80.94	99.70	99.51	60.27	77.00	98.41	54.53	63.03	79.20
DRCT	91.50	95.01	94.41	79.42	89.18	94.67	90.03	81.67	89.49
Ours-basic	95.51	96.06	96.33	95.88	96.00	96.36	95.95	95.71	95.97
Ours-ft	95.03	95.32	95.53	95.29	95.17	95.58	95.10	95.15	95.27
DRCT-m	82.82	92.33	91.87	75.18	87.44	92.23	89.12	87.38	87.67
Ours-m	92.65	92.83	93.16	93.02	93.10	93.55	93.08	93.17	93.07

除数值评估外，我们还对 AI 生成图像和摄影图像的似然分数进行了可视化比较。如图 4.1 所示，AI 生成图像的似然分数明显低于摄影图像。因此，可以通过设置固定阈值准确识别 AI 生成图像。

在 DRCT-2M 数据集上的比较。 DRCT-2M 的训练集同样采用 SDv1.4 子集。与 GenImage




图 4.1 AI 生成图像与摄影图像之间的似然分数分布。为增强可视化效果，将低于 -6000 的似然分数统一截断显示。

上的评估类似，我们在两种设置下对所提方法进行评估，具体实验结果见表 4.2。实验结果与 GenImage 上的结论一致：当测试集与训练集 SDv1.4 高度一致时，所有基准方法均取得了较高的准确率，而本文方法仍然表现最佳。

在这种情况下，微调对于最终检测性能至关重要。除 SDv2-DR 和 SDXL-DR 外，Ours-ft 在多种扩散模型上均取得了显著优势。SDv2-DR 和 SDXL-DR 是更具挑战性的测试集，其中的图像由扩散模型从真实图像而非随机噪声重建得到。有关召回率和精确率分析的更多实验结果见补充材料。

表 4.2 本文方法与基准方法在 DRCT-2M 数据集上的检测准确率对比。Ours-ft 能够以 100% 的召回率识别 DRCT-2M 前十个子集中的所有扩散生成图像。DRCT-2M 中的真实图像与 MSCOCO 中的摄影图像相同，因此检测准确率均为 97.13%。

Method	SD Variants					Turbo Variants			LCM Variants		ControlNet Variants			DR Variants			Avg.
	LDM	SDv1.4	SDv1.5	SDv2	SDXL	SDXL-Refiner	SD-Turbo	SDXL-Turbo	LCM-SDv1.5	LCM-SDXL	SDv1-Ctrl	SDv2-Ctrl	SDXL-Ctrl	SDv1-DR	SDv2-DR	SDXL-DR	
CNNSpot	99.87	99.91	99.90	97.55	66.25	86.55	86.15	72.42	98.26	61.72	97.96	85.89	82.84	60.93	51.41	50.28	81.12
F3Net	99.85	99.78	99.79	88.66	55.85	87.37	68.29	63.66	97.39	54.98	97.98	72.39	81.99	65.42	50.39	50.27	77.13
CLIP/RN50	99.00	99.99	99.96	94.61	62.08	91.43	83.57	64.40	98.97	57.43	99.74	80.69	82.03	65.83	50.67	50.47	80.05
GramNet	99.40	99.01	98.84	95.30	62.63	80.68	71.19	69.32	93.05	57.02	89.97	75.55	82.68	51.23	50.01	50.08	76.62
De-fake	92.10	99.53	99.51	89.65	64.02	69.24	92.00	93.93	99.13	70.89	58.98	62.34	66.66	50.12	50.16	50.00	75.52
Conv-B	99.97	100.00	99.97	95.84	64.44	82.00	80.82	60.75	99.27	62.33	99.80	83.40	73.28	61.65	51.79	50.41	79.11
UnivFD	98.30	96.22	96.33	93.83	91.01	93.91	86.38	85.92	90.44	88.99	90.41	81.06	89.06	51.96	51.03	50.46	83.46
DIRE	98.19	99.94	99.96	68.16	53.84	71.93	58.87	54.35	99.78	59.73	99.65	64.20	59.13	51.99	50.04	49.97	71.23
LNP	49.50	99.45	99.45	51.26	56.37	71.24	99.32	99.44	98.96	65.30	66.07	71.02	69.81	50.71	50.65	49.82	71.77
LGrad	96.79	97.87	97.93	87.80	54.52	77.07	98.11	98.20	97.80	59.75	94.58	92.93	90.67	49.44	49.36	49.44	80.70
NPR	94.92	97.73	97.78	82.96	67.52	79.72	95.81	95.85	97.68	80.32	94.45	92.96	90.22	49.24	49.41	49.01	83.63
DRCT	96.74	96.26	96.33	94.89	96.24	93.46	93.43	92.94	91.17	95.01	95.60	92.68	91.95	94.10	69.55	57.43	90.49
Ours-basic	97.37	97.60	97.54	97.65	97.64	97.67	97.62	97.42	97.61	97.64	50.33	50.14	52.43	92.75	52.31	50.08	82.74
Ours-ft	97.13	97.13	97.13	97.13	97.13	97.13	97.13	97.13	97.13	97.13	97.08	96.81	94.73	92.26	51.79	49.73	90.86

鲁棒性评估。在实际应用中，图像在社交媒体平台上传播时通常会经历 JPEG 压缩等良性后处理。因此，AI 生成图像检测方法应当能够抵御此类后处理的影响。我们采用 JPEG 压缩和下采样两种常见后处理方式评估本文方法的鲁棒性。

直观而言，这些后处理通常不会影响图像的视觉内容，但可能改变图像的低层特征，从而导致检测性能下降。我们选择性能与本文方法最为接近的 DRCT 作为对比方法。JPEG 压

缩的质量因子 (QF) 从 100 变化至 70。对于下采样, 我们将图像分辨率缩小为原始尺寸的 r 倍, 其中 r 的取值范围为 0.9 至 0.5。

图 4.2 展示了 GenImage 数据集上的实验结果。尽管本文方法性能会随着图像失真程度的增加而下降, 但在所有设置下均优于 DRCT。




图 4.2 本文方法与 DRCT 的鲁棒性对比。实验采用 GenImage 中八种生成模型的平均检测准确率作为评价指标。

跨数据库泛化比较。为了进一步验证本文方法的泛化能力, 我们进行了跨数据库评估, 即使用 DRCT-2M 训练集训练检测器, 并在 GenImage 数据集上评估检测性能。我们使用 DRCT-2M 训练集中的真实图像 (MSCOCO) 对摄影图像的低层特征分布进行建模。如前所述, DRCT-2M 和 GenImage 中的真实图像分别来源于 MSCOCO 和 ImageNet。

表 4.1 展示了跨数据库评估结果。在这种设置下, 本文方法性能仅略有下降。该实验表明, 即使测试集中的真实图像 (ImageNet) 与训练集中的真实图像 (MSCOCO) 来源不同, 本文方法仍能正确地将 ImageNet 图像判定为真实图像, 同时准确识别 GenImage 中的 AI 生成图像。

在其他生成模型上的检测。由于本文的低层特征提取器使用预训练潜空间扩散模型 Stable Diffusion v1.4 进行训练, 因此还需评估其对其他生成器的泛化能力, 包括非潜空间扩散模型、流模型和 GAN。该实验旨在证明, 本文特征提取器识别的是图像的通用低层特征, 而非过拟合 Stable Diffusion 的特定伪迹。

表 4.3 展示了不同生成模型对应的 AI 生成图像召回率。本文使用的高斯混合模型在 MSCOCO 真实摄影图像上训练。似然分数低于阈值的图像被判定为 AI 生成图像, 阈值则根据训练集中摄影图像的似然分数确定。

我们采用 DRCT 作为基准方法, 该方法在检测器训练阶段同样使用了预训练的 SDv1.4。实验结果表明, 本文方法能够成功识别几乎所有 AI 生成图像。这些图像的似然分数均明显低于为摄影图像设定的阈值。

表 4.3 其他生成模型上的检测性能（召回率）。具体阈值为 -621.73 。97-P 和 75-P 分别表示测试集中排名前 97% 和前 75% 的似然分数。

	DRCT	Ours	97-P	75-P
DDPM ^[12]	83.43	99.97	-12869	-30540
GLOW ^[7]	100	99.95	-56310	-121336
StarGAN ^[53]	99.9	99.95	-277178	-385297
StyleGAN2 ^[54]	83.53	75.52	2187	-4047
GauGAN ^[55]	72.08	99.98	-60665	-128474
DALLE2 ^[56]	89.53	99.90	-17384	-47721

4.3 消融实验

我们首先分析预训练任务与 AI 生成图像检测准确率之间的关系。图 4.3 展示了特征提取器在训练过程中预训练任务的损失值和检测准确率。结果表明，这两个任务之间存在较强的相关性。随着训练周期的推进，特征提取器辨别低层特征的能力逐渐增强，从而提高了检测准确率。

表 4.4 预训练任务的消融研究。“w/o Reg” 和 “w/o Cls” 分别表示移除回归学习和分类学习。

	Ours	w/o Reg	w/o Cls	BF-CNN	ADM
Midjourney	95.51	94.58	94.34	70.31	65.42
SDv1.4	96.06	95.15	95.99	60.30	89.69
SDv1.5	96.33	95.11	96.04	60.32	90.03
ADM	95.88	94.91	95.63	96.35	94.33
Glide	96.00	94.83	95.93	96.90	65.24
Wukong	96.36	95.22	96.14	69.20	92.73
VQDM	95.59	94.80	95.78	87.01	91.82
BigGAN	95.71	94.59	95.46	85.92	87.65
Avg.	95.97	94.90	95.66	78.36	84.61




图 4.3 预训练任务与 AI 生成图像检测之间的关系。

随后，我们对低层特征提取器的构建进行分析。在特征提取器的训练阶段，我们利用预

训练的 Stable Diffusion 作为现成的去噪工具，生成多对仅在像素级别上存在差异的相似图像。我们采用两种替代去噪工具：一种是用于去除常见高斯噪声的预训练 CNN 去噪网络 BF-CNN^[57]，另一种是早期扩散模型 ADM^[10]。

我们在原始图像的空间域中引入不同强度的高斯噪声，并分别使用预训练的 BF-CNN 和 ADM 获得相应的去噪图像。实验结果见表 4.4。尽管这两种去噪工具的效果不如本文方法，但它们仍表现出一定的有效性。我们推测，BF-CNN 和 ADM 的去噪能力不如 Stable Diffusion，这导致原始图像与恢复图像之间存在像素级差异之外的显著差异。因此，特征提取器无法有效学习图像的低层特征

对于预训练任务的目标函数，我们采用交叉熵损失和回归损失。表 4.4 展示了这两部分的消融实验结果。仅依靠回归学习或仅依靠噪声分类学习的方法均能有效检测 AI 生成图像。无论采用回归学习还是噪声分类学习，特征提取器都能够关注图像的像素级差异。不过，将回归学习和分类学习相结合的效果略优于单独使用其中任何一种。

关于用于特征分布估计的摄影图像数量、高斯分量数量以及阈值设置的更多消融实验结果见补充材料。

第五章 结论

本文提出了一种新的低层图像特征提取器，用于捕捉图像之间的像素级差异。该特征提取器的核心在于预训练任务的设计。我们利用预训练扩散模型作为去噪工具，生成多组仅在像素级别存在差异的原始图像与去噪图像对。

预训练的特征提取器将空间域图像映射至一个具有良好区分性的特征空间。在该空间中，不同来源的图像，包括真实摄影图像和 AI 生成图像，呈现出不同的特征分布。受特征可分离性的启发，我们将 AI 生成图像检测视为一个单分类任务，并通过高斯混合模型对真实摄影图像的特征分布进行建模。因此，低层特征偏离所估计分布的图像将被判定为 AI 生成图像。

大量实验结果表明，本文方法能够有效识别由多种生成模型生成的 AI 图像，并具有良好的泛化能力。

参考文献

- [1] Van der Maaten L, Hinton G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9(11).
- [2] Midjourney. Midjourney[M]. [S.l.: s.n.], 2023.
- [3] Nichol A, Dhariwal P, Ramesh A, et al. GLIDE: Towards photorealistic image generation and editing with text-guided diffusion models[C]. International Conference on Machine Learning. [S.l.: s.n.], 2022: 16784–16804.
- [4] Rombach R, Blattmann A, Lorenz D, et al. High-resolution image synthesis with latent diffusion models[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2022: 10684–10695.
- [5] Kingma D P, Salimans T, Jozefowicz R, et al. Improved variational inference with inverse autoregressive flow [C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2016: 4743–4751.
- [6] Kingma D P, Welling M. Auto-encoding variational bayes[C]. International Conference on Learning Representations. [S.l.: s.n.], 2014.
- [7] Kingma D P, Dhariwal P. Glow: Generative flow with invertible 1x1 convolutions[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2018: 10215–10224.
- [8] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2014: 2672–2680.
- [9] Karras T, Aila T, Laine S, et al. Progressive growing of GANs for improved quality, stability, and variation [C]. International Conference on Learning Representations. [S.l.: s.n.], 2018.
- [10] Dhariwal P, Nichol A. Diffusion models beat GANs on image synthesis[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2021: 8780–8794.
- [11] Gu S, Chen D, Bao J, et al. Vector quantized diffusion model for text-to-image synthesis[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2022: 10696–10706.
- [12] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2020: 6840–6851.
- [13] Cazenavette G, Sud A, Leung T, et al. Fakeinversion: Learning to detect images from unseen text-to-image models by inverting stable diffusion[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2024: 10759–10769.
- [14] Luo Y, Du J, Yan K, et al. LaRE2: Latent reconstruction error based method for diffusion-generated image detection[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2024: 17006–17015.
- [15] Ma R, Duan J, Kong F, et al. Exposing the fake: Effective diffusion-generated images detection[J]. arXiv preprint arXiv:2307.06272, 2023.
- [16] Wang S Y, Wang O, Zhang R, et al. CNN-generated images are surprisingly easy to spot... for now[C].

- IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2020: 8695–8704.
- [17] Wang Z, Bao J, Zhou W, et al. DIRE for diffusion-generated image detection[C]. IEEE/CVF International Conference on Computer Vision. [S.l.: s.n.], 2023: 22445–22455.
- [18] Zhong N, Xu Y, Li S, et al. Patchcraft: Exploring texture patch for efficient AI-generated image detection[J]. arXiv preprint arXiv:2311.12397, 2023.
- [19] Tan C, Zhao Y, Wei S, et al. Learning on gradients: Generalized artifacts representation for GAN-generated images detection[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2023: 12105–12114.
- [20] Chalapathy R, Chawla S. Deep learning for anomaly detection: A survey[J]. arXiv preprint arXiv:1901.03407, 2019.
- [21] Chandola V, Banerjee A, Kumar V. Anomaly detection: A survey[J]. ACM Computing Surveys, 2009, 41(3): 1–58.
- [22] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision [C]. International Conference on Machine Learning. [S.l.: s.n.], 2021: 8748–8763.
- [23] Lukas J, Fridrich J, Goljan M. Digital camera identification from sensor pattern noise[J]. IEEE Transactions on Information Forensics and Security, 2006, 1(2): 205–214.
- [24] Zheng C, Shrivastava A, Owens A. Exif as language: Learning cross-modal associations between images and camera metadata[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2023: 6945–6956.
- [25] Huh M, Liu A, Owens A, et al. Fighting fake news: Image splice detection via learned self-consistency[C]. European Conference on Computer Vision. [S.l.: s.n.], 2018: 101–117.
- [26] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations[C]. International Conference on Learning Representations. [S.l.: s.n.], 2021.
- [27] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2009: 248–255.
- [28] Song Y, Dhariwal P, Chen M, et al. Consistency models[C]. International Conference on Machine Learning. [S.l.: s.n.], 2023: 32211–32252.
- [29] Li Y, Wang H, Jin Q, et al. SnapFusion: Text-to-image diffusion model on mobile devices within two seconds [C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2024: 20662–20678.
- [30] Zhao S, Chen D, Chen Y C, et al. Uni-ControlNet: All-in-one control to text-to-image diffusion models[C]. Advances in Neural Information Processing Systems. [S.l.: s.n.], 2024: 11127–11150.
- [31] Popescu A C, Farid H. Exposing digital forgeries by detecting traces of resampling[J]. IEEE Transactions on Signal Processing, 2005, 53(2): 758–767.
- [32] Popescu A C, Farid H. Exposing digital forgeries in color filter array interpolated images[J]. IEEE Transactions on Signal Processing, 2005, 53(10): 3948–3959.

- [33] O'Brien J F, Farid H. Exposing photo manipulation with inconsistent reflections[J]. *ACM Transactions on Graphics*, 2012, 31(1): 4:1–4:11.
- [34] Frank J, Eisenhofer T, Schönherr L, et al. Leveraging frequency analysis for deep fake image recognition[C]. *International Conference on Machine Learning*. [S.l.: s.n.], 2020: 3247–3258.
- [35] Liu B, Yang F, Bi X, et al. Detecting generated images by real images[C]. *European Conference on Computer Vision*. [S.l.: s.n.], 2022: 95–110.
- [36] Chen B, Zeng J, Yang J, et al. DRCT: Diffusion reconstruction contrastive training towards universal detection of diffusion generated images[C]. *International Conference on Machine Learning*. [S.l.: s.n.], 2024.
- [37] Shen S, Li L H, Tan H, et al. How much can CLIP benefit vision-and-language tasks?[J]. *arXiv preprint arXiv:2107.06383*, 2021.
- [38] Ojha U, Li Y, Lee Y J. Towards universal fake image detectors that generalize across generative models[C]. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2023: 24480–24489.
- [39] Durall R, Keuper M, Keuper J. Watch your up-convolution: CNN based generative deep neural networks are failing to reproduce spectral distributions[C]. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2020: 7890–7899.
- [40] Song J, Meng C, Ermon S. Denoising diffusion implicit models[J]. *arXiv preprint arXiv:2010.02502*, 2020.
- [41] Reynolds D. Gaussian mixture models[M]. *Encyclopedia of Biometrics*. [S.l.: s.n.], 2009: 659–663.
- [42] Moon T K. The expectation-maximization algorithm[J]. *IEEE Signal Processing Magazine*, 1996, 13(6): 47–60.
- [43] Thomee B, Shamma D A, Friedland G, et al. YFCC100M: The new data in multimedia research[J]. *Communications of the ACM*, 2016, 59(2): 64–73.
- [44] Zhu M, Chen H, Yan Q, et al. GenImage: A million-scale benchmark for detecting AI-generated image[C]. *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2023: 77771–77782.
- [45] Zhang L, Rao A, Agrawala M. Adding conditional control to text-to-image diffusion models[C]. *IEEE/CVF International Conference on Computer Vision*. [S.l.: s.n.], 2023: 3836–3847.
- [46] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context[C]. *European Conference on Computer Vision*. [S.l.: s.n.], 2014: 740–755.
- [47] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]. *International Conference on Learning Representations*. [S.l.: s.n.], 2021.
- [48] Qian Y, Yin G, Sheng L, et al. Thinking in frequency: Face forgery detection by mining frequency-aware clues [C]. *European Conference on Computer Vision*. [S.l.: s.n.], 2020: 86–103.
- [49] Liu Z, Qi X, Torr P H S. Global texture enhancement for fake face detection in the wild[C]. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2020: 8060–8069.
- [50] Sha Z, Li Z, Yu N, et al. De-fake: Detection and attribution of fake images generated by text-to-image generation models[C]. *2023 ACM SIGSAC Conference on Computer and Communications Security*. [S.l.: s.n.],

2023: 3418–3432.

- [51] Liu Z, Mao H, Wu C Y, et al. A ConvNet for the 2020s[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2022: 11976–11986.
- [52] Tan C, Zhao Y, Wei S, et al. Rethinking the up-sampling operations in CNN-based generative network for generalizable deepfake detection[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2024: 28130–28139.
- [53] Choi Y, Choi M, Kim M, et al. StarGAN: Unified generative adversarial networks for multi-domain image-to-image translation[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2018: 8789–8797.
- [54] Karras T, Laine S, Aila T. A style-based generator architecture for generative adversarial networks[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2019: 4401–4410.
- [55] Park T, Liu M Y, Wang T C, et al. Semantic image synthesis with spatially-adaptive normalization[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2019: 2337–2346.
- [56] Ramesh A, Dhariwal P, Nichol A, et al. Hierarchical text-conditional image generation with CLIP latents[J]. arXiv preprint arXiv:2204.06125, 2022.
- [57] Mohan S, Kadkhodaie Z, Simoncelli E P, et al. Robust and interpretable blind image denoising via bias-free convolutional neural networks[J]. arXiv preprint arXiv:1906.05478, 2019.